Agente Estadístico de Wald para Decisiones Crediticias

Implementación en LangGraph de un meta-selector Bayes–Minimax

Lab F.7 — Capítulo 7

19 de junio de 2026

Índice

1. Introducción **2**

2. Arquitectura del grafo (DAG) **2**

3. Descripción de los nodos **3**

3.1. Nodo 1: Observar (`observar`) . . . 3
3.2. Nodo 2: Posterior (`make_posterior_node`) . . . 3
3.3. Nodo 3: Riesgo Bayesiano (`riesgo_bayes`) . . . 3
3.4. Nodo 4: Riesgo Minimax (`riesgo_minimax`) . . . 4
3.5. Nodo 5: Meta-selector (`meta_selector`) . . . 4

4. Verificación empírica **4**

5. Validación teórica (tests) **5**

6. Configuración y parametrización **6**

1. Introducción

Este documento describe un agente de decisión estadística que implementa la **teoría de Wald** del Capítulo 7 para la aprobación de solicitudes crediticias. El agente combina tres estrategias de decisión:

1. **Regla de Bayes**: minimiza el riesgo esperado condicional a los datos observados.
2. **Regla Minimax**: minimiza la peor pérdida posible sobre un intervalo de credibilidad posterior.
3. **Escalación a humano**: deriva la decisión a un analista cuando la incertidumbre epistémica es demasiado alta y las reglas discrepan.

Un **meta-selector** elige entre estas tres basándose en la entropía de la distribución posterior y en el acuerdo entre las dos reglas automáticas. El agente está implementado como un grafo acíclico dirigido (DAG) en LangGraph, donde cada nodo es una función pura sobre el estado del agente.

Convención de pérdida (Statlog)

La matriz de pérdida sigue la convención del dataset *German Credit* de Statlog, donde clasificar a un solicitante moroso como bueno es 5 veces más costoso que clasificar a uno bueno como moroso:

$$L(\theta, a) = \begin{array}{c|ccc} \theta \backslash a & \text{accept} & \text{reject} & \text{escalate} \\ \hline \text{Pagador} & 0 & 1 & 1{,}5 \\ \text{Moroso} & 5 & 0 & 1{,}5 \end{array} \tag{1}$$

La acción `escalate` tiene un costo fijo de 1.5, superior al riesgo máximo de las reglas puras ($\max_{p\in[0,1]} \min(5p, 1-p) = 5/6 \approx 0{,}833$), lo que garantiza que está **estrictamente dominada** para cualquier $p \in [0, 1]$. Solo el meta-selector puede activarla.

2. Arquitectura del grafo (DAG)

El agente se compone de cinco nodos funcionales encadenados secuencialmente. Cada nodo recibe el estado completo del agente y devuelve una actualización parcial que LangGraph fusiona automáticamente.

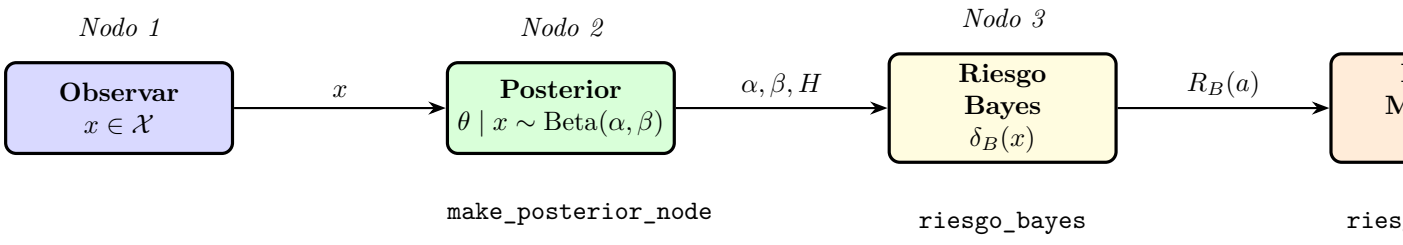


Figura 1: Grafo acíclico dirigido (DAG) del agente de Wald. Cada nodo es una función pura `AgentState` → `AgentState`. Las variables que fluyen entre nodos se indican sobre las aristas.

Estructura del estado

El estado del agente se define como un `TypedDict` con los siguientes campos:

- `applicant_id`, `x`, `y_true`: entrada.
- `p_hat`, `alpha`, `beta`, `entropy_norm`: posterior.
- `bayes_risk`, `minimax_risk`: riesgos por acción.
- `bayes_action`, `minimax_action`, `chosen_action`, `rule_used`, `realised_loss`: decisión.

3. Descripción de los nodos

3.1. Nodo 1: Observar (`observar`)

Recibe el vector de atributos $x \in \mathcal{X}$ del solicitante. En la implementación actual, x es inyectado directamente en el estado por el *runner* externo. El nodo valida que el campo `x` exista y retorna una actualización vacía.

3.2. Nodo 2: Posterior (`make_posterior_node`)

Convierte la salida $p = \hat{P}(\text{bad} \mid x)$ de un clasificador (regresión logística) en una distribución Beta que representa la creencia posterior sobre $\theta = P(\text{bad} \mid x)$:

$$\theta \mid x \sim \text{Beta}(\alpha, \beta), \qquad \alpha = \kappa \cdot p, \quad \beta = \kappa \cdot (1 - p), \tag{2}$$

donde κ es un hiperparámetro de concentración (`POSTERIOR_KAPPA`) que controla la agudeza de la posterior. Valores grandes de κ producen una distribución más concentrada (menos incertidumbre epistémica); valores pequeños la ensanchan.

Este *moment-matching* es una aproximación deliberada (el truco de Laplace–Beta) que evita el costo de una regresión logística Bayesiana completa, manteniendo la estructura de Wald manejable.

Además de la media p y los parámetros (α, β), el nodo calcula la entropía normalizada de la Beta:

$$H_{\text{norm}} = \exp\big(H_{\text{Beta}}(\alpha, \beta)\big) \in [0, 1], \tag{3}$$

donde H_{Beta} es la entropía diferencial de la Beta en nats. $H_{\text{norm}} = 1$ corresponde a $\text{Beta}(1, 1)$ (máxima incertidumbre, distribución uniforme), y $H_{\text{norm}} \to 0$ cuando la distribución se degenera en un punto (certeza total).

3.3. Nodo 3: Riesgo Bayesiano (`riesgo_bayes`)

Calcula el riesgo esperado para cada acción $a \in \mathcal{A}$ bajo la creencia posterior actual:

$$R_B(a) = \mathbb{E}_{\theta|x}[L(\theta, a)] = p \cdot L(\text{bad}, a) + (1 - p) \cdot L(\text{good}, a) \tag{4}$$

La regla de Bayes es el argumento minimizador:

$$\delta_B(x) = \arg\min_{a \in \mathcal{A}} R_B(a) \tag{5}$$

Para la matriz de Statlog, el umbral de decisión cerrado entre aceptar y rechazar es:

$$\theta^* = \frac{L(\text{good}, \text{reject})}{L(\text{good}, \text{reject}) + L(\text{bad}, \text{accept})} = \frac{1}{1 + 5} = \frac{1}{6} \approx 0{,}1667 \tag{6}$$

Si $p < 1/6$ la regla de Bayes acepta; si $p > 1/6$ rechaza. La acción `escalate` nunca es seleccionada porque su costo 1,5 excede el riesgo mínimo de las otras dos acciones para cualquier p.

3.4. Nodo 4: Riesgo Minimax (`riesgo_minimax`)

En lugar de usar un único p, construye un **intervalo de credibilidad** central al $(1-\gamma)\,\%$ sobre la posterior Beta y calcula el riesgo en el peor caso:

$$p_{\text{lo}} = F^{-1}_{\text{Beta}}\left(\tfrac{\gamma}{2}; \alpha, \beta\right), \tag{7}$$

$$p_{\text{hi}} = F^{-1}_{\text{Beta}}\left(1-\tfrac{\gamma}{2}; \alpha, \beta\right), \tag{8}$$

$$R_M(a) = \sup_{p \in [p_{\text{lo}}, p_{\text{hi}}]} \left[p \cdot L(\text{bad}, a) + (1-p)\cdot L(\text{good}, a)\right]. \tag{9}$$

Dado que el riesgo esperado es **lineal** en p, el supremo se alcanza necesariamente en uno de los dos extremos del intervalo:

$$R_M(a) = \max\left(R_B(p_{\text{lo}}; a),\ R_B(p_{\text{hi}}; a)\right) \tag{10}$$

Esto se verifica experimentalmente en el test `test_worst_case_at_endpoints`. La regla minimax es:

$$\delta_M(x) = \arg\min_{a \in \mathcal{A}} R_M(a) \tag{11}$$

Por construcción, δ_M es **más conservadora** que δ_B: rechaza al menos con la misma frecuencia (test `test_minimax_is_more_conservative_than_bayes`).

3.5. Nodo 5: Meta-selector (`meta_selector`)

Selecciona entre las tres estrategias basándose en dos criterios:

1. **Entropía posterior** H_{norm}: cuantifica la incertidumbre epistémica.
2. **Acuerdo entre reglas**: si $\delta_B(x) = \delta_M(x)$ o no.

La lógica de decisión es la siguiente:

- **Entropía baja** ($H < \tau_{\text{mm}}$): se confía en la regla de Bayes (eficiente).
- **Entropía alta** ($H \geq \tau_{\text{mm}}$): se usa la regla minimax (robusta).
- **Entropía muy alta y desacuerdo** ($H \geq \tau_{\text{esc}}$ y $\delta_B \neq \delta_M$): se escala a un analista humano.

Los umbrales τ_{mm} y τ_{esc} están definidos en `config.py` y son editables.

4. Verificación empírica

Configuración experimental

- Dataset: German Credit (Statlog), 1000 filas, 20 atributos, 31.4 % morosos.
- Clasificador base: regresión logística con pipeline (StandardScaler + OneHotEncoder).
- Split: 80/20 estratificado, semilla 42.
- Concentración posterior: $\kappa = 5$ (baja, para activar el meta-selector).

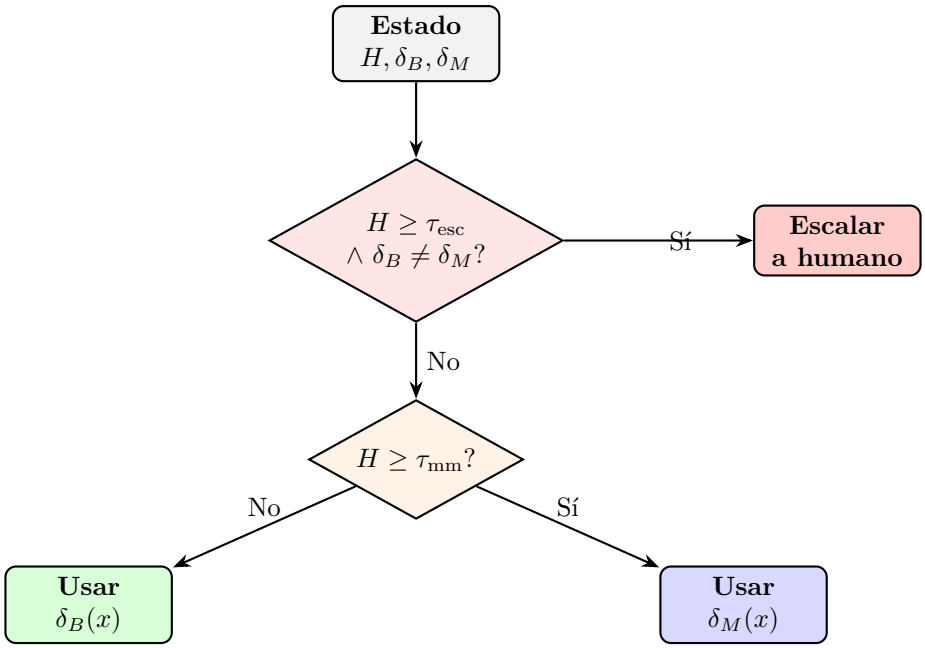


Figura 2: Árbol de decisión del meta-selector. $\tau_{\text{esc}} = 0{,}65$, $\tau_{\text{mm}} = 0{,}45$ con los parámetros actuales.

Métrica	**Valor**
Precisión (train)	0.748
Precisión (test)	0.740
Umbral Bayes cerrado	$1/6 \approx 0{,}1667$
$p_{\text{máx}}$ aceptados	0.1665
$p_{\text{mín}}$ rechazados	0.1667

Tabla 1: La coincidencia entre el umbral cerrado y el observado (0,1665/0,1667) verifica empíricamente el Teorema de Bayes.

Resultados

Distribución de entropía

Con $\kappa = 5$, la entropía normalizada tiene media 0,52 y alcanza hasta 0,82. El meta-selector asigna 129 casos a minimax y 71 a Bayes. La ruta de escalación no se activa porque las condiciones de alta entropía y desacuerdo entre reglas están **anti-correlacionadas**: la entropía es máxima cuando $p \approx 0{,}5$ (ambas reglas coinciden en rechazar), y el desacuerdo ocurre cerca del umbral $p \approx 1/6$ donde la entropía es moderada.

5. Validación teórica (tests)

Los 7 tests de cordura verifican propiedades fundamentales:

1. **Umbral de Bayes**: coincide con $1/6$ (test 1).
2. **Frontera de decisión**: $p < 1/6 \rightarrow$ accept, $p > 1/6 \rightarrow$ reject (test 2).
3. **Minimax es más conservador**: rechaza al menos tantos como Bayes (test 3).
4. **Escalación bajo desacuerdo + alta entropía**: el meta-selector escala (test 4).

Regla	Pérdida total
Always-accept	315.00
Always-reject	137.00
Bayes puro	140.00
Minimax puro	134.00
Meta-selector	140.00

Tabla 2: Pérdida total realizada sobre 200 solicitudes de test. Minimax supera a Bayes en esta ejecución (efecto de muestra finita).

	Minimax	
Bayes	accept	reject
accept	9	60
reject	0	131

Tabla 3: Tabla de contingencia entre reglas. En 60 casos (30 %) discrepan: Bayes acepta donde minimax rechaza.

5. **Bayes bajo certeza**: con entropía baja, usa Bayes (test 5).
6. **Linealidad del riesgo**: $\mathbb{E}[L \mid p, a]$ es lineal en p (test 6).
7. **Peor caso en extremos**: $\sup_{[p_{\text{lo}}, p_{\text{hi}}]}$ se alcanza en un extremo (test 7).

6. Configuración y parametrización

Todos los parámetros editables residen en `config.py`:

Parámetro	**Default**	**Efecto**
`SEED`	42	Reproducibilidad
`POSTERIOR_KAPPA`	5.0	Concentración Beta
`ENTROPY_THRESHOLD`	0.45	Activación de minimax
`ESCALATE_ENTROPY_THRESHOLD`	0.65	Activación de escalación
`MINIMAX_CRED_LEVEL`	0.90	Amplitud del intervalo
`LOSS[("bad","accept")]`	5.0	Asimetría 5:1
`TEST_SIZE`	0.20	Proporción de test

Tabla 4: Parámetros editables del agente.

Conexión con el Capítulo 8 (MDPs)

Cada decisión individual constituye un MDP de un paso donde $\mathcal{R}(\theta, \delta) = -V^{\pi}(s)$. El isomorfismo Wald–MDP del Capítulo 11 se manifiesta al extender este agente a decisiones secuenciales (préstamos renovables con observación posterior del desempeño del prestatario).