Planificación de un Agente Estadístico Determinístico sobre MDPs

DES504 — Capítulo 8

1 Motivación y marco conceptual

Un *agente estadístico determinístico* es la encarnación más simple y a la vez más traicionera del formalismo de Bellman. En cada estado observado $s \in \mathcal{S}$ elige siempre la misma acción $a = \pi(s)$, sin aleatoriedad alguna, y declara óptima esa política porque emerge de aplicar Value Iteration o Policy Iteration a un MDP supuesto conocido. La matemática es limpia: el operador de Bellman $\mathcal{T}^*$ es una contracción en norma ℓ_∞ con constante $\gamma < 1$, y por el teorema de Banach–Caccioppoli existe un único punto fijo V^* al que toda órbita converge geométricamente. Hasta aquí, la superficie luminosa del formalismo.

El problema aparece cuando se inspecciona la lista de supuestos sobre los que descansan esas garantías. La convergencia de Value Iteration es *condicional* a que el modelo (P, r) sea exacto; en la práctica, el agente opera con estimaciones $\widehat{P}$ y $\widehat{r}$ heredadas de datos históricos, y el error de estimación se amplifica por factores que crecen como $(1-\gamma)^{-1}$ o $(1-\gamma)^{-2}$ cuando γ se acerca a 1. A esto se suma el supuesto de suficiencia del espacio de estados, la estacionariedad de la dinámica y el overlap entre la política que generó los datos y la política que el agente pretende evaluar.

Este documento planifica, sección por sección, la construcción y el diagnóstico de tal agente. El énfasis no está en la elegancia de la recursión de Bellman, sino en identificar las grietas por donde se cuela el mundo real: cuándo una política óptima bajo el modelo deja de ser óptima bajo el fenómeno, y qué pruebas mínimas debe incorporar el diseñador antes de declarar inteligente a un optimizador.

2 Definición formal del agente

Definición 2.1 (Agente estadístico determinístico)**.** Un *agente estadístico determinístico* sobre un MDP $\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, r, \gamma)$ es una tupla $\mathfrak{A} = (\pi, V, \widehat{P}, \widehat{r}, \mathcal{D})$ donde:

- $\pi : \mathcal{S} \to \mathcal{A}$ es una *política estacionaria determinista*;
- $V \in \mathbb{R}^{|\mathcal{S}|}$ es la función de valor asociada a π;
- $\widehat{P}, \widehat{r}$ son las estimaciones del kernel de transición y de la recompensa obtenidas a partir de un conjunto de datos $\mathcal{D} = \{(s_i, a_i, r_i, s'_i)\}_{i=1}^{n}$;

- el agente elige, ante la observación s_t, la acción $a_t = \pi(s_t)$ sin aleatoriedad.

Definición 2.2 (Ecuación de Bellman para políticas)**.** Para una política π fija, la función de valor V^π satisface la ecuación lineal

$$V^\pi(s) \;=\; r\big(s,\pi(s)\big) + \gamma \sum_{s' \in \mathcal{S}} P\big(s' \mid s,\pi(s)\big)\, V^\pi(s'), \quad s \in \mathcal{S}.$$

Equivalentemente, V^π es el único punto fijo del operador $\mathcal{T}^\pi$ definido por

$$(\mathcal{T}^\pi V)(s) := r\big(s,\pi(s)\big) + \gamma \sum_{s'} P\big(s' \mid s,\pi(s)\big)\, V(s').$$

El operador $\mathcal{T}^\pi$ es una contracción de módulo γ en $\|\cdot\|_\infty$ (la demostración es la del operador óptimo sin el $\max_a$, que desaparece). Por Banach–Caccioppoli, V^π existe y es único; además, la sucesión $V_{k+1} = \mathcal{T}^\pi V_k$ converge a V^π con cota a priori $\|V_k - V^\pi\|_\infty \le \dfrac{\gamma^k}{1-\gamma}\,\|V_1 - V_0\|_\infty$.

La política óptima π^* se obtiene, en el caso tabular, mediante Value Iteration: iterar $V_{k+1} = \mathcal{T}^* V_k$ hasta convergencia y declarar $\pi^*(s) \in \arg\max_a \{r(s,a) + \gamma \sum_{s'} P(s' \mid s,a) V_k(s')\}$. Lo que sigue analiza qué pasa cuando, en lugar de P y r verdaderos, el agente usa $\widehat{P}$ y $\widehat{r}$.

3 Supuestos operativos

La garantía de optimalidad del agente determinístico se sostiene sobre cuatro supuestos. Ninguno es gratuito; todos merecen una prueba explícita antes de declarar operativo al agente.

3.1 Suficiencia del espacio de estados (Markov)

La propiedad de Markov,

$$P\big(S_{t+1} = s' \mid S_0, A_0, \ldots, S_t, A_t\big) = P\big(s' \mid S_t, A_t\big),$$

no es una propiedad del mundo sino de la representación de estado elegida por el diseñador. Un proceso físicamente Markoviano, observado a través de un sensor con ruido o de una proyección deliberada, deja de ser Markov en el espacio de observaciones. La pregunta operativa es: £mi estado $\mathcal{S}$ es suficiente en el sentido estadístico clásico? Si la respuesta es negativa, todo el aparato de Value Iteration se aplica a un operador equivocado y la política resultante puede ser subóptima en el sistema real.

3.2 Conocimiento exacto de P y r

La convergencia geométrica de VI con cota $\dfrac{R_{\max}}{1-\gamma}$ asume que $\mathcal{T}^*$ se construye con el verdadero P y el verdadero r. En la práctica, el agente dispone de $\widehat{P}$ y $\widehat{r}$ estimados

por frecuencia relativa o por un modelo paramétrico. El error de estimación se propaga al punto fijo con una sensibilidad que crece como $\frac{\gamma}{(1-\gamma)^2}$ para V^*, lo que se traduce en una amplificación dramática cuando $\gamma \to 1$.

3.3 Estacionariedad

La dinámica $P(\cdot \mid s, a)$ se supone constante en el tiempo. Si el entorno es no estacionario (por ejemplo, protocolos clínicos que cambian con las guías, poblaciones que evolucionan, deriva demográfica), la política óptima computada sobre datos históricos deja de ser óptima para el presente. La estacionariedad es un supuesto de diseño, no una verificación trivial: requiere tests de cambio estructural y, en su defecto, ventanas deslizantes o modelos de tiempo variante.

3.4 Overlap con la política de comportamiento

Si los datos $\mathcal{D}$ provienen de una política de comportamiento π_b, el agente solo puede estimar $\widehat{P}(s' \mid s, a)$ y $\widehat{r}(s, a)$ de manera fiable en los pares (s, a) que π_b visitó con probabilidad no despreciable. Si la política objetivo π pone masa en una acción que π_b nunca tomó en cierto estado, no hay forma —ni estadística ni causal— de identificar $Q(s, a)$ para esa acción. Este es el supuesto de *overlap*, central en Off-Policy Evaluation, y su ausencia invalida por completo al agente.

4 Arquitectura del agente

La Figura 1 muestra el pipeline del agente. El flujo es cíclico: observación, decisión, transición, actualización del modelo y, periódicamente, replanificación. La asimetría clave es que la replanificación con $\widehat{P}$ hereda todos los sesgos de $\mathcal{D}$.

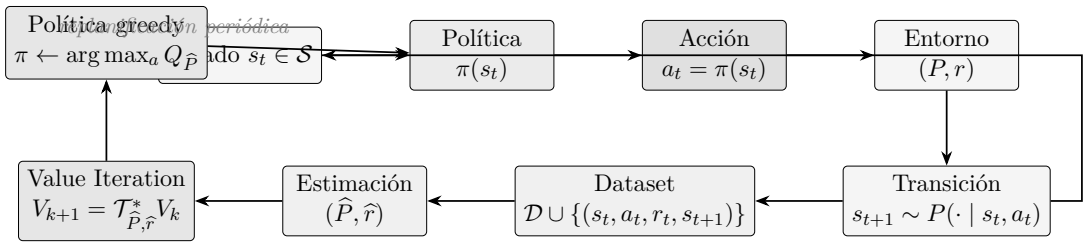


Figure 1: Pipeline del agente estadístico determinístico. El bloque *Value Iteration* es el único componente con garantía de convergencia certificada; los bloques de *Estimación* y *Dataset* heredan los sesgos de π_b y de la representación de estado. La flecha de retroalimentación cierra el ciclo entre transición y siguiente estado.

El ciclo opera en dos escalas de tiempo distintas. En la escala corta (paso a paso), el agente observa, decide con la política actual y actualiza el dataset. En la escala larga (replanificación), reestima $(\widehat{P}, \widehat{r})$, itera Value Iteration hasta satisfacer el criterio de parada $\|V_{k+1} - V_k\|_\infty < \varepsilon_{\text{stop}}$ y recalcula π como política greedy respecto al último V_k.

La separación entre ambas escalas es un parámetro de diseño crítico: replanificar en cada paso es caro y puede introducir inestabilidad; replanificar muy rara vez conduce a políticas obsoletas si la distribución de datos cambia. Una heurística razonable es replanificar cuando el tamaño del dataset se ha duplicado o cuando un test de estacionariedad sobre $\widehat{P}$ detecta deriva significativa.

5 Algoritmo determinista

Teorema 5.1 (Value Iteration con modelo estimado)**.** *Sea $\widehat{\mathcal{T}}^*$ el operador de Bellman construido con $(\widehat{P}, \widehat{r})$. Bajo los supuestos de la Sección 3, $\widehat{\mathcal{T}}^*$ es una contracción de módulo γ en $\|\cdot\|_\infty$ y posee un único punto fijo $\widehat{V}^* \in \mathbb{R}^{|\mathcal{S}|}$. La sucesión $V_{k+1} = \widehat{\mathcal{T}}^* V_k$ converge geométricamente:*

$$\left\| V_k - \widehat{V}^* \right\|_\infty \;\leq\; \frac{\gamma^k}{1-\gamma}\, \|V_1 - V_0\|_\infty .$$

Proof. La demostración es idéntica a la del operador verdadero $\mathcal{T}^*$: el argumento de contracción solo usa que $\widehat{P}(\cdot \mid s,a)$ es una distribución de probabilidad y que $\widehat{r}$ está acotada, propiedades que se heredan del estimador. El teorema de Banach–Caccioppoli se aplica sin modificaciones. □

El subtítulo "con modelo estimado" es engañoso: el teorema garantiza convergencia *al punto fijo del modelo estimado*, no al punto fijo verdadero. La distancia entre ambos es el verdadero objeto de interés y no se controla con la cota a priori del Teorema 5.1.

5.1 Política greedy derivada

Una vez que V_k satisface el criterio de parada, se define la política determinista

$$\pi_{\mathrm{gr}}(s) \;\in\; \arg\max_{a \in \mathcal{A}} \Big\{ \widehat{r}(s,a) + \gamma \sum_{s'} \widehat{P}(s' \mid s,a)\, V_k(s') \Big\}, \quad s \in \mathcal{S}.$$

Por el teorema de la política ε-óptima,

$$\left\| V^{\pi_{\mathrm{gr}}} - \widehat{V}^* \right\|_\infty \;\leq\; \frac{2\gamma}{1-\gamma} \left\| V_k - \widehat{V}^* \right\|_\infty ,$$

de modo que el error en valor se amplifica por un factor $\dfrac{2\gamma}{1-\gamma}$ al traducirse en política. Para $\gamma = 0.99$, este factor es 198: un error de valor de 0.01 se convierte en un error de política de hasta 1.98, lo que destruye cualquier garantía práctica si no se controla Δ_k con suficiente holgura.

5.2 Criterio de parada recomendado

Para garantizar un error de política (respecto al modelo estimado) menor que ε_π, basta iterar hasta

$$\|V_{k+1} - V_k\|_\infty \;<\; \frac{(1-\gamma)^2\, \varepsilon_\pi}{4\gamma^2},$$

que es la versión combinada del criterio a priori y del factor de amplificación. Para γ cercano a 1, esto exige iteraciones del orden de $(1-\gamma)^{-1}\log(1/\varepsilon_\pi)$, lo que puede ser computacionalmente prohibitivo pero es el precio formal de la garantía.

5.3 Ejemplo numérico ilustrativo

Considérese un MDP con dos estados $\mathcal{S} = \{s_1, s_2\}$ y dos acciones $\mathcal{A} = \{a_1, a_2\}$, con $\gamma = 0.9$, recompensas $r(s_1, a_1) = 1$, $r(s_1, a_2) = 0$, $r(s_2, a_1) = r(s_2, a_2) = 0$, y kernel

$$P(\cdot \mid s_1, a_1) = (0.5, 0.5), \quad P(\cdot \mid s_1, a_2) = (1, 0),$$

$$P(\cdot \mid s_2, a_1) = (0.8, 0.2), \quad P(\cdot \mid s_2, a_2) = (0, 1).$$

Tomando $V_0 \equiv 0$, las primeras iteraciones de Value Iteration son

$$V_1 = (1, 0), \quad V_2 = (1.45, 0), \quad V_3 = (1.6525, 0), \quad V_4 = (1.7436, 0),$$

y el punto fijo es $V^* = \left(\frac{1}{1-0.45}, 0\right) \approx (1.818, 0)$. El error decae geométricamente: $\|V_k - V^*\|_\infty \le \dfrac{0.9^k}{0.1}\|V_1 - V_0\|_\infty = 10 \cdot 0.9^k$. Para $\varepsilon = 0.01$ se obtiene $k_\varepsilon = \lceil \log(0.001)/\log(1/0.9) \rceil = 66$ iteraciones.

Este ejemplo mínimo ilustra tres puntos. Primero, la convergencia es efectivamente geométrica pero el prefactor $\|V_1 - V_0\|_\infty/(1-\gamma)$ puede ser grande: aquí vale 10, de modo que la cota a priori es muy generosa respecto al error real. Segundo, la política greedy extraída de V_k coincide con π^* desde $k = 1$ en este caso sencillo, pero esto *no* es general: cuando dos acciones tienen valores cercanos, la amplificación por $\dfrac{2\gamma}{1-\gamma}$ puede revertir el orden durante varias iteraciones. Tercero, si reemplazamos el verdadero P por una estimación $\widehat{P}$ con, digamos, 5% de error en cada entrada, el punto fijo se desplaza en una cantidad proporcional a $\dfrac{\gamma}{(1-\gamma)^2}\left\|\widehat{P} - P\right\|_\infty \approx 90 \cdot 0.05 \approx 4.5$ veces el error de estimación —lo que ilustra concretamente la sensibilidad espectral discutida en la Sección 3.

6 Modos de falla

El agente determinístico falla de cuatro maneras distintas, cada una asociada a la rotura de un supuesto de la Sección 3. Identificar qué supuesto falló es esencial para diagnosticar al agente y, sobre todo, para no atribuir a "mala calibración de γ" lo que en realidad es un problema de diseño.

6.1 Markov roto

Si el espacio de estados es una proyección empobrecida del estado verdadero —típicamente porque se descartaron variables relevantes, se agruparon estados heterogéneos o se acumuló ruido de medición— la propiedad de Markov falla. Síntomas: residuos de la ecuación de Bellman correlacionados con el pasado, valor estimado que no coincide con el valor empírico medio en trayectorias largas, política que se desempeña mejor en simulación que en despliegue. La reparación no es estadística sino

de diseño: enriquecer $\mathcal{S}$ con variables latentes o pasar a un POMDP con creencias explícitas.

6.2 $\widehat{P}$ sesgado

Si el dataset $\mathcal{D}$ proviene de una política π_b diferente de la política objetivo, la estimación $\widehat{P}$ y $\widehat{r}$ heredan el sesgo de muestreo. Esto no es un defecto del estimador, es un defecto del diseño experimental: la información disponible no es representativa del régimen operativo. Síntomas: divergencia entre el valor predicho $\widehat{V}^*$ y el valor observado empíricamente en despliegue, alta varianza en estados poco visitados por π_b. Reparación: importance sampling, modelos causales, o recolección on-policy adicional.

6.3 Ausencia de overlap

Si existe (s, a) tal que $\pi_b(a \mid s) = 0$ pero $\pi(a \mid s) > 0$, no hay información para estimar $Q(s, a)$ en ese par. El agente determinístico puede declarar $\pi(s) = a$ como óptima sobre la base de ruido numérico en $\widehat{P}$, sin posibilidad de validación. Síntomas: acciones óptimas en estados con cero visitas de π_b, intervalos de confianza bootstrap infinitos para V^π, comportamiento errático al desplegar. Reparación: restringir π al soporte de π_b, o realizar exploración dirigida (epsilon-greedy sobre π_b) antes de replanificar.

6.4 Explotación prematura

La ausencia de exploración estocástica (como Thompson Sampling o UCB en el caso de bandidos) expone al agente a explotar una política que parece óptima bajo datos limitados pero que no lo es en el régimen verdadero. Síntomas: política que colapsa a una sola acción para la mayoría de los estados, valor empírico que decrece con el tiempo a pesar de converger $\|V_{k+1} - V_k\|_\infty$, error sistemático en subpoblaciones no representadas. Reparación: añadir una capa exploratoria —ε-greedy, muestreo de Thompson sobre $\widehat{P}$, o UCB sobre V^π— y conservar la política determinística solo para inferencia y análisis.

6.5 Ilustración clínica: escenario SSCH

En el escenario clínico del SSCH (Síndrome Subclínico de Cuidados Hipertensivos, mencionado en el material de partida), los estados codifican niveles de severidad y comorbilidades del paciente, y las acciones corresponden a distintas clases de antihipertensivos: IECA, ARA-II, bloqueadores cálcicos, diuréticos. Supóngase que en el estado s_3 (hipertensión moderada con daño renal incipiente), Value Iteration sobre el modelo estimado $\widehat{P}$ indica que la acción óptima es $\pi^*(s_3) = \text{IECA}$.

La determinidad de π^* implica que *todo* paciente que llegue a s_3 recibirá IECA. Si la política de comportamiento π_b que generó $\mathcal{D}$ rara vez recetó ARA-II en s_3, el estimador $\widehat{P}(s' \mid s_3, \text{ARA-II})$ tiene alta varianza y, posiblemente, un sesgo sistemático. El agente, sin embargo, lo trata como un parámetro cierto y declara IECA como óptimo. En pacientes atípicos —por ejemplo, aquellos con tos seca persistente como

efecto adverso a IECA, una variable latente no incluida en $\mathcal{S}$— la acción ARA-II habría sido superior, pero el agente no puede siquiera detectarlo: el dato no existe en $\mathcal{D}$ y la política no explora. La contracción del operador de Bellman garantiza convergencia *al punto fijo del modelo*, no al óptimo clínico real. Esta brecha, silenciosa en simulación, se manifiesta como deterioro renal acelerado en un subgrupo no representado durante el despliegue.

Observación 6.1 (La determinidad es un punto ciego)**.** La ausencia de aleatoriedad en la política no es una virtud: es una renuncia a recoger información. En el isomorfismo Wald–MDP, el caso $k = 1$ (un solo brazo) corresponde a los bandidos, y ahí la teoría (Thompson, UCB, KL-UCB) muestra que la exploración es *necesaria* para alcanzar optimalidad regret. El agente determinístico del Capítulo 8 elimina la exploración al asumir que el modelo es conocido; cuando este supuesto cae, la determinidad deja de ser óptima y pasa a ser una limitación estructural.

7 Conexión con el Capítulo 11 y con el isomorfismo Wald–MDP

7.1 Mezcla lenta, intervalos de confianza anchos

Cuando $\gamma \to 1$, el tiempo de mezcla efectivo τ_{mix} de la cadena inducida por π^* crece como $(1-\gamma)^{-1}$. Esto afecta directamente a la inferencia estadística sobre el valor: la varianza asintótica del estimador de Monte Carlo del retorno descontado satisface

$$\sigma^2 \;\propto\; \tau_{\text{mix}} \cdot \text{Var}(r) \;\sim\; \frac{\text{Var}(r)}{1-\gamma},$$

y los intervalos de confianza —ya sean por bootstrap o por CLT para cadenas de Markov— crecen como $(1-\gamma)^{-1/2}$. El mismo factor espectral que dificulta la convergencia de Value Iteration dificulta también la inferencia sobre el valor. Planificación e inferencia no son dos problemas separados: comparten raíz espectral.

7.2 Isomorfismo Wald–MDP

La regla de decisión de Wald $\delta : \mathcal{X} \to \mathcal{A}$ minimiza el riesgo $\text{Risk}(\theta, \delta) = \mathbb{E}_\theta\big[L(\theta, \delta(X))\big]$ en un problema estático de un solo paso. La política $\pi : \mathcal{S} \to \mathcal{A}$ del MDP extiende esta idea al caso secuencial: minimiza un riesgo *recursivo* donde la decisión actual condiciona el estado futuro y, con él, las decisiones posteriores. La correspondencia formal es

$$\text{Risk}^*(\theta, \delta) \;\longleftrightarrow\; -V^*(s),$$

donde V^* es la función de valor óptima y θ es el parámetro del modelo. Bajo este isomorfismo, el agente estadístico determinístico del Capítulo 8 es la encarnación recursiva de una regla δ estática, pero sin la robustez minimax que Wald desarrolló para el caso estático. Cuando la identificación del modelo falla (Markov roto, $\widehat{P}$ sesgado, no-overlap), el agente pierde toda garantía y la política óptima computada se convierte en una ilusión de control.

8 Recomendaciones de diseño

A partir del análisis anterior, la construcción de un agente determinístico robusto requiere un protocolo de diseño explícito. Las siguientes recomendaciones no son opcionales: cada una responde a un modo de falla identificado en la Sección 6.

R1. Auditar la suficiencia de $\mathcal{S}$ antes de iterar. Realizar tests de Markov sobre residuos de Bellman: si $V^\pi(s_t) - \big[r(s_t, a_t) + \gamma\, V^\pi(s_{t+1})\big]$ está correlacionado con observaciones pasadas, el estado no es suficiente y la arquitectura debe revisarse antes de cualquier optimización.

R2. Reportar intervalos de confianza para $\widehat{V}^*$. La cota $\dfrac{\gamma^k}{1-\gamma}\,\|V_1 - V_0\|_\infty$ controla el error numérico, no el error estadístico. Es indispensable acompañar $\widehat{V}^*$ con bandas bootstrap o CLT para cadenas, especialmente cuando γ es cercano a 1.

R3. Verificar overlap explícitamente. Antes de desplegar π, calcular $\sum_{s,a} \pi(a \mid s) \mathbb{1}\{\pi_b(a \mid s) = 0\}$: si es positivo, existen pares no identificables y la política no es validable. En tal caso, restringir π al soporte de π_b o realizar exploración dirigida.

R4. Calibrar γ con el horizonte efectivo. Elegir γ de modo que $H_{\text{eff}} = (1-\gamma)^{-1}$ sea coherente con el horizonte operativo del problema. $\gamma = 0.99$ implica $H_{\text{eff}} = 100$: si las trayectorias disponibles son de longitud 20, el agente está extrapolando masivamente.

R5. Añadir una capa exploratoria para despliegue. La política determinística es adecuada para análisis e inferencia off-policy, pero no para despliegue ciego. Combinar π con ε-greedy o Thompson sobre $\widehat{P}$ preserva la interpretabilidad del agente principal mientras recopila información para futuras replanificaciones.

R6. Replanificar con trigger estadístico, no cronológico. En lugar de replanificar cada N pasos, hacerlo cuando un test de deriva sobre $\widehat{P}$ lo indique, o cuando el tamaño del dataset se duplique. Esto evita tanto la obsolescencia de la política como la inestabilidad por replanificación excesiva.

Síntesis.

El agente estadístico determinístico es una máquina elegante de recursión de riesgo, pero su poder descansa sobre presupuestos espectrales: suficiencia del estado, conocimiento o estimación perfecta de P, estacionariedad y overlap. Cuando estos se rompen —y en la mayoría de aplicaciones inteligentes se rompen— la política óptima computada se convierte en una ilusión de control. Quien ignora este punto no construye un agente inteligente; construye un optimizador frágil que colapsa bajo la complejidad del mundo real. La optimalidad es siempre condicional al modelo, y el modelo siempre miente, aunque sea un poco.
