Teoría Avanzada de Inferencia Estadística aplicada a la decisión secuencial y los agentes inteligentes

Un puente formal entre la teoría de decisión de Wald,
los procesos de decisión de Markov y la inferencia semiparamétrica
para el diseño de agentes con garantías estadísticas

Dr. Jaime Lincovil Curivil

Dr. Jaime Lincovil
Lima, Perú

2024

Una política óptima tiene la propiedad de que, cualesquiera que sean el estado y decisión iniciales, las decisiones restantes deben constituir una política óptima respecto al estado resultante de la primera decisión.

— Bellman (1957)

Dr. Jaime Arcovil Curivil

Prefacio

Una pregunta que une el recorrido

Un agente observa una parte del mundo y debe actuar antes de conocerlo por completo. Puede estimar qué ocurrirá, comparar las consecuencias de sus acciones o aplazar la decisión para obtener información. En cualquiera de esos casos necesita distinguir lo que sabe de lo que supone. Esta monografía estudia cómo expresar esa distinción con las herramientas de la teoría de decisión y de la inferencia estadística.

La pregunta que guía el libro es qué permite afirmar una garantía cuando se pasa de un problema estadístico a un sistema que decide de manera secuencial. La teoría de Wald aporta el lenguaje de pérdidas, riesgos y reglas; los procesos de decisión de Markov describen cómo una acción modifica las posibilidades futuras. Entre ambos se construye una representación precisa de una decisión de Wald como una familia de MDP de un paso. La identidad entre riesgo y retorno que resulta de esa construcción permite comparar las mismas reglas en los dos lenguajes (Teorema 5.3).

Al llegar a la evaluación de políticas, aparecen preguntas adicionales. Los datos pueden proceder de otra política, las observaciones de una misma trayectoria pueden depender entre sí y la política evaluada puede haberse aprendido con esos datos. La representación de una decisión ayuda a formular el problema; cada conclusión inferencial exige además su propio resultado, con un objetivo, un procedimiento y unas hipótesis definidos.

Cómo se desarrolla el argumento

El recorrido empieza por las dos tradiciones que dieron forma a estas preguntas. La primera parte presenta la decisión de Wald y la planificación en MDP, y reúne las herramientas estadísticas necesarias para estudiar estimadores e incertidumbre. La segunda establece la representación entre los marcos y examina los cambios que pueden invalidar una transferencia. Con esa distinción, la tercera parte aborda la evaluación de políticas con datos de otra política, los intervalos para su valor y la revisión de las condiciones que sostienen cada afirmación.

La cuarta parte lleva esas preguntas a cálculos y programas reproducibles. El caso sintético de soporte clínico permite seguir decisiones, estimadores y límites sin atribuir a las cifras una validación médica. Los laboratorios amplían ese recorrido y el capítulo de despliegue estudia qué ocurre cuando se modifica la implementación o la población. El último capítulo retoma las preguntas que siguen abiertas y precisa qué faltaría para responderlas.

Los apéndices acompañan la lectura. Las demostraciones desarrollan argumentos que conviene consultar junto con sus enunciados; el glosario, las tablas y las condiciones de regularidad permiten recuperar una definición sin interrumpir el argumento principal. El apéndice de LangGraph describe una posible organización del código, y el de reproducción distingue el diseño del experimento de los resultados que todavía deben obtenerse.

Preparación y formas de lectura

Se presupone familiaridad con probabilidad, esperanza condicional, estimación y contrastes de hipótesis, junto con nociones de álgebra lineal y análisis. La formulación de los MDP se desarrolla en el Capítulo 3; no hace falta experiencia previa con una biblioteca de agentes para seguir el argumento.

La lectura continua permite ver cómo una misma pregunta cambia al introducir nuevos datos o decisiones futuras. Quien ya conozca estadística matemática puede consultar el Capítulo 4 según lo necesite y detenerse en la representación del Capítulo 5. Quien trabaje en aprendizaje por refuerzo puede comenzar por el Capítulo 3 y volver al Capítulo 2 para examinar cómo se comparan las reglas bajo incertidumbre. La Introducción propone otros recorridos de acuerdo con el problema que interese al lector.

El alcance de una garantía

A lo largo del libro, una garantía acompaña siempre a una afirmación concreta. Puede referirse al riesgo de una regla, a la convergencia de un algoritmo o a la cobertura de un intervalo. Conviene conservar esa precisión al interpretar los ejemplos: resolver la planificación dentro de un modelo conocido y estimar el valor de una política a partir de datos plantean exigencias diferentes.

El Capítulo 9 ofrece un procedimiento para registrar esa relación entre afirmación, hipótesis y evidencia. Los diagnósticos, las simulaciones y la documentación del diseño aportan información complementaria. Cuando una condición queda sin justificar, la conclusión conserva ese límite. Los problemas pendientes de reproducción se indican junto al experimento al que pertenecen.

Agradecimientos

El profesor Jaime Lincovil agradece a la comunidad de profesores y alumnos del doctorado de Estadística la oportunidad de compartir y discutir la aplicación de la teoría y los métodos estadísticos al diseño de agentes.

Lima, Perú, marzo de 2026

Dr. Jaime Lincovil Cedrón

Índice General

Prefacio iii
0.1 Una pregunta que une el recorrido iii
0.2 Cómo se desarrolla el argumento iii
0.3 Preparación y formas de lectura iv
0.4 El alcance de una garantía iv
0.5 Agradecimientos iv
Índice General v
Índice de Figuras xiv
Índice de Tablas xv
Notación y símbolos xvii
0.6 Conjuntos y Espacios xvii
0.7 Funciones de Densidad y Verosimilitud xvii
0.8 Funciones de Pérdida, Riesgo y Valor xvii
0.9 Políticas, Reglas de Decisión y Estimadores xviii
0.10 Parámetros y Constantes xviii
0.11 Operadores y Funciones Especiales xix
0.12 Probabilidad y Esperanza xix
0.13 Funciones Nuisance y Tasas xx
0.14 Normas y Distancias xx
0.15 Abreviaturas xx
Introducción 1
0.16 De una decisión a su representación secuencial 1
0.17 El recorrido de la exposición 2
0.18 Guía de lectura 2
1 Dos tradiciones y el problema de la transferencia de garantías 4
1.1 Riesgo estadístico y consecuencias futuras 4
1.2 Dos sentidos de «inferencia» 5
1.3 Cómo leer una garantía a lo largo del libro 5
2 Teoría de decisión de Wald 8
2.1 Observaciones, pérdidas y criterios de decisión 8
2.1.1 Cómo se formula una decisión estadística 8
2.1.2 Función de Riesgo 8
2.1.3 Admisibilidad y Dominancia 9
2.1.4 Reglas de Bayes 9
2.1.5 Relación entre Admisibilidad y Reglas de Bayes 10
2.1.6 Reglas Minimax 11
2.1.7 Tests como reglas de decisión 11
2.2 De la regla estadística al diseño de un agente 11
2.2.1 El Agente como Decisor Estadístico 12
2.2.2 El Modelo Estadístico como Modelo del Mundo 12
2.2.3 Políticas Bayesianas 12
2.2.4 Políticas Minimax: Robustez 12
2.2.5 Metacriterios de Decisión 12

2.2.6 Trazabilidad: Del Teorema al Componente ... 13
2.2.7 La misma decisión expresada como una política ... 13
2.3 Ejercicios ... 13
2.4 Lecturas Propuestas ... 14
3 Procesos de decisión de Markov ... 15
3.1 Planificar con un modelo conocido ... 15
3.1.1 Definición Formal del MDP ... 15
3.1.2 Funciones de Valor ... 16
3.1.3 Ecuaciones de Bellman ... 16
3.1.4 Operadores de Bellman y Contracción ... 16
3.1.5 Value Iteration ... 17
3.1.6 Policy Iteration ... 17
3.1.7 Bandidos Multi-Brazo: Exploración y Aprendizaje ... 18
3.1.8 Bandidos, Memoria y Horizonte ... 19
3.1.9 Conexión con Teoría de Decisión de Wald ... 20
3.1.10 Condiciones para Preservación de Contracción ... 20
3.2 Del operador de Bellman al cálculo de una política ... 20
3.2.1 Value Iteration como Flujo de Computación ... 21
3.2.2 Criterios de Parada Rigurosos ... 21
3.2.3 FrozenLake-v1: Verificación Computacional en Entorno Estándar ... 21
3.2.4 Trazabilidad: Del Teorema al Componente ... 22
3.3 Ejercicios ... 23
3.4 Lecturas Propuestas ... 23
4 Herramientas de transferencia ... 24
4.1 Del modelo a la información que conservan los datos ... 24
4.1.1 El Problema de Inferencia Estadística: Estructura Formal ... 24
4.1.2 Estadísticos y su Clasificación ... 27
4.1.3 Criterios de Optimalidad ... 27
4.1.4 Familias Exponenciales: Definición y Propiedades ... 28
4.1.5 Estadísticos Naturales y Suficiencia ... 30
4.1.6 Priors Conjugados y Actualización Bayesiana ... 31
4.1.7 Otras familias paramétricas con estructura ... 32
4.1.8 El Principio de Suficiencia ... 33
4.1.9 Suficiencia Minimal ... 34
4.1.10 Completitud ... 35
4.1.11 Ancillaridad y el Teorema de Basu ... 36
4.1.12 Equivarianza ... 37
4.2 Estimar y comparar la precisión de los procedimientos ... 38
4.2.1 Criterios de optimalidad en estimación puntual ... 38
4.2.2 El Teorema de Rao-Blackwell ... 38
4.2.3 El Teorema de Lehmann-Scheffé y UMVUE ... 39
4.2.4 La Cota Inferior de Cramér-Rao ... 39
4.2.5 El Estimador de Máxima Verosimilitud ... 41
4.2.6 Métodos Computacionales Bayesianos: MCMC e Inferencia Variacional ... 42
4.2.6.1 Aproximación posterior fuera de la conjugación ... 43
4.3 Contrastar hipótesis con una regla de error explícita ... 44
4.3.1 Formulación del problema de contraste ... 44
4.3.2 Tests Uniformemente Más Potentes ... 45
4.3.3 Tests UMPU ... 45

4.3.4 Dualidad Test-Intervalo de Confianza 46
4.3.5 Múltiples Comparaciones 46
4.3.6 Tests de Hipótesis Bayesianos 48
4.4 Aproximar la distribución del error de estimación 49
4.4.1 El teorema central del límite 49
4.4.2 El Delta Method 51
4.4.3 Procesos Empíricos 52
4.4.4 El Bootstrap 54
4.4.5 Asintótica para Funciones de Valor 55
4.5 Estimar un objetivo con modelos auxiliares complejos 56
4.5.1 Modelos semiparamétricos 56
4.5.2 Scores y Espacios Tangentes en el Par (θ, g) 57
4.5.3 Funciones de Influencia 58
4.5.4 Eficiencia Semiparamétrica 58
4.5.5 Ortogonalidad de Neyman 59
4.5.6 Estimadores Doubly Robust 59
4.5.7 IF Eficiente para V^{π} 60
4.5.8 Debiased Machine Learning 61
4.5.9 Condiciones para Validez de Cross-Fitting 62
4.5.10 Inferencia Causal: DAGs y Criterio Backdoor 62
4.6 Ejercicios 63
4.7 Lecturas Propuestas 67
5 Representación Wald ⟶ MDP: enunciado, demostración y alcance 70
5.1 Construir la representación y precisar su alcance 70
5.1.1 Recapitulación de los Dos Marcos 70
5.1.2 Representación fundamental de un paso 71
5.1.3 Extensión al Caso Secuencial 72
5.1.4 Transferencia de Resultados de Inferencia 73
5.1.5 Preservación de Propiedades de Optimalidad 73
5.1.6 StateSchema como Estadístico Suficiente 74
5.1.7 Síntesis de la representación Wald ⟶ MDP 74
5.2 Leer las correspondencias a partir de sus condiciones 74
5.3 De la representación a una decisión concreta 75
5.3.1 Arquitectura Trazable 75
5.3.2 Garantías y condiciones 75
5.4 Ejercicios 77
5.5 Lecturas Propuestas 77
6 Lo que no se transfiere 78
6.1 Qué cambia al ampliar el problema 78
6.1.1 Límites del Isomorfismo: Contraejemplos 78
6.1.2 Límites del Isomorfismo: Cuándo NO se Transfieren Garantías 80
6.1.3 Qué puede transportarse bajo condiciones adicionales 80
6.1.4 Condiciones de Regularidad para Dependencia Temporal 82
6.2 Representación, identificación e inferencia 84
6.2.1 Límites del isomorfismo estricto 84
6.2.2 Límites de la transferencia condicional 85
6.2.3 Una síntesis de las limitaciones 87
6.3 Cómo se manifiesta una condición que falta 87
6.4 Revisar la afirmación antes de utilizarla 88

6.5 Relacionar cada garantía con su justificación 89
7 Evaluación off-policy 91
7.1 Identificar el valor antes de estimarlo 91
7.1.1 El Problema de Off-Policy Evaluation 91
7.1.2 Supuestos de Identificación 92
7.1.3 Direct Method (DM) 93
7.1.4 Importance Sampling (IS) 94
7.1.5 Curse-of-Horizon 94
7.1.6 Distributional Shift: Cuando el Mundo Cambia 95
7.1.6.1 Distinguir población inicial y ocupación de estados 96
7.1.7 Doubly Robust (DR) 97
7.1.8 Comparación de Estimadores 98
7.1.9 Diagnósticos de Overlap 99
7.1.10 Protocolo de Fallback ante Overlap Insuficiente 99
7.1.11 Verificación en Línea de Supuestos 100
7.2 Convertir la evaluación en una decisión documentada 101
7.3 Ejercicios 102
7.4 Lecturas Propuestas 103
8 Intervalos de confianza para funciones de valor 104
8.1 Definir la incertidumbre según el objetivo y los datos 104
8.1.1 El Problema de Inferencia 104
8.1.2 Condiciones de Mixing 105
8.1.3 Tasas de Mixing Explícitas para MDPs 105
8.1.4 CLT para Procesos Mixing 106
8.1.5 El Teorema de Shi et al. (2022) 107
8.2 Estimación de Varianza 108
8.3 SAVE: Corrección de Sesgo 109
8.4 Diseño de Poder y Tamaño de Muestra 110
8.5 Diagnóstico de Supuestos 110
8.6 Deep Reinforcement Learning: Policy Gradient y REINFORCE 110
8.6.1 El criterio de la política y la estimación del gradiente 111
8.7 Interpretar el intervalo en la decisión 112
8.7.1 Construcción de IC 112
8.7.2 Decisiones Guiadas por IC 112
8.7.3 Trazabilidad: Del Teorema al Componente 113
8.8 Ejercicios 114
8.9 Lecturas Propuestas 114
9 Un cálculo de verificación de garantías 115
9.1 Conservar la información que necesita la decisión 120
9.1.1 Arquitectura de Nodos: Observación, Creencias, Decisión 121
9.1.2 El Estado como Estadístico Suficiente 121
9.1.3 Incertidumbre y Criterios de Decisión 123
9.1.4 Registrar las condiciones de la representación 123
9.1.5 Conexión con la Correspondencia Estructural 124
9.1.6 El Estado del Agente como Estadístico Suficiente 124
9.1.7 Separación Conceptual: Estado versus Contexto 124
9.1.8 Diseño de Memoria Eficiente 125
9.1.9 Completitud y Unicidad de la Representación 125
9.1.10 Equivarianza en el Comportamiento del Agente 125

9.1.11 Qué respalda la reducción de datos 125
9.1.12 Conexión con la Correspondencia Estructural 126
9.2 Elegir un objetivo y un estimador 126
9.2.1 Estimación de Funciones de Valor 126
9.2.2 El Trade-off Sesgo-Varianza en Agentes 126
9.2.3 Rao-Blackwellización de Estimadores Monte Carlo 127
9.2.4 Límites de Precisión: Cramér-Rao en Agentes 127
9.2.5 Qué precisión puede atribuirse al estimador 127
9.3 Comparar políticas con un error de decisión declarado 128
9.3.1 A/B Testing de Políticas 128
9.3.2 Intervalos de Confianza para Diferencias de Valor 128
9.3.3 Comparación de Múltiples Políticas 128
9.3.4 Qué error controla la comparación 129
9.4 Relacionar el intervalo con su régimen de muestreo 129
9.4.1 Cuantificación de Incertidumbre vía Bootstrap 129
9.4.2 Intervalos de Confianza para Decisiones 130
9.4.3 Incertidumbre Epistémica versus Aleatoria 130
9.4.4 Cómo se justifica el intervalo 130
9.5 Revisar las funciones auxiliares y el resto de estimación 130
9.5.1 OPE como Problema Semiparamétrico 131
9.5.2 Diseño de Estimadores DR 131
9.5.3 Ortogonalidad y Robustez 131
9.5.4 Qué aporta la construcción semiparamétrica 132
9.5.5 Reunir la evidencia de una evaluación 132
9.6 Recuperar la justificación de cada componente 134
10 Casos de estudio 138
10.1 El caso longitudinal: Sistema de Soporte Clínico para Hipertensión 138
10.2 Laboratorio 1: Modelo del Mundo y Estadístico Suficiente 143
10.3 Laboratorio 2: Compresión del Estado (Suficiencia) 146
10.4 Laboratorio 3: Estimación Óptima en Agentes 147
10.5 Laboratorio 4: Tests e Intervalos de Confianza en Agentes 148
10.6 Laboratorio 5: Asintótica Aplicada en Agentes 149
10.7 Laboratorio 6: DML y Estimación Semiparamétrica 151
10.8 Laboratorio 7: Regla de Decisión de Wald 153
10.9 Laboratorio 8: MDP y Programación Dinámica 155
10.10 Laboratorio 9: Demostración de la Incrustación Fiel 156
10.11 Laboratorio 10: Off-Policy Evaluation 158
10.12 Laboratorio 11: Inferencia Secuencial para Funciones de Valor 162
10.13 Laboratorio 12: LLM-Agents y Síntesis 164
11 De la garantía al despliegue 167
11.1 Lo que puede cambiar al ejecutar el procedimiento 167
11.2 Cuantización del modelo que aproxima Q 168
11.3 Decodificación especulativa 169
11.4 Latencia como restricción de diseño 170
11.5 Cuando una restricción de ejecución cambia la decisión 170
11.6 Protocolo de validación empírica 171
11.7 Qué permite comprobar la validación 171
11.8 Protocolo 1: Simulación de MDP Controlado 172
11.8.1 Configuración del MDP de Prueba 172

11.8.2 Cálculo de Valores Verdaderos 172
11.8.3 Procedimiento de Validación 172
11.8.4 Métricas de Evaluación 173
11.9 Protocolo 2: Verificación de Overlap 174
11.9.1 Escenarios de Prueba 174
11.9.2 Procedimiento de Verificación de Diagnósticos 174
11.10 Protocolo 3: Verificación de Mixing 175
11.10.1 Tests de Estacionariedad 175
11.10.2 Estimación de Tasa de Mixing 175
11.11 Protocolo 4: Validación de Estimadores DR 176
11.11.1 Comparación de Estimadores 176
11.11.2 Verificación de Doble Robustez 176
11.12 Verificación Previa al Despliegue 177
11.13 Pseudocódigo de Validación 177
11.14 Interpretación de Resultados 178
11.15 Conservar las razones y los límites de la decisión 179
12 Problemas abiertos 181
12.1 Qué conclusiones conservamos 181
12.2 Las fronteras de la evaluación 182
12.2.1 Evaluar cuando hay causas comunes no observadas 182
12.2.2 Decidir a partir de observaciones parciales 182
12.2.3 Evaluación de agentes de lenguaje y modelos auxiliares 183
12.2.3.1 Probabilidad de una acción textual 184
12.2.3.2 Qué información necesita la evaluación 184
12.2.3.3 Qué conserva la discretización de acciones 184
12.2.3.4 Condiciones de una evaluación DR 185
12.2.3.5 Dónde debe revisarse la garantía 185
12.2.3.6 Organizar una evaluación de acciones textuales 185
12.2.4 Un diseño de agente y las garantías que habría que justificar 185
12.2.5 Una agenda a partir de las condiciones que faltan 186
12.2.6 Qué significaría sostener esas garantías 187
12.3 Del problema abierto al diseño de una evaluación 188
12.3.1 Conservar la información entre componentes 188
12.3.2 Responder a una limitación del análisis 188
12.4 Preguntas para continuar el trabajo 189
12.4.1 Confounding no observado: identificación parcial y métodos robustos 189
12.4.2 POMDPs: inferencia con observabilidad parcial 190
12.4.3 LLM-agents: evaluación sin acceso a la política 190
12.4.4 Condiciones de mixing en espacios continuos de alta dimensión 190
12.5 Cómo orientar el trabajo que sigue 191
12.6 Ejercicios 191
12.6.1 Ejercicios Teóricos 191
12.6.2 Ejercicios Prácticos 191
12.6.3 Ejercicios de Síntesis 192
12.7 Lecturas Propuestas 192
12.8 Decidir con la información que se tiene 192
A Demostraciones y argumentos complementarios 195
A.1 Familias exponenciales 195
A.1.1 Propiedades de la función de log-partición 195

A.2 Reducción de datos ... 196
A.2.1 Teorema de Factorización de Neyman-Fisher ... 196
A.2.2 Criterio de suficiencia minimal ... 197
A.2.3 Completitud en familias exponenciales ... 197
A.2.4 Teorema de Basu ... 198
A.2.5 Riesgo de una regla equivariante ... 199
A.3 Estimación puntual y precisión ... 199
A.3.1 Teorema de Rao-Blackwell ... 199
A.3.2 Teorema de Lehmann-Scheffé ... 200
A.3.3 Desigualdad de Cramér-Rao ... 200
A.3.4 Propiedades asintóticas del MLE ... 201
A.4 Contrastes e interpretación del error ... 202
A.4.1 Lema de Neyman–Pearson e inversión de tests ... 202
A.4.2 Procedimiento de Benjamini–Hochberg ... 202
A.4.3 Distribución asintótica del LRT: Wilks ... 203
A.5 Aproximaciones y remuestreo ... 203
A.5.1 CLT de Lindeberg-Lévy ... 203
A.5.2 Método delta ... 204
A.5.3 Consistencia del bootstrap para la media ... 205
A.6 Funciones de influencia y modelos auxiliares ... 205
A.6.1 Doble robustez y expansión con cross-fitting ... 206
A.6.2 Función de influencia eficiente para OPE ... 206
A.6.3 Cota semiparamétrica de varianza ... 207
A.7 Decisión de Wald ... 207
A.7.1 Identidad de riesgo de James–Stein ... 207
A.7.2 Existencia de reglas de Bayes con acciones finitas ... 207
A.7.3 Conexión Bayes-Minimax ... 207
A.7.4 Clase esencialmente completa en el problema finito ... 209
A.8 Programación dinámica ... 209
A.8.1 Ecuación de Bellman de expectación ... 209
A.8.2 Contracción del operador de Bellman ... 210
A.8.3 Existencia y unicidad de V^* ... 211
A.8.4 Cota residual para una política greedy ... 212
A.9 Representación entre decisiones y políticas ... 212
A.9.1 Representación que preserva el riesgo ... 212
A.9.2 Bayes, minimax y admisibilidad ... 213
A.9.3 Suficiencia estadística y estado predictivo ... 213
A.10 Evaluación fuera de política ... 213
A.10.1 Insesgadez del IS ... 213
A.10.2 Varianza de importancia y horizonte ... 214
A.10.3 Doble robustez del DR ... 214
A.10.4 Eficiencia del DR de una decisión ... 215
A.11 Inferencia para funciones de valor ... 215
A.11.1 Inferencia de Shi, Zhang, Lu y Song para política fija ... 215
A.11.2 Eficiencia de Kallus–Uehara ... 215
B Glosario de Notación ... 217
B.1 Notación General ... 217
B.2 Inferencia estadística ... 217
B.3 Procesos de decisión de Markov ... 218

B.4 Evaluación Off-Policy e Inferencia (Parte III) 219
B.5 Representación Wald ⟶ MDP 220
B.6 Sistema de Soporte Clínico para Hipertensión (SSCH) 220
B.7 Abreviaciones y Acrónimos 221
B.8 Convenciones Tipográficas 222
B.8.1 Convenciones de Notación 222
C LangGraph: organización de los cálculos de un agente 224
C.1 Ontología de Componentes 224
C.2 Correspondencia LangGraph ↔ MDP 225
C.3 Diagrama de Arquitectura Genérica 225
C.4 Value Iteration como StateGraph 226
C.4.1 Descripción del StateSchema 226
C.4.2 Descripción de Nodos 227
C.4.3 Arista Condicional 227
C.5 Patrones de Diseño para Agentes con Garantías 227
C.5.1 Patrón: Estimador DR como Nodo 227
C.5.2 Patrón: A/B Testing con Control de FDR 227
C.5.3 Patrón: Human-in-the-Loop con Checkpointer 227
C.6 Una organización posible del código 228
C.7 Notas sobre Versiones y Compatibilidad 228
D Fundamentos Medido-Teóricos 229
D.1 σ-Álgebras y Espacios Medibles 229
D.2 Medibilidad de Funciones 229
D.3 Medidas de Probabilidad y Dominación 229
D.4 σ-Álgebras para Espacios de Trayectorias del MDP 230
D.5 Condiciones de Medibilidad para Estimadores y Políticas 231
D.6 Noción de Dominación en Modelos con Estados Continuos 231
D.7 Teorema de la Función Implícita y medibilidad local 231
D.8 Integrabilidad y Convergencia Dominada 232
D.9 Espacios de Hilbert y Proyecciones Ortogonales 232
D.10 Resumen de Condiciones Técnicas 232
E Tablas de Correspondencia 234
E.1 Correspondencias entre la decisión y su representación 234
E.2 Correspondencia de Estimadores 236
E.3 Correspondencia de Condiciones de Regularidad 236
E.4 Correspondencia de Cotas y Tasas 237
E.5 Glosario de Términos 237
E.6 Índice de Notación por Capítulo 238
E.7 Catálogo de Datasets Utilizados 239
F Condiciones de Regularidad y Mixing 242
F.1 Definiciones de Mixing 242
F.2 Tasas de Decaimiento 242
F.3 Condiciones para MDPs Ergódicos 243
F.4 CLT bajo Dependencia Temporal 243
F.5 Estimación de la Varianza de Largo Plazo 244
F.6 Tabla de Referencia: Ambiente ⟶ Condiciones ⟶ Garantías 245
G Reproducibilidad del estudio de simulación de Shi et al. 246
G.1 El experimento que se propone reproducir 246
G.2 Diseño del experimento 246

G.3 Escenarios 247
G.4 Métricas 247
G.5 Resultados 247
G.6 Esqueleto de código 248
G.7 Requisitos de reproducibilidad 250
Bibliografía 251

Dr. Jaime Lincovil Curivil

Índice de Figuras

4.1 Diagrama de flujo del proceso de inferencia estadística. El proceso comienza con la especificación del modelo $\mathcal{P}$ y parámetro θ, mientras se observan datos X. Un estadístico suficiente $T(X)$, cuando existe una reducción útil, resume los datos sin perder la información de verosimilitud; junto con el modelo alimenta la función de verosimilitud $L(\theta; X)$. Un criterio $\mathcal{C}$ transforma esta información en una regla de decisión $\delta(X)$, cuya calidad se evalúa mediante el riesgo $R(\theta, \delta)$. Las flechas de retroalimentación permiten el aprendizaje y actualización del modelo. 47

5.1 Representación de una decisión. El parámetro indexa el modelo y la evaluación; la regla utiliza únicamente la observación. 93

6.1 Varianza exacta de IS por trayectoria en el ejemplo de recompensa terminal constante. No son resultados de simulación ni curvas de PDIS. 106

6.2 Mapa de los seis mecanismos: cada fila señala el primer objeto que debe revisarse. 107

6.3 Alcance de la coincidencia de criterios. La comparación depende de qué se toma como parámetro y de la distribución inicial. 108

7.1 Elección de estimador después de justificar identificación. Las condiciones son requisitos de análisis, no umbrales automáticos de cobertura. 119

9.1 Revisión de una garantía: la evidencia incompleta conserva un dictamen pendiente, no una certificación. 137

9.2 Ejemplo sintético: separar actualización, comparación de pérdidas y revisión. 143

10.1 Actualización, comparación de pérdidas y revisión del caso sintético. 165

11.1 Dos capas y tres efectos posibles de una transformación de ejecución. 189

C.1 Arquitectura genérica de agente LangGraph con ciclo ReAct. Las anotaciones en colores indican la correspondencia MDP. 247

C.2 Value Iteration implementado como `StateGraph`. El nodo *Aplicar Bellman* corresponde al operador de Bellman $\mathcal{T}$ del Teorema de contracción del Capítulo 3. 247

Versión Preliminar Curricular

Índice de Tablas

0.1 Objetos que deben conservarse al representar una decisión. Las garantías inferenciales se justifican para el experimento y el procedimiento correspondientes. 23
2.1 Del criterio de decisión a su uso en el agente. 34
3.1 Condiciones de convergencia 41
3.2 Garantías y evidencia necesaria 43
4.1 Correspondencia entre conceptos estadísticos y componentes de agentes 46
4.2 Interpretación operativa de los cinco componentes de la inferencia 47
4.3 Familias conjugadas comunes y su aplicación en agentes 52
4.4 Diagnósticos y alcance 83
5.1 Preguntas inferenciales que la representación de riesgo deja abiertas. La dimensión del objetivo y la del modelo son conceptos distintos. 94
5.2 Correspondencias exactas y límites. Las filas inferenciales no son consecuencias automáticas de la identidad entre riesgo y retorno. 96
5.3 Trazabilidad de la representación y del problema bayesiano de parada. 97
6.1 Qué limita cada ejemplo 101
6.2 Garantías de estimación y de decisión 101
6.3 Qué se necesita al cambiar el régimen muestral 105
6.4 Condiciones y límites de su verificación 110
7.1 Respuesta a dificultades de evaluación 122
8.1 Régimen de datos y fundamento de la varianza 127
8.2 Correspondencia entre inferencia y componentes 134
9.1 Catálogo canónico de garantías: resultados, componentes y límites de aplicación. 141
9.2 Componentes y alcance del ejemplo Beta–Bernoulli. 144
9.3 Modelo, información y decisión: vista del catálogo. 145
9.4 Reducción de información y límites de su uso en un estado. 147
9.5 Estimación: clase comparada, precisión y sesgo. 149
9.6 Contrastes, multiplicidad y revisiones temporales. 150
9.7 Resultados asintóticos y remuestreo: condiciones antes que fórmulas. 151
9.8 Modelo, influencia y condiciones de inferencia con aprendizaje auxiliar. 153
9.9 Mapa de rutas: representación, planificación e inferencia. 154
9.10 Resultados y componentes: vista operacional del catálogo canónico. 157
10.1 Recompensas sintéticas del SSCH tabular, en unidades abstractas. 160
10.2 Preguntas y fundamentos de los doce laboratorios. 164
10.3 Qué implementa cada componente y qué no demuestra. 165
11.1 MDP sintético de validación: probabilidades y recompensas de diseño. 193
11.2 Métricas y alcance de su interpretación. 194
11.3 Simulación de referencia: mil muestras de doscientos episodios. 195
11.4 Soporte y concentración: escenarios distintos. 195
11.5 Qué se espera bajo auxiliares fijos y soporte suficiente. 197
11.6 Ficha de decisión previa al uso de una versión. 198
11.7 Hallazgos, posibles causas y revisión requerida. 200
12.1 Desafíos de OPE en LLM-Agents 205
12.2 Agenda de Investigación: Problemas Abiertos 207
12.3 Alcance de las preguntas en esta monografía. «Parcial» indica resultados para casos restringidos; «abierto» indica que el problema formulado aquí queda sin resolver en el libro. 208
B.1 Notación matemática general 238
B.2 Notación de inferencia estadística 239

B.3 Notación de MDPs y programación dinámica 240
B.4 Notación de evaluación off-policy e inferencia 241
B.5 Correspondencias de la incrustación fiel 241
B.6 Notación específica del ejemplo SSCH 242
B.7 Abreviaciones y acrónimos 243
C.1 Correspondencia LangGraph $\leftrightarrow$ MDP 246
D.1 Condiciones Técnicas por Capítulo 254
E.1 Incrustación fiel Wald $\leftrightarrow$ MDP: correspondencias y su estatus 256
E.2 Correspondencia de Estimadores 257
E.3 Condiciones de Regularidad 257
E.4 Cotas de Eficiencia y Tasas de Convergencia 258
E.5 Primera Aparición de Símbolos 260
E.6 Catálogo de datasets utilizados en la monografía. 261
F.1 Tasas de Mixing y sus Implicaciones para Inferencia 264
F.2 Condiciones Requeridas por Tipo de Ambiente 266
G.1 Escenario A: ECP, AL y $\log(\mathrm{MSE})$ por configuración (n, T). Celdas «–»: resultados aún no obtenidos. 269
G.2 Escenario B: ECP, AL y $\log(\mathrm{MSE})$ por configuración (n, T). Celdas «–»: resultados aún no obtenidos. 269
G.3 Escenario C: ECP, AL y $\log(\mathrm{MSE})$ por configuración (n, T). Celdas «–»: resultados aún no obtenidos. 269

Jaime Lincovil Curivil

Notación y símbolos

Esta lista reúne los símbolos que acompañan la lectura. Las categorías ayudan a distinguir el parámetro desconocido, los datos disponibles y la regla que actúa sobre ellos. La columna de consulta señala un capítulo donde se desarrolla el uso del símbolo; el glosario amplía estas referencias.

Conjuntos y Espacios

Símbolo	Significado	Consulta
Θ	Espacio de parámetros (estados de la naturaleza)	4
$\mathcal{X}$	Espacio muestral	4
$\mathcal{A}$	Espacio de acciones	4
$\mathcal{S}$	Espacio de estados (MDP)	3
$\mathcal{O}$	Espacio de observaciones (POMDP)	12
$\mathcal{P}_\theta$	Familia de distribuciones parametrizada por θ	4
$\mathcal{D}$	Problema de decisión de Wald	2
$\mathcal{M}$	Proceso de Decisión de Markov (MDP) completo	3
$\mathcal{P}$	POMDP	12
$\mathbb{R}$, $\mathbb{R}^d$	Números reales, espacio euclídeo d-dimensional	—
$\mathbb{N}$	Números naturales	—

Funciones de Densidad y Verosimilitud

Símbolo	Significado	Consulta
$f_\theta(x)$	Densidad de X bajo P_θ (frecuentista)	4
$f(x\|\theta)$	Densidad de X condicional a θ (bayesiano)	2
$p_\theta(x)$	Alternativa notacional para densidad frecuentista	4
$p(x\|\theta)$	Alternativa notacional para densidad bayesiana	2

Funciones de Pérdida, Riesgo y Valor

Símbolo	Significado	Consulta
$L(\theta, a)$	Función de pérdida	4
$R(\theta, \delta)$	Función de riesgo de la regla δ	2
$r(s, a)$	Función de recompensa (MDP)	3
$V^{\pi}(s)$	Función de valor de estado bajo política π	3
$V^{*}(s)$	Función de valor óptima	3
$Q^{\pi}(s, a)$	Función de valor de acción (función Q)	3
$Q^{*}(s, a)$	Función Q óptima	3
$G(\tau)$	Retorno descontado de una trayectoria τ	7

Políticas, Reglas de Decisión y Estimadores

Símbolo	Significado	Consulta
δ	Regla de decisión (marco de Wald)	2
δ^{*}	Regla de decisión óptima	2
π	Política (MDP)	3
π^{*}	Política óptima	3
π_b	Política de comportamiento (OPE)	7
$T(X)$	Estadístico (función de los datos)	4
$\hat{\theta}$	Estimador del parámetro θ	4
$\hat{V}^{\pi}$	Estimador de la función de valor	7
$\hat{V}^{\mathrm{DM}}$	Estimador Direct Method	7
$\hat{V}^{\mathrm{IS}}$	Estimador Importance Sampling	7
$\hat{V}^{\mathrm{DR}}$	Estimador Doubly Robust	7
π_{prior}	Distribución a priori (Bayes)	2

Parámetros y Constantes

Símbolo	Significado	Consulta
θ	Parámetro (estado de la naturaleza)	4
γ	Factor de descuento ($0 \leq \gamma < 1$)	3
α	Nivel de significancia (tests de hipótesis)	4
β	Probabilidad de error Tipo II	4
n	Tamaño de muestra	4

Uriel Incógnito Curiel

Símbolo	Significado	Consulta
T	Horizonte temporal	3
η	Parámetro natural (familias exponenciales)	4
$A(\eta)$	Función de log-partición	4

Operadores y Funciones Especiales

Símbolo	Significado	Consulta
$\mathcal{T}^\pi$	Operador de Bellman para política π	3
$\mathcal{T}^*$	Operador de Bellman óptimo	3
$P(s'\|s,a)$	Kernel de transición	3
ρ_t	Importance ratio en tiempo t	7
$\rho_{0:T}$	Importance ratio acumulado	7
$\varphi^*(O)$	Función de influencia eficiente	4
$I(\theta)$	Información de Fisher	4
$\mathcal{I}(\theta)$	Matriz de información de Fisher	4

Probabilidad y Esperanza

Símbolo	Significado	Consulta
$\mathbb{P}$	Medida de probabilidad	—
$\mathbb{E}$	Esperanza matemática	—
$\mathbb{E}^\pi[\cdot]$	Esperanza bajo política π	3
$\mathbb{E}_\theta[\cdot]$	Esperanza bajo P_θ	4
$\mathrm{Var}(\cdot)$	Varianza	—
$\mathrm{Cov}(\cdot,\cdot)$	Covarianza	—
$\xrightarrow{d}$	Convergencia en distribución	4
$\xrightarrow{P}$	Convergencia en probabilidad	4
$\xrightarrow{\text{a.s.}}$	Convergencia casi segura	4

Oliver Lincoln Curivil

Funciones Nuisance y Tasas

Símbolo	Significado	Consulta
$g = \left(\hat{Q}, \hat{\pi}_b\right)$	Funciones nuisance del estimador DR (función Q y política de comportamiento estimadas)	4
g_0	Valor verdadero de los nuisance	4
$o_P(a_n)$	Sucesión X_n con $X_n/a_n \xrightarrow{P} 0$	4
$o_P\left(n^{-1/4}\right)$	Tasa de convergencia en L^2 exigida a cada nuisance (Definición 4.151)	4

Normas y Distancias

Símbolo	Significado	Consulta
$\|\cdot\|$	Norma euclídea	—
$\|\cdot\|_\infty$	Norma del supremo	3
$\|\cdot\|_2$	Norma L^2	4

Abreviaturas

Abreviatura	Significado
MDP	Markov Decision Process (Proceso de Decisión de Markov)
POMDP	Partially Observable MDP
OPE	Off-Policy Evaluation
DM	Direct Method
IS	Importance Sampling
DR	Doubly Robust
UMVUE	Uniformly Minimum Variance Unbiased Estimator
UMP	Uniformly Most Powerful
UMPU	Uniformly Most Powerful Unbiased
IC	Intervalo de Confianza
CLT	Central Limit Theorem (Teorema Central del Límite)
IF	Influence Function (Función de Influencia)
FDR	False Discovery Rate
FWER	Family-Wise Error Rate
HAC	Heteroskedasticity and Autocorrelation Consistent

Dr. Jaime Lincoln Curivil

Abreviatura	**Significado**
LLM	Large Language Model

Dr. Jaime Lincovil Curivil

Introducción

Una señal imperfecta puede bastar para cambiar una decisión. Un sistema de seguimiento, por ejemplo, observa una medición y elige entre mantener la atención habitual o intensificarla. Para decidir necesita algo más que una predicción: debe considerar cuánto cuesta cada error y qué información estaba disponible al actuar. Si la intervención modifica las observaciones de la visita siguiente, la misma pregunta adquiere una dimensión temporal.

La teoría de decisión estadística y los procesos de decisión de Markov permiten describir esas dos situaciones. Wald compara reglas mediante la pérdida que producen bajo distintos modelos posibles. La programación dinámica organiza las consecuencias presentes y futuras de las acciones. Este libro recorre la relación entre ambos enfoques para estudiar qué puede conservarse al pasar de uno a otro y qué exige una justificación nueva.

El ejemplo de seguimiento reaparece a lo largo de la exposición como un Sistema de Soporte Clínico para Hipertensión, SSCH. Se trata de un escenario sintético: las cifras permiten comprobar cálculos y observar fallos en un modelo conocido. Sus variantes responden a preguntas distintas; el Capítulo 10 especifica cuáles comparten una dinámica y cuáles constituyen experimentos separados.

De una decisión a su representación secuencial

La relación entre los marcos se vuelve precisa cuando conservamos la información que utiliza quien decide. El parámetro desconocido indexa los modelos posibles, mientras que la observación determina qué acción puede elegirse. En el Capítulo 5, esa decisión se representa mediante una familia de MDP con una sola acción antes de llegar al estado terminal.

Definición 0.1 (Representación de una decisión estadística). Una regla que transforma la observación en una acción puede interpretarse como una política sobre esa misma observación. Si la recompensa de cada modelo es la pérdida con signo cambiado, el retorno promedio de la política coincide con el riesgo negativo de la regla. El parámetro permanece desconocido y no se incorpora a la información disponible para elegir la acción. El Teorema 5.3 establece las condiciones y la identidad exacta de esta representación.

La correspondencia permite traducir los criterios de Bayes, minimax y admisibilidad cuando se mantiene la misma clase de reglas. Al incorporar observaciones sucesivas, en cambio, hay que especificar cómo se generan y qué memoria resume la historia. El problema bayesiano de observación y parada del Capítulo 5 muestra una extensión concreta con horizonte finito y un posterior que actúa como estado de información.

Objeto	Papel en la representación	Distinción que debe mantenerse
Θ	Índice desconocido de la familia de modelos	El decisor no observa el parámetro
$\mathcal{X}$	Observación que recibe la política	La información disponible es la misma
$\mathcal{A}$	Conjunto común de acciones	Se compara la misma clase de reglas
$L(\theta, a)$	Recompensa con signo cambiado	La evaluación conserva su dependencia del modelo
$R(\theta, \delta)$	Retorno promedio negativo	El promedio usa la distribución de la observación
Intervalo, test o estimador	Procedimiento estadístico sobre datos	Su garantía requiere hipótesis adicionales

Tabla 0.1: Objetos que deben conservarse al representar una decisión. Las garantías inferenciales se justifican para el experimento y el procedimiento correspondientes.

Esta separación orienta el resto del libro. Una identidad entre objetivos no aporta por sí sola datos informativos sobre una política nueva. La suficiencia estadística de una muestra tampoco asegura que su resumen sea un estado de Markov controlado. Para evaluar una política necesitamos identificar su valor en la distribución observada; para construir un intervalo, controlar además el error de estimación y su varianza.

El recorrido de la exposición

El Capítulo 1 sitúa las preguntas en las dos tradiciones que las formularon. Después, el Capítulo 2 introduce pérdidas, riesgos y criterios de comparación, y el Capítulo 3 añade las consecuencias futuras de una acción. El Capítulo 4 desarrolla las propiedades estadísticas que se utilizarán al estudiar datos y estimadores.

Con ese vocabulario, el Capítulo 5 construye la representación de una decisión y el Capítulo 6 examina dónde cambia el problema al extenderla. Los capítulos de evaluación e intervalos (Capítulo 7 y Capítulo 8) precisan entonces qué permiten aprender los datos de otra política y cómo cuantificar la incertidumbre. El Capítulo 9 convierte esas exigencias en una revisión de afirmaciones concretas.

Los cálculos del Capítulo 10 ponen a prueba la comprensión del recorrido: cada experimento declara su modelo y compara lo calculado con el objetivo que pretende estimar. El Capítulo 11 examina qué debe revisarse al llevar un procedimiento a una implementación y a una población determinadas. El Capítulo 12 cierra la exposición con las preguntas que permanecen cuando la información es parcial, la política no puede evaluarse o la dependencia temporal es difícil de controlar.

Guía de lectura

Quien se interese por la decisión estadística puede seguir desde el Capítulo 2 hasta el Capítulo 5 y consultar el Capítulo 4 según las propiedades inferenciales que necesite. Para estudiar evaluación de políticas, el recorrido central pasa por el Capítulo 7 y el Capítulo 8, con apoyo en las funciones

de influencia, el método delta y la dependencia temporal. El Capítulo 9 ayuda a relacionar cada resultado con una aplicación.

Quien provenga del aprendizaje por refuerzo puede comenzar por el Capítulo 3 y contrastar después la planificación con modelo conocido con los problemas de estimación del Capítulo 7. Para el diseño de sistemas, el Capítulo 11 y el Apéndice C permiten seguir el paso del procedimiento estadístico al código. Las fronteras de los agentes de lenguaje se discuten en el Capítulo 12; su lectura presupone distinguir una política ejecutable de una política cuya probabilidad de acción se conoce.

Prerrequisitos formales

La exposición utiliza esperanza condicional, convergencia de variables aleatorias y nociones de medida, junto con estimación, contrastes e intervalos de confianza. Las normas, las proyecciones y los argumentos de contracción requieren álgebra lineal y análisis. El Apéndice D reúne las definiciones técnicas y el glosario permite recuperar la notación cuando cambia el contexto.

La primera distinción que conviene llevar a la lectura es sencilla: una regla puede estar bien definida y un algoritmo puede calcularla con precisión, mientras que su valor en el entorno sigue siendo desconocido. Comprender cómo se pasa de una afirmación a la otra será el hilo del libro.

M. Jaime Lincovil Curivil

Capítulo 1

Dos tradiciones y el problema de la transferencia de garantías

La decisión de seguimiento de la Introducción admite dos preguntas. Podemos comparar el costo de las reglas que actúan después de una medición, o estudiar cómo una intervención cambia las oportunidades de las visitas futuras. La primera conduce al riesgo estadístico; la segunda, a la función de valor. Seguir el origen de esos conceptos permite entender tanto su relación como las diferencias que habrá que conservar.

Riesgo estadístico y consecuencias futuras

Los trabajos de Wald y Bellman ofrecen dos maneras de organizar una decisión bajo incertidumbre. Cada una hace explícito un aspecto del problema: qué se pierde al actuar sin conocer el modelo y cómo se acumulan las consecuencias de una acción a lo largo del tiempo.

La síntesis de Wald (1950)
En *Statistical Decision Functions*, Wald (1950) formula la comparación de procedimientos a partir de observaciones, acciones y pérdidas. Una estimación o un contraste pueden verse así como reglas que eligen una acción. La distribución de los datos determina con qué frecuencia cada regla incurre en una pérdida bajo un modelo dado.

La función de riesgo $R(\theta, \delta) = \mathbb{E}_\theta[L(\theta, \delta(X))]$ reúne esas consecuencias en un criterio de comparación. A partir de ella aparecen preguntas diferentes. La admisibilidad busca descartar reglas dominadas; una regla de Bayes minimiza el riesgo promedio bajo un prior; el criterio minimax compara el peor riesgo sobre los modelos considerados. La preferencia por uno de esos criterios depende del problema que se haya formulado y de la información que se esté dispuesto a introducir.

La programación dinámica de Bellman (1957)
Cuando una acción altera el futuro, su pérdida inmediata deja de resumir todas sus consecuencias. La programación dinámica de Bellman (1957) aborda esta dependencia al separar la acción presente del problema que queda por resolver después. El principio de optimalidad permite repetir esa separación en cada estado.

En la formulación de MDP que estudiaremos, la tupla $(\mathcal{S}, \mathcal{A}, P, r, \gamma)$ especifica estados, acciones, transiciones, recompensas y descuento. Para una política fija, la función de valor expresa el retorno esperado desde un estado y satisface la recursión

$$V^\pi(s) = \sum_a \pi(a|s) \left[r(s,a) + \gamma \sum_{s'} P(s'|s,a) V^\pi(s') \right].$$

La ecuación permite calcular valores dentro del modelo. Cuando sus transiciones o recompensas se desconocen, aparece además un problema estadístico: aprender lo necesario para que el cálculo responda al entorno que interesa.

El encuentro en la evaluación de políticas

La evaluación de una política con datos generados por otra reúne ambas perspectivas. El objetivo se define mediante un retorno secuencial, pero los datos disponibles obligan a estudiar identificación, error de estimación y precisión. La literatura de evaluación *off-policy* y de inferencia semiparamétrica proporciona resultados para responder a esas preguntas bajo modelos y diseños muestrales específicos.

El trabajo de Shi et al. (2022) sobre intervalos para funciones de valor y la revisión de Kennedy (2022) sobre estimación doblemente robusta permiten seguir dos aspectos de ese encuentro. Más adelante distinguiremos la aproximación de Bellman mediante bases de las construcciones basadas en funciones de influencia. Ambas se ocupan de la incertidumbre, con procedimientos e hipótesis que conviene leer por separado.

Dos sentidos de «inferencia»

En este recorrido, «inferencia» se refiere a aprender algo sobre un objetivo desconocido a partir de datos y a precisar la incertidumbre de esa conclusión. Un intervalo para el valor de una política es un ejemplo. Su interpretación depende del muestreo y del procedimiento que lo produce.

En ingeniería de aprendizaje automático también se llama *inference* a la ejecución de un modelo entrenado. En ese uso se estudian el tiempo de respuesta, la memoria o el costo de producir una salida. Ejecutar el modelo puede formar parte de un procedimiento estadístico, pero las propiedades del cálculo y las de la conclusión obtenida requieren argumentos distintos.

La diferencia será especialmente útil en el Capítulo 11. Una mejora de latencia puede conservar el procedimiento, introducir un error numérico o modificar las probabilidades de las acciones. Antes de trasladar una garantía habrá que precisar cuál de esos cambios ocurrió.

Cómo leer una garantía a lo largo del libro

Las garantías que utilizaremos se refieren a objetos delimitados. Una regla bayesiana se compara bajo un prior; la contracción de Bellman se establece para un operador y una norma; un intervalo se interpreta en una secuencia de experimentos. Su utilidad depende de poder reconocer esos objetos en la aplicación que se tiene entre manos.

Por eso el libro vuelve sobre el mismo ejemplo desde distintas preguntas. Primero interesa qué regla reduce una pérdida. Después, cómo planificar con una dinámica conocida y qué permiten estimar los datos cuando esa dinámica debe aprenderse. Finalmente, importa si la implementación y la población conservan las condiciones del análisis. Los cambios de pregunta se hacen explícitos para que las conclusiones mantengan su alcance.

El Capítulo 5 precisará la identidad entre riesgo y retorno en la representación de una decisión. Los Capítulo 6 y Capítulo 12 examinarán lo que hace falta al introducir nuevas formas de dependencia, información parcial o políticas complejas. El punto de partida es la comparación de reglas de Wald:

antes de calcular una decisión, debemos definir qué cuenta como error y bajo qué modelos la evaluaremos.

Dr. Jaime Lincovil Curivil

Parte I

Aparato mínimo necesario

Una decisión empieza por definir qué se observa y qué consecuencias se comparan. Wald aporta el criterio de riesgo; los MDP incorporan el futuro. Las herramientas estadísticas permitirán después estudiar qué aprendemos de los datos y con qué precisión.

Dr. Jaime Luna Curiel

Capítulo 2

Teoría de decisión de Wald

Una estimación resume lo que los datos permiten conocer; una decisión añade las consecuencias de actuar. Dos agentes pueden compartir la misma estimación y elegir acciones diferentes si los costos de equivocarse son distintos. La teoría de decisión permite expresar esa diferencia y comparar reglas completas bajo incertidumbre.

El marco de Wald (1950) reúne observaciones, modelos, acciones y pérdidas. En este capítulo se desarrolla primero una decisión basada en una muestra. El capítulo de MDP incorporará consecuencias futuras y el Capítulo 5 precisará la representación que conserva el riesgo.

El hilo conductor es una decisión sintética de seguimiento: una señal imperfecta sugiere si conviene intensificar la atención. La pregunta no se resuelve indicando únicamente qué estado parece más probable; también importa cuánto cuesta cada error. Bayes, minimax y admisibilidad ofrecen criterios distintos para comparar reglas. Todos requieren declarar qué reglas están permitidas y qué modelos se consideran posibles.

Observaciones, pérdidas y criterios de decisión

2.1.1 Cómo se formula una decisión estadística

Definición 2.1 (Problema estadístico de decisión). Un problema se especifica mediante

$$\mathcal{E} = \big(\Theta, \mathcal{X}, (P_\theta)_{\theta\in\Theta}, \mathcal{A}, L\big),$$

donde Θ indexa los modelos posibles, $X \sim P_\theta$ es la observación, $\mathcal{A}$ contiene las acciones y $L(\theta, a)$ mide su pérdida. Los espacios están provistos de estructuras medibles y las funciones usadas deben ser medibles. Se supone pérdida no negativa o integrabilidad suficiente para que los riesgos considerados sean finitos. Las pérdidas acotadas con signo también son admisibles.

El parámetro desconocido y la observación son objetos diferentes. La familia (P_θ) indica cómo la información observada depende de lo desconocido. Una descripción que omita esta familia deja sin especificar la distribución necesaria para calcular el riesgo.

Definición 2.2 (Regla y clase de decisiones). Una regla determinista es una función medible $\delta : \mathcal{X} \to \mathcal{A}$. Una regla aleatorizada es un kernel $d(a|x)$ sobre acciones; cuando estas son finitas, $d(a|x) \geq 0$ y $\sum_a d(a|x) = 1$. La aleatorización utiliza información disponible y azar independiente del parámetro. Denotaremos por $\mathcal{D}$ la clase de reglas permitidas; debe indicarse si incluye aleatorización.

2.1.2 Función de Riesgo

Para una regla determinista,

$$R(\theta, \delta) = \mathbb{E}_{\theta[L(\theta,\delta(X))]}.$$

Para acciones finitas y una regla aleatorizada,

$$R(\theta, d) = \mathbb{E}_{\theta}\big[\sum_a d(a|X)L(\theta,a)\big].$$

El riesgo promedia sobre las muestras y sobre la aleatorización de la regla. Es una función de θ; en general ninguna regla minimiza simultáneamente todas sus componentes.

Ejemplo 2.3 (Pérdidas y objetivos).

Pérdida	Expresión	Riesgo
Cuadrática	$(a-\psi(\theta))^2$	Error cuadrático medio
Absoluta	$\lvert a-\psi(\theta)\rvert$	Error absoluto esperado
Clasificación	$\mathbb{1}_{a\neq g(\theta)}$	Probabilidad de clasificación errónea
Cuadrática ponderada	$w(\theta)(a-\psi(\theta))^2$	Error ponderado, con $w(\theta)\geq 0$

El objetivo $\psi(\theta)$ puede ser escalar aunque el modelo tenga dimensión infinita. La pérdida de clasificación compara acciones con una categoría $g(\theta)$; no exige que todo parámetro sea una etiqueta.

2.1.3 Admisibilidad y Dominancia

Definición 2.4 (Dominancia). En una clase $\mathcal{D}$, δ_1 domina a δ_2 si $R(\theta,\delta_1)\leq R(\theta,\delta_2)$ para todo θ, con desigualdad estricta para al menos uno.

Definición 2.5 (Admisibilidad). Una regla es admisible en $\mathcal{D}$ cuando ninguna otra regla de esa clase la domina. La admisibilidad descarta mejoras uniformes; no ordena todas las reglas ni establece optimalidad para un prior particular.

Ejemplo 2.6 (James–Stein y la dimensión del parámetro). Para $X\sim N_{p(\theta,I_p)}$, $p\geq 3$, y pérdida $\|a-\theta\|^2$, la regla $\delta_0(X)=X$ tiene riesgo p. El estimador

$$\delta_{\mathrm{JS}}(X)=\left(1-\frac{p-2}{\|X\|^2}\right)X$$

satisface

$$R(\theta,\delta_{\mathrm{JS}})=p-(p-2)^2\mathbb{E}_{\theta}\left[\tfrac{1}{\|X\|^2}\right]<p.$$

Su valor en $X=0$ se define arbitrariamente, pues ese evento tiene probabilidad cero. La esperanza es finita para $p\geq 3$. El resultado concierne a la dimensión p del parámetro, no al número de observaciones de una media escalar. La identidad de riesgo se justifica en Sección A.7.1.

La admisibilidad permite descartar algunas reglas sin introducir un prior. Para elegir según un promedio de riesgos, debemos especificar cómo se ponderan los modelos posibles. Esa elección conduce al criterio de Bayes.

2.1.4 Reglas de Bayes

Definición 2.7 (Prior y riesgo de Bayes). Un prior ν sobre Θ define el riesgo promedio

$$\rho_{\nu(\delta)}=\int_{\Theta}R(\theta,\delta)\nu(\mathrm{d}\theta).$$

Se reserva π para políticas secuenciales. El riesgo de Bayes óptimo es $b(\nu)=\inf_{\delta\in\mathcal{D}}\rho_{\nu(\delta)}$.

Universidad Curivil

Definición 2.8 (Regla de Bayes). Una regla δ_ν es de Bayes si alcanza $b(\nu)$. Su optimalidad se refiere al prior, a la pérdida y a la clase especificados.

Teorema 2.9 (Minimización de la pérdida posterior). *Suponga que existe un posterior regular $\nu(\mathrm{d}\theta|x)$, que $\mathcal{A}$ es finito, y que L es acotada y medible. Defina*

$$\ell_{\nu(x,a)} = \int L(\theta, a)\nu(\mathrm{d}\theta|x).$$

Elegir para cada x una acción que minimice $\ell_{\nu(x,a)}$, con desempate fijo, produce una regla medible de Bayes en la clase de todas las reglas, incluso aleatorizadas. Toda regla de Bayes debe concentrarse en acciones minimizadoras para casi toda observación según la distribución predictiva. Su comportamiento en conjuntos predictivamente nulos no queda determinado.

Demostración. Por esperanza iterada, $\rho_{\nu(\delta)} = \mathbb{E}\left[\ell_{\nu(X,\delta(X))}\right]$. La minimización puntual da una cota inferior alcanzable y la diferencia respecto de esa cota es no negativa. Si una regla alcanza el mismo riesgo, esa diferencia debe ser cero casi seguramente. Para aleatorización, el costo es una combinación convexa de pérdidas posteriores y no puede ser inferior al mínimo. Los detalles están en Sección A.7.2. □

Corolario 2.10 (Acciones posteriores para pérdidas habituales). *Bajo pérdida cuadrática escalar y segundo momento posterior finito, la media posterior minimiza la pérdida esperada. Bajo pérdida absoluta y primer momento posterior finito, cualquier mediana posterior es óptima. Bajo pérdida 0–1 para una cantidad discreta, se elige una categoría de máxima masa posterior cuando ese máximo existe.*

Estas afirmaciones para acciones continuas se justifican directamente: la pérdida cuadrática se descompone en varianza posterior más distancia cuadrática a la media; la condición de mediana caracteriza el mínimo de la pérdida absoluta. Para un posterior continuo sin átomos, la pérdida exacta $\mathbb{1}_{a\neq\theta}$ es uno casi seguramente para toda acción fija y no justifica elegir la moda de una densidad.

2.1.5 Relación entre Admisibilidad y Reglas de Bayes

Teorema 2.11 (Admisibilidad bayesiana en un modelo finito). *Si Θ es finito, $\nu(\theta) > 0$ para cada parámetro y δ_ν tiene riesgo de Bayes finito, entonces es admisible en la misma clase de comparación. Para espacios continuos se requieren otras condiciones; una desigualdad estricta en un solo punto de masa previa cero no basta para obtener contradicción.*

Demostración. Una regla dominante tendría una mejora no negativa para todo parámetro y positiva en alguno. Al ponderarla por masas previas estrictamente positivas se obtendría una mejora estricta del riesgo de Bayes, contradiciendo optimalidad. Si el prior no cubre todos los parámetros, el argumento deja de funcionar. □

Teorema 2.12 (Clase esencialmente completa en un problema finito). *Suponga finitos Θ, $\mathcal{X}$ y $\mathcal{A}$, pérdida finita y todas las reglas aleatorizadas permitidas. Toda regla admisible es de Bayes para algún prior, que puede asignar masa cero a ciertos parámetros. Además, para cualquier regla existe una regla de Bayes cuyo riesgo no es mayor en ningún parámetro. La afirmación se refiere a este problema finito; no establece un teorema general de límites de reglas de Bayes en espacios arbitrarios.*

La prueba usa la convexidad del conjunto de vectores de riesgo y un hiperplano de soporte; se desarrolla en Sección A.7.4. La inclusión de reglas aleatorizadas es relevante para esa convexidad. Ser de Bayes para un prior con ceros no garantiza admisibilidad, como muestra el ejercicio correspondiente.

El promedio bayesiano expresa una manera de comparar la incertidumbre sobre el modelo. Si la decisión se evalúa por su riesgo más alto, la comparación cambia: interesa protegerse frente al peor caso dentro de la familia declarada.

2.1.6 Reglas Minimax

Definición 2.13 (Riesgo máximo y regla minimax). Defina $M(\delta) = \sup_{\theta\in\Theta} R(\theta,\delta)$ y $M^* = \inf_{\delta\in\mathcal{D}} M(\delta)$. Una regla es minimax si alcanza M^*. La existencia del ínfimo como valor no implica que alguna regla lo alcance.

Teorema 2.14 (Certificación minimax mediante Bayes). *Si δ_ν es de Bayes y*

$$\sup_{\theta\in\Theta} R(\theta,\delta_\nu) = \rho_{\nu(\delta_\nu)} < \infty,$$

entonces es minimax. Basta que $R(\theta,\delta_\nu) \le \rho_{\nu(\delta_\nu)}$ para todos los parámetros. Un caso particular es una regla de Bayes de riesgo constante en todo Θ.

Demostración. Para cualquier regla δ,

$$\sup_\theta R(\theta,\delta) \ge \rho_{\nu(\delta)} \ge \rho_{\nu(\delta_\nu)} = \sup_\theta R(\theta,\delta_\nu).$$

El último paso exige el control del riesgo en todo el espacio. Constancia únicamente sobre el soporte del prior no garantiza esa igualdad. Véase Sección A.7.3. □

Definición 2.15 (Prior menos favorable). Un prior ν^* es menos favorable si maximiza $b(\nu) = \inf_\delta \rho_{\nu(\delta)}$ entre los priors considerados. Puede existir solo una sucesión menos favorable. Bajo la condición del teorema anterior, $b(\nu) = M^*$ y ν es menos favorable, porque $b(\eta) \le M^*$ para cualquier prior η.

Ejemplo 2.16 (Estimación Bernoulli con riesgo constante). Sea $X \sim \text{Bernoulli}(\theta)$, $\theta \in [0,1]$, con pérdida $(a-\theta)^2$. Bajo prior $\text{Beta}\left(\frac{1}{2},\frac{1}{2}\right)$, la media posterior es $\delta(X) = \frac{X+\frac{1}{2}}{2}$. Su sesgo es $\frac{1}{4} - \frac{\theta}{2}$ y su varianza es $\frac{\theta(1-\theta)}{4}$. Por tanto,

$$R(\theta,\delta) = \frac{\theta(1-\theta)}{4} + \left(\frac{1}{4} - \frac{\theta}{2}\right)^2 = \frac{1}{16}.$$

La regla es minimax por Teorema 2.14. Para $\delta_0(X) = X$, el riesgo máximo es $\frac{1}{4}$. La contracción hacia $\frac{1}{2}$ reduce el peor riesgo, aunque introduce sesgo. Este cálculo ilustra cómo una propiedad inferencial modifica una decisión de estimación.

2.1.7 Tests como reglas de decisión

Proposición 2.17 (Test como regla de decisión). *Para hipótesis que particionan Θ en Θ_0 y Θ_1, las acciones aceptar provisionalmente H_0 o rechazarla tienen pérdidas cero al acertar, $w_I > 0$ por falso rechazo y $w_{II} > 0$ por falso negativo. El riesgo es $w_I P_{\theta(\text{rechazar})}$ bajo H_0 y $w_{II} P_{\theta(\text{no rechazar})}$ bajo H_1. Para un problema bayesiano, se rechaza cuando*

$$w_I P(\Theta_0|X) < w_{II} P(\Theta_1|X).$$

El control frecuentista de nivel requiere una restricción sobre las probabilidades de rechazo bajo Θ_0. Elegir pérdidas y prior no garantiza automáticamente un nivel prefijado.

De la regla estadística al diseño de un agente

2.2.1 El Agente como Decisor Estadístico

El agente debe registrar qué observa, qué desconoce, qué acciones considera y qué pérdida usa para compararlas. La pérdida expresa el objetivo de decisión; el modelo determina cómo se promedian sus consecuencias. Un parámetro desconocido de la dinámica no es el estado físico observado del paciente.

2.2.2 El Modelo Estadístico como Modelo del Mundo

El marco de riesgo admite diferentes regímenes. En un modelo paramétrico, θ es un vector finito con interpretación especificada. En un modelo semiparamétrico se distingue un objetivo de interés de funciones nuisance. En un modelo no paramétrico, el índice puede representar una distribución o función en una clase infinita. Ninguna de estas elecciones elimina los supuestos de identificación.

La representación $\theta = (\psi, \eta)$ permite distinguir el objetivo ψ de los componentes auxiliares η. Una pérdida $L(\theta, a) = (a - \psi)^2$ sigue definiendo un problema de decisión aunque η sea una función. Las herramientas para estimarlo y cuantificar su incertidumbre se desarrollan en Capítulo 4.

2.2.3 Políticas Bayesianas

Para una decisión terminal, se minimiza la pérdida posterior esperada. Si la acción altera observaciones futuras, debe incluirse el costo futuro en la optimización. Una sucesión de acciones miopes que minimizan la pérdida inmediata no es necesariamente bayesianamente óptima para el horizonte completo. El Teorema 5.5 formaliza un caso finito de observación y parada sobre estados de creencia.

2.2.4 Políticas Minimax: Robustez

El criterio minimax controla el máximo riesgo esperado dentro de la familia declarada. Su interpretación depende de que esa familia y la pérdida describan las incertidumbres relevantes. No es una garantía de seguridad en cada trayectoria ni cubre automáticamente entornos fuera de la clase. La aleatorización puede mejorar el máximo riesgo.

2.2.5 Metacriterios de Decisión

La elección del criterio se justifica por el problema: disponibilidad de un prior defendible, costos de error, incertidumbres plausibles y restricciones de operación. Puede estudiarse sensibilidad a varios priors o a una clase de modelos. Cambiar de criterio según los mismos datos utilizados para evaluar la regla define un procedimiento nuevo, cuyo riesgo debe analizarse como un todo.

Hilo longitudinal: SSCH

Ejemplo 2.18 *(sintético)* **(SSCH: señal, pérdida y clase de reglas).** Considere el ejemplo sintético de Ejemplo 5.14: $\theta \in \{0, 1\}$ indica necesidad de seguimiento intensificado; $P_0(X = 1) = 0.2$ y $P_1(X = 1) = 0.8$. Se pierde una unidad al intensificar sin necesidad y cuatro al no intensificar cuando sí se necesita. Con prior $\nu(1) = 0.3$ se obtiene:

Regla	$R(0)$	$R(1)$	**Riesgo promedio**
Siempre ordinario	0	4	1.20
Siempre intensificado	1	0	0.70
Seguir la señal	0.20	0.80	0.38
Invertir la señal	0.80	3.20	1.52

Seguir la señal es Bayes y minimax entre las cuatro reglas deterministas. Al permitir aleatorización, una regla mejor en peor caso intensifica siempre si $X = 1$ y con probabilidad $\frac{3}{8}$ si $X = 0$. Sus riesgos son ambos $\frac{1}{2}$, inferiores a 0.8.

Para verificar minimax en la clase ampliada, use el prior $\nu^*(1) = \frac{1}{2}$. Si $X = 0$, el posterior de $\theta = 1$ es $\frac{1}{5}$, justo el umbral de indiferencia; si $X = 1$, es $\frac{4}{5}$ y conviene intensificar. La regla aleatorizada es Bayes para ese prior y tiene riesgo constante, por lo que es minimax. La elección de la clase cambia la respuesta aunque los datos y las pérdidas sean idénticos.

2.2.6 Trazabilidad: Del Teorema al Componente

Resultado	Componente	Alcance
Definición 2.1	Especificación de datos y pérdidas	Define el problema evaluado
Teorema 2.9	Minimización posterior	Riesgo promedio bajo el prior
Teorema 2.14	Comparación de peor caso	Control sobre toda la clase de modelos
Teorema 2.11	Descarte de reglas dominadas	Modelo finito y prior positivo
Teorema 2.12	Organización de reglas	Problema finito con aleatorización

Tabla 2.1: Del criterio de decisión a su uso en el agente.

2.2.7 La misma decisión expresada como una política

Proposición 2.19 (Identidad entre riesgo y retorno de una decisión). *En la familia de una decisión definida en Teorema 5.3, la política $\pi_{\delta(x)} = \delta(x)$ recibe recompensa evaluativa $r_{\theta(x,a)} = -L(\theta, a)$ y cumple*

$$J_{\theta(\pi_\delta)} = -R(\theta, \delta).$$

El retorno J_θ promedia sobre $X \sim P_\theta$. La política es común a todos los parámetros y no observa el verdadero θ. La igualdad se obtiene sustituyendo la recompensa dentro de la esperanza.

Cuando la acción cambia el futuro

El capítulo siguiente estudia qué cambia cuando una acción modifica el estado y las recompensas futuras. Primero supondrá conocido el modelo para separar la planificación de la estimación. La identidad de una decisión no reemplaza el análisis dinámico, y las garantías de cálculo tampoco sustituyen las garantías inferenciales sobre modelos aprendidos.

Los ejercicios retoman esas diferencias de criterio. Permiten comprobar cómo cambian la regla y su riesgo al modificar el prior, la pérdida o la clase de decisiones permitidas.

Ejercicios

Ejercicio 2.1. *Sea $X|\theta \sim N(\theta, 1)$ y $\theta \sim N(\mu_0, \tau^2)$ con $\tau^2 > 0$. Derive posterior, regla bajo pérdida cuadrática y riesgo de Bayes. Estudie el límite de la regla cuando τ^2 aumenta y distinga ese límite de la existencia de un prior propio límite.*

Ejercicio 2.2. *Compare estimar una media escalar con n observaciones y estimar un vector de dimensión p a partir de $X \sim N_{p(\theta, I_p)}$. Explique cuál dimensión interviene en James–Stein. Calcule el riesgo de X y use la identidad del apéndice para comparar con la regla contraída.*

Ejercicio 2.3. *Reproduzca el cálculo Bernoulli de Ejemplo 2.16. Determine las acciones cuando $X = 0$ y $X = 1$, el sesgo y el riesgo constante. Justifique por qué el prior utilizado es menos favorable.*

Ejercicio 2.4. *Sin observaciones informativas, considere dos parámetros y dos acciones con pérdidas* $L(0, a_0) = 0$, $L(1, a_0) = 2$ *y* $L(0, a_1) = L(1, a_1) = 0$. *Bajo un prior concentrado en* $\theta = 0$, *ambas acciones son de Bayes. Muestre que una está dominada y que constancia de su riesgo sobre el soporte del prior no certifica minimax.*

Ejercicio 2.5. *En el SSCH, escriba los riesgos en función de* $q_0 = P(a = 1|X = 0)$ *y* $q_1 = P(a = 1|X = 1)$. *Verifique la regla minimax aleatorizada y el prior que la certifica. Compare su riesgo bajo* $\nu(1) = 0.3$ *con el de seguir la señal. Explique por qué un criterio puede preferir una regla que el otro no prefiere.*

Lecturas Propuestas

Wald (1950) presenta el marco fundacional. Para pérdidas, reglas bayesianas y minimax, consulte Berger (1985) y Ferguson (1967). Los ejemplos deben leerse con la clase de reglas y las condiciones de cada resultado.

Como apoyo abierto, las notas de Stat 210A sobre estimación minimax desarrollan la certificación mediante Bayes. Los argumentos utilizados aquí se incluyen en el apéndice para que el alcance de cada afirmación sea comprobable.

Cesáreo Jaime Lincovil Curivil

Capítulo 3

Procesos de decisión de Markov

El Capítulo 2 separó datos, reglas y consecuencias. Cuando una acción modifica las oportunidades futuras, comparar solo la pérdida inmediata resulta insuficiente. Un proceso de decisión de Markov permite describir esas consecuencias y calcular políticas que consideran el futuro. El problema estadístico aparece cuando sus recompensas o transiciones deben aprenderse a partir de datos.

La programación dinámica de Bellman (1957) descompone una decisión secuencial en decisiones actuales y problemas de continuación. Su utilidad depende de que el estado conserve la información necesaria para predecir recompensas y transiciones. Un registro de conversación o una variable denominada «estado» en un programa no satisface automáticamente esa condición.

Este capítulo desarrolla garantías de planificación en MDP finitos, descontados y conocidos. Después distingue esas garantías de las necesarias para aprender el modelo. El Capítulo 5 construye una representación precisa de decisiones de Wald en una familia de MDP de un paso con transición terminal determinista; esa construcción no identifica todo problema de inferencia con un MDP secuencial arbitrario.

Planificar con un modelo conocido

3.1.1 Definición Formal del MDP

Definición 3.1 (Proceso de decisión de Markov). En este capítulo, $\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, r, \gamma)$ tiene estados y acciones finitos y no vacíos. Para cada (s, a), $P(s'|s, a) \geq 0$ y $\sum_{s'} P(s'|s, a) = 1$. La recompensa esperada satisface $|r(s, a)| \leq R_{\max} < \infty$ y $0 \leq \gamma < 1$. Una distribución inicial ρ permite definir el valor agregado $J_\rho^\pi = \sum_s \rho(s) V^{\pi(s)}$.

Se permite una recompensa aleatoria cuya esperanza condicional sea $r(s, a)$; para las fórmulas de valor basta integrabilidad y la cota correspondiente. Un estado terminal puede modelarse como absorbente con recompensa posterior cero. Las extensiones a espacios numerables o continuos necesitan especificar espacios funcionales, medibilidad y existencia de selectores; no se incluyen en el teorema finito.

Definición 3.2 (Política). Una política estacionaria aleatorizada asigna probabilidades $\pi(a|s)$; una determinista asigna una acción $\pi(s)$. En la clase general, una política puede depender del tiempo y de toda la historia observada. Las políticas deben usar únicamente información disponible al actuar.

Definición 3.3 (Propiedad de Markov). Para historias con probabilidad positiva,

$$\mathbb{P}(S_{t+1} = s' | S_0, A_0, \ldots, S_t, A_t) = P(s' | S_t, A_t).$$

Además, la recompensa condicional esperada está determinada por (S_t, A_t). Estas propiedades corresponden al estado y al modelo elegidos.

3.1.2 Funciones de Valor

Definición 3.4 (Valor de estado). Para una política estacionaria,

$$V^{\pi(s)} = \mathbb{E}_s^{\pi}\left[\sum_{t=0}^{\infty} \gamma^t r(S_t, A_t)\right].$$

Definición 3.5 (Valor de acción). $Q^{\pi(s,a)}$ es el retorno esperado al iniciar en s, imponer a como primera acción y seguir π desde el siguiente instante. Esta definición también vale si $\pi(a|s) = 0$; no condiciona en un suceso imposible bajo la política.

Proposición 3.6 (Relación entre valores).

$$Q^{\pi(s,a)} = r(s,a) + \gamma \sum_{s'} P(s'|s,a) V^{\pi(s')}, \quad V^{\pi(s)} = \sum_{a} \pi(a|s) Q^{\pi(s,a)}.$$

Proposición 3.7 (Acotación). $\left|V^{\pi(s)}\right| \leq \frac{R_{\max}}{1-\gamma}$. *Se obtiene tomando valores absolutos y sumando la serie geométrica. La misma cota vale para Q^{π}.*

3.1.3 Ecuaciones de Bellman

Teorema 3.8 (Bellman para una política estacionaria).

$$V^{\pi(s)} = \sum_{a} \pi(a|s) \left[r(s,a) + \gamma \sum_{s'} P(s'|s,a) V^{\pi(s')} \right].$$

Demostración. Separar la recompensa inicial del retorno restante, condicionar en la primera acción y el siguiente estado, y usar estacionariedad. La cota geométrica justifica intercambiar esperanza y suma. Véase también (argumento y alcance en Apéndice A, pág. 230). □

Definición 3.9 (Valor óptimo). $V^*(s) = \sup_{\pi} V^{\pi(s)}$, donde el supremo admite políticas dependientes de la historia. Una política es óptima si alcanza este valor en cada estado.

Teorema 3.10 (Bellman de optimalidad). *En el MDP finito descontado existe una política estacionaria determinista óptima y*

$$V^*(s) = \max_{a} \left[r(s,a) + \gamma \sum_{s'} P(s'|s,a) V^*(s') \right].$$

Con $Q^*(s,a) = r(s,a) + \gamma \sum_{s'} P(s'|s,a) V^*(s')$, se obtiene también

$$Q^*(s,a) = r(s,a) + \gamma \sum_{s'} P(s'|s,a) \max_{a'} Q^*(s',a').$$

El valor óptimo es único; las políticas óptimas pueden ser varias si hay empates.

La demostración identifica el punto fijo, construye una política greedy y verifica que domina incluso a políticas con memoria: (argumento y alcance en Apéndice A, pág. 232).

La ecuación de Bellman describe un equilibrio entre la recompensa actual y el valor de continuar. Para calcular ese equilibrio necesitamos saber cómo cambia la ecuación cuando cambia la función de valor que se introduce en ella. La contracción permite controlar esa diferencia.

3.1.4 Operadores de Bellman y Contracción

Definición 3.11 (Operadores de Bellman). Para $V \in \mathbb{R}^{|\mathcal{S}|}$,

$$(T^{\pi} V)(s) = \sum_{a} \pi(a|s) \left[r(s,a) + \gamma \sum_{s'} P(s'|s,a) V(s') \right],$$

$$(T^*V)(s) = \max_{a\left[r(s,a)+\gamma\sum_{s'}P(s'|s,a)V(s')\right]}.$$

Teorema 3.12 (Contracción en norma supremo). *Para $T = T^\pi$ o $T = T^*$,*

$$\|TV - TW\|_\infty \leq \gamma\|V - W\|_\infty.$$

Demostración. La diferencia de dos máximos está acotada por el máximo de las diferencias absolutas. Cada promedio con P está acotado por $\|V - W\|_\infty$. Multiplicar por γ da el resultado. Para T^π, el promedio adicional sobre acciones mantiene la cota. Véase (argumento y alcance en Apéndice A, pág. 231). □

Corolario 3.13 (Puntos fijos únicos). *La completitud del espacio finito con norma supremo y el teorema de Banach dan puntos fijos únicos: V^π para T^π y V^* para T^*.*

La contracción convierte la recursión en un procedimiento de cálculo: al aplicar repetidamente el operador, la distancia al punto fijo se reduce. El residuo de cada paso permitirá además expresar un criterio de parada con un significado preciso.

3.1.5 Value Iteration

Inicializar $V_0 = 0$. En cada paso calcular $W = T^*V_k$ y el residuo $e_k = \|W - V_k\|_\infty$. Si se satisface la tolerancia elegida, devolver V_k y una política greedy respecto de ese mismo vector. En otro caso asignar $V_{k+1} = W$ y continuar. Conservar este orden evita aplicar una cota a un vector distinto del usado para extraer la política.

Teorema 3.14 (Convergencia de Value Iteration).

$$\|V_k - V^*\|_\infty \leq \gamma^k\|V_0 - V^*\|_\infty.$$

Con $V_0 = 0$, la cota es $\gamma^k \frac{R_{\max}}{1-\gamma}$.

Demostración. Aplicar la contracción k veces y usar $T^*V^* = V^*$; luego aplicar la cota del valor óptimo. □

Corolario 3.15 (Certificados de parada). *Para cualquier V, sea $e = \|T^*V - V\|_\infty$ y sea π_V greedy respecto de V. Entonces*

$$\|V - V^*\|_\infty \leq \frac{e}{1-\gamma},$$

$$\|V^* - V^{\pi_V}\|_\infty \leq \frac{2\gamma e}{(1-\gamma)^2}.$$

Para certificar error de valor a lo sumo ϵ, basta $e \leq \epsilon(1-\gamma)$. Para pérdida de política a lo sumo ϵ y $\gamma > 0$, basta $e \leq \frac{\epsilon(1-\gamma)^2}{2\gamma}$. Si $\gamma = 0$, maximizar r resuelve directamente el problema.

La primera desigualdad usa $\|V - V^*\| \leq e + \gamma\|V - V^*\|$. La segunda combina esa desigualdad con la cota de una política greedy demostrada en (argumento y alcance en Apéndice A, pág. 233). Son dos objetivos de precisión diferentes.

3.1.6 Policy Iteration

Inicializar una política determinista. Evaluarla resolviendo $(I - \gamma P^\pi)V^\pi = r^\pi$. Mejorarla escogiendo acciones que maximicen $r(s,a) + \gamma\sum_{s'} P(s'|s,a)V^{\pi(s')}$. **En un empate, conservar la acción actual si es maximizadora.** Detenerse cuando no cambie ninguna acción. La evaluación aquí es exacta; los errores de un solucionador numérico requieren control adicional.

Universidad Curivil

Teorema 3.16 (Mejora de políticas). *Una política greedy π' respecto de V^π satisface $V^{\pi'} \geq V^\pi$. Con la regla de desempate anterior, si cambia una acción, la desigualdad es estricta en al menos un estado.*

Demostración. Sea $d = T^{\pi'}V^\pi - V^\pi \geq 0$. Entonces

$$V^{\pi'} - V^\pi = \left(I - \gamma P^{\pi'}\right)^{-1} d = \sum_{j=0}^{\infty} \gamma^j \left(P^{\pi'}\right)^j d \geq 0.$$

Si una acción cambia bajo la regla indicada, $d(s) > 0$ en algún estado y el término $j = 0$ prueba la mejora estricta. □

Corolario 3.17 (Terminación finita). *No se repite ninguna política antes de detenerse. Hay a lo sumo $|\mathcal{A}|^{|\mathcal{S}|}$ políticas deterministas. Al detenerse, $T^*V^\pi = V^\pi$, de modo que la política es óptima. Este argumento es de mejora y finitud; no afirma que la iteración de políticas sea una contracción.*

3.1.7 Bandidos Multi-Brazo: Exploración y Aprendizaje

Un bandido separa el aprendizaje de recompensas de las transiciones físicas. La elección actual modifica los datos disponibles para elecciones futuras. Por ello, un bandido con varias rondas sigue siendo un problema secuencial aunque no cambie el estado físico.

Definición 3.18 (Bandido estocástico). Hay K brazos con distribuciones desconocidas ν_a, medias μ_a y horizonte T. Las recompensas sucesivas de cada brazo son independientes e idénticamente distribuidas; las secuencias de los brazos son independientes. La acción A_t usa la historia anterior. Definimos $\mu^* = \max_a \mu_a$, $\Delta_a = \mu^* - \mu_a$ y el pseudorregret esperado

$$\mathcal{R}_T = \mathbb{E}\left[\sum_{t=1}^{T} \Delta_{A_t}\right] = \sum_a \Delta_a \mathbb{E}\left[N_{a(T)}\right].$$

Proposición 3.19 (Estado físico y estado de información). *Con medias conocidas, un bandido puede representarse como un MDP de un estado que elige repetidamente un brazo óptimo. Con medias desconocidas, la planificación bayesiana debe incluir el posterior y el horizonte restante. Una única ronda no contiene el beneficio futuro de explorar. El estado físico constante no convierte todo el aprendizaje en un problema de un paso.*

Teorema 3.20 (UCB1: garantía bajo recompensas acotadas). *Para recompensas en $[0, 1]$ y $T \geq K$, UCB1 juega cada brazo una vez y luego elige un máximo de*

$$\hat{\mu}_{a(t-1)} + \sqrt{\frac{2\log t}{N_{a(t-1)}}}.$$

El resultado de (Auer et al., 2002) establece

$$\mathcal{R}_T \leq 8 \sum_{a:\Delta_a>0} \frac{\log T}{\Delta_a} + \left(1 + \frac{\pi^2}{3}\right) \sum_a \Delta_a.$$

Es una cota dependiente de las brechas. No asegura que la constante asintótica sea óptima.

Este resultado se usa con atribución bibliográfica; su demostración completa no se desarrolla aquí. Combina concentración de medias con un control del número de selecciones de brazos subóptimos. Las hipótesis de independencia y acotación son parte de la garantía, no propiedades automáticas de datos longitudinales.

Proposición 3.21 (Thompson Sampling y decisión de Bayes). *Thompson Sampling extrae un vector de medias del posterior conjunto y selecciona un brazo que maximice la muestra. Sin empates,*

la probabilidad de seleccionar un brazo coincide con su probabilidad posterior de ser óptimo. Esto no implica que minimice el riesgo posterior de la acción actual ni el riesgo bayesiano del horizonte completo.

Con una sola ronda restante, la regla de Bayes para maximizar recompensa elige la mayor media posterior. El ejemplo al final del capítulo exhibe la diferencia mediante un cálculo exacto.

Teorema 3.22 (Cota asintótica en bandidos Bernoulli). *Considérese la familia de bandidos Bernoulli con medias en* $(0,1)$ *y mejor brazo único. Una política uniformemente eficiente satisface* $\mathcal{R}_T = o(T^\alpha)$ *para todo* $\alpha > 0$ *en cada instancia de la familia. La cota de tipo Lai–Robbins es*

$$\liminf_{T\to\infty} \frac{\mathcal{R}_T}{\log T} \geq \sum_{a:\Delta_a>0} \frac{\Delta_a}{\mathrm{kl}(\mu_a, \mu^*)},$$

donde $\mathrm{kl}(p,q) = p\log\left(\frac{p}{q}\right) + (1-p)\log\left(\frac{1-p}{1-q}\right)$.

La demostración por cambio de medida y sus extensiones se remiten a (Lai & Robbins, 1985) y (Lattimore & Szepesvári, 2020). La formulación se restringe a Bernoulli: para familias generales, la información relevante requiere optimizar sobre distribuciones alternativas. UCB1 no alcanza en general la constante de esta cota. Cualquier afirmación de optimalidad de otra variante debe indicar algoritmo, familia y condiciones.

Ejemplo 3.23 *(sintético)* **(SSCH: una comparación calculable de exploración).** Como ilustración matemática, cuatro opciones tienen probabilidades de éxito $(0.3, 0.5, 0.6, 0.8)$. No son estimaciones clínicas. La media de una selección uniforme es 0.55, por lo que en 20 rondas su pseudorregret esperado es $20(0.8 - 0.55) = 5$. El oráculo que conoce las medias tiene pseudorregret cero. Probar una vez cada opción cuesta en expectativa $0.5 + 0.3 + 0.2 + 0 = 1$ de pseudorregret.

Estas cifras son cálculos de expectativas bajo el modelo declarado. No se atribuyen porcentajes de éxito a UCB1 o Thompson Sampling sin ejecutar un experimento. Una aplicación real necesitaría definir población, resultados observables, tiempos de observación, heterogeneidad y restricciones sobre las acciones.

3.1.8 Bandidos, Memoria y Horizonte

Definición 3.24 (Estado posterior Beta–Bernoulli). Para brazos Bernoulli con priors Beta independientes, el estado de información reúne (α_a, β_a) para cada brazo y el número de rondas restantes. Tras un éxito en a, aumentar α_a; tras un fracaso, aumentar β_a. La probabilidad predictiva de éxito es $\frac{\alpha_a}{\alpha_a+\beta_a}$.

Proposición 3.25 (Última ronda). *Con una ronda restante y utilidad igual a la recompensa, la acción bayesiana maximiza la media posterior. La exploración no aporta recompensa futura dentro de ese horizonte. Con más rondas, la recursión óptima debe considerar la actualización del posterior y su efecto sobre decisiones posteriores.*

Ejemplo 3.26 *(sintético)* **(SSCH: muestreo posterior frente a decisión final).** Considere dos opciones con posteriores independientes $\mu_1 \sim \mathrm{Beta}(4,1)$ y $\mu_2 \sim \mathrm{Beta}(1,1)$. Sus medias son 0.8 y 0.5. Una decisión bayesiana de última ronda elige la primera opción y obtiene recompensa predictiva 0.8.

Thompson Sampling elige la primera con probabilidad $\mathbb{P}(\tilde{\mu}_1 > \tilde{\mu}_2) = \mathbb{E}[\tilde{\mu}_1] = 0.8$. Como el muestreo interno es independiente de los parámetros verdaderos condicionalmente a los datos, su recompensa predictiva es $0.8(0.8) + 0.2(0.5) = 0.74$. La diferencia 0.06 muestra que muestrear del posterior y actuar según esa muestra no equivale a minimizar el riesgo posterior. El cálculo es sintético y no compara desempeño a largo plazo.

3.1.9 Conexión con Teoría de Decisión de Wald

Nota 3.27 (Alcance de la representación). En el Capítulo 5, el estado inicial es la observación $X \sim P_\theta$, la política reproduce la regla de decisión y la recompensa es $-L(\theta, a)$. Después de actuar se pasa determinísticamente a un estado terminal. Para cada parámetro, el valor agregado sobre la distribución inicial satisface $J_{\theta(\pi_\delta)} = -R(\theta, \delta)$. Es una familia indexada por θ; el agente no recibe ese parámetro desconocido como información para actuar.

No se introduce una recursión sobre un supuesto «siguiente parámetro» sin especificar su dinámica. La programación dinámica bayesiana de observación y parada requiere un modelo secuencial adicional y un estado posterior suficiente, como se desarrolla por separado en ese capítulo.

Corolario 3.28 (Principio de continuación óptima). *En el MDP finito descontado, seleccionar en cada estado una acción que maximice la expresión de Bellman para V^* produce una política óptima. Se deduce de que su operador tiene a V^* como punto fijo. No equivale por sí solo a admisibilidad estadística sobre una familia de modelos desconocidos.*

3.1.10 Condiciones para Preservación de Contracción

Proposición 3.29 (Condiciones suficientes). *Un kernel estocástico, recompensas acotadas y $\gamma < 1$ bastan para que Bellman actúe sobre funciones acotadas y sea una contracción en norma supremo. La recompensa se cancela al comparar dos aplicaciones del operador; su cota asegura que este preserve el espacio. Estas condiciones no se presentan como una caracterización necesaria de todos los operadores posibles.*

Proposición 3.30 (Proyección y norma pertinente). *Si una aproximación Π es Lipschitz con constante L en norma supremo, ΠT^* tiene constante a lo sumo $L\gamma$. Por tanto $L\gamma < 1$ es una condición suficiente de contracción sobre un espacio completo que el operador preserve. Una proyección lineal arbitraria no garantiza esa desigualdad.*

Para evaluar una política fija, si μ es una distribución estacionaria estrictamente positiva de P^π, Jensen da $\|P^\pi v\|_\mu \leq \|v\|_\mu$. Una proyección ortogonal en $L^2(\mu)$ es no expansiva, de modo que ΠT^π es una contracción de factor γ en esa norma. Este argumento no se extiende automáticamente al operador óptimo ni a una distribución de muestreo distinta.

Procedimiento	Condición	Conclusión
VI exacto	MDP finito descontado	Contracción en norma supremo
PI exacto	Evaluación exacta y conservación en empates	Mejora y terminación finita
VI proyectado	$L\gamma < 1$ en el espacio indicado	Punto fijo aproximado único
Evaluación proyectada	Política fija, distribución estacionaria y proyección ortogonal	Contracción en $L^2(\mu)$
Métodos ajustados a datos	Hipótesis específicas del estimador y muestreo	No hay garantía universal

Tabla 3.1: Condiciones de convergencia

Del operador de Bellman al cálculo de una política

3.2.1 Value Iteration como Flujo de Computación

El nodo de actualización calcula $W = T^*V$. El de verificación calcula $e = \|W - V\|_\infty$ y comprueba la tolerancia seleccionada. El de extracción devuelve una política greedy respecto de V, junto con el residuo, el descuento y la cota certificada. Registrar el objetivo —error de valor o pérdida de política — permite interpretar la parada.

3.2.2 Criterios de Parada Rigurosos

Para $0 < \gamma < 1$, $R_{\max} > 0$ y $V_0 = 0$, una cantidad suficiente de actualizaciones para error de valor $\epsilon > 0$ es

$$k \geq \max\left(0, \left\lceil \frac{\log\left(\frac{R_{\max}}{\epsilon(1-\gamma)}\right)}{\log\left(\frac{1}{\gamma}\right)} \right\rceil\right).$$

Para certificar una política, puede usarse directamente el residuo y el Corolario 3.15. Cuando γ se aproxima a uno, ambas cotas se deterioran. Un residuo pequeño calculado con un modelo estimado certifica planificación dentro de ese modelo; no certifica exactitud respecto del entorno verdadero.

(ver Apéndice C)

Hilo longitudinal: SSCH

Ejemplo 3.31 *(sintético)* **(SSCH: modelo reducido de dos estados).** Para aislar el efecto del futuro, se introduce una reducción pedagógica, no una especificación completa del caso longitudinal. Hay estados g y b, acciones 0 y 1, y descuento $\gamma = 0.9$. Todas las transiciones son deterministas:

Estado	Acción	Recompensa	Siguiente estado
g	0	1	b
g	1	0.5	g
b	0	0	b
b	1	-0.5	g

La solución es $V^*(g) = 5$, $V^*(b) = 4$, con acción 1 en ambos estados. En g, los valores de las acciones son $1 + 0.9(4) = 4.6$ y $0.5 + 0.9(5) = 5$. En b son $0.9(4) = 3.6$ y $-0.5 + 0.9(5) = 4$. Esto verifica Bellman y, por unicidad, prueba optimalidad.

Desde cero, las primeras iteraciones son $V_1 = (1, 0)$, $V_2 = (1.4, 0.4)$ y $V_3 = (1.76, 0.76)$. Maximizar solo la recompensa inmediata elegiría 0 en ambos estados. El ejemplo muestra por qué el costo actual puede compensarse con consecuencias futuras; no valida una recomendación clínica.

3.2.3 FrozenLake-v1: Verificación Computacional en Entorno Estándar

Ejemplo 3.32 (Value Iteration con modelo tabular explícito). Se usa el mapa estándar 4x4 de FrozenLake-v1, con deslizamiento y $\gamma = 0.99$. Las acciones son izquierda, abajo, derecha y arriba, codificadas de 0 a 3. Las recompensas son uno al alcanzar la meta y cero en los demás casos. El indicador terminal anula el retorno futuro. Se resuelve el modelo base, sin el límite temporal del wrapper de episodios.

```
import gymnasium as gym
import numpy as np

env = gym.make("FrozenLake-v1", map_name="4x4", is_slippery=True)
P = env.unwrapped.P
gamma = 0.99
```

```
V = np.zeros(16)
for k in range(10000):
    Q = np.array([
        [sum(p * (r + gamma * (not done) * V[next_s])
             for p, next_s, r, done in P[s][a])
         for a in range(4)] for s in range(16)
    ])
    W = Q.max(axis=1)
    residual = np.max(np.abs(W - V))
    if residual <= 1e-12:
        break
    V = W
else:
    raise RuntimeError("No se alcanzo la tolerancia")
policy = Q.argmax(axis=1)
print(gym.__version__, k, residual, V[[0, 14, 15]])
env.close()
```

Con Gymnasium 1.4.0, esta ejecución devuelve $k = 703$, residuo aproximadamente 9.805×10^{-13} y valores $(0.54202593, 0.86283743, 0)$. El índice k cuenta las actualizaciones aceptadas antes de comprobar la parada; se realizan 704 evaluaciones del operador. La cota de error del vector es menor que 10^{-10} y la cota conservadora de pérdida de la política es menor que 1.98×10^{-8}.

El valor inicial es un retorno descontado, no una tasa de éxito por episodio. Esta comprobación numérica ilustra las fórmulas; no sustituye la prueba de contracción ni informa una comparación experimental entre algoritmos. Documentación: FrozenLake de Gymnasium.

3.2.4 Trazabilidad: Del Teorema al Componente

Resultado	Componente	Comprobación
MDP	Representación del estado	Kernel, recompensa y propiedad de Markov
Bellman	Planificador	Modelo y objetivo descontado definidos
Contracción	Actualizador de valores	Descuento y norma
Mejora de políticas	Evaluación y mejora	Exactitud y regla de desempate
Cota residual	Parada y extracción	Mismo vector para residuo y política
Inferencia del valor	Estimador basado en trayectorias	Supuestos estadísticos adicionales

Tabla 3.2: Garantías y evidencia necesaria

Del modelo conocido al modelo aprendido

Estimar P mediante un modelo paramétrico fija una familia de transiciones de dimensión finita. En un espacio finito fijo, incluso una tabla completamente libre tiene dimensión finita: «tabular» no significa automáticamente «no paramétrico». En espacios continuos pueden emplearse modelos no paramétricos de transición o recompensa, con condiciones de suavidad y cobertura. Un enfoque semiparamétrico puede dirigir la inferencia al escalar J_ρ^π dejando componentes auxiliares de dimensión infinita.

Estas son elecciones sobre el modelo estadístico, distintas del algoritmo de Bellman. Una tabla estimada que sigue siendo estocástica conserva la contracción de su operador exacto; aun así, su punto fijo puede diferir del valor verdadero. El Capítulo 4 desarrolla instrumentos para analizar esa incertidumbre; el Capítulo 7 estudia evaluación con datos de otra política. El Capítulo 5 delimita la representación de Wald y el Capítulo 6 estudia fronteras de transferencia.

Ejercicios

Ejercicio 3.1. *Use la tabla completa del ejemplo reducido de SSCH. Escriba Bellman, verifique* $V^* = (5, 4)$ *y calcule las tres primeras iteraciones desde cero. Evalúe la política que siempre elige* 0 *y compare ambas políticas.*

Ejercicio 3.2. *Demuestre la contracción de* T^π *y construya un MDP con varias políticas óptimas y un único valor óptimo. Explique por qué cambiar acciones empatadas puede impedir la parada basada en igualdad de políticas.*

Ejercicio 3.3. *Para* $R_{\max} = 10$, $\gamma = 0.95$ *y* $V_0 = 0$, *calcule cantidades suficientes de actualizaciones para errores de valor* 0.1 *y* 0.01. *Después calcule los umbrales residuales que certifican esas mismas tolerancias como pérdidas de política. Distinga ambas preguntas.*

Ejercicio 3.4. *Compare el costo de una actualización de VI con el de resolver el sistema lineal de PI. Explique por qué menos iteraciones no implica necesariamente menor tiempo total. Identifique qué cambia si la evaluación de la política es aproximada.*

Ejercicio 3.5. *En la representación de un paso del Capítulo 5, derive* $J_{\theta(\pi_\delta)} = -R(\theta, \delta)$ *integrando sobre el estado inicial. Indique qué hipótesis adicionales exigiría representar una decisión con observaciones futuras dependientes de las acciones.*

Lecturas Propuestas

Lecturas Obligatorias

1. Puterman (2005), *Markov Decision Processes*: modelos descontados, evaluación y mejora de políticas.
2. Sutton & Barto (2018), *Reinforcement Learning*: capítulos sobre MDP y programación dinámica. Distinguir modelo conocido y aprendizaje.

Lecturas Complementarias

1. Bellman (1957), *Dynamic Programming*: principio de optimalidad.
2. Lattimore & Szepesvári (2020), *Bandit Algorithms*: UCB, cotas por cambio de medida y muestreo posterior. Texto de los autores.
3. Documentación de FrozenLake enlazada en el ejemplo: revisar recompensas, terminalidad y diferencia entre el modelo base y los wrappers antes de replicar resultados.

Borrador preliminar

Capítulo 4

Herramientas de transferencia

La transferencia de una garantía exige identificar el modelo estadístico, el objetivo y la unidad de observación. Este capítulo reúne las herramientas para hacerlo: reducción de datos y estimación paramétrica, aproximaciones asintóticas y no paramétricas, y teoría semiparamétrica para objetivos escalares con componentes auxiliares complejos. La suficiencia de una muestra no garantiza por sí sola un estado de Markov controlado; esa distinción y la representación de una decisión se precisan en el Capítulo 5.

Ejemplo 4.1 (Motivación: estimar una decisión con modelos auxiliares). Un sistema compara dos acciones a partir de resultados Y, tratamiento A y covariables previas X. El objetivo puede ser $\psi = \mathbb{E}[Y(1) - Y(0)]$. Antes de estimarlo se requieren consistencia, intercambiabilidad condicional y positividad. La propensión $e(X) = P(A = 1|X)$ y las medias $m_a(X) = \mathbb{E}[Y|A = a, X]$ ayudan a estimar ese objetivo.

Ponderar con la propensión verdadera permite una identidad insesgada; sustituirla por una estimación no conserva insesgadez finita automáticamente. La doble robustez pertenece a un estimador aumentado específico: su sesgo poblacional se anula si la propensión o las dos medias condicionales son correctas. Más adelante se deriva esa identidad y se distingue de la normalidad asintótica y de la identificación causal.

Del modelo a la información que conservan los datos

4.1.1 El Problema de Inferencia Estadística: Estructura Formal

Para el investigador que diseña un agente, el modelo paramétrico $\mathcal{P}_\theta$ no es una abstracción: es la *hipótesis de trabajo* sobre cómo el ambiente genera observaciones. La inferencia estadística responde: *dada esta hipótesis y estos datos, qué decisiones son racionales?* La quíntupla $\mathcal{I} = (\mathcal{P}, \theta, \mathcal{X}, T, \mathcal{C})$ formaliza esta pregunta.

La inferencia estadística puede caracterizarse como el problema de extraer información sobre cantidades desconocidas a partir de datos observados, bajo un modelo estadístico que describe el mecanismo generador de los datos.

Definición 4.2 (Modelo Estadístico Paramétrico). Un *modelo estadístico paramétrico* es una familia de distribuciones de probabilidad indexada por un parámetro:

$$\mathcal{P} = \{P_\theta : \theta \in \Theta\}$$

donde:

- $\Theta \subseteq \mathbb{R}^k$ es el *espacio de parámetros*
- P_θ es una medida de probabilidad sobre el espacio muestral $(\mathcal{X}, \mathcal{A})$
- La función $\theta \mapsto P_\theta$ se denomina *parametrización* del modelo

El modelo se dice *identificable* si la parametrización es inyectiva: $\theta_1 \neq \theta_2 \Rightarrow P_{\theta_1} \neq P_{\theta_2}$.

Definición 4.3 (Función de Densidad/Masa). Si cada P_θ admite una densidad (o función de masa) respecto a una medida σ-finita dominante μ, escribimos:

$$f_\theta(x) = \frac{dP_\theta}{d\mu}(x)$$

La existencia de una medida dominante común para toda la familia es una condición técnica importante que asumiremos a lo largo del curso.

Definición 4.4 (Función de Verosimilitud). Dada una observación $x \in \mathcal{X}$, la *función de verosimilitud* es:

$$L(\theta; x) \coloneqq f(x|\theta), \quad \theta \in \Theta$$

Nota crucial: $L(\cdot; x)$ se considera como función de θ (no de x). Dos valores θ_1, θ_2 se comparan mediante el cociente $L(\theta_1; x)/L(\theta_2; x)$: valores mayores indican mayor compatibilidad con los datos observados.

Definición 4.5 (Los Cinco Componentes de la Inferencia). Un problema de inferencia estadística completo se especifica mediante la quíntupla:

$$\mathcal{I} = (\mathcal{P}, \theta, \mathcal{X}, T, \mathcal{C})$$

donde:
1. $\mathcal{P}$: modelo estadístico (paramétrico, semiparamétrico o no paramétrico)
2. $\theta \in \Theta$: parámetro de interés (o funcional $g(\theta)$)
3. $\mathcal{X}$: espacio muestral donde se observan los datos $X = (X_1, ..., X_n)$
4. $T : \mathcal{X} \to \mathcal{T}$: estadístico (función medible de los datos)
5. $\mathcal{C}$: criterio de optimalidad (sesgo, varianza, riesgo, cobertura, etc.)

Concepto Estadístico	**Interpretación en Agentes**	**Implementación en LangGraph**
Modelo paramétrico $\mathcal{P}$	Hipótesis sobre cómo el ambiente genera observaciones	Modelo explícito; el esquema de tipos no define su ley
Parámetro θ	Cantidad o funcional desconocido de interés	Objetivo de estimación
Espacio muestral $\mathcal{X}$	Espacio de observaciones posibles	Tipo de entrada del agente
Estadístico $T(X)$	Estado interno del agente	Variables almacenadas en `State`
Criterio $\mathcal{C}$	Función objetivo del agente	Reglas en nodo `Decidir`
Función de verosimilitud $L(\theta; x)$	Compatibilidad de hipótesis con datos	Cálculo en nodo `Actualizar`
Distribución posterior $p(\theta\|x)$	Creencias actualizadas del agente	Salida de nodo `Estimar`

Tabla 4.1: Correspondencia entre conceptos estadísticos y componentes de agentes

D. Jair Lopez Espinoza

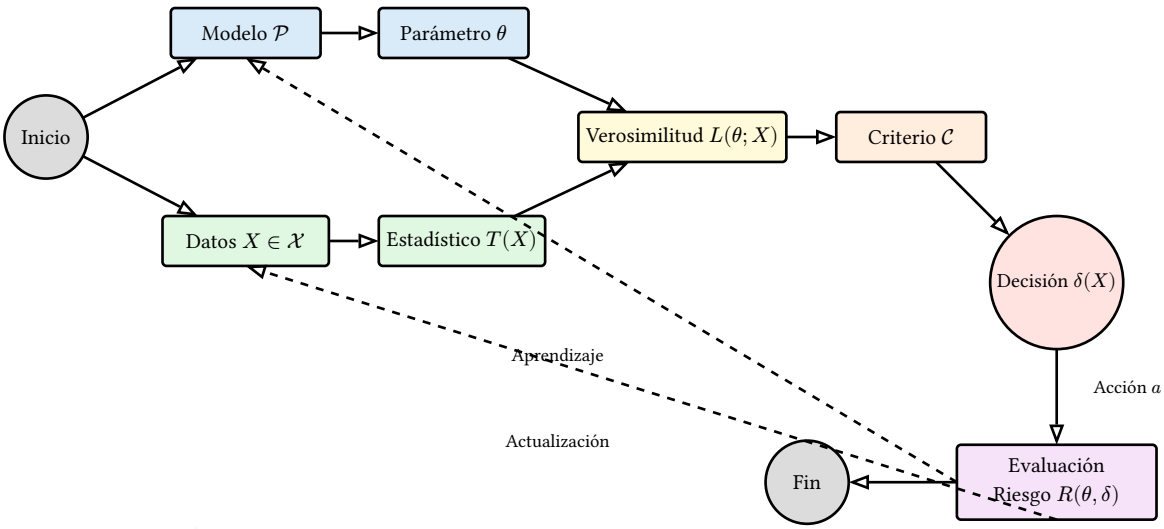


Figura 4.1: Diagrama de flujo del proceso de inferencia estadística. El proceso comienza con la especificación del modelo $\mathcal{P}$ y parámetro θ, mientras se observan datos X. Un estadístico suficiente $T(X)$, cuando existe una reducción útil, resume los datos sin perder la información de verosimilitud; junto con el modelo alimenta la función de verosimilitud $L(\theta; X)$. Un criterio $\mathcal{C}$ transforma esta información en una regla de decisión $\delta(X)$, cuya calidad se evalúa mediante el riesgo $R(\theta, \delta)$. Las flechas de retroalimentación permiten el aprendizaje y actualización del modelo.

Componente	Pregunta que responde	Acción del investigador
$\mathcal{P}$	¿Qué mecanismos generadores son plausibles?	Especificar una clase de distribuciones y justificar sus restricciones
θ	¿Qué aspecto del mecanismo nos importa?	Identificar funcional de interés (ej. media, cuantil)
$\mathcal{X}$	¿Qué podemos observar?	Diseñar protocolo de recolección de datos
T	¿Cómo resumir los datos sin perder información?	Elegir estadístico suficiente o aproximación eficiente
$\mathcal{C}$	¿Qué cuenta como «buena» inferencia?	Seleccionar criterio alineado con objetivos del agente

Tabla 4.2: Interpretación operativa de los cinco componentes de la inferencia

Nota 4.6 (Tres regímenes, un mismo objetivo). Un modelo es una clase $\mathcal{P}$ de leyes y el objetivo es un funcional $\psi : \mathcal{P} \to \mathbb{R}^d$. En el régimen paramétrico regular, la ley se describe por un vector de dimensión finita fija. En el no paramétrico se permite una clase infinita, por ejemplo distribuciones con segundo momento finito o funciones con cierta suavidad. La inferencia semiparamétrica estudia un objetivo finito-dimensional dentro de un modelo con componentes infinitos; puede aplicarse incluso a un modelo observado no paramétrico. No son tres algoritmos ni tres grados de calidad.

Enfoque	Ejemplo	Garantía que debe justificarse
Paramétrico	$Y \sim N(\mu, \sigma^2)$; interés μ	Regularidad, especificación y Fisher
No paramétrico	CDF de retornos sin forma fijada	Convergencia uniforme y bandas

Enfoque	Ejemplo	Garantía que debe justificarse
Semiparamétrico	Valor de una política con regresiones desconocidas	Gradiente canónico y control del resto

La media puede estimarse a tasa $\sqrt{n}$ sin especificar la distribución completa, si hay varianza finita. En cambio, estimar una densidad en un punto suele exigir suavidad y una tasa distinta. El tamaño del objetivo no determina por sí solo la dificultad. Una tabla de transición sobre un número fijo de estados y acciones sigue siendo un modelo de dimensión finita.

4.1.2 Estadísticos y su Clasificación

Definición 4.7 (Función Medible). Una función $T : \mathcal{X} \to \mathcal{T}$ es *medible* si para todo conjunto «razonable» $B \subseteq \mathcal{T}$, el conjunto $\{x \in \mathcal{X} : T(x) \in B\}$ es un evento sobre el cual podemos calcular probabilidades.

Ejemplo 4.8 (Intuición). Si $\mathcal{X} = \mathbb{R}^n$ con la σ-álgebra de Borel, entonces toda función continua es medible. En la práctica del curso, asumiremos que todos los estadísticos de interés son medibles; la definición formal permite definir su distribución; para una esperanza finita se necesita además integrabilidad.

Definición 4.9 (Estadístico). Un *estadístico* es cualquier función medible $T : \mathcal{X} \to \mathcal{T}$ del vector de datos $X = (X_1, ..., X_n)$ que no depende de parámetros desconocidos.

Definición 4.10 (Estimador). Un *estimador* de θ (o de un funcional $g(\theta)$) es un estadístico $\hat{\theta} : \mathcal{X} \to \Theta$ cuyo propósito es aproximar el valor verdadero del parámetro satisfaciendo algún tipo de criterio de optimalidad. Cuando queremos enfatizar que $\hat{\theta}$ depende de la muestra, escribimos $\hat{\theta}(X)$ o $\hat{\theta}_n$ si el tamaño muestral n es relevante.

Ejemplo 4.11 (Estadísticos Fundamentales). Sea $X_1, ..., X_n$ una muestra aleatoria de una distribución con media μ y varianza σ^2 finitas. Los siguientes son estadísticos:

1. **Media muestral:** $\overline{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$
2. **Varianza muestral:** $S_n^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left(X_i - \overline{X}_n\right)^2$
3. **Estadísticos de orden:** $X_{(1)} \leq X_{(2)} \leq ... \leq X_{(n)}$
4. **Rango:** $R_n = X_{(n)} - X_{(1)}$

Cada uno de estos captura diferentes aspectos de la muestra: localización, dispersión, extremos. La elección del estadístico apropiado depende del problema inferencial en cuestión.

4.1.3 Criterios de Optimalidad

Un aspecto central de la inferencia estadística es la evaluación de la calidad de los procedimientos inferenciales. Los criterios de optimalidad proporcionan métricas formales para esta evaluación.

Definición 4.12 (Sesgo). El *sesgo* de un estimador $\hat{\theta}$ para el parámetro θ es:

$$\operatorname{Sesgo}_\theta\left(\hat{\theta}\right) = \mathbb{E}_\theta\left[\hat{\theta}(X)\right] - \theta$$

Un estimador es *insesgado* si $\operatorname{Sesgo}_\theta\left(\hat{\theta}\right) = 0$ para todo $\theta \in \Theta$. Se dice *asintóticamente insesgado* si $\lim_{n\to\infty} \operatorname{Sesgo}_\theta\left(\hat{\theta}_n\right) = 0$.

Definición 4.13 (Varianza y Error Cuadrático Medio). Para un estimador $\hat{\theta}$, definimos:

Varianza:

$$\operatorname{Var}_\theta\left(\hat{\theta}\right) = \mathbb{E}_\theta\left[\left(\hat{\theta} - \mathbb{E}_\theta\left[\hat{\theta}\right]\right)^2\right]$$

Error Cuadrático Medio (ECM):

$$\mathrm{ECM}_\theta\big(\hat{\theta}\big) = \mathbb{E}_\theta\Big[\big(\hat{\theta} - \theta\big)^2\Big]$$

Estas cantidades satisfacen la *descomposición sesgo-varianza*:

$$\mathrm{ECM}_\theta\big(\hat{\theta}\big) = \mathrm{Var}_\theta\big(\hat{\theta}\big) + \Big[\mathrm{Sesgo}_\theta\big(\hat{\theta}\big)\Big]^2$$

Sketch de demostración. La descomposición se obtiene sumando y restando $\mathbb{E}_\theta\big[\hat{\theta}\big]$:

$$\begin{aligned}
\mathrm{ECM}_\theta\big(\hat{\theta}\big) &= \mathbb{E}_\theta\Big[\big(\hat{\theta} - \theta\big)^2\Big] \\
&= \mathbb{E}_\theta\Big[\big(\big(\hat{\theta} - \mathbb{E}\big[\hat{\theta}\big]\big) + \big(\mathbb{E}\big[\hat{\theta}\big] - \theta\big)\big)^2\Big] \\
&= \mathbb{E}_\theta\Big[\big(\hat{\theta} - \mathbb{E}\big[\hat{\theta}\big]\big)^2\Big] + 2\big(\mathbb{E}\big[\hat{\theta}\big] - \theta\big)\underbrace{\mathbb{E}\Big[\hat{\theta} - \mathbb{E}\big[\hat{\theta}\big]\Big]}_{=0} + \big(\mathbb{E}\big[\hat{\theta}\big] - \theta\big)^2 \\
&= \mathrm{Var}_\theta\big(\hat{\theta}\big) + \Big[\mathrm{Sesgo}_\theta\big(\hat{\theta}\big)\Big]^2
\end{aligned}$$

□

Ejemplo 4.14 (Cálculo Numérico de Sesgo, Varianza y ECM). Suponga cinco indicadores iid de transición $X_i \sim \mathrm{Bernoulli}(\theta)$ bajo una acción fija. La muestra $(1, 0, 1, 0, 1)$ da $\hat{\theta}_1 = \overline{X} = 0.6$ y $\hat{\theta}_2 = 0.9\overline{X} = 0.54$. Estos son valores observados, no esperanzas.

Para cualquier θ, el primer estimador tiene sesgo cero y riesgo $\frac{\theta(1-\theta)}{5}$. El segundo tiene sesgo -0.1θ, varianza $0.81\frac{\theta(1-\theta)}{5}$ y riesgo $0.81\frac{\theta(1-\theta)}{5} + 0.01\theta^2$. En $\theta = 0.5$, sus riesgos son 0.05 y 0.043, respectivamente. El error observado $0.54 - 0.5 = 0.04$ no es el sesgo, que vale -0.05.

El contraído mejora el ECM para $0 < \theta < \frac{19}{24}$ y lo empeora para $\theta > \frac{19}{24}$. Ambos riesgos dependen del parámetro: menor varianza o insesgadez no ordenan por sí solas las reglas. Los cinco registros son sintéticos y se supone independencia entre unidades; transiciones repetidas de un paciente requieren otro análisis.

Definición 4.15 (Función de Pérdida y Riesgo). Sea $L : \Theta \times \mathcal{A} \to \mathbb{R}_{\geq 0}$ una *función de pérdida* que mide el costo de tomar la acción $a \in \mathcal{A}$ cuando el estado verdadero de la naturaleza es θ. El *riesgo* de una regla de decisión $\delta : \mathcal{X} \to \mathcal{A}$ es:

$$R(\theta, \delta) = \mathbb{E}_{X \sim P_\theta}[L(\theta, \delta(X))]$$

Ejemplo 4.16 (Pérdidas Comunes).
1. **Pérdida cuadrática:** $L(\theta, a) = (\theta - a)^2$. El riesgo es el ECM.
2. **Pérdida absoluta:** $L(\theta, a) = |\theta - a|$. El riesgo es el error absoluto medio.
3. **Pérdida 0-1:** $L(\theta, a) = \mathbb{1}(a \neq \theta)$. Usada en clasificación; el riesgo es la probabilidad de error.
4. **Pérdida ponderada:** $L(\theta, a) = w(\theta)(\theta - a)^2$ para alguna función de peso $w > 0$.

4.1.4 Familias Exponenciales: Definición y Propiedades

Las familias exponenciales constituyen una clase central de modelos paramétricos, tanto por su tratabilidad analítica como por sus propiedades de suficiencia y regularidad. Muchos modelos clásicos (normal, binomial, Poisson, gamma, beta, multinomial) pertenecen a esta clase. Para agentes inteligentes, estas familias ofrecen ventajas clave:

- **Actualización eficiente:** El estadístico natural $T(X)$ permite actualizaciones incrementales en tiempo constante respecto del tamaño muestral, para dimensión fija.

Dr. Jaime Chávez Chávez

- **Reducción suficiente:** $T(X)$ retiene la información del modelo; la minimalidad exige condiciones adicionales.
- **Propiedades óptimas:** Estimadores de máxima verosimilitud con garantías asintóticas.

Definición 4.17 (Familia Exponencial en Forma Canónica). Una familia paramétrica $\mathcal{P}$ es una *familia exponencial de rango k* si la densidad puede escribirse como:

$$f(x|\eta) = h(x)\exp\left\{\sum_{j=1}^{k}\eta_j T_j(x) - A(\eta)\right\} = h(x)\exp\{\eta^\top T(x) - A(\eta)\}$$

donde:
- $\eta = (\eta_1, ..., \eta_k)^\top \in \mathcal{H} \subseteq \mathbb{R}^k$: *parámetro natural* (o canónico)
- $T(x) = (T_1(x), ..., T_k(x))^\top$: *estadístico natural* (o suficiente)
- $A(\eta)$: *función log-partición* (o función generadora de cumulantes)
- $h(x) \geq 0$: *medida base*
- $\mathcal{H} = \{\eta \in \mathbb{R}^k : A(\eta) < \infty\}$: *espacio de parámetros naturales*

Teorema 4.18 (Propiedades de la Función Log-Partición). *Sea $\mathcal{P}$ una familia exponencial regular con espacio de parámetros naturales $\mathcal{H}$ abierto. Entonces:*
1. *$A(\eta)$ es **convexa** en $\mathcal{H}$*
2. *$A(\eta)$ es **infinitamente diferenciable** en el interior de $\mathcal{H}$*
3. *Las primeras derivadas de A generan los **cumulantes** del estadístico natural:*

$$\frac{\partial A}{\partial \eta_j} = \mathbb{E}_\eta\big[T_j(X)\big]$$

$$\frac{\partial^2 A}{\partial \eta_j \partial \eta_l} = \mathrm{Cov}_\eta\big(T_j(X), T_l(X)\big)$$

Sketch de demostración.
- **Convexidad:** Por la condición de normalización, $\exp(A(\eta)) = \int h(x)\exp(\eta^\top T(x))\,\mathrm{d}\mu(x)$. La función $\eta \mapsto \exp(\eta^\top t)$ es log-lineal (y por tanto log-convexa) para cada t fijo. El logaritmo de una integral de funciones log-convexas es convexo (desigualdad de Hölder generalizada).
- **Diferenciabilidad:** Bajo condiciones de regularidad (que permiten intercambiar derivación e integración), la suavidad de $\exp(\eta^\top T(x))$ en η se transfiere a $A(\eta)$.
- **Fórmulas de momentos:** Derivando $1 = \int f(x|\eta)\,\mathrm{d}\mu(x)$ respecto a η_j:

$$0 = \int \frac{\partial}{\partial \eta_j} f(x|\eta)\,\mathrm{d}\mu(x) = \int \big(T_j(x) - A_j'(\eta)\big) f(x|\eta)\,\mathrm{d}\mu(x)$$

  de donde $A_j'(\eta) = \mathbb{E}_\eta\big[T_j(X)\big]$. La segunda derivada se obtiene análogamente.

Ver Lehmann & Casella (1998), Teorema 1.6.1 para la demostración completa. (argumento y alcance en Apéndice A, pág. 216) □

Corolario 4.19. *La matriz de covarianzas del estadístico natural es igual al Hessiano de A:*

$$\mathrm{Cov}_\eta(T(X)) = \nabla^2 A(\eta)$$

y por convexidad de A, esta matriz es semidefinida positiva. En familias minimales, es definida positiva.

Ejemplo 4.20 (Familia Normal con Varianza Conocida). Sea $X_1, ..., X_n \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$ con σ^2 conocida. La densidad conjunta es:

$$f(\boldsymbol{x}|\mu) = \left(\frac{1}{2\pi\sigma^2}\right)^{\frac{n}{2}} \exp\left\{-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2\right\}$$

Expandiendo el cuadrado y reorganizando:

$$f(\boldsymbol{x}|\mu) = \left(\frac{1}{2\pi\sigma^2}\right)^{\frac{n}{2}} \exp\left\{-\frac{\sum x_i^2}{2\sigma^2}\right\} \cdot \exp\left\{\frac{\mu}{\sigma^2}\sum_{i=1}^{n}x_i - \frac{n\mu^2}{2\sigma^2}\right\}$$

Identificamos los componentes:
- Parámetro natural: $\eta = \mu/\sigma^2$
- Estadístico natural: $T(\boldsymbol{x}) = \sum_{i=1}^{n} x_i$
- Log-partición: $A(\eta) = \frac{n\sigma^2\eta^2}{2} = \frac{n\mu^2}{2\sigma^2}$
- Medida base: $h(\boldsymbol{x}) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left(-\frac{\sum x_i^2}{2\sigma^2}\right)$

Verificación: $\frac{\partial A}{\partial \eta} = n\sigma^2\eta = n\mu = \mathbb{E}[\sum X_i]$ ✓

Ejemplo 4.21 (Familia Bernoulli/Binomial). Sea $X \sim \text{Binomial}(n, p)$. La función de masa es:

$$f(x|p) = \binom{n}{x}p^x(1-p)^{n-x} = \binom{n}{x}\exp\left\{x\log\left(\frac{p}{1-p}\right) + n\log(1-p)\right\}$$

Identificamos:
- Parámetro natural: $\eta = \log\left(\frac{p}{1-p}\right)$ (log-odds)
- Estadístico natural: $T(x) = x$
- Log-partición: $A(\eta) = n\log(1+e^\eta)$
- Espacio de parámetros naturales: $\mathcal{H} = \mathbb{R}$

Verificación: $A'(\eta) = \frac{ne^\eta}{1+e^\eta} = \frac{np}{1} = np = \mathbb{E}[X]$ ✓

Ejemplo 4.22 (Familia Poisson). Sea $X_1, \ldots, X_n \overset{\text{iid}}{\sim} \text{Poisson}(\lambda)$. La densidad conjunta es:

$$f(\boldsymbol{x}|\lambda) = \frac{\lambda^{\sum x_i}e^{-n\lambda}}{\prod_{i=1}^{n} x_i!} = \frac{1}{\prod x_i!}\exp\Big\{(\log\lambda)\sum x_i - n\lambda\Big\}$$

Identificamos:
- Parámetro natural: $\eta = \log\lambda$
- Estadístico natural: $T(\boldsymbol{x}) = \sum_{i=1}^{n} x_i$
- Log-partición: $A(\eta) = ne^\eta = n\lambda$
- Espacio de parámetros naturales: $\mathcal{H} = \mathbb{R}$

4.1.5 Estadísticos Naturales y Suficiencia

Una propiedad fundamental de las familias exponenciales es que el estadístico natural es automáticamente suficiente.

Teorema 4.23 (El Estadístico Natural es Suficiente). *En una familia exponencial, el estadístico natural $T(X)$ es* suficiente *para η (y por lo tanto para cualquier reparametrización $\theta = \theta(\eta)$).*

Sketch de demostración. Por el Teorema de Factorización de Neyman-Fisher (que se desarrollará en detalle en el Capítulo 4), T es suficiente si y solo si la densidad factoriza como:

$$f(x|\theta) = g(T(x), \theta) \cdot h(x)$$

En familias exponenciales, esta factorización es evidente de la definición:

Propiedad intelectual Curivil

$$f(x|\eta) = \underbrace{\exp\{\eta^\top T(x) - A(\eta)\}}_{g(T(x),\eta)} \cdot \underbrace{h(x)}_{h(x)}$$

(argumento y alcance en Apéndice A, pág. 216) □

4.1.6 Priors Conjugados y Actualización Bayesiana

Las familias conjugadas juegan un papel fundamental en la inferencia bayesiana, ya que permiten actualizaciones analíticas cerradas del posterior. Esta propiedad es especialmente valiosa para agentes que deben actualizar sus creencias en tiempo real con recursos computacionales limitados. En esta sección, exploramos cómo los priors conjugados se integran naturalmente con las familias exponenciales, proporcionando un mecanismo eficiente para el aprendizaje secuencial.

Modelo	Prior Conjugado	Actualización	Aplicación en Agentes
Bernoulli/Binomial	Beta(α, β)	$(\alpha + x, \beta + n - x)$	CTR, conversiones binarias
Poisson	Gamma(α, β)	$(\alpha + x, \beta + 1)$	Tasas de eventos, conteos
Normal (varianza conocida)	Normal(μ_0, σ_0^2)	Fórmulas conjugadas	Recompensas continuas
Normal (ambos desconocidos)	Normal-Gamma $(\mu_0, \lambda, \alpha, \beta)$	Actualización cuadrática	Recompensas con incertidumbre
Multinomial	Dirichlet$(\alpha_1, ..., \alpha_k)$	$(\alpha_i + x_i)$	Distribuciones categóricas

Tabla 4.3: Familias conjugadas comunes y su aplicación en agentes

Definición 4.24 (Familia Conjugada). Sea $\mathcal{P} = \{P_\theta : \theta \in \Theta\}$ una familia paramétrica y $\mathcal{F} = \{p(\theta|\eta) : \eta \in \mathcal{H}\}$ una familia de distribuciones sobre Θ. Decimos que $\mathcal{F}$ es *conjugada* para $\mathcal{P}$ si:

$$p(\theta|x, \eta) \propto f(x|\theta)p(\theta|\eta) \quad \Rightarrow \quad p(\cdot\,|x, \eta) \in \mathcal{F}$$

es decir, el posterior pertenece a la misma familia que el prior, con hiperparámetros actualizados $\eta' = \eta'(x, \eta)$.

Ejemplo 4.25 (Beta-Binomial). Para $X|\theta \sim \text{Binomial}(n, \theta)$ y prior $\theta \sim \text{Beta}(\alpha, \beta)$:

$$p(\theta|x) \propto \theta^x(1-\theta)^{n-x} \cdot \theta^{\alpha-1}(1-\theta)^{\beta-1} = \theta^{\alpha+x-1}(1-\theta)^{\beta+n-x-1}$$

Luego $\theta|x \sim \text{Beta}(\alpha + x, \beta + n - x)$. La actualización es aditiva: $(\alpha, \beta) \mapsto (\alpha + x, \beta + n - x)$.

Implicación para agentes: El estado puede almacenar (α, β) como hiperparámetros suficientes; la actualización ante nueva observación x es $O(1)$.

Ejemplo 4.26 (Gamma-Poisson). Para $X|\lambda \sim \text{Poisson}(\lambda)$ y prior $\lambda \sim \text{Gamma}(\alpha, \beta)$:

$$p(\lambda|x) \propto \lambda^x e^{-\lambda} \cdot \lambda^{\alpha-1} e^{-\beta\lambda} = \lambda^{\alpha+x-1} e^{-(\beta+1)\lambda}$$

Luego $\lambda|x \sim \text{Gamma}(\alpha + x, \beta + 1)$. Nuevamente, actualización aditiva en hiperparámetros.

Conexión con suficiencia: En ambos ejemplos, el estadístico suficiente $T(x)$ (éxitos en Binomial, conteo en Poisson) es exactamente la cantidad que actualiza el prior conjugado.

Ejemplo 4.27 (Normal-Gamma para recompensas continuas). Considere un agente que observa recompensas continuas $X_1, X_2, ... \sim N(\mu, \tau^{-1})$ donde tanto la media μ como la precisión $\tau = 1/\sigma^2$ son desconocidas. El prior conjugado es la distribución Normal-Gamma:

$$p(\mu, \tau|\mu_0, \lambda, \alpha, \beta) = \text{NormalGamma}(\mu_0, \lambda, \alpha, \beta)$$

que factoriza como $\mu|\tau \sim N(\mu_0, (\lambda\tau)^{-1})$ y $\tau \sim \text{Gamma}(\alpha, \beta)$.

Actualización secuencial: Dada observación x, los hiperparámetros se actualizan como:

$$\begin{aligned}
\mu_0' &= \frac{\lambda\mu_0 + x}{\lambda + 1} \\
\lambda' &= \lambda + 1 \\
\alpha' &= \alpha + \frac{1}{2} \\
\beta' &= \beta + \frac{\lambda(x - \mu_0)^2}{2(\lambda + 1)}
\end{aligned}$$

Estado del agente: Con prior fijo, el cuádruple $(\mu_0, \lambda, \alpha, \beta)$ permite reconstruir el posterior; no es una representación minimal de cuatro dimensiones. Para n fijo, basta $(\sum X_i, \sum X_i^2)$, y en actualización secuencial se registra también n. Un agente LangGraph puede almacenar este estado y actualizarlo en $O(1)$ por observación.

Decisión informada: El agente puede calcular:
- **Estimación puntual:** $\hat{\mu} = \mu_0$ (media posterior)
- **Incertidumbre:** $\text{Var}(\mu|x) = \frac{\beta}{\lambda(\alpha-1)}$ para $\alpha > 1$
- **Criterio de decisión:** Mostrar contenido si $\hat{\mu} > \mu_{\text{umbral}}$ y $\text{Var}(\mu|x) < \sigma^2_{\text{máx}}$

Este ejemplo ilustra cómo familias conjugadas multidimensionales permiten a agentes manejar múltiples parámetros desconocidos simultáneamente con actualizaciones eficientes.

4.1.7 Otras familias paramétricas con estructura

Aunque las familias exponenciales dominan la teoría de estimación óptima, existen otras clases paramétricas con estructura algebraica que permiten construir estimadores con propiedades garantizadas. Estas familias comparten la característica de que sus distribuciones están relacionadas por transformaciones simples, lo que facilita el análisis de invarianzas y la derivación de estimadores óptimos bajo criterios específicos.

Definición 4.28 (Familia de localización-escala). Una familia $\mathcal{P}$ es de *localización-escala* si existe una densidad base g tal que:

$$f_{\mu,\sigma}(x) = \frac{1}{\sigma} g\left(\frac{x - \mu}{\sigma}\right), \quad \mu \in \mathbb{R}, \sigma > 0$$

donde g es una densidad fija (ej. $g(z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}}$ para la normal).

Ejemplo 4.29 (Distribución t de Student). La distribución t con ν grados de libertad pertenece a una familia de localización-escala con densidad base:

$$g(z) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\,\Gamma\left(\frac{\nu}{2}\right)} \left(1 + \frac{z^2}{\nu}\right)^{-\frac{\nu+1}{2}}$$

Propiedades estadísticas:
- *Robustez:* Colas más pesadas que la normal, resistente a outliers.
- *Estimación:* La media existe solo para $\nu > 1$ y la varianza solo para $\nu > 2$. Si no existen los momentos requeridos, el CLT de varianza finita no se aplica. La mediana y estimadores M responden a objetivos y criterios que deben especificarse.

- *Relevancia para agentes:* Modela ambientes con recompensas extremas donde la política que maximiza valor esperado bajo normalidad puede ser subóptima.

Definición 4.30 (Familia de mezclas finitas). Una *mezcla finita* de K componentes es una distribución de la forma:

$$f(x|\boldsymbol{\theta}) = \sum_{k=1}^{K} w_k f_k(x|\theta_k), \quad \sum_{k=1}^{K} w_k = 1, \quad w_k \geq 0$$

donde cada f_k pertenece a una familia paramétrica (normal, Poisson, etc.).

Ejemplo 4.31 (Mezcla de dos normales). Para $f(x|w, \mu_1, \mu_2, \sigma_1^2, \sigma_2^2) = wN(\mu_1, \sigma_1^2) + (1 - w)N(\mu_2, \sigma_2^2)$:
- *Multimodalidad:* Puede modelar poblaciones heterogéneas.
- *Estimación:* El algoritmo EM alterna entre asignación de responsabilidades (E-step) y maximización de parámetros (M-step).
- *Aplicación a agentes:* Útil cuando el ambiente tiene regímenes distintos (ej. mercado alcista/bajista) que requieren políticas diferentes.

Definición 4.32 (Familia de valores extremos). La familia de *valores extremos* (GEV) describe la distribución límite del máximo (o mínimo) de n variables i.i.d. cuando $n \to \infty$, cuando existen constantes de normalización que producen un límite no degenerado, según el Teorema de Fisher-Tippett-Gnedenko. Incluye tres tipos: Gumbel, Fréchet y Weibull.

Ejemplo 4.33 (Distribución Gumbel). La densidad Gumbel es

$$f(x|\mu, \beta) = \frac{1}{\beta} \exp\left(-\frac{x-\mu}{\beta} - \exp\left(-\frac{x-\mu}{\beta}\right)\right), \quad \beta > 0.$$

Si X_i son iid Gumbel, $\max_i X_i$ tiene parámetros $(\mu + \beta \log n, \beta)$. Para escala conocida, $\sum_i \exp\left(-\frac{X_i}{\beta}\right)$ es suficiente para la localización. Con escala desconocida, $\exp\left(-\frac{x}{\beta}\right)$ depende del parámetro y no puede llamarse estadístico natural: la fórmula no define una familia exponencial de dimensión dos con estadísticos fijos. Un modelo de extremos requiere además justificar su dominio de atracción y la elección de bloques o umbrales.

Los ejemplos paramétricos permiten ahora formular una pregunta común: qué parte de la muestra conserva la información sobre el parámetro. La suficiencia responde dentro de una familia de distribuciones especificada y dará una base para comparar reducciones de datos.

4.1.8 El Principio de Suficiencia

El principio de suficiencia es uno de los pilares fundamentales de la reducción de datos: permite comprimir toda la información relevante sobre el parámetro θ contenida en una muestra $X = (X_1, ..., X_n)$ en un estadístico de dimensión potencialmente mucho menor.

Definición 4.34 (Suficiencia). Sea $X \sim P_\theta$ con $\theta \in \Theta$. Un estadístico $T : \mathcal{X} \to \mathcal{T}$ es *suficiente* para θ si la distribución condicional de X dado $T(X) = t$ no depende de θ para casi todo t bajo cada distribución de T, mediante una versión común de la ley condicional.

Formalmente:

$$P_\theta(X \in A \mid T(X) = t) = P(X \in A \mid T(X) = t) \quad \forall \theta \in \Theta, \forall A \in \mathcal{A}$$

Teorema 4.35 (Factorización de Neyman-Fisher). *En espacios estándar de Borel y para una familia dominada por una medida σ-finita, T es suficiente si y solo si se pueden elegir densidades con*

$$f_\theta(x) = g_\theta(T(x))h(x)$$

casi en todas partes para cada parámetro, con factores no negativos medibles. La igualdad es de versiones de densidades; no exige valores determinados en conjuntos nulos.

Demostración. En el caso discreto, sumar sobre la fibra $T(x) = t$ y cancelar $g_\theta(t)$ muestra que la distribución condicional no depende del parámetro. En el caso continuo no se integra una fibra de medida nula usando la medida ambiente: se utiliza una distribución condicional regular. El argumento mediante una medida dominante de probabilidad y derivadas de Radon–Nikodym se desarrolla en (argumento y alcance en Apéndice A, pág. 217). □

Ejemplo 4.36 (Suficiencia en la Distribución Normal). Sea $X_1, \ldots, X_n \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$ con ambos parámetros desconocidos. La densidad conjunta es:

$$f(\boldsymbol{x}|\mu,\sigma^2) = \left(\frac{1}{2\pi\sigma^2}\right)^{\frac{n}{2}} \exp\left\{-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2\right\}$$

Expandiendo el cuadrado:

$$\sum_{i=1}^{n}(x_i-\mu)^2 = \sum_{i=1}^{n}x_i^2 - 2\mu\sum_{i=1}^{n}x_i + n\mu^2$$

Por lo tanto:

$$f(\boldsymbol{x}|\mu,\sigma^2) = \underbrace{\left(\frac{1}{2\pi\sigma^2}\right)^{\frac{n}{2}} \exp\left\{-\frac{1}{2\sigma^2}\left(\sum x_i^2 - 2\mu\sum x_i + n\mu^2\right)\right\}}_{g(T(\boldsymbol{x}),\mu,\sigma^2)} \cdot \underbrace{1}_{h(\boldsymbol{x})}$$

donde $T(\boldsymbol{x}) = \left(\sum_{i=1}^n x_i, \sum_{i=1}^n x_i^2\right)$.

Por el Teorema de Neyman-Fisher, $T(\boldsymbol{x}) = \left(\sum x_i, \sum x_i^2\right)$ es suficiente para (μ, σ^2). Equivalentemente, $T'(\boldsymbol{x}) = \left(\overline{X}, S^2\right)$ también es suficiente, ya que existe una transformación biyectiva entre T y T'.

Ejemplo 4.37 (Suficiencia en la Distribución de Poisson). Sea $X_1, \ldots, X_n \overset{\text{iid}}{\sim} \text{Poisson}(\lambda)$. La función de masa conjunta es:

$$f(\boldsymbol{x}|\lambda) = \prod_{i=1}^{n}\frac{\lambda^{x_i}e^{-\lambda}}{x_i!} = \frac{\lambda^{\sum x_i}e^{-n\lambda}}{\prod_{i=1}^n x_i!}$$

Reescribiendo:

$$f(\boldsymbol{x}|\lambda) = \underbrace{\exp\left\{(\log\lambda)\sum x_i - n\lambda\right\}}_{g(T(\boldsymbol{x}),\lambda)} \cdot \underbrace{\frac{1}{\prod x_i!}}_{h(\boldsymbol{x})}$$

Por Neyman-Fisher, $T(\boldsymbol{x}) = \sum_{i=1}^n x_i$ es suficiente para λ. Notemos que T tiene dimensión 1 independientemente de n: esto es la esencia de la reducción de datos.

4.1.9 Suficiencia Minimal

No todo estadístico suficiente logra la máxima reducción de datos. Por ejemplo, la muestra completa X siempre es trivialmente suficiente, pero no proporciona ninguna reducción. Buscamos el estadístico suficiente de menor «tamaño» posible.

Definición 4.38 (Suficiencia Minimal). Un estadístico suficiente T es *minimal* si, para cualquier otro estadístico suficiente T', existe una función medible φ tal que $T = \varphi(T')$ casi seguramente bajo P_θ para todo θ.

Dr. Jaime Urrutia

Teorema 4.39 (Caracterización de Suficiencia Minimal (Lehmann-Scheffé)). *Para una familia dominada con densidades estrictamente positivas en un soporte común, el criterio usual es: si un estadístico medible T satisface*

$$f_\theta \frac{x}{f_\theta}(y) \text{ es constante en } \theta \Leftrightarrow T(x) = T(y),$$

con versiones apropiadas fuera de conjuntos nulos y las condiciones medibles de la factorización, entonces es suficiente minimal. Cuando hay ceros, debe usarse proporcionalidad de los vectores de verosimilitud y considerar los soportes; no se dividen densidades nulas.

Demostración. La relación de proporcionalidad agrupa observaciones que aportan los mismos cocientes de verosimilitud. La factorización muestra suficiencia, y cualquier otro resumen suficiente debe determinar esas clases, salvo conjuntos nulos. Véase (argumento y alcance en Apéndice A, pág. 218) no se interpreta el criterio como una igualdad punto a punto para versiones arbitrarias de densidades. □

Ejemplo 4.40 (Suficiencia Minimal en Familias Exponenciales). En una familia exponencial de rango k en forma canónica:

$$f(x|\eta) = h(x) \exp\{\eta^\top T(x) - A(\eta)\}$$

Para $x, y \in \mathcal{X}$:

$$\frac{f(x|\eta)}{f(y|\eta)} = \frac{h(x)}{h(y)} \exp\{\eta^\top (T(x) - T(y))\}$$

Este cociente no depende de η si y solo si $T(x) = T(y)$ (asumiendo que η varía en un conjunto abierto). Por el Teorema 4.39, el estadístico natural $T(x) = (T_1(x), ..., T_k(x))$ es suficiente minimal cuando la familia es minimal (sin componentes afínmente dependientes).

4.1.10 Completitud

La completitud es una propiedad adicional que, junto con la suficiencia, garantiza propiedades de optimalidad únicas. Es fundamental para el Teorema de Lehmann-Scheffé (Capítulo 4) y para el Teorema de Basu.

Definición 4.41 (Completitud). Un estadístico T es *completo* para la familia $\{P_\theta : \theta \in \Theta\}$ si:

$$\mathbb{E}_\theta[g(T)] = 0 \text{ para todo } \theta \in \Theta \quad \Rightarrow \quad P_\theta(g(T) = 0) = 1 \text{ para todo } \theta$$

para toda función medible g tal que $\mathbb{E}_\theta[|g(T)|] < \infty$.

Definición 4.42 (Completitud Acotada). Un estadístico T es *acotadamente completo* si la condición de completitud se cumple para toda función g acotada.

Teorema 4.43 (Completitud en Familias Exponenciales). *En una familia exponencial de rango k con espacio de parámetros naturales $\mathcal{H}$ que contiene un conjunto abierto de $\mathbb{R}^k$, el estadístico natural $T(X)$ es completo.*

Sketch de demostración. Fije un parámetro interior η_0. Si $\mathbb{E}_{\eta[g(T)]} = 0$ para todo η, la medida firmada $g(t)P_{\eta_0}^{T(\mathrm{d}t)}$ tiene transformada de Laplace nula cerca de cero. Su unicidad implica que la medida es cero; la equivalencia de las leyes sobre el soporte base extiende la igualdad a toda la familia. La integrabilidad exponencial y los detalles se especifican en (argumento y alcance en Apéndice A, pág. 218). □

Corolario 4.44. *Bajo un dominio natural que contiene un abierto, el estadístico natural es **suficiente, minimal y completo** (SMC).*

Ejemplo 4.45 (Familia Exponencial Multinomial para SSCH). Fije estado y acción. Suponga diez transiciones independientes hacia tres categorías con probabilidades estrictamente positivas $(\theta_1, \theta_2, \theta_3)$. Los conteos son multinomiales. Use θ_3 como categoría de referencia:

$$\eta_j = \log\left(\frac{\theta_j}{\theta_3}\right), \quad j = 1, 2, \quad A(\eta) = n \log(1 + e^{\eta_1} + e^{\eta_2}).$$

El estadístico natural es (N_1, N_2); $N_3 = n - N_1 - N_2$ es redundante. El parámetro natural recorre $\mathbb{R}^2$, por lo que los conteos son suficientes y completos.

Para $(N_1, N_2, N_3) = (2, 5, 3)$, el MLE es $(0.2, 0.5, 0.3)$. Cada proporción es insesgada, con varianza $\theta_j \frac{1-\theta_j}{n}$; entre categorías, la covarianza es $-\theta_j \frac{\theta_k}{n}$. Esas covarianzas deben conservarse al propagar incertidumbre hacia el valor. El supuesto multinomial aquí corresponde a transiciones independientes recolectadas para el mismo par estado–acción; no convierte una trayectoria longitudinal completa en datos iid.

4.1.11 Ancillaridad y el Teorema de Basu

Definición 4.46 (Estadístico Ancilar). Un estadístico $A(X)$ es *ancilar* (o ancilario) para θ si su distribución no depende de θ:

$$P_\theta(A(X) \in B) = P(A(X) \in B) \quad \forall \theta \in \Theta, \forall B$$

Ejemplo 4.47 (Ancilaridad en Modelo de Localización). Sea $X_1, ..., X_n \overset{\text{iid}}{\sim} f(x - \theta)$ donde f es una densidad simétrica conocida centrada en cero. Entonces:

- $\overline{X}$ es equivariante bajo traslaciones, pero no es suficiente en una familia de localización general. La suficiencia requiere comprobar la factorización.
- Los residuos centrados $D_i = X_i - \overline{X}$ para $i = 1, ..., n$ son ancilares: su distribución conjunta no depende de θ ya que $(X_i - \theta) - \frac{1}{n}\sum_j (X_j - \theta) = D_i$

La configuración de los residuos nos dice sobre la «forma» de la muestra, pero no sobre su localización θ.

Teorema 4.48 (Teorema de Basu). *Sea T un estadístico suficiente completo para θ, y sea A un estadístico ancilar. Entonces T y A son independientes bajo P_θ para todo $\theta \in \Theta$.*

Demostración. Definimos la función $g : \mathcal{T} \to \mathbb{R}$ por:

$$g(t) = P(A \in B \mid T = t) - P(A \in B)$$

para un conjunto medible B arbitrario. Mostraremos que $\mathbb{E}_\theta[g(T)] = 0$ para todo θ:

$$\begin{aligned} \mathbb{E}_\theta[g(T)] &= \mathbb{E}_\theta[P(A \in B \mid T)] - P(A \in B) \\ &= P_\theta(A \in B) - P(A \in B) \\ &= 0 \end{aligned}$$

donde la última igualdad se debe a que A es ancilar, por lo que $P_\theta(A \in B) = P(A \in B)$ no depende de θ.

Por completitud de T, concluimos que $g(T) = 0$ casi seguramente, es decir:

$$P(A \in B \mid T = t) = P(A \in B) \quad \text{para casi todo } \ t$$

Esto implica que A es independiente de T. □

Ejemplo 4.49 (Aplicación del Teorema de Basu). En la muestra normal $X_1, ..., X_n \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$ con σ^2 conocida:

- $\overline{X}$ es suficiente completo para μ (por el Teorema 4.43)
- El vector $\left(X_1 - \overline{X}, ..., X_n - \overline{X}\right)$ es ancilar (su distribución no depende de μ)

Por el Teorema de Basu, $\overline{X}$ es independiente de los residuos centrados. En particular, $\overline{X}$ es independiente de $S^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left(X_i - \overline{X}\right)^2$.

Esta independencia, que normalmente se demuestra mediante cálculos laboriosos con la distribución normal multivariante, se obtiene aquí como corolario inmediato de un resultado general.

4.1.12 Equivarianza

El principio de equivarianza proporciona otra vía de reducción, restringiendo la clase de estimadores a aquellos que respetan las simetrías inherentes del problema.

Definición 4.50 (Grupo de Transformaciones e Invariancia). Sea $\mathcal{G}$ un grupo que actúa sobre $\mathcal{X}$ (espacio muestral) y sobre Θ (espacio de parámetros). Decimos que el modelo $\{P_\theta : \theta \in \Theta\}$ es *invariante* bajo $\mathcal{G}$ si:

$$X \sim P_\theta \quad \Rightarrow \quad gX \sim P_{g\theta} \quad \forall g \in \mathcal{G}$$

donde gX denota la acción de g sobre X y $g\theta$ la acción sobre θ.

Definición 4.51 (Estimador Equivariante). Un estimador $\hat{\theta} : \mathcal{X} \to \Theta$ es *equivariante* bajo $\mathcal{G}$ si:

$$\hat{\theta}(gX) = g\hat{\theta}(X) \quad \forall g \in \mathcal{G}, \forall X \in \mathcal{X}$$

Teorema 4.52 (Principio de Equivarianza). *Si el modelo y la pérdida son invariantes y δ es equivariante, entonces $R(g\theta, \delta) = R(\theta, \delta)$. El riesgo es constante sobre cada órbita del grupo; es constante en todo el espacio únicamente si la acción es transitiva. La existencia de una regla equivariante minimax requiere hipótesis adicionales y no se deduce de invariancia sola.*

Demostración. Si $X \sim P_\theta$, entonces $gX \sim P_{g\theta}$. Por equivarianza e invariancia,

$$R(g\theta, \delta) = \mathbb{E}_{\theta[L(g\theta, \delta(gX))]} = \mathbb{E}_{\theta[L(g\theta, g\delta(X))]} = R(\theta, \delta).$$

Promediar sobre un grupo no compacto requiere cuidado: una medida de Haar no es en general una probabilidad. No se usa aquí para afirmar minimax. Véase (argumento y alcance en Apéndice A, pág. 220). □

Ejemplo 4.53 (Equivarianza bajo Traslaciones). Para $X_1, ..., X_n \overset{\text{iid}}{\sim} f(x - \theta)$ con $\theta \in \mathbb{R}$, el grupo de traslaciones $\mathcal{G} = (\mathbb{R}, +)$ actúa por:

- $g \cdot x_i = x_i + g$ (sobre los datos)
- $g \cdot \theta = \theta + g$ (sobre el parámetro)

Un estimador $\hat{\theta}$ es equivariante si $\hat{\theta}(X_1 + c, ..., X_n + c) = \hat{\theta}(X_1, ..., X_n) + c$ para todo $c \in \mathbb{R}$.

La media muestral $\overline{X}$ es equivariante. La mediana muestral también lo es. El estimador $\hat{\theta} = X_1$ (usar solo la primera observación) es equivariante pero ineficiente.

Ejemplo 4.54 (Equivarianza bajo Escala). Para $X_1, ..., X_n \overset{\text{iid}}{\sim} \frac{1}{\sigma} f\left(\frac{x}{\sigma}\right)$ con $\sigma > 0$, el grupo multiplicativo $\mathcal{G} = (\mathbb{R}^+, \cdot)$ actúa por:

- $g \cdot x_i = g \cdot x_i$ (multiplicación)
- $g \cdot \sigma = g \cdot \sigma$

Un estimador $\hat{\sigma}$ es equivariante si $\hat{\sigma}(cX_1, ..., cX_n) = c \cdot \hat{\sigma}(X_1, ..., X_n)$ para todo $c > 0$.

La desviación estándar muestral S es equivariante. También lo es el rango $R = X_{(n)} - X_{(1)}$ multiplicado por cualquier constante.

Diplomado Universitario

Estimar y comparar la precisión de los procedimientos

Una vez definido qué información retiene la muestra, interesa cómo convertirla en una estimación. El criterio de comparación determina qué mejoras buscamos: reducir riesgo, conservar insesgadez o alcanzar una cota de precisión.

4.2.1 Criterios de optimalidad en estimación puntual

La teoría de estimación puntual busca estadísticos $\hat{\theta}(X)$ que aproximen el parámetro verdadero θ de manera óptima según algún criterio formal.

Definición 4.55 (Error Cuadrático Medio). El *error cuadrático medio* (ECM) de un estimador $\hat{\theta}$ es:

$$\mathrm{ECM}_\theta\big(\hat{\theta}\big) = \mathbb{E}_\theta\Big[\big(\hat{\theta}(X) - \theta\big)^2\Big]$$

4.2.2 El Teorema de Rao-Blackwell

El teorema de Rao-Blackwell proporciona un método constructivo para mejorar estimadores mediante condicionamiento sobre estadísticos suficientes (ver Capítulo 4).

Teorema 4.56 (Rao-Blackwell). *Sea $\hat{\theta}$ un estimador de θ con $\mathbb{E}_\theta\big[\hat{\theta}^2\big] < \infty$ para todo θ, y sea T un estadístico suficiente para θ. Definamos:*

$$\tilde{\theta} = \mathbb{E}\big[\hat{\theta} \mid T\big]$$

Entonces:
1. *$\tilde{\theta}$ es un estadístico (función de T únicamente)*
2. *$\mathbb{E}_\theta\big[\tilde{\theta}\big] = \mathbb{E}_\theta\big[\hat{\theta}\big]$ (mismo sesgo)*
3. *$\mathrm{Var}_\theta\big(\tilde{\theta}\big) \le \mathrm{Var}_\theta\big(\hat{\theta}\big)$ para todo θ, con igualdad si y solo si $\hat{\theta}$ es función de T casi seguramente*

Demostración. **(1)** Por suficiencia, la distribución condicional de X dado T no depende de θ (Definición 4.34), por lo que $\mathbb{E}\big[\hat{\theta} \mid T\big]$ no depende de θ y es función medible de T.

(2) Por la ley de esperanzas iteradas:

$$\mathbb{E}_\theta\big[\tilde{\theta}\big] = \mathbb{E}_\theta\Big[\mathbb{E}\big[\hat{\theta} \mid T\big]\Big] = \mathbb{E}_\theta\big[\hat{\theta}\big]$$

(3) Por la ley de varianza total:

$$\mathrm{Var}_\theta\big(\hat{\theta}\big) = \mathbb{E}_\theta\Big[\mathrm{Var}\big(\hat{\theta} \mid T\big)\Big] + \mathrm{Var}_\theta\Big(\mathbb{E}\big[\hat{\theta} \mid T\big]\Big)$$

Como $\mathbb{E}_\theta\Big[\mathrm{Var}\big(\hat{\theta} \mid T\big)\Big] \ge 0$:

$$\mathrm{Var}_\theta\big(\hat{\theta}\big) \ge \mathrm{Var}_\theta\big(\tilde{\theta}\big)$$

La igualdad se da si y solo si $\mathrm{Var}\big(\hat{\theta} \mid T\big) = 0$ c.s., es decir, $\hat{\theta}$ es función de T. □

Corolario 4.57. *Si $\hat{\theta}$ es insesgado, entonces $\tilde{\theta} = \mathbb{E}\big[\hat{\theta} \mid T\big]$ también es insesgado y tiene varianza menor o igual.*

Ejemplo 4.58 (Rao-Blackwellización en Bernoulli). Sea $X_1, \ldots, X_n \overset{\text{iid}}{\sim} \mathrm{Bernoulli}(p)$.
- Estimador inicial: $\hat{p} = X_1$ (insesgado, usa solo una observación)
- Estadístico suficiente: $T = \sum_{i=1}^{n} X_i$
- Estimador Rao-Blackwellizado:

$$\tilde{p} = \mathbb{E}[X_1 \mid T] = \frac{T}{n} = \overline{X}$$

Documento de uso personal

La varianza mejora de $\mathrm{Var}(X_1) = p(1-p)$ a $\mathrm{Var}\left(\overline{X}\right) = p(1-p)/n$, una reducción por factor n.

4.2.3 El Teorema de Lehmann-Scheffé y UMVUE

Definición 4.59 (UMVUE). Un estimador $\hat{\theta}^*$ es el *estimador insesgado de varianza uniformemente mínima* (UMVUE) para $g(\theta)$ si:
1. $\mathbb{E}_\theta\left[\hat{\theta}^*\right] = g(\theta)$ para todo θ (insesgado)
2. Para cualquier otro estimador insesgado $\tilde{\theta}$ de $g(\theta)$: $\mathrm{Var}_\theta\left(\hat{\theta}^*\right) \leq \mathrm{Var}_\theta\left(\tilde{\theta}\right)$ para todo $\theta \in \Theta$

Teorema 4.60 (Lehmann-Scheffé). *Sea T un estadístico suficiente y completo para θ (ver Definición 4.41). Si $\hat{\theta}$ es cualquier estimador insesgado de varianza finita de $g(\theta)$, entonces:*

$$\hat{\theta}^* = \mathbb{E}\left[\hat{\theta} \mid T\right]$$

es el único UMVUE para $g(\theta)$, salvo igualdad casi segura bajo cada modelo.

Demostración. **Existencia:** Por Rao-Blackwell (Teorema 4.56), $\hat{\theta}^* = \mathbb{E}\left[\hat{\theta} \mid T\right]$ es insesgado y tiene varianza no mayor que la del estimador inicial. La comparación con otros estimadores requiere completitud, como se prueba a continuación.

Optimalidad global: Sea δ cualquier estimador insesgado de $g(\theta)$. Definamos $\delta^* = \mathbb{E}[\delta \mid T]$. Por Rao-Blackwell, $\mathrm{Var}_\theta(\delta^*) \leq \mathrm{Var}_\theta(\delta)$.

Ahora, tanto $\hat{\theta}^*$ como δ^* son funciones de T e insesgados para $g(\theta)$. Por lo tanto:

$$\mathbb{E}_\theta\left[\hat{\theta}^* - \delta^*\right] = g(\theta) - g(\theta) = 0 \quad \forall \theta$$

Por completitud de T (Definición 4.41), esto implica $\hat{\theta}^* = \delta^*$ casi seguramente.

Por lo tanto, $\mathrm{Var}_\theta\left(\hat{\theta}^*\right) = \mathrm{Var}_\theta(\delta^*) \leq \mathrm{Var}_\theta(\delta)$ para todo δ insesgado.

Unicidad: Si $\hat{\theta}_1^*$ y $\hat{\theta}_2^*$ son ambos UMVUE, la igualdad en Rao–Blackwell obliga a que ambos sean funciones de T casi seguramente; la completitud aplicada a su diferencia prueba que coinciden. □

Corolario 4.61. *En familias exponenciales regulares, el estadístico natural T es suficiente completo (Corolario 4.44), y cualquier función insesgada de T es el UMVUE.*

4.2.4 La Cota Inferior de Cramér-Rao

La cota de Cramér-Rao establece un límite fundamental para la precisión alcanzable por cualquier estimador insesgado.

Definición 4.62 (Información de Fisher). Sea $f(x|\theta)$ la densidad de X con $\theta \in \Theta \subseteq \mathbb{R}$. La *información de Fisher* es:

$$I(\theta) = \mathbb{E}_\theta\left[\left(\frac{\partial}{\partial\theta}\log f(X|\theta)\right)^2\right]$$

Bajo condiciones de regularidad (intercambio de derivación e integración):

$$I(\theta) = -\mathbb{E}_\theta\left[\frac{\partial^2}{\partial\theta^2}\log f(X|\theta)\right]$$

Definición 4.63 (Función Score). La *función score* es:

$$S(\theta; X) = \frac{\partial}{\partial\theta}\log f(X|\theta)$$

Bajo regularidad, $\mathbb{E}_\theta[S(\theta;X)] = 0$ y $\mathrm{Var}_\theta(S(\theta;X)) = I(\theta)$.

Teorema 4.64 (Cota Inferior de Cramér-Rao). *Suponga parámetro interior escalar, soporte común, diferenciación bajo la integral para la densidad y para la esperanza del estimador, score centrado,* $0 < I(\theta) < \infty$ *y varianza finita. Para cualquier estimador* $\hat{\theta}$ *de* $g(\theta)$ *con* $\mathbb{E}_\theta\left[\hat{\theta}\right] = g(\theta) + b(\theta)$ *(donde* $b(\theta)$ *es el sesgo):*

$$\operatorname{Var}_\theta\left(\hat{\theta}\right) \geq \frac{\left([g'(\theta) + b'(\theta)]\right)^2}{I(\theta)}$$

Para estimadores insesgados ($b(\theta) = 0$*):*

$$\operatorname{Var}_\theta\left(\hat{\theta}\right) \geq \frac{\left(g'(\theta)\right)^2}{I(\theta)}$$

En particular, para estimar θ *directamente sin sesgo (*$g(\theta) = \theta$*,* $b = 0$*):*

$$\operatorname{Var}_\theta\left(\hat{\theta}\right) \geq \frac{1}{I(\theta)}$$

Demostración. Utilizamos la desigualdad de Cauchy-Schwarz. Sea $S = S(\theta; X)$ la función score. Entonces:

$$\operatorname{Cov}_\theta\left(\hat{\theta}, S\right)^2 \leq \operatorname{Var}_\theta\left(\hat{\theta}\right) \cdot \operatorname{Var}_\theta(S) = \operatorname{Var}_\theta\left(\hat{\theta}\right) \cdot I(\theta)$$

Calculamos la covarianza. Bajo regularidad, diferenciando $\mathbb{E}_\theta\left[\hat{\theta}\right] = g(\theta) + b(\theta)$:

$$\frac{\mathrm{d}}{\mathrm{d}\theta} \int \hat{\theta}(x) f(x|\theta)\, \mathrm{d}x = g'(\theta) + b'(\theta)$$

$$\int \hat{\theta}(x) \frac{\partial f}{\partial \theta}\, \mathrm{d}x = \int \hat{\theta}(x) f(x|\theta) \cdot \frac{\partial \log f}{\partial \theta}\, \mathrm{d}x = \mathbb{E}_\theta\left[\hat{\theta} \cdot S\right]$$

Como $\mathbb{E}_\theta[S] = 0$:

$$\operatorname{Cov}_\theta\left(\hat{\theta}, S\right) = \mathbb{E}_\theta\left[\hat{\theta} \cdot S\right] = g'(\theta) + b'(\theta)$$

Sustituyendo en Cauchy-Schwarz:

$$\left(g'(\theta) + b'(\theta)\right)^2 \leq \operatorname{Var}_\theta\left(\hat{\theta}\right) \cdot I(\theta)$$

Despejando se obtiene la cota. □

Definición 4.65 (Eficiencia). Un estimador insesgado $\hat{\theta}$ de θ es *eficiente* si alcanza la cota de Cramér-Rao:

$$\operatorname{Var}_\theta\left(\hat{\theta}\right) = \frac{1}{I(\theta)}$$

La información de una muestra independiente se obtiene sumando las contribuciones de sus observaciones. Esa identidad permite expresar la cota en función del tamaño de muestra.

Proposición 4.66 (Aditividad de la Información). *Si* $X_1, \ldots, X_n$ *son iid con información de Fisher* $I_1(\theta)$ *por observación, entonces la información total es:*

$$I_n(\theta) = n \cdot I_1(\theta)$$

Demostración. Por independencia, el score total es la suma de scores individuales:

Dr. Jaime Chávez Chuquiruivil

$$S_n(\theta; X_1, ..., X_n) = \sum_{i=1}^{n} \frac{\partial}{\partial \theta} \log f(X_i|\theta)$$

Por independencia e idéntica distribución:

$$I_n(\theta) = \mathrm{Var}_\theta(S_n) = \sum_{i=1}^{n} \mathrm{Var}_\theta(S_i) = n \cdot I_1(\theta)$$

□

Corolario 4.67 (Cota de Cramér-Rao para Muestras iid). *Para un estimador insesgado de θ basado en n observaciones iid y bajo las condiciones de Cramér–Rao:*

$$\mathrm{Var}_\theta\big(\hat{\theta}\big) \geq \frac{1}{n \cdot I_1(\theta)}$$

La cota decrece como $\frac{1}{n}$; no implica que se alcance para todo modelo y parámetro.

4.2.5 El Estimador de Máxima Verosimilitud

Definición 4.68 (Función de Verosimilitud). Para datos iid $\boldsymbol{x} = (x_1, ..., x_n)$, la *función de verosimilitud* es:

$$L(\theta; \boldsymbol{x}) = \prod_{i=1}^{n} f(x_i|\theta)$$

La *log-verosimilitud* es $\ell(\theta; \boldsymbol{x}) = \log L(\theta; \boldsymbol{x}) = \sum_{i=1}^{n} \log f(x_i|\theta)$.

Definición 4.69 (Estimador de Máxima Verosimilitud). El *MLE* es:

$$\hat{\theta}_{\mathrm{MLE}} = \arg\max_{\theta \in \Theta} L(\theta; \boldsymbol{x}) = \arg\max_{\theta \in \Theta} \ell(\theta; \boldsymbol{x})$$

Teorema 4.70 (Propiedades del MLE bajo Regularidad). *Suponga datos iid de un modelo correctamente especificado e identificable, parámetro verdadero interior, existencia de un máximo y consistencia de la secuencia de máximos elegida. Para garantizar esta última pueden usarse una ley uniforme de grandes números y separación del máximo poblacional. Suponga además score de varianza finita $0 < I_1(\theta_0) < \infty$, diferenciabilidad local y convergencia uniforme del Hessiano normalizado a $-I_1(\theta_0)$. Entonces*

$$\sqrt{n}\big(\hat{\theta}_{\mathrm{MLE}} - \theta_0\big) \xrightarrow{d} N\big(0, I_1(\theta_0)^{-1}\big).$$

Bajo regularidad local del experimento, alcanza la cota asintótica entre estimadores regulares. La propiedad de invarianza usa maximización de la verosimilitud perfilada si la transformación no es inyectiva. Fronteras, mezclas singulares y mala especificación requieren otros resultados.

Sketch de demostración. **(Normalidad asintótica)** Expandiendo la ecuación score $\sum_i S(\theta; X_i) = 0$ en Taylor alrededor de θ_0:

$$0 = \sum_{i=1}^{n} S(\theta_0; X_i) + \big(\hat{\theta}_{\mathrm{MLE}} - \theta_0\big) \sum_{i=1}^{n} S'\big(\tilde{\theta}; X_i\big)$$

donde $\tilde{\theta}$ está entre $\hat{\theta}_{\mathrm{MLE}}$ y θ_0. Reorganizando:

$$\sqrt{n}\big(\hat{\theta}_{\mathrm{MLE}} - \theta_0\big) = \frac{\frac{1}{\sqrt{n}} \sum_{i=1}^{n} S(\theta_0; X_i)}{-\frac{1}{n} \sum_{i=1}^{n} S'\big(\tilde{\theta}; X_i\big)}$$

Por el CLT, el numerador converge a $N(0, I_1(\theta_0))$. Por la LGN, el denominador converge a $I_1(\theta_0)$. Por Slutsky, el cociente converge a $N(0, 1/I_1(\theta_0))$.

Ver van der Vaart (1998), Capítulo 5. (argumento y alcance en Apéndice A, pág. 222) □

Ejemplo 4.71 (MLE para la Normal). Sea $X_1, ..., X_n \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$. La log-verosimilitud es:

$$\ell(\mu, \sigma^2) = -\frac{n}{2}\log(2\pi) - \frac{n}{2}\log\sigma^2 - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i - \mu)^2$$

Las ecuaciones de verosimilitud dan:

$$\hat{\mu}_{\text{MLE}} = \overline{X}, \quad \hat{\sigma}^2_{\text{MLE}} = \frac{1}{n}\sum_{i=1}^{n}\left(X_i - \overline{X}\right)^2$$

El MLE de σ^2 es sesgado (factor $\frac{n-1}{n}$), pero consistente y asintóticamente eficiente.

Ejemplo 4.72 (Regularidad, mala especificación y frontera). Si se ajusta una normal de varianza fijada a datos iid de media μ_0 y varianza real τ^2, el MLE de la media sigue siendo $\overline{Y}$. Su varianza asintótica es $\frac{\tau^2}{n}$, no la varianza impuesta al modelo dividida por n. Estimar la varianza de los datos puede corregir el error estándar de esa media; no corrige automáticamente otros objetivos de un modelo mal especificado.

En general, un estimador de ecuaciones regulares tiene matriz sándwich $H^{-1}JH^{-\top}$, donde H es la derivada media del momento y J su matriz de covarianza. Con dependencia se reemplaza J por una covarianza de largo plazo.

Para $X_i \sim \text{Uniforme}(0, \theta)$, el máximo converge a escala n, no $\sqrt{n}$: $n\left(1 - \frac{X_{(n)}}{\theta}\right)$ converge a una exponencial de media uno. El soporte depende del parámetro y el score formal no tiene media cero. Esta es una frontera del razonamiento regular de Fisher, no una violación de Cramér–Rao.

4.2.6 Métodos Computacionales Bayesianos: MCMC e Inferencia Variacional

Los resultados de optimalidad frecuentista no exigen una fórmula cerrada. Sin embargo, el error numérico debe controlarse por separado del error estadístico. En la práctica del agente inteligente, las distribuciones a posteriori rara vez admiten soluciones analíticas, y se requieren métodos computacionales para aproximar integrales de alta dimensión. Aquí se consideran **Markov Chain Monte Carlo (MCMC)** e **inferencia variacional (VI)**, que aproximan el posterior de maneras distintas.

Definición 4.73 (Algoritmo de Metropolis-Hastings). Sea $\pi(\theta) \propto L(\theta)p(\theta)$ la distribución a posteriori de interés (no normalizada). El algoritmo *Metropolis-Hastings* genera una cadena de Markov $\left\{\theta^{(t)}\right\}$ con distribución estacionaria $\pi(\theta)$ mediante:

1. Dado $\theta^{(t)}$, proponer $\theta^* \sim q\left(\cdot \mid \theta^{(t)}\right)$
2. Calcular la probabilidad de aceptación:

$$\alpha = \min\left(1, \frac{\pi(\theta^*)q\left(\theta^{(t)} \mid \theta^*\right)}{\pi\left(\theta^{(t)}\right)q\left(\theta^* \mid \theta^{(t)}\right)}\right)$$

3. Con probabilidad α, aceptar $\theta^{(t+1)} = \theta^*$; caso contrario, $\theta^{(t+1)} = \theta^{(t)}$

Bajo recurrencia de Harris positiva, irreducibilidad y aperiodicidad adecuadas, la cadena converge a $\pi(\theta)$ y se satisface el Teorema Ergódico: $\frac{1}{T}\sum_{t=1}^{T} g\left(\theta^{(t)}\right) \to \mathbb{E}_\pi[g(\theta)]$ para funciones integrables. Un CLT y un error estándar requieren condiciones adicionales.

Definición 4.74 (Inferencia Variacional y ELBO). La *Inferencia Variacional* aproxima la posterior $\pi(\theta)$ mediante una distribución $q_\lambda(\theta)$ en una familia variacional $\mathcal{Q}$, minimizando la divergencia de Kullback-Leibler:

$$\mathrm{KL}(q_\lambda \parallel \pi) = \mathbb{E}_{q_\lambda}[\log q_\lambda(\theta)] - \mathbb{E}_{q_\lambda}[\log \pi(\theta)].$$

Equivalentemente, se maximiza la *Evidence Lower Bound* (ELBO):

$$\mathrm{ELBO}(\lambda) = \mathbb{E}_{q_\lambda}[\log L(\theta)] - \mathrm{KL}(q_\lambda \parallel p),$$

donde $L(\theta)$ es la verosimilitud y $p(\theta)$ la prior. La maximización del ELBO equivale a minimizar $\mathrm{KL}(q_\lambda \parallel \pi)$, ya que $\log p(X) = \mathrm{ELBO}(\lambda) + \mathrm{KL}(q_\lambda \parallel \pi)$.

Las dos aproximaciones difieren en el error que permanece al aumentar el esfuerzo de cálculo. Esa diferencia importa al utilizar sus resultados para decidir.

Nota 4.75 (Comparación MCMC vs. VI). Bajo las condiciones ergódicas indicadas, los promedios MCMC convergen al promedio posterior, aunque el error Monte Carlo finito y su varianza requieren control. En VI, la restricción de la familia puede dejar error de aproximación incluso con optimización exacta; ese error es cero si la familia contiene el posterior y se alcanza el mínimo global. Rapidez, escalabilidad y precisión dependen del problema y de la implementación, no son una ordenación universal de ambos métodos.

Un posterior conjugado permite observar esa diferencia con una referencia conocida.

Ejemplo 4.76 *(sintético)* **(SSCH — Estimación Bayesiana de Probabilidades de Transición).** Use los conteos sintéticos $(2, 5, 3)$ y prior Dirichlet$(1, 1, 1)$, uniforme sobre el simplex, sin llamarlo neutral frente a toda parametrización. El posterior es Dirichlet$(3, 6, 4)$ y su media $\left(\frac{3}{13}, \frac{6}{13}, \frac{4}{13}\right)$. La varianza de la segunda probabilidad es $6\frac{13-6}{13^2(14)} = \frac{3}{169}$.

Este posterior permite muestreo directo independiente y proporciona una referencia exacta para comprobar un algoritmo MCMC. Si la familia variacional contiene todas las Dirichlet, contiene el posterior exacto y el mínimo global de KL es cero. Una Dirichlet no factoriza en variables independientes sobre sus coordenadas: suman uno. No se reportan tiempos, ESS ni diagnósticos de cadenas que no se hayan ejecutado.

4.2.6.1 Aproximación posterior fuera de la conjugación

El ejemplo conjugado anterior proporciona una referencia exacta. Fuera de la conjugación, MCMC y la aproximación variacional permiten continuar el cálculo, con errores que deben distinguirse de la incertidumbre estadística. Esa diferencia orienta la lectura de los diagnósticos y del ejemplo siguiente.

Markov Chain Monte Carlo (MCMC). La idea central de MCMC es construir una cadena de Markov cuya distribución estacionaria sea el posterior $\pi(\theta|x)$. El algoritmo de Metropolis-Hastings (Gelman et al., 2013) genera una propuesta $\theta^* \sim q\left(\cdot\,|\theta^{(t)}\right)$ y la acepta con probabilidad $\alpha = \min\left(1, \frac{\pi(\theta^*|x)q(\theta^{(t)}|\theta^*)}{\pi(\theta^{(t)}|x)q(\theta^*|\theta^{(t)})}\right)$. Bajo condiciones de irreducibilidad y aperiodicidad, $\theta^{(t)} \xrightarrow{d} \pi(\theta|x)$. El tamaño muestral efectivo y $\hat{R}$ son diagnósticos, no pruebas de convergencia. La aproximación de su error utiliza el CLT para cadenas de Markov bajo condiciones de mixing (Teorema 4.104) garantiza la normalidad asintótica de los estimadores MCMC.

Variational Inference (VI). VI reformula la inferencia como un problema de optimización: en lugar de muestrear del posterior, se busca la distribución q^* en una familia $\mathcal{Q}$ que minimiza $\mathrm{KL}(q \parallel \pi(\cdot\,|x))$. Equivalentemente, VI maximiza el *Evidence Lower Bound* (ELBO):

$$\mathrm{ELBO}(q) = \mathbb{E}_q[\log p(x, \theta)] - \mathbb{E}_q[\log q(\theta)].$$

La descomposición $\log p(x) = \mathrm{ELBO}(q) + \mathrm{KL}(q \parallel \pi(\cdot\,|x))$ revela que maximizar el ELBO equivale a minimizar la divergencia KL al posterior. El ELBO acota la log-evidencia $\log p(X)$, no el riesgo de Bayes bajo una pérdida arbitraria. La calidad de decisiones e intervalos requiere evaluar además el efecto de la aproximación posterior.

Ejemplo 4.77 (MCMC para el SSCH con Prior No Conjugado). Para tres destinos, parametrice $\theta_j = \frac{e^{z_j}}{1+e^{z_1}+e^{z_2}}$ para $j = 1, 2$ y $\theta_3 = \frac{1}{1+e^{z_1}+e^{z_2}}$. Un prior $z \sim N_2(0, I)$ induce una logística normal no conjugada. Con conteos $(2, 5, 3)$,

$$\ell(z) = 2z_1 + 5z_2 - 10\log(1 + e^{z_1} + e^{z_2}) - \frac{\|z\|^2}{2} + C.$$

Una propuesta simétrica $z' = z + \varepsilon$, $\varepsilon \sim N_2(0, 0.1^2 I)$, se acepta con probabilidad $\min(1, \exp(\ell(z') - \ell(z)))$. En $z = (0, 0)$ y $z' = (0, 0.1)$, la diferencia es aproximadamente 0.15044 y la aceptación vale uno. Esto ilustra un paso, no una cadena convergida. El prior está definido en logits, por lo que no se agrega un jacobiano a esta densidad en z.

Contrastar hipótesis con una regla de error explícita

Estimar un objetivo y decidir si los datos contradicen una hipótesis plantean preguntas relacionadas. Para pasar a la segunda debemos fijar las acciones del contraste y los errores que se pretende controlar.

4.3.1 Formulación del problema de contraste

Definición 4.78 (Hipótesis Estadísticas). Sea $\mathcal{P} = \{P_\theta : \theta \in \Theta\}$ un modelo paramétrico. Un *test de hipótesis* contrasta:

$$H_0 : \theta \in \Theta_0 \quad \text{versus} \quad H_1 : \theta \in \Theta_1$$

donde $\Theta_0 \cup \Theta_1 \subseteq \Theta$ y típicamente $\Theta_0 \cap \Theta_1 = \varnothing$. H_0 es la *hipótesis nula*, H_1 la *alternativa*. Si $\Theta_0 = \{\theta_0\}$, H_0 es *simple*; de lo contrario es *compuesta*.

Definición 4.79 (Test y Región Crítica). Un *test* (no aleatorizado) es una función $\varphi : \mathcal{X} \to \{0, 1\}$:
- $\varphi(x) = 1$: rechazar H_0
- $\varphi(x) = 0$: no rechazar H_0

La *región crítica* es $C = \{x \in \mathcal{X} : \varphi(x) = 1\}$.

Un *test aleatorizado* es $\varphi : \mathcal{X} \to [0, 1]$ donde $\varphi(x)$ es la probabilidad de rechazar H_0 dado $X = x$.

Definición 4.80 (Errores Tipo I y II).

Decisión	H_0 verdadera	H_1 verdadera
No rechazar H_0	Correcta	Error Tipo II (β)
Rechazar H_0	Error Tipo I (α)	Correcta (Poder = $1 - \beta$)

Definición 4.81 (Función de Potencia). La *función de potencia* de un test φ es:

$$\beta_\varphi(\theta) = \mathbb{E}_\theta[\varphi(X)] = P_\theta(\text{rechazar} \quad H_0)$$

Para $\theta \in \Theta_0$: probabilidad de error Tipo I. Para $\theta \in \Theta_1$: *poder* del test.

Definición 4.82 (Tamaño y Nivel). El *tamaño* de un test φ es $\alpha_\varphi = \sup_{\theta \in \Theta_0} \beta_\varphi(\theta)$. Un test tiene *nivel* α si $\alpha_\varphi \leq \alpha$.

D. Ignacio Quiviger

Teorema 4.83 (Lema de Neyman-Pearson). *Para el test de $H_0 : \theta = \theta_0$ versus $H_1 : \theta = \theta_1$, sea $\Lambda(x) = \frac{f(x|\theta_1)}{f(x|\theta_0)}$ el* cociente de verosimilitudes. *Para cualquier $\alpha \in (0,1)$, existe un test φ^* de la forma:*

$$\varphi^*(x) = \begin{cases} 1 \text{ si } & \Lambda(x) > k \\ \gamma \text{ si } & \Lambda(x) = k \\ 0 \text{ si } & \Lambda(x) < k \end{cases}$$

donde $k \geq 0$ y $\gamma \in [0,1]$ satisfacen $\mathbb{E}_{\theta_0}[\varphi^*(X)] = \alpha$.

Este test φ^* es el test más potente *(MP) de nivel α: para cualquier otro test φ con $\mathbb{E}_{\theta_0}[\varphi(X)] \leq \alpha$:*

$$\mathbb{E}_{\theta_1}[\varphi^*(X)] \geq \mathbb{E}_{\theta_1}[\varphi(X)]$$

Demostración. Use densidades f_0, f_1 respecto de una medida común. Donde $f_0 = 0 < f_1$, la razón se define como infinita y se rechaza; donde ambas son cero la decisión no afecta el resultado. El umbral se elige como cuantil bajo P_0 y se aleatoriza en el átomo si es necesario. Con $D = \varphi^* - \varphi$, se tiene $D(f_1 - kf_0) \geq 0$ punto a punto. Integrar da $\mathbb{E}_1[D] \geq k\mathbb{E}_0[D] \geq 0$. Esta prueba evita dividir por cero y no requiere continuidad de la distribución de la razón. Véase (argumento y alcance en Apéndice A, pág. 223). □

Ejemplo 4.84 (Test MP para Normal). Sea $X_1, ..., X_n \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$ con σ^2 conocida. Para $H_0 : \mu = \mu_0$ versus $H_1 : \mu = \mu_1 > \mu_0$:

$$\Lambda(\boldsymbol{x}) = \exp\left\{ \frac{(\mu_1 - \mu_0)}{\sigma^2} \sum x_i - \frac{n(\mu_1^2 - \mu_0^2)}{2\sigma^2} \right\}$$

$\Lambda(\boldsymbol{x}) > k$ equivale a $\overline{x} > c$ para algún c. El test MP rechaza cuando $\overline{X} > \mu_0 + z_{1-\alpha} \cdot \frac{\sigma}{\sqrt{n}}$.

4.3.2 Tests Uniformemente Más Potentes

Definición 4.85 (Test UMP). Un test φ^* es *uniformemente más potente* (UMP) de nivel α si:
1. $\sup_{\theta \in \Theta_0} \mathbb{E}_\theta[\varphi^*] \leq \alpha$
2. Para todo $\theta \in \Theta_1$ y todo test φ de nivel α: $\mathbb{E}_\theta[\varphi^*] \geq \mathbb{E}_\theta[\varphi]$

Teorema 4.86 (Existencia de UMP en Familias MLR). *Sea $\mathcal{P}$ una familia con* cociente de verosimilitudes monótono *(MLR) en $T(X)$:*

$$\frac{f(x|\theta_2)}{f(x|\theta_1)} \text{ es no decreciente en } \; T(x) \text{ para } \; \theta_2 > \theta_1$$

Para $H_0 : \theta \leq \theta_0$ versus $H_1 : \theta > \theta_0$, el test UMP de nivel α rechaza cuando $T(X) > c$, con aleatorización en $T = c$ si es necesaria, elegida para que $\mathbb{E}_{\theta_0}[\varphi] = \alpha$. El orden estocástico inducido por MLR controla el nivel en toda la nula compuesta.

Sketch de demostración. Para cada $\theta_1 > \theta_0$, el test de Neyman-Pearson rechaza para $\Lambda(x)$ grande, que por MLR equivale a $T(x)$ grande. Como la región crítica $\{T > c\}$ no depende de θ_1, el mismo test es MP para todos los $\theta_1 > \theta_0$.

Ver Lehmann & Romano (2005), Capítulo 3. (argumento y alcance en Apéndice A, pág. 223) □

Corolario 4.87. *Las familias exponenciales canónicas de un parámetro, ordenadas por su parámetro natural, tienen MLR en el estadístico natural, y admiten tests UMP para hipótesis unilaterales.*

4.3.3 Tests UMPU

Para hipótesis bilaterales, típicamente no existen tests UMP.

Definición 4.88 (Test Insesgado y UMPU). Un test φ de nivel α es *insesgado* si $\beta_\varphi(\theta) \geq \alpha$ para todo $\theta \in \Theta_1$.

Un test φ^* es *UMPU* si es UMP dentro de la clase de tests insesgados de nivel α.

Teorema 4.89 (UMPU para Hipótesis Bilateral). *Sea $f(x|\theta) = c(\theta)h(x)\exp\{\eta(\theta)T(x)\}$ con $\eta(\theta)$ estrictamente creciente. Para $H_0 : \theta = \theta_0$ vs $H_1 : \theta \neq \theta_0$, el test UMPU de nivel α rechaza cuando $T(x) < c_1$ o $T(x) > c_2$, donde c_1, c_2 se determinan por las condiciones $\mathbb{E}_{\theta_0}[\varphi] = \alpha$ y $\mathbb{E}_{\theta_0}[T\varphi] = \alpha\mathbb{E}_{\theta_0}[T]$, bajo regularidad e interioridad del parámetro natural. En modelos discretos se permite aleatorizar en los extremos.*

Demostración: resultado clásico; véase Lehmann & Romano (2005).

4.3.4 Dualidad Test-Intervalo de Confianza

Definición 4.90 (Intervalo de Confianza). Un *intervalo de confianza* de nivel $1-\alpha$ para θ es un intervalo aleatorio $[L(X), U(X)]$ tal que:

$$P_\theta(\theta \in [L(X), U(X)]) \geq 1-\alpha \quad \forall \theta \in \Theta$$

Teorema 4.91 (Inversión de Tests). *Sea $\left\{\varphi_{\theta_0} : \theta_0 \in \Theta\right\}$ una familia de tests no aleatorizados de nivel α para $H_0 : \theta = \theta_0$. Entonces:*

$$C(X) = \left\{\theta_0 : \varphi_{\theta_0}(X) = 0\right\}$$

es una región de confianza de nivel $1-\alpha$.

Demostración. Para cualquier $\theta^* \in \Theta$:

$$P_{\theta^*}(\theta^* \in C(X)) = P_{\theta^*}(\varphi_{\theta^*}(X) = 0) = 1 - P_{\theta^*}(\varphi_{\theta^*}(X) = 1) \geq 1-\alpha$$

ya que φ_{θ^*} tiene nivel α para $H_0 : \theta = \theta^*$. □

Corolario 4.92 (IC a partir de Test Z). *Para $X_1, ..., X_n \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$ con σ^2 conocida, invirtiendo el test bilateral de nivel α:*

$$IC_{1-\alpha} = \left[\overline{X} - z_{1-\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}},\ \overline{X} + z_{1-\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}}\right]$$

4.3.5 Múltiples Comparaciones

Cuando se realizan múltiples tests, la probabilidad de al menos un error Tipo I aumenta.

Definición 4.93 (FWER y FDR). El *Family-Wise Error Rate* es:

$$\text{FWER} = P(\text{al menos un falso positivo})$$

Sea V el número de falsos positivos y R el total de rechazos. El *False Discovery Rate* es:

$$\text{FDR} = \mathbb{E}\left[\frac{V}{\max(R, 1)}\right]$$

La distinción entre FWER y FDR cambia lo que significa controlar el error. Incluso antes de escoger una corrección, varios contrastes independientes muestran cómo puede aumentar la probabilidad de algún falso positivo.

Proposición 4.94 (Problema de Multiplicidad). *Si se realizan m tests independientes de tamaño exacto α, y todas las H_0 son verdaderas:*

$$\text{FWER} = 1 - (1-\alpha)^m \approx m\alpha \text{ para } \alpha \text{ pequeño}$$

Documento sin valor oficial

Para controlar esa probabilidad sin exigir independencia, puede distribuirse el nivel de error entre los contrastes mediante la desigualdad de la unión.

Teorema 4.95 (Corrección de Bonferroni). *Para p-valores válidos (superuniformes bajo sus nulas) y una familia fijada de m tests, para controlar FWER $\leq \alpha$, rechazar $H_{0,i}$ solo si $p_i \leq \frac{\alpha}{m}$.*

Demostración. Por la desigualdad de Boole:

$$\text{FWER} = P\left(\bigcup_{i\in I_0}\left\{p_i \leq \frac{\alpha}{m}\right\}\right) \leq \sum_{i\in I_0} P\left(p_i \leq \frac{\alpha}{m}\right) \leq |I_0| \cdot \frac{\alpha}{m} \leq \alpha$$

donde I_0 es el conjunto de hipótesis nulas verdaderas. □

Ejemplo 4.96 (Pruebas Múltiples en SSCH con Corrección de Bonferroni). En el Sistema de Soporte Clínico para Hipertensión, queremos comparar la efectividad de 4 tratamientos diferentes ($m = 4$). Para cada tratamiento, probamos:

- $H_{0,i}$: El tratamiento i no mejora la presión arterial
- $H_{1,i}$: El tratamiento i mejora la presión arterial

Valores p observados:

- Tratamiento 1: $p_1 = 0.03$
- Tratamiento 2: $p_2 = 0.01$
- Tratamiento 3: $p_3 = 0.08$
- Tratamiento 4: $p_4 = 0.04$

Sin corrección ($\alpha = 0.05$):

- Rechazamos $H_{0,1}$, $H_{0,2}$, $H_{0,4}$ (todos con $p < 0.05$)
- Si las cuatro nulas fueran verdaderas y los tests independientes de tamaño exacto 0.05, FWER sería $1 - (1 - 0.05)^4 \approx 0.185$. No se infiere esa probabilidad de los cuatro p-valores observados.

Con corrección de Bonferroni ($\frac{\alpha}{m} = 0.0125$):

- Solo rechazamos $H_{0,2}$ (único con $p < 0.0125$)
- FWER ≤ 0.05 (controlado)

Interpretación: Sin corrección, rechazaríamos tres hipótesis. Los p-valores no permiten saber cuáles rechazos serían errores. Con Bonferroni, solo el tratamiento 2 (con el valor p más pequeño) se considera significativo, protegiéndonos contra falsos positivos.

Teorema 4.97 (Procedimiento de Holm). *Sea $p_{(1)} \leq p_{(2)} \leq \ldots \leq p_{(m)}$ los p-valores ordenados. El procedimiento de Holm:*

1. *Sea $k = \min\left\{i : p_{(i)} > \frac{\alpha}{m-i+1}\right\}$*
2. *Rechazar $H_{0,(1)}, \ldots, H_{0,(k-1)}$*

Si ningún índice cumple la condición, se rechazan todas las hipótesis. Para p-valores válidos, controla FWER bajo dependencia arbitraria y su conjunto de rechazos contiene al de Bonferroni.

Teorema 4.98 (Benjamini-Hochberg para FDR). *Sea $p_{(1)} \leq \ldots \leq p_{(m)}$ los p-valores ordenados. Definir:*

$$k = \max\left\{i : p_{(i)} \leq \frac{i \cdot \alpha}{m}\right\}$$

Si el conjunto es vacío, fijar $k = 0$. Rechazar las primeras k hipótesis. Para p-valores válidos, este procedimiento controla FDR $\leq m_0 \frac{\alpha}{m} \leq \alpha$ si los p-valores nulos son independientes de los restantes, o bajo la condición PRDS sobre el subconjunto de nulas verdaderas. La correlación positiva por sí sola no establece PRDS; véase (Benjamini & Yekutieli, 2001).

Uriel Jaime Hernández Corral

Demostración. Bajo independencia se usa que, al sustituir un p-valor nulo por cero, el total de rechazos permite acotar su contribución a la FDR por $\frac{\alpha}{m}$. La suma da $m_0\frac{\alpha}{m}$. La extensión PRDS requiere un argumento adicional; se atribuye a la literatura, no se deduce de independencia. Véase (argumento y alcance en Apéndice A, pág. 223). □

4.3.6 Tests de Hipótesis Bayesianos

El paradigma frecuentista fija α antes de observar los datos y controla el error Tipo I en el largo plazo. El paradigma bayesiano aborda el mismo problema desde otra dirección: dado el posterior $\pi(\theta|x)$, ¿cuánta evidencia aportan los datos en favor de H_1 frente a H_0? La respuesta se codifica en el *factor de Bayes*, que puede interpretarse como la actualización multiplicativa que los datos producen sobre la razón de probabilidades a priori.

Definición 4.99 (Factor de Bayes). Sean $H_0 : \theta \in \Theta_0$ y $H_1 : \theta \in \Theta_1$ hipótesis mutuamente excluyentes y exhaustivas, con probabilidades previas estrictamente positivas $\pi_0 = P(\theta \in \Theta_0)$ y $\pi_1 = 1 - \pi_0$, y priors condicionales propios con evidencias finitas y positivas. El *factor de Bayes* a favor de H_1 sobre H_0 es:

$$\mathrm{BF}_{10}(x) = \frac{m_1(x)}{m_0(x)}, \quad m_j(x) = \int_{\Theta_j} f(x|\theta)\pi\big(\theta|H_j\big)\,\mathrm{d}\theta,$$

donde m_j es la verosimilitud marginal (evidencia) bajo H_j y $\pi\big(\theta|H_j\big)$ es el prior sobre θ condicional a H_j.

Equivalentemente, el factor de Bayes actualiza las razones de probabilidad:

$$\underbrace{\frac{P(H_1|x)}{P(H_0|x)}}_{\text{razón posterior}} = \mathrm{BF}_{10}(x) \times \underbrace{\frac{\pi_1}{\pi_0}}_{\text{razón a priori}}.$$

Ejemplo 4.100 (Factor de Bayes en el SSCH: Comparación de dos tratamientos). Considere dos muestras binomiales independientes, $n_A = n_B = 50$, $y_A = 32$, $y_B = 20$, con priors independientes $\mathrm{Beta}(1,1)$. Los posteriores son $p_A|y \sim \mathrm{Beta}(33,19)$ y $p_B|y \sim \mathrm{Beta}(21,31)$. Para las hipótesis de orden $H_1 : p_A > p_B$ y $H_0 : p_A \le p_B$, la probabilidad previa de cada región es $\frac{1}{2}$.

Calcule $q = \int_0^1 f_{33,19}(u)F_{21,31}(u)\,\mathrm{d}u$, donde f y F son densidad y CDF beta. La integración numérica da $q \approx 0.99151457$ y $\mathrm{BF}_{10} = \frac{q}{1-q} \approx 116.8491$. Los priors dentro de las hipótesis son los priors conjuntos restringidos y normalizados en cada región. No es un contraste de igualdad puntual ni un p-valor.

La actualización de los cuatro parámetros beta es constante por observación; evaluar la integral tiene costo numérico propio. El siguiente código reproduce el cálculo, sin atribuirle una precisión clínica:

```
from scipy.integrate import quad
from scipy.stats import beta
q, error = quad(lambda u: beta.pdf(u, 33, 19)
                        * beta.cdf(u, 21, 31), 0, 1)
print(q, q / (1 - q), error)
```

La comparación de las dos pérdidas posteriores convierte la evidencia bayesiana en una regla de decisión con costos explícitos.

Proposición 4.101 (Regla de Bayes para contraste de hipótesis con pérdida 0–1). *Bajo la función de pérdida 0–1 con costos asimétricos w_I y w_{II}, la regla de Bayes rechaza H_0 si y solo si:*

$$\mathrm{BF}_{10}(x) > \frac{w_I}{w_{II}} \cdot \frac{\pi_0}{\pi_1}.$$

En particular, si $w_I = w_{II}$ y $\pi_0 = \pi_1 = \frac{1}{2}$, se rechaza H_0 cuando $\mathrm{BF}_{10} > 1$, es decir, cuando los datos favorecen a H_1 sobre H_0.

Sketch de demostración. La pérdida esperada posterior de aceptar H_0 es $w_{II} \cdot P(H_1|x)$; la de rechazar H_0 es $w_I \cdot P(H_0|x)$. La regla de Bayes elige la acción con menor pérdida esperada, lo que conduce directamente a la desigualdad. □

Aproximar la distribución del error de estimación

Los criterios anteriores describen propiedades de estimadores y contrastes. Para cuantificar su error con muestras grandes necesitamos aproximaciones a sus distribuciones. El recorrido empieza por medias y continúa con transformaciones, funciones y procedimientos de remuestreo.

4.4.1 El teorema central del límite

El Teorema Central del Límite (CLT) justifica la aproximación normal para sumas de variables aleatorias y, por extensión, para la mayoría de los estimadores estadísticos.

Teorema 4.102 (CLT Clásico de Lindeberg-Lévy). *Sea $X_1, X_2, \ldots$ una sucesión de variables aleatorias iid con $\mathbb{E}[X_i] = \mu$ y $0 < \mathrm{Var}(X_i) = \sigma^2 < \infty$. Entonces:*

$$\sqrt{n}\big(\overline{X}_n - \mu\big) \xrightarrow{d} N(0, \sigma^2)$$

o equivalentemente:

$$\frac{\overline{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}} \xrightarrow{d} N(0,1)$$

El CLT es una afirmación límite; no fija un umbral universal de 30 o 50 trayectorias. Asimetría, colas pesadas y pesos extremos pueden retrasar la aproximación. Para usar un intervalo normal se necesita además estimar consistentemente su varianza y justificar la unidad de observación independiente.

Demostración. Sea $\varphi_X(t) = \mathbb{E}\big[e^{it(X-\mu)}\big]$ la función característica de $X_i - \mu$. Tenemos $\varphi_X(0) = 1$, $\varphi_X'(0) = 0$, y $\varphi_X''(0) = -\sigma^2$.

La función característica de $Z_n = \sqrt{n}\big(\overline{X}_n - \mu\big)$ es:

$$\varphi_{Z_n}(t) = \left[\varphi_X\left(\frac{t}{\sqrt{n}}\right)\right]^n$$

Expandiendo en Taylor:

$$\varphi_X\left(\frac{t}{\sqrt{n}}\right) = 1 - \frac{\sigma^2 t^2}{2n} + o\left(\frac{1}{n}\right)$$

Por lo tanto:

$$\varphi_{Z_n}(t) = \left(1 - \frac{\sigma^2 t^2}{2n} + o\left(\frac{1}{n}\right)\right)^n \to e^{-\sigma^2 \frac{t^2}{2}}$$

que es la función característica de $N(0,\sigma^2)$. Por el teorema de continuidad de Lévy, $Z_n \xrightarrow{d} N(0,\sigma^2)$. □

El CLT clásico cubre variables idénticamente distribuidas. Otros diseños requieren una versión diferente. El teorema de Lindeberg–Feller relaja esta exigencia: basta controlar las colas de las distribuciones individuales.

Teorema 4.103 (CLT de Lindeberg-Feller). *Sea $\{X_{n,i} : 1 \le i \le k_n\}$ un arreglo triangular con variables independientes dentro de cada fila (no necesariamente idénticas), con medias y varianzas finitas. Suponga $0 < s_n^2 < \infty$ en cada fila. Sea $s_n^2 = \sum_{i=1}^{k_n} \sigma_{n,i}^2$.*

Si se cumple la condición de Lindeberg*: para todo $\epsilon > 0$,*

$$\frac{1}{s_n^2}\sum_{i=1}^{k_n} \mathbb{E}\Big[(X_{n,i}-\mu_{n,i})^2 \mathbb{1}_{|X_{n,i}-\mu_{n,i}|>\epsilon s_n}\Big] \to 0$$

entonces:

$$\frac{\sum_{i=1}^{k_n}(X_{n,i}-\mu_{n,i})}{s_n} \xrightarrow{d} N(0,1)$$

Demostración: resultado clásico; véase van der Vaart (1998).

La condición de Lindeberg controla que ninguna observación individual domine la varianza total. Para un agente que combina múltiples fuentes de evidencia con precisiones heterogéneas —por ejemplo, retornos de trayectorias de distintas longitudes o políticas con distinto número de datos — este teorema garantiza que la normalidad asintótica se preserva incluso cuando las varianzas individuales difieren sustancialmente, siempre que ninguna trayectoria por sí sola determine el resultado.

Teorema 4.104 (CLT bajo mezcla fuerte). *Sea (Z_t) estrictamente estacionaria, de media μ, con $\mathbb{E}\big[|Z_0|^{2+\delta}\big] < \infty$ para algún $\delta > 0$. Defina*

$$\alpha(k) = \sup_{A\in\sigma(Z_t:t\le 0),\, B\in\sigma(Z_t:t\ge k)} |P(A\cap B) - P(A)P(B)|.$$

Si $\sum_{k=1}^{\infty} \alpha(k)^{\frac{\delta}{2+\delta}} < \infty$ y

$$\tau^2 = \operatorname{Var}(Z_0) + 2\sum_{k=1}^{\infty}\operatorname{Cov}(Z_0,Z_k) > 0,$$

entonces $\sqrt{n}\big(\overline{Z}_n - \mu\big)$ converge a $N(0,\tau^2)$. Se cita este teorema de dependencia, sin reproducir aquí su prueba por aproximación de martingalas; véanse (Bradley, 2005) y las notas de mezcla de Shalizi.

Ejemplo 4.105 (La correlación cambia el error estándar). Sea $Z_t - \mu = \rho(Z_{t-1}-\mu) + \varepsilon_t$, con innovaciones gaussianas iid, $|\rho| < 1$ e inicio estacionario. Si la varianza marginal es σ_Z^2, entonces $\operatorname{Cov}(Z_0, Z_k) = \sigma_Z^2 \rho^k$ y

$$\tau^2 = \sigma_Z^2 \frac{1+\rho}{1-\rho}.$$

Para $\rho = 0.6$, $\tau^2 = 4\sigma_Z^2$: el error estándar de la media es asintóticamente el doble del calculado suponiendo independencia. La equivalencia heurística de tamaño efectivo sería $\frac{n}{4}$ para esta media; no es una identidad universal para todo estimador.

Para una sola serie, estimar la varianza marginal y dividir por n omite autocovarianzas. Un estimador HAC o de medias por bloques debe acompañarse de condiciones sobre momentos, dependencia

Dr. Ignacio Curiel

y crecimiento del ancho de banda. Para episodios independientes, se puede trabajar con un retorno por episodio aunque dentro de cada uno haya dependencia.

Muchos objetivos se obtienen transformando estimaciones: una razón, una probabilidad o el valor calculado a partir de transiciones. El método delta permite seguir el efecto de esa transformación sobre la fluctuación de primer orden.

4.4.2 El Delta Method

Teorema 4.106 (Delta Method Univariado). *Sea $\{T_n\}$ una sucesión de estadísticos con $\sqrt{n}(T_n - \theta) \xrightarrow{d} N(0, \sigma^2)$. Sea $g : \mathbb{R} \to \mathbb{R}$ diferenciable en θ con $g'(\theta) \neq 0$. Entonces:*

$$\sqrt{n}(g(T_n) - g(\theta)) \xrightarrow{d} N\Big(0, [g'(\theta)]^2 \sigma^2\Big)$$

El Delta Method es la herramienta fundamental para propagar incertidumbre a través de cualquier transformación suave. Para un agente, esto significa que si conocemos la distribución asintótica de un estimador de parámetros del entorno (digamos, probabilidades de transición), podemos derivar automáticamente la distribución del valor de la política, que es una función no lineal de esos parámetros. La demostración es una aplicación directa del teorema de Slutsky junto con una expansión de Taylor de primer orden.

Demostración. Por expansión de Taylor:

$$g(T_n) = g(\theta) + g'(\theta)(T_n - \theta) + o(|T_n - \theta|)$$

Multiplicando por $\sqrt{n}$:

$$\sqrt{n}(g(T_n) - g(\theta)) = g'(\theta) \cdot \sqrt{n}(T_n - \theta) + o_P(1)$$

Como $T_n \xrightarrow{P} \theta$, el término residual es $o_P(1)$. Por Slutsky, el resultado converge a $g'(\theta) \cdot N(0, \sigma^2) = N\Big(0, [g'(\theta)]^2 \sigma^2\Big)$. □

El Delta Method univariado cubre transformaciones escalares. Para funciones vectoriales —como las que aparecen al estimar múltiples componentes de la función de valor— necesitamos la versión multivariada.

Teorema 4.107 (Delta Method Multivariado). *Sea $\boldsymbol{T}_n \in \mathbb{R}^k$ con $\sqrt{n}(\boldsymbol{T}_n - \boldsymbol{\theta}) \xrightarrow{d} N(\mathbf{0}, \boldsymbol{\Sigma})$. Sea $g : \mathbb{R}^k \to \mathbb{R}^m$ diferenciable con Jacobiana $\boldsymbol{J} = \nabla g(\boldsymbol{\theta})$. Entonces:*

$$\sqrt{n}(g(\boldsymbol{T}_n) - g(\boldsymbol{\theta})) \xrightarrow{d} N\big(\mathbf{0}, \boldsymbol{J}\boldsymbol{\Sigma}\boldsymbol{J}^\top\big)$$

Demostración: resultado clásico; véase van der Vaart (1998).

La matriz Jacobiana $\boldsymbol{J}$ actúa como un amplificador selectivo de la incertidumbre: direcciones del espacio de parámetros donde g varía rápidamente (gradiente grande) magnifican la varianza asintótica, mientras que direcciones planas la atenúan. Para un agente, esto significa que la incertidumbre en V^π depende no solo de cuánto ruido hay en las estimaciones de transición, sino de cuán sensible es el valor a cada parámetro — una noción que cuantificaremos en el Capítulo 8 vía funciones de influencia.

Una aplicación inmediata del Delta Method es derivar la varianza asintótica de razones de estimadores — un problema que aparece cada vez que comparamos dos políticas mediante el cociente de sus valores estimados.

Ejemplo 4.108 (Varianza Asintótica del Cociente). Si $\sqrt{n}\Big(\big(\overline{X}_n, \overline{Y}_n\big) - (\mu_X, \mu_Y)\Big) \xrightarrow{d} N(\mathbf{0}, \boldsymbol{\Sigma})$ con $\boldsymbol{\Sigma} = \begin{pmatrix} \sigma_X^2 & \sigma_{XY} \\ \sigma_{XY} & \sigma_Y^2 \end{pmatrix}$, para $g(x, y) = \frac{x}{y}$ y $\mu_Y \neq 0$:

$$\nabla g = \left(\frac{1}{\mu_Y}, -\frac{\mu_X}{\mu_Y^2} \right)$$

$$\mathrm{Var}_{\text{asint}} \left(\frac{\overline{X}_n}{\overline{Y}_n} \right) = \frac{1}{n\mu_Y^2} \left(\sigma_X^2 - 2\frac{\mu_X}{\mu_Y}\sigma_{XY} + \frac{\mu_X^2}{\mu_Y^2}\sigma_Y^2 \right)$$

Interpretación: esta fórmula revela un hecho crucial para la evaluación comparativa de políticas: la varianza de un cociente de valores estimados depende de la correlación σ_{XY} entre numerador y denominador. Si ambas políticas se evalúan sobre las mismas trayectorias (como en importance sampling con el mismo conjunto de datos), cuando $\frac{\mu_X}{\mu_Y} > 0$, la covarianza positiva reduce la expresión de varianza del cociente — un fenómeno que explotaremos en los estimadores doblemente robustos del Capítulo 7.

4.4.3 Procesos Empíricos

Definición 4.109 (Función de Distribución Empírica). Dada una muestra $X_1, ..., X_n$ iid con distribución F:

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^{n} \mathbb{1}_{X_i \leq x}$$

La función de distribución empírica es el análogo muestral de F. Cada punto x recibe una masa de $\frac{1}{n}$ por cada observación menor o igual a x; por la ley de los grandes números, $\hat{F}_n(x) \xrightarrow{P} F(x)$ punto a punto. Pero necesitamos más: necesitamos que esta convergencia sea uniforme sobre todo x simultáneamente, porque las decisiones de un agente dependen de la comparación entre valores en distintos estados, no de la estimación en un solo punto. El teorema de Glivenko–Cantelli establece que esta aproximación es uniformemente consistente — un resultado fundamental para la teoría de bootstrap.

Teorema 4.110 (Glivenko-Cantelli). *Sea $\hat{F}_n$ la distribución empírica de una muestra iid de F. Entonces:*

$$\left\| \hat{F}_n - F \right\|_\infty = \sup_{x \in \mathbb{R}} \left| \hat{F}_n(x) - F(x) \right| \xrightarrow{\text{a.s.}} 0$$

Demostración: resultado clásico; véase van der Vaart (1998).

La convergencia uniforme de la CDF no garantiza consistencia del bootstrap para cualquier funcional. Se necesitan condiciones sobre el estadístico, su escala y la regularidad del mapa que lo define. Extremos muestrales y problemas no regulares proporcionan contraejemplos.

Más allá de la convergencia puntual, necesitamos entender el comportamiento del proceso empírico como objeto aleatorio. Esto requiere extender el CLT a espacios de funciones.

Definición 4.111 (Proceso Empírico). El *proceso empírico* es:

$$\mathbb{G}_n(x) = \sqrt{n}\left(\hat{F}_n(x) - F(x) \right)$$

Cada $\mathbb{G}_n(x)$ es una variable aleatoria (diferencia escalada entre CDF empírica y verdadera en x), pero la colección $\{\mathbb{G}_n(x) : x \in \mathbb{R}\}$ es un proceso estocástico indexado por x. El teorema de Donsker es la extensión funcional del CLT: así como $\sqrt{n}\left(\overline{X}_n - \mu \right)$ converge a una normal, $\mathbb{G}_n$ converge a un proceso Gaussiano.

¿Por qué un puente Browniano? Intuitivamente, $\mathbb{G}_n(x)$ tiene media cero para cada x (porque $\mathbb{E}\left[\hat{F}_n(x) \right] = F(x)$) y su función de covarianza es:

$$\operatorname{Cov}(\mathbb{G}_n(s), \mathbb{G}_n(t)) = F(\min(s,t)) - F(s)F(t)$$

que es exactamente la covarianza de un puente Browniano $\mathbb{B}$ compuesto con F. Además, en los extremos $x = \pm\infty$, $\mathbb{G}_n(-\infty) = \mathbb{G}_n(\infty) = 0$ — el proceso está «anclado» en cero, igual que $\mathbb{B}(0) = \mathbb{B}(1) = 0$. Esta intuición se formaliza en:

Teorema 4.112 (Donsker). *Sea $\{X_i\}$ iid con distribución F. El proceso empírico converge débilmente a un puente Browniano:*

$$\mathbb{G}_n \xrightarrow{d} \mathbb{B} \circ F$$

donde $\mathbb{B}$ es un puente Browniano con $\mathbb{E}[\mathbb{B}(t)] = 0$ y $\operatorname{Cov}(\mathbb{B}(s), \mathbb{B}(t)) = \min(s,t) - st$.

Demostración: resultado clásico; véase van der Vaart (1998).

Donsker nos dice que cualquier funcional continuo del proceso empírico hereda la convergencia débil al correspondiente funcional del puente Browniano. Para un agente, esto significa que estadísticos como el estadístico de Kolmogorov-Smirnov $D_n = \sup_x \left|\hat{F}_n(x) - F_0(x)\right|$ o la norma L_2 de la diferencia entre CDFs tienen distribuciones asintóticas conocidas, lo que permite construir tests de bondad de ajuste y bandas de confianza para la distribución completa de retornos sin asumir ninguna forma paramétrica.

Ejemplo 4.113 (Bandas de Confianza para la CDF vía Donsker). Para una CDF continua y un análisis a tamaño fijo, el teorema de Donsker permite construir una banda de confianza asintótica para F:

1. Del límite de Donsker, $\sup_x |\mathbb{G}_n(x)| \xrightarrow{d} \sup_{t\in[0,1]} |\mathbb{B}(t)|$, cuya distribución es conocida (distribución de Kolmogorov).
2. Para nivel $1-\alpha$, sea c_α el cuantil $1-\alpha$ de $\sup_t |\mathbb{B}(t)|$. Entonces:

$$\mathbb{P}\left(F(x) \in \left[\hat{F}_n(x) \pm \frac{c_\alpha}{\sqrt{n}} \right] \quad \forall x \right) \to 1 - \alpha$$

3. Para un agente que monitorea la distribución de retornos de una política desplegada, esta banda permite detectar cambios en la distribución (p.ej., deriva del entorno) sin asumir normalidad: si la CDF histórica F_0 sale de la banda alrededor de $\hat{F}_n$, hay evidencia contra la referencia fija. Si la referencia también se estima o se monitorea repetidamente, deben incorporarse ambas fuentes de incertidumbre o un control secuencial.

Ejemplo 4.114 (No paramétrico: distribución y suavizado). Para los retornos sintéticos $(0, 1, 2, 3, 4)$, $\hat{F}_5(2) = \frac{3}{5}$. Esta CDF se calcula sin fijar una familia de densidades. Si se quiere estimar una densidad, el kernel uniforme da

$$\hat{f}_h(x) = \frac{1}{2nh} \sum_i \mathbb{1}_{|X_i - x| \le h}.$$

En $x = 2$, con $h = 0.6$ resulta $\frac{1}{6} \approx 0.1667$; con $h = 1.1$, resulta $\frac{3}{11} \approx 0.2727$. El ancho de banda cambia qué observaciones contribuyen y el suavizado.

En un punto interior, para densidad suficientemente suave y un kernel simétrico de segundo orden, el sesgo es de orden h^2 y la varianza de orden $\frac{1}{nh}$. Equilibrarlos motiva h de orden $n^{-\frac{1}{5}}$ y error típico de orden $n^{-\frac{2}{5}}$ en una dimensión. Son órdenes bajo hipótesis explícitas, no garantías para estos cinco datos. Para inferir sobre $f(x)$, el sesgo puede ser comparable al error estándar y debe corregirse o reducirse mediante otra elección de h; una banda para la CDF no es un intervalo para la densidad.

La aproximación analítica puede resultar difícil cuando el estimador combina varios pasos. El remuestreo intenta reproducir su fluctuación a partir de los datos; para que lo consiga, el esquema de remuestreo debe conservar la estructura que determina esa fluctuación.

4.4.4 El Bootstrap

Definición 4.115 (Bootstrap No Paramétrico). Dada una muestra $X_1, ..., X_n$:

1. Generar muestra bootstrap $X_1^*, ..., X_n^*$ muestreando uniformemente con reemplazo de $\{X_1, ..., X_n\}$
2. Calcular $T_n^* = T(X_1^*, ..., X_n^*)$
3. Repetir B veces para obtener $T_n^{*(1)}, ..., T_n^{*(B)}$
4. Usar la distribución empírica de $\left\{T_n^{*(b)}\right\}$ como aproximación

Para estadísticos regulares, $\hat{F}_n$ es el análogo no paramétrico de F que, por Glivenko-Cantelli, converge uniformemente a F. Remuestrear de $\hat{F}_n$ produce réplicas del estadístico cuya distribución condicional aproxima la distribución muestral verdadera. El siguiente resultado formaliza esta intuición para la media, confirmando que la distribución bootstrap converge a la misma normal que el estimador original.

Teorema 4.116 (Consistencia del Bootstrap para la Media). *Sea $X_1, ..., X_n$ iid con $\mathbb{E}[X_i] = \mu$ y $\mathrm{Var}(X_i) = \sigma^2 < \infty$. Sea $\overline{X}_n^*$ la media bootstrap. Condicionalmente en la muestra original:*

$$\sqrt{n}\left(\overline{X}_n^* - \overline{X}_n\right) \xrightarrow{d} N(0, \sigma^2) \quad \text{en probabilidad}$$

Sketch de demostración. Condicionalmente en $X_1, ..., X_n$, las observaciones bootstrap X_i^* son iid con distribución $\hat{F}_n$. La media condicional es $\overline{X}_n$ y la varianza condicional es $\hat{\sigma}_n^2 \to \sigma^2$ por la LGN. Aplicando el CLT para el arreglo triangular condicional, verificando además Lindeberg, se obtiene el resultado. La distribución empírica cambia con n, por lo que no basta invocar el CLT iid de una ley fija. (argumento y alcance en Apéndice A, pág. 226) □

Definición 4.117 (IC Bootstrap Percentil). El IC percentil de nivel $1 - \alpha$ es:

$$IC_{\text{perc}} = \left[\hat{\theta}_n^{*(\frac{\alpha}{2})}, \hat{\theta}_n^{*(1-\frac{\alpha}{2})}\right]$$

donde $\hat{\theta}_n^{*(q)}$ denota el cuantil q de la distribución bootstrap.

Los cuantiles percentiles pueden ser asimétricos, pero no corrigen automáticamente el sesgo ni la distorsión de escala. La studentización aproxima la distribución de un pivote y puede mejorar la cobertura bajo condiciones adicionales de momentos, suavidad y expansión asintótica.

Ejemplo 4.118 (IC Bootstrap Percentil-t). Sea $t_n^* = \frac{\hat{\theta}_n^* - \hat{\theta}_n}{\widehat{SE}^*\left(\hat{\theta}_n^*\right)}$. El IC es:

$$IC_{\text{perc-t}} = \left[\hat{\theta}_n - t_n^{*(1-\frac{\alpha}{2})} \cdot \widehat{SE},\ \hat{\theta}_n - t_n^{*(\frac{\alpha}{2})} \cdot \widehat{SE}\right]$$

Nota 4.119 (Alcance de los refinamientos de cobertura). Para modelos y estadísticos que admiten expansiones de Edgeworth válidas y una studentización regular, el bootstrap-t puede ofrecer refinamientos de orden superior respecto de aproximaciones de primer orden; véase (Hall, 1992). Esos órdenes dependen del procedimiento y de si se estudia una cola o cobertura bilateral. Una afirmación $O(n^{-1})$ no equivale a un error numérico $\frac{1}{n}$ ni proporciona una cota a $n = 100$ sin constantes. La validez no se extiende a extremos, fronteras o datos dependientes remuestreados como iid.

Ejemplo 4.120 (Bootstrap que respeta el muestreo). Si hay pacientes independientes con varias visitas, remuestrear pacientes completos preserva la estructura interna de cada unidad. Para una sola serie estacionaria se pueden remuestrear bloques consecutivos bajo condiciones específicas de

mezcla y longitud de bloque; típicamente se exige que esta crezca mientras su proporción respecto de n tienda a cero. Esas relaciones por sí solas no cubren todos los estadísticos. Véase (Künsch, 1989).

Un contraejemplo iid muestra otro límite: para $X_i \sim \text{Uniforme}(0, \theta)$, el máximo bootstrap nunca supera al máximo observado y lo iguala con probabilidad $1 - \left(1 - \frac{1}{n}\right)^n$, que tiende a $1 - e^{-1}$. La distribución límite continua del error escalado del máximo no tiene ese átomo. Por tanto el bootstrap ordinario del máximo no reproduce su distribución límite.

4.4.5 Asintótica para Funciones de Valor

Proposición 4.121 (CLT para Retornos Monte Carlo). *Sea $\{G_i\}_{i=1}^n$ una muestra iid de retornos bajo política π, con el mismo estado inicial fijo s_0. Si $\mathbb{E}[G^2] < \infty$, entonces:*

$$\sqrt{n}\left(\frac{1}{n}\sum_{i=1}^{n} G_i - V^\pi(s_0)\right) \xrightarrow{d} N(0, \text{Var}(G))$$

Esta proposición justifica el procedimiento más básico de evaluación de políticas: ejecutar n trayectorias independientes, promediar sus retornos, y reportar un IC basado en la aproximación normal. Es el fundamento estadístico de la evaluación Monte Carlo que usamos en el Capítulo 7.

La proposición anterior garantiza normalidad para estimadores directos de V^π. Pero en la práctica, un agente frecuentemente estima Q^π (por pares estado-acción) y luego agrega para obtener V^π. El siguiente resultado propaga la incertidumbre desde las estimaciones de Q hasta el valor agregado, usando exactamente el Delta Method multivariado.

Proposición 4.122 (Delta Method para Funciones de Q). *Para una política fija, suponga convergencia conjunta*

$$\sqrt{n}\big(\hat{\boldsymbol{Q}}_n(s) - \boldsymbol{Q}^\pi(s)\big) \xrightarrow{d} N\big(0, \Sigma_Q\big).$$

Con el vector $p_s = (\pi(a|s))_a$ y $\hat{V}_n(s) = p_s^\top \hat{\boldsymbol{Q}}_n(s)$,

$$\sqrt{n}\big(\hat{V}_n(s) - V^\pi(s)\big) \xrightarrow{d} N\big(0, p_s^\top \Sigma_Q p_s\big).$$

CLT marginales separados no bastan para afirmar este resultado. Si la política se aprende con los mismos datos, el objetivo y la expansión deben revisarse.

La varianza asintótica de $\hat{V}_n(s)$ contiene dos tipos de términos: (i) varianzas puras $\pi(a|s)^2 \sigma_Q^2(s,a)$, que reflejan la incertidumbre en cada estimación de Q ponderada por la probabilidad de la acción al cuadrado; y (ii) covarianzas $2\pi(a|s)\pi(a'|s)\,\text{Cov}\big(\hat{Q}(s,a), \hat{Q}(s,a')\big)$, que capturan el hecho de que los estimadores de Q para distintas acciones en el mismo estado están correlacionados — comparten las mismas trayectorias. Ignorar estos términos (como haría un IC ingenuo) subestima o sobrestima la incertidumbre total según el signo de las correlaciones. Este fenómeno es análogo al del Ejemplo 4.108 y será central en los estimadores que combinan múltiples fuentes de información en el Capítulo 7.

Ejemplo 4.123 (Propagación de Varianza: MDP de 3 estados y 2 acciones). Considere un MDP con $\mathcal{S} = \{s_1, s_2, s_3\}$ y $\mathcal{A} = \{a_1, a_2\}$. Para el estado s_1, la política es $\pi(a_1|s_1) = 0.6$, $\pi(a_2|s_1) = 0.4$. Se estiman $\hat{Q}_n(s_1, a_1)$ y $\hat{Q}_n(s_1, a_2)$ usando $n = 50$ trayectorias compartidas, con matriz de covarianza asintótica:

$$\boldsymbol{\Sigma}_Q = \begin{pmatrix} 4.0 & 1.2 \\ 1.2 & 9.0 \end{pmatrix}$$

Esta es la covarianza del límite escalado por $\sqrt{n}$; la covarianza aproximada del estimador es $\frac{\Sigma_Q}{n}$. La varianza asintótica de $\hat{V}_n(s_1) = 0.6\hat{Q}_n(s_1, a_1) + 0.4\hat{Q}_n(s_1, a_2)$ es:

$$\sigma_V^2 = (0.6)^2(4.0) + (0.4)^2(9.0) + 2(0.6)(0.4)(1.2) = 1.44 + 1.44 + 0.576 = 3.456$$

con $\sigma_V \approx 1.86$. El IC 95% asintótico es:

$$\hat{V}_n(s_1) \pm 1.96 \times \frac{1.86}{\sqrt{50}} = \hat{V}_n(s_1) \pm 0.516$$

Nótese que si se ignorara la covarianza (1.2), la varianza sería 2.88 y el ancho del IC se subestimaría en un 9%, llevando a decisiones potencialmente sobre-confiadas del agente.

Estimar un objetivo con modelos auxiliares complejos

En la evaluación de políticas puede interesar un valor escalar, aunque la ley de los datos contenga funciones difíciles de estimar. La teoría semiparamétrica permite estudiar la precisión del objetivo sin reducir todos esos componentes a un vector paramétrico fijo.

4.5.1 Modelos semiparamétricos

La pregunta de interés puede ser pequeña aunque la distribución de los datos sea compleja. Para evaluar una política interesa un escalar, pero puede ser necesario estimar regresiones, mecanismos de asignación y distribuciones de estados. La teoría semiparamétrica distingue la dificultad de estimar esos componentes de la dificultad del objetivo final.

Definición 4.124 (Modelo y objetivo semiparamétricos). Un modelo semiparamétrico puede escribirse $\mathcal{P} = \{P_{\theta,\eta} : \theta \in \Theta \subseteq \mathbb{R}^d, \eta \in \mathcal{H}\}$, con d fijo y η infinito-dimensional. Más generalmente, se define un funcional $\psi(P)$ finito-dimensional sobre una clase infinita de leyes. La existencia de una parametrización global por componentes independientes no se supone. El término *nuisance* designa componentes auxiliares respecto del objetivo, no variables irrelevantes.

Usaremos O para una unidad observacional, P_0 para su ley verdadera, $\psi_0 = \psi(P_0)$ para el objetivo y η para las funciones auxiliares. En un problema causal, la identificación de ψ a partir de la distribución observada se justifica antes de estudiar su estimación. Las funciones de influencia que siguen se refieren al funcional identificado.

Ejemplo 4.125 (Regresión parcialmente lineal). Sea $Y = X^\top\beta + g(Z) + \varepsilon$, con $\mathbb{E}[\varepsilon|X, Z] = 0$. Defina $m(Z) = \mathbb{E}[X|Z]$ y $\ell(Z) = \mathbb{E}[Y|Z]$. Entonces

$$Y - \ell(Z) = (X - m(Z))^\top\beta + \varepsilon.$$

Si $M = \mathbb{E}\big[(X - m(Z))(X - m(Z))^\top\big]$ es invertible,

$$\beta = M^{-1}\mathbb{E}[(X - m(Z))(Y - \ell(Z))].$$

Esta identidad motiva residualizar resultado y exposición. La densidad completa incluye también las leyes de covariables y errores: g no es todo el nuisance. Bajo homocedasticidad, la función de influencia eficiente de β es $M^{-1}(X - m(Z))\varepsilon$. La heterocedasticidad cambia la ponderación eficiente. La forma parcialmente lineal impone una restricción; no garantiza una interpretación causal de β.

Ejemplo 4.126 (Modelo de Cox). El modelo $h(t|Z) = h_0(t)\exp(Z^\top\beta)$ combina un vector β y una función basal h_0. Con censura se observa (U, Δ, Z), donde U es el mínimo entre evento y censura. La inferencia requiere condiciones sobre censura, observación y proporcionalidad de

riesgos. La verosimilitud parcial evita estimar directamente h_0 para calcular β, pero no elimina esas condiciones ni el resto del modelo observado.

Ejemplo 4.127 (ATE como funcional de la ley observada). Con $O = (X, A, Y)$, $A \in \{0, 1\}$, defina $e(X) = P(A = 1|X)$ y $m_a(X) = \mathbb{E}[Y|A = a, X]$. Bajo consistencia, intercambiabilidad condicional y positividad,

$$\psi(P) = \mathbb{E}[m_1(X) - m_0(X)] = \mathbb{E}[Y(1) - Y(0)].$$

El objetivo depende también de la distribución de X. Las tres funciones (e, m_0, m_1) no especifican por sí solas toda la densidad observada. El funcional puede estudiarse en un modelo observado no paramétrico usando herramientas semiparamétricas.

Ejemplo 4.128 (Objetivo de OPE). Fije política objetivo, horizonte, descuento y distribución inicial. El objetivo J^π es un escalar, mientras que dinámica y recompensas pueden variar sobre clases funcionales. Si estados y acciones son finitos y fijos y todas las leyes se parametrizan con tablas finitas, el problema es finito-dimensional; llamarlo semiparamétrico requiere alguna parte genuinamente infinita. Un valor $V^\pi(s)$ para todo s continuo es un objetivo funcional, distinto del escalar J^π.

4.5.2 Scores y Espacios Tangentes en el Par (θ, g)

El encabezado conserva la notación habitual (θ, g); en las fórmulas se usa η para el nuisance y ψ para el objetivo. Un submodelo permite estudiar perturbaciones de la distribución sin parametrizar globalmente toda la clase.

Definición 4.129 (Submodelo regular y score). Un camino $t \mapsto P_t$, con $P_{t=0} = P_0$, es diferenciable en media cuadrática si sus densidades satisfacen

$$\int \left(\sqrt{p_t} - \sqrt{p_0} - \frac{t}{2} S \sqrt{p_0}\right)^2 \mathrm{d}\mu = o(t^2),$$

para un $S \in L_0^2(P_0)$, llamado score. En modelos suficientemente suaves coincide con $\partial_t \log p_t|_{t=0}$. La condición $\mathbb{E}_0[S] = 0$ procede de normalización y regularidad; no basta escribir una derivada formal.

Ejemplo 4.130 (Scores de perturbaciones concretas). En la regresión parcialmente lineal con error normal de varianza conocida, perturbar g como $g_t = g + th$ produce $S_g = h(Z)\frac{\varepsilon}{\sigma^2}$. Esa fórmula requiere el submodelo normal especificado.

Para Bernoulli condicional, una perturbación admisible $e_t = e + th$ produce $S_e = h(X)\frac{A - e(X)}{e(X)(1-e(X))}$. Su media condicional dado X es cero.

En supervivencia, perturbar h_0 como $h_{0,t}(u) = h_0(u)\exp(tb(u))$ da, bajo el modelo de intensidad y censura apropiados, el score $\int b(u)\,\mathrm{d}M(u)$, con M el martingala de conteo compensado. No se sustituye la intensidad por una distribución empírica sin justificarlo.

Definición 4.131 (Espacio tangente). $\mathcal{T}$ es la clausura en $L_0^2(P_0)$ del espacio lineal generado por los scores de caminos regulares admisibles. El producto interno es $\langle f, g\rangle = \mathbb{E}_0[fg]$.

Definición 4.132 (Espacio tangente auxiliar). $\mathcal{T}_\eta$ es la clausura del espacio generado por scores de caminos que mantienen el objetivo fijo. Depende del modelo y del funcional; no se identifica con todas las perturbaciones arbitrarias de funciones empleadas por un algoritmo.

Nota 4.133 (Qué se mantiene fijo). En el ATE, cambiar m_1 suele cambiar $\psi = \mathbb{E}[m_1 - m_0]$. Por ello, una perturbación libre de m_1 no es automáticamente una dirección nuisance a objetivo fijo. En la regresión parcialmente lineal, mantener β fijo aún permite variar otras leyes además de g. Estos

ejemplos evitan confundir los componentes de trabajo de un estimador con el espacio tangente auxiliar.

Proposición 4.134 (Descomposición ortogonal correcta). *Como $\mathcal{T}_\eta$ es un subespacio cerrado de $\mathcal{T}$,*

$$\mathcal{T} = \mathcal{T}_\eta \oplus \left(\mathcal{T} \cap \mathcal{T}_\eta^{\perp}\right).$$

Las direcciones que varían un parámetro manteniendo otros fijos no son necesariamente ortogonales antes de proyectarlas. La igualdad anterior es la descomposición de Hilbert respecto de un subespacio cerrado.

4.5.3 Funciones de Influencia

Definición 4.135 (Función de influencia). Una función $\varphi \in L_0^2(P_0)$ representa la derivada del funcional si, para todo camino regular con score S,

$$\frac{\mathrm{d}}{\mathrm{d}t}\psi(P_t)\bigg|_{t=0} = \mathbb{E}_0[\varphi(O)S(O)].$$

El funcional debe ser diferenciable por caminos, con derivada lineal continua en el espacio tangente. Las distintas funciones que representan la misma derivada pueden diferir por un elemento de $\mathcal{T}^{\perp}$.

Proposición 4.136 (Expansión asintóticamente lineal). *Para unidades iid, si un estimador admite*

$$\hat{\psi} - \psi_0 = \frac{1}{n}\sum_i \varphi(O_i) + o_P\left(n^{-\frac{1}{2}}\right),$$

con $\mathbb{E}_0[\varphi] = 0$ y $0 < \mathbb{E}_0[\varphi^2] < \infty$, entonces

$$\sqrt{n}\left(\hat{\psi} - \psi_0\right) \xrightarrow{d} N(0, \mathbb{E}_0[\varphi^2]).$$

Para un estimador regular en el modelo, su función de influencia debe representar las derivadas del objetivo. La existencia de una representación del funcional no demuestra por sí sola esta expansión para un estimador propuesto.

Ejemplo 4.137 (Media y cuantil sin modelo paramétrico). Para la media, $\varphi(y) = y - \psi$ y la expansión de la media muestral es exacta. Para el cuantil q_τ, si la densidad es continua y positiva en él, la función de influencia es

$$\varphi_\tau(y) = \frac{\tau - \mathbb{1}_{y \le q_\tau}}{f(q_\tau)}.$$

La varianza límite es $\frac{\tau(1-\tau)}{f(q_\tau)^2}$. Una densidad pequeña cerca del cuantil amplifica la incertidumbre. Si hay un átomo o densidad cero, esta fórmula y el CLT regular pueden fallar. Así, dos objetivos escalares del mismo modelo no paramétrico pueden exigir condiciones diferentes.

4.5.4 Eficiencia Semiparamétrica

Definición 4.138 (Gradiente canónico). La función de influencia eficiente es la proyección de cualquier representante φ sobre el espacio tangente completo:

$$\varphi_{\text{eff}} = \Pi(\varphi \mid \mathcal{T}).$$

Si se parte de un score paramétrico de interés S_θ, el score eficiente es $S_{\text{eff}} = S_\theta - \Pi\big(S_\theta|\mathcal{T}_\eta\big)$. En una parametrización regular con información eficiente invertible, la IF eficiente es $I_{\text{eff}}^{-1}S_{\text{eff}}$. Proyectar una IF y residualizar un score son operaciones distintas.

Nota 4.139 (Ejemplos de la distinción score–IF). En la normal de media desconocida y varianza conocida, el score es $\frac{Y-\mu}{\sigma^2}$, mientras que la IF de la media es $Y-\mu$: falta la normalización por información si se confunden ambos. En Cox, el score parcial tampoco es por sí solo la IF del estimador. En el ATE, la IF eficiente en el modelo observado no paramétrico es

$$\varphi_{\text{eff}}(O) = m_1(X) - m_0(X) + \frac{A}{e(X)}(Y - m_1(X)) - \frac{1-A}{1-e(X)}(Y - m_0(X)) - \psi_0.$$

Se requieren momentos finitos y control de los denominadores para usarla en inferencia de varianza finita.

Teorema 4.140 (Cota de eficiencia). *Para un estimador regular asintóticamente lineal con IF φ,*

$$\mathbb{E}_0[\varphi^2] \geq \mathbb{E}_0[\varphi_{\text{eff}}^2].$$

La igualdad exige $\varphi = \varphi_{\text{eff}}$ en $L^2(P_0)$.

Demostración. Escriba $\varphi = \varphi_{\text{eff}} + h$ con $h \in \mathcal{T}^\perp$. Pitágoras da $\|\varphi\|^2 = \|\varphi_{\text{eff}}\|^2 + \|h\|^2$. El componente descartado está en el complemento del espacio tangente completo, no en el espacio nuisance. Véase (argumento y alcance en Apéndice A, pág. 228). □

Corolario 4.141 (Varianza de referencia). *La cota por observación es $\sigma_{\text{eff}}^2 = \mathbb{E}_0[\varphi_{\text{eff}}^2]$; un estimador eficiente tiene varianza asintótica $\frac{\sigma_{\text{eff}}^2}{n}$. Alcanzarla requiere construir un estimador con resto despreciable; no se garantiza únicamente escribiendo la IF.*

4.5.5 Ortogonalidad de Neyman

Definición 4.142 (Ortogonalidad de un momento). Sea $M(\psi,\eta) = \mathbb{E}_{P_0}[m(O;\psi,\eta)]$, con $M(\psi_0,\eta_0) = 0$. Hay ortogonalidad de Neyman si

$$\frac{\mathrm{d}}{\mathrm{d}t}\mathbb{E}_{P_0}[m(O;\psi_0,\eta_0 + th)]\Big|_{t=0} = 0$$

para toda dirección admisible h. La distribución de integración permanece fija en P_0; se perturba el argumento auxiliar del momento.

Proposición 4.143 (Ortogonalidad, sesgo y eficiencia). *Si el mapa auxiliar tiene una expansión de segundo orden con resto controlado, la ortogonalidad elimina el término lineal de su error. No garantiza por sí sola eficiencia, doble robustez global ni identificación. Multiplicar un momento ortogonal por una constante no nula conserva sus raíces y la ortogonalidad, pero cambia el momento: por ello no puede caracterizarse como una IF eficiente única sin normalización y condiciones adicionales.*

La ortogonalidad controla perturbaciones locales alrededor de η_0. La doble robustez que sigue es una identidad algebraica más fuerte para un momento particular. Conviene comprobar ambas propiedades por separado.

La ortogonalidad describe cómo cambia un momento al perturbar sus componentes auxiliares. En los estimadores aumentados siguientes, esa relación se hace visible mediante una identidad de sesgo y permite distinguir doble robustez de eficiencia.

4.5.6 Estimadores Doubly Robust

Definición 4.144 (Estimador AIPW y doble robustez). Para funciones candidatas $\overline{e}$ y $\overline{m}_a$, defina el pseudoresultado

$$D(O;\overline{\eta}) = \overline{m}_1(X) - \overline{m}_0(X) + \frac{A}{\overline{e}(X)}(Y - \overline{m}_1(X)) - \frac{1-A}{1-\overline{e}(X)}(Y - \overline{m}_0(X)).$$

AIPW promedia D con funciones ajustadas fuera de cada fold. Su momento centrado es $D - \psi$. La media de una IF centrada estima cero, no ψ.

Teorema 4.145 (Identidad exacta de doble robustez). *Para funciones candidatas fijas y denominadores alejados de cero,*

$$\mathbb{E}_0[D(O;\overline{\eta})] - \psi_0 = \mathbb{E}_0\left[(\overline{e} - e)\left(\frac{\overline{m}_1 - m_1}{\overline{e}} + \frac{\overline{m}_0 - m_0}{1-\overline{e}}\right)\right].$$

La igualdad se obtiene condicionando en X. El lado derecho es cero si $\overline{e} = e$ o si $\overline{m}_0 = m_0$ y $\overline{m}_1 = m_1$. Para funciones estimadas, consistencia exige además una ley de grandes números y control de sus errores; no se afirma insesgadez finita con ajustes reutilizados en la misma muestra.

Demostración. La esperanza del término tratado es $\frac{e}{\overline{e}}(m_1 - \overline{m}_1)$ y la del término no tratado es $\frac{1-e}{1-\overline{e}}(m_0 - \overline{m}_0)$. Sumarlos con $\overline{m}_1 - \overline{m}_0$ y restar $m_1 - m_0$ produce la fórmula. Véase (argumento y alcance en Apéndice A, pág. 227). □

La identidad permite comparar errores sin exigir tasas iguales: si un componente converge rápido, el otro puede hacerlo más despacio. La consistencia cuando un solo modelo es correcto no implica automáticamente un intervalo eficiente calculado como si ambos lo fueran.

4.5.7 IF Eficiente para V^π

Fijamos un experimento para evitar mezclar resultados de una decisión, trayectorias finitas y horizonte infinito. Observamos n trayectorias iid $O = (S_0, A_0, R_0, ..., S_H)$ bajo una política de comportamiento b_t. Dentro de cada trayectoria, el kernel conjunto de recompensa y siguiente estado es Markov y puede variar libremente con t. Las políticas objetivo π_t son fijas y la distribución inicial desconocida es común a comportamiento y objetivo. Hay H decisiones, $0 \leq \gamma \leq 1$ y recompensas acotadas. Se exige cobertura y razones marginales acotadas.

Defina $q_t(s,a) = \mathbb{E}_{\pi\left[\sum_{u=t}^{H-1} \gamma^{u-t} R_u | S_t = s, A_t = a\right]}$, $v_t(s) = \sum_a \pi_t(a|s) q_t(s,a)$, $v_H = 0$ y $J = \mathbb{E}[v_0(S_0)]$. La razón marginal es $w_t(s,a) = d_t^\pi \frac{s,a}{d_t^b}(s,a)$, entre las distribuciones estado–acción de ese tiempo. No es el producto de razones de acciones de una trayectoria.

Teorema 4.146 (Gradiente canónico en el modelo Markov finito). *En el modelo no paramétrico Markov de kernels por tiempo descrito arriba,*

$$\varphi_{\text{eff}}(O) = v_0(S_0) - J + \sum_{t=0}^{H-1} \gamma^t w_t(S_t, A_t)[R_t + \gamma v_{t+1}(S_{t+1}) - q_t(S_t, A_t)].$$

Es la forma de diferencias de Bellman del gradiente para OPE Markov de horizonte finito; véase (Kallus & Uehara, 2020). Si se conoce la ley inicial y se integra respecto de ella, se elimina el componente $v_0(S_0) - J$ asociado a estimarla. Las restricciones de homogeneidad temporal o un horizonte infinito definen otros modelos y pueden cambiar el gradiente eficiente.

Cada residuo tiene esperanza condicional cero con las funciones verdaderas, pero no es cero observación por observación. El término inicial integra el valor con la población objetivo. Los pesos corrigen la distribución de estados y acciones; en modelos con memoria, las razones acumuladas y el estado de historia corresponden a otro espacio tangente. La versión estacionaria de horizonte infinito de (Kallus & Uehara, 2022) no se obtiene simplemente extendiendo esta suma sin revisar normalización, muestreo y regularidad.

Corolario 4.147 (Estimador aumentado para OPE). *Con ajustes externos al fold de evaluación y $\hat{v}_t = \sum_a \pi_t(a|s)\hat{q}_t(s,a)$, use para cada observación i suprima el índice de entrenamiento $-k(i)$ en la siguiente notación abreviada:*

$$\hat{\varepsilon}_{i,t} = R_{i,t} + \gamma \hat{v}_{t+1}(S_{i,t+1}) - \hat{q}_t(S_{i,t}, A_{i,t}),$$

$$\hat{D}_i = \hat{v}_0(S_{i,0}) + \sum_{t=0}^{H-1} \gamma^t \hat{w}_t(S_{i,t}, A_{i,t})\hat{\varepsilon}_{i,t},$$

$$\hat{J} = \frac{1}{n}\sum_i \hat{D}_i.$$

La identidad poblacional es correcta si todas las funciones q_t son correctas o si todas las razones w_t lo son. Bajo convergencia e integrabilidad apropiadas, esto da consistencia. Para eficiencia y un CLT se necesitan controles adicionales de productos de errores. La prueba de centrado y cancelación está en (argumento y alcance en Apéndice A, pág. 227).

Ejemplo 4.148 (OPE de una decisión: cálculo completo). En un contexto fijo, hay dos acciones. La política observada es $b = (0.6, 0.4)$ y la objetivo $\pi = (0.3, 0.7)$. Tres registros sintéticos son $(A, R) = (1, 5), (2, 8), (1, 3)$; las predicciones fijadas antes de evaluar son $\hat{q} = (4, 7)$. La predicción bajo la política objetivo es $\hat{v} = 0.3(4) + 0.7(7) = 6.1$ para los tres registros.

Registro	Peso	Residuo ponderado	Pseudoresultado
1	0.5	$0.5(5-4) = 0.5$	6.6
2	1.75	$1.75(8-7) = 1.75$	7.85
3	0.5	$0.5(3-4) = -0.5$	5.6

Por tanto $\hat{J} = \frac{6.6+7.85+5.6}{3} = \frac{401}{60} \approx 6.6833$. El estimador directo es 6.1 y el de importancia simple es $\frac{0.5(5)+1.75(8)+0.5(3)}{3} = 6$. Sus diferencias son muestrales: tres registros no verifican consistencia ni eficiencia. Sustituir $\hat{v}$ por $\hat{q}(A_i)$ en el término directo cambia la política que se promedia y destruye la identidad de doble robustez.

4.5.8 Debiased Machine Learning

Definición 4.149 (DML mediante momentos ortogonales). DML combina momentos ortogonales con ajustes auxiliares separados de las observaciones donde se evalúan. En general resuelve $n^{-1}\sum_i m\big(O_i; \hat{\psi}, \hat{\eta}_{-k(i)}\big) = 0$. Para el ATE, el momento es $D - \psi$ y la solución es la media de los pseudoresultados D. El trabajo de (Chernozhukov et al., 2018) establece condiciones generales; aquí se explicita un caso suficiente.

Dividir las unidades iid en un número fijo $K \geq 2$ de folds de proporciones positivas. Ajustar e, m_0, m_1 fuera de cada fold; calcular D_i dentro de él; promediar todos los D_i. Estimar $\hat{\sigma}^2 = n^{-1}\sum_i \left(D_i - \hat{\psi}\right)^2$ y, cuando se cumplen las condiciones siguientes, usar $\hat{\psi} \pm z_{1-\frac{\alpha}{2}}\frac{\hat{\sigma}}{\sqrt{n}}$.

Teorema 4.150 (Un caso suficiente para AIPW con cross-fitting). *Suponga unidades iid, $|Y| \leq C$, propensión verdadera y ajustada en $[c, 1-c]$ para un $c > 0$, ajustes de resultados uniformemente acotados, K fijo y folds de tamaño proporcional a n. En cada fold, suponga convergencia $L^2(P_X)$ de las tres funciones y*

$$\|\hat{e} - e\|_2\big(\|\hat{m}_1 - m_1\|_2 + \|\hat{m}_0 - m_0\|_2\big) = o_P\big(n^{-\frac{1}{2}}\big).$$

Si $\sigma^2_{\text{eff}} = \mathbb{E}_0[\varphi^2_{\text{eff}}] > 0$, entonces

$$\sqrt{n}\big(\hat{\psi} - \psi_0\big) = \frac{1}{\sqrt{n}} \sum_i \varphi_{\text{eff}(O_i)} + o_P(1) \xrightarrow{d} N\big(0, \sigma^2_{\text{eff}}\big).$$

La varianza empírica de los pseudoresultados centrados es consistente. Véase (argumento y alcance en Apéndice A, pág. 227). Estas hipótesis son suficientes, no necesarias; resultados con desenlaces no acotados requieren condiciones de momentos adicionales.

La ortogonalidad controla el sesgo poblacional; el cross-fitting controla un término empírico que reutilizar los datos puede hacer difícil de acotar. Estimadores sin cross-fitting también pueden ser válidos bajo condiciones de complejidad adecuadas. Separar folds no vuelve independientes los pseudoresultados entre sí ni resuelve la dependencia temporal de las unidades originales.

4.5.9 Condiciones para Validez de Cross-Fitting

Definición 4.151 (Tasas de producto). En el teorema anterior importa el producto de errores. Que cada componente sea $o_P\big(n^{-\frac{1}{4}}\big)$ es una condición suficiente. Tasas $O_P(n^{-0.3})$ y $O_P(n^{-0.25})$ también dan un producto $o_P\big(n^{-\frac{1}{2}}\big)$. Dos tasas meramente $O_P\big(n^{-\frac{1}{4}}\big)$ solo aseguran $O_P\big(n^{-\frac{1}{2}}\big)$, que puede dejar un sesgo en el límite. No hay una tasa individual necesaria de un cuarto para todos los modelos.

Proposición 4.152 (Unidad de partición). *La independencia usada en la prueba corresponde a la unidad O_i. Con pacientes independientes y visitas repetidas, se particiona por paciente. Con episodios independientes, por episodio. Dividir aleatoriamente transiciones de una misma trayectoria no satisface la prueba iid. Una única serie requiere un argumento específico de dependencia, separación temporal y, cuando proceda, bloques con huecos.*

Nota 4.153 (Diagnósticos y límites de verificación). Curvas de aprendizaje, residuos y pérdidas fuera de muestra ayudan a detectar problemas, pero no certifican una tasa $o_P\big(n^{-\frac{1}{4}}\big)$ con una muestra finita. La pérdida predictiva incluye ruido irreducible y no es automáticamente el error L^2 respecto de una función desconocida. No existen umbrales universales de R^2 que validen DML. Una simulación con verdad conocida puede estudiar tasas y cobertura bajo su mecanismo declarado; no demuestra esas propiedades para la población real.

Comprobación	Qué aporta	Qué no establece
Propensiones y pesos	Detecta solapamiento empírico débil	Positividad poblacional garantizada
Pérdida fuera de muestra	Compara ajustes en datos separados	Tasa asintótica del nuisance
Identificadores de folds	Detecta fuga entre unidades	Independencia de una serie
Simulación repetida	Cobertura bajo un modelo conocido	Validez causal en datos reales

Tabla 4.4: Diagnósticos y alcance

4.5.10 Inferencia Causal: DAGs y Criterio Backdoor

La inferencia estadística de un funcional observado y su interpretación causal son preguntas distintas. Las propiedades de AIPW no pueden corregir una identificación causal equivocada.

Definición 4.154 (DAG causal). Un DAG es un grafo dirigido acíclico. Su interpretación causal requiere un modelo de intervenciones, por ejemplo ecuaciones estructurales con supuestos sobre las perturbaciones exógenas. La factorización observacional o la condición de Markov por sí solas no determinan los efectos de intervenir.

Definición 4.155 (Criterio backdoor). En un DAG causal apropiado, Z satisface el criterio si no contiene descendientes del tratamiento A y bloquea todos los caminos entre A e Y que empiezan con una flecha hacia A. Con consistencia y positividad, el criterio permite identificar

$$\mathbb{E}[Y(a)] = \int \mathbb{E}[Y|A=a, Z=z]\,\mathrm{d}P_Z(z).$$

Proposición 4.156 (Ajuste gráfico y resultados potenciales). *En un modelo causal estructural compatible, el criterio backdoor es una condición gráfica suficiente para el ajuste. En resultados potenciales, consistencia, $Y(a) \perp A|Z$ y positividad permiten derivar la misma fórmula por esperanza iterada. No se afirma el recíproco: una independencia distribucional puede ocurrir por restricciones particulares aunque el criterio gráfico falle. Los supuestos causales no se verifican únicamente con la distribución observada.*

Demostración. Por intercambiabilidad, $\mathbb{E}[Y(a)|Z] = \mathbb{E}[Y(a)|A=a, Z]$. Por consistencia, el último término es $\mathbb{E}[Y|A=a, Z]$. Integrar respecto de Z da la fórmula. El criterio gráfico justifica el ajuste dentro de un modelo causal; véanse (Pearl, 2009) y (Hernán & Robins, 2020). □

Ejemplo 4.157 *(sintético)* **(SSCH: confusión y estandarización).** Considere dos estratos previos $Z = 0, 1$, cada uno con probabilidad $\frac{1}{2}$. El resultado es un puntaje adverso, de modo que menos es mejor. Las propensiones son $e(0) = 0.2$, $e(1) = 0.8$; las medias sin intervención son $m_0 = (10, 20)$ y con intervención $m_1 = (8, 16)$.

En el DAG supuesto aparecen $Z \to A$, $Z \to Y$ y $A \to Y$. Si Z basta para ajuste, el efecto es $\psi = \frac{8-10}{2} + \frac{16-20}{2} = -3$. Entre tratados, las proporciones de estratos son $(0.2, 0.8)$, de modo que $\mathbb{E}[Y|A=1] = 14.4$. Entre no tratados son $(0.8, 0.2)$, de modo que $\mathbb{E}[Y|A=0] = 12$. La diferencia cruda es $+2.4$: tiene signo opuesto al efecto ajustado.

Este cálculo es poblacional bajo un mecanismo sintético completo para las medias y asignación. No se presenta un intervalo de confianza sin especificar tamaño muestral y variabilidad del resultado. El contraste ilustra por qué un buen predictor y una asociación observada no bastan para identificar una decisión causal.

Causalidad y Sensibilidad

Un confusor no medido que afecte asignación y resultado puede invalidar la interpretación causal aunque los modelos observados se ajusten correctamente. El análisis de sensibilidad cuantifica cómo cambiaría la conclusión bajo desviaciones especificadas; no detecta ni descarta toda confusión oculta. Una variable instrumental define otro análisis y exige supuestos propios. Para decisiones longitudinales se requiere identificación secuencial y control de positividad en las historias pertinentes.

El recorrido del capítulo puede resumirse así: definir el objetivo y la ley observada; justificar identificación; elegir la clase de modelos; derivar una expansión y controlar su resto; estimar la varianza según la unidad de muestreo. La representación del Capítulo 5 preserva un objetivo de decisión bajo condiciones explícitas, pero no sustituye ninguno de esos pasos inferenciales.

El recorrido ha pasado de conservar información a controlar el error de un objetivo estimado. Estas herramientas se utilizarán después con una pregunta adicional: qué se mantiene cuando una regla se representa como política y los datos proceden de un proceso secuencial. El Capítulo 5 empieza por fijar esa representación; cada uso inferencial conservará las condiciones desarrolladas aquí.

Ejercicios

Ejercicio 4.1. *Implemente una actualización secuencial Normal-Gamma para la media de una sola secuencia iid, según Ejemplo 4.27. Fije prior propio $(\mu_0, \lambda, \alpha, \beta) = (0, 1, 2, 1)$ y semilla 20261027. La siguiente regla es ilustrativa, no una solución óptima de parada ni un test secuencial de nivel controlado.*

1. *Diseñe un `StateSchema` que almacene los hiperparámetros $(\mu_0, \lambda, \alpha, \beta)$.*
2. *Implemente el nodo `actualizar` que recibe una observación x (recompensa continua) y actualiza el estado según las fórmulas del ejemplo.*
3. *Implemente el nodo `decidir` que:*
   - *Calcula la media posterior $\hat{\mu}$ y varianza $\mathrm{Var}(\mu|x)$*
   - *Decide `detener` si $\hat{\mu} > 0.5$ y $\mathrm{Var}(\mu|x) < 0.1$*
   - *Decide `continuar` en caso contrario, hasta un máximo de 100 observaciones*
4. *Simule 100 observaciones de $N(0.6, 0.2^2)$ y trace la evolución de $\hat{\mu}$ y $\mathrm{Var}(\mu|x)$.*

Ejercicio 4.2. *Demuestre que la distribución Gamma(α, β) con densidad*

$$f(x|\alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, \quad x > 0$$

pertenece a una familia exponencial de rango 2 cuando tanto α como β son desconocidos. Identifique el parámetro natural $\eta = (\eta_1, \eta_2)$, el estadístico natural $T(x) = (T_1(x), T_2(x))$, y la función log-partición $A(\eta)$.

Ejercicio 4.3. *Para la familia Normal(μ, σ^2) con ambos parámetros desconocidos:*

1. *Escriba la densidad en forma exponencial canónica, identificando η, $T(x)$, $h(x)$ y $A(\eta)$.*
2. *Verifique que $\nabla A(\eta) = \mathbb{E}_\eta[T(X)]$ calculando explícitamente ambos lados.*
3. *Calcule la matriz de covarianzas $\mathrm{Cov}_\eta(T(X))$ usando el Corolario 4.19 y verifique el resultado directamente.*

Ejercicio 4.4. *Sea $X_1, \ldots, X_n \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$ con σ^2 conocida. Considere los siguientes estimadores de μ:*

1. *$\hat{\mu}_1 = \overline{X}$ (media muestral)*
2. *$\hat{\mu}_2 = X_1$ (primera observación)*
3. *$\hat{\mu}_3 = c\overline{X}$ para $c \in (0, 1)$ fijo (estimador contraído)*

Para cada estimador, calcule el sesgo, la varianza y el ECM. ¿Cuál es óptimo bajo pérdida cuadrática? ¿Depende la respuesta del valor verdadero de μ?

Ejercicio 4.5. *Considere un agente que observa secuencialmente datos $X_1, X_2, \ldots$ de una distribución Poisson(λ) desconocida y debe estimar λ en cada paso.*

1. *¿Cuál es el estadístico suficiente para λ basado en $X_1, \ldots, X_n$?*
2. *Diseñe un `StateSchema` minimal que permita al agente actualizar su estimación de λ de forma incremental sin almacenar todas las observaciones pasadas.*
3. *Si el agente usa un prior Gamma(α_0, β_0) para λ, ¿cómo debe modificarse el estado para mantener el posterior actualizado?*

Ejercicio 4.6. *Sea $\mathcal{D} = (\Theta, (P_\theta), \mathcal{A}, \mathcal{X}, L)$ un problema de decisión con $\Theta = \{0, 1\}$, $\mathcal{A} = \{0, 1\}$, y pérdida 0-1: $L(\theta, a) = \mathbb{1}(\theta \neq a)$.*

1. *Escriba la función de riesgo $R(\theta, \delta)$ para una regla de decisión general δ.*
2. *Fije $P_0(X = 1) = 0.2$ y $P_1(X = 1) = 0.8$. Represente la observación como estado inicial y la pérdida negativa como recompensa evaluativa indexada por θ.*
3. *Verifique $J_\theta(\pi_\delta) = -R(\theta, \delta)$ y promedie con prior $\nu(\theta = 1) = p$. Explique por qué el estado inicial no revela el parámetro desconocido.*

Ejercicio 4.7. *Compare el modelo Beta-Binomial (Ejemplo 4.25) y Normal-Gamma (Ejemplo 4.27):*

1. *Identifique las similitudes y diferencias en la estructura de sus estados internos.*
2. *Analice la complejidad computacional de la actualización en cada caso.*

Propiedad intelectual UFHEC

3. *Discuta en qué escenarios prácticos sería preferible cada modelo:*
   - *Bernoulli-Beta: CTR en anuncios, conversiones binarias*
   - *Normal-Gamma: Recompensas continuas (ventas, tiempo de sesión)*
4. *Proponga un criterio de decisión híbrido para un agente que maneje tanto conversiones binarias como recompensas continuas.*

Ejercicio 4.8. *Sea* $X_1, ..., X_n \overset{\text{iid}}{\sim} \text{Uniforme}(0, \theta)$ *con* $\theta > 0$ *desconocido.*

1. *Escriba la densidad conjunta* $f(\boldsymbol{x}|\theta)$.
2. *Use el Teorema de Neyman-Fisher para mostrar que* $T(\boldsymbol{x}) = X_{(n)} = \max\{X_1, ..., X_n\}$ *es suficiente para* θ.
3. *¿Es* $\left(\sum X_i, X_{(n)}\right)$ *también suficiente? ¿Por qué esto no contradice la minimalidad de* $X_{(n)}$*?*

Ejercicio 4.9. *Para la familia de Cauchy* $f(x|\theta) = \frac{1}{\pi(1+(x-\theta)^2)}$, $\theta \in \mathbb{R}$*:*

1. *Muestre que esta familia NO es exponencial.*
2. *Use el criterio de Lehmann-Scheffé para argumentar que el vector de estadísticos de orden* $\left(X_{(1)}, ..., X_{(n)}\right)$ *es suficiente minimal.*
3. *¿Qué implicaciones tiene esto para el diseño del estado de un agente que modela observaciones Cauchy?*

Ejercicio 4.10. *Sea* $X_1, ..., X_n \overset{\text{iid}}{\sim} \text{Exponencial}(\lambda)$ *con* $\lambda > 0$.

1. *Muestre que* $T = \sum_{i=1}^{n} X_i$ *es suficiente completo para* λ.
2. *Muestre que* $A = \left(\frac{X_1}{T}, \frac{X_2}{T}, ..., \frac{X_{n-1}}{T}\right)$ *es ancilar (el vector completo de* n *proporciones tiene distribución Dirichlet*$(1, ..., 1)$*, y su subvector tampoco depende de* λ*).*
3. *Use el Teorema de Basu para concluir que* T *y* A *son independientes sin hacer cálculos directos.*
4. *¿Cómo se traduce esta independencia al diseño de un agente que estima tasas de eventos?*

Ejercicio 4.11. *Considere el modelo de localización-escala:* $X_1, ..., X_n \overset{\text{iid}}{\sim} \frac{1}{\sigma} f\left(\frac{x-\mu}{\sigma}\right)$ *con* $(\mu, \sigma) \in \mathbb{R} \times \mathbb{R}^+$.

1. *Identifique el grupo de transformaciones afines bajo el cual el modelo es invariante.*
2. *Muestre que* $\left(\overline{X}, S\right)$ *es un estimador equivariante de* (μ, σ).
3. *Si la pérdida es* $L((\mu, \sigma), (a, b)) = \frac{(\mu-a)^2}{\sigma^2} + \frac{(\sigma-b)^2}{\sigma^2}$*, ¿es invariante bajo el grupo? ¿Qué implica esto para el riesgo de estimadores equivariantes?*

Ejercicio 4.12. *Un agente observa secuencialmente tiempos entre eventos* $X_1, X_2, ... \overset{\text{iid}}{\sim} \text{Gamma}(\alpha, \beta)$ *donde* α *es conocido pero* β *es desconocido.*

1. *Identifique el estadístico suficiente minimal para* β *basado en* n *observaciones.*
2. *Diseñe un* `StateSchema` *que permita actualización incremental del estado cuando llega* X_{n+1}.
3. *Si el agente usa un prior* $\text{Gamma}(a_0, b_0)$ *para* β*, ¿cómo se extiende el estado para mantener el posterior?*
4. *Calcule la complejidad espacial y temporal de su diseño.*

Ejercicio 4.13. *Sea* $X_1, ..., X_n \overset{\text{iid}}{\sim} \text{Poisson}(\lambda)$*. Considere el estimador inicial* $\hat{\lambda} = X_1$.

1. *Muestre que* $\hat{\lambda}$ *es insesgado para* λ.
2. *Identifique el estadístico suficiente* T *para* λ.
3. *Calcule* $\tilde{\lambda} = \mathbb{E}[X_1 \mid T]$ *y verifique que* $\tilde{\lambda} = \overline{X}$.
4. *Compare* $\text{Var}\left(\hat{\lambda}\right)$ *con* $\text{Var}\left(\tilde{\lambda}\right)$.

Ejercicio 4.14. *Sea* $X_1, ..., X_n \overset{\text{iid}}{\sim} \text{Exponencial}(\theta)$ *con* $f(x|\theta) = \theta e^{-\theta x}$, $x > 0$.

1. *Muestre que* $T = \sum_{i=1}^{n} X_i$ *es suficiente completo.*
2. *Para* $n > 2$*, encuentre el UMVUE de* θ *y compruebe que tiene varianza finita.*
3. *Encuentre el UMVUE de* $1/\theta$ *(la media de la distribución).*
4. *Calcule la información de Fisher y verifique que el UMVUE de* $1/\theta$ *alcanza la cota de Cramér-Rao.*

Ejercicio 4.15. *Para la familia* $\text{Uniforme}(0, \theta)$*:*

1. *Calcule el score formal dentro del soporte y compruebe que su esperanza no es cero.*
2. *Explique por qué no se puede aplicar la cota regular de Cramér–Rao.*
3. *Muestre que* $\hat{\theta} = \frac{n+1}{n} X_{(n)}$ *es insesgado.*
4. *Calcule* $\mathrm{Var}\left(\hat{\theta}\right)$ *y compare con la cota de Cramér-Rao. ¿Qué paso de la prueba regular falla?*

Ejercicio 4.16. *Sea* $X_1, \ldots, X_n \overset{\text{iid}}{\sim} \mathrm{Gamma}(\alpha, \beta)$ *con* α *conocido y* β *desconocido.*

1. *Derive el MLE* $\hat{\beta}_{\mathrm{MLE}}$.
2. *Calcule la información de Fisher* $I_1(\beta)$.
3. *Establezca la distribución asintótica de* $\hat{\beta}_{\mathrm{MLE}}$.
4. *¿Es* $\hat{\beta}_{\mathrm{MLE}}$ *el UMVUE?*

Ejercicio 4.17. *Un agente observa retornos* $G_1, \ldots, G_n \overset{\text{iid}}{\sim} N(V^\pi, \sigma^2)$ *con* σ^2 *conocida.*

1. *Muestre que* $\hat{V}^\pi = \overline{G}$ *es el UMVUE de* V^π.
2. *Derive la cota de Cramér-Rao y verifique que* $\overline{G}$ *la alcanza.*
3. *Si el agente quiere* $\mathrm{Var}\left(\hat{V}^\pi\right) \leq 0.01$ *y* $\sigma^2 = 4$, *¿cuántas trayectorias necesita?*
4. *Diseñe un test de nivel* $\alpha = 0.05$ *para* $H_0 : V^\pi \leq 0$ *vs* $H_1 : V^\pi > 0$.

Ejercicio 4.18. *Sea* $X \sim \mathrm{Exponencial}(\lambda)$. *Para* $H_0 : \lambda = 1$ *vs* $H_1 : \lambda = 2$*:*

1. *Derive el cociente de verosimilitudes* $\Lambda(x)$.
2. *Muestre que el test MP rechaza para* $X < c$.
3. *Encuentre* c *para nivel* $\alpha = 0.05$.
4. *Calcule el poder del test.*

Ejercicio 4.19. *Sea* $X_1, \ldots, X_n \overset{\text{iid}}{\sim} \mathrm{Poisson}(\lambda)$.

1. *Muestre que la familia tiene MLR en* $T = \sum X_i$.
2. *Derive el test UMP de nivel* α *para* $H_0 : \lambda \leq \lambda_0$ *vs* $H_1 : \lambda > \lambda_0$.
3. *¿Existe un test UMP para* $H_0 : \lambda = \lambda_0$ *vs* $H_1 : \lambda \neq \lambda_0$*? Justifique.*

Ejercicio 4.20. *Para* $X_1, \ldots, X_n \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$ *con* σ^2 *desconocida:*

1. *Derive el test t de nivel* α *para* $H_0 : \mu = \mu_0$.
2. *Use inversión de tests para derivar el IC* $1 - \alpha$ *para* μ.
3. *Verifique que este es el IC t clásico.*

Ejercicio 4.21. *Un agente compara 10 políticas contra una base. Los p-valores son: 0.001, 0.01, 0.02, 0.03, 0.04, 0.06, 0.08, 0.12, 0.25, 0.50.*

1. *Aplique Bonferroni con* $\alpha = 0.05$. *¿Cuáles rechaza?*
2. *Aplique Holm. ¿Cuáles rechaza?*
3. *Aplique Benjamini-Hochberg. ¿Cuáles rechaza?*
4. *Compare los resultados e interprete para el agente.*

Ejercicio 4.22. *Un agente quiere detectar una diferencia* $\Delta V = 0.5$ *entre políticas, con* $\sigma = 2$, *nivel bilateral* $\alpha = 0.05$ *y poder* $1 - \beta = 0.80$, *con grupos independientes de igual tamaño y varianza conocida.*

1. *Calcule el tamaño de efecto* $\delta = \Delta V / \sigma$.
2. *Calcule el tamaño de muestra necesario por grupo.*
3. *Si solo puede recolectar* $n = 50$ *trayectorias por política, ¿cuál es el poder real?*
4. *¿Qué* ΔV *mínimo puede detectar con* $n = 50$ *y poder 0.80?*

Ejercicio 4.23. *Sea* $X_1, \ldots, X_n \overset{\text{iid}}{\sim} \mathrm{Poisson}(\lambda)$. *Considere* $g(\lambda) = \sqrt{\lambda}$.

1. *Use el CLT para establecer la distribución asintótica de* $\overline{X}_n$.
2. *Aplique el Delta Method para derivar la distribución asintótica de* $\sqrt{\overline{X}_n}$.
3. *Construya un IC asintótico de nivel 95% para* $\sqrt{\lambda}$.

Ejercicio 4.24. *Sea* $X_1, \ldots, X_n$ *una muestra de distribución desconocida.*

1. *Describa el procedimiento bootstrap para estimar la varianza de la mediana muestral.*

Universidad Curivil

2. *¿Por qué el bootstrap es particularmente útil para la mediana (vs. la media)?*
3. *Diseñe una simulación para verificar cobertura del IC bootstrap percentil.*

Ejercicio 4.25. *Un agente estima V^π con retornos $G_i \overset{\text{iid}}{\sim} N(V^\pi, \sigma^2)$.*
1. *Describa un protocolo de simulación para verificar cobertura del IC bootstrap.*
2. *Si la cobertura empírica es 0.87 para un IC nominal 0.95, ¿qué diagnóstico sugiere?*
3. *Proponga una corrección y explique cuándo sería apropiada.*

Ejercicio 4.26. *Un agente estima $Q^\pi(s,a)$ para K pares estado-acción. Cada estimador tiene varianza asintótica $\frac{\sigma^2}{n}$.*
1. *Si $V^\pi(s) = \frac{1}{K}\sum_a Q^\pi(s,a)$, derive la varianza asintótica de $\hat{V}^\pi(s)$.*
2. *Use el Delta Method si el agente calcula $\exp(V^\pi(s))$.*
3. *¿Cómo afectan las correlaciones entre estimadores de Q?*

Ejercicio 4.27. *Un agente tiene 100 trayectorias bajo π_0 y 100 bajo π_1.*
1. *Diseñe un procedimiento bootstrap para IC de $V^{\pi_1} - V^{\pi_0}$.*
2. *¿Cómo manejaría pares de trayectorias que comparten la misma aleatorización o unidad? Un estado inicial fijo común no crea dependencia por sí solo.*
3. *Proponga un test de permutación y especifique la hipótesis de intercambio o el mecanismo de aleatorización que lo hace válido.*

Ejercicio 4.28. *Compare estimar una media, una CDF, una densidad puntual y el valor de una política. Para cada objetivo, declare un modelo, unidad de muestreo, estimador y condición de regularidad. Explique por qué «no paramétrico» no equivale a «sin supuestos».*

Ejercicio 4.29. *En el ejemplo causal de dos estratos, use $\overline{e} = (0.4, 0.6)$, $\overline{m}_0 = (11, 19)$ y $\overline{m}_1 = (9, 15)$. Calcule el sesgo con la identidad DR. Repita con propensión correcta y luego con ambas regresiones correctas. Compruebe qué propiedad es poblacional y qué haría falta para construir un intervalo muestral.*

Ejercicio 4.30. *Derive la varianza de largo plazo del AR(1) y compare $\rho = 0$, 0.6 y -0.4. Diseñe una simulación de cobertura con réplicas independientes y reporte el error Monte Carlo de la cobertura estimada. No confunda repetir una simulación con aumentar la longitud de una sola trayectoria.*

Ejercicio 4.31. *Utilizando los datos del ejemplo anterior y priors $\text{Beta}(1,1)$:*
1. *Calcule el factor de Bayes BF_{10} para $H_1 : p_A > p_B$ vs. $H_0 : p_A \leq p_B$.*
2. *Si la pérdida por error Tipo I (adoptar un tratamiento inferior) es 5 veces la del error Tipo II (no detectar uno superior), ¿rechazaría H_0?*
3. *Compare su decisión con la que obtendría usando un test frecuentista de una cola con $\alpha = 0.05$.*

Lecturas Propuestas

Lecturas Obligatorias

1. Casella & Berger (2002) y Lehmann & Casella (1998): suficiencia, completitud y estimación puntual. Usar el segundo para revisar el alcance de los resultados de invariancia.
2. Lehmann & Romano (2005): tests óptimos, aleatorización e inversión de tests.
3. van der Vaart (1998): estimación regular, método delta, procesos empíricos y bootstrap. El método delta se desarrolla en el capítulo 3, no en el 2.
4. Bickel et al. (1993) y Tsiatis (2006): espacios tangentes, gradiente canónico y cotas de eficiencia.

Lecturas Complementarias

1. Kennedy (2017) y Kennedy (2022): introducciones a funciones de influencia y estimación de funcionales.
2. Chernozhukov et al. (2018): momentos ortogonales, cross-fitting y condiciones sobre los restos.

3. Kallus & Uehara (2020) y Kallus & Uehara (2022): distinguir los modelos finitos por tiempo de los modelos estacionarios de horizonte infinito antes de trasladar una IF.
4. Efron & Tibshirani (1993), Hall (1992) y Künsch (1989): remuestreo, refinamientos y dependencia.
5. Bradley (2005) y Newey & West (1987): condiciones de mezcla y estimación de varianza con autocorrelación.
6. Hernán & Robins (2020) y Pearl (2009): identificación causal y límites del ajuste observado.

Dr. Jaime Lincovil Curivil

Parte II

La correspondencia y sus fronteras

Con los dos marcos definidos, podemos preguntar qué se conserva al representar una regla como política. La construcción de un paso precisa esa relación. Sus límites muestran qué información y qué resultados adicionales hacen falta al ampliar el problema.

Dr. Jaime Luna Curiel

Capítulo 5

Representación Wald → MDP: enunciado, demostración y alcance

Un agente recibe información y elige una acción cuyas consecuencias dependen de un entorno desconocido. La teoría de decisión describe esa elección mediante una pérdida y su riesgo esperado. Los MDP describen acciones, recompensas y transiciones. Para conectar ambos lenguajes debemos conservar la información disponible para decidir y el criterio con el que se comparan las decisiones.

Este capítulo construye una representación exacta de un problema estadístico como una **familia de MDP de una decisión**, indexada por el parámetro desconocido. La identidad central relaciona el riesgo con el retorno esperado desde la distribución inicial. El parámetro no se convierte en una observación y la política no puede utilizarlo. La transición posterior a la acción conduce a un estado terminal; la observación inicial puede ser aleatoria.

La construcción permite traducir Bayes, minimax y admisibilidad dentro de una misma clase de reglas. Su alcance es una representación que preserva el riesgo. No se afirma una equivalencia de categorías ni se utiliza una composición de reglas de decisión. Después se demuestra una extensión concreta: un problema bayesiano de observación y parada, con horizonte finito, admite programación dinámica sobre el posterior. Esta extensión requiere un modelo de observaciones y un prior explícitos.

Construir la representación y precisar su alcance

5.1.1 Recapitulación de los Dos Marcos

Definición 5.1 (Problema estadístico de decisión). Sean Θ un conjunto finito no vacío, $\mathcal{X}$ un espacio finito o numerable y $\mathcal{A}$ un conjunto finito no vacío. Un problema está especificado por

$$\mathcal{D} = \Big(\Theta, \mathcal{X}, (P_\theta)_{\theta\in\Theta}, \mathcal{A}, L\Big),$$

donde P_θ es la distribución de X y $L : \Theta \times \mathcal{A} \to \mathbb{R}$ es acotada. Una regla determinista es una función $\delta : \mathcal{X} \to \mathcal{A}$ elegida sin conocer θ. Su riesgo es

$$R(\theta, \delta) = \sum_{x\in\mathcal{X}} P_{\theta(x)} L(\theta, \delta(x)).$$

Denotamos por $\mathcal{D}_0$ la clase de todas estas reglas. Las comparaciones se harán siempre dentro de esta clase, salvo indicación expresa.

La familia (P_θ) forma parte del problema: indica qué puede aprenderse de la observación. El riesgo es una función de θ que evalúa una regla completa. No se exige que una sola regla minimice el riesgo simultáneamente para todos los parámetros.

Definición 5.2 (MDP de una decisión con estado terminal). Se observa un estado inicial S_0 en $\mathcal{X}$, se elige una acción A_0 en $\mathcal{A}$ y se recibe una única recompensa. Después el proceso llega a un estado terminal s_{fin}, de recompensa cero. Una política determinista es una función $\pi : \mathcal{X} \to \mathcal{A}$; su extensión al estado terminal es irrelevante y se fija por convenio. Para un modelo indexado por θ, distinguimos

$$V_\theta^{\pi(x)} = r_{\theta(x,\pi(x))}, \quad J_{\theta(\pi)} = \sum_x P_{\theta(x)} V_\theta^{\pi(x)}.$$

El primer objeto condiciona en el estado inicial; el segundo promedia sobre su distribución. Un descuento igual a uno es admisible porque solo hay una recompensa y el horizonte es finito.

5.1.2 Representación fundamental de un paso

Teorema 5.3 (Representación que preserva el riesgo). *Para el problema de Definición 5.1, construya, para cada θ, un MDP $\mathcal{M}_\theta$ con distribución inicial P_θ, recompensa*

$$r_{\theta(x,a)} = -L(\theta, a)$$

y transición determinista desde cualquier (x, a) al estado terminal. La correspondencia $F(\delta) = \pi_\delta$, definida por $\pi_{\delta(x)} = \delta(x)$, es una biyección entre reglas deterministas y políticas deterministas en los estados de decisión de esta familia. Para todo θ y toda regla,

$$J_{\theta(\pi_\delta)} = -R(\theta, \delta).$$

Una única política se utiliza en todos los modelos. La biyección se refiere a funciones puntuales; dos reglas distintas pueden tener el mismo riesgo, por ejemplo si difieren únicamente en observaciones de probabilidad cero bajo todos los modelos.

Demostración. La regla y la política tienen el mismo dominio y codominio; copiarlas en cualquiera de los dos sentidos define aplicaciones inversas. Por la definición de recompensa,

$$J_{\theta(\pi_\delta)} = \sum_x P_{\theta(x)}[-L(\theta, \delta(x))] = -R(\theta, \delta).$$

La acotación de la pérdida asegura convergencia absoluta de las sumas. La transición terminal garantiza que no existen recompensas futuras que alteren la igualdad. La demostración y sus consecuencias se detallan en Sección A.9.1. □

Nota 5.4 (Alcance de la construcción). El estado inicial es observable, pero el índice θ es desconocido. La familia sirve para evaluar una política común; no entrega al agente el verdadero modelo. La representación tampoco supone que la recompensa evaluativa pueda observarse después de actuar: una pérdida estadística puede depender de una verdad que continúa desconocida. Por ello no constituye, por sí sola, un protocolo de aprendizaje por refuerzo con recompensas registradas.

La transición al estado terminal es determinista. Esa propiedad no hace determinista el muestreo de X. La identidad demostrada usa J_θ, no el valor condicionado $V_\theta^{\pi(x)}$. No establece que un MDP general sea equivalente a un problema estadístico de una decisión.

Documento Oficial

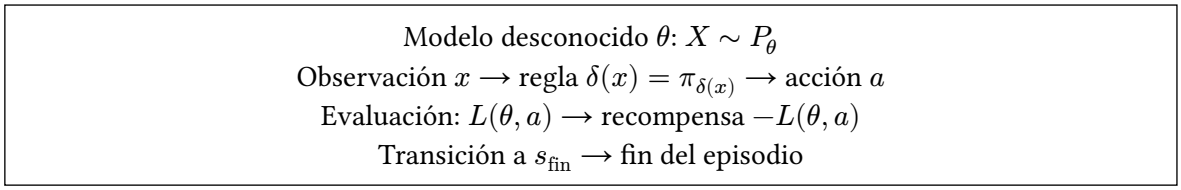


Figura 5.1: Representación de una decisión. El parámetro indexa el modelo y la evaluación; la regla utiliza únicamente la observación.

5.1.3 Extensión al Caso Secuencial

Considere ahora un parámetro fijo desconocido, un prior b_0 sobre Θ y observaciones en un conjunto finito $\mathcal{Y}$. Condicionalmente en θ, las observaciones sucesivas son independientes con probabilidades conocidas $q_{\theta(y)}$. En cada instante se puede decidir una acción terminal o pagar un costo conocido $c \geq 0$ para observar de nuevo. Se permiten como máximo T observaciones y al llegar al horizonte se debe decidir.

Sea b el posterior actual. Defina

$$m_{b(y)} = \sum_{\theta \in \Theta} b(\theta) q_{\theta(y)}, \quad B(b, y)(\theta) = \frac{b(\theta) q_{\theta(y)}}{m_{b(y)}}.$$

La actualización se usa cuando $m_{b(y)} > 0$; para observaciones de probabilidad predictiva cero se asigna un posterior arbitrario, sin efecto sobre las esperanzas. La pérdida esperada de decidir a es

$$\ell(b, a) = \sum_{\theta} b(\theta) L(\theta, a).$$

Teorema 5.5 (Programación dinámica bayesiana de observación y parada). *Bajo el modelo finito anterior existe una estrategia bayesiana óptima que depende del historial solo mediante el número k de observaciones restantes y el posterior b. Su riesgo restante mínimo satisface*

$$W_0(b) = \min_{a \in \mathcal{A}} \ell(b, a),$$

y, para $k \geq 1$,

$$W_{k(b)} = \min \left\{ \min_{a \in \mathcal{A}} \ell(b, a), c + \sum_{y \in \mathcal{Y}} m_{b(y)} W_{k-1}(B(b, y)) \right\}.$$

La estrategia elige la alternativa que alcanza el mínimo. Los empates pueden resolverse mediante una regla fija. La demostración por inducción está en Sección A.9.3.

El estado de decisión es (k, b). Observar produce una transición aleatoria determinada por m_b; decidir conduce al estado terminal. La actualización del posterior es determinista **dada la observación**, pero el proceso de creencias es generalmente estocástico. El resultado pertenece al enfoque bayesiano de estados de información y no implica optimalidad frecuentista uniforme en θ.

Corolario 5.6 (Bellman para el retorno bayesiano). *Defina $U_{k(b)} = -W_{k(b)}$. Entonces*

$$U_0(b) = \max_a [-\ell(b, a)],$$

$$U_{k(b)} = \max \left\{ \max_a [-\ell(b, a)], -c + \sum_y m_{b(y)} U_{k-1}(B(b, y)) \right\}.$$

La recompensa al observar es $-c$ y la recompensa terminal esperada es $-\ell(b, a)$. La igualdad se obtiene cambiando el signo en la recursión anterior. El estado oculto θ permanece fijo; la actualización afecta la distribución de creencias sobre él.

5.1.4 Transferencia de Resultados de Inferencia

La igualdad entre objetivos no proporciona automáticamente un estimador ni una distribución muestral. Para obtener intervalos, tests o eficiencia se deben definir los datos disponibles, el parámetro objetivo, el estimador y las condiciones del resultado inferencial invocado. Las propuestas de transferencia se examinan en Capítulo 6; la evaluación de políticas y sus intervalos se desarrollan en Capítulo 7 y Capítulo 8.

El índice θ de la teoría de decisión puede representar un vector o un mecanismo probabilístico. El teorema principal se ha formulado aquí para conjuntos finitos y observaciones numerables. En espacios medibles más generales, la identidad de esperanzas sigue siendo válida cuando reglas y pérdidas son medibles y las integrales existen; la existencia de óptimos requiere análisis adicional.

Régimen	Objeto inferencial	Trabajo adicional
Paramétrico	Parámetros finitos de un modelo especificado	Identificación, especificación y regularidad del estimador
Semiparamétrico	Objetivo con componentes nuisance funcionales	Función de influencia, resto de la expansión y tasas de nuisance
No paramétrico	Funciones o distribuciones en una clase de dimensión infinita	Complejidad, regularización y control de aproximación

Tabla 5.1: Preguntas inferenciales que la representación de riesgo deja abiertas. La dimensión del objetivo y la del modelo son conceptos distintos.

5.1.5 Preservación de Propiedades de Optimalidad

Teorema 5.7 (Admisibilidad y no dominancia). *Una regla δ es admisible en $\mathcal{D}_0$ si y solo si no existe una política π' de la clase correspondiente tal que*

$$J_{\theta(\pi')} \geq J_{\theta(\pi_\delta)} \quad \text{para todo } \theta,$$

con desigualdad estricta para algún θ. El orden compara el vector de retornos indexado por los modelos, no por estados iniciales observados. La conclusión se sigue de cambiar el signo en la definición de dominancia; (argumento y alcance en Apéndice A, pág. 234).

Corolario 5.8 (Criterio de Bayes). *Para un prior ν sobre Θ, sean*

$$\rho_{\nu(\delta)} = \sum_\theta \nu(\theta) R(\theta, \delta), \quad J_{\nu(\pi)} = \sum_\theta \nu(\theta) J_{\theta(\pi)}.$$

Entonces $J_{\nu(\pi_\delta)} = -\rho_{\nu(\delta)}$. La correspondencia identifica los conjuntos de minimizadores del riesgo de Bayes con los de maximizadores de J_ν. La distribución conjunta usada es $\nu(\theta) P_{\theta(x)}$; en general no se puede reemplazar por una recompensa promediada sin condicionar en x. Véase Sección A.9.2.

Con datos x, la regla bayesiana minimiza la pérdida posterior. No se necesita que el prior tenga soporte completo para esta identidad. La admisibilidad de una regla de Bayes es una cuestión adicional; no se deduce aquí para cualquier prior y cualquier situación.

5.1.6 StateSchema como Estadístico Suficiente

Nota 5.9 (Tres requisitos distintos para el estado). Una estructura de datos tipada especifica qué se almacena. La suficiencia estadística se refiere a la información sobre un parámetro contenida en una muestra. Un estado de información para control debe permitir calcular las distribuciones futuras y los costos relevantes. La propiedad de Markov se refiere a una ley de transición condicional. Ninguna de estas propiedades se obtiene únicamente al declarar un `StateSchema`.

En Teorema 5.5, el posterior y el horizonte restante constituyen un estado de información bajo el modelo establecido. Si el costo o las observaciones dependen de una variable histórica adicional, esa variable también debe almacenarse o justificarse su eliminación.

Ejemplo 5.10 (Memoria suficiente para observaciones normales). Sean $Y_1, \ldots, Y_n$ independientes con distribución normal de media μ y varianza conocida $\sigma^2 > 0$, con tamaño n fijo. La factorización de la verosimilitud muestra que $\sum_i Y_i$ es suficiente para μ. Para actualizar una media a medida que llegan datos puede almacenarse:

```
estado = {"n": 0, "suma": 0.0}
def actualizar(estado, y):
    return {"n": estado["n"] + 1, "suma": estado["suma"] + y}
```

El contador es información de diseño para la actualización. Si media y varianza son desconocidas, la pareja $\left(\sum_i Y_i, \sum_i Y_i^2\right)$ es suficiente para el modelo normal con n fijo; se debe almacenar también la suma de cuadrados. Este ejemplo no convierte una trayectoria clínica dependiente en una muestra normal independiente.

5.1.7 Síntesis de la representación Wald → MDP

Nota 5.11 (Identidad que debe conservarse). La identidad exacta es $R(\theta, \delta) = -J_{\theta(\pi_\delta)}$, con J_θ promediado sobre P_θ. Se mantiene el mismo parámetro, la misma información y la misma clase de decisiones en ambos lados. La recompensa depende del modelo desconocido y la política solo utiliza la observación.

Corolario 5.12 (Traducción del criterio minimax). *Además de las correspondencias de Bayes y admisibilidad,*

$$\inf_{\delta \in \mathcal{D}_0} \sup_{\theta \in \Theta} R(\theta, \delta) = -\sup_{\pi} \inf_{\theta \in \Theta} J_{\theta(\pi)}.$$

Si existen óptimos, las reglas minimax corresponden a políticas maximin de la familia. No se intercambia el orden de optimización con el del parámetro. Admitir reglas aleatorizadas exige ampliar ambos lados a la misma clase; un óptimo determinista puede dejar de ser óptimo en la clase ampliada.

Nota 5.13 (Alcance secuencial demostrado). El resultado secuencial de este capítulo es Teorema 5.5: observaciones condicionalmente independientes, espacios finitos, prior especificado, costo conocido y horizonte finito. La generalización a observaciones controladas o a estados ocultos dinámicos exige definir el kernel correspondiente y el filtro bayesiano. Este capítulo no afirma un teorema general sobre todos los agentes adaptativos.

Leer las correspondencias a partir de sus condiciones

Objeto	Correspondencia	Respaldo y alcance
θ	Índice desconocido de la familia	Teorema 5.3
$X \sim P_\theta$	Estado inicial y su distribución	Una decisión observable
$\delta(x)$	$\pi_{\delta(x)}$	Biyección entre funciones
$L(\theta, a)$	$-r_{\theta(x,a)}$	Recompensa evaluativa
$R(\theta, \delta)$	$-J_{\theta(\pi_\delta)}$	Identidad de objetivos
Bayes	Retorno promedio máximo bajo el prior	Corolario 5.8
Minimax	Retorno mínimo sobre modelos, maximizado	Corolario 5.12
Admisibilidad	No dominancia sobre modelos	Teorema 5.7
Posterior y horizonte	Estado de información	Teorema 5.5; modelo finito
Suficiencia, ancillaridad	Sin equivalencia general con estado mínimo o contexto descartable	Requieren análisis propio
Cobertura y eficiencia	Propiedades de estimadores especificados	Requieren resultados inferenciales adicionales

Tabla 5.2: Correspondencias exactas y límites. Las filas inferenciales no son consecuencias automáticas de la identidad entre riesgo y retorno.

De la representación a una decisión concreta

La identidad de objetivos puede orientar la organización de un agente si se distingue qué información recibe cada paso. El ejemplo de seguimiento permite cerrar el recorrido con una regla y una comparación de riesgos que pueden calcularse explícitamente.

5.3.1 Arquitectura Trazable

El nodo de observación produce los datos disponibles. El nodo de estado almacena la información cuya adecuación se ha justificado para el modelo. El nodo de inferencia estima los objetos desconocidos; el nodo de decisión utiliza una regla explícita. Cada paso tiene una responsabilidad verificable. La identidad de objetivos no certifica por sí sola la arquitectura completa.

5.3.2 Garantías y condiciones

La cobertura pertenece a un intervalo, un objetivo y un régimen muestral concretos. El control de error requiere especificar las hipótesis, la selección y la regla de parada. La eficiencia exige un modelo y una cota de referencia. La consistencia de un estimador no basta para probar convergencia a una decisión única: pueden existir empates o regiones donde las acciones sean casi equivalentes.

Trazabilidad: Del Teorema al Componente

Resultado	Componente	Conclusión disponible
Teorema 5.3	Evaluación de reglas	Retorno igual a riesgo negativo
Corolario 5.8	Selección bajo prior	Óptimos del mismo criterio promedio
Teorema 5.7	Comparación de políticas	No dominancia en la clase fijada
Teorema 5.5	Estado posterior y parada	Optimalidad bayesiana en el modelo finito
Resultado inferencial adicional	Intervalo o test	Solo la garantía y condiciones de ese resultado

Tabla 5.3: Trazabilidad de la representación y del problema bayesiano de parada.

Hilo longitudinal: SSCH

Ejemplo 5.14 *(sintético)* **(SSCH: decidir a partir de una señal).** Este ejemplo aislado ilustra una decisión de seguimiento. No utiliza datos clínicos ni representa una recomendación terapéutica. El estado desconocido $\theta \in \{0, 1\}$ indica si existe necesidad de seguimiento intensificado. La señal $X \in \{0, 1\}$ satisface $P_0(X = 1) = 0.2$ y $P_1(X = 1) = 0.8$. Las acciones son seguimiento ordinario ($a = 0$) e intensificado ($a = 1$). Las pérdidas ilustrativas son

$$L(0,0) = 0, \quad L(0,1) = 1, \quad L(1,0) = 4, \quad L(1,1) = 0.$$

Regla	$R(0, \delta)$	$R(1, \delta)$	Riesgo de Bayes
Siempre $a = 0$	0	4	1.20
Siempre $a = 1$	1	0	0.70
$a = X$	0.20	0.80	0.38
$a = 1 - X$	0.80	3.20	1.52

El prior usado en la última columna es $\nu(1) = 0.3$. Por ejemplo, el riesgo de seguir la señal es $0.7 \times 0.2 + 0.3 \times 0.8 = 0.38$. En la familia de MDP correspondiente, sus retornos son $J_0 = -0.2$ y $J_1 = -0.8$. Son retornos promedio sobre señales, no valores condicionados en una señal particular.

Si $p = P(\theta = 1|X)$, las pérdidas posteriores de las acciones son $4p$ y $1 - p$. Se intensifica cuando $p > \frac{1}{5}$. Para $X = 1$, el posterior es $\frac{12}{19}$; para $X = 0$, es $\frac{3}{31}$. Por tanto, la regla de Bayes sigue la señal. La tabla enumera todas las reglas deterministas y confirma esa elección.

Antes de observar, decidir inmediatamente tiene riesgo mínimo 0.7. Si se permite obtener una señal con costo 0.05, el riesgo total es $0.05 + 0.38 = 0.43$: conviene observar en este diseño. El beneficio proviene de información que puede cambiar la acción. Esta comparación aplica la recursión bayesiana con una observación disponible; no demuestra optimalidad de una política clínica longitudinal.

La representación deja así una identidad precisa y una extensión bayesiana delimitada. Al modificar la memoria, el horizonte o el mecanismo de datos aparecen preguntas nuevas. El Capítulo 6 examina esos cambios para reconocer qué parte del argumento necesita otra justificación.

Ejercicios

Ejercicio 5.1. *Para $X \sim \text{Bernoulli}(\theta)$ con $\theta \in \{0.2, 0.8\}$, acciones $\{0, 1\}$ y pérdida cuadrática, construya la familia de una decisión. Calcule los riesgos de las cuatro reglas deterministas y verifique la identidad con sus retornos. Compare Bayes bajo prior uniforme y minimax dentro de esa clase.*

Ejercicio 5.2. *Formule Rao–Blackwell para una pérdida convexa y un estadístico suficiente, indicando las condiciones de integrabilidad y del espacio de acciones. Explique por qué la media condicional de una acción puede no pertenecer a un conjunto de acciones discretas. Determine qué cambia al permitir aleatorización.*

Ejercicio 5.3. *Para una muestra independiente de tamaño fijo de una distribución exponencial de tasa desconocida, factorice la verosimilitud y proponga una memoria suficiente. Distinga esta propiedad de una afirmación sobre transiciones de un proceso controlado.*

Ejercicio 5.4. *Demuestre Teorema 5.7 escribiendo los cuantificadores de dominancia. Explique por qué el orden se toma sobre θ. Analice si la conclusión cambia al ampliar simultáneamente las clases a decisiones aleatorizadas.*

Ejercicio 5.5. *En el ejemplo SSCH de este capítulo, calcule el posterior para ambas señales y la regla de Bayes. Permita una única observación adicional con costo $c = 0.05$ y aplique Teorema 5.5 desde el prior indicado. Determine si conviene observar o decidir inmediatamente.*

Lecturas Propuestas

La teoría de riesgo y los criterios de decisión se desarrollan en Berger (1985) y Ferguson (1967). La programación dinámica y la formulación de MDP se estudian en Puterman (2005). La representación de este capítulo debe leerse junto con las hipótesis específicas de cada resultado de esas obras.

Como apoyo abierto, las notas de Will Fithian sobre teoría de decisión estadística precisan modelo, pérdida y riesgo; las notas de Russ Tedrake sobre planificación bajo incertidumbre explican los estados de creencia. Estas referencias sirven de orientación; las demostraciones de los enunciados particulares usados aquí están incluidas en el apéndice.

Universidad de Curicó

Capítulo 6

Lo que no se transfiere

Una identidad entre riesgo y retorno permite trasladar un criterio de comparación, pero no produce nuevos datos ni justifica por sí sola un intervalo de confianza. La representación del Capítulo 5 conserva $J_\theta(\pi_\delta) = -R(\theta, \delta)$ en una familia de MDP de un paso. El parámetro sigue siendo desconocido y la regla no puede consultarlo. Este capítulo estudia qué cambia al pasar a decisiones repetidas, estados resumidos y evaluación con datos de otra política.

El hilo conductor es SSCH: observar señales, elegir una acción y evaluar sus consecuencias. Los ejemplos numéricos son sintéticos; las recompensas no constituyen recomendaciones clínicas. Cada ejemplo distingue el objeto que deja de estar justificado —representación, identificación, estimación o decisión— y la información adicional que permitiría continuar.

Qué cambia al ampliar el problema

6.1.1 Límites del Isomorfismo: Contraejemplos

Un supuesto fuera del alcance de un teorema no es un contraejemplo a ese teorema. Los casos siguientes delimitan extensiones posibles y exhiben fallos de afirmaciones más amplias. En particular, ni los estados continuos ni las variables latentes contradicen la teoría de decisión de Wald.

Ejemplo 6.1 (Espacio de Estados Infinito). Considérese $S_{t+1} = S_t + A_t + \epsilon_t$, con acciones en $\{-1, 1\}$, innovaciones independientes $N(0, 1)$ y recompensa $-S_t^2$. El estado continuo queda fuera de la construcción discreta demostrada en el Capítulo 5, pero no impide definir un MDP medible.

De hecho, para $S_0 = s$ y cualquier política no anticipativa,

$$\mathbb{E}[S_t^2] \leq 3s^2 + 3t^2 + 3t.$$

Basta escribir $S_t = s + \sum_{j<t} A_j + \sum_{j<t} \epsilon_j$ y usar $(x + y + z)^2 \leq 3(x^2 + y^2 + z^2)$. Por ello, si $0 < \gamma < 1$, $\sum_{t\geq 0} \gamma^t \mathbb{E}[S_t^2] < \infty$. En este ejemplo el retorno esperado existe pese a la recompensa no acotada. La existencia de una política óptima y la validez de un algoritmo requieren argumentos adicionales; no se deducen de esta cota.

Un fallo auténtico de integrabilidad aparece si, en una sola decisión, S_0 tiene distribución Cauchy y la pérdida es S_0^2: su esperanza es infinita. El problema es la cola de la distribución, no que el espacio de estados sea continuo. En SSCH, discretizar una medición tampoco elimina automáticamente el error de modelo o la información perdida.

Ejemplo 6.2 (Observabilidad Parcial). Sea un estado oculto fijo $Z \in \{0, 1\}$ con probabilidad inicial $\frac{1}{2}$. En cada visita se observa una señal independiente condicionalmente en Z, con $\mathbb{P}(O_t = Z|Z) = 0.8$. Tras las historias $(0, 1)$ y $(1, 1)$, que comparten la última observación, las probabilidades posteriores son

$$\mathbb{P}(Z = 1|0, 1) = \frac{1}{2}, \quad \mathbb{P}(Z = 1|1, 1) = \frac{16}{17}.$$

La primera razón de verosimilitudes es $\frac{4}{4} = 1$ y la segunda $4^2 = 16$. Una decisión con umbral posterior 0.7 toma acciones distintas en esas historias. El último dato no resume la información pertinente.

Wald observa $X \sim P_\theta$, no necesariamente θ. El fallo consiste aquí en identificar el estado informativo con la última señal. Con modelo y prior especificados, el posterior $b_t = \mathbb{P}(Z = 1|H_t)$ conserva la información para este problema. Para un estado latente finito, la creencia pertenece a un simplex de dimensión finita; el posterior puede ser infinito-dimensional en modelos más generales.

Ejemplo 6.3 (Horizonte Infinito sin Ergodicidad). Dos estados son absorbentes bajo todas las acciones; sus recompensas por paso son respectivamente uno y cero. Desde el primero, con $\gamma = 1$, el retorno total es $\sum_{t\geq 0} 1 = \infty$. Con $\gamma = 0.99$, vale 100. La ergodicidad no es necesaria para este retorno descontado finito.

Un horizonte de veinte años con un número finito de decisiones y recompensas acotadas tampoco produce divergencia por usar $\gamma = 1$. Si se desea el rendimiento medio por paso, este vale uno o cero según el estado inicial: es otro objetivo, con otra ecuación de evaluación. Antes de trasladar una garantía debe fijarse cuál de estos tres funcionales —total finito, total descontado o promedio— se estudia.

Ejemplo 6.4 (Confounding No Observado). Sea U Bernoulli con parámetro $\frac{1}{2}$. La acción registrada es $A = U$. Compare dos modelos de resultados potenciales: en M1, $Y(0) = Y(1) = U$; en M2, $Y(a) = a$. En ambos se observa exactamente $\mathbb{P}(A = Y = 0) = \mathbb{P}(A = Y = 1) = \frac{1}{2}$. Sin embargo, intervenir fijando $A = 1$ da

$$\mathbb{E}[Y(1)] = \begin{cases} \frac{1}{2} \text{ en M1} \\ 1 \text{ en M2} \end{cases}.$$

Hay solapamiento marginal de las acciones, pero la misma ley observada admite valores distintos de la intervención. Ningún estimador basado solo en esos registros distingue ambos modelos.

Agregar una covariable independiente de (U, A, Y) tampoco distingue ambos modelos. En SSCH, añadir columnas al registro no sustituye un argumento de identificación. Aleatorización, medición pertinente o restricciones estructurales justificadas pueden cambiar el problema; DM, IS y DR no eliminan por su nombre esta ambigüedad.

Situación	Objeto afectado	Conclusión precisa
Estado continuo	Alcance del resultado discreto	Requiere una extensión medible; no implica imposibilidad.
Señal parcial	Estado informativo	La última observación puede perder información de la historia.
Total infinito sin descuento	Definición del valor	El retorno puede divergir aun con recompensa acotada.
Confusión no medida	Identificación causal	La ley observada puede no determinar el valor de intervenir.
Colas pesadas	Integrabilidad	La pérdida esperada puede ser infinita.

Situación	Objeto afectado	Conclusión precisa
Memoria insuficiente	Modelo de transición	Bellman sobre el resumen elegido puede resolver otro problema.

Tabla 6.1: Qué limita cada ejemplo

6.1.2 Límites del Isomorfismo: Cuándo NO se Transfieren Garantías

Conviene separar cuatro preguntas: ¿se conserva el objetivo?, ¿lo identifican los datos?, ¿el estimador converge con la distribución anunciada?, ¿la decisión seleccionada mantiene esa garantía? Una respuesta positiva a una pregunta no responde automáticamente las siguientes.

Definición 6.5 (Garantía Transferible). Una garantía se transporta mediante una representación cuando se especifican el experimento, el objetivo, el procedimiento y sus correspondencias, y se demuestra que la afirmación probabilística o de riesgo se conserva. Al cambiar el experimento —por ejemplo, de muestras independientes a una trayectoria adaptativa— hace falta un resultado que cubra el nuevo régimen de datos.

Nota 6.6 (Condiciones suficientes según el régimen). No existe una lista única de condiciones necesarias formada por mixing, overlap y tasas $n^{-\frac{1}{4}}$. Son requisitos de resultados particulares. Tres rutas ilustran la diferencia:

1. **Retornos completos independientes:** para una política fija, retornos iid con varianza positiva y finita admiten el CLT habitual para la media. No se exige mixing dentro de cada episodio de horizonte fijo.
2. **Una trayectoria estacionaria:** el CLT de Proposición 6.16 proporciona una ruta suficiente mediante momentos y mixing.
3. **Estimación ortogonal:** además de identificación, expansión asintóticamente lineal y una varianza estimable, se controla el resto debido a las funciones auxiliares. Una condición de producto de errores puede permitir tasas diferentes para cada función.

Overlap se necesita para ciertas identificaciones fuera de política; no para calcular el valor en un modelo completamente conocido. Cada ruta debe acompañarse de su teorema y su unidad de muestreo.

Tipo	Pregunta	Justificación
Estimación	¿Se estima $J(\pi)$ con cobertura correcta?	Identificación, expansión y varianza para el muestreo considerado.
Planificación	¿La política optimiza el modelo dado?	Existencia y solución del problema de control.
Selección	¿Es válida la comparación tras elegir una política?	Evaluación independiente o inferencia uniforme o selectiva apropiada.

Tabla 6.2: Garantías de estimación y de decisión

6.1.3 Qué puede transportarse bajo condiciones adicionales

Las dificultades anteriores permiten precisar qué información adicional necesita una transferencia. En algunos casos basta aplicar un mapa conocido a un conjunto de confianza; en otros, la selección de la política o el cambio de unidad muestral modifica el problema inferencial. Los resultados siguientes delimitan esas situaciones.

Proposición 6.7 (Transporte de conjuntos de confianza). *Si C_n satisface $\mathbb{P}_\theta(\theta \in C_n) \geq 1-\alpha$ y el objetivo es $g(\theta)$, entonces el conjunto imagen $g(C_n)$ satisface*

$$\mathbb{P}_\theta(g(\theta) \in g(C_n)) \geq 1-\alpha.$$

Demostración. *El suceso $\{\theta \in C_n\}$ está contenido en $\{g(\theta) \in g(C_n)\}$. La cobertura puede aumentar y el conjunto imagen no tiene por qué ser un intervalo. Tomar su envolvente intervalar conserva la desigualdad cuando esta está bien definida.*

Esto no construye un intervalo normal. Si, adicionalmente, $\sqrt{n}\left(\hat{\theta}-\theta\right)$ converge a $N(0,\Sigma)$ y g es diferenciable, el método delta da varianza $\nabla g(\theta)^T \Sigma \nabla g(\theta)$, que debe ser positiva para el intervalo normal no degenerado usual. El CLT inicial debe ser válido para los datos efectivamente usados.

Nota 6.8 (Hipótesis y potencia bajo una transformación). Contrastar $g(\theta) = v_0$ significa contrastar el conjunto $\{\theta : g(\theta) = v_0\}$. Coincide con $\theta = \theta_0$ solo si la preimagen relevante es ese punto. Por ejemplo, para $g(\theta) = \theta^2$, la hipótesis $g(\theta) = 1$ contiene tanto $\theta = 1$ como $\theta = -1$. Un test diseñado únicamente para $\theta = 1$ no controla por ello el nivel sobre toda esa hipótesis compuesta.

Nivel y potencia se preservan exactamente cuando se conserva el experimento y la misma función de rechazo bajo una correspondencia de hipótesis. Cambiar a trayectorias dependientes requiere una nueva justificación de la distribución del estadístico.

Nota 6.9 (Correspondencias que requieren una prueba propia).

Resultado	Paso adicional
Consistencia	Continuidad del funcional y convergencia en una topología adecuada.
Normalidad	Diferenciabilidad pertinente, CLT y resto despreciable.
Cramér–Rao	Modelo paramétrico regular y parámetro funcional especificado.
Eficiencia semiparamétrica	Gradiente canónico del modelo observado y estimador que lo alcance.
Test óptimo	Familia, hipótesis y clase de tests para las que se demuestra optimalidad.
Control FDR	Valores p válidos y condiciones de dependencia del procedimiento elegido.

Ejemplo 6.10 (Eficiencia no equivale a normalidad de cualquier funcional). Sean X_i iid $N(\theta,1)$. La media es eficiente para θ. Para $g(\theta) = \theta^2$, el estimador $\overline{X}^2$ tiene, si $\theta \neq 0$, varianza asintótica $4\frac{\theta^2}{n}$. En $\theta = 0$,

$$n\overline{X}^2 \sim \chi^2_1.$$

La escala y la ley límite cambian; una fórmula normal obtenida sustituyendo una derivada nula no proporciona el intervalo habitual. La eficiencia se declara respecto de un modelo, un funcional y una noción de regularidad. Tampoco basta llamar DR a un estimador para que su función de influencia sea la eficiente del modelo de MDP.

Ejemplo 6.11 (Fallo por Violación de Mixing). Elija $Z \sim \text{Bernoulli}\left(\frac{1}{2}\right)$ una sola vez y defina $X_t = Z$ para todo t. El proceso es estacionario, pero $\overline{X}_n = Z$ nunca converge en probabilidad a $\frac{1}{2}$. Los sucesos $\{X_0 = 1\}$ y $\{X_k = 1\}$ mantienen dependencia $\frac{1}{4}$ para cualquier rezago. Una trayectoria no identifica la proporción de componentes en la población. Muchas trayectorias con reinicios independientes sí permiten estimarla: cambia la unidad muestral, no el teorema original.

Ejemplo 6.12 (Fallo por Overlap Insuficiente). En una decisión, el registro contiene solo $A = 0$ con recompensa cero; la política objetivo toma $A = 1$ con probabilidad 0.9. Dos modelos asignan a la acción nunca observada recompensas respectivas cero y uno. Generan exactamente los mismos registros, pero sus valores objetivo son cero y 0.9. Sin restricciones adicionales no hay identificación puntual. DM extrapola; no constituye una solución identificada por los datos. El cociente en la acción ausente no es un peso observable al que baste asignar «varianza infinita».

Distinto es el solapamiento débil: si $\pi_b(1) = \epsilon > 0$, $\pi_e(1) = 0.9$ y $R = A$, una contribución IS vale $\frac{0.9}{\epsilon}$ con probabilidad ϵ, y cero en otro caso. Entonces

$$\mathbb{E}[W] = 0.9, \quad \mathrm{Var}(W) = 0.81\left(\frac{1}{\epsilon} - 1\right).$$

Con $\epsilon = 0.01$ la varianza es 80.19: finita, pero grande. Si $0 \leq R \leq 1$ y no hay soporte para la acción uno, el primer escenario solo permite el intervalo de identificación $[0, 0.9]$.

Ejemplo 6.13 (Fallo por No-Estacionariedad). Hay $\frac{n}{2}$ resultados Bernoulli independientes de media 0.2, seguidos de $\frac{n}{2}$ con media 0.8. La media conjunta estima 0.5, no la media del régimen final. Su varianza es $\frac{0.16}{n}$, de modo que admite un CLT para ese promedio de regímenes. La no estacionariedad no elimina toda inferencia: obliga a definir qué población y periodo se evalúan. Incluir tiempo en el estado puede representar una dinámica no homogénea; no prueba estabilidad futura ni devuelve episodios iid.

Nota 6.14 (Protocolo antes de invocar una garantía). Registrar objetivo, política, periodo, unidad independiente y modelo; separar supuestos de identificación de condiciones del estimador; citar el resultado aplicable; documentar qué condiciones se conocen por diseño y cuáles solo reciben apoyo diagnóstico. Si una condición esencial permanece injustificada, informar una estimación descriptiva, una región de identificación o un análisis de sensibilidad según el caso, sin adjuntar la garantía que no se ha establecido.

Hasta aquí hemos seguido cambios del objetivo y de la información disponible. La estructura temporal de los datos añade otra dificultad: dos estimadores con la misma fórmula pueden tener fluctuaciones diferentes si uno promedia episodios independientes y el otro una trayectoria larga.

6.1.4 Condiciones de Regularidad para Dependencia Temporal

En n episodios independientes de horizonte fijo, la observación estadística puede ser una trayectoria completa. En una trayectoria de longitud T, los pasos son dependientes y el argumento asintótico es otro. Confundir n con nH multiplica ficticiamente la información. La siguiente ruta suficiente se refiere a un proceso escalar estacionario, por ejemplo una contribución de influencia ya definida.

Definición 6.15 (Condición de Mixing para CLT). Para un proceso estrictamente estacionario $(X_t)_{t\in\mathbb{Z}}$, sean $\mathcal{F}_{-\infty}^{0} = \sigma(X_t : t \leq 0)$ y $\mathcal{F}_{k}^{\infty} = \sigma(X_t : t \geq k)$. Defínase

$$\alpha(k) = \sup_{A\in\mathcal{F}_{-\infty}^{0}, B\in\mathcal{F}_{k}^{\infty}} |\mathbb{P}(A \cap B) - \mathbb{P}(A)\mathbb{P}(B)|.$$

La condición utilizada aquí exige que, para algún $\delta > 0$,

$$\mathbb{E}\left[|X_0|^{2+\delta}\right] < \infty, \quad \sum_{k=1}^{\infty} \alpha(k)^{\frac{\delta}{2+\delta}} < \infty.$$

Es una condición sobre sigma-álgebras de pasado y futuro, no solo sobre la correlación entre dos variables.

La autocorrelación controla relaciones lineales de un observable; $\alpha(k)$ controla dependencia entre sucesos. No son intercambiables. Una cadena finita irreducible y aperiódica tiene convergencia

geométrica; en un espacio general, recurrencia positiva y aperiodicidad no bastan para afirmar esa velocidad. Véase (Bradley, 2005) para las distinciones entre nociones de mixing.

Proposición 6.16 (CLT para una contribución estacionaria). *Bajo Definición 6.15, con* $\mu = \mathbb{E}[X_0]$,

$$\sqrt{T}\big(\overline{X}_T - \mu\big) \xrightarrow{d} N(0, \sigma_{LR}^2),$$

$$\sigma_{LR}^2 = \operatorname{Var}(X_0) + 2\sum_{k=1}^{\infty} \operatorname{Cov}(X_0, X_k).$$

La serie de covarianzas es absolutamente convergente. Si además $\sigma_{LR}^2 > 0$ *y* $\hat{\sigma}_{LR}^2 \xrightarrow{P} \sigma_{LR}^2$*, un intervalo asintótico es*

$$\overline{X}_T \pm z_{1-\frac{\alpha}{2}} \frac{\hat{\sigma}_{LR}}{\sqrt{T}}.$$

La varianza de la media es aproximadamente $\frac{\sigma_{LR}^2}{T}$*; no se reemplaza una varianza de la media por una varianza sin dividir por el tamaño de la trayectoria.*

Este CLT es un resultado externo de teoría de procesos dependientes; una exposición con estas condiciones es el teorema 355 de las notas de Shalizi sobre mixing. Aplicarlo a un estimador que utiliza funciones aprendidas exige además controlar el resto de su expansión; el CLT escalar no realiza ese paso.

Ejemplo 6.17 (Cálculo de σ_{LR}^2 en una Cadena de Markov de 2 estados). Sea $S_t \in \{0, 1\}$ con matriz

$$P = \begin{pmatrix} 0.8 & 0.2 \\ 0.3 & 0.7 \end{pmatrix},$$

iniciada en su distribución invariante $(0.6, 0.4)$. Defina $X_t = 10 S_t$: el estado y la recompensa no son la misma variable. La media de la recompensa es cuatro y su varianza es 24. El segundo autovalor es 0.5, de modo que

$$\operatorname{Cov}(X_0, X_k) = 24(0.5)^k, \quad \sigma_{LR}^2 = 72.$$

Para $T = 100$, el error estándar asintótico es $\sqrt{\frac{72}{100}} = 0.849$, frente a $\sqrt{\frac{24}{100}} = 0.490$ si se ignora la dependencia. La fórmula finita exacta da

$$\operatorname{Var}\big(\overline{X}_T\big) = \frac{24}{T} + \frac{48}{T^2}\sum_{k=1}^{T-1}(T-k)(0.5)^k,$$

cuyo valor en $T = 100$ es aproximadamente 0.7104, con error estándar 0.843. La comparación distingue cálculo exacto de aproximación asintótica; no afirma una cobertura exacta con cien observaciones.

Nota 6.18 (Diagnóstico empírico de dependencia). Examinar autocorrelaciones de recompensas, ocupaciones y contribuciones del estimador; comparar periodos y reinicios; buscar estados con pocas visitas; estudiar sensibilidad a la longitud de bloque o al ancho de banda de la varianza. Son diagnósticos de incompatibilidad y fragilidad. No certifican una cota poblacional de mixing ni la existencia de momentos. Un ajuste log-lineal de autocorrelaciones y un umbral arbitrario como 0.95 no sustituyen una demostración.

Una estimación HAC, por ejemplo con pesos de Bartlett, toma la forma

$$\hat{\sigma}^2_{LR} = \hat{c}_0 + 2\sum_{k=1}^{K}\left(1 - \frac{k}{K+1}\right)\hat{c}_k,$$

donde $\hat{c}_k = T^{-1}\sum_{t=k+1}^{T}\left(X_t - \overline{X}\right)\left(X_{t-k} - \overline{X}\right)$. Su consistencia requiere condiciones sobre dependencia, momentos y crecimiento de K; no basta elegir un valor por inspección. Véase (Newey & West, 1987) para la construcción de covarianzas HAC.

Herramienta	Versión dependiente	Condición pendiente
CLT de una media	CLT con varianza de largo plazo	Dependencia y momentos que permitan ese CLT.
Bootstrap iid	Remuestreo de episodios o bloques	Unidad correcta y teorema de consistencia para el funcional y los bloques.
Método delta	Transformación de un límite conjunto	Diferenciabilidad y control del resto.

Tabla 6.3: Qué se necesita al cambiar el régimen muestral

Representación, identificación e inferencia

Los seis mecanismos L1–L6 organizan la revisión sin ampliar la afirmación formal del Capítulo 5. Los encabezados históricos «isomorfismo estricto» y «transferencia condicional» se conservan; se refieren aquí, respectivamente, a límites de representación secuencial y a requisitos para inferir con datos. Ninguno modifica la identidad de un paso.

6.2.1 Límites del isomorfismo estricto

L1. Memoria y propiedad de Markov. Un estado debe conservar la información necesaria para predecir la siguiente recompensa y transición bajo cada acción del modelo. La suficiencia estadística para un parámetro es una propiedad diferente; no implica automáticamente esta condición.

Ejemplo 6.19 (Dos historias con el mismo estado resumido). En la decisión final de un episodio, $S_1 = 0$ siempre, pero la recompensa es $R_1 = 1$ si $A_1 = A_0$ y cero en otro caso. Si A_0 fue elegido uniformemente, una regla que recuerde la acción previa obtiene uno; cualquier regla que use solo S_1 y aleatorización independiente de la historia obtiene esperanza $\frac{1}{2}$. El resumen borra información decisiva. Aumentar el estado a (S_1, A_0) corrige este ejemplo y permite una ecuación de Bellman para el problema ampliado.

L2. Observabilidad. El posterior de Ejemplo 6.2 recupera información para el modelo latente especificado. Su cálculo presupone conocer o estimar los mecanismos de observación y evolución. Introducir una creencia no vuelve conocidos esos mecanismos ni elimina el error de aproximación. En SSCH, se debe documentar qué historial conserva el agente y qué información latente se supone representada por su posterior.

L3. Dinámica, horizonte y muestreo. Son cuestiones distintas: la homogeneidad describe un núcleo que no cambia con el tiempo; la estacionariedad describe una ley del proceso invariante; la ergodicidad relaciona promedios temporales y poblacionales; el descuento ayuda a hacer finito un retorno total. Un MDP conocido, finito y descontado admite planificación óptima aunque la cadena de una política tenga varias clases recurrentes. Eso no justifica inferencia poblacional basada en una sola clase observada.

6.2.2 Límites de la transferencia condicional

L4. Identificación causal. Para interpretar una política como intervención, la fórmula usual basada en historias observadas necesita consistencia, positividad e intercambiabilidad secuencial respecto de esas historias. La última no equivale a observar toda causa del resultado: exige ausencia de confusión residual relevante para esa identificación. Otras estrategias de identificación usan otras restricciones. El Ejemplo 6.4 muestra por qué un buen ajuste predictivo no permite elegir entre modelos causalmente distintos.

L5. Soporte y concentración de pesos. Debe haber soporte de los estados y acciones que visita la política objetivo, no solo de las acciones en estados frecuentes del registro. Los pesos por trayectoria multiplican razones y pueden concentrarse con el horizonte aun cuando cada razón sea finita. Recortar pesos puede reducir varianza y añadir sesgo; su magnitud debe incorporarse a la evaluación.

Ejemplo 6.20 (Costo de un horizonte largo). En un modelo de un estado, acciones iid bajo cada política y horizonte H, sean $\pi_e(1) = p = 0.8$, $\pi_b(1) = b$ y recompensa terminal siempre igual a uno. El valor es uno. IS por trayectoria usa

$$W_H = \prod_{t=1}^{H} \frac{\pi_e(A_t)}{\pi_b(A_t)}.$$

Por independencia, $\mathbb{E}_b(W_H) = 1$ y

$$\mathrm{Var}_b(W_H) = c^H - 1, \quad c = \frac{p^2}{b} + \frac{(1-p)^2}{1-b}.$$

Para $b = 0.5$, $c = 1.36$; para $b = 0.2$, $c = 3.25$. El estimador promedio sobre n trayectorias tiene esa varianza dividida por n. Como aquí se conoce que la recompensa es constante, se puede evaluar sin IS: la explosión es de este procedimiento, no una imposibilidad universal de evaluación.

b	$H = 1$	$H = 5$	$H = 10$
0.8	0	0	0
0.5	0.36	3.65	20.65
0.2	2.25	361.59	131 471.10

Figura 6.1: Varianza exacta de IS por trayectoria en el ejemplo de recompensa terminal constante. No son resultados de simulación ni curvas de PDIS.

L6. Error de las funciones auxiliares. Para una expansión ortogonal con resto acotado por Ca_nb_n, donde a_n y b_n son errores L^2 de dos funciones auxiliares, la condición pertinente es $a_nb_n = o_P\left(n^{-\frac{1}{2}}\right)$, junto con los demás supuestos de la expansión. No es una ley universal de todos los estimadores. La separación de muestras ayuda a controlar términos empíricos; no establece tasas de aprendizaje por sí sola.

Ejemplo 6.21 (Tasas compatibles e incompatibles). Si $a_n = O_P(n^{-0.30})$ y $b_n = O_P(n^{-0.25})$, su producto es $O_P(n^{-0.55}) = o_P\left(n^{-\frac{1}{2}}\right)$. Si ambas tasas son $O_P(n^{-0.20})$, el límite disponible para el resto es $O_P(n^{-0.40})$, insuficiente para garantizar inferencia a escala $\sqrt{n}$. Dos tasas exactamente $O_P\left(n^{-\frac{1}{4}}\right)$ tampoco aseguran el pequeño orden requerido. Un resto concreto puede cancelar, pero esa cancelación necesita prueba.

En un modelo paramétrico regular correctamente especificado, tasas $n^{-\frac{1}{2}}$ para ambos componentes suelen hacer este producto pequeño. En una regresión no paramétrica de suavidad β y dimensión

d, la tasa ilustrativa $n^{-\frac{\beta}{2\beta+d}}$, bajo las condiciones del método y diseño, supera $n^{-\frac{1}{4}}$ si $\beta > \frac{d}{2}$. La dimensión fija por sí sola no establece esa desigualdad ni garantiza que un bosque o una red alcance la tasa. El modelo semiparamétrico conserva un objetivo de dimensión baja, pero no elimina esta dificultad.

En evaluación de MDP, las funciones y normas pertinentes dependen del modelo de trayectorias. La construcción de (Kallus & Uehara, 2020) emplea funciones de valor y razones de ocupación marginal; no autoriza a sustituirlas sin más por propensiones de una sola acción. Sus condiciones son propias de esa construcción, independientes de la incrustación de Wald.

Límite	Objeto	Pregunta operativa
L1	Memoria del estado	¿Historias resumidas igual requieren decisiones distintas?
L2	Información observada	¿Qué parte del estado se infiere y bajo qué modelo?
L3	Dinámica y muestreo	¿Se evalúa un episodio, una trayectoria o un régimen cambiante?
L4	Intervención	¿La ley observada determina el resultado de cambiar la política?
L5	Soporte	¿Hay información en las regiones visitadas por la política objetivo?
L6	Estimador	¿El resto y la varianza permiten la distribución anunciada?

Figura 6.2: Mapa de los seis mecanismos: cada fila señala el primer objeto que debe revisarse.

Cuándo coinciden Bayes, minimax y admisibilidad. La propiedad de Markov y la observación del estado no eliminan la incertidumbre sobre el modelo. Para evitar que siglas como MA y CMIA sustituyan hipótesis, se distinguen dos formulaciones explícitas.

En un modelo conocido con distribución inicial fija ν, todas las políticas se comparan por el mismo escalar $J_\nu(\pi)$. Si el supremo se alcanza, las políticas que lo maximizan son precisamente las admisibles para la pérdida $-J_\nu$ en el problema de parámetro único; Bayes y minimax también optimizan ese escalar. Esta coincidencia no requiere inferir un parámetro y no afirma optimalidad en estados que ν no visita.

Si se usa cada estado inicial como índice del riesgo, $R(s,\pi) = -V^\pi(s)$, la comparación es vectorial. Para un MDP finito con recompensa acotada y $0 \le \gamma < 1$, existe una política estacionaria óptima en todos los estados ((Puterman, 2005)). Toda política que sea estrictamente peor en alguno queda dominada por ella. Así, las admisibles son las uniformemente óptimas en esta clase. Un prior con masa positiva en cada estado tiene las mismas políticas de Bayes, pero un criterio minimax puede admitir políticas adicionales.

Ejemplo 6.22 (Una política minimax puede ser dominada). En una decisión con dos estados iniciales, dos políticas factibles tienen vectores de valor $V^a = (1, 0)$ y $V^b = (0, 0)$. La primera domina a la segunda. Sin embargo,

$$\min_s V^a(s) = \min_s V^b(s) = 0.$$

Ambas son maximin si estas son las únicas opciones relevantes; con pérdida negativa ambas son minimax. Bajo un prior que asigne masa positiva al primer estado, solo a es Bayes. Si el prior

concentra toda su masa en el segundo, ambas son Bayes. Por tanto, existencia de una política uniformemente óptima no implica igualdad de los tres conjuntos de soluciones.

Problema	**Relación entre criterios**
Modelo conocido, objetivo escalar fijo	Si existe óptimo, Bayes, minimax y admisibilidad coinciden en maximizar ese objetivo.
Riesgo indexado por estados	Optimalidad uniforme y admisibilidad coinciden bajo existencia; Bayes necesita soporte apropiado; minimax puede incluir políticas dominadas.
Familia de modelos desconocidos	Vuelven a importar el prior y el peor caso; observar el estado no revela el modelo.

Figura 6.3: Alcance de la coincidencia de criterios. La comparación depende de qué se toma como parámetro y de la distribución inicial.

6.2.3 Una síntesis de las limitaciones

La clasificación paramétrica, semiparamétrica o no paramétrica se refiere a la familia de leyes, no a si el algoritmo utiliza aprendizaje automático. Un MDP tabular de tamaño fijo con transiciones desconocidas tiene un número finito de parámetros. Un modelo de regresiones desconocidas sobre un estado continuo puede ser infinito-dimensional; estimar un valor escalar dentro de él plantea un problema semiparamétrico.

En cualquiera de esos casos, el primer obstáculo puede ser identificación, antes de discutir tasas. Con identificación, una especificación paramétrica incorrecta puede dar intervalos estrechos alrededor del objetivo equivocado. Una clase más flexible reduce algunas restricciones, pero puede aumentar el error de estimación. La ortogonalidad protege frente a ciertos errores de primer orden; no corrige ausencia de soporte, confusión no medida o una política seleccionada con los mismos datos sin ajuste inferencial.

Aplicación al agente SSCH. Su reporte debe declarar la política que se evalúa, el horizonte, la población inicial, la información usada para actuar y el régimen de recolección. Si aprende una política, puede reservar episodios independientes para evaluarla condicionalmente en el conjunto de entrenamiento. Un intervalo puntual para esa política no es una banda simultánea para todas las políticas consideradas durante la búsqueda.

Cómo se manifiesta una condición que falta

Ejemplo 6.23 (Violación de Irreducibilidad). En las dos clases absorbentes de Ejemplo 6.11, una trayectoria revela su clase, pero no la probabilidad poblacional de iniciar en cada una. Condicionar el análisis a la clase observada cambia el objetivo y debe declararse. Reinicios independientes con la distribución inicial de interés aportan información sobre la mezcla. Redefinir nombres de estados no crea esa información.

Reducibilidad no implica siempre múltiples distribuciones invariantes: puede haber estados transitorios y una sola clase cerrada. Debe analizarse la cadena concreta, no sustituir ese análisis por una etiqueta.

Ejemplo 6.24 (Violación de Aperiodicidad). Considere la cadena determinista $0, 1, 0, 1, \ldots$ con fase inicial uniforme. Es estacionaria y periódica. Para $X_t = S_t$,

$$\left|\overline{X}_T - \frac{1}{2}\right| \leq \frac{1}{2T}.$$

El promedio sí converge, aunque la distribución desde un estado inicial fijo oscile. El límite a escala $\sqrt{T}$ es degenerado y la serie usual de autocovarianzas no es absolutamente convergente. Este caso no cumple la ruta de mixing anterior; no demuestra que todo promedio periódico deje de converger. Añadir ruido de transición cambia el proceso y no valida retrospectivamente los datos originales.

Ejemplo 6.25 (Mixing Lento (Polinomial)). Suponga que se ha demostrado $\alpha(k) \leq Ck^{-\nu}$ y que existe el momento de orden $2+\delta$. La sumabilidad utilizada en Definición 6.15 queda asegurada si

$$\nu\frac{\delta}{2+\delta} > 1.$$

Con $\delta = 2$, basta $\nu > 2$; una cota con $\nu = 1$ no permite concluir ese CLT. Que la condición suficiente no se verifique tampoco prueba que todo CLT sea imposible. Hace falta otro argumento.

En una cadena finita irreducible y aperiódica, un cuello de botella puede producir convergencia geométrica muy lenta; no la convierte por sí solo en polinomial. Aumentar bloques o tamaño muestral no repara un supuesto falso, y no existe un tamaño universal que garantice cobertura nominal.

Revisar la afirmación antes de utilizarla

El protocolo produce una ficha de justificación, no una certificación automática de supuestos poblacionales a partir de diagnósticos.

1. **Fijar la pregunta.** Escribir $J(\pi)$ con horizonte, descuento, distribución inicial, población y periodo. Distinguir política fija, aprendida con datos independientes y seleccionada durante la evaluación.
2. **Identificar las unidades.** Registrar número de pacientes o episodios independientes, longitud de trayectorias y posibles dependencias entre unidades. Separar muestras por unidad completa cuando ese sea el supuesto de independencia.
3. **Justificar el modelo.** Documentar qué memoria conserva el estado, qué es observado y qué es latente; distinguir núcleo conocido de núcleo estimado. La conectividad del grafo estimado no prueba que el grafo poblacional sea el mismo.
4. **Justificar identificación.** Explicitar la fuente de intercambiabilidad y el soporte relevante. Si se conoce la política de asignación por diseño, conservar sus probabilidades registradas. La ausencia de una acción en una muestra finita no prueba probabilidad poblacional cero.
5. **Elegir el resultado inferencial.** Registrar CLT, expansión, normas, momentos, control del resto y método de varianza que correspondan. Evitar mezclar episodios independientes con teoremas de una trayectoria estacionaria o trasladar tasas de un estimador a otro.
6. **Examinar fragilidad.** Mostrar pesos, ocupaciones, autocorrelaciones y sensibilidad a modelado, bloques o recorte. El ESS de pesos $\frac{\left(\sum_i w_i\right)^2}{\sum_i w_i^2}$ no es automáticamente el tamaño efectivo por dependencia serial ni una prueba de cobertura.
7. **Emitir una conclusión proporcional.** Separar condiciones garantizadas por diseño, demostradas para el modelo, apoyadas solo por diagnóstico y no justificadas. Si falta identificación, presentar sensibilidad o cotas cuando sean posibles. Si falla la inferencia, conservar el resultado descriptivo con su alcance, sin un intervalo nominal injustificado.

Ejemplo de cierre de la ficha. «Se evalúa una política fijada antes de analizar cien episodios independientes de tres visitas. La incertidumbre se calcula entre episodios. Las probabilidades de asignación se conocen por diseño y el soporte requerido está garantizado en el modelo del estudio. No se afirma validez para una política reajustada durante estas visitas ni para otra población inicial». Este texto identifica qué nueva pregunta exigiría otra evaluación, sin inventar un resultado numérico.

Relacionar cada garantía con su justificación

Garantía	Base de la justificación	Límite diagnóstico
Identidad riesgo–retorno	Construcción de un paso y misma clase de reglas del Capítulo 5.	Se verifica algebraicamente; no requiere una prueba de mixing.
IC para una media iid	Independencia, objetivo fijo, varianza finita positiva y CLT con varianza consistente.	La muestra finita no certifica los momentos.
IC con dependencia	CLT apropiado y estimador consistente de la varianza asintótica.	Una ACF favorable no prueba mixing.
Valor fuera de política	Identificación y soporte de la ley objetivo en la ley observada.	ESS no certifica soporte poblacional.
Eficiencia ortogonal	Gradiente correcto, expansión regular, resto pequeño y varianza válida.	Validación predictiva no demuestra tasas asintóticas.
Bootstrap	Teorema para el funcional, el muestreo y el remuestreo utilizados.	Bloques largos no garantizan consistencia por sí solos.
Garantía tras selección	Separación de evaluación o resultado uniforme o selectivo aplicable.	Un IC puntual no cubre toda una búsqueda de políticas.

Tabla 6.4: Condiciones y límites de su verificación

La contribución de este capítulo es precisar la pregunta que debe resolverse antes de atribuir una garantía al agente. Los capítulos de evaluación e intervalos desarrollan procedimientos para regímenes específicos; su validez debe leerse junto con esas condiciones, sin extender la representación de un paso a entornos que no cubre.

Con estas distinciones, la evaluación fuera de política puede formularse como un problema concreto: aprender el valor de una regla usando acciones registradas por otra. El capítulo siguiente comienza por identificar ese valor y después compara los estimadores que permiten aproximarlo.

Parte III

Inferencia para agentes

La evaluación de una política comienza por relacionar su valor con los datos disponibles. Después podemos estudiar su incertidumbre y revisar qué conclusión permite utilizar un resultado en un agente. Cada paso conserva el objetivo, el muestreo y las condiciones de su procedimiento.

Dr. Jaime Linares Zurivil

Capítulo 7

Evaluación off-policy

Una política propuesta puede diferir de la que produjo los datos disponibles. Evaluar su valor exige relacionar esas dos formas de actuar antes de calcular un promedio. El método directo (DM) estima el valor por sustitución; la ponderación por importancia (IS) cambia la medida de probabilidad; el estimador doblemente robusto (DR) combina una predicción bajo la política objetivo con una corrección residual. Cada procedimiento requiere una justificación propia. Doble robustez no significa protección frente a cualquier error ni garantiza menor varianza en toda muestra.

La representación del Capítulo 5 conserva el riesgo en un MDP de un paso. Los resultados de este capítulo se justifican por identificación, cambio de medida y teoría de estimación; no son corolarios automáticos de aquella representación. Los límites del Capítulo 6 orientan la lectura.

Una política de recomendación, asignación de recursos o seguimiento puede proponer acciones distintas de las registradas. Comparar los promedios observados entre quienes recibieron cada acción no reproduce necesariamente el resultado de aplicar la política propuesta. La evaluación fuera de política, u OPE, formula con precisión esa pregunta contrafactual.

La ponderación en aprendizaje por refuerzo aparece, entre otros trabajos, en (Precup et al., 2000). La combinación de regresión y ponderación se desarrolla para bandits contextuales en (Dudík et al., 2011) y para decisiones secuenciales en (Jiang & Li, 2016). La inferencia eficiente depende además del modelo estadístico de trayectorias, como muestra (Kallus & Uehara, 2020). Estas contribuciones responden a problemas relacionados, pero no tienen idénticas hipótesis ni el mismo estimador.

En SSCH, la motivación es evaluar una regla de seguimiento antes de utilizarla. Los ejemplos serán sintéticos, con recompensas abstractas; no aportan evidencia sobre tratamientos reales. El propósito es que el lector pueda reconstruir cada estimación y localizar qué supuesto la sostiene. Un registro clínico extenso no certifica por sí solo ausencia de confusión no medida.

Identificar el valor antes de estimarlo

7.1.1 El Problema de Off-Policy Evaluation

Definición 7.1 (Experimento y objetivo de OPE). Se observan n episodios iid

$$O_i = \big(S_{i,0}, A_{i,0}, R_{i,0}, \ldots, S_{i,H}\big),$$

de horizonte fijo H. Las acciones pertenecen a un conjunto finito; la política de registro es $b_t(a|s)$ y la política objetivo fija es $e_t(a|s)$. Ambas pueden variar con t. La distribución inicial común es ν y el núcleo de recompensa y transición es $K_t(\mathrm{d}r, \mathrm{d}s'|s, a)$. Se supone $|R_t| \le R_*$ y $0 < \gamma \le 1$ para los resultados acotados de este capítulo.

El objetivo escalar es

$$J(e) = \mathbb{E}_e(G) = \int v_0(s)\nu(\mathrm{d}s),$$

donde v_t es el valor desde el tiempo t bajo e. Estimar $v_0(s_0)$ en un estado fijado es otro problema; no se obtiene promediando indiscriminadamente estados iniciales distintos.

Las funciones b_t y e_t equivalen a las políticas π_b y π_e de capítulos anteriores. Aquí se abrevian para hacer legibles los pesos. Un episodio completo constituye una observación estadística; sus H pasos no son H observaciones independientes. El régimen de una sola trayectoria larga requiere resultados diferentes.

Definición 7.2 (Retorno y funciones de valor).

$$G = \sum_{t=0}^{H-1} \gamma^t R_t, \quad B_H = R_* \sum_{t=0}^{H-1} \gamma^t.$$

Así, $|G| \le B_H$. Con $v_H = 0$,

$$q_t(s,a) = \mathbb{E}\big[R_t + \gamma v_{t+1}(S_{t+1}) | S_t = s, A_t = a\big],$$

$$v_t(s) = \sum_a e_t(a|s) q_t(s,a).$$

El modelo directo debe estimar estos valores futuros, no solo la recompensa inmediata cuando hay más de una decisión.

Tres familias estadísticas. Un MDP tabular de tamaño fijo tiene una parametrización finita de sus transiciones y medias de recompensa; la ley completa de las recompensas podría seguir sin parametrizarse. Con estados continuos, estimar funciones libres de recompensa o transición es un problema no paramétrico. Estimar $J(e)$, escalar, dentro de una familia que contiene funciones desconocidas de dimensión infinita es un problema semiparamétrico. El uso de una red neuronal no determina por sí solo a cuál de estas familias pertenece el modelo.

7.1.2 Supuestos de Identificación

Supuesto 7.1 (Consistencia e intervención bien definida). Los estados y recompensas observados coinciden con sus resultados potenciales bajo la secuencia de acciones efectivamente recibida. Las versiones de cada acción están especificadas y no hay interferencia entre episodios. El resultado en t puede depender de toda la secuencia previa: no se reduce en general a $R_t(a_t)$.

Supuesto 7.2 (Soporte de la política objetivo). En las historias alcanzables bajo e, toda acción con probabilidad objetivo positiva tiene probabilidad positiva bajo el registro. Con distribución inicial común y núcleos invariantes, esto asegura dominación de la ley objetivo por la ley registrada. Para las cotas acotadas se impondrá además $\frac{e_t(a|s)}{b_t(a|s)} \le C < \infty$ en el soporte pertinente. Esta restricción cuantitativa es más fuerte que la mera positividad.

Definición 7.3 (Coeficiente de overlap).

$$\rho_{\max} = C = \sup_{t,s,a} \frac{e_t(a|s)}{b_t(a|s)},$$

tomando el supremo esencial en el soporte pertinente. En espacios finitos puede usarse el máximo. El mayor cociente observado en una muestra es un diagnóstico, no necesariamente esta cota poblacional.

Supuesto 7.3 (Intercambiabilidad y estructura de Markov). Se distinguen dos requisitos. Primero, dado el historial previo a actuar, la acción registrada es independiente de los resultados

potenciales futuros de las intervenciones consideradas —intercambiabilidad secuencial—. Segundo, el estado S_t resume ese historial para el núcleo de recompensa y transición y para las políticas utilizadas. Los núcleos K_t permanecen invariantes al sustituir b por e.

La propiedad de Markov observacional no implica ausencia de confusión. Con historias completas puede formularse el cambio de medida sin exigir un resumen de Markov; en tal caso también cambian los argumentos de las políticas y de las funciones de valor.

Teorema 7.4 (Identificación del valor de una política). *Bajo los supuestos anteriores, defina*

$$\rho_t = \frac{e_t(A_t|S_t)}{b_t(A_t|S_t)}, \quad W_t = \prod_{k=0}^{t} \rho_k, \quad W_{-1} = 1.$$

Para retornos integrables bajo la ley objetivo,

$$J(e) = \mathbb{E}_b(W_{H-1}G) = \sum_{t=0}^{H-1} \gamma^t \mathbb{E}_b(W_t R_t).$$

Demostración. La ley de un episodio se factoriza en distribución inicial, políticas y núcleos K_t. En el cociente de leyes se cancelan ν y los núcleos, y queda W_{H-1}. Para la recompensa en t, basta el cociente de la historia que termina después de esa recompensa: W_t. Integrar respecto de cada ley proporciona ambas identidades. El argumento usa integrales y también cubre estados continuos.□

La identificación es poblacional. La consistencia de un estimador, su varianza finita y la cobertura de un intervalo son afirmaciones distintas. Los supuestos causales no se verifican completamente con una tabla de frecuencias o una métrica predictiva.

Una vez expresado el valor en términos de la ley observada, hay varias maneras de estimarlo. El método directo utiliza un modelo de valor; la ponderación cambia la medida con la que se promedian las trayectorias. Comparar ambos permite entender después la corrección residual de DR.

7.1.3 Direct Method (DM)

Definición 7.5 (Estimador DM). Ajuste $\hat{q}_t$ por un modelo de transición y recompensa o por regresiones de Bellman hacia atrás; defina

$$\hat{v}_t(s) = \sum_a e_t(a|s)\hat{q}_t(s,a), \quad \hat{v}_H = 0.$$

Sobre estados iniciales de evaluación independientes del ajuste,

$$\hat{J}_{\mathrm{DM}} = \frac{1}{n}\sum_{i=1}^{n} \hat{v}_0\big(S_{i,0}\big).$$

Si se usa cross-fitting, cada predicción procede de un ajuste que excluye el episodio completo que se evalúa.

Proposición 7.6 (Error y variabilidad de DM). *Condicionalmente en un ajuste independiente, su sesgo es*

$$\mathbb{E}_\nu(\hat{v}_0 - v_0),$$

cuyo valor absoluto no supera $\mathbb{E}_\nu\big(\sum_a e_0(a|S_0)|\hat{q}_0(S_0,a) - q_0(S_0,a)|\big)$. *Su varianza condicional es* $\mathrm{Var}_\nu \frac{\hat{v}_0(S_0)}{n}$. *La variabilidad total incluye además la del entrenamiento.*

No estimar b explícitamente es una ventaja de DM; no permite aprender respuestas en regiones sin soporte sin restricciones extrapolativas. En un modelo paramétrico mal especificado, el error puede persistir al aumentar n. En una regresión no paramétrica, la complejidad, la suavidad y el

diseño determinan la precisión. Un buen ajuste de la recompensa inmediata no garantiza una buena aproximación a q_t.

7.1.4 Importance Sampling (IS)

Definición 7.7 (Razón de importancia por trayectoria). La razón completa es $W_{H-1} = \prod_{t=0}^{H-1} \rho_t$. Los resultados exactos siguientes usan probabilidades de registro verdaderas, conocidas por diseño o como objetos teóricos. Reemplazarlas por estimaciones requiere otro análisis; no conserva automáticamente la insesgadez finita.

Definición 7.8 (Estimador IS).

$$\hat{J}_{\mathrm{IS}} = \frac{1}{n} \sum_{i=1}^{n} W_{i,H-1} G_i.$$

Los pesos son no negativos y no se normalizan empíricamente en esta definición. El estimador autonormalizado divide $\sum_i W_i G_i$ por $\sum_i W_i$; suele tener sesgo finito y requiere que el denominador sea positivo. Es un procedimiento diferente.

Teorema 7.9 (Insesgadez de IS). *Con pesos verdaderos y $\mathbb{E}_e(|G|) < \infty$,*

$$\mathbb{E}_b\big(\hat{J}_{\mathrm{IS}}\big) = J(e).$$

Si además $\mathbb{E}_b(W_{H-1}^2 G^2) < \infty$,

$$\mathrm{Var}_b\big(\hat{J}_{\mathrm{IS}}\big) = \frac{\mathrm{Var}_b(W_{H-1} G)}{n}.$$

La segunda condición no se necesita para la primera igualdad.

Demostración. La esperanza de cada sumando coincide con $\mathbb{E}_e(G)$ por Teorema 7.4. La independencia entre episodios proporciona la fórmula de varianza. La ley de grandes números da consistencia bajo integrabilidad; insesgadez y consistencia no son sinónimos. (argumento y alcance en Apéndice A, pág. 234) □

Definición 7.10 (Per-Decision IS (PDIS)).

$$\hat{J}_{\mathrm{PDIS}} = \frac{1}{n} \sum_{i=1}^{n} \sum_{t=0}^{H-1} \gamma^t W_{i,t} R_{i,t}.$$

Es insesgado con pesos verdaderos bajo las mismas condiciones de identificación e integrabilidad de cada término. Elimina de una recompensa pasada los pesos de acciones futuras.

Cada término PDIS es la esperanza condicional del correspondiente término IS dado el historial hasta esa recompensa. Su segundo momento no aumenta. Esto no basta, por sí solo, para ordenar las varianzas de las sumas: también intervienen covarianzas entre tiempos. Se debe evaluar el procedimiento completo.

7.1.5 Curse-of-Horizon

Teorema 7.11 (Cota de varianza y crecimiento posible). *Si $|G| \le B_H$ y $\rho_t \le C$, entonces*

$$\mathrm{Var}_b\big(\hat{J}_{\mathrm{IS}}\big) \le \frac{B_H^2 C^H}{n}.$$

No se requiere independencia entre los pesos de distintos tiempos. Esta es una cota superior, no una tasa exacta ni una cota inferior.

U. Jaime I. Oficial Curso

Demostración. Se tiene $0 \le W_{H-1} \le C^H$ y $\mathbb{E}_b(W_{H-1}) = 1$, por lo que $\mathbb{E}_b(W_{H-1}^2) \le C^H$. Finalmente, $\mathrm{Var}_b(W_{H-1}G) \le \mathbb{E}_b(W_{H-1}^2 G^2) \le B_H^2 C^H$. (argumento y alcance en Apéndice A, pág. 235) □

Ejemplo exacto. En un estado, con acciones iid Bernoulli de parámetros p bajo e y b bajo el registro, considere recompensa terminal uno, las demás cero, y $\gamma = 1$. El valor es uno, pero IS tiene varianza

$$\frac{c^H - 1}{n}, \quad c = \frac{p^2}{b} + \frac{(1-p)^2}{1-b}.$$

La fórmula se obtiene multiplicando segundos momentos de pesos independientes en este ejemplo específico. Con $p = 0.8$, $b = 0.5$ y $H = 10$, $c = 1.36$ y la varianza por trayectoria es aproximadamente 20.65. Un modelo que conoce la recompensa constante evalúa el valor sin esa variabilidad. La dificultad de IS no equivale a imposibilidad universal de OPE.

Corolario 7.12 (Implicación para el diseño de evaluación). *En familias donde la varianza realmente crece como c^H, mantener un error estándar fijo exige un número de episodios del mismo orden. Una cota grande basada en C alerta sobre un riesgo, pero no prueba que IS sea inutilizable en todos los modelos con ese horizonte.*

PDIS, pesos de ocupación marginal, modelos de valor y controles de varianza pueden ayudar bajo condiciones específicas. Recortar pesos introduce sesgo. DR secuencial todavía puede contener productos de pesos; no elimina automáticamente el crecimiento con el horizonte.

7.1.6 Distributional Shift: Cuando el Mundo Cambia

OPE ya compara dos distribuciones diferentes: las inducidas por b y por e. Lo que se mantiene en el planteamiento básico es la distribución inicial y el núcleo del entorno. Cambiar también la población inicial introduce una diferencia adicional; cambiar el núcleo requiere aún más información.

Definición 7.13 (Cambio de población inicial). En el caso estudiado aquí, ν_b es la distribución inicial del registro y ν_* la de la población objetivo, con absoluta continuidad de ν_* respecto de ν_b. Los núcleos K_t permanecen invariantes. Defina

$$u(s) = \frac{\mathrm{d}\nu_*}{\mathrm{d}\nu_b}(s).$$

Este cambio no debe confundirse con la diferencia de ocupaciones intermedias que las propias políticas generan.

Proposición 7.14 (IS con cambio de población inicial). *Si se conocen u y las razones de política, y el retorno es integrable,*

$$J_*(e) = \mathbb{E}_b(u(S_0) W_{H-1} G).$$

El promedio de estas contribuciones es insesgado. Para su varianza se necesita el segundo momento conjunto de $u(S_0)W_{H-1}G$; no se puede factorizar sin condiciones adicionales.

Para ilustrar el efecto de u aislado, si $G = 1$ y $e = b$, la varianza por observación de $u(S_0)$ es $\mathbb{E}_{\nu_b}(u^2) - 1 = \chi^2(\nu_* \| \nu_b)$: no es exponencial en esta divergencia. Estimar u agrega error y exige soporte y regularidad.

Definición 7.15 (Evaluación y optimización robustas). Para una política fija y un conjunto explícito de modelos plausibles $\mathcal{U}$, la evaluación robusta de recompensa es

$$J_{\mathrm{rob}(e)} = \inf_{P \in \mathcal{U}} J_P(e).$$

Seleccionar una política robusta supone además maximizar esa cantidad sobre las políticas permitidas. En términos de pérdidas, se minimiza el peor riesgo. No son el mismo objeto que un estimador puntual OPE.

Proposición 7.16 (Alcance de una cota robusta). *Si un conjunto aleatorio $\mathcal{U}_n$ contiene el modelo verdadero de despliegue P_* con probabilidad al menos $1-\alpha$, entonces, para política fija,*

$$\mathbb{P}\Big(J_{P_*}(e) \geq \inf_{P\in\mathcal{U}_n} J_P(e)\Big) \geq 1-\alpha.$$

Demostración. *En el suceso $P_* \in \mathcal{U}_n$, el ínfimo no supera el valor del elemento P_*. La dificultad estadística es construir un conjunto con la cobertura anunciada, no esta desigualdad.*

Una bola de KL, otra divergencia o Wasserstein requiere especificar su centro, métrica, radio y justificación. No hay una cota universal de producción que dependa solo de escribir un radio ϵ. Las bolas con divergencia f respecto de una medida empírica pueden restringir el soporte; una ley continua no pertenece automáticamente a ellas. (Duchi & Namkoong, 2021) desarrolla garantías bajo condiciones propias de su formulación, no para cualquier conjunto de incertidumbre.

Ejemplo 7.17 *(sintético)* **(SSCH: cambio de composición poblacional).** Dos estratos tienen valores condicionales conocidos $v_0 = (2, 6)$. El registro tiene proporciones $(0.8, 0.2)$ y la población objetivo $(0.3, 0.7)$. El valor registrado es 2.8 y el objetivo es 4.8. Los pesos iniciales son $(0.375, 3.5)$, de modo que

$$0.8(0.375)2 + 0.2(3.5)6 = 4.8.$$

No corregir la población estima otro objetivo; la diferencia es dos unidades. No es un porcentaje obtenido de una simulación.

Si solo se sabe que la proporción del segundo estrato está en $[0.6, 0.8]$ y se mantienen los valores condicionales, el valor está en $[4.4, 5.2]$. Es un rango de sensibilidad. Solo sería una región con cobertura estadística si también se justificara la cobertura del conjunto de proporciones y se incorporara el error al estimar los valores condicionales.

7.1.6.1 Distinguir población inicial y ocupación de estados

Al cambiar la población inicial aparece un segundo mecanismo de reponderación. El cambio de política no exige igualdad entre las leyes de entrenamiento y de despliegue; precisamente se corrige su diferencia. La pregunta es qué componentes del mecanismo siguen siendo transportables.

Definición 7.18 (Dos razones de distribución distintas). El peso $u = \frac{\mathrm{d}\nu_*}{\mathrm{d}\nu_b}$ corrige la población inicial. Una razón marginal $w_t = \frac{d_t^e}{d_t^b}$ compara ocupaciones de estado y acción en un tiempo dado. No son intercambiables. Si cambia además el núcleo de recompensa o transición, ninguno de esos cocientes aislados identifica automáticamente el valor en el nuevo entorno.

DRO constituye una posible formulación de sensibilidad o decisión robusta, no una obligación ni una solución universal cuando se desconoce el cambio. Su conexión con minimax de Wald exige especificar la familia de modelos que se considera plausible. Un radio elegido sin justificación no crea una garantía de desempeño.

Ejemplo 7.19 *(sintético)* **(SSCH: cambio de población y de respuesta).** Retome los estratos de Ejemplo 7.17. Si además del cambio a proporciones $(0.3, 0.7)$, el valor del segundo estrato pasa de seis a cuatro, el valor nuevo es $0.3(2) + 0.7(4) = 3.4$. Reponderar únicamente la población inicial con el antiguo modelo produce 4.8, una diferencia de 1.4. Los mismos pesos iniciales no corrigen una respuesta condicional que ha cambiado.

Un contraste de distribución de estados, como MMD con un kernel y calibración especificados, puede detectar diferencias en esos estados. No certifica invariancia de recompensas o transiciones, ni identifica por sí solo el efecto del cambio de política. No existe un umbral MMD universal de 0.05: su escala depende, entre otros factores, del kernel. Véase (Gretton et al., 2012).

7.1.7 Doubly Robust (DR)

Definición 7.20 (DR de una decisión y su extensión secuencial). En una decisión, $m(s,a) = \mathbb{E}[R|S=s, A=a]$ y $\hat{v}(s) = \sum_a e(a|s)\hat{m}(s,a)$. La contribución es

$$D_i = \hat{v}(S_i) + \frac{e(A_i|S_i)}{\hat{b}(A_i|S_i)}(R_i - \hat{m}(S_i, A_i)).$$

El promedio es $\hat{J}_{\mathrm{DR}}$. El primer término promedia acciones bajo e: no puede sustituirse por $\hat{m}(S_i, A_i)$.

Para H decisiones, con modelos entrenados fuera del episodio i, defina $\widehat{W}_{i,t}$ mediante las propensiones estimadas y

$$\Delta_{i,t} = R_{i,t} + \gamma \hat{v}_{t+1}(S_{i,t+1}) - \hat{q}_t(S_{i,t}, A_{i,t}).$$

La contribución secuencial y el estimador son

$$D_i = \hat{v}_0(S_{i,0}) + \sum_{t=0}^{H-1} \gamma^t \widehat{W}_{i,t}\Delta_{i,t},$$

$$\hat{J}_{\mathrm{DR}} = \frac{1}{n}\sum_{i=1}^{n} D_i.$$

Por qué importa el término inicial. En un estado, sea $R = A$, $b(1) = \frac{1}{2}$, $e(1) = \frac{3}{4}$ y modelo exacto $m(a) = a$. El residuo es cero. El término correcto vale $\frac{3}{4}$, mientras que usar $m(A)$ produce media $\frac{1}{2}$. Incluso un modelo perfecto falla con aquella fórmula incorrecta.

Teorema 7.21 (Identidad de doble robustez). *Para una decisión, trate $\overline{m}$ y $\overline{b} > 0$ como funciones fijas independientes de la muestra de evaluación, y sea D la contribución anterior con esas funciones. Entonces*

$$\mathbb{E}_b(D) - J(e) = \mathbb{E}_\nu\left(\sum_a e(a|S)\frac{\overline{b}(a|S) - b(a|S)}{\overline{b}(a|S)}(\overline{m}(S,a) - m(S,a))\right).$$

Si todos los términos son integrables, el sesgo se anula cuando $\overline{m} = m$ o $\overline{b} = b$.

Demostración. Condicione en S, promedie la acción con b y sustituya $\mathbb{E}[R|S,A] = m(S,A)$. Al restar $\sum_a e(a|S)m(S,a)$, se agrupan los errores con factor $1 - \frac{b}{\overline{b}}$. No se requiere que ambos modelos sean correctos. (argumento y alcance en Apéndice A, pág. 235) □

Con propensiones alejadas de cero, Cauchy–Schwarz acota el sesgo por un producto de errores L^2. La insesgadez con funciones exactamente correctas es distinta de la consistencia con funciones aprendidas. Esta última requiere también una ley de grandes números y control de los pesos. Para el estimador secuencial, con horizonte fijo, la misma cancelación opera si todos los q_t son correctos o todas las propensiones son correctas; la demostración se presenta en el apéndice. No significa que una única regresión correcta en un tiempo arbitrario baste para todo el episodio.

Proposición 7.22 (Inferencia eficiente en una decisión). *Suponga episodios iid, acciones finitas, e fija, recompensas y regresiones ajustadas uniformemente acotadas, y $b, \hat{b} \geq \epsilon > 0$. Use un número fijo de folds de tamaños proporcionales a n, con separación por episodios. En cada fold, los dos errores*

L^2 convergen a cero y su producto es $o_P\left(n^{-\frac{1}{2}}\right)$, para la norma respecto de $\nu(s)e(a|s)$. Si la varianza indicada abajo es positiva,

$$\sqrt{n}\left(\hat{J}_{\mathrm{DR}} - J\right) = \frac{1}{\sqrt{n}} \sum_{i=1}^{n} \varphi(O_i) + o_P(1),$$

$$\varphi(O) = v(S) - J + \frac{e(A|S)}{b(A|S)}(R - m(S, A)).$$

En el modelo observado no paramétrico de una decisión, φ es el gradiente canónico. Su varianza es la cota de eficiencia para estimadores regulares; la varianza muestral de las contribuciones cross-fitted estima esa varianza bajo estas condiciones.

(argumento y alcance en Apéndice A, pág. 236)

La eficiencia exige más que doble robustez. Tener un componente correcto y otro convergente a una función incorrecta puede dar consistencia sin la función de influencia eficiente anterior. Dos errores $O_P\left(n^{-\frac{1}{4}}\right)$ no garantizan el pequeño orden de su producto; tasas algo más rápidas o un argumento adicional pueden proporcionarlo.

Para un MDP finito en horizonte con núcleos temporales sin restricciones adicionales y distribución inicial desconocida, la función eficiente usa razones marginales de ocupación $w_t = \frac{d_t^e}{d_t^b}$ en lugar de W_t. El Capítulo 4 especifica ese modelo y la expansión correspondiente. El estimador secuencial por productos presentado aquí no debe declararse eficiente en todo modelo Markov por llevar el nombre DR.

Ejemplo 7.23 (DR puede aumentar la varianza). Sea $R = 0$ siempre, $b(1) = \frac{1}{2}$ y $e(1) = 1$. Con modelo $\overline{m}(a) = 1$ para ambas acciones y propensión correcta, $D = 1 - 2A$, cuya media es cero y varianza uno. IS es idénticamente cero. El modelo es no nulo y tiene error cuadrático finito, pero aumenta la varianza. Un residuo útil puede reducirla; esa reducción no está garantizada para una aproximación arbitraria.

Ruta	Información utilizada	Comprobación adicional
DM	Modelo de valor de la política objetivo.	Error de aproximación y del entrenamiento.
IS / PDIS	Probabilidades de registro y objetivo.	Momentos de pesos y retornos; soporte.
DR	Modelo de valor y corrección ponderada.	Resto, separación muestral y varianza del estimador concreto.
IS recortado	Pesos limitados por un umbral.	Sesgo añadido y regla de elección del umbral.

Figura 7.1: Elección de estimador después de justificar identificación. Las condiciones son requisitos de análisis, no umbrales automáticos de cobertura.

7.1.8 Comparación de Estimadores

Nota 7.24 (Compromisos entre sesgo y varianza).

Método	Base de la validez	Riesgo principal
DM	Valor ajustado que converge al objetivo.	Sesgo de modelo y extrapolación.

Método	Base de la validez	Riesgo principal
IS	Cambio de medida con pesos verdaderos.	Concentración de pesos y segundos momentos grandes.
PDIS	Cambio de medida hasta cada recompensa.	Persistencia de pesos acumulados y covarianzas temporales.
DR	Cancelación residual bajo una de las dos familias correctas.	Ambas familias incorrectas; resto o varianza sin controlar.

No hay un orden universal de varianzas «baja, media, alta». Comparar estimaciones sobre los mismos episodios es útil para diagnosticar sensibilidad, pero la coincidencia de DM, IS y DR no demuestra ausencia de confusión o validez de los intervalos. Tampoco debe elegirse el método por el intervalo más favorable y luego interpretar su cobertura como si la elección hubiera sido previa.

La comparación entre estimadores vuelve sobre la misma restricción de información: los datos deben representar las acciones que necesita la política objetivo. Los diagnósticos siguientes permiten examinar cómo aparece esa dificultad en la muestra y qué decisiones de análisis obliga a revisar.

7.1.9 Diagnósticos de Overlap

Definición 7.25 (Tamaño efectivo basado en pesos). Para pesos no negativos w_i con suma positiva,

$$\mathrm{ESS} = \frac{\left(\sum_i w_i\right)^2}{\sum_i w_i^2}.$$

Está entre uno y n. Describe concentración de estos pesos, no certifica soporte poblacional ni la información efectiva de cualquier estimador. Si todos los pesos son cero, la expresión no está definida.

Conviene indicar si se calcula con W_{H-1}, con W_t por tiempo o con razones marginales. Para los cuatro pesos $(0.25, 0.75, 0.75, 2.25)$, la suma es cuatro, la suma de cuadrados 6.25 y el ESS es 2.56. La media y el máximo no determinan por sí solos la suma de cuadrados. Un ESS elevado también puede coexistir con una región objetivo nunca representada en la muestra.

7.1.10 Protocolo de Fallback ante Overlap Insuficiente

La respuesta depende de si faltan datos, si el modelo impone restricciones extrapolativas o si existe información pero está muy concentrada. Cambiar el estimador no restituye soporte ausente.

Definición 7.26 (Estados de la evaluación de soporte).

1. **Soporte justificado:** proviene del diseño o de supuestos explícitos; se examina además la concentración de pesos.
2. **Concentración preocupante:** pocas trayectorias dominan los pesos; se estudia sensibilidad sin deducir automáticamente invalidez.
3. **Soporte no establecido:** la muestra y la información de diseño no permiten justificar la condición poblacional.
4. **Falta de soporte conocida:** una región visitada por e tiene probabilidad cero bajo el registro. Sin restricciones adicionales, el valor completo puede no estar identificado.

Teorema 7.27 (Sesgo y varianza por truncamiento). *Sea $W = W_{H-1}$ verdadero, $|G| \le B_H$ y $M > 0$ fijo. Para $\hat{J}_M = n^{-1} \sum_i \min(W_i, M) G_i$,*

$$\left|\mathbb{E}_b\left(\hat{J}_M\right) - J\right| \le B_H \mathbb{E}_b((W - M)_+),$$

$$\mathrm{Var}_b\big(\hat{J}_M\big) \le \frac{B_H^2 \min(M^2, M)}{n}.$$

El sesgo depende de la masa ponderada de la cola, no solo de $\mathbb{P}_b(W > M)$.

Demostración. Reste $\mathbb{E}_b(WG)$ y aplique valor absoluto. Para la varianza, $\min(W, M)^2 \le M^2$ y también $\min(W, M)^2 \le MW$, con $\mathbb{E}_b(W) = 1$. Un umbral fijo generalmente mantiene sesgo al aumentar n. Si M_n es determinista, $M_n \to \infty$ y $\frac{M_n}{n} \to 0$, la cota de varianza tiende a cero y el sesgo también, por convergencia dominada de $(W - M_n)_+$ cuando el experimento y H permanecen fijos. □

Nota 7.28 (Elección del umbral). Recortar en el percentil 95 no asegura sesgo pequeño. Un percentil muestral es aleatorio y las cotas para M fijo no se trasladan automáticamente a una elección sobre la misma muestra. Puede prefijarse una rejilla, usar datos independientes para elegir o desarrollar un resultado uniforme que cubra la selección. Reportar estabilidad ante varios umbrales es un diagnóstico, no una demostración de cobertura.

Ejemplo de cola rara. Si $e(1) = 1$, $b(1) = 0.01$ y $R = A$, entonces $W = 100$ con probabilidad 0.01 y cero en otro caso. El valor es uno. Recortar en $M = 10$ produce esperanza 0.1: sesgo -0.9 aunque $\mathbb{P}(W > M) = 0.01$. La cota correcta usa $\mathbb{E}\big((W - 10)_+\big) = 0.9$.

Árbol de respuesta:

```
Si falta soporte poblacional:
    delimitar población/política evaluable, o presentar cotas y supuestos
Si el soporte existe pero los pesos se concentran:
    comparar métodos y sensibilidad; revisar momentos y error de modelo
Si se recortan pesos:
    registrar umbral, criterio de elección y tratamiento del sesgo
Emitir un intervalo nominal solo con una justificación inferencial aplicable
```

Un intervalo multiplicado por 1.5 no tiene cobertura garantizada por ese factor. Una estimación DM puede presentarse como extrapolación condicionada al modelo, no como reparación automática de identificación.

7.1.11 Verificación en Línea de Supuestos

Monitorear aporta evidencia sobre incompatibilidades, pero observar continuamente y detenerse al obtener un resultado favorable modifica el procedimiento. Los intervalos de tamaño fijo no son automáticamente válidos bajo parada opcional.

Definición 7.29 (Indicadores de monitoreo). Registrar pesos por acción y acumulados, máximo observado, ESS por horizonte, cuantiles, fracción de peso concentrada en pocos episodios, ocupaciones por estado y residuos de Bellman. Para pesos de media positiva puede calcularse su coeficiente de variación. Examinar la dependencia entre unidades cuando estas no sean episodios independientes.

Nota 7.30 (Calibración de alertas). Los umbrales operativos se fijan antes de la evaluación y se calibran respecto de escenarios, tamaño de muestra, política y costo del error. Una alerta indica revisión; su ausencia no acredita una garantía. No hay valores universales de ESS, peso máximo o autocorrelación que certifiquen identificación, mixing o cobertura del 95%.

Ejemplo 7.31 (Pipeline de monitoreo).

```
AL CERRAR UN EPISODIO:
    validar horizonte, acciones, recompensas y probabilidades registradas
    guardar versión de la política y población inicial de evaluación
    actualizar pesos acumulados y diagnósticos por tiempo
```

```
contrastar con los criterios operativos fijados previamente
si hay alerta: emitir diagnóstico y análisis de sensibilidad
en el punto de análisis previsto:
    calcular estimador, varianza por episodio y alcance de la inferencia
```

Si la política de registro se adapta entre episodios usando resultados previos, conservar sus probabilidades condicionales reales. El régimen iid planteado al inicio deja de ser aplicable sin una justificación específica para esos datos adaptativos.

Situación	Qué compromete	Respuesta
Soporte ausente	Identificación sin extrapolación.	Restringir objetivo, justificar modelo o presentar cotas.
Pesos concentrados	Precisión de ciertos estimadores.	Examinar segundos momentos, sensibilidad y diseño de datos.
Dependencia no modelada	Varianza e inferencia.	Usar unidades y teoremas apropiados.
Cambio del entorno	Transportabilidad del valor.	Separar población inicial de cambios del núcleo.
Modelo de valor deficiente	DM y parte de DR.	Revisar ajuste y soporte; usar ponderación solo si está justificada.

Tabla 7.1: Respuesta a dificultades de evaluación

Convertir la evaluación en una decisión documentada

El agente debe conservar un registro que permita reconstruir la pregunta estadística: versión de e, horizonte, descuento, definición de recompensa, población inicial, unidad independiente, probabilidades registradas y particiones de entrenamiento. La identificación se documenta antes de seleccionar el estimador. Un nodo de diagnóstico no puede comprobar por sí solo intercambiabilidad ni corregir un estado insuficiente.

Una implementación separa validación de episodios, entrenamiento de funciones auxiliares, cálculo de contribuciones, diagnóstico e informe. Los modelos se entrenan fuera de los episodios en que se evalúan sus residuos. El informe distingue estimación, error estándar, evidencia de soporte y supuestos no contrastables. El Laboratorio 10.11 del Apéndice 10 es el lugar de integración; su implementación debe respetar estas fórmulas y no reutilizar reglas que conviertan ESS en una certificación automática.

Hilo longitudinal: SSCH

Ejemplo 7.32 *(sintético)* **(SSCH: dos decisiones con cálculo completo).** Considere dos visitas, un estado y acciones binarias independientes entre visitas bajo cada política. La recompensa abstracta es $R_t = A_t$, $\gamma = 0.9$, $b_t(1) = 0.5$ y $e_t(1) = 0.75$. El valor exacto es

$$J(e) = 0.75 + 0.9(0.75) = 1.425.$$

Use modelos fijados independientemente de los episodios: $\hat{q}_1(a) = 0.2 + 0.6a$, por lo que $\hat{v}_1 = 0.65$, y $\hat{q}_0(a) = 0.1 + 0.8a + 0.9(0.65) = 0.685 + 0.8a$. Entonces $\hat{v}_0 = 1.285$. No son los modelos verdaderos.

Cada trayectoria binaria tiene probabilidad $\frac{1}{4}$ bajo b. Los cocientes por acción son 0.5 para cero y 1.5 para uno. La tabla enumera contribuciones, no resultados de una corrida aleatoria.

(A_0, A_1)	W_1	IS	PDIS	DR
$(0,0)$	0.25	0	0	1.190
$(0,1)$	0.75	0.675	0.675	1.370
$(1,0)$	0.75	0.750	1.500	1.300
$(1,1)$	2.25	4.275	3.525	1.840

Para $(1,0)$, el retorno es uno. IS vale 0.75 y PDIS vale 1.5. Los residuos de DR son 0.1 y -0.2, de donde

$$D = 1.285 + 1.5(0.1) + 0.9(0.75)(-0.2) = 1.300.$$

Al promediar las cuatro filas con probabilidad $\frac{1}{4}$, IS, PDIS y DR dan 1.425; DM permanece en 1.285. La diferencia de DM es -0.140. Las varianzas exactas por episodio son, respectivamente, 2.7928125, 1.7521875 y 0.061525. Para n episodios iid y estos modelos fijos, cada varianza del promedio se divide por n.

La menor varianza de DR en este ejemplo se debe al ajuste y al modelo concretos. No demuestra un orden universal ni proporciona un intervalo clínico. Si se usaran los valores verdaderos, $q_1(a) = a$ y $q_0(a) = a + 0.675$, ambos residuos serían cero y DR devolvería 1.425 en todos los episodios de este entorno determinista.

Conexión con el Capítulo 8

El próximo capítulo estudia cómo cuantificar la incertidumbre del valor. Para episodios iid, se trabaja con contribuciones por episodio; no hace falta declarar que todos los pasos son independientes. Para una trayectoria larga, la varianza puede requerir autocovarianzas o una representación martingala. El régimen muestral determina la herramienta.

En estimadores aprendidos, el intervalo necesita además controlar el resto de estimación de las funciones auxiliares. La eficiencia semiparamétrica de OPE y los resultados de aproximación de funciones de valor son desarrollos diferentes: no debe atribuirse a cualquier teorema de evaluación una función eficiente o un bootstrap que no establece.

Al comparar dos políticas sobre los mismos episodios se usa la variabilidad de la diferencia de contribuciones, incluida su covarianza. Si la política se elige con esos datos, debe separarse la evaluación o emplearse inferencia apropiada para la selección. Una estimación puntual mayor que la de referencia no basta para autorizar un despliegue.

Ejercicios

Ejercicio 7.1. *Factorice la ley de una trayectoria con H decisiones y demuestre las dos identidades de Teorema 7.4. Distinga la condición para esperanza finita de la necesaria para varianza finita. Explique qué cambia si la distribución inicial objetivo es diferente.*

Ejercicio 7.2. *Suponga $|G| \le 1$, $C = 2$ y $H = 20$. Calcule la cota superior de varianza de IS y un tamaño suficiente según esa cota para que sea menor que uno. Explique por qué no es un tamaño necesario. Construya un caso de recompensa cero que impida interpretar la cota como crecimiento obligatorio de la varianza.*

Ejercicio 7.3. *Derive la identidad de sesgo de DR en una decisión. En un estado, tome* $b(1) = \frac{1}{2}, e(1) = 1, m(1) = 1, \overline{b}(1) = \frac{1}{4}$ *y* $\overline{m}(1) = 0$. *Calcule esperanza y sesgo de DR. Compare con el caso en que solo una de las funciones coincide con la verdadera.*

Ejercicio 7.4. *Cien pesos tienen media* 1.5 *y máximo* 50. *Explique por qué esto no determina el ESS. Calcule el ESS si los otros 99 pesos son* $\frac{100}{99}$*; compárelo con el de tres pesos iguales a* 50 *y los restantes cero. Interprete qué información adicional se necesita para evaluar soporte poblacional.*

Ejercicio 7.5. *Se dispone de mil episodios, cien decisiones por episodio, un máximo observado de cocientes igual a cinco y un modelo con* $R^2 = 0.7$. *Explique por qué estos datos no bastan para escoger un estimador con garantía. Diseñe la ficha de evaluación, incluyendo objetivo, identificación, pesos por horizonte, separación muestral, modelo de valor, sesgo por recorte y método de incertidumbre.*

Lecturas Propuestas

Lecturas Obligatorias

1. (Jiang & Li, 2016): estimación DR secuencial; distinguir los supuestos de insesgadez de los escenarios donde se alcanza una cota de varianza.
2. (Dudík et al., 2011): evaluación y aprendizaje en bandits contextuales; identificar el promedio inicial bajo la política objetivo.
3. (Thomas et al., 2015): evaluación con alta confianza; examinar las condiciones concretas de las cotas, no solo el valor estimado.

Lecturas Complementarias

1. (Kallus & Uehara, 2020) y (Kallus & Uehara, 2022): razones marginales, modelos de trayectorias y eficiencia; diferenciar horizontes finitos de formulaciones estacionarias.
2. (Liu et al., 2018): evaluación mediante distribuciones de ocupación.
3. (Duchi & Namkoong, 2021): construcción y alcance de objetivos robustos.
4. (Sugiyama & Kawanabe, 2012) y (Quiñonero-Candela et al., 2009): cambios de distribución y condiciones de transporte; (Gretton et al., 2012) para contrastes de dos muestras basados en kernels.

Universidad Nacional Curivil

Capítulo 8

Intervalos de confianza para funciones de valor

Una estimación de valor necesita una medida de incertidumbre referida a un objetivo y a un régimen de datos. Este capítulo distingue tres rutas: promedios de contribuciones de episodios independientes, inferencia con una trayectoria dependiente y estimación de Bellman mediante bases. Una cuarta cuestión aparece al aprender la política con los mismos datos: el objetivo de evaluación deja de ser una política fijada de antemano.

La evaluación OPE del Capítulo 7 proporciona estimadores, pero su nombre no determina la validez del intervalo. Hay que justificar identificación, expansión asintótica, error de aproximación y estimación de varianza. Los ejemplos SSCH de este capítulo son cálculos sintéticos reproducibles; no son resultados de una validación clínica.

La dependencia dentro de una trayectoria no implica dependencia entre trayectorias. Cien episodios independientes pueden analizarse mediante cien contribuciones, aunque cada episodio contenga muchas decisiones. Una trayectoria larga requiere, en cambio, un argumento que tenga en cuenta su dependencia o una estructura de diferencias de martingala.

Shi et al. (2022) estudian el valor descontado en horizonte infinito mediante aproximación sieve y desarrollan SAVE para políticas dependientes de los datos. La eficiencia semiparamétrica de DRL se estudia en (Kallus & Uehara, 2020) y (Kallus & Uehara, 2022). Son resultados con estimadores y modelos diferentes. No cabe atribuir a todos ellos una misma función eficiente o un bootstrap universal.

La pregunta aplicada debe preceder al cálculo: ¿interesa el valor de una política, su diferencia frente a una referencia o el rendimiento de una regla aprendida? Un valor positivo no demuestra mejora frente a otra política. Un intervalo estrecho tampoco corrige un objetivo no identificado.

Definir la incertidumbre según el objetivo y los datos

8.1.1 El Problema de Inferencia

Fijadas una política π y una distribución inicial ν, sea $J(\pi) = \int V^\pi(s)\nu(\mathrm{d}s)$. La inferencia puntual sobre $V^\pi(s_0)$, la inferencia sobre $J(\pi)$ y una banda simultánea sobre muchos estados son objetos distintos. La distribución ν se considera fija y conocida, salvo indicación contraria; estimarla puede añadir variabilidad.

Un intervalo asintótico de nivel $1-\alpha$ satisface

$$\mathbb{P}(J(\pi) \in C_n) \to 1-\alpha.$$

Esto no es la desigualdad de cobertura exacta para cada tamaño finito. Tampoco asigna probabilidad posterior al parámetro fijo. Si el estimador admite una expansión

$$\hat{J} - J = \frac{1}{n}\sum_{i=1}^{n} \varphi(O_i) + o_P\left(n^{-\frac{1}{2}}\right),$$

con episodios iid, $\mathbb{E}(\varphi) = 0$ y $0 < \sigma^2 = \mathbb{E}(\varphi^2) < \infty$, el CLT y una varianza consistente justifican

$$\hat{J} \pm z_{1-\frac{\alpha}{2}} \frac{\hat{\sigma}}{\sqrt{n}}.$$

Aquí σ es una desviación de contribuciones; $\frac{\hat{\sigma}}{\sqrt{n}}$ es el error estándar de la estimación. Dividir dos veces por $\sqrt{n}$ produce intervalos artificialmente estrechos.

Modelos e inferencia. En un modelo paramétrico regular puede usarse una matriz de covarianza y el método delta. En un modelo semiparamétrico, el funcional puede tener tasa $\sqrt{n}$ aunque sus funciones auxiliares converjan más lentamente. En un problema no paramétrico, estimar una función completa suele exigir otra tasa y controlar sesgo de suavización. No todo funcional admite una expansión regular de primer orden.

8.1.2 Condiciones de Mixing

Definición 8.1 (α-mixing). Para un proceso estacionario $(X_t)_{t\in\mathbb{Z}}$, defina

$$\alpha(k) = \sup_{A\in\mathcal{F}_{-\infty}^{0},\, B\in\mathcal{F}_{k}^{\infty}} |\mathbb{P}(A\cap B) - \mathbb{P}(A)\mathbb{P}(B)|,$$

donde las sigma-álgebras corresponden al pasado y al futuro separados por k pasos. El proceso es fuertemente mixing si $\alpha(k) \to 0$. No basta con que un observable tenga autocorrelación pequeña.

Definición 8.2 (Mixing geométrico). Existe una cota $\alpha(k) \le Cr^k$ con $C < \infty$ y $0 < r < 1$. La tasa pertenece a una ley del proceso; una autocorrelación estimada no constituye por sí sola una prueba de esa cota.

Proposición 8.3 (Alcance del caso finito). *Una cadena finita irreducible y aperiódica, iniciada en su ley invariante, es geométricamente mixing. Para trasladarlo a acciones y recompensas se requiere que su generación siga los núcleos especificados sin dependencia latente adicional entre tiempos. En espacios generales, recurrencia positiva y aperiodicidad no garantizan por sí solas una tasa geométrica.*

La cadena relevante para los datos es la inducida por la política de registro. Estudiar exclusivamente la política objetivo no caracteriza la dependencia de la muestra observada. Véase (Bradley, 2005) para las distinciones entre condiciones de mixing.

8.1.3 Tasas de Mixing Explícitas para MDPs

Teorema 8.4 (Una cota espectral bajo reversibilidad). *Sea P una matriz finita, irreducible, aperiódica y reversible respecto de μ, con m estados. Si $r = \max_{j\ge 2}|\lambda_j| < 1$, entonces*

$$\left\|P^k(s,\cdot) - \mu\right\|_{\mathrm{TV}} \le \frac{1}{2}\sqrt{\frac{1}{\mu(s)} - 1}\, r^k.$$

Con la convención estacionaria $\beta(k) = \sum_s \mu(s)\left\|P^k(s,\cdot) - \mu\right\|_{\mathrm{TV}}$, se obtiene

$$\beta(k) \le \frac{1}{2}\sqrt{m-1}\, r^k.$$

Demostración. En $L^2(\mu)$, reversibilidad hace autoadjunto al operador de transición. Su restricción al subespacio de media cero tiene norma r. La densidad inicial desde s, menos uno, tiene norma

$\sqrt{\frac{1}{\mu(s)} - 1}$. Aplicar P^k y Cauchy–Schwarz da la cota en variación total. Promediar y aplicar nuevamente Cauchy–Schwarz produce $\sqrt{m-1}$. No se ha supuesto que los autovalores sean positivos.□

Nota 8.5 (Interpretación del gap). El gap absoluto usado arriba es $1 - r$. No debe confundirse con el segundo autovalor sin valor absoluto. En $P = \begin{pmatrix} 0.01 & 0.99 \\ 0.99 & 0.01 \end{pmatrix}$, el autovalor no trivial es -0.98: ignorar su módulo ocultaría la persistencia de la alternancia. Para una matriz no reversible hacen falta otras cotas; una fórmula con un único autovalor real ordenado no es una regla general. Una matriz estimada agrega incertidumbre a cualquier diagnóstico.

Ejemplo 8.6 (Dependencia y tamaño efectivo de una media). Si un observable estacionario tiene autocovarianza $\mathrm{Cov}(X_0, X_k) = \sigma_X^2 \rho^k$ con $|\rho| < 1$, entonces

$$\sigma_{\mathrm{LR}}^2 = \sigma_X^2 \frac{1+\rho}{1-\rho}, \quad T_{\mathrm{eff}} \approx T \frac{1-\rho}{1+\rho}.$$

Para $\rho = 0.95$ y $T = 1000$, el factor de varianza es 39, $T_{\mathrm{eff}} \approx 25.64$ y el error estándar asintótico se multiplica por $\sqrt{39} \approx 6.24$. Son fórmulas para este observable, no para todo proceso con cierta tasa de mixing. Con correlaciones negativas, la varianza de la media puede disminuir.

Datos	Ruta posible	Condición adicional
Episodios independientes	Varianza entre contribuciones de episodios.	Reinicios y unidades realmente independientes.
Cadena finita reversible	Cota espectral con módulo de autovalores.	Política de registro fija y modelo apropiado.
Estado continuo	Drift, minoración u otra condición demostrada.	Una ACF no prueba ergodicidad geométrica.
Residuos martingala	Varianza condicional y CLT de martingala.	Filtración, momentos y resto controlados.

Tabla 8.1: Régimen de datos y fundamento de la varianza

Algoritmo 8.1: Selección justificada del método de varianza

1. Fijar estimando, política, unidad de muestreo y régimen asintótico.
2. Si hay episodios iid, calcular contribuciones por episodio.
3. Si se usa una trayectoria, identificar la secuencia de influencia o momentos y justificar su CLT; distinguir mixing y martingalas.
4. Escoger un estimador de varianza compatible con esa representación.
5. Examinar sensibilidad a ajustes, rezagos y bloques, sin convertir umbrales de autocorrelación en certificados de validez.

8.1.4 CLT para Procesos Mixing

Teorema 8.7 (CLT bajo mixing fuerte). *Para un proceso estrictamente estacionario de media cero, suponga* $\mathbb{E}\left(|X_0|^{2+\delta}\right) < \infty$ *para algún* $\delta > 0$ *y* $\sum_{k \geq 1} \alpha(k)^{\frac{\delta}{2+\delta}} < \infty$. *Entonces*

$$\frac{1}{\sqrt{T}} \sum_{t=1}^{T} X_t \xrightarrow{d} N(0, \sigma_{\mathrm{LR}}^2),$$

$$\sigma_{\mathrm{LR}}^2 = \mathrm{Var}(X_0) + 2 \sum_{k \geq 1} \mathrm{Cov}(X_0, X_k).$$

Para un intervalo normal no degenerado se necesita además $\sigma^2_{\mathrm{LR}} > 0$ y estimación consistente de esa varianza.

Este resultado de teoría de procesos dependientes no controla por sí solo el error de funciones aprendidas. Si X_t se reemplaza por una contribución estimada, hay que demostrar que la sustitución y el resto son despreciables a la escala usada. El Capítulo 6 desarrolla esta frontera.

8.1.5 El Teorema de Shi et al. (2022)

Aquí cambia el horizonte del objetivo: se considera $V^\pi(s) = \mathbb{E}_\pi\Big(\sum_{t\geq 0}\gamma^t R_t | S_0 = s\Big)$, con $0 < \gamma < 1$, aunque cada trayectoria observada tenga longitud T. No es el retorno truncado a T usado como objetivo en otros procedimientos.

La ecuación que permite estimar. Para mostrar la construcción de Bellman, tome un vector de bases $f(s,a)$ y una aproximación $q_\beta(s,a) = f(s,a)^T\beta$. Defina

$$u_\pi(s) = \sum_a \pi(a|s) f(s,a), \quad a_\nu = \int u_\pi(s)\nu(\mathrm{d}s).$$

Con $N = nT$, use

$$\widehat{M} = \frac{1}{N}\sum_{i,t} f_{i,t}\big(f_{i,t} - \gamma u_\pi\big(S_{i,t+1}\big)\big)^T,$$

$$\hat{h} = \frac{1}{N}\sum_{i,t} f_{i,t} R_{i,t}, \quad \hat{\beta} = \widehat{M}^{-1}\hat{h}, \quad \hat{J} = a_\nu^T\hat{\beta}.$$

Las sumas cubren los T pares de transición de cada trayectoria. Estas fórmulas necesitan invertibilidad. Una matriz casi singular puede hacer inestable tanto la estimación como su error estándar.

En un modelo lineal exacto, el residuo $\epsilon_{i,t} = R_{i,t} + \gamma u_\pi\big(S_{i,t+1}\big)^T\beta - f_{i,t}^T\beta$ tiene media condicional cero si la ecuación de Bellman es válida dado el historial previo a observar recompensa y siguiente estado. El momento $f_{i,t}\epsilon_{i,t}$ es entonces una diferencia de martingala. En una aproximación sieve, las bases crecen y se debe controlar además el error de aproximación. No basta con ajustar una regresión flexible.

Nota 8.8 (Alcance del Teorema 1 de SZLS). Bajo las hipótesis completas de su Teorema 1, incluidos los requisitos sobre bases, regularidad, información y crecimiento de dimensiones, Shi et al. (2022) obtienen, para política fija,

$$\frac{\sqrt{nT}\Big(\hat{J}(\pi;\nu) - J(\pi;\nu)\Big)}{\hat{\sigma}(\pi;\nu)} \xrightarrow{d} N(0,1),$$

en los regímenes admitidos con n o T creciente. Es una referencia al resultado original, no un teorema DR ni una transcripción completa de sus hipótesis.

MA describe la transición Markov; CMIA describe la independencia condicional en media de la recompensa respecto del pasado dado estado y acción. Ninguna de esas siglas equivale, por definición, a identificación causal de intervenciones con confusión no medida. Tampoco «no estimar la política de registro» significa poder evaluar acciones sin información: la información del diseño y la invertibilidad siguen siendo esenciales.

Corolario 8.9 (Intervalo por studentización). *Siempre que se haya establecido el límite studentizado anterior,*

$$\hat{J}(\pi;\nu) \pm z_{1-\frac{\alpha}{2}} \frac{\hat{\sigma}(\pi;\nu)}{\sqrt{nT}}$$

tiene cobertura asintótica $1-\alpha$. *En un procedimiento basado en episodios de horizonte fijo con contribución por episodio, la escala correspondiente es* $\sqrt{n}$ *y no se reemplaza por* $\sqrt{nT}$.

(argumento y alcance en Apéndice A, pág. 236)

Una expansión asintótica describe la escala y la distribución límite del error. Para utilizarla con datos necesitamos además estimar su varianza en el mismo régimen de muestreo. La elección entre episodios, trayectorias y bloques determina qué contribuciones pueden promediarse.

Estimación de Varianza

Definición 8.10 (Varianza de contribuciones por episodio). Si D_i son contribuciones de evaluación y $\hat{J} = \overline{D}$, defina $\hat{\varphi}_i = D_i - \overline{D}$ y

$$s_D^2 = \frac{1}{n-1}\sum_i \hat{\varphi}_i^2, \quad \widehat{\mathrm{SE}} = \frac{s_D}{\sqrt{n}}.$$

Para contribuciones cross-fitted, la consistencia de esta fórmula requiere las condiciones de la expansión; no se deduce de tratar los ajustes compartidos como si fueran independientes.

Definición 8.11 (Varianza HAC con pesos de Bartlett). Para una secuencia estimada $\hat{\varphi}_t$, con promedio $\overline{\varphi}$,

$$\hat{c}_k = \frac{1}{T}\sum_{t=k+1}^{T} (\hat{\varphi}_t - \overline{\varphi})(\hat{\varphi}_{t-k} - \overline{\varphi}),$$

$$\hat{\sigma}^2_{\mathrm{HAC}} = \hat{c}_0 + 2\sum_{k=1}^{K}\left(1 - \frac{k}{K+1}\right)\hat{c}_k.$$

El error estándar de una media es $\frac{\hat{\sigma}_{\mathrm{HAC}}}{\sqrt{T}}$. El crecimiento de K debe cumplir el teorema de consistencia usado; elegir K del orden $T^{\frac{1}{3}}$ no es una regla válida para todo proceso.

Proposición 8.12 (Consistencia: una ruta suficiente para HAC). *Sea* c_k *la autocovarianza de una secuencia estacionaria y suponga* $\sum_{k\geq 0}|c_k| < \infty$, $K \to \infty$, $\frac{K}{T} \to 0$ *y*

$$\sum_{k=0}^{K} |\hat{c}_k - c_k| \xrightarrow{P} 0.$$

Entonces $\hat{\sigma}^2_{\mathrm{HAC}} \xrightarrow{P} \sigma^2_{\mathrm{LR}}$.

Demostración. El error se separa en estimación de covarianzas, cola omitida y ponderación de Bartlett. El primero se acota por dos veces la suma del enunciado. Los otros tienden a cero por sumabilidad y convergencia de los pesos a uno en cada rezago fijo. La condición sobre las covarianzas estimadas debe demostrarse; no se obtiene solo del CLT. □

En la ecuación de Bellman anterior, si los momentos son diferencias de martingala y la aproximación es despreciable, se utiliza una matriz sandwich compatible con ellos. En dimensión fija, una forma es

$$\hat{\Omega} = \frac{1}{N}\sum_{i,t} f_{i,t} f_{i,t}^{T} \hat{\epsilon}_{i,t}^2,$$

$$\hat{\sigma}^2 = a_\nu^T \widehat{M}^{-1} \hat{\Omega} \widehat{M}^{-T} a_\nu.$$

Esta fórmula no es una varianza HAC genérica ni una cota de eficiencia semiparamétrica por definición. Si falla la propiedad martingala, las covarianzas de los momentos pueden dejar de anularse.

Bootstrap: qué se remuestrea. Con episodios iid se remuestrean episodios completos. Con una trayectoria se consideran bloques u otro método justificado para su dependencia. Cuando el estimador aprende funciones, remuestrear solo las contribuciones fijadas exige que la aproximación lineal ya controle ese aprendizaje; otro procedimiento puede requerir reajustar los modelos en cada réplica. La validez del bootstrap debe probarse para el funcional y el estimador concretos. Que los bloques crezcan y sean pequeños frente a T no constituye, por sí solo, una prueba completa. Véase también (Hall, 1992).

Hasta aquí la interpretación del intervalo descansaba en un objetivo fijado para la evaluación. Si los datos también actualizan la política, la cantidad evaluada puede cambiar entre bloques. SAVE aborda esa organización secuencial mediante un procedimiento específico.

SAVE: Corrección de Sesgo

Se conserva el título histórico, pero SAVE aborda la evaluación secuencial de políticas aprendidas; no es una corrección residual IS equivalente a DR.

Definición 8.13 (SAVE y orden de aprendizaje). SAVE significa SequentiAl Value Evaluation. El procedimiento de Shi et al. (2022) actualiza políticas y evaluaciones en bloques ordenados. Puede tratar no unicidad de la política óptima bajo sus condiciones. La partición, agregación y studentización deben seguir el procedimiento original; un promedio arbitrario de contribuciones DR no lo reproduce.

La dificultad que hay que resolver. Si π_k se aprende antes de un bloque de evaluación y $\hat{J}_k$ estima su valor, un promedio con pesos predeterminados a_k suma estimaciones de políticas distintas. Para compararlo con una política final π_f, aparece el término

$$\sum_k a_k \big(J(\pi_k) - J\big(\pi_f\big)\big), \quad \sum_k a_k = 1.$$

Aunque cada evaluación tenga un error centrado, ese término no se anula por respetar el orden temporal. Se necesita controlarlo a la escala del intervalo. Esta descomposición explica el problema; no define la fórmula exacta de SAVE.

Nota 8.14 (Margen y tasas de valor). Los Teoremas 3–4 de SZLS relacionan errores de estimación de Q con tasas de valor bajo condiciones de margen. Las tasas dependen de la norma de error; no se puede trasladar una tasa uniforme a un error L^2 sin otro argumento.

Ejemplo elemental de una decisión. Con dos acciones, sea $\Delta(s) = |q(s,1) - q(s,0)|$ y suponga $\mathbb{P}(0 < \Delta(S) \le u) \le C u^\kappa$. Si $\|\hat{q} - q\|_\infty \le \epsilon$, una acción greedy incorrecta solo puede tener gap positivo menor o igual a 2ϵ. Por tanto,

$$\mathbb{E}(q(S, a^*(S)) - q(S, \hat{a}(S))) \le C(2\epsilon)^{1+\kappa}.$$

Los empates tienen pérdida cero. Este cálculo es autocontenido para una decisión; no certifica que una red neuronal alcance el error supuesto, ni sustituye las condiciones longitudinales del artículo.

Nota 8.15 (Qué se puede atribuir a SAVE). Evaluar con orden temporal atiende la adaptación, pero no demuestra por sí solo ausencia de sesgo, doble robustez o varianza menor que IS. Con

Original Research Guide

una política aprendida y congelada puede usarse evaluación en episodios independientes, condicionando en el entrenamiento. Ese objetivo es el valor de la política aprendida, no necesariamente el valor óptimo desconocido.

Diseño de Poder y Tamaño de Muestra

Proposición 8.16 (Planificación normal aproximada). *Para un contraste bilateral de nivel α, diferencia positiva relevante δ, poder aproximado $1-\beta$ y desviación σ_D de la contribución de la diferencia por unidad independiente,*

$$n \approx \left\lceil \frac{\left(z_{1-\frac{\alpha}{2}} + z_{1-\beta}\right)^2 \sigma_D^2}{\delta^2} \right\rceil.$$

Es una aproximación de planificación, no una garantía finita universal. La varianza debe corresponder al estimador, diseño y objetivo elegidos.

Con $\alpha = 0.05$, poder 0.80 y efecto estandarizado 0.2, cuantiles normales precisos dan $n = 197$. Redondear primero a 1.96 y 0.84 da 196; para planificar conviene redondear el tamaño al final. Si $\delta = 0.5$ y $\sigma_D = 2$, se necesitan aproximadamente 126 unidades para poder 80% y 169 para 90%. Son unidades independientes, no pasos de una misma trayectoria.

Para dos grupos independientes de igual tamaño, la varianza de la diferencia es la suma de las varianzas de sus medias y el tamaño debe especificarse por grupo. Para dos políticas evaluadas sobre los mismos episodios, se usa la varianza de sus diferencias, incluida la covarianza. Añadir automáticamente un factor dos puede desperdiciar o subestimar información. La dependencia y los errores de modelos auxiliares requieren una planificación adicional o simulación del procedimiento completo.

Diagnóstico de Supuestos

La ficha de evaluación debe separar condiciones del diseño, supuestos del modelo y señales empíricas. El ESS y los pesos informan sobre concentración; no certifican soporte poblacional. Una ACF informa sobre un observable; no prueba mixing. Residuos de Bellman pequeños no prueban identificación causal ni ausencia de sesgo de aproximación.

Una simulación de cobertura necesita un valor verdadero conocido, repetir todo el ajuste y contar la fracción de intervalos que lo contienen. Con M réplicas independientes, el error Monte Carlo estimado es $\sqrt{\hat{p}\frac{1-\hat{p}}{M}}$. Si $M = 2000$ y la cobertura es 0.95, es aproximadamente 0.0049. Una cobertura de 0.88 no se repara multiplicando intervalos por un factor elegido después de ver el resultado: primero se investiga si falla el sesgo, la varianza, la selección o el régimen muestral. No se reportan aquí corridas de simulación que no hayan sido realizadas.

Deep Reinforcement Learning: Policy Gradient y REINFORCE

Aprender una política e inferir su valor son tareas diferentes. Para hacer explícito el cálculo del gradiente, se usa primero horizonte finito H, distribución inicial fija y núcleo del entorno que no depende del parámetro de política θ.

Definición 8.17 (Objetivo diferenciable de política). Sea π_θ una política diferenciable con soporte fijo, $J(\theta) = \mathbb{E}_\theta\left(\sum_{t=0}^{H-1} \gamma^t R_t\right)$ y $G_t = \sum_{k=t}^{H-1} \gamma^{k-t} R_k$. El score de acción es $z_t = \nabla_\theta \log \pi_\theta(A_t|S_t)$. Se supone integrabilidad suficiente para intercambiar derivada e integral.

Teorema 8.18 (Identidad del gradiente de política). *En el experimento anterior,*

$$\nabla_\theta J(\theta) = \mathbb{E}_\theta\left(\sum_{t=0}^{H-1} \gamma^t z_t G_t\right) = \mathbb{E}_\theta\left(\sum_{t=0}^{H-1} \gamma^t z_t q_t^{\pi_\theta}(S_t, A_t)\right).$$

Demostración. El score de la trayectoria es $\sum_t z_t$, porque solo las probabilidades de acción dependen de θ. Multiplicarlo por el retorno total y tomar esperanza da la derivada. Las recompensas anteriores a la acción t tienen producto de esperanza cero con z_t, cuyo promedio condicional dado el historial es cero. Restan los retornos desde t, con factor γ^t. Condicionar en S_t, A_t permite sustituir G_t por q_t. Para horizonte infinito se necesitan condiciones adicionales de dominación y convergencia; $\gamma < 1$ por sí solo no controla un score arbitrariamente grande. □

Definición 8.19 (REINFORCE). Con la política congelada durante un episodio, calcule

$$\hat{g} = \sum_{t=0}^{H-1} \gamma^t z_t G_t$$

y actualice θ mediante $\theta + \eta\hat{g}$. La contribución es insesgada bajo el modelo y las condiciones anteriores. Que el gradiente sea insesgado no prueba convergencia global de la optimización.

Proposición 8.20 (Baseline: centrado y varianza). *Si b_t depende del historial anterior a actuar, pero no de la acción muestreada, $\mathbb{E}(z_t b_t) = 0$ bajo integrabilidad. Puede reemplazarse G_t por $G_t - b_t$ sin alterar la esperanza del gradiente. Una baseline aprendida con la misma acción o resultado necesita un argumento adicional de independencia o corrección.*

Para una contribución vectorial de un solo tiempo, minimizar la traza de su varianza condicional da

$$b^*(s) = \frac{\mathbb{E}(\|z\|^2 G | S = s)}{\mathbb{E}(\|z\|^2 | S = s)},$$

si el denominador es positivo. No tiene que coincidir con $V(s)$. En varios tiempos intervienen además covarianzas entre contribuciones; la fórmula local no resuelve automáticamente la minimización global.

Ejemplo 8.21 *(sintético)* **(SSCH: baseline con cálculo exacto).** En una decisión abstracta, A es Bernoulli con $p = \frac{1}{1+\exp(-\theta)}$ y $R = A$. El score es $A - p$ y el gradiente verdadero es $p(1-p)$. Tome $p = 0.75$, de modo que el gradiente es 0.1875.

Sin baseline, la contribución $A(A-p)$ vale cero o 0.25 y su varianza es 0.01171875. La baseline de valor $b = p = 0.75$ produce contribuciones 0.5625 o 0.0625: conserva la media, pero su varianza es 0.046875, cuatro veces mayor. La baseline óptima $b = 1 - p = 0.25$ produce 0.1875 para ambas acciones y varianza cero. Una baseline puede mejorar, empeorar o anular la varianza según el problema. No se ha simulado una red ni estimado un beneficio clínico.

8.6.1 El criterio de la política y la estimación del gradiente

El parámetro que indexa la política no debe confundirse con el parámetro estadístico desconocido del entorno. Si se define una pérdida de política como el negativo del retorno, derivar respecto de

su parámetro cambia el signo del gradiente de valor; no convierte todo aprendizaje profundo en una transferencia de la representación de Wald.

Definición 8.22 (Gradiente y aproximación por un crítico). Para el objetivo finito definido antes, la identidad exacta utiliza $q_t^{\pi_\theta}$ y los factores γ^t. Sustituir esa función por $\hat{q}_t$ produce un estimador cuyo sesgo incluye

$$\mathbb{E}_\theta\left(\sum_t \gamma^t z_t(\hat{q}_t(S_t, A_t) - q_t^{\pi_\theta}(S_t, A_t))\right).$$

Este término no es cero para un crítico arbitrario.

Proposición 8.23 (Momentos del gradiente y función de influencia). *Para una política fija y episodios iid, sea $Z(O) = \sum_t \gamma^t z_t G_t$, con segundo momento finito. El promedio $\hat{g}$ satisface un CLT multivariado con matriz $\Sigma = \mathrm{Var}(Z(O))$. Como estimador de la media $\mathbb{E}(Z)$ de una ley observada, su función de influencia es $Z(O) - \mathbb{E}(Z)$. La matriz Σ es una covarianza, no una función de influencia. Tampoco es automáticamente el gradiente canónico del valor J en un modelo de MDP ni coincide con la influencia de DR.*

Ejemplo 8.24 ***(sintético)*** **(Estado continuo y gradiente verificable).** Sea S uniforme en $[-1, 1]$, $\pi_\theta(1|s) = \frac{1}{1+\exp(-\theta s)}$ y recompensa abstracta $R = AS$. En $\theta = 0$, $p = \frac{1}{2}$ y el score es $S\left(A - \frac{1}{2}\right)$. El gradiente verdadero es

$$\frac{\mathbb{E}(S^2)}{4} = \frac{1}{12}.$$

Sin baseline, la contribución es $Z = A\frac{S^2}{2}$, de varianza $\frac{13}{720}$. Con baseline $b(s) = \frac{s}{2}$, vale $Z_b = \frac{S^2}{4}$, de varianza $\frac{1}{180}$. Se obtiene usando $\mathbb{E}(S^2) = \frac{1}{3}$ y $\mathbb{E}(S^4) = \frac{1}{5}$. La reducción de varianza es $\frac{9}{13}$, aproximadamente 69.2%, en este modelo exacto. No se ha entrenado una red ni afirmado convergencia a una política óptima.

Interpretar el intervalo en la decisión

8.7.1 Construcción de IC

El agente registra objetivo, política, distribución inicial y unidad independiente. Para DR de una decisión con episodios iid, usa la contribución correcta del Capítulo 7:

$$D_i = \sum_a \pi(a|S_i)\hat{m}(S_i, a) + \frac{\pi(A_i|S_i)}{\hat{b}(A_i|S_i)}(R_i - \hat{m}(S_i, A_i)).$$

Entrena las funciones fuera del episodio evaluado y comprueba las condiciones de la expansión. Calcula $\overline{D}$, s_D^2 y $\overline{D} \pm z_{1-\frac{\alpha}{2}}\frac{s_D}{\sqrt{n}}$. Para un episodio de varias decisiones usa su contribución secuencial completa; para una trayectoria o un estimador sieve, la varianza y escala se sustituyen por las justificadas para ese procedimiento.

8.7.2 Decisiones Guiadas por IC

Para comparar políticas, forme contribuciones pareadas $D_i^\Delta = D_i^{\text{nueva}} - D_i^{\text{referencia}}$. El intervalo de la diferencia usa su varianza, no el solapamiento visual entre dos intervalos marginales. La hipótesis de mejora relevante puede ser $\Delta > \delta_0$ para un margen prefijado, no necesariamente $\Delta > 0$.

Un límite inferior unilateral por encima de δ_0 aporta evidencia según el nivel y el diseño establecidos. No basta por sí solo para aprobar un despliegue: permanecen el alcance causal, la población

y las restricciones de decisión. Repetir el análisis hasta que el límite sea positivo requiere inferencia secuencial válida o un plan de análisis que controle esas revisiones.

(ver Apéndice C)

8.7.3 Trazabilidad: Del Teorema al Componente

Resultado	Componente	Alcance
Expansión por episodio	Contribuciones y varianza entre episodios.	Política fija y resto controlado.
CLT mixing	Secuencia de influencia y varianza de largo plazo.	Dependencia y momentos especificados.
Bellman sieve	Bases, momentos, inversión y sandwich.	Información y aproximación controladas.
SAVE	Aprendizaje y evaluación por bloques ordenados.	Procedimiento y condiciones originales.
Comparación pareada	Diferencias de contribuciones.	Incluye covarianza entre políticas.
Planificación de poder	Varianza de la diferencia relevante.	Aproximación para un diseño definido.

Tabla 8.2: Correspondencia entre inferencia y componentes

Hilo longitudinal: SSCH

Ejemplo 8.25 *(sintético)* **(SSCH: intervalo y comparación pareada).** Retome el entorno de dos visitas de Ejemplo 7.32. La política objetivo toma acción uno con probabilidad 0.75; la referencia con probabilidad 0.5. Sus valores verdaderos son 1.425 y 0.950, respectivamente. Los modelos de evaluación se fijan de antemano.

Para la referencia, use $\hat{q}_1(a) = 0.2 + 0.6a$ y $\hat{q}_0(a) = 0.1 + 0.8a + 0.9(0.5)$. Sus contribuciones DR, junto con las del capítulo anterior, son:

(A_0, A_1)	Objetivo	Referencia	Diferencia
$(0,0)$	1.190	0.670	0.520
$(0,1)$	1.370	1.030	0.340
$(1,0)$	1.300	0.870	0.430
$(1,1)$	1.840	1.230	0.610

Considere una realización de $n = 100$ episodios iid en la que cada trayectoria aparece 25 veces. No se ha impuesto por diseño esa frecuencia. Para la política objetivo,

$$\hat{J} = 1.425, \quad s_D^2 = \frac{100}{99}(0.061525), \quad \text{SE} \approx 0.02493.$$

Su intervalo normal aproximado del 95% es $[1.376, 1.474]$. La varianza empírica de las diferencias es $s_\Delta^2 = \left(\frac{100}{99}\right)(0.010125)$, por lo que

$$\hat{\Delta} = 0.475, \quad \text{SE}_\Delta \approx 0.01011, \quad \text{IC}_{95\%} \approx [0.455, 0.495].$$

Este intervalo usa las diferencias dentro de los mismos episodios. El cálculo es reproducible a partir de la tabla; no demuestra cobertura exacta en cien episodios ni evidencia de superioridad clínica.

De un intervalo a una afirmación revisable

La inferencia depende de una cadena de justificaciones: identificación, objetivo, régimen muestral, expansión y varianza. La identidad de riesgo y retorno del Capítulo 5 no sustituye ninguno de esos pasos. El Capítulo 9 organiza el paso siguiente: relacionar el resultado con el cálculo que realiza un agente y registrar qué conclusión autoriza. Esa revisión conservará el objetivo, el régimen de datos y la forma de estimar la varianza que dieron sentido al intervalo.

Ejercicios

Ejercicio 8.1. *Para un AR(1) estacionario con innovaciones iid de varianza finita τ^2 y coeficiente ρ con $|\rho| < 1$, calcule varianza marginal y de largo plazo. Distinga el cálculo de covarianzas de las condiciones suficientes para aplicar un CLT. Compare $\rho = 0.95$ y $\rho = -0.95$.*

Ejercicio 8.2. *Implemente HAC con pesos de Bartlett. Use la misma secuencia de contribuciones y varios rezagos máximos; describa sensibilidad y sesgos posibles. Explique por qué un resultado numérico estable no demuestra consistencia del estimador.*

Ejercicio 8.3. *Para una diferencia con desviación por episodio $\sigma_D = 2$ y efecto 0.5, calcule tamaños aproximados para poder 80% y 90%, nivel bilateral 5%. Con cien episodios, calcule el efecto detectable aproximado al 80%. Repita el planteamiento para dos grupos independientes.*

Ejercicio 8.4. *Diseñe una simulación de cobertura con valor verdadero calculado por Bellman. Repita el ajuste completo en cada réplica y reporte sesgo, cobertura, longitud e incertidumbre Monte Carlo. Incluya un escenario con pesos concentrados y otro con sesgo de aproximación persistente.*

Ejercicio 8.5. *Explique por qué SAVE no es una reescritura de DR. Para políticas distintas evaluadas en bloques, derive el término que separa un promedio de valores de bloque del valor de una política final. Compare con congelar una política y evaluarla en episodios independientes.*

Lecturas Propuestas

Lecturas Obligatorias

1. Shi et al. (2022): distinguir evaluación fija, aproximación sieve y evaluación secuencial de políticas aprendidas; leer las hipótesis completas antes de aplicar su normalización.
2. Kallus & Uehara (2020): modelo de trayectorias, razones marginales y eficiencia semiparamétrica.
3. Kallus & Uehara (2022): condiciones de evaluación eficiente en su régimen temporal específico.

Lecturas Complementarias

1. (Newey & West, 1987): construcción de covarianzas HAC y sus condiciones.
2. (Bradley, 2005): nociones de mixing y relaciones entre ellas.
3. (Hall, 1992): fundamento y límites de procedimientos bootstrap.
4. (Sutton & Barto, 2018): gradientes de política y relación entre evaluación, aproximación y optimización.

Uso educativo. Curso

Capítulo 9

Un cálculo de verificación de garantías

Una garantía se aplica a un estimando, un experimento y un procedimiento. No se aplica a un agente por el nombre de sus nodos. Este capítulo organiza la revisión que conecta esos tres objetos con la decisión final. Un catálogo común permite seguir el alcance de cada resultado cuando interviene en partes distintas del agente.

La pregunta conductora es concreta: **¿qué conclusión está autorizada por este resultado, para estos datos y esta implementación?** El resultado puede ser exacto dentro de un modelo, asintótico bajo una secuencia de experimentos, o una decisión de diseño sin garantía estadística propia. La representación de Wald del Capítulo 5 preserva el riesgo en su familia de una decisión; no reemplaza la identificación, la inferencia ni la validación del código.

La ficha de una afirmación. Registre el objetivo y la población; el modelo paramétrico, semiparamétrico o no paramétrico; la unidad de muestreo y el horizonte; el estimador y sus funciones auxiliares; el resultado citado y sus hipótesis; la evidencia disponible; y la decisión que se pretende tomar. Por ejemplo, «DR produce un IC válido» es incompleto: falta precisar qué DR, qué régimen de datos y qué condiciones controlan su resto y varianza.

Tres clases de evidencia. Una igualdad algebraica, la pertenencia de una implementación a una fórmula o una enumeración finita pueden verificarse directamente. Las condiciones del diseño, como la aleatorización registrada, requieren documentación. Los supuestos poblacionales, como ausencia de confusión no medida, regularidad o tasas de aprendizaje, se justifican mediante argumentos y análisis de sensibilidad; un diagnóstico favorable no los convierte en hechos demostrados por la muestra.

El dictamen usa cuatro estados: **aplicable bajo supuestos declarados**, **pendiente de justificación**, **no aplicable** y **regla de diseño**. El primero no significa que todos los supuestos poblacionales se hayan probado. Si cambia la población, el horizonte, la política, la regla de parada o el estimador, se revisa el dictamen. No se transforma una garantía ausente en una garantía más débil sin demostrar también esta última.

Protocolo de revisión.

1. Fijar la afirmación: estimando, comparación, nivel y alcance temporal.
2. Identificar modelo, población, unidad independiente y mecanismo de datos.
3. Escribir el estimador realmente calculado, con sus ajustes y particiones.
4. Asociar un resultado del catálogo y enumerar todas sus hipótesis relevantes.
5. Separar comprobaciones ejecutables, evidencia del diseño y supuestos.
6. Determinar qué conclusión se sostiene y qué falta justificar.
7. Traducirla a una decisión con pérdida, margen o restricción prefijados.
8. Registrar versiones, evidencia, dictamen y causas de revisión.

Objetivo, modelo, datos y procedimiento

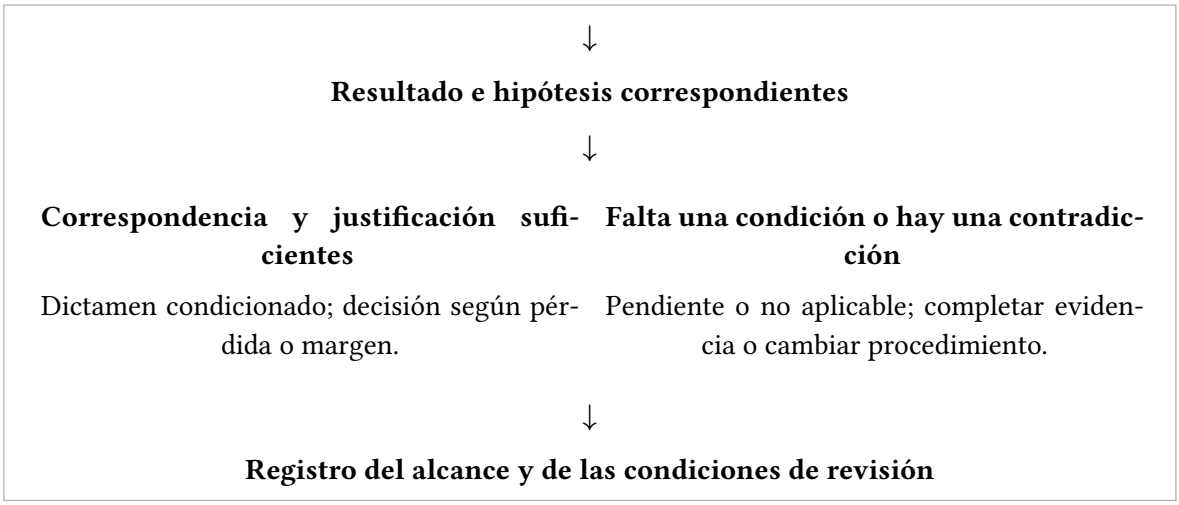


Figura 9.1: Revisión de una garantía: la evidencia incompleta conserva un dictamen pendiente, no una certificación.

La tabla relaciona cada resultado con la tarea en la que puede utilizarse y con el alcance de su conclusión. Las secciones siguientes recorren esas relaciones desde la información disponible hasta la decisión. Las vistas locales del catálogo permiten consultar las condiciones pertinentes en cada paso sin perder la referencia al resultado completo.

La tabla es un catálogo de afirmaciones condicionadas, no una certificación de implementaciones. Los identificadores permiten remitir a una sola formulación; las tablas posteriores son vistas temáticas del mismo catálogo. La evidencia y el dictamen se registran por aplicación.

Resultado	Componente	Conclusión condicionada y frontera
BETA · Actualización Beta–Bernoulli Definición 4.24	Estado de creencias	Posterior exacto dentro del modelo: observaciones Bernoulli iid, prior Beta propio y mecanismo de observación compatible. No modela por sí solo pruebas diagnósticas imperfectas.
POST · Varianza posterior Sección 9.1.2	Resumen de incertidumbre	Dispersión de theta condicional en los datos. No es la varianza frecuentista de la media posterior ni demuestra calibración del modelo.
DEC · Decisión y abstención Sección 9.1.3	Selector de acciones	Minimizar pérdida posterior requiere especificar costos y acciones. Un umbral de dispersión añadido es una regla de diseño; no hereda optimalidad Bayes.
HUM · Revisión humana Sección 9.1.1	Derivación y registro	Procedimiento operativo, sin garantía estadística automática. Debe especificarse qué información recibe el revisor y qué decisiones puede cambiar.
SEQ · Parada y revisiones Sección 9.3.3	Control temporal	Un IC de tamaño fijo no permite detenerse libremente conservando cobertura. Se necesita un método secuencial válido o un plan de análisis que controle el error.
LOG · Trazabilidad Nota 9.4	Registro de evidencia	Vincular fórmula, supuestos, datos y versión facilita auditoría. Un registro completo o un hash no prueba validez estadística.

Resultado	Componente	Conclusión condicionada y frontera
MOD · Modelo estadístico Sección 9.5.1	Especificación del experimento	Distinguir ley observada, objetivo e identificación. Una parametrización y un esquema de tipos no prueban que el modelo represente los datos.
SUF · Suficiencia Teorema 4.35	Resumen de datos	La factorización establece suficiencia para una familia especificada. No implica automáticamente estado Markov para futuras decisiones.
EXP · Familia exponencial Teorema 4.23	Actualización incremental	Bajo el modelo iid y dimensión fija, el estadístico natural puede actualizarse por sumas. No toda familia es minimal ni toda memoria del agente puede descartarse.
MOM · Log--partición Teorema 4.18	Cálculo de momentos	Sus derivadas dan momentos bajo diferenciabilidad e intercambio válido con la integral. La identidad es condicional a la familia especificada.
MIN · Suficiencia minimal Sección 9.1.8	Reducción estadística	Minimalidad compara sigma-álgebras suficientes, salvo conjuntos nulos; no minimiza bytes ni equivale a completitud.
COM · Completitud Sección 9.1.9	Unicidad insesgada	Si una función integrable del estadístico tiene esperanza cero para todos los parámetros, es nula casi seguramente. No elimina toda redundancia computacional.
BAS · Basu Teorema 4.48	Separación de estadísticas	Suficiencia completa y ancilaridad implican independencia. Un campo llamado contexto no es ancilar por su nombre.
EQU · Equivarianza Sección 9.1.10	Consistencia ante simetrías	Comprobar transformaciones del modelo, pérdida y acción. La restricción a reglas equivariantes necesita un argumento separado de optimalidad.
RED · Reducción de reglas Proposición 9.1	Política basada en un resumen	Un núcleo condicional independiente del parámetro preserva el riesgo de reglas aleatorizadas. Para acciones deterministas se necesitan condiciones adicionales.
RB · Rao–Blackwell Proposición 9.3	Mejora de estimación	Condicionamiento implementable en un estadístico suficiente, con segundo momento finito: mismo sesgo y varianza no mayor. No garantiza eficiencia semiparamétrica.
LS · Lehmann–Scheffé Teorema 4.60	Selección de estimador	Un estimador insesgado con varianza finita, función de un estadístico suficiente completo, es UMVUE. La comparación se restringe a estimadores insesgados.
CR · Cramér–Rao Proposición 9.2	Referencia de precisión	Para valor g(theta), estimación insesgada y experimento paramétrico regular: cota con gradiente de g e inversa de la información del experimento.
MSE · Sesgo y varianza Sección 9.2.2	Evaluación de error	Con segundo momento finito, ECM = varianza + sesgo al cuadrado. La identidad no prescribe qué estimador minimiza el ECM.

Resultado	Componente	Conclusión condicionada y frontera
MLE · Máxima verosimilitud Teorema 4.70	Estimación del entorno	Consistencia, normalidad y eficiencia requieren condiciones específicas: identificación, regularidad y control de la optimización. No basta maximizar una función.
NP · Neyman–Pearson Teorema 4.83	Contraste simple	Máxima potencia para dos hipótesis simples y nivel fijado, con aleatorización si corresponde. No es un resultado UMP para toda alternativa compuesta.
UMP · Razón monótona de verosimilitud Teorema 4.86	Contraste unilateral	UMP solo en las familias y alternativas que cumplen las hipótesis del resultado correspondiente.
CI · Inversión de contrastes Teorema 4.91	Intervalo y comparación	El conjunto invertido hereda el nivel de los contrastes utilizados. Distinguir cobertura finita de asintótica y puntual de simultánea.
FWER · Bonferroni y Holm Teorema 4.97	Comparaciones múltiples	Control de probabilidad de al menos un falso rechazo hasta alpha, con p-valores válidos. No promete ausencia de falsos positivos.
FDR · Benjamini–Hochberg Teorema 4.98	Selección múltiple	Control de proporción esperada de falsos descubrimientos bajo independencia o dependencia admitida. No controla la probabilidad de cada decisión individual.
POWER · Potencia y tamaño muestral Proposición 8.16	Planificación	Depende de alternativa, efecto, diseño y varianza de la diferencia. La fórmula normal del capítulo de intervalos es una aproximación.
CLT · CLT por episodio Sección 8.1.1	Error estándar	Episodios iid, contribución con varianza finita positiva y resto despreciable. Dependencia dentro de episodios no crea más unidades independientes.
DELTA · Método delta Teorema 4.106	Transformación de estimandos	Expansión diferenciable y límite del estimador inicial; si la derivada se anula o el funcional es no regular, revisar la escala y el límite.
GC · Glivenko–Cantelli Teorema 4.110	Distribución empírica	Para la CDF univariada iid, convergencia uniforme casi segura; para otras clases, verificar condiciones. No constituye un intervalo por sí sola.
DON · Donsker Teorema 4.112	Proceso empírico	Un límite funcional exige la clase y topología apropiadas; estimación de funciones auxiliares o dependencia requieren condiciones adicionales.
BOOT · Bootstrap Sección 9.4.1	Remuestreo para inferencia	Respetar unidad independiente o bloques y justificar consistencia para el funcional; considerar el reajuste. Aumentar réplicas no corrige un bootstrap inválido.
BT · Bootstrap studentizado Ejemplo 4.118	Refinamiento del IC	Mejoras de orden superior necesitan momentos, suavidad y expansión suficientes. No se atribuye un error universal de orden n elevado a menos uno.

Dr. Jaime Lara Jiménez

Resultado	Componente	Conclusión condicionada y frontera
TAN · Espacio tangente Sección 9.5.1	Definición de eficiencia	El gradiente canónico depende del modelo observado y sus restricciones. Una función centrada cualquiera no es necesariamente eficiente.
EIF · Gradiente canónico OPE Teorema 4.146	Contribuciones de valor	En el modelo Markov de horizonte finito por tiempo: razones marginales y residuos de Bellman. Eficiencia requiere además una expansión regular con resto despreciable.
BOUND · Cota semiparamétrica Teorema 4.140	Comparación de estimadores	Cota entre estimadores regulares en un modelo fijado. No se identifica con la cota de un modelo distinto ni con una garantía finita.
ORTH · Ortogonalidad Sección 9.5.3	Momento de estimación	Derivada poblacional nula respecto del auxiliar en la verdad; hay que controlar el resto de orden superior y la fluctuación empírica.
DR · Doble robustez Sección 9.5.2	Evaluación aumentada	La identidad poblacional y condiciones de convergencia permiten consistencia si uno de los conjuntos auxiliares es correcto. Esto no basta para un IC eficiente.
DML · Cross--fitting y DML Teorema 4.150	Aprendizaje auxiliar	Separación por unidades, convergencia y productos de errores pequeños a escala raíz de n; también momentos y varianza. El algoritmo de partición no prueba esas tasas.
WALD · Problema y riesgo de Wald Definición 2.1	Criterio de decisión	Modelo, espacio de acciones y pérdida especificados; riesgo como esperanza de pérdida. Representar un problema no prueba identificación ni optimalidad.
BAYES · Regla de Bayes Teorema 2.9	Minimización posterior	Prior y pérdida especificados, riesgo definido y mínimo alcanzado. El resultado es relativo a ese problema.
MM · Minimax Teorema 2.14	Peor riesgo	La certificación Bayes requiere que el riesgo máximo global iguale al riesgo Bayes; constancia solo sobre el soporte del prior no basta.
ADM · Admisibilidad Definición 2.5	No dominancia	Ausencia de otra regla que mejore todos los riesgos y alguno estrictamente, dentro de la clase comparada. Bayes no implica admisibilidad sin condiciones.
CC · Clase completa Teorema 2.12	Restricción de reglas	Aplicar la versión del teorema con sus condiciones y clase de reglas. No implica que toda regla admisible sea Bayes para un prior propio.
MDP · Modelo de Markov Definición 3.1	Estado y dinámica	La ley del siguiente estado y recompensa debe corresponder al historial resumido y a la acción; omitir variables puede romper la representación.
BELL · Bellman y contracción Teorema 3.12	Planificación	Para MDP finito descontado y recompensas acotadas, el operador contrae en norma suprema. Convergencia computacional dentro del modelo no valida el modelo.

Dr. Jaime Hernández Garcés

Resultado	Componente	Conclusión condicionada y frontera
VI · Iteración de valores Teorema 3.14	Cálculo de valor óptimo	Modelo finito conocido, descuento menor que uno y actualizaciones exactas dan convergencia geométrica. Aproximación y error del modelo se controlan aparte.
PI · Mejora y extracción de política Teorema 3.16	Selección greedy	En el MDP finito descontado, evaluación exacta y elección greedy dan mejora no decreciente y permiten una política óptima determinista.
STOP · Residuo de Bellman Corolario 3.15	Parada computacional	Con contracción gamma, el error de valor no supera el residuo dividido por uno menos gamma. Es distinto de la pérdida de valor de la política extraída.
EMB · Incrustación Wald–MDP Teorema 5.3	Representación de reglas	Identidad de retorno integrado y riesgo negativo en la familia de una decisión y transición terminal determinista. No transfiere garantías a cualquier agente.
IMAGE · Imagen de un conjunto de confianza Sección 9.3.2	Transformación de incertidumbre	Con mapa conocido g y política fija, g(C) contiene g(theta) siempre que C contiene theta; su cobertura es al menos la del conjunto original.
IS · Importance sampling Capítulo 7	Reponderación	Razones correctas, soporte e integrabilidad permiten insesgadez del estimador no normalizado. Razones estimadas o normalización cambian sus propiedades.
SIEVE · Bellman sieve de SZLS Nota 8.8	Inferencia de valor	Procedimiento y condiciones completos del artículo, incluidas aproximación, información y varianza; no equivale al estimador DR.
MIX · CLT con mixing Teorema 8.7	Inferencia dependiente	Estacionariedad, momentos, sumabilidad de mixing y varianza de largo plazo positiva según el teorema; un diagnóstico ACF no los prueba.
HAC · Varianza de largo plazo Proposición 8.12	Studentización	Estimar covarianzas y controlar rezagos y error agregado según un resultado de consistencia. No hay un ancho universal.
SAVE · Evaluación secuencial SAVE Definición 8.13	Políticas aprendidas	Respetar bloques, agregación y condiciones de la evaluación secuencial original. No es una corrección DR ni una garantía de optimalidad aprendida.

Tabla 9.1: Catálogo canónico de garantías: resultados, componentes y límites de aplicación.

Conservar la información que necesita la decisión

La revisión comienza por los datos que recibe el agente y por lo que guarda de ellos. Para interpretar una estimación debemos poder reconstruir la unidad de observación, la información anterior a la acción y el mecanismo que produjo el registro.

9.1.1 Arquitectura de Nodos: Observación, Creencias, Decisión

El nodo de observación recibe unidades definidas por el diseño: pacientes, episodios completos o transiciones de una trayectoria. Registra procedencia, acción tomada, resultado y mecanismo de asignación cuando corresponda. Contar filas no determina el número de unidades independientes.

El nodo de inferencia calcula un estimador o una distribución posterior bajo un modelo explícito. Debe devolver también el estimando, la escala de la incertidumbre y las condiciones pendientes. El nodo de decisión utiliza esos resultados junto con una pérdida o un margen prefijado. Un nodo adicional de revisión conserva los motivos de abstención y las modificaciones humanas.

Un sistema de tipos puede exigir que cada resultado incluya esos campos; no puede certificar por sí solo suficiencia, identificación causal o cobertura. La arquitectura implementa el procedimiento que se ha justificado, y su verificación requiere comprobar que el código coincide con él. (ver Apéndice C)

9.1.2 El Estado como Estadístico Suficiente

La suficiencia es una propiedad relativa a una familia de distribuciones. Si $T(X)$ es suficiente para θ, la ley condicional de X dado T puede elegirse independiente de θ bajo las condiciones correspondientes. Esto permite reducir el experimento estadístico, pero no demuestra que T sea un estado Markov suficiente para cualquier entorno secuencial.

En observaciones Bernoulli iid con tamaño fijo conocido, la suma de éxitos es suficiente minimal para $\theta \in (0,1)$. Si el tamaño cambia, se registra también cuántas unidades se observaron. Para un prior Beta fijo, sus parámetros actualizados codifican éxitos y fracasos; no son una representación universal de toda la información que necesita un agente.

Ejemplo integrador: Agente de diagnóstico médico con asistencia del médico

Modelo pedagógico sintético. Suponga que se observan estados de enfermedad confirmados $Y_i \in \{0,1\}$ de personas independientes e intercambiables, con $Y_i|\theta \sim \text{Bernoulli}(\theta)$ y prior $\theta \sim \text{Beta}(a_0, b_0)$. No se trata de repetir un test imperfecto en un mismo paciente. Ese otro problema requiere modelar sensibilidad, especificidad y dependencia de las pruebas.

Con $s = \sum_i Y_i$, el posterior es $\text{Beta}(a, b)$, donde

$$a = a_0 + s, \quad b = b_0 + n - s.$$

La probabilidad predictiva para una nueva persona sin otras covariables es $p = \mathbb{E}(\theta|Y) = \frac{a}{a+b}$ y la varianza posterior es

$$\text{Var}(\theta|Y) = \frac{ab}{(a+b)^2(a+b+1)}.$$

Esta varianza describe incertidumbre sobre la prevalencia. No es $\text{Var}_\theta\left(\hat{\theta}\right)$ ni la varianza predictiva de la enfermedad de la nueva persona, que es $p(1-p)$.

Considere dos acciones abstractas. Tratar a una persona sana cuesta c; no tratar a una persona enferma cuesta d; las otras pérdidas se fijan en cero. La pérdida se escribe $L(Y, a)$, con Y binaria; no se confunde ese estado con la prevalencia continua θ. Las pérdidas predictivas son

$$\ell(\text{tratar}) = c(1-p), \quad \ell(\text{no tratar}) = dp.$$

Por tanto, tratar minimiza la pérdida entre esas dos acciones si

$$p > \frac{c}{c+d},$$

con indiferencia en la igualdad. El umbral disminuye si aumenta el costo de omitir una enfermedad. Es una comprobación útil del sentido de la fórmula.

Tome prior $\mathrm{Beta}(1,1)$ y 12 enfermos confirmados en 100 observaciones. Entonces $a = 13$, $b = 89$, $p = \frac{13}{102} \approx 0.12745$ y la desviación posterior es aproximadamente 0.03286. Con $c = 1, d = 9$, el umbral es 0.10; las pérdidas son $\frac{89}{102} \approx 0.87255$ al tratar y $\frac{117}{102} \approx 1.14706$ al no tratar. Dentro de este modelo, la primera acción tiene menor pérdida esperada. No es una recomendación clínica.

Si se añade «consultar» cuando la desviación posterior supera 0.03, esta observación se deriva a revisión. Esa regla es una restricción de diseño; no es la regla Bayes de dos acciones que acabamos de derivar. Para justificar una tercera acción óptima hay que especificar el costo de consultar, la información que aporta y las decisiones posteriores.

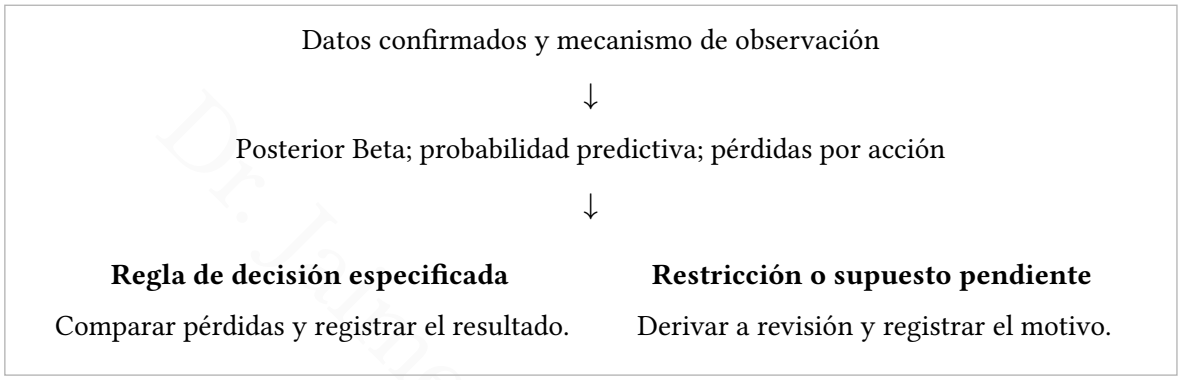


Figura 9.2: Ejemplo sintético: separar actualización, comparación de pérdidas y revisión.

Resultado	Componente	Conclusión condicionada y frontera
BETA · Actualización Beta–Bernoulli Definición 4.24	Estado de creencias	Posterior exacto dentro del modelo: observaciones Bernoulli iid, prior Beta propio y mecanismo de observación compatible. No modela por sí solo pruebas diagnósticas imperfectas.
POST · Varianza posterior Sección 9.1.2	Resumen de incertidumbre	Dispersión de theta condicional en los datos. No es la varianza frecuentista de la media posterior ni demuestra calibración del modelo.
DEC · Decisión y abstención Sección 9.1.3	Selector de acciones	Minimizar pérdida posterior requiere especificar costos y acciones. Un umbral de dispersión añadido es una regla de diseño; no hereda optimalidad Bayes.
BAYES · Regla de Bayes Teorema 2.9	Minimización posterior	Prior y pérdida especificados, riesgo definido y mínimo alcanzado. El resultado es relativo a ese problema.
HUM · Revisión humana Sección 9.1.1	Derivación y registro	Procedimiento operativo, sin garantía estadística automática. Debe especificarse qué información recibe el revisor y qué decisiones puede cambiar.
SEQ · Parada y revisiones Sección 9.3.3	Control temporal	Un IC de tamaño fijo no permite detenerse libremente conservando cobertura. Se necesita un método secuencial válido o un plan de análisis que controle el error.

Resultado	Componente	Conclusión condicionada y frontera
LOG · Trazabilidad Nota 9.4	Registro de evidencia	Vincular fórmula, supuestos, datos y versión facilita auditoría. Un registro completo o un hash no prueba validez estadística.

Tabla 9.2: Componentes y alcance del ejemplo Beta–Bernoulli.

Ejemplo práctico: Agente Bernoulli-Beta

En un ejemplo de clics, mantenga el mismo modelo con prior $\mathrm{Beta}(1,1)$ y observe 18 clics en 100 exposiciones comparables e independientes. El posterior es $\mathrm{Beta}(19,83)$ y $p = \frac{19}{102} \approx 0.18627$. Si mostrar el producto produce beneficio uno cuando hay clic y cuesta 0.15 en cada exposición, su beneficio predictivo es $p - 0.15 \approx 0.03627$, frente a cero al no mostrarlo.

La decisión favorable se refiere a ese modelo, costo y población. Si las exposiciones fueron seleccionadas por una política adaptativa o cambió la población, la verosimilitud y el objetivo deben revisarse. La actualización conjugada puede seguir siendo algebraicamente correcta para una verosimilitud especificada y, sin embargo, describir mal el experimento.

9.1.3 Incertidumbre y Criterios de Decisión

Una baja varianza no implica bajo sesgo, buena predicción individual ni validez causal. Un IC frecuentista tiene una propiedad de cobertura bajo un diseño; una distribución posterior expresa incertidumbre condicional en un modelo y un prior. Sus interpretaciones no se intercambian.

El criterio de decisión añade una pérdida, un margen de mejora o una restricción. Un intervalo estrecho puede estar enteramente en una región desfavorable; por ello su anchura no basta para autorizar una acción. Repetir análisis hasta lograr el criterio requiere controlar la regla de parada. En la incrustación del Capítulo 5, la igualdad es $J_\theta(\pi_\delta) = -R(\theta, \delta)$ para el retorno integrado de una decisión. No es una identidad entre cualquier intervalo y una política óptima.

9.1.4 Registrar las condiciones de la representación

Estas filas distinguen propiedades del modelo, compresión de observaciones y reglas de decisión. Leerlas por separado permite identificar qué justifica la representación de los datos y qué criterio se utiliza para elegir una acción.

Resultado	Componente	Conclusión condicionada y frontera
MOD · Modelo estadístico Sección 9.5.1	Especificación del experimento	Distinguir ley observada, objetivo e identificación. Una parametrización y un esquema de tipos no prueban que el modelo represente los datos.
SUF · Suficiencia Teorema 4.35	Resumen de datos	La factorización establece suficiencia para una familia especificada. No implica automáticamente estado Markov para futuras decisiones.
DEC · Decisión y abstención Sección 9.1.3	Selector de acciones	Minimizar pérdida posterior requiere especificar costos y acciones. Un umbral de dispersión añadido es una regla de diseño; no hereda optimalidad Bayes.
EXP · Familia exponencial Teorema 4.23	Actualización incremental	Bajo el modelo iid y dimensión fija, el estadístico natural puede actualizarse por sumas. No toda familia es minimal ni toda memoria del agente puede descartarse.

Resultado	Componente	Conclusión condicionada y frontera
MOM · Log--partición Teorema 4.18	Cálculo de momentos	Sus derivadas dan momentos bajo diferenciabilidad e intercambio válido con la integral. La identidad es condicional a la familia especificada.
MSE · Sesgo y varianza Sección 9.2.2	Evaluación de error	Con segundo momento finito, ECM = varianza + sesgo al cuadrado. La identidad no prescribe qué estimador minimiza el ECM.

Tabla 9.3: Modelo, información y decisión: vista del catálogo.

9.1.5 Conexión con la Correspondencia Estructural

Reducir una observación y representar una regla en un MDP son operaciones distintas. La primera necesita suficiencia y una clase de acciones; la segunda copia la regla en la familia construida en el Capítulo 5.

Proposición 9.1 (Suficiencia y Políticas Óptimas). *Suponga espacios estándar de Borel y un núcleo condicional común $K(\mathrm{d}x|t)$ de X dado $T = t$, independiente del parámetro. Para una regla aleatorizada $\delta(\mathrm{d}a|x)$ con pérdida integrable, defina $\delta_T(\mathrm{d}a|t) = \int \delta(\mathrm{d}a|x)K(\mathrm{d}x|t)$. Entonces $R(\theta, \delta_T) = R(\theta, \delta)$ para todo θ. La comparación se hace en la clase de reglas aleatorizadas.*

Demostración. Integrar la pérdida bajo δ_T y después sobre la distribución de T reproduce, por esperanza iterada, la integral original bajo X y δ. La independencia del núcleo respecto de θ hace implementable la regla. Si se exige una acción determinista, esta construcción puede salir de la clase permitida. Para acciones en un conjunto convexo y pérdida convexa, la media condicional, cuando existe y pertenece al espacio de acciones, da riesgo no mayor por Jensen, pero no igualdad automática para toda regla. □

La aleatorización de esta proposición no amplía silenciosamente el teorema central, que se enuncia para reglas deterministas. Con acciones discretas, la media de dos acciones puede no ser una acción admisible.

9.1.6 El Estado del Agente como Estadístico Suficiente

Para un modelo iid exponencial, el resumen puede actualizarse como $T_{n+1} = T_n + t(X_{n+1})$. Debe conservarse el tamaño muestral cuando participa en la verosimilitud. El estado operacional puede necesitar además tiempos, acciones, probabilidades de asignación y datos para auditoría.

En un sistema longitudinal, la suficiencia para un parámetro estático no implica suficiencia predictiva de la siguiente transición. Esa segunda propiedad exige especificar la dinámica y la información disponible antes de actuar. Un resumen válido para estimar prevalencia puede ser insuficiente para elegir tratamientos según la historia de cada paciente.

9.1.7 Separación Conceptual: Estado versus Contexto

Basu establece independencia entre un estadístico suficiente completo y un estadístico ancilar bajo sus hipótesis. Ancilar significa que su ley no depende del parámetro; no significa «campo de contexto» ni «variable que parece secundaria».

Una fecha de medición puede revelar un cambio de población; una covariable puede ser necesaria para identificar un efecto. No deben descartarse por llamarlas contexto. La separación de memoria es una decisión de ingeniería que debe justificarse mediante el modelo y las necesidades de trazabilidad.

9.1.8 Diseño de Memoria Eficiente

Una familia exponencial iid con estadístico aditivo de dimensión fija k permite almacenar $O(k)$ números y actualizar sus sumas en $O(k)$ operaciones. Esto no implica memoria constante en bits: los contadores necesitan más bits al crecer n, y conservar datos o procedencia tiene otro costo.

La minimalidad estadística compara la información contenida en estadísticas suficientes, salvo conjuntos nulos. No determina un formato óptimo de archivos ni permite borrar registros necesarios para detectar errores de medición, cambios de modelo o decisiones adaptativas.

9.1.9 Completitud y Unicidad de la Representación

La completitud establece que una función integrable del estadístico con esperanza cero para todos los parámetros es nula casi seguramente. Junto con suficiencia e insesgadez, Lehmann–Scheffé da unicidad del estimador UMVUE, cuando existe y tiene varianza finita.

No es una garantía de representación computacional mínima. Si T es completo, almacenar (T, T) no destruye esa propiedad y, sin embargo, duplica un campo. Tampoco compara el UMVUE con todos los estimadores sesgados bajo error cuadrático medio, ni asegura buen comportamiento fuera del modelo.

9.1.10 Equivarianza en el Comportamiento del Agente

La equivarianza exige que transformar datos y después decidir coincida con decidir y transformar la acción según la regla correspondiente. Antes de imponerla deben comprobarse las transformaciones del modelo y de la pérdida. Cambiar la unidad monetaria, por ejemplo, exige transformar también costos y umbrales.

Restringir la búsqueda a reglas equivariantes puede simplificar el problema; conservar optimalidad requiere un resultado adicional sobre esa clase y ese criterio. La simetría visual de una arquitectura no lo demuestra.

9.1.11 Qué respalda la reducción de datos

Resultado	Componente	Conclusión condicionada y frontera
SUF · Suficiencia Teorema 4.35	Resumen de datos	La factorización establece suficiencia para una familia especificada. No implica automáticamente estado Markov para futuras decisiones.
MIN · Suficiencia minimal Sección 9.1.8	Reducción estadística	Minimalidad compara sigma-álgebras suficientes, salvo conjuntos nulos; no minimiza bytes ni equivale a completitud.
COM · Completitud Sección 9.1.9	Unicidad insesgada	Si una función integrable del estadístico tiene esperanza cero para todos los parámetros, es nula casi seguramente. No elimina toda redundancia computacional.
BAS · Basu Teorema 4.48	Separación de estadísticas	Suficiencia completa y ancilaridad implican independencia. Un campo llamado contexto no es ancilar por su nombre.
EQU · Equivarianza Sección 9.1.10	Consistencia ante simetrías	Comprobar transformaciones del modelo, pérdida y acción. La restricción a reglas equivariantes necesita un argumento separado de optimalidad.

Resultado	Componente	Conclusión condicionada y frontera
RED · Reducción de reglas Proposición 9.1	Política basada en un resumen	Un núcleo condicional independiente del parámetro preserva el riesgo de reglas aleatorizadas. Para acciones deterministas se necesitan condiciones adicionales.

Tabla 9.4: Reducción de información y límites de su uso en un estado.

9.1.12 Conexión con la Correspondencia Estructural

El valor de una política fija puede ser un funcional de un parámetro del entorno. La información relevante es la del experimento observado completo, no necesariamente la de una recompensa aislada.

Proposición 9.2 (Estimación de Valores y Cramér-Rao). *En un experimento paramétrico regular con n episodios iid, sea $g(\theta) = J_\theta(\pi)$ diferenciable, con política fija. Si $\hat{J}$ es insesgado para $g(\theta)$, tiene varianza finita y se cumplen las condiciones de diferenciación e información, entonces*

$$\operatorname{Var}_\theta\big(\hat{J}\big) \geq \frac{1}{n} \nabla g(\theta)^T I_1(\theta)^{-1} \nabla g(\theta),$$

donde I_1 es la información de Fisher invertible de un episodio. Para parámetro escalar, la cota es $\frac{(g'(\theta))^2}{n I_1(\theta)}$.

Demostración. El score total tiene varianza nI_1 y su covarianza con $\hat{J}$ es ∇g, al derivar la identidad de insesgadez. La desigualdad de covarianzas da la cota. La derivada del funcional no puede omitirse.□

Proposición 9.3 (Rao-Blackwell para Q-Estimadores). *Para política, estado y acción fijos, sea U un estimador de $q^\pi(s,a)$ con segundo momento finito. Si T es suficiente y $\tilde{U} = \mathbb{E}(U|T)$ puede elegirse sin usar el parámetro desconocido, entonces tiene la misma esperanza y varianza no mayor que U.*

Demostración. La esperanza iterada conserva la media; la descomposición $\operatorname{Var}(U) = \operatorname{Var}(\mathbb{E}(U|T)) + \mathbb{E}(\operatorname{Var}(U|T))$ prueba la reducción. La suficiencia permite una versión implementable del condicionamiento; la identidad de varianzas, por sí sola, no proporciona cómo calcularla.□

Elegir un objetivo y un estimador

Una representación adecuada de los datos permite formular qué se pretende aprender. El valor de una política puede ser un funcional de un modelo paramétrico o de una ley más amplia; esa elección determina cómo se estudian sesgo, varianza y eficiencia.

9.2.1 Estimación de Funciones de Valor

Defina primero política, población inicial, horizonte y descuento. En un modelo paramétrico regular, $J = g(\theta)$ puede estimarse por sustitución y analizarse mediante delta. En un modelo semiparamétrico se estudia la regularidad del funcional y su influencia. En un modelo no paramétrico, no todo valor puntual ni toda función de valor admite tasa raíz de n.

La representación de riesgo del Capítulo 5 conserva una cantidad esperada; no produce una expansión asintótica del estimador de esa cantidad.

9.2.2 El Trade-off Sesgo-Varianza en Agentes

Con segundo momento finito,

$$\mathbb{E}\Big(\big(\hat{J} - J\big)^2\Big) = \operatorname{Var}\big(\hat{J}\big) + \Big(\mathbb{E}\big(\hat{J}\big) - J\Big)^2.$$

Una estimación estable puede estar sistemáticamente desplazada. Una regularización puede disminuir el ECM a costa de sesgo, aunque excluya al estimador de una comparación UMVUE.

Para una decisión importa además la distancia al umbral. Dos estimadores con ECM parecido pueden dar frecuencias distintas de seleccionar una política inferior. La evaluación debe incluir el objetivo inferencial y la pérdida de la decisión, sin confundir ambas métricas.

9.2.3 Rao-Blackwellización de Estimadores Monte Carlo

Un retorno generado bajo la política objetivo, desde el estado y acción especificados, estima insesgadamente el valor de horizonte finito. Un retorno infinito necesita integrabilidad. Si se trunca a H y $|R_t| \le B$, con $0 < \gamma < 1$, el sesgo absoluto frente al valor infinito se acota por $B\frac{\gamma^H}{1-\gamma}$.

Condicionar un estimador en un resumen con ley condicional conocida puede reducir varianza; sustituir esa esperanza por una regresión aprendida no hereda automáticamente el resultado exacto. Una evaluación off-policy requiere, además, corregir la distribución de las acciones y estados.

9.2.4 Límites de Precisión: Cramér-Rao en Agentes

Ejemplo paramétrico calculable. Observe n recompensas Bernoulli iid de probabilidad θ y defina $J = 2\theta$. La información por observación es $I_1(\theta) = \frac{1}{\theta(1-\theta)}$. La cota correcta es

$$\operatorname{Var}\left(\hat{J}\right) \ge \frac{4\theta(1-\theta)}{n}.$$

El estimador $2\overline{X}$ la alcanza. En $\theta = 0.5$ y $n = 100$, la varianza es 0.01; omitir la derivada daría 0.0025, cuatro veces menor.

Para exigir varianza no mayor que ϵ^2, la cota proporciona una condición necesaria sobre n dentro de la clase regular insesgada. Solo cuando se sabe que el estimador alcanza la cota puede usarse como condición suficiente de varianza. En este ejemplo, $n \ge 100$ controla la varianza por 0.01 uniformemente en θ. Esto no es todavía una garantía de cobertura ni de potencia de un contraste.

9.2.5 Qué precisión puede atribuirse al estimador

Resultado	Componente	Conclusión condicionada y frontera
RB · Rao–Blackwell Proposición 9.3	Mejora de estimación	Condicionamiento implementable en un estadístico suficiente, con segundo momento finito: mismo sesgo y varianza no mayor. No garantiza eficiencia semiparamétrica.
LS · Lehmann–Scheffé Teorema 4.60	Selección de estimador	Un estimador insesgado con varianza finita, función de un estadístico suficiente completo, es UMVUE. La comparación se restringe a estimadores insesgados.
CR · Cramér–Rao Proposición 9.2	Referencia de precisión	Para valor g(theta), estimación insesgada y experimento paramétrico regular: cota con gradiente de g e inversa de la información del experimento.
MSE · Sesgo y varianza Sección 9.2.2	Evaluación de error	Con segundo momento finito, ECM = varianza + sesgo al cuadrado. La identidad no prescribe qué estimador minimiza el ECM.
MLE · Máxima verosimilitud Teorema 4.70	Estimación del entorno	Consistencia, normalidad y eficiencia requieren condiciones específicas: identificación, regularidad y control de la optimización. No basta maximizar una función.

Tabla 9.5: Estimación: clase comparada, precisión y sesgo.

Comparar políticas con un error de decisión declarado

La precisión de una estimación adquiere un significado distinto cuando se usa para elegir entre políticas. La comparación debe incorporar el diseño, la dependencia entre estimaciones y el número de decisiones que se apoyarán en los mismos datos.

9.3.1 A/B Testing de Políticas

Para dos políticas fijas, defina $\Delta = J(\pi_1) - J(\pi_0)$ y un margen relevante δ_0. Contraste $H_0 : \Delta \leq \delta_0$ frente a $H_1 : \Delta > \delta_0$. En un ensayo aleatorizado por episodios, el análisis respeta esa unidad; en OPE, la comparación requiere además identificación, soporte y la expansión del estimador utilizado.

El nivel controla falsos rechazos bajo la nula según el diseño. No es la probabilidad posterior de que la política sea peor después de observar un rechazo. La potencia depende de una alternativa concreta, del tamaño y de la varianza. Fijar un nivel pequeño no asegura potencia suficiente.

9.3.2 Intervalos de Confianza para Diferencias de Valor

Cuando las dos políticas se evalúan sobre los mismos episodios, forme $D_i^{\Delta} = D_i^{\text{nueva}} - D_i^{\text{referencia}}$ y estime la varianza de esas diferencias. Dos intervalos marginales que se solapan no equivalen a un contraste de la diferencia. Un límite inferior válido superior al margen aporta evidencia bajo el diseño especificado; un intervalo que contiene cero no demuestra equivalencia.

Transferencia por imagen. Si C cubre un parámetro θ y g es un mapa conocido para una política fija, entonces

$$\theta \in C \Rightarrow g(\theta) \in g(C).$$

Por tanto, $g(C)$ tiene cobertura al menos igual a la de C. En dimensión mayor o con g no monótona, transformar solo dos extremos puede fallar. Por ejemplo, para $g(\theta) = \theta^2$ y $C = [-1, 2]$, la imagen es $[0, 4]$; usar únicamente los cuadrados de los extremos produce $[1, 4]$ y pierde cero.

9.3.3 Comparación de Múltiples Políticas

Bonferroni y Holm controlan FWER con p-valores válidos; no eliminan todo falso positivo. Benjamini–Hochberg controla FDR bajo las condiciones de dependencia admitidas. FDR no es una probabilidad de error individual ni una autorización automática para desplegar la mejor variante observada. Seleccionar políticas y evaluarlas con los mismos datos introduce otra fuente de selección que también debe tratarse.

Repetir un test de Wald de tamaño fijo en cada consulta no produce un contraste secuencial válido. El SPRT es un contraste secuencial de razón de verosimilitudes, no un test de rangos. Su aplicación exige hipótesis, modelo y fronteras apropiados; no justifica cualquier regla de parada. Puede usarse una secuencia de confianza válida para todo tiempo o un plan de análisis con control de revisiones, según el experimento.

En la ruta bayesiana, las odds posteriores son el factor de Bayes por las odds previas. Para dos hipótesis y pérdidas c por falsa adopción y d por falsa omisión, se elige la alternativa cuando las odds posteriores superan $\frac{c}{d}$, bajo esa matriz de pérdidas. El factor de Bayes aislado no elimina el prior, la pérdida ni el mecanismo de observación. Tampoco otorga por sí solo control frecuentista de error bajo parada opcional.

9.3.4 Qué error controla la comparación

Resultado	Componente	Conclusión condicionada y frontera
NP · Neyman–Pearson Teorema 4.83	Contraste simple	Máxima potencia para dos hipótesis simples y nivel fijado, con aleatorización si corresponde. No es un resultado UMP para toda alternativa compuesta.
UMP · Razón monótona de verosimilitud Teorema 4.86	Contraste unilateral	UMP solo en las familias y alternativas que cumplen las hipótesis del resultado correspondiente.
CI · Inversión de contrastes Teorema 4.91	Intervalo y comparación	El conjunto invertido hereda el nivel de los contrastes utilizados. Distinguir cobertura finita de asintótica y puntual de simultánea.
FWER · Bonferroni y Holm Teorema 4.97	Comparaciones múltiples	Control de probabilidad de al menos un falso rechazo hasta alpha, con p-valores válidos. No promete ausencia de falsos positivos.
FDR · Benjamini–Hochberg Teorema 4.98	Selección múltiple	Control de proporción esperada de falsos descubrimientos bajo independencia o dependencia admitida. No controla la probabilidad de cada decisión individual.
POWER · Potencia y tamaño muestral Proposición 8.16	Planificación	Depende de alternativa, efecto, diseño y varianza de la diferencia. La fórmula normal del capítulo de intervalos es una aproximación.
SEQ · Parada y revisiones Sección 9.3.3	Control temporal	Un IC de tamaño fijo no permite detenerse libremente conservando cobertura. Se necesita un método secuencial válido o un plan de análisis que controle el error.

Tabla 9.6: Contrastes, multiplicidad y revisiones temporales.

Relacionar el intervalo con su régimen de muestreo

La forma del estimador no determina por sí sola cómo cuantificar su incertidumbre. El remuestreo, las aproximaciones normales y las transformaciones de conjuntos de confianza deben conservar el objetivo y la estructura de los datos.

9.4.1 Cuantificación de Incertidumbre vía Bootstrap

Para una media de retornos de episodios iid, el bootstrap remuestrea **episodios completos**. Para comparar políticas se conserva el emparejamiento dentro de cada episodio. Si el estimador aprende modelos auxiliares, se reajusta el procedimiento o se justifica una aproximación basada en su influencia; fijar todos los ajustes cambia lo que se remuestrea.

Una trayectoria larga requiere bloques u otro método válido para la dependencia. Un funcional no regular puede invalidar el bootstrap ordinario. El número de réplicas controla el error Monte Carlo del remuestreo, no el sesgo ni la validez del método. Un refinamiento de orden superior requiere más condiciones que un CLT y una varianza finita.

9.4.2 Intervalos de Confianza para Decisiones

Separe tres preguntas: si el intervalo es válido para el estimando, si su precisión es suficiente y si la comparación supera el margen de decisión. Un intervalo estrecho no repara falta de soporte ni una población incorrecta.

Si el procedimiento recoge más datos cuando la anchura es grande, debe analizarse también esa regla de parada. La alternativa de congelar el diseño y usar un nuevo conjunto independiente de evaluación cambia el experimento y debe quedar registrada. En ambos casos, el dictamen es específico de la regla completa, no de una sola fórmula de error estándar.

9.4.3 Incertidumbre Epistémica versus Aleatoria

En una media regular de unidades iid, la varianza de estimación puede ser del orden $\frac{1}{n}$, mientras que la dispersión de un retorno individual no desaparece. Esa distinción ayuda a separar precisión inferencial de riesgo predictivo.

No toda incertidumbre epistémica disminuye como $\frac{1}{n}$: identificación parcial, sesgo de modelo, dependencia fuerte y problemas no regulares pueden impedirlo. Más datos del mismo mecanismo no resuelven por sí solos confusión no medida ni falta de acciones observadas.

9.4.4 Cómo se justifica el intervalo

Resultado	Componente	Conclusión condicionada y frontera
CLT · CLT por episodio Sección 8.1.1	Error estándar	Episodios iid, contribución con varianza finita positiva y resto despreciable. Dependencia dentro de episodios no crea más unidades independientes.
DELTA · Método delta Teorema 4.106	Transformación de estimandos	Expansión diferenciable y límite del estimador inicial; si la derivada se anula o el funcional es no regular, revisar la escala y el límite.
GC · Glivenko–Cantelli Teorema 4.110	Distribución empírica	Para la CDF univariada iid, convergencia uniforme casi segura; para otras clases, verificar condiciones. No constituye un intervalo por sí sola.
DON · Donsker Teorema 4.112	Proceso empírico	Un límite funcional exige la clase y topología apropiadas; estimación de funciones auxiliares o dependencia requieren condiciones adicionales.
BOOT · Bootstrap Sección 9.4.1	Remuestreo para inferencia	Respetar unidad independiente o bloques y justificar consistencia para el funcional; considerar el reajuste. Aumentar réplicas no corrige un bootstrap inválido.
BT · Bootstrap studentizado Ejemplo 4.118	Refinamiento del IC	Mejoras de orden superior necesitan momentos, suavidad y expansión suficientes. No se atribuye un error universal de orden n elevado a menos uno.

Tabla 9.7: Resultados asintóticos y remuestreo: condiciones antes que fórmulas.

Revisar las funciones auxiliares y el resto de estimación

En la ruta semiparamétrica, el objetivo puede ser escalar mientras que sus modelos auxiliares son complejos. La revisión debe seguir la influencia utilizada, la identidad de centrado y los errores que permanecen al estimar esos componentes.

9.5.1 OPE como Problema Semiparamétrico

OPE puede formularse en modelos paramétricos, semiparamétricos o no paramétricos. La clasificación depende de las restricciones sobre la ley, no de que se use una red neuronal. Un funcional escalar de una ley no paramétrica puede analizarse con herramientas semiparamétricas de influencia y eficiencia, si es regular.

Para un mismo valor $J(\pi)$, un modelo paramétrico del entorno permite una ruta por verosimilitud y delta; un modelo flexible de funciones auxiliares requiere controlar el resto de una expansión; estimar una función completa puede exigir tasas y sesgos distintos. Cada ruta tiene su propio espacio comparado y su propia cota. El modelo Markov por tiempo del Teorema 4.146 no se sustituye por uno estacionario infinito sin revisar la influencia.

9.5.2 Diseño de Estimadores DR

Para una decisión, observe episodios iid $O = (S, A, R)$ con política de registro $b(a|s)$ y política objetivo fija $\pi(a|s)$. Sea $m(s,a) = \mathbb{E}(R|S=s, A=a)$ y $J = \mathbb{E}\Big(\sum_a \pi(a|S)m(S,a)\Big)$. La interpretación como intervención requiere las condiciones de identificación del problema. Con ajustes externos al episodio evaluado, la contribución correcta es

$$D\big(O; \hat{m}, \hat{b}\big) = \sum_a \pi(a|S)\hat{m}(S,a) + \frac{\pi(A|S)}{\hat{b}(A|S)}(R - \hat{m}(S,A)).$$

El término directo promedia sobre las acciones de la política objetivo; no es simplemente $\hat{m}(S,A)$.

Para funciones fijadas $\tilde{m}, \tilde{b}$, denominadores positivos y cantidades integrables, la esperanza condicional y la suma sobre acciones dan

$$\mathbb{E}(D) - J = \mathbb{E}\left(\sum_a \pi(a|S)\frac{\tilde{b}(a|S) - b(a|S)}{\tilde{b}(a|S)}(\tilde{m}(S,a) - m(S,a))\right).$$

Así se ve la cancelación cuando uno de los dos auxiliares es correcto. La consistencia muestral necesita además convergencia y control de las fluctuaciones. Para varios tiempos, se usa la contribución secuencial o marginal apropiada del Capítulo 7, no una copia de la fórmula de una decisión.

9.5.3 Ortogonalidad y Robustez

La identidad anterior muestra un resto de producto. Con soporte acotado y normas compatibles, su magnitud se controla por una constante por el producto de errores de los auxiliares. Para que no afecte un CLT a escala raíz de n, ese producto debe ser $o_P\big(n^{-\frac{1}{2}}\big)$, junto con las demás condiciones de la expansión. No basta que ambos modelos parezcan razonables.

Como ilustración de tasas, errores $O_P(n^{-0.30})$ y $O_P(n^{-0.25})$ producen un producto $O_P(n^{-0.55})$, despreciable frente a $n^{-\frac{1}{2}}$. Dos errores meramente $O_P(n^{-0.25})$ solo dan $O_P\big(n^{-\frac{1}{2}}\big)$, que no asegura el pequeño orden requerido. Cross-fitting ayuda a controlar un término empírico; no demuestra estas tasas ni elimina falta de soporte.

Los trabajos de (Chernozhukov et al., 2018) y (Kallus & Uehara, 2020) desarrollan resultados para modelos y procedimientos especificados. La aplicación debe documentar el que corresponde; «usa ML» no es una hipótesis suficiente. Eficiencia, ortogonalidad y doble robustez son propiedades relacionadas, pero no equivalentes.

9.5.4 Qué aporta la construcción semiparamétrica

Resultado	Componente	Conclusión condicionada y frontera
MOD · Modelo estadístico Sección 9.5.1	Especificación del experimento	Distinguir ley observada, objetivo e identificación. Una parametrización y un esquema de tipos no prueban que el modelo represente los datos.
TAN · Espacio tangente Sección 9.5.1	Definición de eficiencia	El gradiente canónico depende del modelo observado y sus restricciones. Una función centrada cualquiera no es necesariamente eficiente.
EIF · Gradiente canónico OPE Teorema 4.146	Contribuciones de valor	En el modelo Markov de horizonte finito por tiempo: razones marginales y residuos de Bellman. Eficiencia requiere además una expansión regular con resto despreciable.
BOUND · Cota semiparamétrica Teorema 4.140	Comparación de estimadores	Cota entre estimadores regulares en un modelo fijado. No se identifica con la cota de un modelo distinto ni con una garantía finita.
ORTH · Ortogonalidad Sección 9.5.3	Momento de estimación	Derivada poblacional nula respecto del auxiliar en la verdad; hay que controlar el resto de orden superior y la fluctuación empírica.
DR · Doble robustez Sección 9.5.2	Evaluación aumentada	La identidad poblacional y condiciones de convergencia permiten consistencia si uno de los conjuntos auxiliares es correcto. Esto no basta para un IC eficiente.
DML · Cross--fitting y DML Teorema 4.150	Aprendizaje auxiliar	Separación por unidades, convergencia y productos de errores pequeños a escala raíz de n; también momentos y varianza. El algoritmo de partición no prueba esas tasas.

Tabla 9.8: Modelo, influencia y condiciones de inferencia con aprendizaje auxiliar.

9.5.5 Reunir la evidencia de una evaluación

El mapa reúne rutas distintas: decisión de Wald, planificación dentro de un MDP, evaluación de políticas e inferencia. No son eslabones que puedan intercambiarse. En particular, el sandwich de Bellman sieve, SAVE y la varianza de contribuciones DR por episodio responden a procedimientos diferentes, como se explicó en el Capítulo 8.

Resultado	Componente	Conclusión condicionada y frontera
WALD · Problema y riesgo de Wald Definición 2.1	Criterio de decisión	Modelo, espacio de acciones y pérdida especificados; riesgo como esperanza de pérdida. Representar un problema no prueba identificación ni optimalidad.
BAYES · Regla de Bayes Teorema 2.9	Minimización posterior	Prior y pérdida especificados, riesgo definido y mínimo alcanzado. El resultado es relativo a ese problema.
MM · Minimax Teorema 2.14	Peor riesgo	La certificación Bayes requiere que el riesgo máximo global iguale al riesgo Bayes; constancia solo sobre el soporte del prior no basta.

Resultado	Componente	Conclusión condicionada y frontera
EMB · Incrustación Wald–MDP Teorema 5.3	Representación de reglas	Identidad de retorno integrado y riesgo negativo en la familia de una decisión y transición terminal determinista. No transfiere garantías a cualquier agente.
BELL · Bellman y contracción Teorema 3.12	Planificación	Para MDP finito descontado y recompensas acotadas, el operador contrae en norma suprema. Convergencia computacional dentro del modelo no valida el modelo.
VI · Iteración de valores Teorema 3.14	Cálculo de valor óptimo	Modelo finito conocido, descuento menor que uno y actualizaciones exactas dan convergencia geométrica. Aproximación y error del modelo se controlan aparte.
DR · Doble robustez Sección 9.5.2	Evaluación aumentada	La identidad poblacional y condiciones de convergencia permiten consistencia si uno de los conjuntos auxiliares es correcto. Esto no basta para un IC eficiente.
CLT · CLT por episodio Sección 8.1.1	Error estándar	Episodios iid, contribución con varianza finita positiva y resto despreciable. Dependencia dentro de episodios no crea más unidades independientes.
SIEVE · Bellman sieve de SZLS Nota 8.8	Inferencia de valor	Procedimiento y condiciones completos del artículo, incluidas aproximación, información y varianza; no equivale al estimador DR.
SAVE · Evaluación secuencial SAVE Definición 8.13	Políticas aprendidas	Respetar bloques, agregación y condiciones de la evaluación secuencial original. No es una corrección DR ni una garantía de optimalidad aprendida.
CI · Inversión de contrastes Teorema 4.91	Intervalo y comparación	El conjunto invertido hereda el nivel de los contrastes utilizados. Distinguir cobertura finita de asintótica y puntual de simultánea.
BOOT · Bootstrap Sección 9.4.1	Remuestreo para inferencia	Respetar unidad independiente o bloques y justificar consistencia para el funcional; considerar el reajuste. Aumentar réplicas no corrige un bootstrap inválido.

Tabla 9.9: Mapa de rutas: representación, planificación e inferencia.

Nota 9.4 (Propiedades de Trazabilidad). Un registro enlazado permite localizar la justificación de una decisión, reproducir su cálculo si se conservan los insumos y detectar cambios en sus condiciones. No demuestra verdad del modelo, cobertura empírica universal ni corrección del software. La reproducibilidad requiere datos o generador, código, versiones, parámetros y resultados contrastables. Un hash identifica bytes; no certifica el significado de una garantía.

Ejemplo 9.5 *(sintético)* **(Trazabilidad en SSCH).** Retome el ejemplo de dos visitas de Ejemplo 8.25. El objetivo es la diferencia entre una política que toma acción uno con probabilidad 0.75 y una referencia con probabilidad 0.5, con descuento 0.9. Hay cien episodios iid de un entorno sintético, con modelos de evaluación fijados previamente y política de registro conocida. El horizonte es finito: no se utiliza el resultado sieve de horizonte infinito.

Modelo y datos. En cada visita, el registro elige acciones con probabilidad 0.5 y la recompensa sintética es la acción. Los episodios se reinician independientemente. Las cuatro historias de acciones son equiprobables; la muestra considerada tiene 25 de cada una como realización posible, no como cuota impuesta por el diseño.

Estimador. Las contribuciones pareadas de diferencia son $0.520, 0.340, 0.430, 0.610$, cada una repetida 25 veces. Por ello,

$$\hat{\Delta} = 0.475, \quad s_\Delta^2 = \frac{100}{99}(0.010125), \quad \mathrm{SE} = \sqrt{\frac{s_\Delta^2}{100}} \approx 0.010113.$$

Su media poblacional es 0.475 y su varianza poblacional 0.010125; se verifican enumerando las cuatro historias. No se necesita invocar eficiencia semiparamétrica para justificar el CLT de estas contribuciones fijas, acotadas e independientes entre episodios.

Garantía inferencial. La ruta del catálogo es DR $\longrightarrow$ CLT $\longrightarrow$ CI. El IC bilateral normal aproximado al 95% es $[0.455, 0.495]$. La propiedad afirmada es asintótica; el cálculo de cien episodios no prueba cobertura exacta. La varianza pareada conserva la covarianza entre políticas.

Decisión. Suponga un margen prefijado $\delta_0 = 0.40$ y contraste unilateral al 5%. El límite inferior correspondiente es

$$0.475 - 1.64485(0.010113) \approx 0.45837.$$

Supera el margen. Bajo el experimento y la aproximación declarados, el dictamen es evidencia de mejora superior a 0.40 en recompensa sintética. No es una conclusión clínica ni una garantía de mejora en otra población.

Qué invalida o limita el dictamen. Reutilizar los cien episodios para seleccionar la política, detenerse al obtener significación, perder soporte o sustituir episodios por transiciones dependientes obliga a revisar la inferencia. Si cambia solo el margen a 0.47, manteniendo todo lo demás, el límite inferior ya no lo supera: no hay evidencia suficiente de esa mejora mayor. Cambiar el criterio después de observar resultados tampoco conserva el análisis prefijado.

Aplicación del mismo esquema a un modelo paramétrico. En el ejemplo $J = 2\theta$, la ruta es MOD $\longrightarrow$ CR y, para inferencia, una construcción de IC válida para θ seguida de IMAGE. En la ruta semiparamétrica DR, la identidad de producto debe acompañarse del control de errores. En una estimación no paramétrica de $V(s)$ sobre muchos estados, se añaden sesgo de aproximación y requisitos de uniformidad. El nombre «valor» no permite usar el mismo certificado para los tres problemas.

Recuperar la justificación de cada componente

La vista final reúne resultados que intervienen en varias tareas del agente. Los componentes son funciones conceptuales que pueden implementarse en LangGraph u otro sistema. La herramienta de orquestación no modifica las hipótesis estadísticas. Las condiciones de cada fila se leen junto con el resultado completo y con la ficha de la aplicación.

Resultado	Componente	Conclusión condicionada y frontera
EXP · Familia exponencial Teorema 4.23	Actualización incremental	Bajo el modelo iid y dimensión fija, el estadístico natural puede actualizarse por sumas. No toda familia es minimal ni toda memoria del agente puede descartarse.
SUF · Suficiencia Teorema 4.35	Resumen de datos	La factorización establece suficiencia para una familia especificada. No implica automáticamente estado Markov para futuras decisiones.
RB · Rao–Blackwell Proposición 9.3	Mejora de estimación	Condicionamiento implementable en un estadístico suficiente, con segundo momento finito: mismo sesgo y varianza no mayor. No garantiza eficiencia semiparamétrica.
LS · Lehmann–Scheffé Teorema 4.60	Selección de estimador	Un estimador insesgado con varianza finita, función de un estadístico suficiente completo, es UMVUE. La comparación se restringe a estimadores insesgados.
CR · Cramér–Rao Proposición 9.2	Referencia de precisión	Para valor g(theta), estimación insesgada y experimento paramétrico regular: cota con gradiente de g e inversa de la información del experimento.
NP · Neyman–Pearson Teorema 4.83	Contraste simple	Máxima potencia para dos hipótesis simples y nivel fijado, con aleatorización si corresponde. No es un resultado UMP para toda alternativa compuesta.
FDR · Benjamini–Hochberg Teorema 4.98	Selección múltiple	Control de proporción esperada de falsos descubrimientos bajo independencia o dependencia admitida. No controla la probabilidad de cada decisión individual.
DON · Donsker Teorema 4.112	Proceso empírico	Un límite funcional exige la clase y topología apropiadas; estimación de funciones auxiliares o dependencia requieren condiciones adicionales.
ORTH · Ortogonalidad Sección 9.5.3	Momento de estimación	Derivada poblacional nula respecto del auxiliar en la verdad; hay que controlar el resto de orden superior y la fluctuación empírica.
CC · Clase completa Teorema 2.12	Restricción de reglas	Aplicar la versión del teorema con sus condiciones y clase de reglas. No implica que toda regla admisible sea Bayes para un prior propio.
ADM · Admisibilidad Definición 2.5	No dominancia	Ausencia de otra regla que mejore todos los riesgos y alguno estrictamente, dentro de la clase comparada. Bayes no implica admisibilidad sin condiciones.
BELL · Bellman y contracción Teorema 3.12	Planificación	Para MDP finito descontado y recompensas acotadas, el operador contrae en norma suprema. Convergencia computacional dentro del modelo no valida el modelo.
PI · Mejora y extracción de política Teorema 3.16	Selección greedy	En el MDP finito descontado, evaluación exacta y elección greedy dan mejora no decreciente y permiten una política óptima determinista.

Resultado	Componente	Conclusión condicionada y frontera
EMB · Incrustación Wald–MDP Teorema 5.3	Representación de reglas	Identidad de retorno integrado y riesgo negativo en la familia de una decisión y transición terminal determinista. No transfiere garantías a cualquier agente.
IS · Importance sampling Capítulo 7	Reponderación	Razones correctas, soporte e integrabilidad permiten insesgadez del estimador no normalizado. Razones estimadas o normalización cambian sus propiedades.
DR · Doble robustez Sección 9.5.2	Evaluación aumentada	La identidad poblacional y condiciones de convergencia permiten consistencia si uno de los conjuntos auxiliares es correcto. Esto no basta para un IC eficiente.
EIF · Gradiente canónico OPE Teorema 4.146	Contribuciones de valor	En el modelo Markov de horizonte finito por tiempo: razones marginales y residuos de Bellman. Eficiencia requiere además una expansión regular con resto despreciable.
SIEVE · Bellman sieve de SZLS Nota 8.8	Inferencia de valor	Procedimiento y condiciones completos del artículo, incluidas aproximación, información y varianza; no equivale al estimador DR.
DML · Cross--fitting y DML Teorema 4.150	Aprendizaje auxiliar	Separación por unidades, convergencia y productos de errores pequeños a escala raíz de n; también momentos y varianza. El algoritmo de partición no prueba esas tasas.

Tabla 9.10: Resultados y componentes: vista operacional del catálogo canónico.

Para cerrar una revisión, el agente debe poder reconstruir qué se estimó, con qué datos, qué hipótesis se declararon, qué resultado se aplicó y por qué la decisión respeta su alcance. Una condición no justificada permanece visible. Esa disciplina prepara el análisis de casos y despliegue sin presentar una correspondencia matemática acotada como garantía general.

Dr. Jaime Lizcano Carrivil

Parte IV

Ejercicio y límites

Los resultados anteriores adquieren una interpretación concreta al reproducir sus cálculos. Los casos permiten seguir la relación entre modelo, datos y decisión; el despliegue obliga a revisarla cuando cambia el sistema. Las preguntas que quedan abiertas cierran el recorrido.

Dr. Jaime Linares Curiel

Capítulo 10

Casos de estudio

Los casos de este capítulo convierten las condiciones de los capítulos anteriores en cálculos que pueden repetirse. El recorrido distingue un modelo finito conocido, su estimación a partir de datos, la evaluación de políticas y la decisión posterior. Un resultado de simulación comprueba una implementación en un escenario; no sustituye la demostración de un teorema ni valida una aplicación clínica.

El recorrido comienza con un modelo tabular y continúa con doce laboratorios. Cada uno retoma una pregunta de los capítulos anteriores y la lleva a un cálculo. Los programas completos y sus salidas acompañan la exposición, de modo que el lector puede seguir la relación entre la fórmula y su implementación.

El caso longitudinal: Sistema de Soporte Clínico para Hipertensión

El SSCH es un escenario docente sintético. Sus estados ordenados y acciones abstractas permiten estudiar decisiones longitudinales sin atribuir a sus números un significado médico validado. No se utilizan pacientes reales, umbrales diagnósticos ni estimaciones de eficacia de medicamentos.

Hay dos experimentos que no deben confundirse. El **SSCH tabular** de cinco estados estudia estimación paramétrica y planificación con una dinámica completamente especificada. El **subcaso de dos visitas** de los capítulos 7–9 estudia OPE e intervalos mediante cuatro historias enumerables. Comparten la motivación pedagógica, pero no los parámetros, el horizonte ni los datos. Cada comparación mantiene fijo su propio estimando.

El modelo tabular y sus recompensas

Ejemplo 10.1 *(sintético)* **(SSCH — El MDP Clínico como Modelo Paramétrico).** Considere cinco estados $s_1, \ldots, s_5$, ordenados de menor a mayor severidad abstracta, y cuatro acciones $a_1, \ldots, a_4$. Las denominaciones clínicas motivan el escenario, pero ninguna acción representa una pauta terapéutica. Se fija $\gamma = 0.9$ y horizonte descontado infinito. El objetivo de comparación será $V^{\pi}(s_3)$.

Para hacer reproducible la dinámica, use índices $s, j \in \{0, \ldots, 4\}$ y desplazamientos $d = (0.45, 0, -0.45, -0.8)$ para las cuatro acciones. Defina

$$w_{s,a,j} = \exp\left(-\frac{|j - (s + d_a)|}{0.7}\right), \quad P_{s,a,j} = 0.98\frac{w_{s,a,j}}{\sum_{u=0}^{4} w_{s,a,u}} + \frac{0.02}{5}.$$

Cada fila suma uno y cada entrada es al menos 0.004. Esta es una elección de diseño del simulador, no una estimación de transiciones humanas.

Estado	a_1	a_2	a_3	a_4
s_1	1.0	0.9	0.7	0.5
s_2	0.5	0.7	0.6	0.4
s_3	0.0	0.3	0.6	0.5
s_4	−0.5	0.0	0.4	0.7
s_5	−2.0	−1.5	−0.5	0.2

Tabla 10.1: Recompensas sintéticas del SSCH tabular, en unidades abstractas.

Cuando P es desconocida, sus veinte filas pertenecen a Δ^4: hay cien probabilidades y ochenta parámetros libres en el interior. La recompensa se considera conocida. Si también se estima, su error debe incorporarse a la inferencia de valor.

Los datos que conservan información de las transiciones

Ejemplo 10.2 *(sintético)* **(SSCH — Estadístico Suficiente para las Transiciones).** Si la distribución inicial y las probabilidades de asignación son conocidas o no contienen el parámetro de transición, la verosimilitud observada tiene la forma

$$L(\theta; X) = h(X) \prod_{s,a,j} \theta_{s,a,j}^{N_{s,a,j}}.$$

La factorización muestra suficiencia de los conteos bajo ese modelo. Deben revisarse también el mecanismo de parada, pérdidas de seguimiento y recompensas si contienen información sobre el mismo parámetro.

El número de visitas a una fila puede depender de las transiciones anteriores. Por tanto, no es automáticamente ancilar ni independiente de los conteos; Basu no autoriza descartarlo. Condicionar retrospectivamente en un número de visitas adaptativo tampoco produce sin más un experimento multinomial de tamaño fijo.

Para los cálculos siguientes se usa un **diseño generativo por filas**: ochenta transiciones independientes desde cada par estado–acción, con tamaño fijado antes de observarlas. Son 1600 transiciones de diseño, no 200 pacientes ni una sola trayectoria. En este experimento, cada fila es multinomial y las filas son independientes. Guardar cien conteos basta para esa verosimilitud; la procedencia y el diseño se conservan aparte.

Estimar la dinámica y calcular el valor

Ejemplo 10.3 *(sintético)* **(SSCH — Estimación de las Probabilidades de Transición).** En el diseño de tamaño fijo $m = 80$ por fila,

$$\hat{P}_{s,a,j} = \frac{N_{s,a,j}}{m}, \quad \operatorname{Cov}\big(\hat{P}_{s,a,\cdot}\big) = \frac{1}{m}\big(\operatorname{diag}(P_{s,a,\cdot}) - P_{s,a,\cdot}P_{s,a,\cdot}^{T}\big).$$

Las frecuencias son insesgadas y UMVUE para sus probabilidades en el modelo multinomial completo. La afirmación se refiere a este diseño, no a cualquier cociente de conteos de una trayectoria adaptativa.

Para una política fija,

$$V^{\pi} = (I - \gamma P^{\pi})^{-1} r^{\pi}.$$

El programa usa exactamente esa ecuación, con matrices compatibles. El estimador plug-in de valor no es necesariamente insesgado en muestra finita. Su análisis asintótico exige que crezcan los tamaños de las filas necesarias y que se cumpla la regularidad del funcional.

Con el generador y semilla especificados, desde s_3 se obtienen $\hat{V}^{\pi_2} \approx 0.964091$ y $\hat{V}^{\pi_3} \approx 5.570888$, donde π_a usa siempre la acción a. Los valores verdaderos del simulador son aproximadamente 1.635906 y 5.855945.

Comparar dos políticas con los mismos datos

Ejemplo 10.4 *(sintético)* **(SSCH: comparación de dos políticas del simulador).** Para comparar las acciones abstractas a_3 y a_2, defina $\Delta = V^{\pi_3}(s_3) - V^{\pi_2}(s_3)$ y contraste $H_0 : \Delta \leq 0$ frente a $H_1 : \Delta > 0$, con un único análisis prefijado.

La realización generada da $\hat{\Delta} \approx 4.606798$ y error estándar delta 0.882817. El intervalo bilateral normal aproximado al 95% es $[2.876508, 6.337087]$. La interpretación es evidencia bajo el modelo, el diseño por filas y la aproximación asintótica. No es una prueba de cobertura finita ni de eficacia clínica.

La varianza corresponde a la diferencia completa. Si las dos políticas comparten parámetros estimados, se incluye su covarianza. Comparar varios estados o políticas cambia la familia de contrastes y exige un plan de multiplicidad; no se inventan resultados de seis contrastes que el programa no calculó.

Propagar el error de las transiciones al valor

Ejemplo 10.5 *(sintético)* **(SSCH — Distribución Asintótica de $\widehat{V}^{\pi}$).** Con tamaños iguales m por fila y parámetros interiores, el CLT multinomial usa escala $\sqrt{m}$. Para una perturbación de transición $\mathrm{d}P^{\pi}$, con recompensa fija,

$$\mathrm{d}V^{\pi} = \gamma(I - \gamma P^{\pi})^{-1}(\mathrm{d}P^{\pi})V^{\pi}.$$

Para el componente inicial s_3, sea $A^{\pi} = (I - \gamma P^{\pi})^{-1}$. La derivada respecto de una entrada de la fila (s, a) es

$$g^{\pi}_{s,a,j} = \gamma A^{\pi}_{s_3,s}\pi(a|s)V^{\pi}_j.$$

Se usa en direcciones cuyas entradas suman cero. Para la diferencia, se resta el gradiente de ambas políticas y se aplica la covarianza multinomial de cada fila, sumando las contribuciones independientes.

El bootstrap del programa remuestrea conteos multinomiales de tamaño ochenta por fila bajo $\hat{P}$ y reajusta ambos valores. Es un bootstrap paramétrico del diseño generativo, no un remuestreo de pacientes. Que su intervalo resulte próximo al normal es una comparación de métodos; para estudiar cobertura se necesitan muchas muestras nuevas del modelo verdadero y error Monte Carlo.

La positividad del núcleo construido proporciona una minoración uniforme para cualquier política estacionaria del simulador. Esta propiedad no se infiere de una ACF favorable. En el diseño de filas independientes no se necesita usar un CLT de trayectoria para justificar las frecuencias.

El siguiente programa define el modelo completo, genera los conteos, calcula la varianza por delta y el bootstrap, y contrasta la derivada con una perturbación numérica que preserva las sumas de fila. Guárdese como `lab00_ssch.py`; también lo utiliza el laboratorio 8.

```
import numpy as np
from scipy.stats import norm

GAMMA = 0.9
```

```
R = np.array(
    [
        [1, 0.9, 0.7, 0.5],
        [0.5, 0.7, 0.6, 0.4],
        [0, 0.3, 0.6, 0.5],
        [-0.5, 0, 0.4, 0.7],
        [-2, -1.5, -0.5, 0.2],
    ]
)
DRIFT = np.array([0.45, 0, -0.45, -0.8])


def model():
    s = np.arange(5)[:, None, None]
    j = np.arange(5)[None, None, :]
    w = np.exp(-np.abs(j - (s + DRIFT[None, :, None])) / 0.7)
    return 0.98 * w / w.sum(axis=2, keepdims=True) + 0.02 / 5


def evaluate(P, pi):
    pp = np.einsum("sa,saj->sj", pi, P)
    rr = (pi * R).sum(axis=1)
    inv = np.linalg.inv(np.eye(5) - GAMMA * pp)
    return inv @ rr, inv


def gradient(P, pi, initial=2):
    v, inv = evaluate(P, pi)
    return (
        GAMMA
        * inv[initial, :, None, None]
        * pi[:, :, None]
        * v[None, None, :]
    )


def delta_variance(P, grad, m):
    return float(
        np.sum(
            (np.sum(P * grad**2, axis=2) - np.sum(P * grad, axis=2) ** 2)
            / m
        )
    )


def main():
    P = model()
    rng = np.random.default_rng(20261027)
    m = 80
    counts = np.array(
        [
            [rng.multinomial(m, P[s, a]) for a in range(4)]
            for s in range(5)
        ]
    )
    phat = counts / m
    policies = [np.eye(4)[np.full(5, a)] for a in range(4)]
    vals = [evaluate(phat, pi)[0][2] for pi in policies]
    true = [evaluate(P, pi)[0][2] for pi in policies]
    g = gradient(phat, policies[2]) - gradient(phat, policies[1])
    se = np.sqrt(delta_variance(phat, g, m))
    diff = vals[2] - vals[1]
    print("Diseno: 80 transiciones independientes por fila; total 1600")
    print("Valores verdaderos desde s3:", np.round(true, 6))
    print("Valores estimados desde s3:", np.round(vals, 6))
    print(f"Diferencia a3-a2={diff:.6f}; SE delta={se:.6f}")
    print(
        "IC normal 95%:",
        np.round(diff + np.array([-1, 1]) * norm.ppf(0.975) * se, 6),
    )
    print(f"p unilateral normal={norm.sf(diff/se):.6g}")
    boot = []
    for _ in range(1000):
        pb = np.array(
            [
                [rng.multinomial(m, phat[s, a]) / m for a in range(4)]
                for s in range(5)
            ]
```

Orijaime Linconil Curivil

```
        )
        boot.append(
            evaluate(pb, policies[2])[0][2]
            - evaluate(pb, policies[1])[0][2]
        )
    print(
        "IC bootstrap parametrico 95%:",
        np.round(np.quantile(boot, [0.025, 0.975]), 6),
    )
    # Comprobacion direccional de la derivada, dentro del simplex.
    d = np.zeros_like(P)
    d[2, 2, 0] = 1
    d[2, 2, 1] = -1
    h = 1e-6
    gd = gradient(P, policies[2])
    fd = (
        evaluate(P + h * d, policies[2])[0][2]
        - evaluate(P - h * d, policies[2])[0][2]
    ) / (2 * h)
    assert np.isclose(fd, np.sum(gd * d), rtol=1e-5)
    assert np.allclose(P.sum(axis=2), 1) and np.min(P) > 0
    print("Filas estocasticas y derivada direccional: OK")


if __name__ == "__main__":
    main()
```

Listado 1: `lab00_ssch.py`. Código ejecutado.

Salida de la ejecución de referencia.

```
Diseno: 80 transiciones independientes por fila; total 1600
Valores verdaderos desde s3: [-7.771309  1.635906  5.855945  4.786908]
Valores estimados desde s3: [-5.091062  0.964091  5.570888  4.835083]
Diferencia a3-a2=4.606798; SE delta=0.882817
IC normal 95%: [2.876508 6.337087]
p unilateral normal=9.029e-08
IC bootstrap parametrico 95%: [2.998922 6.409819]
Filas estocasticas y derivada direccional: OK
```

Pasar del diseño por filas a episodios observacionales

Ejemplo 10.6 *(sintético)* **(SSCH — OPE Semiparamétrica con Datos Observacionales).** El diseño generativo anterior es paramétrico finito. Para pasar a datos longitudinales observacionales, hay que especificar otra ley de muestreo, la política de registro y la información que precede a cada acción. La interpretación causal exige consistencia, intercambio secuencial y positividad respecto del historial pertinente; un estado discretizado puede omitir confusores. No se presumen esas propiedades para un hospital.

En el modelo Markov por tiempo, horizonte fijo H y episodios iid del Teorema 4.146, con ley inicial desconocida compartida, la influencia eficiente para el valor integrado tiene la forma

$$\varphi(O) = v_0(S_0) - J + \sum_{t=0}^{H-1} \gamma^t w_t(S_t, A_t)(R_t + \gamma v_{t+1}(S_{t+1}) - q_t(S_t, A_t)), \quad v_H = 0.$$

Aquí w_t es una razón **marginal** de ocupación. No es automáticamente el producto de razones de acciones de la trayectoria. Cambiar el modelo a historias completas, a homogeneidad temporal o a horizonte infinito puede cambiar la influencia y su cota.

La doble robustez da una identidad de centrado bajo los conjuntos de auxiliares correctos. Un IC regular requiere además control de productos de errores, fluctuaciones empíricas y varianza. No se reemplaza ese argumento por una afirmación genérica de sesgo cuadrático en un solo modelo de recompensa. Los laboratorios 6 y 10 separan ambas tareas.

De los cálculos del caso a los experimentos reproducibles

Los programas usan escenarios sintéticos con verdad conocida y un entorno público de simulación, CartPole. No se presenta una replicación de NHEFS ni un análisis de pacientes. Cada salida «esperada» que se reproduce es una salida efectivamente obtenida con el código adjunto; una semilla fija facilita repetición dentro del entorno documentado, pero no demuestra una propiedad asintótica.

Ejecución. El paquete incluye `lab00_ssch.py`, los doce laboratorios (con 1 dividido en dos programas), `ejecutar_todos.py`, versiones y salidas. 8 importa el modelo de 0; todos los archivos se mantienen en la misma carpeta. Los demás programas no requieren ejecutar los anteriores. Ejecute:

```
python -m venv .venv
source .venv/bin/activate
python -m pip install -r requirements.txt
python ejecutar_todos.py
```

El código estadístico usa NumPy, SciPy y scikit-learn; 10 añade Gymnasium. La arquitectura por nodos se describe sin exigir un servicio LLM ni una cuenta externa. No se atribuyen garantías estadísticas a un framework. Las versiones de la ejecución de referencia constan en `versiones.json`.

Lectura de resultados. La media de una simulación, su error Monte Carlo, un intervalo inferencial y una cota determinista responden a preguntas distintas. Los laboratorios indican cuál calculan. Las preguntas de extensión no se presentan como experimentos ya realizados.

Lab	Contenido	Capítulo vinculado
1	Modelos y actualización	4
2	Suficiencia y memoria	4
3	Rao–Blackwell y precisión	4
4	Comparación e intervalos	4
5	Bootstrap y cobertura	4
6	AIPW y cross-fitting	4
7	Decisión y bandits	2
8	Programación dinámica	3
9	Incrustación de una decisión	5
10	OPE	7
11	Dependencia e inferencia	8
12	Agentes y síntesis	11

Tabla 10.2: Preguntas y fundamentos de los doce laboratorios.

Laboratorio 1: Modelo del Mundo y Estadístico Suficiente

El primer laboratorio sigue el paso de las observaciones a la actualización de un modelo. La formulación del Capítulo 4 y la Definición 4.24 permiten interpretar qué se aprende en cada actualización.

Eduardo Lincovil Curivil

Laboratorio 1.1: Agente de Diagnóstico Médico con Asistencia Experta

Objetivo

Implementar una actualización Beta–Bernoulli y distinguir probabilidad predictiva, incertidumbre sobre una prevalencia y pérdida de decisión. Se reproduce el ejemplo sintético del Capítulo 9, sin afirmar que una prevalencia poblacional sea un diagnóstico individual.

Conexión Teórica

Con prior $\mathrm{Beta}(a_0, b_0)$ y observaciones Bernoulli iid confirmadas, $T = \left(n, \sum_i Y_i\right)$ determina el posterior. Las probabilidades de falso positivo y falso negativo pertenecen a otro modelo: no están representadas por sumar resultados de pruebas imperfectas como si fueran estados verdaderos.

Planteamiento

Tome prior $\mathrm{Beta}(1, 1)$ y doce estados positivos confirmados de cien personas independientes e intercambiables. El posterior es $\mathrm{Beta}(13, 89)$. Para una persona nueva sin covariables, $p = \frac{13}{102}$. La pérdida predictiva de tratar es $c(1 - p)$ y la de no tratar es dp; el umbral es $\frac{c}{c+d}$. Con $c = 1, d = 9$, se prefiere la primera acción en el problema de dos opciones.

Añadir una regla que deriva a revisión si la desviación posterior supera 0.03 cambia el procedimiento. La revisión puede ser razonable como restricción de diseño, pero su optimalidad exige modelar su costo y la información que aporta. No se denomina a esa regla «Bayes óptima» sin más.

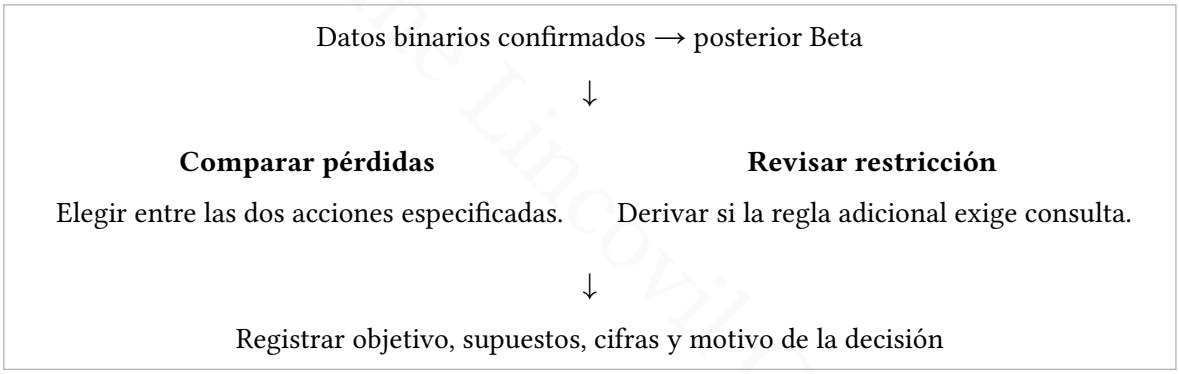


Figura 10.1: Actualización, comparación de pérdidas y revisión del caso sintético.

Componente	Operación	Alcance
Actualizar	Sumar éxitos y fracasos	Exacto bajo el modelo Bernoulli especificado.
Cuantificar	Media y varianza posterior	No equivalen a cobertura frecuentista.
Decidir	Comparar pérdidas predictivas	Depende de costos y acciones.
Revisar	Aplicar restricción adicional	Regla de diseño, no teorema clínico.

Tabla 10.3: Qué implementa cada componente y qué no demuestra.

```
from math import sqrt


def update(a, b, y):
    if y not in (0, 1):
        raise ValueError("Se requiere estado binario confirmado")
    return a + y, b + 1 - y


a, b = 1.0, 1.0
```

```
for y in [1] * 12 + [0] * 88:
    a, b = update(a, b, y)
p = a / (a + b)
sd = sqrt(a * b / ((a + b) ** 2 * (a + b + 1)))
c, d = 1.0, 9.0
losses = {"tratar": c * (1 - p), "no_tratar": d * p}
action = min(losses, key=losses.get)
print(f"Posterior Beta({a:.0f},{b:.0f}); p={p:.6f}; SD={sd:.6f}")
print(f"Umbral={c/(c+d):.3f}; accion de dos opciones={action}")
print("Regla adicional SD<=0.03:", action if sd <= 0.03 else "consultar")
assert action == "tratar" and sd > 0.03
```

Listado 2: `lab01a_beta.py`. Código ejecutado.

```
Posterior Beta(13,89); p=0.127451; SD=0.032859
Umbral=0.100; accion de dos opciones=tratar
Regla adicional SD<=0.03: consultar
```

Preguntas de Exploración

1. Derive el umbral cuando $d = 3c$ y explique por qué disminuye al aumentar el costo de omisión. Mantenga separados el estado binario y su probabilidad.
2. Compare priors $\text{Beta}(1, 1)$ y $\text{Beta}(10, 2)$ sobre la misma secuencia. Examine sensibilidad, sin calificar al prior uniforme como universalmente no informativo.
3. Modele una prueba imperfecta con sensibilidad y especificidad conocidas. Derive su verosimilitud en términos de prevalencia y explique por qué la actualización Beta conjugada ordinaria deja de ser válida en general.

Laboratorio 1.2: Agente Bernoulli-Beta para Optimización de CTR

Objetivo

Relacionar el posterior de una tasa de clic con una utilidad concreta y un costo por exposición. El caso necesita una política de observación compatible con el modelo, no solo una fórmula de actualización.

Planteamiento

Con dieciocho clics de cien exposiciones y prior $\text{Beta}(1, 1)$, el beneficio predictivo de mostrar un producto que produce uno por clic y cuesta 0.15 por exposición es $\frac{19}{102} - 0.15 \approx 0.036275$. Para este objetivo, el signo del beneficio determina la decisión.

La varianza posterior satisface

$$\text{Var}(\theta|X) = \frac{p(1-p)}{n + a_0 + b_0 + 1} \leq \frac{1}{4(n + a_0 + b_0 + 1)}.$$

Con prior uniforme, la cota estricta de desviación menor que 0.05 se obtiene para $n \geq 98$. Es una cota de dispersión posterior, no un cálculo de potencia ni una garantía de calibración frecuentista.

```
from fractions import Fraction

success, n = 18, 100
a, b = 1 + success, 1 + n - success
p = a / (a + b)
cost = 0.15
print(f"Posterior Beta({a},{b}); beneficio esperado={p-cost:.6f}")
print("Mostrar:", p > cost)
# Var(theta|datos)<=1/[4(n+a0+b0+1)]. Cota para todo numero de exitos.
minimum_n = next(
    k for k in range(1000) if Fraction(1, 4 * (k + 3)) < Fraction(1, 400)
)
print("n suficiente por cota uniforme para SD<0.05:", minimum_n)
assert minimum_n == 98
```

Listado 3: `lab01b_ctr.py`. Código ejecutado.

```
Posterior Beta(19,83); beneficio esperado=0.036275
Mostrar: True
n suficiente por cota uniforme para SD<0.05: 98
```

Preguntas de Exploración

1. Derive la cota uniforme para otros priors y tolerancias, distinguiendo desigualdad estricta y no estricta.
2. Compare sesgo y ECM de media posterior y frecuencia empírica para varios valores verdaderos, usando réplicas e incertidumbre Monte Carlo.
3. Extienda a cinco productos y registre el mecanismo adaptativo de selección. Compare la decisión de una sola ronda con Thompson Sampling de 7.

Laboratorio 2: Compresión del Estado (Suficiencia)

La actualización anterior plantea qué información conviene guardar. Este laboratorio examina la compresión de los datos mediante la suficiencia del Capítulo 4.

Objetivo

Mostrar una reducción suficiente y un resumen realmente insuficiente. La media incremental con tamaño muestral no pierde información estadística respecto de la suma en aritmética exacta; errores de redondeo son una cuestión diferente.

Conexión Teórica

En Bernoulli iid, el historial, $(n, \sum X_i)$ y $\left(n, \overline{X}\right)$ contienen la misma información para la verosimilitud. Guardar solo el último dato no es suficiente cuando hay más de una observación. El criterio de razones de verosimilitud permite exhibir la diferencia sin inventar una divergencia KL atribuida a «insuficiencia» de la media.

Dataset y Setup

Mil observaciones Bernoulli de probabilidad 0.3, generador local y semilla 20261027. Se cuentan operaciones; no se publican tiempos supuestos de una máquina no medida. Recalcular la suma de todo el historial en cada llegada cuesta en total orden n^2, frente a orden n para las actualizaciones.

Implementación

```
import numpy as np

rng = np.random.default_rng(20261027)
x = rng.binomial(1, 0.3, size=1000)
n = total = 0
online = 0.0
for y in x:
    n += 1
    total += int(y)
    online += (y - online) / n
assert np.isclose(total / n, online) and np.isclose(x.mean(), online)
print(f"n={n}; exitos={total}; media={online:.6f}")
print("Conteos, historial y (n,media) coinciden: OK")
# Un resumen realmente insuficiente: el ultimo dato.
# Estas muestras tienen mismo ultimo dato y razones de verosimilitud distintas.
a = np.array([0, 0, 0, 1])
b = np.array([1, 1, 0, 1])
for theta in [0.2, 0.7]:
    ratio = (theta / (1 - theta)) ** (a.sum() - b.sum())
    print(f"Razón L(a)/L(b) en theta={theta}: {ratio:.6f}")
print("Operaciones suma completa a cada llegada:", n * (n + 1) // 2)
print("Actualizaciones incrementales:", n)
```

Listado 4: `lab02_suficiencia.py`. Código ejecutado.

Resultados Esperados

```
n=1000; exitos=305; media=0.305000
Conteos, historial y (n,media) coinciden: OK
Razón L(a)/L(b) en theta=0.2: 16.000000
Razón L(a)/L(b) en theta=0.7: 0.183673
Operaciones suma completa a cada llegada: 500500
Actualizaciones incrementales: 1000
```

Las dos muestras de cuatro observaciones tienen el mismo último dato y razones de verosimilitud que dependen de θ: ese resumen no es suficiente. La coincidencia de los tres cálculos de la media comprueba la implementación; la factorización es la justificación estadística.

Preguntas de Exploración

1. Repita con Poisson y conserve el tamaño muestral cuando no sea fijo.
2. En una normal de varianza conocida, compare media y mediana mediante distribuciones muestrales. No llame «varianza posterior» a cualquier variabilidad de un estimador.
3. En $N(\mu, 1)$ iid con al menos dos observaciones, identifique una estadística ancilar basada en residuos y use Basu bajo sus hipótesis. Una correlación muestral cercana a cero no demuestra independencia.

Laboratorio 3: Estimación Óptima en Agentes

Con los datos representados, la siguiente pregunta es cómo cambia la precisión al modificar un estimador. Los argumentos del Capítulo 4 proporcionan el criterio para comparar esas alternativas.

Laboratorio 3.1: Estimación de Funciones de Valor

Objetivo

Construir un ejemplo donde el condicionamiento Rao–Blackwell sea calculable, la cota de precisión incluya la derivada del funcional y la comparación entre estimadores pueda verificarse por simulación.

Conexión Teórica

Para X_i Bernoulli iid, defina un retorno abstracto de una decisión $G = 2X$ y su valor $J = 2\theta$. El estimador $U = 2X_1$ es insesgado. Si $T = \sum_i X_i$, la intercambiabilidad da

$$\mathbb{E}(U|T) = 2\frac{T}{n}.$$

Sus varianzas son $4\theta(1-\theta)$ y $4\frac{\theta(1-\theta)}{n}$. No se ha sustituido una esperanza condicional desconocida por una regresión sin justificar el error adicional.

Laboratorio 3.2: Rao-Blackwellización de Estimadores Monte Carlo

El programa genera veinte mil muestras de tamaño veinte. El objeto aleatorio comparado es un estimador por muestra, no veinte mil observaciones tratadas como una sola muestra de entrenamiento.

```
import numpy as np

rng = np.random.default_rng(20261027)
M, n, theta = 20000, 20, 0.3
x = rng.binomial(1, theta, size=(M, n))
u = 2 * x[:, 0]
rb = 2 * x.mean(axis=1)
print(f"Objetivo J=2theta={2*theta:.3f}")
```

```
print(f"Var teorica inicial={4*theta*(1-theta):.6f}")
print(f"Var teorica RB y cota CR={4*theta*(1-theta)/n:.6f}")
print(
    f"Var simulada inicial={u.var(ddof=1):.6f}; RB={rb.var(ddof=1):.6f}"
)
print(f"Medias simuladas: {u.mean():.6f}, {rb.mean():.6f}")
# No se usa una asercion aleatoria para demostrar un teorema.
assert np.isclose(4 * theta * (1 - theta) / n, 0.042)
```

Listado 5: `lab03_rb.py`. Código ejecutado.

```
Objetivo J=2theta=0.600
Var teorica inicial=0.840000
Var teorica RB y cota CR=0.042000
Var simulada inicial=0.845121; RB=0.041860
Medias simuladas: 0.606400, 0.600420
```

La desigualdad de varianzas se demuestra por esperanza condicional. Las varianzas simuladas aproximan las cantidades exactas; una realización favorable no prueba un resultado universal.

Laboratorio 3.3: Cramér-Rao como Límite de Precisión del Agente
En el interior Bernoulli, $I_1(\theta) = \frac{1}{\theta(1-\theta)}$ y $g'(\theta) = 2$, por lo que la cota regular insesgada para $J = g(\theta)$ es

$$\operatorname{Var}\left(\hat{J}\right) \geq \frac{\left(g'(\theta)\right)^2}{nI_1(\theta)} = \frac{4\theta(1-\theta)}{n}.$$

El estimador Rao–Blackwell la alcanza. La cota no afirma que todo estimador sesgado tenga varianza superior ni que cualquier función de valor sea regular.

Ejemplo numérico (SSCH) ***(sintético).*** En una fila multinomial de tamaño fijado ochenta, observar 24 transiciones a un estado da frecuencia 0.30 y error estándar plug-in $\sqrt{0.3\frac{0.7}{80}} \approx 0.051235$. Es un ejemplo de fila independiente, no una cifra extraída de la ejecución de `lab00_ssch.py`. El valor longitudinal requiere todas las filas usadas por la política y su propagación conjunta.

Preguntas de Exploración

1. Derive el sesgo y ECM de un estimador contraído de θ y compárelo con el UMVUE; explique por qué una menor varianza no viola Cramér–Rao.
2. En el modelo tabular, verifique numéricamente la derivada en varias direcciones del simplex antes de calcular la varianza delta.
3. Compare horizonte finito e infinito: con recompensas acotadas por B, derive el error de truncamiento $B\frac{\gamma^H}{1-\gamma}$.

Laboratorio 4: Tests e Intervalos de Confianza en Agentes

La comparación entre políticas añade una decisión al cálculo del valor. El Capítulo 4 y el Capítulo 9 permiten seguir qué error controla el contraste y qué información requiere su interpretación.

Laboratorio 4.1: A/B Testing de Políticas
Defina una diferencia de valores bajo la misma población, recompensa, horizonte y descuento. Contraste $H_0 : \Delta \leq \delta_0$ frente a $H_1 : \Delta > \delta_0$. Cambiar el descuento entre políticas cambia el criterio y no constituye por sí solo una comparación de mejora.

Con episodios compartidos, el error estándar usa las diferencias pareadas. Holm controla FWER con p-valores válidos; BH requiere las condiciones de dependencia correspondientes para FDR. Ninguno autoriza repetir libremente el análisis hasta obtener significación.

Gil Javier Fernández Cuervo

Laboratorio 4.2: Ejemplo SSCH *(sintético)* — Medicación vs. Estilo de Vida

El título conserva su motivación, pero el cálculo usa las dos políticas abstractas del subcaso de dos visitas de Ejemplo 8.25. Las contribuciones pareadas son $0.520, 0.340, 0.430, 0.610$. Se considera una realización iid con veinticinco apariciones de cada historia; esas frecuencias no fueron impuestas por estratificación. La misma estimación puede superar un margen 0.40 y no aportar evidencia suficiente para superar 0.47.

```
import numpy as np
from scipy.stats import norm

# Realizacion posible de 100 episodios iid, no diseno de cuotas.
d = np.tile([0.520, 0.340, 0.430, 0.610], 25)
se = d.std(ddof=1) / np.sqrt(len(d))
est = d.mean()
print(f"Diferencia={est:.6f}; SE={se:.6f}")
print(
    "IC bilateral 95%:",
    np.round(est + np.array([-1, 1]) * norm.ppf(0.975) * se, 6),
)
for margin in [0.40, 0.47]:
    z = (est - margin) / se
    p = norm.sf(z)
    lower = est - norm.ppf(0.95) * se
    print(
        f"Margen={margin:.2f}; p unilateral={p:.6f}; limite={lower:.6f}; rechazo={p<.05}"
    )
# Holm con p-valores ilustrativos prefijados, no seis comparaciones clinicas.
p = np.array([0.002, 0.018, 0.040, 0.070, 0.20, 0.80])
order = np.argsort(p)
adj = np.empty(6)
adj[order] = np.minimum(
    1, np.maximum.accumulate((6 - np.arange(6)) * p[order])
)
print("p ajustados Holm (ejemplo separado):", adj)
```

Listado 6: `lab04_comparacion.py`. Código ejecutado.

```
Diferencia=0.475000; SE=0.010113
IC bilateral 95%: [0.455179 0.494821]
Margen=0.40; p unilateral=0.000000; limite=0.458366; rechazo=True
Margen=0.47; p unilateral=0.310507; limite=0.458366; rechazo=False
p ajustados Holm (ejemplo separado): [0.012 0.09  0.16  0.21  0.4   0.8  ]
```

Los seis p-valores usados para ilustrar Holm son una lista sintética separada. No representan seis hallazgos del SSCH. La conclusión estadística del ejemplo no se interpreta como comparación de medicamentos.

Preguntas de Exploración

1. Compare un intervalo de diferencias pareadas con la suma incorrecta de varianzas que ignora su covarianza.
2. Diseñe tres análisis intermedios con niveles cuya suma sea 0.05. Justifique el control por unión de eventos y discuta el costo en potencia.
3. Simule potencia para márgenes y tamaños prefijados; reporte error Monte Carlo y no seleccione el margen después de ver los resultados.

Laboratorio 5: Asintótica Aplicada en Agentes

Una vez calculado el estimador, interesa reproducir su variación entre muestras. El laboratorio utiliza las aproximaciones y el remuestreo del Capítulo 4 para estudiar esa incertidumbre.

Laboratorio 5.1: Bootstrap de Políticas

Se estudia cobertura en un experimento con verdad conocida. Cada réplica genera cien contribuciones iid de la distribución equiprobable de cuatro valores del subcaso de dos visitas. Dentro de cada réplica se construye un IC normal y uno percentil con 499 remuestras de episodios. Se realizan 500 réplicas independientes. La cobertura estimada tiene error Monte Carlo $\sqrt{\hat{p}\frac{1-\hat{p}}{500}}$.

```
import numpy as np
from scipy.stats import norm

rng = np.random.default_rng(20261027)
# Distribucion conocida de las contribuciones pareadas del ejemplo de dos visitas.
values = np.array([0.520, 0.340, 0.430, 0.610])
truth = values.mean()
M, n, B = 500, 100, 499
cover = np.zeros((M, 2), bool)
length = np.zeros((M, 2))
for j in range(M):
    d = rng.choice(values, size=n)
    se = d.std(ddof=1) / np.sqrt(n)
    intervals = [
        d.mean() + np.array([-1, 1]) * norm.ppf(0.975) * se,
        np.quantile(
            rng.choice(d, size=(B, n)).mean(axis=1), [0.025, 0.975]
        ),
    ]
    for k, (lo, hi) in enumerate(intervals):
        cover[j, k] = lo <= truth <= hi
        length[j, k] = hi - lo
for k, name in enumerate(["Normal", "Bootstrap percentil"]):
    p = cover[:, k].mean()
    mcse = np.sqrt(p * (1 - p) / M)
    print(
        f"{name}: cobertura={p:.3f}; MCSE={mcse:.4f}; longitud={length[:,k].mean():.5f}"
    )
print(f"M={M}; n={n}; B={B}; verdadero={truth:.3f}")
print("Varianza individual:", values.var())
print("Varianza de la media:", values.var() / n)
```

Listado 7: `lab05_bootstrap.py`. Código ejecutado.

Las contribuciones usan modelos fijados de antemano. Si se aprende una política o auxiliares en la misma muestra, ese aprendizaje debe incluirse en el procedimiento de evaluación y remuestreo o controlarse mediante una expansión válida. No se extrapola la cobertura del ejemplo a ese otro estimador.

Laboratorio 5.2: Incertidumbre Epistémica vs. Aleatoria

La distribución de una contribución tiene varianza 0.010125; la media de cien contribuciones iid tiene varianza 0.00010125. La variabilidad individual permanece aunque aumente el tamaño, mientras la de la media disminuye bajo este diseño. Más datos no eliminan sesgo de modelo o falta de identificación.

Ejemplo numérico (SSCH) *(sintético)*.

```
Normal: cobertura=0.958; MCSE=0.0090; longitud=0.03958
Bootstrap percentil: cobertura=0.950; MCSE=0.0097; longitud=0.03900
M=500; n=100; B=499; verdadero=0.475
Varianza individual: 0.010124999999999999
Varianza de la media: 0.00010124999999999998
```

Estas son coberturas de una simulación limitada y completamente especificada, no una demostración de validez general. Aumentar las réplicas Monte Carlo mejora su precisión; aumentar las remuestras bootstrap resuelve otra fuente de error numérico.

Preguntas de Exploración

1. Aumente separadamente el número de réplicas, el tamaño muestral y las remuestras internas. Distinga los tres efectos.

2. Compare una razón de valores cuyo denominador está alejado de cero con otra cuyo denominador se aproxima a cero; revise delta y bootstrap.
3. Introduzca aprendizaje de auxiliares y compare reajuste completo con mantener ajustes fijos. Identifique el estimando y la incertidumbre en cada procedimiento.

Laboratorio 6: DML y Estimación Semiparamétrica

Cuando la estimación utiliza modelos auxiliares, hay que separar el aprendizaje de esos modelos de la evaluación del objetivo. El Capítulo 4 y el Teorema 4.150 explican la relación que se examina en este laboratorio.

Objetivo

Implementar AIPW con cross-fitting y separar dos verificaciones: la identidad poblacional de doble robustez y el comportamiento de un estimador aprendido en una muestra. Se utiliza un generador conocido, sin atribuir el resultado a una replicación de datos clínicos.

Conexión Teórica

Con $e(X) = \mathbb{P}(A = 1|X)$ y $m_a(X) = \mathbb{E}(Y|A = a, X)$, el pseudoresultado es

$$D = m_1(X) - m_0(X) + \frac{A(Y - m_1(X))}{e(X)} - \frac{(1 - A)(Y - m_0(X))}{1 - e(X)}.$$

Su esperanza es el ATE bajo identificación. La influencia centrada es $D - \psi$, no D sin centrar. Para inferencia con ajustes aprendidos se requieren condiciones de momentos, soporte, convergencia y productos de errores, además de la separación de entrenamiento y evaluación.

Dataset y Setup

Se generan dos mil unidades iid con X uniforme en $[-1, 1]$, $e(X) = \frac{1}{1+\exp(-0.6X)}$, $m_0(X) = X + X^2$ y $m_1(X) = m_0(X) + 1 + 0.5X$. El error es normal estándar, independiente de covariable y asignación. En este generador, el ATE es exactamente uno. Se ajustan cinco folds con propensión logística y regresiones cuadráticas separadas por brazo. Las funciones verdaderas pertenecen a los modelos ajustados; el ejercicio no demuestra validez para todo algoritmo ML.

Implementación

```
import numpy as np
from scipy.special import expit
from scipy.stats import norm
from sklearn.linear_model import LogisticRegression, LinearRegression
from sklearn.model_selection import KFold

rng = np.random.default_rng(20261027)
n = 2000
x = rng.uniform(-1, 1, size=n)
X = x[:, None]
e = expit(0.6 * x)
a = rng.binomial(1, e)
m0 = x + x * x
m1 = m0 + 1 + 0.5 * x
y = m0 + a * (1 + 0.5 * x) + rng.normal(size=n)
eh = np.zeros(n)
h0 = np.zeros(n)
h1 = np.zeros(n)
for train, test in KFold(5, shuffle=True, random_state=42).split(X):
    ps = LogisticRegression(C=1e6, max_iter=1000).fit(X[train], a[train])
    eh[test] = ps.predict_proba(X[test])[:, 1]
    for arm, out in [(0, h0), (1, h1)]:
        ix = train[a[train] == arm]
        design = np.column_stack([x[ix], x[ix] ** 2])
```

```
        model = LinearRegression().fit(design, y[ix])
        out[test] = model.predict(
            np.column_stack([x[test], x[test] ** 2])
        )
assert np.all((eh > 0) & (eh < 1))
d = h1 - h0 + a * (y - h1) / eh - (1 - a) * (y - h0) / (1 - eh)
se = d.std(ddof=1) / np.sqrt(n)
print(f"ATE verdadero=1; AIPW={d.mean():.6f}; SE={se:.6f}")
print(
    "IC normal 95%:",
    np.round(d.mean() + np.array([-1, 1]) * norm.ppf(0.975) * se, 6),
)
print(
    "Propensiones ajustadas min,max:", np.round([eh.min(), eh.max()], 6)
)
# Identidad poblacional DR comprobada por cuadratura, no por una sola muestra.
z, w = np.polynomial.legendre.leggauss(80)
w = w / 2
true_e = expit(0.6 * z)
t0 = z + z * z
t1 = t0 + 1 + 0.5 * z
for name, ee, u0, u1 in [
    ("ambos correctos", true_e, t0, t1),
    ("solo propension", true_e, np.zeros_like(z), np.zeros_like(z)),
    ("solo resultado", np.full_like(z, 0.5), t0, t1),
    (
        "ambos incorrectos",
        np.full_like(z, 0.5),
        np.zeros_like(z),
        np.zeros_like(z),
    ),
]:
    expected = (
        u1
        - u0
        + true_e * (t1 - u1) / ee
        - (1 - true_e) * (t0 - u0) / (1 - ee)
    )
    print(f"Esperanza AIPW, {name}: {w@expected:.6f}")
```

Listado 8: `lab06_aipw.py`. Código ejecutado.

Resultados Esperados

```
ATE verdadero=1; AIPW=0.977928; SE=0.045716
IC normal 95%: [0.888328 1.067529]
Propensiones ajustadas min,max: [0.334971 0.695206]
Esperanza AIPW, ambos correctos: 1.000000
Esperanza AIPW, solo propension: 1.000000
Esperanza AIPW, solo resultado: 1.000000
Esperanza AIPW, ambos incorrectos: 1.245613
```

La segunda parte integra la esperanza poblacional mediante cuadratura. Muestra la cancelación cuando uno de los auxiliares es verdadero y un sesgo cuando ambos son incorrectos en este ejemplo. Una única estimación muestral cercana a uno no habría demostrado consistencia. La comprobación de propensiones finitas no prueba positividad poblacional; aquí esta se conoce por el generador.

Preguntas de Exploración

1. Repita la simulación para varios tamaños y reporte sesgo, RMSE, cobertura

y error Monte Carlo, reajustando todos los modelos en cada réplica.

1. Sustituya la propensión o las regresiones por constantes. Distinga

consistencia bajo una especificación correcta de validez del IC calculado como si ambas fueran correctas.

1. Sustituya los modelos paramétricos por aproximadores no paramétricos y

registre qué condiciones de la expansión siguen justificadas. El desempeño predictivo por sí solo no demuestra el producto de tasas requerido.

1. Si se aplica a datos reales, documente exposición, población, faltantes,

identificación y diseño. No reutilice los valores verdaderos de este simulador.

Ejercicios sobre identificación y modelos auxiliares

Los cálculos anteriores permiten volver a las condiciones que justifican el estimador. Los ejercicios siguientes examinan el papel del modelo, de la observación y de la separación entre entrenamiento y evaluación.

Ejercicio 10.1. *En una familia regular de localización con densidad conocida $f(x-\mu)$, derive el score, su información y la influencia eficiente para μ. Indique condiciones de diferenciabilidad e integrabilidad. Explique por qué el modelo es paramétrico y qué cambiaría si f fuera desconocida.*

Ejercicio 10.2. *Observe (X, S, SY), con S indicador de observación. Bajo independencia condicional entre Y y S dado X, propensión conocida positiva y segundos momentos, derive la influencia de $\psi = \mathbb{E}(Y)$ usando $m(X) = \mathbb{E}(Y|X)$. Distinga identificación, centrado y eficiencia; el resultado Y no está disponible cuando $S = 0$.*

Ejercicio 10.3. *Para ATE bajo intercambio condicional y positividad, escriba AIPW usando ambas regresiones m_0, m_1 y la propensión e. Derive su resto poblacional cuando los auxiliares son funciones fijas. Construya un ejemplo en el que ambos modelos incorrectos produzcan sesgo distinto de cero.*

Ejercicio 10.4. *Diseñe cross-fitting de cinco folds para mil episodios independientes, sin repartir visitas del mismo episodio entre entrenamiento y evaluación. Indique qué evidencia apoya las tasas requeridas y por qué error predictivo pequeño o balance muestral no demuestra por sí solo una tasa poblacional.*

Ejercicio 10.5. *En $Y = \beta X + g(Z) + \epsilon$, especifique exogeneidad condicional, varianza del error y modelo de covariables antes de derivar una influencia eficiente. Compare homocedasticidad y heterocedasticidad; explique por qué OLS que omite $g(Z)$ puede ser inconsistente, no solo menos eficiente.*

Laboratorio 7: Regla de Decisión de Wald

El recorrido vuelve ahora a la elección de una regla. La pérdida y el criterio de riesgo del Capítulo 2 permiten interpretar por qué las mismas observaciones pueden conducir a decisiones diferentes.

Objetivo

Distinguir la regla de Bayes de una decisión de los algoritmos de exploración en un bandit. Thompson Sampling no se identifica con la política Bayes óptima de horizonte finito; UCB1 tampoco se denomina regla minimax de Wald.

Conexión Teórica

Con una ronda restante y recompensa Bernoulli, la acción Bayes maximiza la media posterior. Con varias rondas, la elección afecta la información futura y la optimización bayesiana es un problema dinámico. Thompson Sampling muestrea parámetros del posterior y actúa según ellos: es otro procedimiento.

El código mide pseudo-arrepentimiento

$$\sum_{t=1}^{T} \left(\max_a \theta_a - \theta_{A_t} \right).$$

Es aleatorio por la selección de acciones, pero no incluye el ruido de la recompensa realizada. No es el riesgo Bayes integrado respecto de un prior. Una media de cien corridas tampoco verifica una cota de orden asintótico.

Dataset y Setup

Cinco brazos Bernoulli con probabilidades $(0.1, 0.3, 0.5, 0.7, 0.9)$, dos mil rondas y cien corridas por algoritmo. Se comparan Thompson Sampling, UCB1 y ϵ-greedy con $\epsilon = 0.1$. Se incluyen todas las rondas iniciales en el pseudo-arrepentimiento. Las semillas se fijan por corrida; no se supone que produzcan trayectorias idénticas entre algoritmos.

Implementación

```
import numpy as np

THETA = np.array([0.1, 0.3, 0.5, 0.7, 0.9])
K = len(THETA)


def run(method, seed, T=2000):
    rng = np.random.default_rng(seed)
    counts = np.zeros(K, int)
    sums = np.zeros(K)
    regret = 0.0
    for t in range(T):
        if method == "TS":
            a = int(np.argmax(rng.beta(1 + sums, 1 + counts - sums)))
        elif method == "UCB1":
            a = (
                t
                if t < K
                else int(
                    np.argmax(
                        sums / counts
                        + np.sqrt(2 * np.log(t + 1) / counts)
                    )
                )
            )
        else:
            a = (
                int(rng.integers(K))
                if rng.random() < 0.1
                else int(np.argmax(sums / np.maximum(counts, 1)))
            )
        y = rng.binomial(1, THETA[a])
        counts[a] += 1
        sums[a] += y
        regret += THETA.max() - THETA[a]  # Incluye las rondas iniciales.
    assert counts.sum() == T
    return regret


if __name__ == "__main__":
    for method in ["TS", "UCB1", "epsilon-greedy"]:
        values = np.array([run(method, 20261027 + j) for j in range(100)])
        print(
            f"{method}: pseudo-regret medio={values.mean():.3f}; MCSE={values.std(ddof=1)/10:.3f}"
        )
    # Una decision restante: Bayes elige la mayor media posterior.
    means = np.array([3 / 4, 5 / 10])
    print("Bayes con una ronda restante:", int(np.argmax(means)))
```

Listado 9: `lab07_bandit.py`. Código ejecutado.

Resultados Esperados

```
TS: pseudo-regret medio=14.404; MCSE=0.451
UCB1: pseudo-regret medio=94.150; MCSE=1.294
epsilon-greedy: pseudo-regret medio=104.736; MCSE=2.287
Bayes con una ronda restante: 0
```

La comparación corresponde a este vector de probabilidades, horizonte e inicialización. No demuestra superioridad uniforme, admisibilidad ni optimalidad minimax. El error Monte Carlo acompaña las medias para evitar interpretar una sola trayectoria como propiedad general.

Valeria Lincovil Curivil

Preguntas de Exploración

1. Compare medias posteriores y Thompson Sampling con una sola ronda restante; explique por qué las decisiones pueden diferir.
1. Varíe las brechas entre brazos y el prior. Reporte por separado el arrepentimiento inicial y el total, con incertidumbre Monte Carlo.
1. Para dos brazos y un horizonte pequeño, enumere estados de creencia y resuelva la recursión Bayes exacta. Compárela con Thompson Sampling.
1. Si diseña un selector entre algoritmos, evalúelo en corridas nuevas.

No atribuya al selector las garantías de sus componentes sin otro argumento.

Laboratorio 8: MDP y Programación Dinámica

Cuando una acción cambia el futuro, la comparación requiere una función de valor. El Capítulo 3 y el Teorema 3.12 dan el fundamento para seguir el cálculo y su residuo.

Objetivo

Calcular la política óptima del SSCH tabular mediante iteración de valores y evaluación exacta de políticas. Se distingue una cota determinista del error computacional de la incertidumbre por estimar el modelo.

Conexión Teórica

En el modelo finito descontado, Bellman contrae en norma suprema. Si $e = \|\mathcal{T}V - V\|_\infty$, entonces

$$\|V - V^*\|_\infty \leq \frac{e}{1-\gamma}.$$

El programa termina por esta cota. La pérdida de la política greedy es otra cantidad y requiere su cota correspondiente. La iteración de políticas se ejecuta con evaluación por sistema lineal y conserva la acción previa en empates numéricos. No se afirma una tasa cuadrática universal.

Dataset y Setup

Se importa `model`, `R`, `GAMMA` y `evaluate` de `lab00_ssch.py`. El planificador recibe el modelo verdadero conocido del simulador, no la matriz estimada con ochenta transiciones por fila. El contraste entre ambas matrices queda como extensión para separar error estadístico y computacional.

Implementación

```
import numpy as np
from lab00_ssch import model, R, GAMMA, evaluate

P = model()


def qvalues(v):
    return R + GAMMA * np.einsum("saj,j->sa", P, v)


def bellman(v):
    return qvalues(v).max(axis=1)


v = np.zeros(5)
for k in range(10000):
    v = bellman(v)
    res = np.max(np.abs(bellman(v) - v))
    if res / (1 - GAMMA) < 1e-9:
```

```
        break
else:
    raise RuntimeError("VI no converge")
pi = np.zeros(5, int)
for j in range(1000):
    vp, _ = evaluate(P, np.eye(4)[pi])
    q = qvalues(vp)
    new = pi.copy()
    # Conservar accion anterior en empates numericos.
    for s in range(5):
        best = int(q[s].argmax())
        if q[s, best] > q[s, pi[s]] + 1e-12:
            new[s] = best
    if np.array_equal(new, pi):
        break
    pi = new
else:
    raise RuntimeError("PI no converge")
assert np.max(np.abs(v - vp)) < 1e-8
print("Politica optima (acciones 1..4):", pi + 1)
print("V* por PI:", np.round(vp, 6))
print(f"VI: {k+1} actualizaciones; PI: {j+1} evaluaciones")
print(f"Residuo VI={res:.3e}; cota error valor={res/(1-GAMMA):.3e}")
rng = np.random.default_rng(42)
for _ in range(100):
    x, y = rng.normal(size=(2, 5))
    assert (
        np.max(np.abs(bellman(x) - bellman(y)))
        <= GAMMA * np.max(np.abs(x - y)) + 1e-12
    )
print("Comprobaciones numericas de contraccion: OK")
```

Listado 10: `lab08_bellman.py`. Código ejecutado.

Resultados Esperados

```
Politica optima (acciones 1..4): [2 3 3 4 4]
V* por PI: [7.77928  7.311139 7.096966 7.102004 6.46565 ]
VI: 216 actualizaciones; PI: 3 evaluaciones
Residuo VI=9.645e-11; cota error valor=9.645e-10
Comprobaciones numericas de contraccion: OK
```

La coincidencia entre VI y PI y las comprobaciones numéricas detectan posibles errores de implementación. El teorema de contracción justifica la cota para todas las entradas del espacio considerado; probar cien pares de vectores no sustituye ese teorema. Los números de iteraciones tampoco son una comparación directa de costos: una evaluación de política y una actualización de valores no realizan el mismo trabajo.

Preguntas de Exploración

1. Cambie el descuento y compare residuo, cota de error y número de

actualizaciones. No use una fórmula que divida por $\|V_0\|$ si $V_0 = 0$.

1. Planifique con la matriz estimada de 0 y evalúe la política resultante

bajo la matriz verdadera. Separe error de planificación y error del modelo.

1. Extienda a un entorno con estados terminales. En el backup, anule el

valor futuro después de la terminación; documente aparte la truncación por un límite artificial de tiempo.

Laboratorio 9: Demostración de la Incrustación Fiel

Con la regla y el proceso definidos, podemos comprobar qué conserva su representación. Este laboratorio examina la identidad del Teorema 5.3 dentro del alcance del Capítulo 5.

Objetivo

Verificar por enumeración la identidad de riesgo y retorno en un problema finito de una decisión. La demostración general está en el capítulo teórico; este laboratorio comprueba todas las reglas del ejemplo.

Conexión Teórica

El índice desconocido θ identifica la ley de observación. El estado observado del MDP es x, no θ. Para cada regla determinista $\delta(x)$, la política copiada recibe recompensa evaluativa $-L(\theta, \delta(x))$ y termina. Al promediar respecto de P_θ,

$$J_\theta(\pi_\delta) = -R(\theta, \delta).$$

No se entrega al agente el parámetro verdadero ni se presupone que la recompensa evaluativa pueda observarse en una aplicación.

Dataset y Setup

Hay dos modelos, dos observaciones posibles y dos acciones. La matriz de probabilidades de observación es

$$P_X = \begin{pmatrix} 0.8 & 0.2 \\ 0.2 & 0.8 \end{pmatrix},$$

y la de pérdidas, con filas por modelo y columnas por acción, es

$$L = \begin{pmatrix} 0 & 1 \\ 3 & 0 \end{pmatrix}.$$

El prior asigna probabilidad $\frac{1}{2}$ a cada modelo. Se enumeran las cuatro reglas deterministas, incluida la que elige una acción distinta para cada observación. No se confunde la optimización de una acción posterior con una verificación del riesgo de una regla completa.

Implementación

```
import numpy as np
from itertools import product

# Experimento finito: theta indexa modelos, x es el estado observado.
theta = np.array([0.2, 0.8])
prior = np.array([0.5, 0.5])
PX = np.array([[0.8, 0.2], [0.2, 0.8]])  # Filas theta; columnas x=0,1.
L = np.array([[0, 1], [3, 0.0]])  # Filas theta; acciones 0,1.
rules = list(product([0, 1], repeat=2))
risks = []
for rule in rules:
    risk = np.array(
        [
            sum(PX[k, x] * L[k, rule[x]] for x in range(2))
            for k in range(2)
        ]
    )
    ret = np.array(
        [
            sum(PX[k, x] * (-L[k, rule[x]]) for x in range(2))
            for k in range(2)
        ]
    )
    assert np.allclose(risk, -ret)
    risks.append(risk)
    print(f"regla={rule}; riesgo={risk}; retorno={ret}")
risks = np.array(risks)
bayes = risks @ prior
best = int(bayes.argmin())
print("Regla Bayes:", rules[best], "; riesgo Bayes:", bayes[best])
assert rules[best] == (0, 1)
# Imagen exacta de un conjunto: objetivo de una accion fijada, no optimizada.
```

Dr. Jaime Ruiz-Serra Curivil

```
C = np.array([0.25, 0.55])
c = 0.2
print("Imagen por g(theta)=-c*(1-theta):", -c * (1 - C))
print("Todas las reglas enumeradas satisfacen J=-R: OK")
```

Listado 11: `lab09_incrustacion.py`. Código ejecutado.

Resultados Esperados

```
regla=(0, 0); riesgo=[0. 3.]; retorno=[ 0. -3.]
regla=(0, 1); riesgo=[0.2 0.6]; retorno=[-0.2 -0.6]
regla=(1, 0); riesgo=[0.8 2.4]; retorno=[-0.8 -2.4]
regla=(1, 1); riesgo=[1. 0.]; retorno=[-1.  0.]
Regla Bayes: (0, 1) ; riesgo Bayes: 0.4
Imagen por g(theta)=-c*(1-theta): [-0.15 -0.09]
Todas las reglas enumeradas satisfacen J=-R: OK
```

La regla Bayes del experimento finito es $(0, 1)$ y su riesgo Bayes es 0.4. La última línea de imagen de un conjunto es un ejemplo separado: para una acción fijada y $g(\theta) = -0.2(1 - \theta)$, la imagen de $[0.25, 0.55]$ es $[-0.15, -0.09]$. Si el conjunto inicial fuera un IC válido, su imagen heredaría al menos su cobertura. No se convierte un intervalo posterior en uno frecuentista mediante un cambio de nombre, ni se afirma cobertura para una política seleccionada con los mismos datos sin tratar la selección.

Preguntas de Exploración

1. Cambie el prior y calcule todas las pérdidas Bayes. Identifique los

valores donde cambia la regla y cómo se resuelven empates.

1. Añada una segunda decisión con observación intermedia. Especifique el

nuevo problema y explique qué parte ya no queda cubierta por la identidad de una decisión del libro.

1. Para un funcional no monótono, compare la imagen del conjunto completo

con la transformación de sus extremos. Distinga esta construcción del método delta local.

Laboratorio 10: Off-Policy Evaluation

La evaluación pasa ahora a datos producidos por otra política. El Capítulo 7 y el Capítulo 8 permiten distinguir la estimación del valor, los diagnósticos y la incertidumbre de la comparación.

Laboratorio 10.1: Pipeline OPE Completo en CartPole

Objetivo

Comparar DM, IS, PDIS y DR secuencial en CartPole con horizonte truncado prefijado de veinte decisiones y descuento 0.99. El objetivo es el retorno hasta esa truncación o terminación anterior; no es el valor infinito ni el rendimiento hasta el límite estándar del entorno.

El registro elige cada acción con probabilidad 0.5. La política objetivo es una función fija de las coordenadas observadas:

$$\pi(1|s) = 0.2 + \frac{0.6}{1 + \exp(-(4s_3 + s_4))}.$$

Las probabilidades de ambas acciones suman uno y están entre 0.2 y 0.8. No se asigna el mismo numerador a las dos acciones ni se inventa una propensión pequeña para sustituir datos ausentes.

Arquitectura LangGraph

La arquitectura conceptual tiene nodos de recolección, ajuste de q_t, contribuciones y diagnóstico. El código los ejecuta como funciones de Python para que el cálculo sea inspeccionable sin un servicio externo. Si se encapsulan en LangGraph, deben conservarse exactamente los mismos datos, particiones y fórmulas; la orquestación no añade validez estadística.

Se usan seiscientos episodios de entrenamiento independientes de mil de evaluación. El crítico se ajusta hacia atrás mediante regresión ridge y rasgos polinómicos, ponderando la continuación por la política objetivo. Puede estar mal especificado. Las probabilidades de registro son conocidas; esto conserva el centrado de IS y DR bajo el diseño, condicionado al ajuste externo, con las condiciones de integrabilidad pertinentes.

La contribución DR de un episodio es

$$D_i = \hat{v}_0(S_{i,0}) + \sum_{t=0}^{H_i-1} \gamma^t \rho_{i,0:t}\big(R_{i,t} + \gamma \hat{v}_{t+1}(S_{i,t+1}) - \hat{q}_t(S_{i,t}, A_{i,t})\big),$$

con continuación cero después de terminar. El código incluye el término inicial, descuento, razón acumulada, valor siguiente y tratamiento de la terminación. Los intervalos usan variación entre episodios independientes.

La interfaz del entorno sigue la documentación oficial de Gymnasium: se fijan semillas al reiniciar y se distinguen terminación y truncación. En este objetivo finito, ambas ponen fin al retorno observado.

```
import numpy as np
import gymnasium as gym
from scipy.special import expit
from scipy.stats import norm

H, GAMMA = 20, 0.99


def target(s):
    p = 0.2 + 0.6 * expit(4 * s[2] + s[3])
    return np.array([1 - p, p])


def collect(n, seed, on_target=False):
    rng = np.random.default_rng(seed)
    env = gym.make("CartPole-v1")
    data = []
    for _ in range(n):
        s, _ = env.reset(seed=int(rng.integers(2**31 - 1)))
        episode = []
        for t in range(H):
            probs = target(s) if on_target else np.array([0.5, 0.5])
            a = int(rng.choice(2, p=probs))
            nxt, r, terminated, truncated, _ = env.step(a)
            end = bool(terminated or truncated or t == H - 1)
            episode.append(
                (s.copy(), a, float(r), nxt.copy(), end, float(probs[a]))
            )
            s = nxt
            if end:
                break
        data.append(episode)
    env.close()
    return data


def features(s, a):
    return np.r_[1.0, s, s * s, float(a), a * s]


def fit_q(train):
    beta = [np.zeros(14) for _ in range(H)]
```

Daniele Lincovil Curivil

```
    def value(t, s):
        if t >= H:
            return 0.0
        return sum(
            target(s)[a] * (features(s, a) @ beta[t]) for a in range(2)
        )

    for t in reversed(range(H)):
        rows = [ep[t] for ep in train if len(ep) > t]
        if not rows:
            raise ValueError(
                "Sin datos de entrenamiento para este tiempo"
            )
        X = np.array([features(s, a) for s, a, r, nxt, end, b in rows])
        y = np.array(
            [
                r + (0 if end else GAMMA * value(t + 1, nxt))
                for s, a, r, nxt, end, b in rows
            ]
        )
        beta[t] = np.linalg.solve(X.T @ X + 0.1 * np.eye(14), X.T @ y)
    return beta


def scores(episode, beta):
    def q(t, s, a):
        return float(features(s, a) @ beta[t]) if t < H else 0.0

    def v(t, s):
        return (
            sum(target(s)[a] * q(t, s, a) for a in range(2))
            if t < H
            else 0.0
        )

    dm = v(0, episode[0][0])
    dr = dm
    w = 1.0
    pdis = 0.0
    ret = 0.0
    for t, (s, a, r, nxt, end, b) in enumerate(episode):
        if not (0 < b <= 1):
            raise ValueError("Propension registrada no valida")
        w *= target(s)[a] / b
        ret += GAMMA**t * r
        pdis += GAMMA**t * w * r
        dr += (
            GAMMA**t
            * w
            * (r + (0 if end else GAMMA * v(t + 1, nxt)) - q(t, s, a))
        )
    return dm, w * ret, pdis, dr, w, ret


def pipeline():
    train = collect(600, 20261027)
    evaluation = collect(1000, 20261028)
    beta = fit_q(train)
    out = np.array([scores(ep, beta) for ep in evaluation])
    for k, name in enumerate(["DM", "IS", "PDIS", "DR"]):
        est = out[:, k].mean()
        se = out[:, k].std(ddof=1) / np.sqrt(len(out))
        print(f"{name}: media={est:.5f}; SE entre episodios={se:.5f}")
    # El SE de DM no contempla el sesgo de aproximacion ni todo el entrenamiento.
    d = out[:, 3]
    se = d.std(ddof=1) / np.sqrt(len(d))
    print(
        "IC DR normal 95%:",
        np.round(d.mean() + np.array([-1, 1]) * norm.ppf(0.975) * se, 5),
    )
    w = out[:, 4]
    print(
        f"ESS pesos finales={w.sum()**2/(w@w):.2f}/1000; max={w.max():.3f}"
    )
    # Referencia independiente on-policy: estimacion MC, no verdad exacta.
    reference = collect(5000, 20261029, on_target=True)
    g = np.array(
```

Dr. Jaime Lincoyil Curivil

```
        [
            sum(GAMMA**t * row[2] for t, row in enumerate(ep))
            for ep in reference
        ]
    )
    print(
        f"Referencia on-policy={g.mean():.5f}; SE={g.std(ddof=1)/np.sqrt(len(g)):.5f}"
    )
    assert np.isfinite(out).all() and np.all(w > 0)
    return {
        "n_evaluation": len(out),
        "horizon": H,
        "dr": float(d.mean()),
        "se": float(se),
    }


if __name__ == "__main__":
    pipeline()
```

Listado 12: `lab10_cartpole.py`. Código ejecutado.

Salida de la ejecución de referencia.

```
DM: media=16.98554; SE entre episodios=0.00096
IS: media=16.85609; SE entre episodios=0.53158
PDIS: media=17.12232; SE entre episodios=0.24905
DR: media=17.30569; SE entre episodios=0.04221
IC DR normal 95%: [17.22297 17.38842]
ESS pesos finales=535.29/1000; max=4.014
Referencia on-policy=17.24282; SE=0.02907
```

La referencia on-policy usa otros cinco mil episodios y tiene su propio error Monte Carlo; no es una verdad exacta. El SE impreso para DM solo describe variación de su predicción entre estados iniciales condicionada al entrenamiento: no contempla su sesgo de aproximación ni toda la incertidumbre del ajuste. No debe interpretarse como un IC válido para el valor verdadero. En este experimento, el IC DR se justifica por la ruta de contribuciones independientes y registro conocido; no por SAVE.

Laboratorio 10.2: Diagnóstico de Overlap y Protocolo de Fallback

El soporte se conoce aquí por construcción. El ESS de los pesos finales resume su concentración en la muestra; no certifica soporte poblacional, normalidad del estimador ni cobertura. La unidad del denominador del ESS es el episodio, coherente con esos pesos.

Si un registro necesario tiene probabilidad cero bajo la política de comportamiento y positiva bajo la objetivo, la evaluación por importancia no está identificada a partir de esos datos sin supuestos adicionales. Si hay concentración extrema, se informa sensibilidad y precisión; no se cambia silenciosamente a DM como si garantizara el mismo objetivo. Recortar pesos introduce sesgo, y restringir acciones o población puede cambiar el estimando. Cada alternativa necesita una justificación y un dictamen nuevo.

Preguntas de Exploración

1. Repita entrenamiento y evaluación en muestras nuevas para medir sesgo,

RMSE y cobertura. Use una referencia on-policy mucho más precisa y reporte su error residual.
1. Varíe el horizonte y mantenga fijas las políticas. Examine pesos acumulados,

ESS y varianza de IS, PDIS y DR sin atribuir eficiencia universal a DR.
1. Compare pesos recortados y normalizados, documentando el sesgo y la

fórmula de varianza correspondiente. No use el IC de IS sin modificaciones.
1. Añada nodos de orquestación y compruebe que sus contribuciones coinciden

con las funciones de referencia para los mismos episodios.

Laboratorio 11: Inferencia Secuencial para Funciones de Valor

La estructura temporal de los datos vuelve a ser decisiva al construir un intervalo. El Capítulo 8, el Teorema 8.7 y la Definición 8.11 orientan la elección de la varianza y la lectura de sus límites.

Objetivo

Estudiar el efecto de dependencia temporal en una media y comparar HAC, bootstrap por bloques y un IC que ignora la dependencia. «Secuencial» describe aquí la estructura de los datos; el análisis se hace al tamaño prefijado y no proporciona validez bajo parada opcional.

Conexión Teórica

Use una cadena estacionaria de dos estados con matriz

$$P = \begin{pmatrix} 0.8 & 0.2 \\ 0.2 & 0.8 \end{pmatrix}$$

y observable $X_t \in \{-1, 1\}$. Su media es cero, su varianza uno y su autocovarianza es 0.6^k. Por tanto,

$$\sigma^2_{\mathrm{LR}} = 1 + 2 \sum_{k \geq 1} 0.6^k = 4.$$

El error estándar asintótico de la media es $\frac{2}{\sqrt{T}}$, frente a $\frac{1}{\sqrt{T}}$ si se ignora la dependencia. Esta comparación tiene verdad analítica; no se deduce de que dos intervalos resulten parecidos.

La cadena es reversible y su radio no trivial es 0.6. La distancia en variación total desde cualquiera de sus estados es $0.5(0.6)^k$. El tiempo calculado para esa cota no se generaliza a cualquier MDP mediante una fórmula que solo incluya un autovalor estimado.

Dataset y Setup

Mil pasos de una cadena iniciada en su distribución estacionaria uniforme. Se muestran HAC con rezagos 10, 20 y 40, y bootstrap de bloques móviles con longitud veinte y 999 remuestras. Una evaluación de cobertura adicional usa 500 cadenas nuevas para el intervalo iid incorrecto y HAC de rezago veinte. El estudio no estima cobertura del bootstrap en esas 500 réplicas.

Implementación

```
import numpy as np
from scipy.stats import norm

P = np.array([[0.8, 0.2], [0.2, 0.8]])
rho = 0.6
T = 1000


def chain(rng, n):
    x = np.empty(n)
    state = int(rng.integers(2))
    for t in range(n):
        x[t] = 2 * state - 1
        if rng.random() < 0.2:
            state = 1 - state
    return x


def hac(x, K):
    if not (0 <= K < len(x)):
        raise ValueError("Rezagos fuera de rango")
    z = x - x.mean()
```

Dr. Jaime Lizcano Vila

```
    n = len(z)
    v = z @ z / n
    for k in range(1, K + 1):
        v += 2 * (1 - k / (K + 1)) * (z[k:] @ z[:-k]) / n
    if v < -1e-10:
        raise ArithmeticError("Varianza negativa: revisar implementacion")
    return max(0.0, v)


rng = np.random.default_rng(20261027)
x = chain(rng, T)
print(f"Media verdadera=0; estimada={x.mean():.5f}; varianza LR exacta=4")
for K in [10, 20, 40]:
    var = hac(x, K)
    se = np.sqrt(var / T)
    print(
        f"HAC K={K}: LR={var:.5f}; IC={np.round(x.mean()+np.array([-1,1])*norm.ppf(.975)*se,5)}"
    )
# Moving block bootstrap: bloques solapados y longitud prefijada.
b, B = 20, 999
starts = rng.integers(0, T - b + 1, size=(B, int(np.ceil(T / b))))
ix = (starts[:, :, None] + np.arange(b)).reshape(B, -1)[:, :T]
boot = x[ix].mean(axis=1)
print(
    "IC block bootstrap percentil:",
    np.round(np.quantile(boot, [0.025, 0.975]), 5),
)
r = max(abs(np.linalg.eigvals(P - np.ones((2, 2)) * 0.5)))
k = int(np.ceil(np.log(2 * 0.01) / np.log(r)))
print(
    f"Radio no trivial={r:.2f}; gap absoluto={1-r:.2f}; pasos TV<=0.01: {k}"
)
print(
    f"Tamano efectivo asintotico del observable: {T*(1-rho)/(1+rho):.1f}"
)
M = 500
covered = np.zeros((M, 2), bool)
for j in range(M):
    y = chain(rng, T)
    ses = [y.std(ddof=1) / np.sqrt(T), np.sqrt(hac(y, 20) / T)]
    for c, se in enumerate(ses):
        covered[j, c] = abs(y.mean()) <= norm.ppf(0.975) * se
for c, name in enumerate(["iid aplicado incorrectamente", "HAC K=20"]):
    p = covered[:, c].mean()
    print(f"{name}: cobertura={p:.3f}; MCSE={np.sqrt(p*(1-p)/M):.4f}")
```

Listado 13: `lab11_dependencia.py`. Código ejecutado.

Resultados Esperados

```
Media verdadera=0; estimada=-0.10600; varianza LR exacta=4
HAC K=10: LR=3.49375; IC=[-0.22185  0.00985]
HAC K=20: LR=4.15126; IC=[-0.23228  0.02028]
HAC K=40: LR=4.96757; IC=[-0.24414  0.03214]
IC block bootstrap percentil: [-0.232   0.0203]
Radio no trivial=0.60; gap absoluto=0.40; pasos TV<=0.01: 8
Tamano efectivo asintotico del observable: 250.0
iid aplicado incorrectamente: cobertura=0.660; MCSE=0.0212
HAC K=20: cobertura=0.918; MCSE=0.0123
```

El tamaño efectivo $\frac{T}{4}$ corresponde al observable y a su varianza asintótica, no a un conteo universal de datos independientes. Las coberturas observadas incluyen error Monte Carlo. Los rezagos fijos de esta ejecución son elecciones de muestra finita; no constituyen por sí solos una secuencia de anchos que pruebe consistencia HAC al crecer T.

Episodios de CartPole reiniciados independientemente no deben declararse dependientes solo porque cada uno contiene transiciones correlacionadas. Por eso este laboratorio utiliza una trayectoria realmente dependiente.

Preguntas de Exploración

1. Repita con autocorrelación negativa y explique por qué ignorar dependencia

Daniel Lincoln Curivil

no siempre estrecha el intervalo: también puede hacerlo más ancho.
1. Estudie cobertura del bootstrap por bloques con varias longitudes y

muchas cadenas nuevas. Declare el costo y error Monte Carlo.
1. Construya una cadena no reversible y explique qué parte de la cota

espectral anterior deja de estar justificada.
1. Compare una media de una trayectoria larga con una media de retornos

de episodios independientes, identificando la unidad de cada varianza.

Laboratorio 12: LLM-Agents y Síntesis

El último laboratorio reúne las preguntas anteriores en un agente con acciones registradas. El Capítulo 9 y el Capítulo 12 permiten recuperar qué se ha evaluado y qué conclusiones quedan por justificar.

Objetivo

Evaluar dos políticas de selección de acciones discretas en un simulador de diálogos. El experimento no ejecuta un modelo de lenguaje: representa un selector entre cuatro acciones abstractas para aislar el problema estadístico. El valor verdadero puede calcularse por Bellman finito.

Conexión Teórica

Las probabilidades registradas corresponden al mecanismo que selecciona la acción realmente ejecutada. Clasificar después un texto libre en cuatro categorías no convierte las probabilidades de sus tokens en probabilidades de esas categorías. Para trasladar el análisis a un agente real se necesita un mecanismo de selección documentado y una política objetivo definida sobre las mismas acciones y estados.

El contraste usa diferencias pareadas de contribuciones DR por diálogo, con $H = 3$ y $\gamma = 0.9$. Un rechazo bilateral no demuestra superioridad sin examinar el signo; aquí se utiliza un contraste unilateral de mejora prefijado, junto con un intervalo bilateral descriptivo.

Dataset y Setup

Dos estados observados, cuatro acciones y dos mil diálogos independientes. La política de registro es $(0.4, 0.3, 0.2, 0.1)$ y la candidata $(0.2, 0.5, 0.1, 0.2)$. El código especifica todas las medias de recompensa Bernoulli y transiciones entre estados. Los críticos se fijan en el 80% de los valores verdaderos para introducir una mala especificación controlada; no son modelos entrenados con acceso a información real.

El registro correcto mantiene el centrado DR en este simulador. El estado inicial es uniforme y el valor objetivo promedia respecto de esa ley. Sumar una constante común a todos los logits no cambia una distribución softmax: el programa incluye esta comprobación para impedir interpretar ese desplazamiento como una política mejorada.

Implementación

```
import numpy as np
from scipy.stats import norm

H, GAMMA = 3, 0.9
B = np.array([0.4, 0.3, 0.2, 0.1])
E = np.array([0.2, 0.5, 0.1, 0.2])
MU = np.array([[0.6, 0.8, 0.1, 0.3], [0.4, 0.7, 0.2, 0.5]])
P1 = np.array([[0.2, 0.1, 0.4, 0.3], [0.4, 0.3, 0.6, 0.5]])
```

```
def truth(policy):
    v = np.zeros((H + 1, 2))
    q = np.zeros((H, 2, 4))
    for t in reversed(range(H)):
        q[t] = MU + GAMMA * ((1 - P1) * v[t + 1, 0] + P1 * v[t + 1, 1])
        v[t] = q[t] @ policy
    return v, q


def evaluate(ep, policy, qhat):
    vhat = qhat @ policy
    value = vhat[0, ep[0][0]]
    w = 1.0
    for t, (s, a, r, nxt) in enumerate(ep):
        w *= policy[a] / B[a]
        vn = 0 if t == H - 1 else vhat[t + 1, nxt]
        value += GAMMA**t * w * (r + GAMMA * vn - qhat[t, s, a])
    return value, w


rng = np.random.default_rng(20261027)
N = 2000
ve, qe = truth(E)
vb, qb = truth(B)
# Auxiliares fijos deliberadamente imperfectos: registro exacto mantiene el centrado.
qhe = 0.8 * qe
qhb = 0.8 * qb
contrib = []
weights = []
for _ in range(N):
    s = int(rng.integers(2))
    ep = []
    for t in range(H):
        a = int(rng.choice(4, p=B))
        r = int(rng.binomial(1, MU[s, a]))
        nxt = int(rng.binomial(1, P1[s, a]))
        ep.append((s, a, r, nxt))
        s = nxt
    de, w = evaluate(ep, E, qhe)
    db, _ = evaluate(ep, B, qhb)
    contrib.append(de - db)
    weights.append(w)
d = np.array(contrib)
w = np.array(weights)
se = d.std(ddof=1) / np.sqrt(N)
true = ve[0].mean() - vb[0].mean()
p = norm.sf(d.mean() / se)
print(
    f"Diferencia verdadera={true:.6f}; estimada DR={d.mean():.6f}; SE={se:.6f}"
)
print(
    "IC bilateral 95%:",
    np.round(d.mean() + np.array([-1, 1]) * norm.ppf(0.975) * se, 6),
)
print(
    f"Limite inferior unilateral={d.mean()-norm.ppf(.95)*se:.6f}; p={p:.6g}"
)
print(f"ESS pesos finales={w.sum()**2/(w@w):.2f}/{N}")
print("Decision de mejora, analisis unico:", p < 0.05)
assert np.isclose(B.sum(), 1) and np.isclose(E.sum(), 1)
# Sumar una constante a todos los logits NO cambia una politica softmax.
softmax = lambda z: np.exp(z - z.max()) / np.exp(z - z.max()).sum()
assert np.allclose(softmax(np.log(B) + 0.3), B)
print("Invariancia softmax a desplazamiento comun: OK")
```

Listado 14: `lab12_dialogos.py`. Código ejecutado.

Resultados Esperados

```
Diferencia verdadera=0.195388; estimada DR=0.226384; SE=0.016039
IC bilateral 95%: [0.194948 0.257821]
Limite inferior unilateral=0.200002; p=1.54763e-45
ESS pesos finales=751.79/2000
Decision de mejora, analisis unico: True
Invariancia softmax a desplazamiento comun: OK
```

Dr. Jaime Lincovil Curivil

La diferencia verdadera y la estimada corresponden al simulador, no a un benchmark de calidad de LLM. La decisión de mejora utiliza un único análisis con políticas fijadas de antemano. El ESS describe los pesos observados; no valida la abstracción de texto, la recompensa ni la propiedad Markov.

Preguntas de Exploración

1. Diseñe un selector real entre acciones discretas que registre las

probabilidades exactas, la versión de la política y la información disponible antes de actuar. Defina cómo se mantiene estable la recompensa.

1. Aprenda críticos en diálogos separados y compare su error y la varianza

DR. Si selecciona la candidata con datos, reserve evaluación independiente o justifique un procedimiento que trate la selección.

1. Prefije momentos de revisión y un control de error secuencial válido.

No detenga un test ordinario la primera vez que su p-valor sea pequeño.

1. Compare predicción de siguiente estado y recompensa usando estado resumido

frente a historia. Un aumento de precisión puede revelar una limitación; ningún umbral arbitrario de accuracy demuestra o refuta por sí solo todas las condiciones Markov e identificación necesarias.

El cierre de cada laboratorio debe identificar el estimando, las unidades, el modelo, la fórmula implementada, la evidencia calculada y el límite de la conclusión. El Capítulo 9 proporciona el procedimiento para registrarlo; el despliegue requiere revisar nuevamente esas condiciones cuando cambian datos, política o entorno.

Los experimentos permiten reconocer qué cálculo corresponde a cada afirmación. El paso siguiente consiste en conservar esa relación cuando el procedimiento se ejecuta bajo restricciones de tiempo, precisión y acceso a las acciones. El Capítulo 11 estudia cómo documentar esos cambios y cuándo requieren otra evaluación.

Traducción Civil Curivil

Capítulo 11

De la garantía al despliegue

Una garantía describe un procedimiento bajo un modelo y un diseño de datos. Desplegarlo exige comprobar qué procedimiento se ejecuta realmente, qué población recibe sus decisiones y qué ocurre cuando las condiciones dejan de sostenerse. El protocolo del Capítulo 9 proporciona la ficha de cada afirmación; este capítulo la aplica a transformaciones numéricas, generación de acciones, presupuestos de cómputo y monitoreo.

Los ejemplos son sintéticos. Las tolerancias operativas se presentan como decisiones de diseño explícitas, no como constantes universales. El objetivo es producir una decisión revisable de continuar, restringir, abstenerse o suspender, con una explicación de su fundamento.

Lo que puede cambiar al ejecutar el procedimiento

Conviene distinguir dos sentidos de inferencia. La **inferencia estadística** estudia un objetivo como $J(\pi)$ y la incertidumbre de su estimación. La **ejecución del modelo** transforma entradas en predicciones o acciones mediante una implementación concreta. Una optimización de ejecución puede conservar el procedimiento estadístico, alterar sus contribuciones o cambiar la propia política. Son situaciones diferentes.

Una demostración no se vuelve conjetura porque sus hipótesis no puedan comprobarse por completo con una muestra. La simulación examina consecuencias en escenarios especificados; los datos reales permiten diagnósticos parciales; la identificación y las hipótesis poblacionales requieren argumentos propios. Ni pasar una batería de pruebas prueba el modelo, ni un resultado favorable de cobertura certifica cualquier futuro despliegue.

Antes de modificar una implementación, se registra una versión de referencia: política, población inicial, acciones, recompensa, horizonte, mecanismo de registro, estimador, funciones auxiliares y regla de decisión. Después se compara con la versión ejecutada. La comparación debe incluir los mecanismos de selección y parada, no solo el archivo de pesos de una red.

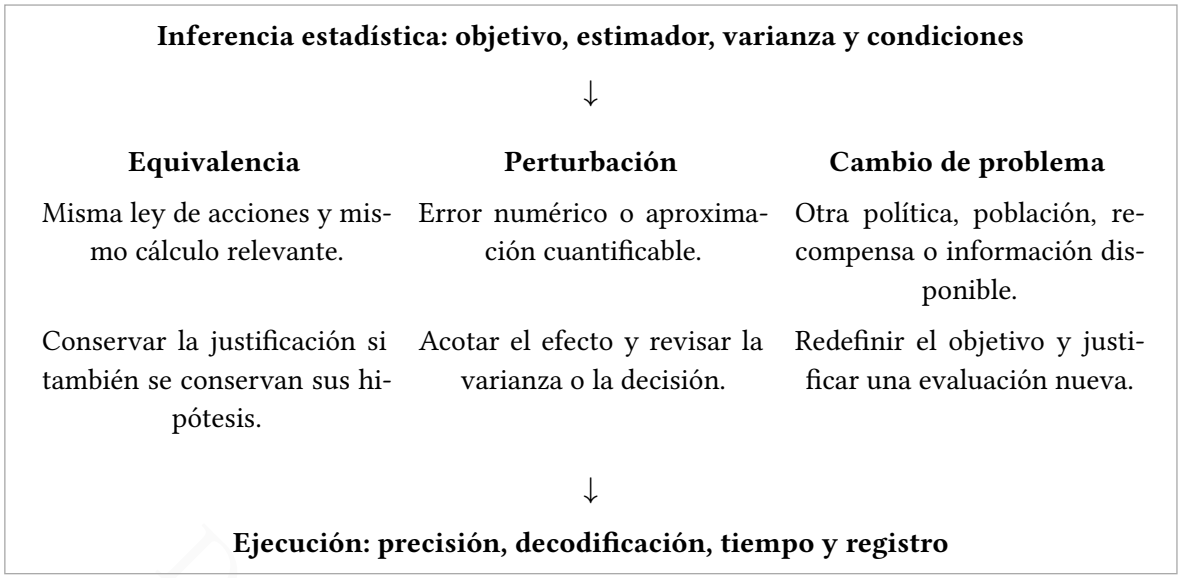


Figura 11.1: Dos capas y tres efectos posibles de una transformación de ejecución.

La clase de modelo determina qué control se necesita. En un modelo paramétrico regular puede propagarse una perturbación mediante derivadas del funcional. En una expansión semiparamétrica importa cómo interactúa con los errores auxiliares. En una estimación no paramétrica de una función completa deben revisarse también sesgo, norma y uniformidad. Una tolerancia adecuada para un promedio no certifica una banda sobre todos los estados.

Cuantización del modelo que aproxima Q

Sea $\hat{q}$ el ajuste estadístico y $\tilde{q}$ su versión de precisión reducida. Separamos el error de aprendizaje $\hat{q} - q$ del error de representación $\tilde{q} - \hat{q}$. Medir el segundo en un conjunto de prueba no proporciona automáticamente una cota uniforme en la población.

Un cálculo de una decisión. Para episodios iid y política objetivo fija, use la contribución DR del Capítulo 7, con auxiliares ajustados fuera de la unidad evaluada:

$$D\big(\hat{m}, \hat{b}\big) = \sum_a \pi(a|S)\hat{m}(S,a) + \frac{\pi(A|S)}{\hat{b}(A|S)}(R - \hat{m}(S,A)).$$

Si $\Delta_m = \tilde{m} - \hat{m}$, entonces

$$D\big(\tilde{m}, \hat{b}\big) - D\big(\hat{m}, \hat{b}\big) = \sum_a \pi(a|S)\Delta_m(S,a) - \frac{\pi(A|S)}{\hat{b}(A|S)}\Delta_m(S,A).$$

Bajo $\|\Delta_m\|_\infty \le \epsilon_q$ y $\frac{\pi(A|S)}{\hat{b}}(A|S) \le C$, el valor absoluto de la diferencia no supera $\epsilon_q(1+C)$. La cota vale para cada contribución y por tanto para su media, cuando esas desigualdades valen en el dominio pertinente.

Si el registro verdadero b se conoce, el incremento tiene esperanza condicional cero al promediar sobre la acción. Cuantizar el auxiliar no produce entonces necesariamente sesgo de DR, aunque puede cambiar su varianza. Si $\hat{b}$ también está estimado, la esperanza del incremento es

$$\mathbb{E}\left(\sum_a \pi(a|S)\frac{\hat{b}(a|S)-b(a|S)}{\hat{b}(a|S)}\Delta_m(S,a)\right).$$

Con soporte controlado, aparece un producto de errores. Para conservar una expansión eficiente original se necesitan condiciones que hagan despreciables el resto y la diferencia de influencias: no basta una etiqueta de precisión «8 bits». Con registro conocido y un auxiliar fijo distinto puede mantenerse un CLT para las nuevas contribuciones sin mantener la varianza eficiente.

Ejemplo verificable. Tome una acción binaria, $b(1)=0.5$, $\pi(1)=0.75$, $R=A$ y $\hat{m}=(0.2,0.8)$. Las contribuciones DR son 0.55 y 0.95, con media 0.75. Una perturbación $(0.01,-0.01)$ las cambia en $(-0.01,0.01)$. La media permanece igual, pero la dispersión aumenta. La cota anterior es $0.01(1+1.5)=0.025$. El programa al final del capítulo comprueba estas identidades. Una alteración pequeña de números no significa que deba conservarse sin cambios el error estándar anterior.

Transferencia de un intervalo mediante una cota. Suponga que el intervalo original $\left[\hat{J}-h,\hat{J}+h\right]$ tiene la cobertura afirmada y que $\left|\tilde{J}-\hat{J}\right|\le B_q$. Entonces

$$\left[\tilde{J}-h-B_q,\tilde{J}+h+B_q\right]$$

contiene el intervalo original. Conserva al menos su cobertura si la cota es determinista; si solo se cumple con probabilidad $1-\eta$, la cobertura se reduce como máximo en η por la unión de eventos. Aquí se mantiene el semiancho original h: sustituirlo por otro calculado después de la cuantización exige una justificación adicional.

Cuando Q selecciona acciones. Si una política greedy usa un aproximador con error uniforme a lo sumo ϵ respecto de Q^*, una acción puede cambiar cuando la brecha entre las dos mejores acciones no supera 2ϵ. En un MDP descontado con las condiciones usuales de Bellman, la pérdida uniforme de valor de esa política se acota por $2\frac{\epsilon}{1-\gamma}$. La desigualdad compara con Q^*; si solo se conoce el error de cuantización respecto de $\hat{Q}$, falta añadir el error de aprendizaje. Con valores 1 y 0.99, errores de magnitud 0.006 pueden invertir la elección. La discontinuidad de argmax impide describir todos los cambios de despliegue como degradaciones suaves.

Decodificación especulativa

No toda decodificación especulativa modifica la distribución objetivo. El método exacto de Leviathan, Kalman y Matias (2023) utiliza propuestas y una corrección de aceptación para conservar la ley del modelo objetivo bajo las condiciones de su algoritmo. La afirmación se refiere a la distribución, no a producir exactamente la misma secuencia con cualquier semilla o implementación.

La revisión distingue tres casos. Si el algoritmo implementado conserva la ley de la política evaluada, no hay un cambio de política por ese motivo. Si usa una aproximación, cambia temperatura, truncamiento de vocabulario, reglas de aceptación o límites de generación, debe caracterizarse la ley efectiva. Si no puede caracterizarse, ciertas rutas de OPE dejan de ser operativas; esto no equivale por sí solo a demostrar falta de identificación del valor por cualquier método.

La política incluye cómo se convierte la salida en una acción: generación, validación, filtros, reintentos, selección entre candidatos y posibles intervenciones humanas. La probabilidad de una secuencia de tokens no es la probabilidad de una categoría asignada después a muchas secuencias. Tampoco basta normalizar probabilidades de las acciones observadas si quedan otras acciones posibles fuera del denominador.

Ficha de equivalencia. Registre la política de referencia, el mecanismo ejecutado, la propiedad de equivalencia alegada y la evidencia que la sostiene. Una prueba de equivalencia del algoritmo y pruebas del código atienden preguntas distintas. Comparar frecuencias en un conjunto finito de entradas puede detectar discrepancias, pero no demuestra igualdad de leyes para todas las historias.

Latencia como restricción de diseño

Una latencia menor no cambia necesariamente la inferencia: puede obtenerse con una implementación equivalente. El cambio estadístico aparece cuando se reduce el horizonte, se aproxima una recursión, se descartan datos o se seleccionan resultados según su tiempo de respuesta.

Truncamiento de horizonte. Si $|R_t| \le R_{\max}$ y $0 < \gamma < 1$, el error entre el retorno infinito y el truncado después de H recompensas se acota por

$$B_H = \frac{R_{\max}\gamma^H}{1-\gamma}.$$

Para garantizar $B_H \le \epsilon$ basta escoger el menor entero no negativo que cumpla la desigualdad. Con $R_{\max} = 1.2$, $\gamma = 0.9$ y tolerancia 0.1, se necesita $H \ge 46$. Veinte o cinco pasos definen aproximaciones distintas; un IC válido para el retorno truncado no cubre automáticamente el infinito.

Planificación interrumpida. Para un operador de Bellman contractivo con factor γ, el residuo $e = \|\mathcal{T}V - V\|_\infty$ da la cota $\|V - V^*\|_\infty \le \frac{e}{1-\gamma}$. Es una cota computacional dentro del modelo utilizado. No incorpora incertidumbre de transiciones estimadas ni es, por sí sola, una cota de pérdida de la política extraída.

Selección por tiempo de respuesta. Conservar solo episodios que terminan antes del plazo puede seleccionar casos fáciles. El objetivo pasa a ser una población condicionada por finalización, salvo que se justifique una corrección de observación o censura. Si se detiene una simulación cuando su media parece favorable, cambia la regla de muestreo. Un presupuesto fijo de réplicas independientes y una parada dependiente de resultados no tienen la misma justificación inferencial.

Presupuesto conjunto. La ficha registra por separado error estadístico, error de representación y error de truncamiento. Solo pueden sumarse cotas cuando se refieren a la misma cantidad, norma y versión del procedimiento. La probabilidad de exceder una latencia y el error de estimación de valor son métricas diferentes; una no sustituye a la otra.

Cuando una restricción de ejecución cambia la decisión

La dificultad central es evaluar el procedimiento que efectivamente actúa. Hay que separar tres obstáculos: probabilidades difíciles de calcular, ausencia de soporte e identificación causal insuficiente. Cada uno requiere una respuesta distinta.

Una política objetivo que puede ejecutarse pero cuya masa de probabilidad no se evalúa fácilmente puede estudiarse on-policy en nuevos episodios, si el experimento está autorizado y bien definido. Una simulación de acciones objetivo puede aproximar integrales de un modelo directo, con su error Monte Carlo y sus supuestos. En cambio, IS necesita razones pertinentes; no puede reemplazarlas por números arbitrarios. Las políticas deterministas con regla conocida sí tienen probabilidades evaluables: cero o uno.

La falta de soporte es otro problema. Si una acción relevante para la objetivo nunca puede observarse bajo el registro, la ley observada puede ser compatible con varios resultados contrafactuales y valores distintos. Un modelo directo que extrapola aporta restricciones adicionales; no recupera una garantía no paramétrica por cambiar de estimador. La confusión no medida constituye aún otra limitación, que no resuelve conocer las probabilidades nominales de un algoritmo.

Caso operativo SSCH. En el subcaso de dos visitas de los capítulos 8–9, la diferencia estimada es 0.475 y el límite inferior unilateral aproximado al 95% es 0.45837. Para un margen prefijado 0.40, el contraste aporta evidencia bajo ese diseño. Si la versión ejecutada modifica la política, el intervalo sigue refiriéndose a la versión evaluada. Se necesita una nueva evaluación o una cota de diferencia de valores justificada; no basta con conservar el nombre SSCH.

La abstención se define como una acción operativa: mantener una alternativa previamente evaluada, derivar a revisión o suspender la automatización, según el problema. Cada alternativa tiene consecuencias y un responsable. No se presupone que «no actuar» carezca de pérdida ni que volver a una política anterior sea siempre adecuado para una población que cambió.

Protocolo de validación empírica

El protocolo comienza con la ficha del Capítulo 9 y termina con un dictamen limitado al escenario examinado. Combina verificación de fórmulas, comprobaciones del diseño, simulación con verdad conocida y seguimiento del sistema ejecutado. Los apartados siguientes cumplen funciones diferentes; ningún promedio de sus resultados reemplaza una condición de identificación.

El código reproducible que acompaña este capítulo realiza una simulación controlada, calcula esperanzas DR por recursión y comprueba una perturbación numérica. No despliega un agente, no estima auxiliares con ML y no certifica una aplicación real. Cuando la aplicación aprende funciones o selecciona políticas, la validación debe repetir también esas etapas.

Qué permite comprobar la validación

1. **Corrección del cálculo:** verificar que el valor de referencia y el estimador corresponden al mismo horizonte, descuento y población inicial.
2. **Comportamiento inferencial:** estimar sesgo, variabilidad, cobertura y longitud de intervalos, acompañados de incertidumbre Monte Carlo.
3. **Sensibilidad:** cambiar de forma controlada soporte, dependencia, especificación de auxiliares y precisión numérica.
4. **Funcionamiento del sistema:** comprobar acciones de abstención, registros, límites de tiempo y detección de versiones incompatibles.
5. **Alcance del dictamen:** distinguir condiciones comprobadas en el experimento, supuestos poblacionales declarados y evidencia aún pendiente.

La eficiencia semiparamétrica es relativa a un modelo y una clase de estimadores regulares. Una varianza pequeña o un RMSE favorable en una simulación no demuestra que se alcance esa cota. La doble robustez tampoco implica insesgadez exacta cuando los auxiliares son aprendidos en la muestra.

Protocolo 1: Simulación de MDP Controlado

11.8.1 Configuración del MDP de Prueba

Definición 11.1 (MDP de Validación Estándar). Se utilizan tres estados, dos acciones y descuento $\gamma = 0.9$. Las recompensas de Tabla 11.1 son deterministas dado estado y acción. La política objetivo fija es $\pi(a_1|s) = 0.6$, $\pi(a_2|s) = 0.4$. El registro de la simulación principal asigna probabilidad 0.5 a cada acción. Los episodios comienzan en s_1, tienen cinco decisiones y se generan independientemente. El objetivo simulado es $J_5 = V_0^\pi(s_1)$.

Par	$P(s_1)$	$P(s_2)$	$P(s_3)$	r
(s_1, a_1)	0.7	0.2	0.1	1.0
(s_1, a_2)	0.3	0.5	0.2	0.5
(s_2, a_1)	0.2	0.6	0.2	0.8
(s_2, a_2)	0.1	0.3	0.6	1.2
(s_3, a_1)	0.4	0.3	0.3	0.3
(s_3, a_2)	0.2	0.2	0.6	0.7

Tabla 11.1: MDP sintético de validación: probabilidades y recompensas de diseño.

11.8.2 Cálculo de Valores Verdaderos

Para horizonte infinito se resuelve

$$V_\infty^\pi = (I - \gamma P^\pi)^{-1} r^\pi,$$

con $P^\pi = \sum_a \pi(a|s) P(\cdot\,|s,a)$ y $r^\pi = \sum_a \pi(a|s) r(s,a)$. El cálculo numérico da

$$V_\infty^\pi \approx (7.651602, 7.732035, 7.191250)^T.$$

La política es constante respecto del estado, pero no uniforme entre acciones.

Para cinco decisiones se calcula hacia atrás:

$$v_5(s) = 0, \quad q_t(s,a) = r(s,a) + \gamma \sum_j P(s_j|s,a) v_{t+1}(s_j),$$

$$v_t(s) = \sum_a \pi(a|s) q_t(s,a).$$

Se obtiene

$$v_0 \approx (3.198864, 3.279764, 2.738539)^T.$$

El parámetro de cobertura del programa es $J_5 \approx 3.198864$, no el primer componente del vector de horizonte infinito. Compararlos sin controlar la cola generaría un falso diagnóstico de sesgo.

11.8.3 Procedimiento de Validación

Algoritmo 11.2: Validación de cobertura para un procedimiento especificado.

1. Fijar objetivo, generador, horizonte, tamaño y procedimiento antes de simular.
2. Calcular la verdad analítica o numérica con error controlado.

Dr. Jaime Uscátegui Cubillos

3. Generar M muestras independientes; en cada una repetir las etapas de entrenamiento, selección y evaluación que realmente use el método.
4. Registrar estimación, error estándar, extremos del IC y fallos numéricos. No eliminar silenciosamente las réplicas fallidas.
5. Calcular sesgo, RMSE, cobertura y longitud; estimar su error Monte Carlo.
6. Comparar con tolerancias prefijadas y conservar los escenarios donde el procedimiento resulte insuficiente o no aplicable.

En la ejecución de referencia, $M = 1000$, $n = 200$ episodios y $H = 5$. Los auxiliares se fijan de antemano: q verdadero o $0.8q$, y registro correcto o una función incorrecta $(0.8, 0.2)$. Se añade $0.8q$ redondeado a una cifra decimal con registro correcto. Se calcula el DR secuencial con razones acumuladas, término inicial y residuos de Bellman. Los IC son normales por episodios, de validez asintótica, no intervalos exactos.

El uso de funciones verdaderas en algunos escenarios es una herramienta para aislar propiedades matemáticas. No representa acceso a la verdad en una aplicación ni valida un ajuste de redes neuronales.

11.8.4 Métricas de Evaluación

Con estimaciones $\hat{J}_m$ y errores estándar $\hat{s}_m$, defina

$$\hat{B} = \overline{\hat{J}} - J, \quad s_{\mathrm{MC}}^2 = \frac{1}{M-1} \sum_m \left(\hat{J}_m - \overline{\hat{J}} \right)^2.$$

El error Monte Carlo del sesgo es $\frac{s_{\mathrm{MC}}}{\sqrt{M}}$. La cobertura estimada es $\hat{C} = M^{-1} \sum_m \mathbb{1}_{J \in C_m}$ y su error Monte Carlo plug-in es $\sqrt{\hat{C} \frac{1-\hat{C}}{M}}$. En coberturas cero o uno, ese error plug-in se anula sin demostrar ausencia de incertidumbre; use un intervalo binomial.

Métrica	Cálculo	Interpretación
Cobertura	Fracción de IC que contienen el objetivo.	Reportar incertidumbre binomial; no exigir igualdad numérica a 0.95.
Sesgo	Media de errores y su error Monte Carlo.	Distinguir sesgo sustantivo de ruido de simulación.
Calibración del SE	$\sqrt{M^{-1} \sum_m \hat{s}_m^2}$ frente a s_{MC}.	Compara varianza estimada y dispersión muestral; no prueba eficiencia.
RMSE	$\sqrt{M^{-1} \sum_m \left(\hat{J}_m - J \right)^2}$.	Combina sesgo y variabilidad para ese objetivo.
Longitud y fallos	Longitud media y proporción de ejecuciones fallidas.	La cobertura aislada puede ocultar intervalos inútiles o réplicas descartadas.

Tabla 11.2: Métricas y alcance de su interpretación.

Resultados obtenidos. La tabla reproduce la ejecución del programa adjunto. «Correcto» describe las funciones fijadas, no un diagnóstico aprendido.

Escenario	Sesgo	Cobertura	MCSE	RMSE
Ambos correctos	−0.001046	0.951	0.0068	0.021366
Solo Q correcto	0.000449	0.944	0.0073	0.076099

Escenario	Sesgo	Cobertura	MCSE	RMSE
Solo registro correcto	−0.001844	0.938	0.0076	0.027548
Ambos incorrectos	1.047845	0.000	—	1.055570
Q cuantizado; registro correcto	−0.002005	0.948	0.0070	0.027915

Tabla 11.3: Simulación de referencia: mil muestras de doscientos episodios.

Por ilustración, un requisito de diseño puede ser que el límite inferior unilateral de Wilson al 95% para la cobertura supere 0.93. En los escenarios de ambos correctos, solo Q correcto, solo registro correcto y Q cuantizado, los límites son 0.9385, 0.9308, 0.9242 y 0.9352. El tercero no satisface ese criterio con esta ejecución. No corresponde ajustar la tolerancia después para hacerlo pasar; puede ampliarse el estudio o revisarse el método. Wilson es aquí una aproximación binomial para incertidumbre Monte Carlo, no una prueba exacta de cobertura poblacional. Si se pretende un dictamen simultáneo sobre muchos escenarios, también se controla esa multiplicidad.

Protocolo 2: Verificación de Overlap

11.9.1 Escenarios de Prueba

La igualdad de políticas hace unitarios los pesos de importancia, pero no prueba que el estimador tenga un IC óptimo. Con soporte insuficiente pueden observarse solo pesos aparentemente benignos: el ESS de los datos existentes no cuenta las acciones que nunca aparecen.

Escenario	Configuración	Conclusión permitida
Misma política	$b = \pi$ conocido.	Pesos iguales a uno; revisar el resto de condiciones.
Soporte amplio	Probabilidades de registro alejadas de cero en acciones objetivo.	Evaluar precisión sin umbral universal de ESS.
Concentración	Probabilidades pequeñas pero positivas en acciones relevantes.	Puede haber alta varianza y mala aproximación normal en muestra finita.
Sin soporte	$b(a\|s) = 0$ y $\pi(a\|s) > 0$ en un estado relevante.	La ruta por importancia no se justifica; DM requiere otras restricciones.
Registro incompleto	No se conserva el mecanismo efectivo de asignación.	Pendiente de reconstrucción; no inventar probabilidades.

Tabla 11.4: Soporte y concentración: escenarios distintos.

11.9.2 Procedimiento de Verificación de Diagnósticos

Algoritmo 11.3: Comprobación de soporte y evaluación de alertas.

1. En simulación, comprobar el soporte del generador y la alcanzabilidad de estados, no solo las acciones presentes en una muestra.
2. Calcular pesos compatibles con el estimador y su unidad: por episodio, por tiempo o razones marginales según corresponda.

3. Registrar ESS, máximos y colas como diagnósticos de concentración.
4. Calibrar alertas en escenarios separados de aquellos usados para evaluarlas; reportar sensibilidad y falsas alarmas con incertidumbre binomial.
5. Ante ausencia estructural de soporte, suspender la afirmación afectada o cambiar explícitamente diseño, población, política o supuestos.

En el programa, sustituir el registro por $(1, 0)$ mientras la política objetivo usa la segunda acción con probabilidad 0.4 produce una violación estructural detectable. No se generan pesos con denominador artificial 10^{-9} ni se exige que su ESS observado sea cercano a cero. En datos reales, cero observaciones no demuestra por sí solo probabilidad cero; tampoco una probabilidad ajustada positiva demuestra soporte suficiente.

Protocolo 3: Verificación de Mixing

11.10.1 Tests de Estacionariedad

ADF contrasta una hipótesis de raíz unitaria dentro de una especificación de serie temporal. KPSS contrasta estacionariedad de nivel o tendencia según su versión. Rechazar una nula o no rechazar otra no demuestra que el proceso observado sea estacionario, y ninguno de esos resultados prueba mixing geométrico del estado completo.

La elección de rezagos, términos deterministas, tamaño y variables observadas importa. Un cambio de política durante la recolección puede modificar la ley sin que un test tenga potencia suficiente para detectarlo. Los diagnósticos se registran como evidencia parcial, no como casillas obligatorias capaces de certificar una condición poblacional.

La primera decisión es identificar el régimen muestral. Episodios con reinicios independientes permiten una ruta iid por contribuciones completas. Una trayectoria larga necesita una justificación de dependencia y varianza compatible. El experimento principal de este capítulo usa episodios iid; no requiere aprobar ADF ni estimar una tasa de mixing para su CLT.

11.10.2 Estimación de Tasa de Mixing

Una regresión de $\log(|\hat{\rho}_k|)$ sobre el rezago describe, como mucho, un patrón de autocorrelación estimada de un observable. No estima en general los coeficientes de mixing entre sigma-álgebras. Correlaciones negativas, ceros y ruido en rezagos grandes hacen aún más frágil esa interpretación.

Algoritmo 11.4: Justificación de dependencia y análisis de sensibilidad.

1. Identificar política de registro, ley inicial, unidad y posible adaptación.
2. Si el núcleo finito es conocido, estudiar irreducibilidad, aperiodicidad y las condiciones de la cota utilizada; exigir reversibilidad cuando se emplee la cota espectral que la necesita.
3. Si el núcleo se estima, incorporar su incertidumbre y evitar interpretar un autovalor plug-in como certificado poblacional.
4. Examinar ACF de las contribuciones relevantes y sensibilidad a rezagos HAC o longitudes de bloque, como diagnósticos complementarios.
5. Registrar qué condición permite el CLT y qué estimador de varianza es consistente bajo ella. Si falta, conservar el dictamen pendiente.

El Sección 10.12 ilustra una cadena conocida con autocovarianza 0.6^k y varianza de largo plazo cuatro. Su cobertura HAC de muestra finita fue 0.918 con error Monte Carlo 0.0123. Ese resultado

ayuda a discutir calibración; no autoriza a afirmar cobertura nominal porque HAC y bootstrap produzcan intervalos visualmente parecidos.

Protocolo 4: Validación de Estimadores DR

11.11.1 Comparación de Estimadores

La comparación mantiene fijo el estimando y separa especificación, identificación y precisión. «Overlap malo» no es sinónimo de «sin soporte». Un estimador IS con soporte y razones correctas puede ser insesgado y tener varianza demasiado grande para ser útil. DR no domina siempre a DM o IS en varianza o RMSE.

Funciones	DM	IS	DR
Q y registro correctos	Centrado si integración correcta.	Centrado.	Centrado; comparar varianzas.
Solo Q correcto	Puede ser centrado.	Puede tener sesgo.	Centrado con la fórmula y condiciones apropiadas.
Solo registro correcto	Puede tener sesgo.	Centrado.	Centrado; no se garantiza eficiencia.
Ambos incorrectos	Sin garantía general.	Sin garantía general.	Puede tener sesgo grande.
Sin soporte	Extrapolación bajo supuestos adicionales.	No justificado por la ley observada.	No recupera una garantía no paramétrica por sí solo.

Tabla 11.5: Qué se espera bajo auxiliares fijos y soporte suficiente.

11.11.2 Verificación de Doble Robustez

Algoritmo 11.5: Identidad poblacional, comportamiento muestral y aprendizaje.

1. Escribir la contribución exacta del estimador, incluidos horizonte, valor inicial y pesos, y fijar su población objetivo.
2. Con un generador conocido, calcular su esperanza por enumeración, integración o recursión cuando sea posible.
3. Examinar auxiliares ambos correctos, solo uno correcto y ambos incorrectos. No exigir que el último caso tenga sesgo menor que los anteriores.
4. Repetir muestras para estimar sesgo y varianza con error Monte Carlo.
5. Si se aprenden auxiliares, repetir ese aprendizaje y respetar la separación por unidades; revisar las condiciones del CLT además de la consistencia.

En la simulación, la esperanza exacta de DR es 3.198864 cuando alguno de los dos conjuntos auxiliares es correcto. Con ambos incorrectos es 4.239321. La diferencia no contradice doble robustez: el procedimiento está fuera de los casos que anulan el resto. Un resto de producto tampoco implica que dos errores grandes se cancelen o que su sesgo sea menor que cuando uno de ellos es cero.

El cálculo de esperanza se realiza por propagación de ocupaciones ponderadas en el modelo conocido. Es más informativo para comprobar la identidad que exigir $\left|\hat{J} - J\right| < \epsilon$ en una sola muestra.

Las cifras observadas de cobertura siguen siendo resultados de muestra finita con auxiliares fijos; no prueban tasas de aprendizaje ni eficiencia semiparamétrica.

Verificación Previa al Despliegue

El dictamen se refiere a una versión y un uso definidos. Una evidencia pendiente no se convierte en «verificada» por la ausencia de una alarma. Un piloto limitado puede ser una decisión operacional, pero debe describirse como tal y no como una garantía estadística general.

N.º	Comprobación	Evidencia requerida
1	Objetivo, población, horizonte y recompensa definidos.	Ficha del estimando.
2	Política evaluada vinculada a la ejecutada.	Versión y argumento de equivalencia o nueva evaluación.
3	Identificación y soporte de la ruta elegida.	Diseño documentado y supuestos pendientes explícitos.
4	Unidad y dependencia tratadas correctamente.	Derivación de contribuciones y varianza.
5	Selección, aprendizaje y revisiones temporales incluidos.	Particiones, plan de análisis y condiciones de expansión.
6	Errores numéricos y truncamiento controlados.	Cotas o estudio de sensibilidad con alcance declarado.
7	Métricas de simulación y fallos reportados.	Resultados con incertidumbre Monte Carlo.
8	Criterio de decisión y abstención prefijados.	Margen o pérdida, responsable y acción alternativa.
9	Registro y monitoreo capaces de detectar cambios relevantes.	Esquema de datos, alarmas y causas de suspensión.
10	Límites comunicados y revisión asignada.	Dictamen fechado y condiciones de reevaluación.

Tabla 11.6: Ficha de decisión previa al uso de una versión.

No se exige que DR gane siempre ni que el ESS supere un número universal. Los criterios técnicos deben probar lo que afirman. Un denominador cero puede detectarse por una comprobación estructural del generador; una tasa de convergencia no puede probarse con la misma clase de comprobación.

Pseudocódigo de Validación

El esquema siguiente separa las métricas de simulación del dictamen sobre una aplicación. Es pseudocódigo: las funciones nombradas representan operaciones que deben implementarse para el

problema concreto. El archivo `validar_despliegue.py` adjunto sí es ejecutable y produce las cifras de este capítulo para el generador especificado.

```
validar_version (ficha, procedimiento, escenarios, tolerancias):
    comprobar_coherencia_de_objetivo_y_version (ficha)
    obligaciones = enumerar_hipotesis_del_resultado (ficha)
    evidencia = clasificar_evidencia (obligaciones)
        # algebra/codigo, diseno documentado, supuesto poblacional

    si hay_contradiccion_de_identificacion_o_soporte (evidencia):
        devolver "NO APLICABLE", motivo_y_alternativas_explicitadas

    resultados = []
    para escenario en escenarios:
        verdad = calcular_objetivo_del_mismo_horizonte (escenario)
        para replica en 1..M:
            datos = generar_muestra_independiente (escenario)
            salida = ejecutar_procedimiento_completo (datos)
                # incluye ajuste y seleccion cuando correspondan
            registrar_estimacion_intervalo_y_fallos (salida, verdad)
        resultados.agregar(resumir_con_error_Monte_Carlo ())

    si falta_justificacion_necesaria (evidencia):
        devolver "PENDIENTE", evidencia, resultados
    si no_satisface_criterios_prefijados (resultados, tolerancias):
        devolver "REVISAR", resultados, causas_a_investigar

    devolver "APLICABLE BAJO SUPUESTOS DECLARADOS", ficha,
             evidencia, resultados, limites_y_causas_de_revision
```

Listado 15: Revisión de una versión sin certificaciones automáticas de supuestos.

Para reproducir la simulación, instale NumPy y ejecute `python validar_despliegue.py`. El paquete incluye versión usada, semilla, salida de consola y resultados estructurados. La ejecución no necesita datos privados, una API de lenguaje ni una biblioteca de orquestación.

Control mínimo de errores. El programa comprueba que las filas de transición suman uno, que las transiciones simuladas pertenecen al espacio de estados, que las esperanzas DR de los casos correctos coinciden con el objetivo, y que el ejemplo de perturbación satisface su cota. Estas comprobaciones son específicas; no equivalen a verificar todas las condiciones de un teorema para datos futuros.

Interpretación de Resultados

Un resultado fuera de tolerancia inicia una investigación causal del fallo del procedimiento. Aumentar el ancho de un intervalo hasta que cubra la verdad de simulación puede ocultar sesgo, errores de objetivo o selección. Modificar el método exige evaluar la nueva versión en escenarios reservados o nuevas réplicas, manteniendo visibles las decisiones tomadas.

Hallazgo	Causas posibles	Acción
Cobertura baja	Sesgo, SE incorrecto, colas, selección u objetivo distinto.	Separar causas; revisar expansión y diseño antes de cambiar varianza.

Hallazgo	Causas posibles	Acción
Cobertura alta	Conservadurismo, intervalos muy amplios o referencia errónea.	Examinar longitud y verdad usada; no estrechar por conveniencia.
Pesos concentrados	Poco soporte práctico o política distante.	Cuantificar precisión y sensibilidad; declarar sesgo si se recortan pesos.
Soporte ausente	Acciones relevantes nunca registradas.	Suspender la ruta afectada o justificar un nuevo diseño o modelo.
Cambio temporal	Población, política, medición o dinámica diferentes.	Localizar el cambio y reevaluar la garantía pertinente.
Fallo de registro	Probabilidades, versiones o resultados incompletos.	Corregir procedencia; abstenerse cuando no pueda reconstruirse.

Tabla 11.7: Hallazgos, posibles causas y revisión requerida.

Monitoreo y multiplicidad temporal. Revisar cada día un IC ordinario hasta que sea favorable no conserva su nivel. Una opción elemental, para datos independientes de media fija y contribuciones acotadas en $[a, b]$, consiste en prefijar tamaños n_m y asignar

$$\alpha_m = \frac{\alpha}{m(m+1)}.$$

La suma de los niveles es α. Por Hoeffding, los límites inferiores

$$L_m = \overline{D}_{n_m} - (b-a)\sqrt{\frac{\log\left(\frac{1}{\alpha_m}\right)}{2n_m}}$$

satisfacen $\mathbb{P}(\exists m : L_m > J) \leq \alpha$ por la unión de eventos. No se requiere independencia entre revisiones, pero sí las condiciones de cada desigualdad y el objetivo fijo. En DR deben acotarse las contribuciones con sus pesos, no solo las recompensas. Si cambia la política objetivo o se ajusta el estimador adaptativamente, este argumento no se traslada sin revisión. Para construcciones más eficientes, véase Howard et al. (2021), sobre secuencias de confianza.

Las alarmas técnicas, como ausencia de una versión o datos mal formados, no necesitan fingir ser tests estadísticos. Las alarmas de degradación de rendimiento sí requieren definir qué se contrasta, con qué población y cómo se controlan las revisiones. Suspender por precaución operacional y concluir estadísticamente que el valor cayó son afirmaciones diferentes.

Conservar las razones y los límites de la decisión

Cada versión conserva el estimando y sus unidades; la política y el mecanismo de acción; el origen y diseño de los datos; los supuestos de identificación; la ruta inferencial; los errores de aproximación y precisión; los resultados de evaluación con incertidumbre; y el responsable de revisión. Se distingue lo comprobado en código, lo documentado por diseño y lo asumido sobre la población. No se usa una columna «verificado» para borrar esas diferencias.

Cambio de población. Suponga diferencias de valor condicionales 0.5 y -0.2 en dos grupos. Con pesos poblacionales $(0.9, 0.1)$, la diferencia integrada es 0.43; con pesos $(0.4, 0.6)$ es 0.08. Aunque

las diferencias dentro de cada grupo no cambien, el objetivo agregado sí cambia. El intervalo de la primera población no responde automáticamente a la segunda. Una reponderación exige soporte y los supuestos de transporte pertinentes.

Condiciones de suspensión. Deben quedar definidos los cambios que obligan a revisar: versión de política no evaluada, nueva población relevante, pérdida del registro de acciones, alteración de recompensa, fallos de soporte, parada no contemplada o error numérico que excede la cota usada. El registro de suspensión indica qué garantía deja de sostenerse, qué operación se interrumpe y qué evidencia se necesita para reanudarla.

La contribución formal del libro sigue siendo la representación fiel de una decisión de Wald en la familia de MDP correspondiente. Los protocolos de este capítulo añaden disciplina para usar resultados estadísticos en sistemas ejecutables; no amplían aquella representación a todos los agentes ni convierten un informe favorable de simulación en una autorización general de despliegue.

Al conservar ese registro, las preguntas que siguen abiertas quedan mejor delimitadas. Algunas requieren nuevos datos; otras, un modelo de observación o un resultado inferencial diferente. El último capítulo vuelve sobre ellas para precisar qué se ha resuelto en el recorrido y qué trabajo permitiría continuarlo.

Cf. Jaime Lincoñil Curivil

Capítulo 12

Problemas abiertos

El despliegue deja una pregunta abierta cada vez que cambia una condición sobre la que descansaba el análisis. Una población distinta puede alterar el valor agregado; una historia incompleta puede ocultar información usada para asignar acciones; un modelo de lenguaje puede producir decisiones sin permitir calcular sus probabilidades. En esas situaciones, antes de escoger otro estimador conviene precisar qué parte del argumento sigue siendo válida.

Este capítulo retoma el recorrido para formular esas preguntas. La primera parte del libro permitió comparar reglas y planificar dentro de modelos especificados. La evaluación y la inferencia añadieron las condiciones para aprender de datos. Los casos y el despliegue mostraron cómo una implementación puede conservar o cambiar el objeto del análisis. Ahora interesa delimitar lo que falta cuando la información, la política o el entorno exceden esos supuestos.

Las preguntas se presentan primero a través de sus dificultades de identificación y estimación. Después se traducen en problemas de trabajo y en un diseño de agente cuyas garantías deben justificarse por separado. El SSCH sirve de referencia para interpretar esas dificultades; conserva su carácter de escenario sintético.

Qué conclusiones conservamos

La representación del Capítulo 5 conserva el riesgo al escribir una decisión de Wald como una política en una familia de MDP de un paso. Bayes, minimax y admisibilidad comparan entonces las mismas reglas con el mismo criterio. La extensión bayesiana de observación y parada requiere además un modelo de datos, un prior y un horizonte definidos.

La suficiencia del Capítulo 4 precisa qué información de una muestra puede retenerse para un parámetro. Al construir un estado controlado, la pregunta cambia: el resumen debe permitir predecir lo que sucederá bajo las acciones consideradas. El Capítulo 6 y el Capítulo 9 muestran por qué conviene justificar esa propiedad en el proceso que se utiliza.

Las funciones de influencia y la ortogonalidad permiten estudiar cómo los errores de los modelos auxiliares afectan a un estimador. En una construcción DR concreta, la doble robustez identifica combinaciones de modelos para las que se conserva el centrado poblacional. La precisión asintótica exige también tasas, momentos y una estimación de varianza adecuados.

La evaluación *off-policy* del Capítulo 7 hace explícita la información que falta cuando una política propone acciones poco representadas en los datos. Los pesos acumulados pueden tener una varianza elevada en horizontes largos. Los modelos, las restricciones de política y los cambios de estimando deben juzgarse por las hipótesis que incorporan y por la conclusión que permiten.

El Capítulo 8 distingue las rutas para cuantificar incertidumbre: las contribuciones de episodios independientes, la dependencia dentro de una trayectoria y la aproximación de Bellman mediante

bases. El método SAVE trata la evaluación de políticas aprendidas con una organización secuencial específica. Estas rutas ofrecen resultados que deben leerse con sus propios procedimientos; su relación se documenta antes de combinarlas.

Las fronteras de la evaluación

12.2.1 Evaluar cuando hay causas comunes no observadas

Una persona que decide puede utilizar información que no queda registrada. Si esa información también se relaciona con el resultado, comparar las acciones a partir de los registros observados deja una causa común sin ajustar. La identificación de V^π debe entonces estudiarse bajo un modelo que reconozca esa información ausente.

Definición 12.1 (Confounding No Observado). Existe confounding no observado si existe una variable U tal que:
- U afecta la acción A: $P(A|S,U) \neq P(A|S)$
- U afecta la recompensa R: $P(R|S,A,U) \neq P(R|S,A)$
- U no es observada en los datos

La dificultad aparece cuando el ajuste por las variables registradas deja sin controlar una causa común de las acciones y los resultados.

Nota 12.2 (Sesgo del estimador DR bajo confounding no observado). Bajo confounding no observado el estimador DR puede conservar un sesgo que la reponderación por importancia no elimina: los pesos corrigen la diferencia entre política objetivo y de comportamiento, pero no la dependencia común entre acción y recompensa mediada por la variable no observada U. El sesgo depende del mecanismo completo; puede incluso cancelarse en casos particulares. La ausencia de esta causa común no descarta otras fuentes de confusión.

Para el tratamiento estándar del sesgo por confounding en estimadores ponderados, véase Hernán & Robins (2020).

Para continuar, hace falta añadir información o formular una conclusión menos exigente. Las siguientes estrategias introducen supuestos distintos y deben justificarse en el diseño correspondiente.

Nota 12.3 (Estrategias de Mitigación). Estrategias para manejar confounding no observado:
1. **Instrumental Variables:** Usar variables que afectan A pero no R directamente
2. **Sensitivity Analysis:** Cuantificar el sesgo bajo diferentes escenarios de U
3. **Bounds:** Construir límites para V^π sin asumir no confoundamiento
4. **Proxy Variables:** Usar variables observadas correlacionadas con U

La adherencia no registrada ofrece una manera de plantear esa dificultad en el SSCH.

Ejemplo 12.4 *(sintético)* **(SSCH con Confounding).** En el SSCH, la adherencia del paciente a las recomendaciones (U) no es completamente observada. Pacientes más adherentes tienden a recibir más intervenciones y también tienen mejores resultados, creando confounding. El estimador DR puede estar sesgado si no se controla por U; la dirección del sesgo requiere especificar el mecanismo generador.

12.2.2 Decidir a partir de observaciones parciales

La información puede ser parcial incluso antes de decidir qué registrar. En un POMDP, el estado S_t se relaciona con una observación O_t que recibe el agente. Para evaluar una política interesa reconstruir qué puede aprenderse de esas observaciones y qué parte del pasado necesita conservarse.

Definición 12.5 (POMDP). Un POMDP se define por la tupla $(\mathcal{S}, \mathcal{A}, \mathcal{O}, T, O, R, \gamma)$ donde:
- $O_t \in \mathcal{O}$ es la observación en el paso t
- $O(o_t|s_t)$ es la probabilidad de observar o_t dado el estado s_t
- El agente mantiene una creencia $b_t(s) = P(S_t = s|O_{0:t}, A_{0:t-1})$

El historial observado pasa a ser parte de la información de la política. La representación del valor debe respetar esa dependencia y los requisitos de identificación del Capítulo 7.

Teorema 12.6 (Identificación en POMDPs). *Sea H_t la historia observada antes de A_t, incluyendo observaciones, acciones y recompensas pasadas. Suponga horizonte finito, la misma ley inicial y los mismos kernels del entorno bajo ambas políticas, que el mecanismo de asignación observado es $b_{t(a|H_t)}$ y que la asignación no usa información latente adicional relacionada con resultados futuros. Suponga también soporte objetivo cubierto e integrabilidad. Entonces, con*

$$W_t = \prod_{u=0}^{t} \frac{\pi_{u(A_u|H_u)}}{b_{u(A_u|H_u)}},$$

el cambio de medida sobre historias da

$$J(\pi) = \mathbb{E}_b\left[\sum_{t=0}^{H-1} \gamma^t W_t R_t\right].$$

En efecto, W_t es la derivada de la ley objetivo respecto de la observada hasta la recompensa R_t; integrar cada término demuestra la igualdad. Una razón solo del tiempo t no corrige la distribución de historias inducida por las acciones anteriores. Si quien asigna acciones observa información latente no registrada, estas hipótesis pueden fallar y la fórmula no identifica en general el valor causal.

El estado de creencia ofrece una formulación del problema cuando el modelo de observación está especificado. Para trabajar con datos, las siguientes estrategias abordan partes distintas de esa reconstrucción.

Nota 12.7 (Estrategias para OPE en POMDPs). Estrategias para manejar observabilidad parcial:
1. **State Estimation:** Usar filtros de partículas o filtros de Kalman para estimar S_t desde $O_{0:t}$
2. **History-Based Policies:** Modelar $\pi(a|h_t)$ donde $h_t = (o_0, a_0, ..., o_t)$
3. **Recurrent Models:** Usar RNNs o transformers para procesar el historial
4. **Belief State MDP:** Convertir el POMDP en un MDP sobre el espacio de creencias

El mismo ejemplo de seguimiento cambia cuando las mediciones solo revelan una parte del estado que interesa.

Ejemplo 12.8 *(sintético)* **(SSCH como POMDP).** En el SSCH, el estado de salud completo del paciente (incluyendo factores no medidos como estrés, calidad de sueño) no es completamente observable. El médico solo observa mediciones clínicas parciales. Esto crea un POMDP donde las políticas deben basarse en observaciones incompletas.

12.2.3 Evaluación de agentes de lenguaje y modelos auxiliares

En un agente de lenguaje, la acción puede ser una secuencia de palabras y su probabilidad depende del contexto utilizado para generarla. La evaluación requiere conocer o modelar ese mecanismo y precisar qué significa comparar dos acciones textuales. Los modelos auxiliares siguientes hacen explícitas esas preguntas.

Definición 12.9 (LLM-Agent). Un LLM-Agent es un sistema donde:
- **Observación:** $o_t \in \mathcal{O}$ (texto, multimodal)
- **Acción:** $a_t \in \Sigma^* = \bigcup_{k=1}^{L} \Sigma^k$ (secuencia de hasta L tokens)
- **Política:** $\pi(a|o) = \prod_{j=1}^{|a|} p_{\text{LLM}}\big(\text{token}_j \mid o, \text{tokens}_{<j}\big)$

12.2.3.1 Probabilidad de una acción textual

Definición 12.10 (Propensity Score para LLM-Actions). La probabilidad de una acción textual $a = (t_1, ..., t_K)$ bajo política π_b es:

$$\pi_b(a|o) = \prod_{j=1}^{K} p_{\pi_b}\big(t_j \mid o, t_1, ..., t_{j-1}\big)$$

El log-propensity es:

$$\log \pi_b(a|o) = \sum_{j=1}^{K} \log p_{\pi_b}\big(t_j \mid o, t_{<j}\big)$$

El producto representa la probabilidad de la acción completa si incluye el token de terminación o una regla de longitud fija. Debe usar las probabilidades del muestreador efectivo, después de temperatura, filtros y restricciones; las probabilidades del modelo base pueden ser distintas. Con esas condiciones, puede calcularse en escala logarítmica.

Proposición 12.11 (Estimación de Propensity vía Log-Probs). *Si el LLM proporciona log-probabilidades por token (e.g., API de OpenAI con `logprobs`), entonces:*

$$\hat{\pi}_b(a|o) = \exp\left(\sum_{j=1}^{|a|} \text{logprob}\big(t_j\big)\right)$$

Limitación: *Requiere acceso a log-probs del modelo que generó los datos.*

12.2.3.2 Qué información necesita la evaluación

Desafío	Implicación	Mitigación Propuesta
$\lvert\mathcal{A}\rvert = \sum_{k=1}^{L} \lvert\Sigma\rvert^k$	Los pesos pueden concentrarse	Discretizar por clusters o templates
π_b desconocida	No hay log-probs	Entrenar modelo surrogate de π_b
No estacionariedad	Modelo actualizado	Usar solo datos recientes, detectar drift
Evaluación humana	r costoso, ruidoso	Usar LLM-as-judge calibrado
Confounding latente	Prompt history afecta	Incluir historia en estado, o bounds

Tabla 12.1: Desafíos de OPE en LLM-Agents

12.2.3.3 Qué conserva la discretización de acciones

Definición 12.12 (Discretización por Templates). Definir K templates de acción $\{T_1, ..., T_K\}$ y mapear cada acción a al template más cercano:

$$\tilde{a} = \underset{k \in \{1,...,K\}}{\arg\min}\ d(a, T_k)$$

donde d es distancia semántica (embedding cosine, BLEU, etc.).

El espacio agrupado es $\tilde{\mathcal{A}} = \{T_1, ..., T_K\}$. Aplicar OPE requiere especificar cómo se selecciona y ejecuta una acción dentro de cada grupo y justificar identificación para esa intervención.

La representación escogida determina qué diferencias entre acciones se conservan. Su evaluación exige considerar también el error que puede introducir esa agrupación.

Proposición 12.13 (Sesgo de Discretización). *Una cota concreta requiere fijar el criterio. En una decisión, sea $g(a)$ el template ejecutable y suponga $\sup_{s,a}|m(s,a) - m(s,g(a))| \leq \varepsilon$. Si la política agrupada es la imagen de la política original mediante g, integrar la diferencia de recompensas da $|J(\pi) - J(\pi_g)| \leq \varepsilon$. En horizonte infinito descontado, una condición análoga sobre Q^π, uniforme en estados y acciones, permite mediante la identidad de diferencia de rendimiento una cota $\frac{\varepsilon}{1-\gamma}$. La semejanza semántica por sí sola no demuestra ninguna de estas condiciones.*

12.2.3.4 Condiciones de una evaluación DR

Nota 12.14 (DR para LLM-Agents: Condiciones). Para una evaluación de una decisión con templates finitos se puede aplicar el resultado DR del Capítulo 7 si la agrupación define una intervención identificada, la política objetivo es fija, las unidades son iid, las recompensas y los ajustes están acotados, hay positividad uniforme y se usa cross-fitting por unidad independiente. Se requiere consistencia L^2 de ambos auxiliares y producto de errores $o_{P\left(n^{-\frac{1}{2}}\right)}$; dos tasas $o_{P\left(n^{-\frac{1}{4}}\right)}$ son suficientes. Con varianza límite positiva, esas condiciones permiten el CLT y el intervalo asociado. Para acciones secuenciales hacen falta el estimador longitudinal y las condiciones de su propio teorema. Los tres requisitos de overlap, aproximación de Q y estimación de propensiones, aislados, no prueban esa extensión.

12.2.3.5 Dónde debe revisarse la garantía

El Nota 8.8 (presentado en Sección 8.1.5) y su IC asociado **no** se transfieren automáticamente a LLM-agents en los siguientes casos:

1. Cuando la política objetivo no es evaluable como densidad ($\pi(a|s)$ no computable, típico de LLMs comerciales sin acceso a log-probs) — no hay overlap verificable ni ratio de importancia calculable.
2. Cuando la agrupación de acciones modifica el estimando sin una cota de aproximación — la cobertura nominal del IC no está garantizada.
3. Cuando el confounding por historial de prompt no está incluido en el estado — la identificación (MA/CMIA) falla.

En estos regímenes el agente debe reportar la ausencia de garantía explícitamente, no un IC con cobertura asumida.

12.2.3.6 Organizar una evaluación de acciones textuales

Primero se define la acción completa, incluyendo el mecanismo de terminación y el contexto disponible. Sus probabilidades deben corresponder al mecanismo efectivo de muestreo, con sus filtros y transformaciones. Un modelo surrogate introduce error de estimación que debe entrar en el análisis.

Agrupar acciones exige definir la intervención dentro de cada grupo; la distancia semántica no basta para preservar recompensas ni transiciones. Los pesos se calculan por unidad evaluada, y el diagnóstico habitual es $\text{ESS} = \frac{\left(\sum_{i=1}^{n} w_i\right)^2}{\sum_{i=1}^{n} w_i^2}$ cuando el denominador es positivo. No hay un umbral universal de ESS que certifique soporte poblacional, identificación o cobertura.

Si se truncan los pesos, se cambia el estimador y aparece un posible sesgo. El umbral debe acompañarse de un análisis de ese sesgo y de la inferencia resultante. La evaluación debe declarar el estimando, la unidad de partición, la agrupación de acciones, los pesos y las hipótesis del intervalo utilizado.

12.2.4 Un diseño de agente y las garantías que habría que justificar

Algoritmo: Decisión Basada en IC

1. **Observar:** Recibir o_t
2. **Actualizar estado:** $T_{t+1} = \text{update}(T_t, o_t)$
3. **Estimar valor:** $\hat{V}^\pi = f(T_{t+1})$
4. **Construir IC:** $\text{IC} = \left[\hat{V}^\pi \pm z_{0.975} \cdot \hat{\sigma}/\sqrt{n}\right]$
5. **Decidir:**

$$\text{Decisión} = \begin{cases} \text{EXPLORAR} & \text{si} \quad \text{ancho(IC)} > \epsilon \\ \text{ACTUAR} & \text{si} \quad \text{ancho(IC)} \leq \epsilon \quad \text{y} \quad L_{\text{IC}} \geq V_{\min} \\ \text{CONSULTAR} & \text{si} \quad \text{ancho(IC)} \leq \epsilon \quad \text{y} \quad L_{\text{IC}} < V_{\min} \end{cases}$$

Nota 12.15 (Objetivos de garantía del diseño). El diseño plantea los siguientes objetivos, que requieren resultados e hipótesis específicos antes de atribuirlos a una implementación:
1. **Cobertura:** IC con cobertura asintótica $\geq 1 - \alpha$
2. **Consistencia:** Decisiones convergen a óptimas
3. **Eficiencia:** Estimadores alcanzan cota semiparamétrica
4. **Trazabilidad:** Cada componente justificado teóricamente

12.2.5 Una agenda a partir de las condiciones que faltan

Las dificultades anteriores permiten distinguir tareas que suelen confundirse: identificar el valor, estimarlo con precisión y sostener una decisión posterior. La tabla relaciona cada pregunta con el trabajo adicional que exige dentro del alcance de esta monografía.

Área	Problema Central	Dirección de Investigación
Confounding	Identificación sin no-confoundamiento	Desarrollar bounds no paramétricos para V^π que no asuman no confoundamiento, extendiendo el trabajo de Shi et al. (2024) sobre MDP confundidos
POMDPs	Inferencia con observabilidad parcial	Diseñar estimadores DR que operen directamente sobre el espacio de creencias, sin necesidad de estimar el estado latente
LLM-Agents	Evaluación de políticas estocásticas complejas	Desarrollar teoría de OPE para acciones textuales de espacio discreto combinatorio y dependencia de contexto
Teoría	Condiciones de mixing en MDPs continuos	Caracterizar tasas de mixing para MDPs con estados continuos y políticas no estacionarias
Aplicación	Validación en dominios reales	Diseñar protocolos de validación que combinen garantías teóricas con evaluación empírica robusta

Tabla 12.2: Agenda de Investigación: Problemas Abiertos

Nota 12.16 (Problemas de Alto Impacto). Problemas con mayor potencial de impacto:
1. **OPE con Confounding:** Métodos que relajen el supuesto de no confoundamiento sin perder eficiencia
2. **LLM-Agent Evaluation:** Frameworks estadísticos para evaluar agentes basados en modelos de lenguaje
3. **Sample-Efficient OPE:** Métodos que requieran menos trayectorias sin sacrificar precisión
4. **Causal RL:** Integración de inferencia causal con aprendizaje por refuerzo

ID	Problema	Estado	Señal en la literatura
P12-1	OPE con confounding no observado	Parcial	Intervalos con MDP confundido (Shi et al., 2024); cotas *sharp* en MDP robustos (Bennett et al., 2024)
P12-2	Mitigación sin no-confoundamiento	Abierto	Estrategias (IV, sensibilidad, cotas, *proxies*) sin teorema propio
P12-3	OPE en POMDP	Parcial	Caso episódico vía *proxies* (Miao et al., 2022); falta el caso de horizonte largo en el espacio de creencias
P12-4	Evaluación de LLM-agents	Abierto	Sin protocolo OPE para acciones textuales
P12-5	*Mixing* en MDP continuos	Abierto	Los métodos recientes suponen *mixing* (Mehrabi & Wager, 2024)
P12-6	Validación en dominios reales	Abierto	Infraestructura de laboratorios; sin protocolo cerrado
P12-7	OPE eficiente en muestra	Parcial	Eficiencia semiparamétrica y maldición del horizonte (Kallus & Uehara, 2022)
P12-8	Causal RL	Abierto	Puentes parciales; sin integración formal en el libro
P12-9	Agente *end-to-end* con garantías	Abierto	Marco del capítulo; no es resultado cerrado

Tabla 12.3: Alcance de las preguntas en esta monografía. «Parcial» indica resultados para casos restringidos; «abierto» indica que el problema formulado aquí queda sin resolver en el libro.

12.2.6 Qué significaría sostener esas garantías

La pregunta por la confiabilidad vuelve así a una relación entre el diseño y sus condiciones de uso. Los criterios siguientes describen qué se espera documentar y revisar en un agente; cada propiedad estadística conserva el alcance del procedimiento que la respalda.

Definición 12.17 (Agente Confiable). Un agente es *confiable* si:

1. **Validación Estadística:** Sus decisiones están respaldadas por garantías estadísticas verificables
2. **Transparencia:** Cada componente puede ser trazado hasta su justificación teórica
3. **Robustez:** Declara las variaciones del modelo que tolera y los límites de esa tolerancia
4. **Interpretabilidad:** Sus decisiones pueden ser explicadas en términos del dominio

Esos criterios pueden relacionarse con resultados concretos de la inferencia, siempre que el modelo y el procedimiento cumplan sus hipótesis.

Nota 12.18 (Resultados que pueden respaldar el diseño). Bajo las hipótesis correspondientes, el diseño puede apoyarse en:

1. **Garantías de Cobertura:** Los IC del Capítulo 8 tienen cobertura asintótica verificable
2. **Trazabilidad Completa:** Cada componente puede ser rastreado hasta su origen teórico
3. **Robustez DR:** La identidad del Capítulo 7 precisa las combinaciones de modelos auxiliares para las que se conserva el centrado
4. **Eficiencia:** La función de influencia del Capítulo 4 permite comparar la varianza con la cota del modelo

Estas exigencias pueden leerse como condiciones por justificar en una implementación del SSCH.

Ejemplo 12.19 *(sintético)* **(Agente SSCH Confiable).** Para estudiar la confiabilidad de una implementación SSCH, habría que justificar que:
- Cada recomendación viene con un IC que cuantifica la incertidumbre
- La política puede ser explicada en términos de los principios de Bellman
- El estimador DR es robusto ante errores en el modelo de transiciones
- La eficiencia semiparamétrica garantiza que no se desperdicia información

Del problema abierto al diseño de una evaluación

12.3.1 Conservar la información entre componentes

Una vez fijados el objetivo y el experimento, la arquitectura debe conservar la información que exige el procedimiento. La separación de responsabilidades permite revisar dónde se estiman los modelos auxiliares, cómo se calcula el valor y qué evidencia utiliza la decisión.

Definición 12.20 (Arquitectura del Agente). Un agente basado en el marco Wald-MDP tiene los siguientes componentes:
1. **Módulo de Estimación:** Implementa $\hat{Q}$ y $\hat{\pi}_b$ usando métodos semiparamétricos
2. **Módulo de Evaluación:** Calcula $\hat{V}^{\mathrm{DR}}$ y sus IC mediante una ruta inferencial justificada para ese estimador y ese muestreo
3. **Módulo de Inferencia:** Proporciona garantías estadísticas y tests de hipótesis
4. **Módulo de Decisión:** Usa la información del módulo de evaluación para tomar decisiones

El objetivo y la incertidumbre deben viajar con la estimación a lo largo de los módulos. De ese modo, la decisión puede recuperar qué se calculó y bajo qué condiciones.

Nota 12.21 (Flujo de Información). El flujo de información entre componentes:
1. Datos observacionales $\to$ Módulo de Estimación $\to \hat{Q}, \hat{\pi}_b$
2. $\hat{Q}, \hat{\pi}_b \to$ Módulo de Evaluación $\to \hat{V}^{\mathrm{DR}}$, IC
3. $\hat{V}^{\mathrm{DR}}$, IC $\to$ Módulo de Inferencia $\to$ Tests, poder
4. $\hat{V}^{\mathrm{DR}}$, IC, tests $\to$ Módulo de Decisión $\to$ Acción

El flujo anterior permite describir cómo una comparación del SSCH llegaría hasta la decisión.

Ejemplo 12.22 *(sintético)* **(Integración en SSCH).** En el SSCH, la integración funciona así:
- El módulo de estimación ajusta modelos de transición y recompensa usando datos históricos
- El módulo de evaluación calcula el valor de cada política candidata con ICs
- El módulo de inferencia verifica si las diferencias son estadísticamente significativas
- El módulo de decisión selecciona la política con mayor valor, respetando los ICs

12.3.2 Responder a una limitación del análisis

Las limitaciones reaparecen en el flujo de datos: una acción poco observada dificulta el cambio de medida, una trayectoria dependiente exige tratar su varianza y un modelo auxiliar introduce error de aproximación. La respuesta debe referirse a la dificultad que se ha encontrado.

Nota 12.23 (Limitaciones del Marco). Limitaciones principales:
1. **Overlap:** Una condición suficiente de control de razones es $\pi_b(a|s) \geq \eta \cdot \pi_e(a|s)$ con $\eta > 0$; no es necesaria para toda variante DR
2. **Mixing:** El Teorema de Shi et al. requiere condiciones de mixing
3. **Nuisance Estimation:** La calidad de $\hat{Q}$ y $\hat{\pi}_b$ afecta la performance
4. **Horizonte Infinito:** La estimación de valor es más difícil en horizontes largos

Una respuesta posible es modificar el procedimiento o acotar el objetivo. Cada cambio requiere registrar la nueva pregunta y el error que se acepta.

Definición 12.24 (Estrategias de Mitigación). Estrategias para manejar limitaciones:
1. **Clipping de Ratios:** Truncar $\rho = \pi_e/\pi_b$ para evitar varianza excesiva
2. **Importance Sampling Truncado:** Descartar trayectorias con ratios extremos
3. **Modelos Nuisance Robustos:** Usar métodos robustos para estimar Q y π_b
4. **Horizonte Finito:** Truncar el horizonte cuando la dependencia temporal es débil

En una evaluación longitudinal del SSCH, esos cambios deben relacionarse con la información disponible en cada visita.

Ejemplo 12.25 *(sintético)* **(Limitaciones en SSCH).** En el SSCH, las principales limitaciones son:
- **Overlap:** Algunas políticas agresivas tienen baja probabilidad bajo π_b
- **Mixing:** Las transiciones de salud tienen dependencia temporal de largo plazo
- **Nuisance:** Los modelos de transición son aproximados
- **Solución:** Usar clipping de ratios y horizonte finito de 12 meses

El recorrido del SSCH leído como una evaluación

Ejemplo 12.26 *(sintético)* **(SSCH: preguntas que acompañan una decisión).** Al volver al SSCH, conviene seguir la pregunta de cada experimento. El caso tabular y el subcaso de dos visitas tienen diseños distintos, descritos en el Capítulo 10. Sus cifras se interpretan dentro de esos diseños.

Recorrido	Pregunta	Límite de la conclusión
Capítulo 2	¿Qué costo asignamos a cada error?	La regla depende de la pérdida y la clase de decisiones
Capítulo 3	¿Qué política optimiza la dinámica conocida?	La planificación se refiere al modelo especificado
Capítulo 4	¿Qué permiten estimar los datos?	La propiedad corresponde al estimador y al muestreo
Capítulo 5	¿Se conserva el riesgo al representar la regla?	La identidad se demuestra para la familia construida
Capítulo 7 y Capítulo 8	¿Podemos evaluar otra política y cuantificar su incertidumbre?	Identificación, soporte y ruta inferencial deben justificarse
Capítulo 9 y Capítulo 11	¿La implementación conserva esas condiciones?	Un cambio de población, procedimiento o política obliga a revisar

La continuidad del ejemplo está en esas preguntas. Un cálculo de riesgo, una comparación de políticas y un intervalo responden a objetivos que se relacionan, pero cuya interpretación depende del experimento. El registro de cada decisión permite recuperar qué datos y qué supuestos la sostienen.

Preguntas para continuar el trabajo

Las dificultades de identificación, observación y dependencia pueden formularse ahora como objetivos de investigación. Los enunciados siguientes precisan qué se buscaría obtener dentro de los modelos indicados. Su resolución general queda fuera de los resultados desarrollados en el libro.

12.4.1 Confounding no observado: identificación parcial y métodos robustos

Cuando la ausencia de confusión no observada no puede justificarse, puede ser más adecuado buscar un conjunto de valores compatibles con los datos y con supuestos de sensibilidad. La literatura de

identificación parcial de Manski (1990) e Imbens y Manski (2004) ofrece un punto de partida para estudiar cotas de V^{π_e}. La pregunta siguiente precisa una forma de continuar ese trabajo:

Problema 12.27 (Cotas eficientes bajo confounding parcial). Dado un nivel de confounding no observado acotado por un parámetro de sensibilidad Γ, caracterizar la función de influencia eficiente para las cotas de V^{π_e} y construir intervalos de confianza para dichas cotas que sean óptimos en el sentido semiparamétrico.

Los trabajos de un solo período (Rosenbaum, 2002; Yadlowsky et al., 2022) permiten estudiar cómo se formula la sensibilidad. La extensión solicitada al caso secuencial de horizonte largo queda fuera del desarrollo de esta monografía.

12.4.2 POMDPs: inferencia con observabilidad parcial

En un POMDP, el estado de creencia b_t depende de la información observada y del modelo de filtrado. Si el estado latente es finito, la creencia es un vector de probabilidades; para espacios generales puede ser una distribución de dimensión infinita. Además del cálculo de una política, interesa saber cómo el error del filtro afecta a la evaluación estadística:

Problema 12.28 (Inferencia eficiente en POMDPs con estado latente finito). Para un POMDP con espacio de estados latentes finito $|\mathcal{S}| = K$ conocido, caracterizar la IF eficiente para V^{π_e} en términos de las distribuciones de filtrado $P(s_t \mid o_1, \ldots, o_t)$ y derivar estimadores DR que hereden la doble robustez del caso de observabilidad completa.

El trabajo de Tennenholtz, Shalit y Mannor (2020) sobre OPE con confounding latente representa avances en esta dirección, pero sin las garantías de eficiencia semiparamétrica que el Problema 12.28 solicita.

12.4.3 LLM-agents: evaluación sin acceso a la política

Cuando una política π produce acciones pero su mecanismo de generación no permite calcular $\pi(a|s)$, los cocientes habituales de OPE no están directamente disponibles. El historial de conversación añade además un espacio de información extenso. La pregunta consiste en precisar qué datos y qué restricciones permitirían recuperar una evaluación en ese régimen.

Problema 12.29 (OPE para políticas no evaluables). Desarrollar métodos de evaluación off--policy para políticas π_e cuya densidad $\pi_e(a|s)$ no es computacionalmente accesible, ya sea mediante estimación del ratio $\pi_e(a|s)/\pi_b(a|s)$ directamente como razón de densidades, o mediante métodos de evaluación que no requieran dichos ratios.

El método directo utiliza un modelo de valor y evita calcular algunos cocientes, a cambio de depender de la calidad de ese modelo. Una propuesta para el problema anterior tendría que precisar qué información sustituye a las probabilidades de acción y cómo se controla el sesgo que pueda quedar.

12.4.4 Condiciones de mixing en espacios continuos de alta dimensión

Las condiciones de mixing del Capítulo 4 y los resultados del Capítulo 8 están formuladas para cadenas de Markov en espacios de estados discretos o en $\mathbb{R}^d$ con d fijo. En aplicaciones modernas de RL con redes neuronales profundas, el espacio de estados efectivo tiene dimensión muy alta y la cadena de Markov inducida por π_b puede no satisfacer las condiciones de mixing geométrico bajo las que el CLT se extiende.

Problema 12.30 (Condiciones de mixing en espacios de alta dimensión). Caracterizar clases de MDPs con espacio de estados en $\mathbb{R}^d$ (o en espacios de secuencias) bajo las cuales la cadena de Markov inducida por políticas representadas por redes neuronales satisface condiciones de mixing polynomial, y derivar tasas de convergencia explícitas para el CLT del estimador DR.

Cómo orientar el trabajo que sigue

Una forma de avanzar consiste en escoger una dificultad y declarar qué información adicional permitiría tratarla. En presencia de confusión no observada, por ejemplo, un análisis de sensibilidad necesita definir el modelo de desviación antes de construir sus cotas. En observación parcial, hay que fijar la relación entre el estado latente, el registro disponible y las acciones. Esa delimitación permite comparar un método nuevo con los resultados de los capítulos anteriores.

Otra línea de trabajo es sostener una evaluación cuando el sistema cambia. El Capítulo 11 distingue los cambios de implementación, política y población. Un protocolo de auditoría puede apoyarse en esa distinción para registrar la evidencia de cada versión, sus condiciones de revisión y el alcance de las decisiones que permite tomar.

Aprender una política con datos observacionales plantea una exigencia adicional a evaluarla. La selección favorece candidatas con resultados muestrales altos y obliga a considerar la incertidumbre del procedimiento completo. El diseño de evaluaciones independientes, restricciones de política y criterios conservadores ofrece preguntas que conectan la comparación de riesgos del Capítulo 2 con los problemas de aprendizaje fuera de línea. Cada propuesta debe precisar cómo se justifica la decisión final.

Ejercicios

12.6.1 Ejercicios Teóricos

1. **Confounding No Observado:** Demuestre que bajo confounding no observado, el estimador IS está sesgado incluso si $\pi_b(a|s) > 0$ para todo a. Use la definición de confounding de la Sección 12.2.1.
2. **POMDPs:** Demuestre que el espacio de creencias en un POMDP es un espacio de probabilidad infinito-dimensional. ¿Qué implicaciones tiene esto para la estimación de valor?
3. **LLM-Agents:** Derive la varianza del estimador IS para acciones textuales cuando el espacio de acciones es Σ^L. ¿Cómo crece la varianza con L?
4. **Mixing:** Demuestre que un MDP con cadena de Markov irreducible y aperiódica es geométricamente β-mixing. Use el gap espectral.
5. **SAVE:** Demuestre que el estimador SAVE tiene varianza menor o igual que el estimador IS bajo las condiciones del Nota 8.8.

12.6.2 Ejercicios Prácticos

1. **Implementación de DR:** Implemente el estimador DR para el SSCH usando Python. Compare con IS y DM cuando el modelo de recompensa está mal especificado.
2. **ICs para V^π:** Implemente el cálculo de ICs usando el procedimiento de Shi et al. con su estimador de varianza; compare por separado con una ruta que justifique HAC. Valide la cobertura mediante simulación.
3. **Análisis de Poder:** Para el SSCH, calcule el tamaño de muestra necesario para detectar una diferencia de 0.5 unidades entre π_1 y π_2 con poder 80%.
4. **LLM-Agent OPE:** Implemente un estimador de propensity para acciones textuales usando log--probabilidades de un LLM. Evalúe una política simple.

Dr. Jaime Lizcano Cuervo

5. **POMDP State Estimation:** Implemente un filtro de partículas para estimar el estado latente en un POMDP simple. Compare con el caso completamente observable.

12.6.3 Ejercicios de Síntesis

1. **Mapa de Trazabilidad:** Para un agente que usted diseñe, cree un mapa de trazabilidad completo conectando cada componente con su justificación teórica.
2. **Análisis de Limitaciones:** Identifique las limitaciones del marco Wald-MDP en su dominio de aplicación. Proporcione estrategias de mitigación específicas.
3. **Diseño de Experimento:** Diseñe un experimento para validar las garantías del marco en un dominio real. Incluya métricas de cobertura, eficiencia y robustez.
4. **Extensión Teórica:** Proponga una extensión del marco para manejar uno de los problemas abiertos identificados en la Sección 12.2.5.
5. **Agente Confiable:** Diseñe un agente confiable para un dominio de su elección. Justifique cada componente usando el marco Wald-MDP.

Lecturas Propuestas

Lecturas Obligatorias

1. **Shi et al. (2022)**, «Statistical Inference for RL».
2. **Kallus & Uehara (2022)**, «Efficient OPE».

Decidir con la información que se tiene

La medición imperfecta de la Introducción sigue planteando la misma elección: actuar con lo observado o buscar información antes de hacerlo. Después del recorrido podemos describir mejor esa elección. La pérdida precisa qué consecuencias importan; el modelo indica cómo se relacionan con los datos; la regla establece qué información usa la acción. Si la decisión afecta al futuro, las transiciones y el horizonte completan el problema.

La incertidumbre acompaña a esa descripción. Conocer el valor óptimo en un modelo tabular no determina el valor de una política en una población nueva. Una estimación favorable requiere además entender qué datos la producen y con qué precisión aproxima su objetivo. Los intervalos, los contrastes y las cotas permiten expresar parte de esa incertidumbre bajo condiciones que deben permanecer visibles.

El procedimiento de verificación permite volver desde una decisión hasta sus razones. Ante una discrepancia, se puede examinar la distribución de los datos, el soporte de las acciones, el error de los modelos auxiliares o la implementación del estimador. Esa posibilidad de revisión es parte del uso de una garantía: el registro de sus condiciones orienta lo que hay que comprobar cuando cambia la situación.

Los apéndices permiten seguir ese trabajo con más detalle. Reúnen argumentos, notación y condiciones, además de un diseño de reproducción cuyos resultados pendientes se señalan junto al experimento. El lector puede consultar esos materiales al retomar una demostración, reproducir un cálculo o formular una pregunta nueva.

Una decisión posterior volverá a exigir el mismo cuidado: precisar qué se quiere conseguir, qué información está disponible y qué conclusión permiten los datos. Las herramientas del libro ayudan a responder esas preguntas y a reconocer cuándo todavía hace falta aprender algo antes de actuar.

Lima, Perú, 2026

Dr. Jaime Lincovil Curivil

Dr. Jaime Lino Grau Curivil

Apéndices

Las demostraciones y los materiales de consulta permiten volver sobre los argumentos del libro. La notación, las condiciones de regularidad y los diseños de reproducción se leen junto con el resultado o el experimento al que pertenecen.

Apéndice A

Demostraciones y argumentos complementarios

Las demostraciones permiten volver desde un enunciado hasta las razones que lo sostienen. Este apéndice reúne los argumentos por temas, con referencias al resultado correspondiente en el cuerpo del libro. Cuando se ofrece un bosquejo o se remite al desarrollo de la fuente, esa indicación delimita lo que se presenta aquí.

La lectura puede comenzar en el resultado que haya motivado la consulta. Las familias exponenciales y la reducción de datos acompañan las herramientas estadísticas; las pruebas de decisión, programación dinámica y evaluación siguen las preguntas que enlazan el resto de la exposición.

Familias exponenciales

La función de log-partición relaciona el modelo con sus momentos. Sus propiedades preparan el uso de los estadísticos naturales del Capítulo 4.

A.1.1 Propiedades de la función de log-partición

Demostración completa del Teorema 4.18. Sea $f(x|\eta) = h(x)\exp\{\eta^\top T(x) - A(\eta)\}$ la densidad de una familia exponencial regular con espacio de parámetros naturales $\mathcal{H}$ abierto.

1. Convexidad de $A(\eta)$. Por definición, $A(\eta) = \log \int h(x)\exp\{\eta^\top T(x)\}\,\mathrm{d}\mu(x)$. Para cualquier $\eta_1, \eta_2 \in \mathcal{H}$ y $\lambda \in [0,1]$, aplicamos la desigualdad de Hölder:

$$\begin{aligned}
\exp\{A(\lambda\eta_1 + (1-\lambda)\eta_2)\} &= \int h(x)\exp\big\{[\lambda\eta_1 + (1-\lambda)\eta_2]^\top T(x)\big\}\,\mathrm{d}\mu(x) \\
&= \int \big[h(x)\exp\{\eta_1^\top T(x)\}\big]^{\lambda}\big[h(x)\exp\{\eta_2^\top T(x)\}\big]^{1-\lambda}\,\mathrm{d}\mu(x) \\
&\le \left(\int h(x)\exp\{\eta_1^\top T(x)\}\,\mathrm{d}\mu(x)\right)^{\lambda}\left(\int h(x)\exp\{\eta_2^\top T(x)\}\,\mathrm{d}\mu(x)\right)^{1-\lambda} \\
&= \exp\{\lambda A(\eta_1) + (1-\lambda)A(\eta_2)\}
\end{aligned}$$

Tomando logaritmos, $A(\lambda\eta_1 + (1-\lambda)\eta_2) \le \lambda A(\eta_1) + (1-\lambda)A(\eta_2)$, por lo que A es convexa.

2. $\nabla A(\eta) = \mathbb{E}_\eta[T(X)]$. Diferenciamos la condición de normalización:

$$1 = \int f(x|\eta)\,\mathrm{d}\mu(x) = \int h(x)\exp\{\eta^\top T(x) - A(\eta)\}\,\mathrm{d}\mu(x)$$

Derivando respecto a η_j e intercambiando derivación e integración (justificado por regularidad):

$$
\begin{aligned}
0 &= \frac{\partial}{\partial \eta_j} \int h(x) \exp\{\eta^\top T(x) - A(\eta)\} \, \mathrm{d}\mu(x) \\
&= \int h(x) \exp\{\eta^\top T(x) - A(\eta)\} \big[T_j(x) - \partial_j A(\eta)\big] \, \mathrm{d}\mu(x) \\
&= \mathbb{E}_\eta\big[T_j(X)\big] - \partial_j A(\eta)
\end{aligned}
$$

Por lo tanto, $\partial_j A(\eta) = \mathbb{E}_\eta\big[T_j(X)\big]$ para cada j, es decir, $\nabla A(\eta) = \mathbb{E}_\eta[T(X)]$.

3. $\nabla^2 A(\eta) = \mathrm{Cov}_\eta(T(X))$. Diferenciamos nuevamente la identidad $\partial_j A(\eta) = \mathbb{E}_\eta\big[T_j(X)\big]$:

$$
\begin{aligned}
\partial_k \partial_j A(\eta) &= \frac{\partial}{\partial \eta_k} \int T_j(x) f(x|\eta) \, \mathrm{d}\mu(x) \\
&= \int T_j(x) \frac{\partial}{\partial \eta_k} f(x|\eta) \, \mathrm{d}\mu(x) \\
&= \int T_j(x) [T_k(x) - \partial_k A(\eta)] f(x|\eta) \, \mathrm{d}\mu(x) \\
&= \mathbb{E}_\eta\big[T_j(X) T_k(X)\big] - \mathbb{E}_\eta\big[T_j(X)\big] \mathbb{E}_\eta[T_k(X)] \\
&= \mathrm{Cov}_\eta\big(T_j(X), T_k(X)\big)
\end{aligned}
$$

Por lo tanto, $\nabla^2 A(\eta) = \mathrm{Cov}_\eta(T(X))$, que es semidefinida positiva por convexidad de A. En familias minimales, es definida positiva. □

Reducción de datos

La factorización y la completitud precisan qué información conserva un estadístico bajo el modelo considerado. Los argumentos siguientes se consultan junto con las condiciones de sus enunciados en el Capítulo 4.

A.2.1 Teorema de Factorización de Neyman-Fisher

Demostración del Teorema 4.35. En el modelo dominado puede elegirse una mezcla numerable $Q = \sum_j c_j P_{\theta_j}$, con $c_j > 0$, que domina todas las leyes de la familia (lema de Halmos–Savage). Trabajamos con $f_\theta = \mathrm{d}\frac{P_\theta}{\mathrm{d}} Q$. Si T es suficiente, su núcleo condicional común $K(t, B)$ también es la ley de X dado T bajo Q. Al escribir $g_\theta = \mathrm{d}\frac{P_\theta^T}{\mathrm{d}} Q^T$, la desintegración da

$$
P_{\theta(B)} = \int K(t, B) g_{\theta(t)} \, \mathrm{d}Q^T(t) = \int_B g_{\theta(T(x))} \, \mathrm{d}Q(x).
$$

Luego $f_{\theta(x)} = g_{\theta(T(x))}$, casi seguramente bajo Q. Multiplicar por la densidad de Q respecto de la medida dominante da la factorización solicitada. Recíprocamente, una factorización respecto de la medida original implica que $\mathrm{d}\frac{P_\theta}{\mathrm{d}} Q$ es función de T, pues la densidad de la mezcla tiene el mismo factor h. Entonces

$$
\mathbb{E}_{\theta[\mathbb{1}_B|T]} = \frac{\mathbb{E}_{Q[f_\theta \mathbb{1}_B|T]}}{\mathbb{E}_{Q[f_\theta|T]}} = K(T, B)
$$

donde el denominador es positivo; fuera de ese soporte la versión es irrelevante para P_θ. Los espacios estándar de Borel aseguran los núcleos regulares usados. No se integra sobre fibras usando una medida ambiente que les asigne masa cero. □

Dr. Jaime Lincovil C. M.V.

A.2.2 Criterio de suficiencia minimal

Argumento del criterio de proporcionalidad. Bajo las condiciones de versiones y medibilidad del Teorema 4.39, las clases de observaciones con verosimilitudes proporcionales determinan los cocientes $\frac{f_\theta}{f_{\theta_0}}$. Su sigma-álgebra es suficiente por factorización. Cualquier estadístico suficiente S hace esos cocientes medibles respecto de S; por tanto determina las clases y, por la hipótesis medible del criterio, $T = h(S)$ casi seguramente. Esta es la dirección correcta de la minimalidad. No se necesita ni existe en general una inversa de h. En un modelo multinomial con tamaño fijo conocido, los conteos y las proporciones son transformaciones biyectivas y tienen la misma suficiencia minimal. En una trayectoria de Markov los conteos por pares pueden factorizar la verosimilitud, pero sus totales aleatorios impiden deducir completitud o propiedades UMVUE del experimento multinomial de tamaño fijo. □

A.2.3 Completitud en familias exponenciales

Demostración completa del Teorema 4.43. Sea $\mathcal{P} = \{P_\eta : \eta \in \Xi\}$ una familia exponencial natural con densidad:

$$p(x|\eta) = h(x)\exp\{\eta^T T(x) - A(\eta)\}$$

donde Ξ contiene un conjunto abierto en $\mathbb{R}^k$.

Definición de completitud: El estadístico $T(X)$ es *completo* si para toda función medible $g : \mathcal{T} \to \mathbb{R}$ tal que:

$$\mathbb{E}_\eta[g(T(X))] = 0 \quad \forall \eta \in \Xi$$

se sigue que $g(T(X)) = 0$ casi seguramente bajo todo P_η.

Demostración: Supongamos que $\mathbb{E}_\eta[g(T(X))] = 0$ para todo $\eta \in \Xi$. Entonces:

$$0 = \mathbb{E}_\eta[g(T(X))] = \int g(T(x))h(x)\exp\{\eta^T T(x) - A(\eta)\}\,\mathrm{d}x$$

$$= \exp\{-A(\eta)\}\int g(T(x))h(x)\exp\{\eta^T T(x)\}\,\mathrm{d}x$$

Multiplicando por $\exp\{A(\eta)\}$:

$$\int g(T(x))h(x)\exp\{\eta^T T(x)\}\,\mathrm{d}x = 0 \quad \forall \eta \in \Xi$$

Para justificar unicidad, trabaje con la ley de T, no con una transformada en la variable x. Fije η_0 interior y defina la medida firmada finita $\nu(\mathrm{d}t) = g(t)P_{\eta_0}^T(\mathrm{d}t)$. Su transformada de Laplace es cero en un entorno del origen, porque

$$\int \exp(u^\top t)\nu(\mathrm{d}t) = \exp(A(\eta_0 + u) - A(\eta_0))\mathbb{E}_{\eta_0+u}[g(T)] = 0.$$

La integrabilidad absoluta de g bajo cada parámetro asegura existencia en ese entorno. La unicidad de la transformada implica $\nu = 0$, luego $g(T) = 0$ bajo P_{η_0}. La equivalencia de las leyes de T en el soporte común extiende la conclusión a todo parámetro de la familia.

Condiciones de regularidad: Esta demostración requiere:
1. El espacio de parámetros naturales Ξ contiene un conjunto abierto en $\mathbb{R}^k$
2. La función $h(x) > 0$ en el soporte de la familia
3. La transformada de la medida firmada de T existe en un entorno del origen

Dr. Rafael Rincón Quintero

4. La función g es medible y la integral está bien definida

Alcance: Aplicar este resultado a conteos de una trayectoria requiere demostrar sus hipótesis en ese experimento. Los conteos de transiciones no tienen en general una ley multinomial de tamaño fijo; tampoco se ha probado aquí que el orden sea ancilar ni que los cocientes de conteos sean insesgados. □

A.2.4 Teorema de Basu

Demostración completa del Teorema 4.48. Sea $T(X)$ un estadístico suficiente completo y $A(X)$ un estadístico ancilar. Queremos demostrar que $T(X)$ y $A(X)$ son independientes.

Definiciones:
- $T(X)$ es *suficiente completo*: la distribución de $X \mid T(X)$ no depende de θ, y si $\mathbb{E}_\theta[g(T(X))] = 0$ para todo θ, entonces $g(T(X)) = 0$ casi seguramente.
- $A(X)$ es *ancilar*: la distribución de $A(X)$ no depende de θ.

Demostración:

Para cualquier conjunto medible B en el espacio de $A(X)$, consideramos la probabilidad condicional:

$$h(T(X)) = P_\theta(A(X) \in B \mid T(X))$$

Paso 1: $h(T(X))$ no depende de θ.

Por suficiencia de $T(X)$, la distribución condicional $X \mid T(X)$ no depende de θ. Por tanto, $P_\theta(A(X) \in B \mid T(X))$ tampoco depende de θ, y podemos escribir $h(T(X))$ sin subíndice θ.

Paso 2: Tomar esperanza sobre θ.

$$\begin{aligned}\mathbb{E}_\theta[h(T(X))] &= \mathbb{E}_\theta[P_\theta(A(X) \in B \mid T(X))] \\ &= P_\theta(A(X) \in B) \quad \text{(ley de la probabilidad total)}\end{aligned}$$

Como $A(X)$ es ancilar, $P_\theta(A(X) \in B) = P(A(X) \in B)$ no depende de θ. Por tanto:

$$\mathbb{E}_\theta[h(T(X))] = P(A(X) \in B) \quad \forall\theta$$

Paso 3: Aplicar completitud.

Definimos $g(T(X)) = h(T(X)) - P(A(X) \in B)$. Entonces:

$$\mathbb{E}_\theta[g(T(X))] = \mathbb{E}_\theta[h(T(X))] - P(A(X) \in B) = 0 \quad \forall\theta$$

Por completitud de $T(X)$, esto implica que:

$$g(T(X)) = 0 \quad \text{casi seguramente}$$

Por tanto:

$$h(T(X)) = P(A(X) \in B) \quad \text{casi seguramente}$$

Paso 4: Conclusión de independencia.

La ecuación anterior significa que:

$$P_\theta(A(X) \in B \mid T(X) = t) = P(A(X) \in B) \quad \text{para casi todo } \ t$$

Esto es exactamente la definición de independencia entre $A(X)$ y $T(X)$: la distribución condicional de $A(X)$ dado $T(X)$ no depende del valor de $T(X)$.

Dr. Jair Cortés Durivil

Condiciones de regularidad: Esta demostración requiere:
1. $T(X)$ es suficiente completo
2. $A(X)$ es ancilar
3. Las probabilidades condicionales están bien definidas

Alcance: Aplicar este resultado a conteos de una trayectoria requiere demostrar sus hipótesis en ese experimento. Los conteos de transiciones no tienen en general una ley multinomial de tamaño fijo; tampoco se ha probado aquí que el orden sea ancilar ni que los cocientes de conteos sean insesgados. □

A.2.5 Riesgo de una regla equivariante

Demostración. Si $X \sim P_\theta$ y el modelo es invariante, $gX \sim P_{g\theta}$. Para pérdida invariante y regla equivariante,

$$R(g\theta, \delta) = \mathbb{E}_{\theta[L(g\theta, \delta(gX))]} = \mathbb{E}_{\theta[L(g\theta, g\delta(X))]} = R(\theta, \delta).$$

Se exige que las esperanzas estén definidas. El riesgo es constante en cada órbita. Una acción transitiva da constancia global, pero no demuestra por sí sola minimax ni existencia de una regla óptima equivariante. □

Estimación puntual y precisión

Con una reducción de datos justificada, la comparación de estimadores puede apoyarse en condicionamiento, unicidad o cotas de información. Cada argumento conserva el criterio de optimalidad de su enunciado.

A.3.1 Teorema de Rao-Blackwell

Demostración completa del Teorema 4.56. Sea $\delta(X)$ un estimador arbitrario y $T(X)$ un estadístico suficiente. Definimos $\delta^*(X) = \mathbb{E}[\delta(X) \mid T(X)]$.

Insesgadez: Si $\delta(X)$ es insesgado para $g(\theta)$, entonces:

$$\mathbb{E}_\theta[\delta^*(X)] = \mathbb{E}_\theta[\mathbb{E}[\delta(X) \mid T(X)]] = \mathbb{E}_\theta[\delta(X)] = g(\theta)$$

por la ley de la esperanza iterada. Por tanto, $\delta^*(X)$ también es insesgado.

Reducción de varianza: Usamos la ley de la varianza total:

$$\mathrm{Var}_\theta(\delta(X)) = \mathbb{E}_\theta[\mathrm{Var}_\theta(\delta(X) \mid T(X))] + \mathrm{Var}_\theta(\mathbb{E}_\theta[\delta(X) \mid T(X)])$$

El primer término es $\mathbb{E}_\theta[\mathrm{Var}_\theta(\delta(X) \mid T(X))] \geq 0$ y el segundo término es $\mathrm{Var}_\theta(\delta^*(X))$. Por tanto:

$$\mathrm{Var}_\theta(\delta(X)) = \mathrm{Var}_\theta(\delta^*(X)) + \mathbb{E}_\theta[\mathrm{Var}_\theta(\delta(X) \mid T(X))] \geq \mathrm{Var}_\theta(\delta^*(X))$$

La igualdad se cumple si y solo si $\mathrm{Var}_\theta(\delta(X) \mid T(X)) = 0$ casi seguramente, lo que significa que $\delta(X)$ es función de $T(X)$.

Condiciones de regularidad: Esta demostración requiere:
1. $T(X)$ es suficiente para θ
2. $\delta(X)$ es un estimador insesgado
3. Las esperanzas y varianzas condicionales están bien definidas
4. $\mathbb{E}[\delta(X)^2] < \infty$ (varianza finita)

Aplicación al contexto MDP (SSCH): En el Sistema de Soporte Clínico para Hipertensión, este teorema justifica el uso de estimadores basados en los conteos de transiciones $T(X) = (N_1, N_2, N_3, N_4, N_5)$ en lugar de usar la secuencia completa de observaciones. Al condicionar sobre los conteos suficientes, obtenemos estimadores con menor varianza para las probabilidades de transición del MDP, lo que mejora la precisión de las predicciones de evolución de la hipertensión.□

A.3.2 Teorema de Lehmann-Scheffé

Demostración completa del Teorema 4.60. Sea $T(X)$ un estadístico suficiente completo y $\delta(T(X))$ un estimador insesgado para $g(\theta)$. Queremos mostrar que $\delta(T(X))$ es el UMVUE.

Unicidad: Supongamos que existe otro estimador insesgado $\tilde{\delta}(X)$ para $g(\theta)$. Por el teorema de Rao-Blackwell, el estimador $\tilde{\delta}^*(X) = \mathbb{E}\left[\tilde{\delta}(X) \mid T(X)\right]$ tiene varianza menor o igual a $\tilde{\delta}(X)$ y también es insesgado.

Como $T(X)$ es suficiente, $\tilde{\delta}^*(X)$ es función de $T(X)$, es decir, $\tilde{\delta}^*(X) = \varphi(T(X))$ para alguna función φ.

Aplicación de completitud: Consideramos la diferencia:

$$\mathbb{E}_\theta[\delta(T(X)) - \varphi(T(X))] = g(\theta) - g(\theta) = 0 \quad \forall\theta$$

Como $T(X)$ es completo, esto implica que:

$$\delta(T(X)) - \varphi(T(X)) = 0 \quad \text{casi seguramente}$$

Por tanto, $\delta(T(X)) = \varphi(T(X)) = \tilde{\delta}^*(X)$ casi seguramente.

Optimalidad: Como $\tilde{\delta}^*(X)$ tiene varianza menor o igual a cualquier otro estimador insesgado $\tilde{\delta}(X)$, y $\delta(T(X)) = \tilde{\delta}^*(X)$, concluimos que $\delta(T(X))$ tiene varianza mínima entre todos los estimadores insesgados.

Condiciones de regularidad: Esta demostración requiere:
1. $T(X)$ es suficiente para θ
2. $T(X)$ es completo
3. $\delta(T(X))$ es insesgado para $g(\theta)$
4. Las esperanzas están bien definidas

Alcance: Aplicar este resultado a conteos de una trayectoria requiere demostrar sus hipótesis en ese experimento. Los conteos de transiciones no tienen en general una ley multinomial de tamaño fijo; tampoco se ha probado aquí que el orden sea ancilar ni que los cocientes de conteos sean insesgados. □

A.3.3 Desigualdad de Cramér-Rao

Demostración completa del Teorema 4.64. Sea $\delta(X)$ un estimador insesgado para $g(\theta)$, es decir, $\mathbb{E}_\theta[\delta(X)] = g(\theta)$ para todo θ.

Paso 1: Derivada de la esperanza. Diferenciamos ambos lados de la ecuación de insesgadez:

$$g'(\theta) = \frac{\mathrm{d}}{\mathrm{d}\theta}\mathbb{E}_\theta[\delta(X)] = \frac{\mathrm{d}}{\mathrm{d}\theta}\int \delta(x)p_\theta(x)\,\mathrm{d}x$$

Bajo condiciones de regularidad que permiten diferenciar bajo el signo integral:

$$g'(\theta) = \int \delta(x)\frac{\partial p_\theta(x)}{\partial\theta}\,\mathrm{d}x = \int \delta(x)\frac{\partial \log p_\theta(x)}{\partial\theta}p_\theta(x)\,\mathrm{d}x$$

Esto es la covarianza entre $\delta(X)$ y el score $S_\theta(X) = \frac{\partial \log p_\theta(X)}{\partial \theta}$:

$$g'(\theta) = \mathrm{Cov}_\theta(\delta(X), S_\theta(X))$$

Paso 2: Aplicación de Cauchy-Schwarz. Por la desigualdad de Cauchy-Schwarz:

$$[\mathrm{Cov}_\theta(\delta(X), S_\theta(X))]^2 \leq \mathrm{Var}_\theta(\delta(X)) \cdot \mathrm{Var}_\theta(S_\theta(X))$$

Paso 3: Varianza del score. La varianza del score es la información de Fisher:

$$\mathrm{Var}_\theta(S_\theta(X)) = \mathbb{E}_\theta\left[\left(\frac{\partial \log p_\theta(X)}{\partial \theta}\right)^2\right] = I(\theta)$$

Paso 4: Cota de Cramér-Rao. Combinando los resultados:

$$[g'(\theta)]^2 \leq \mathrm{Var}_\theta(\delta(X)) \cdot I(\theta)$$

Reorganizando:

$$\mathrm{Var}_\theta(\delta(X)) \geq \frac{[g'(\theta)]^2}{I(\theta)}$$

Condiciones de regularidad: Esta demostración requiere:
1. Diferenciabilidad bajo el signo integral: $\frac{\partial}{\partial \theta} \int \delta(x) p_\theta(x)\, \mathrm{d}x = \int \delta(x) \frac{\partial p_\theta(x)}{\partial \theta}\, \mathrm{d}x$
2. Intercambio de derivada e integral: $\int \frac{\partial p_\theta(x)}{\partial \theta}\, \mathrm{d}x = \frac{\partial}{\partial \theta} \int p_\theta(x)\, \mathrm{d}x = 0$
3. Información de Fisher positiva y finita: $0 < I(\theta) < \infty$
4. Varianza finita del estimador: $\mathrm{Var}_\theta(\delta(X)) < \infty$

Caso con sesgo: Si la media del estimador es $g(\theta) + b(\theta)$ y ambas funciones son diferenciables, el mismo cálculo reemplaza g' por $g' + b'$. Para N ensayos Bernoulli independientes con N fijo conocido, la proporción tiene varianza $\frac{\theta(1-\theta)}{N}$ y alcanza la cota en el interior. Con conteos de visitas aleatorios de una cadena, este experimento no está dado: hacen falta la información de la trayectoria y condiciones propias; no se concluye automáticamente que un cociente de conteos sea UMVUE.

□

A.3.4 Propiedades asintóticas del MLE

Consistencia y normalidad bajo condiciones explícitas. Sea P_{θ_0} la ley verdadera y $M(\theta) = \mathbb{E}_{\theta_0}\left[\log p_{\theta(X)}\right]$. Suponga una ley uniforme de grandes números para $n^{-1}\ell_n$, un máximo poblacional separado en θ_0 y un maximizador aproximado $\hat{\theta}$ con error $o_{P(1)}$ en el criterio normalizado. Para cada $\varepsilon > 0$, la separación significa

$$M(\theta_0) - \sup_{\|\theta - \theta_0\| \geq \varepsilon} M(\theta) > 0.$$

La convergencia uniforme implica que el máximo muestral no puede estar fuera de ese entorno con probabilidad que no tienda a cero. Así $\hat{\theta} \xrightarrow{P} \theta_0$. En un modelo correctamente especificado,

$$M(\theta_0) - M(\theta) = \mathrm{KL}\big(P_{\theta_0} \| P_\theta\big) \geq 0.$$

La esperanza siempre se toma bajo la ley verdadera. Identificabilidad da unicidad cuando las esperanzas están definidas, pero la convergencia puntual de verosimilitudes no basta para consistencia. Para normalidad, suponga θ_0 interior, score centrado con segundo momento y matriz I positiva definida, ecuación de score satisfecha por $\hat{\theta}$, y convergencia uniforme del Hessiano normalizado a $-I$ en un entorno del verdadero parámetro. Taylor en forma integral da

$$0 = n^{-\frac{1}{2}} \nabla \ell_{n(\theta_0)} + A_n \sqrt{n}\big(\hat{\theta} - \theta_0\big),$$

$$A_n = \int_0^1 n^{-1} \nabla^2 \ell_{n\left(\theta_0 + u\left(\hat{\theta} - \theta_0\right)\right)} \, \mathrm{d}u \xrightarrow{P} -I.$$

El CLT iid del score y Slutsky producen $\sqrt{n}\big(\hat{\theta} - \theta_0\big) \xrightarrow{d} N(0, I^{-1})$. Las condiciones de derivación justifican la identidad de información. En una trayectoria dependiente hay que probar otra ley uniforme y otro CLT; esta demostración iid no los proporciona. □

Contrastes e interpretación del error

El paso de una distribución de datos a una decisión de contraste exige controlar el error declarado. Las pruebas siguientes acompañan la discusión de potencia, multiplicidad y aproximaciones del Capítulo 4.

A.4.1 Lema de Neyman–Pearson e inversión de tests

Demostración del lema de Neyman–Pearson. Con densidades p_0, p_1 respecto de una medida común, tome $\Lambda = \frac{p_1}{p_0}$ donde $p_0 > 0$, $\Lambda = \infty$ donde $p_0 = 0 < p_1$ y una versión arbitraria donde ambas son cero. Elija un cuantil $k \geq 0$ tal que $P_0(\Lambda > k) \leq \alpha \leq P_0(\Lambda \geq k)$. Aleatorice en la igualdad para obtener tamaño exacto α. La distribución puede tener átomos; no se exige continuidad ni se usa el teorema del valor intermedio. La regla φ^* que rechaza para $p_1 > kp_0$ satisface, para cualquier test φ,

$$(\varphi^* - \varphi)(p_1 - kp_0) \geq 0.$$

Integrar da $\mathbb{E}_1[\varphi^* - \varphi] \geq k\mathbb{E}_0[\varphi^* - \varphi] \geq 0$ si $\mathbb{E}_0[\varphi] \leq \alpha$. Este argumento incluye el soporte donde $p_0 = 0$. Para la inversión, un test no aleatorizado φ_θ de nivel α define $C(X) = \big\{\theta : \varphi_{\theta(X)} = 0\big\}$, y $P_{\theta(\theta \in C)} = 1 - \mathbb{E}_{\theta[\varphi_\theta]} \geq 1 - \alpha$. El conjunto puede ser disconexo. Con aleatorización se incorpora una variable uniforme auxiliar independiente y se invierten los tests realizados con ella. Los resultados UMP, UMPU y Bonferroni tienen condiciones y argumentos propios, desarrollados en el Capítulo 4; el lema simple contra simple no demuestra por sí solo todos esos resultados. □

A.4.2 Procedimiento de Benjamini–Hochberg

Control FDR bajo independencia. Sea R el número de rechazos BH y I_0 el conjunto de nulas verdaderas. Suponga que cada p_i, $i \in I_0$, es superuniforme y es independiente de los otros p-valores. Defina R_i^0 como el número de rechazos al reemplazar p_i por cero. Entonces $R_i^0 \geq 1$ y depende solo de los otros p-valores. La propiedad step-up da

$$\{i \ \text{ rechazado}, R = r\} = \Big\{p_i \leq \alpha \frac{r}{m}, R_i^0 = r\Big\}.$$

En efecto, reemplazar por cero un p-valor ya rechazado no altera el total, y si el reemplazado permite r rechazos, devolver un valor menor que el umbral $\alpha \frac{r}{m}$ conserva ese total. Por independencia,

$$\mathbb{E}\left[\frac{\mathbb{1}_{i \ \text{rechazado}}}{\max(R, 1)}\right] = \sum_{r=1}^{m} \frac{1}{r} P\Big(p_i \leq \alpha \frac{r}{m}\Big) P(R_i^0 = r) \leq \frac{\alpha}{m}.$$

Sumar sobre I_0 da $\mathrm{FDR} \leq m_0 \frac{\alpha}{m} \leq \alpha$. No se divide por cero. Con nulas uniformes la primera cota es igualdad. La extensión a PRDS sobre las nulas verdaderas requiere otro argumento: véase (Benjamini & Yekutieli, 2001), no el artículo de independencia de 1995. □

A.4.3 Distribución asintótica del LRT: Wilks

Esquema para restricciones regulares. Considere un modelo paramétrico regular de dimensión d, parámetro verdadero interior e información I positiva definida. Bajo la nula $g(\theta) = 0$, suponga que g es continuamente diferenciable y su Jacobiano tiene rango r. Se requieren la expansión cuadrática local uniforme de la log-verosimilitud y consistencia/localización de los máximos libre y restringido. En coordenadas blanqueadas por $I^{\frac{1}{2}}$, el score normalizado converge a $Z \sim N(0, I_d)$ y la nula tiene espacio tangente L de dimensión $d - r$. Maximizar la forma cuadrática libre y sobre L da

$$2\Big(\ell_{n(\hat{\theta})} - \ell_{n(\hat{\theta}_0)}\Big) = \|Z_n - \Pi_L Z_n\|^2 + o_{P(1)} \xrightarrow{d} \chi^2(r).$$

La diferencia de los máximos corresponde al complemento ortogonal del tangente nulo, de dimensión r, no al propio tangente. Fronteras, singularidades o falta de identificación pueden cambiar el límite. Este resultado es distinto del lema de Neyman–Pearson. Véase (van der Vaart, 1998), capítulo 16. □

Aproximaciones y remuestreo

Para utilizar una distribución límite hay que seguir la escala del error y el funcional que se estima. El teorema central del límite, el método delta y el remuestreo permiten examinar esas relaciones.

A.5.1 CLT de Lindeberg-Lévy

Demostración completa del Teorema 4.102. Sea $X_1, X_2, ..., X_n$ variables aleatorias i.i.d. con $\mathbb{E}[X_i] = \mu$ y $0 < \mathrm{Var}(X_i) = \sigma^2 < \infty$. Definimos $S_n = \sum_{i=1}^{n} X_i$ y consideramos la variable estandarizada:

$$Z_n = \frac{S_n - n\mu}{\sigma\sqrt{n}} = \frac{1}{\sqrt{n}} \sum_{i=1}^{n} \frac{X_i - \mu}{\sigma}$$

Paso 1: Función característica. Sea $\phi_X(t)$ la función característica de X_i. La función característica de Z_n es:

$$\phi_{Z_n}(t) = \left[\phi_X\left(\frac{t}{\sigma\sqrt{n}}\right)\right]^n e^{-it\sqrt{n}\mu/\sigma}$$

Paso 2: Expansión de Taylor. Expandimos ϕ_X alrededor de 0:

$$\phi_X(s) = 1 + is\mathbb{E}[X] - \frac{s^2}{2}\mathbb{E}[X^2] + o(s^2)$$

Para $s = t/(\sigma\sqrt{n})$:

$$\phi_X\left(\frac{t}{\sigma\sqrt{n}}\right) = 1 + i\frac{t}{\sigma\sqrt{n}}\mu - \frac{t^2}{2n\sigma^2}(\mu^2 + \sigma^2) + o\left(\frac{t^2}{n}\right)$$

Paso 3: Combinar términos. Multiplicando por el factor de normalización:

$$\phi_X\left(\frac{t}{\sigma\sqrt{n}}\right)e^{-it\mu/(\sigma\sqrt{n})} = 1 - \frac{t^2}{2n} + o\left(\frac{t^2}{n}\right)$$

Paso 4: Límite cuando $n \to \infty$.

$$\phi_{Z_n}(t) = \left[1 - \frac{t^2}{2n} + o\left(\frac{t^2}{n}\right)\right]^n \to e^{-t^2/2}$$

por el límite $\lim_{n\to\infty}(1 + a_n/n)^n = e^a$ cuando $a_n \to a$.

Paso 5: Conclusión. La función característica límite $e^{-t^2/2}$ corresponde a la distribución normal estándar $\mathcal{N}(0,1)$. Por el teorema de continuidad de Lévy, esto implica:

$$Z_n \xrightarrow{d} \mathcal{N}(0,1)$$

o equivalentemente:

$$\frac{S_n - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} \mathcal{N}(0,1)$$

Condiciones de regularidad: Esta demostración requiere:
1. Las variables X_i son i.i.d.
2. $\mathbb{E}[X_i] = \mu$ existe (esperanza finita)
3. $0 < \text{Var}(X_i) = \sigma^2 < \infty$ (varianza finita)
4. La función característica $\phi_X(t)$ existe y es dos veces diferenciable en 0

Aplicación al contexto MDP (SSCH): En el Sistema de Soporte Clínico para Hipertensión, el CLT permite aproximar la distribución del número de pacientes que mejoran su presión arterial en n pacientes independientes con una medición por paciente. Si X_i indica si el paciente i mejoró (1) o no (0), entonces $S_n = \sum_{i=1}^n X_i$ sigue aproximadamente una distribución normal $\mathcal{N}(n\mu, n\sigma^2)$ para n grande, donde μ es la probabilidad de mejora y $\sigma^2 = \mu(1-\mu)$. Esto permite construir intervalos de confianza para la efectividad de un tratamiento y realizar pruebas de hipótesis sobre si un tratamiento es significativamente mejor que otro. □

A.5.2 Método delta

Demostración completa del Teorema 4.106. Sea $X_1, X_2, ..., X_n$ variables aleatorias i.i.d. con $\mathbb{E}[X_i] = \mu$ y $0 < \text{Var}(X_i) = \sigma^2 < \infty$. Supongamos que $\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$ por el CLT.

Sea $g : \mathbb{R} \to \mathbb{R}$ una función diferenciable en μ con derivada $g'(\mu) \neq 0$. Queremos encontrar la distribución asintótica de $g(\bar{X}_n)$.

Expansión de Taylor de primer orden: Expandimos g alrededor de μ:

$$g(\bar{X}_n) = g(\mu) + g'(\mu)(\bar{X}_n - \mu) + R_n$$

donde el residuo R_n satisface $R_n = o_P(|\bar{X}_n - \mu|)$.

Reorganización:

$$g(\bar{X}_n) - g(\mu) = g'(\mu)(\bar{X}_n - \mu) + R_n$$

Multiplicación por $\sqrt{n}$:

$$\sqrt{n}(g(\bar{X}_n) - g(\mu)) = g'(\mu)\sqrt{n}(\bar{X}_n - \mu) + \sqrt{n}R_n$$

Análisis del residuo: Como $\bar{X}_n \xrightarrow{P} \mu$ por la ley de los grandes números, tenemos:

$$\sqrt{n}R_n = \sqrt{n} \cdot o_P(|\bar{X}_n - \mu|) = o_P(\sqrt{n}|\bar{X}_n - \mu|) = o_P(1)$$

porque $\sqrt{n}(\bar{X}_n - \mu)$ converge en distribución (y por tanto es acotado en probabilidad).

Aplicación del teorema de Slutsky: Por el teorema de Slutsky, si $A_n \xrightarrow{d} A$ y $B_n \xrightarrow{P} 0$, entonces $A_n + B_n \xrightarrow{d} A$. Por tanto:

$$\sqrt{n}\big(g\big(\bar{X}_n\big) - g(\mu)\big) \xrightarrow{d} g'(\mu) \cdot \mathcal{N}(0, \sigma^2) = \mathcal{N}\Big(0, [g'(\mu)]^2 \sigma^2\Big)$$

Caso multivariado: Para $\boldsymbol{X}_n \in \mathbb{R}^k$ con $\sqrt{n}\big(\bar{\boldsymbol{X}}_n - \boldsymbol{\mu}\big) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma})$ y $g : \mathbb{R}^k \to \mathbb{R}$ diferenciable en $\boldsymbol{\mu}$ con gradiente $\nabla g(\boldsymbol{\mu}) \neq \mathbf{0}$:

$$\sqrt{n}\big(g\big(\bar{\boldsymbol{X}}_n\big) - g(\boldsymbol{\mu})\big) \xrightarrow{d} \mathcal{N}(0, \nabla g(\boldsymbol{\mu})^\top \boldsymbol{\Sigma} \nabla g(\boldsymbol{\mu}))$$

Condiciones de regularidad: Esta demostración requiere:
1. $\sqrt{n}\big(\bar{X}_n - \mu\big)$ converge en distribución a una normal
2. g es diferenciable en μ (o $\boldsymbol{\mu}$ en el caso multivariado)
3. $g'(\mu) \neq 0$ (o $\nabla g(\boldsymbol{\mu}) \neq \mathbf{0}$)
4. El residuo de Taylor es $o_P\big(|\bar{X}_n - \mu|\big)$

Aplicación al contexto MDP (SSCH): En el Sistema de Soporte Clínico para Hipertensión, el método delta permite derivar la distribución asintótica de transformaciones no lineales de estimadores. Por ejemplo, si estimamos la probabilidad de transición $\hat{\theta}_{ij} = N_{ij}/N_i$, entonces el log-odds $\log\Big(\hat{\theta}_{ij}/\Big(1 - \hat{\theta}_{ij}\Big)\Big)$ tiene distribución asintótica normal con varianza $\big[g'\big(\theta_{ij}\big)\big]^2 \cdot \frac{\theta_{ij}\big(1-\theta_{ij}\big)}{N_i}$, donde $g(\theta) = \log(\theta/(1-\theta))$ y $g'(\theta) = 1/[\theta(1-\theta)]$. Esto es útil para construir intervalos de confianza en la escala de log-odds, bajo un experimento binomial de tamaño fijo y parámetro interior. No se deduce una mejora universal de cobertura ni se transfiere la fórmula a visitas dependientes sin otro CLT. □

A.5.3 Consistencia del bootstrap para la media

Demostración del Teorema 4.116. Suponga datos iid con $0 < \sigma^2 = \mathrm{Var}(X) < \infty$. Condicionalmente a la muestra, las variables bootstrap son iid dentro de cada fila, pero su distribución cambia con n. Se necesita el CLT de un arreglo triangular condicional. La varianza empírica $s_n^2 = n^{-1} \sum_{i\big(X_i - \overline{X}\big)}^2$ converge a σ^2. La condición de Lindeberg es

$$\frac{1}{n} \sum_i \left(X_i - \overline{X}\right)^2 \mathbb{1}_{|X_i - \overline{X}| > \varepsilon\sqrt{n}} \xrightarrow{P} 0.$$

Para comprobarla, use $\overline{X} = O_{P(1)}$ y compare el umbral con $\varepsilon\frac{\sqrt{n}}{2}$. El término de cola de X_i^2 tiene esperanza $\mathbb{E}\Big[X^2 \mathbb{1}_{|X| > \varepsilon\frac{\sqrt{n}}{2}}\Big]$, que tiende a cero por integrabilidad. El término de centrado también desaparece. El CLT condicional da la convergencia débil en probabilidad a $N\big(0, \sigma^2\big)$. La continuidad de la distribución límite convierte la convergencia de funciones de distribución en uniforme; combinada con el CLT original, justifica la aproximación bootstrap. Si $\sigma^2 = 0$, las observaciones son constantes casi seguramente y ambas fluctuaciones son cero. Para studentizar se exige $\sigma^2 > 0$. Varianza finita no proporciona una tasa $O_{P\left(n^{-\frac{1}{2}}\right)}$ de la varianza empírica ni refinamientos de cobertura; esos resultados requieren otras hipótesis. □

Funciones de influencia y modelos auxiliares

La identidad de centrado y la cota de eficiencia responden a preguntas distintas. Los argumentos semiparamétricos permiten localizar qué papel desempeñan las funciones auxiliares en cada una.

A.6.1 Doble robustez y expansión con cross-fitting

Demostración de la identidad AIPW y del caso suficiente DML. Con la notación del Teorema 4.145, condicionar en X da

$$\mathbb{E}[D|X] = \overline{m}_1 - \overline{m}_0 + \frac{e}{\overline{e}}(m_1 - \overline{m}_1) - \frac{1-e}{1-\overline{e}}(m_0 - \overline{m}_0).$$

Restar $m_1 - m_0$ y agrupar produce

$$\mathbb{E}[D] - \psi_0 = \mathbb{E}\left[(\overline{e} - e)\left(\frac{\overline{m}_1 - m_1}{\overline{e}} + \frac{\overline{m}_0 - m_0}{1-\overline{e}}\right)\right].$$

Para DML, escriba $D_0 = \psi_0 + \varphi_{\text{eff}}$ y sea P_k la media del fold k, de tamaño n_k. La descomposición exacta es

$$\hat{\psi} - \psi_0 = (P_n - P)D_0 + \sum_k \frac{n_k}{n}\left((P_k - P)\left(\hat{D}_k - D_0\right) + P\left(\hat{D}_k - D_0\right)\right).$$

Condicional al entrenamiento del fold, la varianza del término empírico centrado es a lo sumo $\frac{\left\|\hat{D}_k - D_0\right\|_2^2}{n_k}$. Acotación, positividad y consistencia de auxiliares implican que esa norma es $o_{P(1)}$. Chebyshev condicional y K fijo dan un término total $o_{P\left(n^{-\frac{1}{2}}\right)}$, sin suponer independencia entre folds. La identidad de sesgo y Cauchy–Schwarz acotan el último término por una constante multiplicada por el producto de errores del Teorema 4.150. Es también $o_{P\left(n^{-\frac{1}{2}}\right)}$. El CLT iid aplicado a φ_{eff} completa la expansión. La misma convergencia cuadrática de los pseudoresultados, junto con la ley de grandes números, justifica su varianza empírica consistente. □

A.6.2 Función de influencia eficiente para OPE

Derivación en el modelo Markov de horizonte finito. Usamos exactamente el experimento del Teorema 4.146: episodios iid, H fijo, kernels libres por tiempo y ley inicial desconocida. Defina $\varepsilon_t = R_t + \gamma v_{t+1}(S_{t+1}) - q_{t(S_t,A_t)}$. Entonces

$$\varphi_{\text{eff}} = v_0(S_0) - J + \sum_{t=0}^{H-1} \gamma^t w_{t(S_t,A_t)} \varepsilon_t.$$

El score de cualquier submodelo se descompone en un componente inicial, scores de asignación y scores de los kernels de recompensa/transición. Cada componente tiene media condicional cero. Derivar el retorno esperado da, para el componente inicial, el producto interno con $v_0 - J$; para el kernel del tiempo t, da el producto interno con $\gamma^t w_t \varepsilon_t$, por cambio de la ocupación objetivo a la observada. La derivada respecto de la política de comportamiento es cero. Los términos cruzados se anulan por condicionamiento temporal. Así, $\mathbb{E}[\varphi_{\text{eff}} s]$ representa la derivada para todo score s. Cada sumando pertenece al espacio tangente de su kernel y el inicial al de la ley inicial. La función pertenece al espacio tangente completo y es, por ello, el gradiente canónico. Esta identificación usa la libertad de los kernels por tiempo; imponer homogeneidad cambia el espacio tangente. Véase (Kallus & Uehara, 2020). Para el estimador aumentado, si todas las q_t son correctas, los residuos tienen media condicional cero para cualquier peso candidato integrable. Si todos los w_t son correctos, el cambio de medida transforma la esperanza del residuo candidato en

$$\mathbb{E}_{\pi}\left[R_t + \gamma \overline{v}_{t+1}(S_{t+1}) - \overline{v}_{t(S_t)}\right].$$

La suma descontada cancela los términos de valor, incluido el inicial, y $\overline{v}_H = 0$ deja J. Esta prueba es poblacional para candidatos fijos; la eficiencia de ajustes estimados exige además controlar sus errores. □

A.6.3 Cota semiparamétrica de varianza

Demostración del Teorema 4.140. Sea $\mathcal{T}$ el espacio tangente cerrado en $L_0^2(P)$. Toda IF φ de un estimador regular asintóticamente lineal representa las mismas derivadas: $\mathbb{E}[\varphi s] = \dot{\psi}(s)$ para cada score s. El gradiente canónico φ_{eff} satisface esas identidades y pertenece a $\mathcal{T}$. Por densidad, $h = \varphi - \varphi_{\text{eff}}$ es ortogonal a $\mathcal{T}$. Por Pitágoras,

$$\mathbb{E}[\varphi^2] = \mathbb{E}[\varphi_{\text{eff}}^2] + \mathbb{E}[h^2] \geq \mathbb{E}[\varphi_{\text{eff}}^2].$$

Hay igualdad si y solo si $h = 0$ en $L^2(P)$. El argumento establece una cota; construir un estimador que la alcance requiere una expansión con resto despreciable. □

Decisión de Wald

Los criterios del Capítulo 2 comparan riesgos dentro de una clase de reglas. Las demostraciones de esta sección se refieren al modelo y al criterio que declara cada resultado.

A.7.1 Identidad de riesgo de James–Stein

Demostración de la identidad de riesgo de James–Stein. Escriba $\delta_{\text{JS}}(x) = x + g(x)$, donde $g(x) = -(p-2)\frac{x}{\|x\|^2}$ para $x \neq 0$. Para $X \sim N_{p(\theta, I_p)}$, la identidad de Stein para el riesgo cuadrático da

$$R(\theta, \delta_{\text{JS}}) = p + \mathbb{E}_{\theta[\|g(X)\|^2 + 2 \div g(X)]}.$$

Para $x \neq 0$, $\|g(x)\|^2 = \frac{(p-2)^2}{\|x\|^2}$ y $\div g(x) = -(p-2)\frac{p-2}{\|x\|^2}$, pues $\div \left(\frac{x}{\|x\|^2}\right) = \frac{p-2}{\|x\|^2}$. Por tanto,

$$R(\theta, \delta_{\text{JS}}) = p - (p-2)^2 \mathbb{E}_{\theta\left[\frac{1}{\|X\|^2}\right]}.$$

La esperanza es finita para $p \geq 3$. Como el término que se resta es positivo, el riesgo es estrictamente menor que el riesgo p de $\delta_0(X) = X$. □

A.7.2 Existencia de reglas de Bayes con acciones finitas

Demostración del Teorema 2.9. Bajo las condiciones del capítulo, cada pérdida posterior $\ell_{\nu(x,a)}$ es medible y finita. Enumere las acciones y elija el primer índice que alcanza el mínimo. Su región de selección es una intersección finita de comparaciones entre funciones medibles, así que la regla es medible. La esperanza iterada escribe el riesgo de cualquier regla aleatorizada como la esperanza de una combinación convexa de pérdidas posteriores. Cada combinación es mayor o igual que $\min_a \ell_{\nu(X,a)}$. La regla construida alcanza esa cota. Si otra regla alcanza el mismo riesgo, la diferencia no negativa tiene esperanza cero y debe anularse casi seguramente, por lo que solo asigna masa a minimizadores salvo conjuntos predictivamente nulos. Para acciones compactas o no compactas se requieren hipótesis adicionales de existencia y selección medible. Continuidad puntual de la pérdida no justifica por sí sola intercambiar límite e integral ni seleccionar un argmin medible. Aquí no se afirma esa extensión. □

A.7.3 Conexión Bayes-Minimax

Demostración completa del Teorema 2.14. Sea $\mathcal{D} = (\Theta, \mathcal{A}, \mathcal{X}, L)$ un problema de decisión. El riesgo minimax es:

$$\inf_{\delta} \sup_{\theta \in \Theta} R(\theta, \delta)$$

y el riesgo Bayesiano bajo un a priori π es:

$$r(\pi, \delta) = \int_{\Theta} R(\theta, \delta) \, \mathrm{d}\pi(\theta)$$

Teorema de conexión Bayes-Minimax: Si existe una regla de Bayes δ^{π} bajo algún a priori π tal que su riesgo es constante, es decir, $R(\theta, \delta^{\pi}) = c$ para todo $\theta \in \Theta$, entonces δ^{π} es una regla minimax.

Demostración:

Paso 1: Riesgo minimax $\leq$ riesgo constante.

$$\inf_{\delta} \sup_{\theta} R(\theta, \delta) \leq \sup_{\theta} R(\theta, \delta^{\pi}) = c$$

Paso 2: Riesgo Bayesiano $\leq$ riesgo minimax. Para cualquier regla δ:

$$r(\pi, \delta) = \int R(\theta, \delta) \, \mathrm{d}\pi(\theta) \leq \int \sup_{\theta'} R(\theta', \delta) \, \mathrm{d}\pi(\theta) = \sup_{\theta'} R(\theta', \delta)$$

Tomando el mínimo sobre todas las reglas:

$$\inf_{\delta} r(\pi, \delta) \leq \inf_{\delta} \sup_{\theta'} R(\theta', \delta)$$

Paso 3: Riesgo Bayesiano de δ^{π}. Como δ^{π} es una regla de Bayes:

$$r(\pi, \delta^{\pi}) = \inf_{\delta} r(\pi, \delta)$$

Paso 4: Igualdad de riesgos. Como $R(\theta, \delta^{\pi}) = c$ para todo θ:

$$r(\pi, \delta^{\pi}) = \int R(\theta, \delta^{\pi}) \, \mathrm{d}\pi(\theta) = \int c \, \mathrm{d}\pi(\theta) = c$$

Paso 5: Conclusión. Combinando los resultados:

$$c = r(\pi, \delta^{\pi}) = \inf_{\delta} r(\pi, \delta) \leq \inf_{\delta} \sup_{\theta'} R(\theta', \delta) \leq c$$

Por tanto:

$$\inf_{\delta} \sup_{\theta'} R(\theta', \delta) = c = \sup_{\theta} R(\theta, \delta^{\pi})$$

Lo que significa que δ^{π} es una regla minimax.

Condiciones de regularidad: Esta demostración requiere:
1. Existe un a priori π con soporte en Θ
2. Existe una regla de Bayes δ^{π} bajo π
3. El riesgo $R(\theta, \delta^{\pi})$ es constante en θ
4. Los riesgos están bien definidos y las integrales convergen

Aplicación al contexto MDP (SSCH): En el Sistema de Soporte Clínico para Hipertensión, este teorema permite encontrar políticas de tratamiento minimax (que minimizan el peor caso) buscando políticas Bayesianas con riesgo constante. Por ejemplo, si construimos un a priori π sobre la distribución de presión arterial y encontramos una política δ^{π} que tiene el mismo riesgo clínico para todos los posibles valores verdaderos de la presión arterial, entonces esta política es minimax. Esto

Propiedad Intelectual UCI-VII

es importante en medicina porque garantiza protección contra el peor escenario clínico, lo cual es crucial para la seguridad del paciente. □

A.7.4 Clase esencialmente completa en el problema finito

Demostración del Teorema 2.12. Con parámetros, datos y acciones finitos, las reglas aleatorizadas forman un producto finito de simplex compactos. El mapa que envía una regla a su vector de riesgos es lineal y continuo. Su imagen $C \subset \mathbb{R}^d$ es por tanto compacta y convexa. Sea $r \in C$ un riesgo admisible. El conjunto convexo abierto $U = \{u : u_j < r_j \text{ para todo } j\}$ es disjunto de C. Separación convexa proporciona $w \neq 0$ y $w^T c \geq w^T u$ para todo $c \in C, u \in U$. Como U es ilimitado hacia abajo en cada coordenada, necesariamente $w_j \geq 0$. Tomando u hacia r se obtiene $w^T c \geq w^T r$. Normalizar por $\sum_j w_j > 0$ produce un prior para el que r minimiza el riesgo de Bayes. Para cualquier $r_0 \in C$, minimice $\sum_j r_j$ sobre el compacto no vacío $C \cap \{r : r \leq r_0\}$. Un minimizador r_* no puede ser dominado: una mejora estricta en alguna coordenada disminuiría la suma sin salir del conjunto. Es admisible y, por el párrafo anterior, Bayes; además $r_* \leq r_0$. Esto demuestra la completitud esencial. El prior obtenido puede tener ceros. Mejor riesgo promedio bajo un prior no implica dominancia coordenada a coordenada; la prueba usa separación y compactitud, no esa implicación falsa. □

Programación dinámica

La contracción permite pasar de las ecuaciones de Bellman a un procedimiento de cálculo. Los argumentos de esta sección acompañan la planificación con modelo conocido del Capítulo 3.

A.8.1 Ecuación de Bellman de expectación

Demostración completa del Nota 3.27. Sea π una política estacionaria y $G_t = \sum_{k=0}^{\infty} \gamma^k R_{t+k}$ el retorno desde el tiempo t.

Paso 1: Definición de la función de valor.

$$V^\pi(s) = \mathbb{E}^\pi[G_t \mid S_t = s]$$

Paso 2: Descomposición del retorno.

$$G_t = R_t + \gamma R_{t+1} + \gamma^2 R_{t+2} + \cdots = R_t + \gamma G_{t+1}$$

Paso 3: Aplicación de la ley de esperanzas iteradas.

$$\begin{aligned} V^\pi(s) &= \mathbb{E}^\pi[G_t \mid S_t = s] \\ &= \mathbb{E}^\pi[R_t + \gamma G_{t+1} \mid S_t = s] \\ &= \mathbb{E}^\pi[R_t \mid S_t = s] + \gamma \mathbb{E}^\pi[G_{t+1} \mid S_t = s] \end{aligned}$$

Paso 4: Condicional sobre la acción. Por la ley de la probabilidad total:

$$\mathbb{E}^\pi[R_t \mid S_t = s] = \sum_{a \in \mathcal{A}} \pi(a|s) \mathbb{E}^\pi[R_t \mid S_t = s, A_t = a]$$

Por la propiedad de Markov, $\mathbb{E}^\pi[R_t \mid S_t = s, A_t = a] = r(s,a)$, por lo que:

$$\mathbb{E}^\pi[R_t \mid S_t = s] = \sum_{a \in \mathcal{A}} \pi(a|s) r(s,a)$$

Paso 5: Condicional sobre el siguiente estado.

$$\begin{aligned}\mathbb{E}^\pi\big[G_{t+1} \mid S_t = s\big] &= \mathbb{E}^\pi\big[\mathbb{E}^\pi\big[G_{t+1} \mid S_{t+1}\big] \,\big|\, S_t = s\big] \\ &= \mathbb{E}^\pi\big[V^\pi(S_{t+1}) \,\big|\, S_t = s\big]\end{aligned}$$

Condicional sobre la acción:

$$\begin{aligned}\mathbb{E}^\pi\big[V^\pi(S_{t+1}) \mid S_t = s\big] &= \sum_{a\in\mathcal{A}} \pi(a|s)\mathbb{E}^\pi\big[V^\pi(S_{t+1}) \mid S_t = s, A_t = a\big] \\ &= \sum_{a\in\mathcal{A}} \pi(a|s) \sum_{s'\in\mathcal{S}} P(s'|s,a)V^\pi(s')\end{aligned}$$

Paso 6: Combinación de resultados.

$$\begin{aligned}V^\pi(s) &= \sum_{a\in\mathcal{A}} \pi(a|s)r(s,a) + \gamma \sum_{a\in\mathcal{A}} \pi(a|s) \sum_{s'\in\mathcal{S}} P(s'|s,a)V^\pi(s') \\ &= \sum_{a\in\mathcal{A}} \pi(a|s)\left[r(s,a) + \gamma \sum_{s'\in\mathcal{S}} P(s'|s,a)V^\pi(s')\right]\end{aligned}$$

Condiciones de regularidad: Esta demostración requiere:
1. Espacio de estados $\mathcal{S}$ finito o numerable
2. Espacio de acciones $\mathcal{A}$ finito
3. Factor de descuento $\gamma \in [0, 1)$
4. Recompensas acotadas: $|r(s,a)| \le R_{\max}$ para todo (s,a)
5. Kernel de transición válido: $P(s'|s,a) \ge 0$, $\sum_{s'} P(s'|s,a) = 1$
6. Propiedad de Markov: $P(S_{t+1}, R_t \mid S_t, A_t, H_{t-1}) = P(S_{t+1}, R_t \mid S_t, A_t)$

Aplicación al contexto MDP (SSCH): En el Sistema de Soporte Clínico para Hipertensión, la ecuación de Bellman de expectación permite calcular el valor esperado a largo plazo de seguir una política de tratamiento π desde un estado de salud s. Por ejemplo, si s representa «presión arterial alta», entonces $V^\pi(s)$ es el beneficio esperado acumulado de seguir la política π a partir de ese estado. La ecuación descompone este valor en el beneficio inmediato de la acción elegida $r(s,a)$ más el beneficio descontado esperado del siguiente estado de salud $\gamma \sum_{s'} P(s'|s,a)V^\pi(s')$. Esta recursión es fundamental para algoritmos como Policy Iteration y Value Iteration que encuentran políticas óptimas en la práctica clínica. □

A.8.2 Contracción del operador de Bellman

Demostración completa del Teorema 3.12. Sea $\mathcal{T} : \mathcal{V} \to \mathcal{V}$ el operador de Bellman definido como:

$$(\mathcal{T}V)(s) = \max_{a\in\mathcal{A}} \left\{ r(s,a) + \gamma \sum_{s'\in\mathcal{S}} P(s'|s,a)V(s') \right\}$$

donde $\mathcal{V}$ es el espacio de funciones acotadas $V : \mathcal{S} \to \mathbb{R}$ con la norma ℓ_∞:

$$\|V\|_\infty = \sup_{s\in\mathcal{S}} |V(s)|$$

Demostración de contracción: Para cualesquiera funciones $V, W \in \mathcal{V}$, consideramos:

$$\|\mathcal{T}V - \mathcal{T}W\|_\infty = \sup_{s\in\mathcal{S}} |(\mathcal{T}V)(s) - (\mathcal{T}W)(s)|$$

Para un estado s fijo, sea a^* la acción que maximiza $(\mathcal{T}V)(s)$. Entonces:

$$(\mathcal{T}V)(s) - (\mathcal{T}W)(s) \leq \left[r(s,a^*) + \gamma \sum_{s'} P(s'|s,a^*)V(s')\right] - \left[r(s,a^*) + \gamma \sum_{s'} P(s'|s,a^*)W(s')\right]$$
$$= \gamma \sum_{s'} P(s'|s,a^*)(V(s') - W(s'))$$

Repitiendo la desigualdad con V y W intercambiados se acotan ambos signos. Usando que $P(s'|s,a^*) \geq 0$ y $\sum_{s'} P(s'|s,a^*) = 1$:

$$|(\mathcal{T}V)(s) - (\mathcal{T}W)(s)| \leq \gamma \|V - W\|_\infty$$

Como esto vale para todo s, tenemos:

$$\|\mathcal{T}V - \mathcal{T}W\|_\infty \leq \gamma \|V - W\|_\infty$$

Por tanto, $\mathcal{T}$ es una contracción con factor $\gamma \in [0, 1)$.

Condiciones de regularidad: Esta demostración requiere:
1. Espacio de estados $\mathcal{S}$ finito o numerable
2. Espacio de acciones $\mathcal{A}$ finito
3. Factor de descuento $\gamma \in [0, 1)$
4. Recompensas acotadas: $|r(s,a)| \leq R_{\max}$ para todo (s,a)
5. Kernel de transición válido: $P(s'|s,a) \geq 0$, $\sum_{s'} P(s'|s,a) = 1$

Aplicación al contexto MDP (SSCH): En el Sistema de Soporte Clínico para Hipertensión, esta propiedad de contracción garantiza que el algoritmo de Value Iteration converge a la función de valor óptima V^* independientemente de la inicialización. Con un factor de descuento $\gamma = 0.95$ (típico en decisiones médicas a largo plazo), el error se reduce geométricamente en cada iteración, lo que permite obtener políticas de tratamiento óptimas en tiempo computacional razonable. La contracción asegura unicidad del valor óptimo; distintas políticas pueden alcanzarlo cuando hay empates. □

A.8.3 Existencia y unicidad de V^*

Demostración completa del Teorema 3.10. Sea $\mathcal{V}$ el espacio de funciones acotadas $V : \mathcal{S} \to \mathbb{R}$ con la norma ℓ_∞:

$$\|V\|_\infty = \sup_{s \in \mathcal{S}} |V(s)|$$

Paso 1: $\mathcal{V}$ es un espacio métrico completo. El espacio $(\mathcal{V}, \|\cdot\|_\infty)$ es completo porque toda sucesión de Cauchy de funciones acotadas converge uniformemente a una función acotada.

Paso 2: $\mathcal{T}$ es una contracción. Por el Teorema 3.12, el operador de Bellman satisface:

$$\|\mathcal{T}V - \mathcal{T}W\|_\infty \leq \gamma \|V - W\|_\infty$$

para todo $V, W \in \mathcal{V}$, donde $\gamma \in [0, 1)$.

Paso 3: Aplicación del teorema del punto fijo de Banach. Por el teorema del punto fijo de Banach, toda contracción en un espacio métrico completo tiene un único punto fijo. Por tanto, existe una única función $V^* \in \mathcal{V}$ tal que:

$$V^* = \mathcal{T}V^*$$

Paso 4: Interpretación. Esta función V^* es la función de valor óptima:

$$V^*(s) = \max_\pi V^\pi(s)$$

para todo $s \in \mathcal{S}$.

Paso 5: Convergencia de Value Iteration. Además, el teorema de Banach garantiza que para cualquier función inicial $V_0 \in \mathcal{V}$, la sucesión $V_{n+1} = \mathcal{T}V_n$ converge a V^* con tasa geométrica:

$$\|V_n - V^*\|_\infty \leq \gamma^n \|V_0 - V^*\|_\infty$$

Condiciones de regularidad: Esta demostración requiere:
1. Espacio de estados $\mathcal{S}$ finito o numerable
2. Espacio de acciones $\mathcal{A}$ finito
3. Factor de descuento $\gamma \in [0, 1)$
4. Recompensas acotadas: $|r(s, a)| \leq R_{\max}$ para todo (s, a)
5. Kernel de transición válido: $P(s'|s, a) \geq 0$, $\sum_{s'} P(s'|s, a) = 1$

Aplicación al contexto MDP (SSCH): En el Sistema de Soporte Clínico para Hipertensión, este teorema garantiza que existe una única función de valor óptima V^* que representa el beneficio esperado a largo plazo de seguir la política de tratamiento óptima desde cada estado de salud. La unicidad concierne al valor. Una política greedy respecto del punto fijo lo alcanza, pues su operador tiene ese mismo punto fijo. Pueden existir varias políticas óptimas. La cota geométrica determina el número de iteraciones a partir de la tolerancia y del error inicial; no establece un número universal de iteraciones. □

A.8.4 Cota residual para una política greedy

Demostración del certificado residual de pérdida de política. Sea T^* el operador óptimo, sea T^π el operador de una política π y suponga que π_V es greedy respecto de V, de modo que $T^{\pi_V}V = T^*V$. Escriba $\delta = \|V - V^*\|_\infty$ y $d = \|V^{\pi_V} - V^*\|_\infty$. Por las ecuaciones de punto fijo, la igualdad de greedy y la contracción de ambos operadores,

$$d = \|T^*V^* - T^{\pi_V}V^{\pi_V}\|_\infty \setminus \leq \gamma\delta + \gamma\|V - V^{\pi_V}\|_\infty \setminus \leq \gamma\delta + \gamma(\delta + d).$$

Luego $(1 - \gamma)d \leq 2\gamma\delta$, así que $d \leq 2\gamma\frac{\delta}{1-\gamma}$.

Si $e = \|T^*V - V\|_\infty$, la contracción de T^* también da $\delta \leq e + \gamma\delta$, y por tanto $\delta \leq \frac{e}{1-\gamma}$. Al combinar las cotas,

$$\|V^{\pi_V} - V^*\|_\infty \leq 2\gamma\frac{e}{(1-\gamma)^2}.$$

Estas desigualdades requieren $\gamma \in [0, 1)$ y una política greedy bien definida; la cota de política es cero cuando $\gamma = 0$. □

Representación entre decisiones y políticas

Las correspondencias se leen con el alcance de la representación del Capítulo 5. Es importante conservar qué información utiliza la regla, qué distribución se promedia y dentro de qué clase se comparan los riesgos.

A.9.1 Representación que preserva el riesgo

Demostración del Teorema 5.3. Para cada θ, el estado inicial es $X \sim P_\theta$, la recompensa de la única decisión es $r_{\theta(x,a)} = -L(\theta, a)$ y la transición lleva a un estado terminal de recompensa cero. La política $\pi_{\delta(x)} = \delta(x)$ usa la observación, no el parámetro desconocido. Entonces

$$J_{\theta(\pi_\delta)} = \sum_x P_{\theta(x)} r_{\theta(x,\delta(x))} = -\sum_x P_{\theta(x)} L(\theta, \delta(x)) = -R(\theta, \delta).$$

La correspondencia es biyectiva entre las funciones de decisión y las políticas en los estados de decisión. Las acciones en el estado terminal se identifican por ser irrelevantes. La acotación de la pérdida asegura integrabilidad. No se afirma una equivalencia entre todos los problemas secuenciales y los experimentos de Wald. □

A.9.2 Bayes, minimax y admisibilidad

Demostración. Integrar la identidad anterior con un prior ν da $J_{\nu(\pi_\delta)} = -\rho_{\nu(\delta)}$. Por tanto una regla minimiza el riesgo de Bayes si y solo si su política maximiza ese retorno. Además

$$\inf_\delta \sup_\theta R(\theta, \delta) = -\sup_\pi \inf_\theta J_{\theta(\pi)}.$$

Estas son igualdades de valores y correspondencias entre optimizadores cuando existen; no prueban su existencia ni intercambian inf y sup. Finalmente, una regla que domina a otra tiene riesgo menor o igual en todo θ, con desigualdad estricta en alguno, exactamente cuando su política tiene mayor o igual retorno en todo θ, con desigualdad estricta en alguno. Esto prueba la correspondencia de admisibilidad. Todas las comparaciones usan la misma clase: si se permiten reglas aleatorizadas, también deben permitirse las políticas correspondientes. □

A.9.3 Suficiencia estadística y estado predictivo

Contraejemplo y condición que sí basta. Sea X_1, X_2 iid Bernoulli(θ), con $0 < \theta < 1$. El proceso es Markov, pero el estado actual X_2 no es suficiente para θ en la muestra (X_1, X_2): $P_{\theta(X_1=1|X_2)} = \theta$. Por tanto la propiedad de Markov no implica suficiencia estadística. Para un resumen $Z_t = f_{t(H_t)}$, la condición pertinente para control es que la ley de (R_t, Z_{t+1}) dado (H_t, A_t) dependa solo de (Z_t, A_t), para todas las acciones admisibles. Junto con actualización medible y criterio de recompensa compatible, esta condición permite programación dinámica en Z_t. La suficiencia para un parámetro estático no establece esa propiedad de transición. En el problema bayesiano del Teorema 5.5, el posterior y el horizonte restante sí la satisfacen: la distribución predictiva y la actualización posterior se calculan a partir de ellos. Para $k = 0$ solo se decide y el mínimo es $\min_a \ell(b, a)$. Supuesta la fórmula para $k-1$, cualquier estrategia con k observaciones disponibles debe parar, con costo mínimo $\min_a \ell(b, a)$, u observar, con costo mínimo $c + \sum_y m_{b(y)} W_{k-1}(B(b, y))$. La hipótesis inductiva permite alcanzar cada valor de continuación. Tomar el menor de ambas alternativas prueba la fórmula y construye una estrategia óptima; la finitud asegura mínimos y desempates medibles. □

Evaluación fuera de política

El cambio de medida y la corrección residual permiten relacionar el valor objetivo con la ley observada. Sus argumentos deben interpretarse junto con el modelo de trayectorias y el horizonte del Capítulo 7.

A.10.1 Insesgadez del IS

Demostración del Teorema 7.9. En un episodio de H decisiones, suponga que las leyes iniciales y los kernels del entorno coinciden y que el soporte objetivo está cubierto por comportamiento. Factorizar las densidades de la trayectoria cancela los factores del entorno y deja

$$\mathrm{d}\frac{P_\pi}{\mathrm{d}}P_b = W_{H-1} = \prod_{t=0}^{H-1} \frac{\pi_{t(A_t|H_t)}}{b_{t(A_t|H_t)}}.$$

Si $\mathbb{E}_{\pi[\![G]\!]} < \infty$, entonces $\mathbb{E}_{b[WG]} = \mathbb{E}_{\pi[G]} = J(\pi)$. La media de n episodios tiene esa misma esperanza. La independencia y el segundo momento finito permiten además $\mathrm{Var}\big(\hat{J}\big) = \frac{\mathrm{Var}_{b(WG)}}{n}$, pero no se necesitan para la identidad de esperanza. Aplicar el mismo cambio de medida a la historia hasta R_t da $\mathbb{E}_{b[W_t R_t]} = \mathbb{E}_{\pi[R_t]}$. Así se justifica PDIS, sin condicionar productos futuros en una historia que omita la recompensa y el siguiente estado. Se usan las propensiones verdaderas; sustituirlas por ajustes no preserva automáticamente insesgadez finita. Una interpretación causal requiere además identificación del mecanismo de intervención. □

A.10.2 Varianza de importancia y horizonte

Demostración del ejemplo y la cota del Teorema 7.11. Sea W el peso acumulado de H decisiones, con razones por acción acotadas por C y $|G| \le B_H$. Por cambio de medida $\mathbb{E}_{b[W]} = 1$, y $0 \le W \le C^H$. Para episodios iid,

$$\mathrm{Var}\big(\hat{J}_{\mathrm{IS}}\big) \le \frac{\mathbb{E}_{b[W^2G^2]}}{n} \le B_H^2 \frac{C^H}{n}.$$

Esta es una cota superior. La sola acotación no permite una cota inferior positiva: si todas las recompensas son cero, la varianza es cero. Para mostrar que el crecimiento exponencial es posible, tome acciones independientes Bernoulli(b) bajo comportamiento y Bernoulli(p) bajo objetivo, con $0 < b < 1$, $p \neq b$, y retorno terminal constante $G = 1$ (descuento uno). La razón de un paso tiene segundo momento

$$c = \frac{p^2}{b} + \frac{(1-p)^2}{1-b} = 1 + \frac{(p-b)^2}{b(1-b)} > 1.$$

La independencia da $\mathbb{E}_{b[W^2]} = c^H$ y, exactamente,

$$\mathrm{Var}\big(\hat{J}_{\mathrm{IS}}\big) = \frac{c^H - 1}{n}.$$

Se trata de un ejemplo de dificultad para IS, no de una imposibilidad universal para todos los estimadores. □

A.10.3 Doble robustez del DR

Demostración de la identidad de una decisión y su extensión. Sea $m(s,a) = \mathbb{E}[R|S=s, A=a]$, $S \sim \nu$, y sea π fija. Para candidatos fijos $\overline{m}, \overline{b}$ con denominadores positivos en el soporte objetivo, defina

$$\overline{v}(s) = \sum_a \pi(a|s)\overline{m}(s,a), \quad D = \overline{v}(S) + \frac{\pi(A|S)}{\overline{b}}(A|S)(R - \overline{m}(S,A)).$$

Condicionar en S, A y restar $J = \mathbb{E}_{\nu\left[\sum_a \pi(a|S)m(S,a)\right]}$ da

$$\mathbb{E}_{b[D]} - J = \mathbb{E}_{\nu\left[\sum_a \pi(a|S)\frac{\overline{b}(a|S) - b(a|S)}{\overline{b}}(a|S)(\overline{m}(S,a) - m(S,a))\right]}.$$

El sesgo se anula si $\overline{b} = b$ o $\overline{m} = m$. El término directo debe ser $\overline{v}(S)$; usar $\overline{m}(S,A)$ promedia bajo la política observada y no produce esta identidad. En horizonte finito use $\overline{v}_0 + \sum_t \gamma^t \overline{W}_{t(R_t + \gamma\overline{v}_{t+1} - \overline{q}_t)}$, con pesos acumulados y $\overline{v}_H = 0$. Si todas las q_t son correctas, cada residuo tiene media cero condicional a la historia y acción. Si todos los pesos son correctos, el cambio de medida y la cancelación telescópica dejan J. No basta con acertar un solo tiempo del horizonte. Para modelos aprendidos,

el centrado condicional requiere entrenamiento externo; la inferencia añade condiciones de tasas y momentos. □

A.10.4 Eficiencia del DR de una decisión

Expansión bajo condiciones suficientes. Para episodios iid de una decisión, ley inicial desconocida, política objetivo fija y modelo observado no paramétrico, la IF eficiente es

$$\varphi(O) = v(S) - J + \frac{\pi(A|S)}{b(A|S)}(R - m(S, A)).$$

Suponga acciones finitas, recompensas y regresiones ajustadas acotadas, propensiones verdaderas y ajustadas mayores que $c > 0$ en el soporte objetivo, y cross-fitting con un número fijo de folds. Si ambos auxiliares convergen en L^2 y su producto de errores es $o_{P\left(n^{-\frac{1}{2}}\right)}$, la identidad anterior y Cauchy–Schwarz controlan el sesgo. El argumento condicional de Sección A.6.1 controla la fluctuación empírica. Luego

$$\hat{J} - J = \frac{1}{n}\sum_i \varphi(O_i) + o_{P\left(n^{-\frac{1}{2}}\right)}.$$

Si $0 < \mathbb{E}[\varphi^2] < \infty$, el CLT y la varianza empírica consistente dan inferencia eficiente. Una tasa $O_{P\left(n^{-\frac{1}{2}}\right)}$ de un auxiliar no convierte por sí sola cualquier resto en $o_{P\left(n^{-\frac{1}{2}}\right)}$. Para episodios de varios tiempos la IF y las tasas se verifican en el modelo longitudinal correspondiente. □

Inferencia para funciones de valor

El Capítulo 8 distingue la aproximación de Bellman mediante bases de la ruta semiparamétrica. Las fuentes y los alcances se indican junto a cada argumento para conservar esa distinción.

A.11.1 Inferencia de Shi, Zhang, Lu y Song para política fija

Esquema, sujeto a las condiciones del artículo. El Nota 8.8 usa la aproximación de Bellman por bases y la studentización del artículo (Shi et al., 2022). La ecuación muestral se linealiza alrededor de la aproximación poblacional. El error se separa en una suma de residuos de Bellman premultiplicados por la inversa de la matriz de momentos y un resto de aproximación y estimación. Las hipótesis de diseño, momentos, dependencia, invertibilidad y crecimiento de la base controlan ese resto en relación con el error estándar. El CLT pertinente y la consistencia de la varianza producen

$$\sqrt{nT}\frac{\hat{J} - J}{\hat{\sigma}} \xrightarrow{d} N(0, 1).$$

Este es un esquema de lectura, no una demostración completa: se requieren todas las condiciones del teorema y su suplemento. El término lineal de este estimador no se identifica automáticamente con un gradiente semiparamétrico eficiente. Tampoco se reemplaza su estimador de varianza por uno HAC arbitrario sin justificar otra expansión. Para una política aprendida, SAVE añade una organización secuencial y condiciones propias; el resultado de política fija no basta. □

A.11.2 Eficiencia de Kallus–Uehara

Alcance del argumento de eficiencia. En el experimento finito con episodios iid del Teorema 4.146, la IF se obtiene como en (argumento y alcance en Apéndice A, pág. 227). Para que un estimador DRL alcance su varianza se necesita que su expansión tenga esa IF y resto despreciable. (Kallus & Uehara, 2020) establece condiciones para ajustes cruzados de funciones de valor y razones marginales. El

modelo temporalmente homogéneo de horizonte infinito de (Kallus & Uehara, 2022) admite otro experimento y otra cota; sus condiciones no se sustituyen por las del caso finito. Aquí no se reproduce la prueba técnica completa de ninguno de los dos artículos. □

Dr. Jaime Lincovil Curivil

Apéndice B

Glosario de Notación

El glosario permite recuperar un símbolo y volver al problema en el que se utiliza. Las categorías distinguen datos, modelos, reglas y valores para mantener visibles las diferencias que acompañan el recorrido del libro. La columna de consulta remite al capítulo donde se desarrolla el uso indicado.

Notación General

Símbolo	Descripción	Consulta
$\mathbb{R}$	Conjunto de números reales	4
$\mathbb{R}_{\geq 0}$	Conjunto de números reales no negativos	4
$\mathbb{R}^k$	Espacio euclídeo de dimensión k	4
$\mathbb{N}$	Conjunto de números naturales $\{0, 1, 2, \ldots\}$	4
$\mathbb{E}[X]$	Esperanza matemática de la variable aleatoria X	4
$\mathrm{Var}(X)$	Varianza de X	4
$\mathrm{Cov}(X, Y)$	Covarianza entre X e Y	4
$X \sim P$	X sigue la distribución P	4
$X \xrightarrow{d} Y$	Convergencia en distribución	4
$X_n \xrightarrow{p} X$	Convergencia en probabilidad	4
$\mathbb{1}_A$	Función indicadora del conjunto A	4
∇f	Gradiente de la función f	4
$\nabla^2 f$	Hessiano de f	4
$\partial_i f$	Derivada parcial respecto a la variable i	4
Δ^{k-1}	Simplex $(k-1)$-dimensional	4
$\Gamma(\alpha)$	Función gamma	4
$\mathcal{O}(n)$	Notación de Landau (orden de magnitud)	4

Tabla B.1: Notación matemática general

Inferencia estadística

Dr. Julio Urizar Civil Curivil

Símbolo	Descripción	Consulta
$\mathcal{P} = \{P_\theta\}$	Familia paramétrica de distribuciones	4
Θ	Espacio de parámetros	4
$\theta \in \Theta$	Parámetro (estado de la naturaleza)	4
$\mathcal{X}$	Espacio muestral	4
$X \in \mathcal{X}$	Vector de datos observados	4
$T : \mathcal{X} \to \mathcal{T}$	Estadístico	4
$\mathcal{C}$	Criterio de optimalidad	4
$\hat{\theta}$	Estimador de θ	4
$\hat{\theta}_n$	Estimador basado en n observaciones	4
$\text{Sesgo}_\theta\left(\hat{\theta}\right)$	Sesgo del estimador $\hat{\theta}$	4
$\text{ECM}_\theta\left(\hat{\theta}\right)$	Error cuadrático medio	4
$L : \Theta \times \mathcal{A} \to \mathbb{R}$	Función de pérdida	4
$R(\theta, \delta)$	Riesgo de la regla de decisión δ	4
$\delta : \mathcal{X} \to \mathcal{A}$	Regla de decisión	4
$\mathcal{A}$	Espacio de acciones	4
η	Parámetro natural (familias exponenciales)	4
$T(X)$	Estadístico natural	4
$A(\eta)$	Función log-partición	4
$h(x)$	Medida base	4
$\mathcal{H}$	Espacio de parámetros naturales	4
$I(\theta)$	Información de Fisher	4
$L(\theta; x)$	Función de verosimilitud	4
$\ell(\theta; x)$	Log-verosimilitud	4
$\pi(\theta)$	Distribución prior	4
$p(\theta \mid x)$	Distribución posterior	4

Tabla B.2: Notación de inferencia estadística

Procesos de decisión de Markov

Símbolo	Descripción	Consulta
$\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, r, \gamma)$	MDP	3
$\mathcal{S}$	Espacio de estados	3

Dr. Eduardo Incovil Curivil

Símbolo	Descripción	Consulta
$s \in \mathcal{S}$	Estado	3
$\mathcal{A}$	Espacio de acciones	3
$a \in \mathcal{A}$	Acción	3
$P(s'\|s,a)$	Probabilidad de transición	3
$r : \mathcal{S} \times \mathcal{A} \to \mathbb{R}$	Función de recompensa	3
$\gamma \in [0,1]$	Factor de descuento	3
$\pi_{\delta(x)} = \delta(x)$	Política (distribución sobre acciones)	3
$\pi(a\|s)$	Probabilidad de elegir a en estado s	3
$V^\pi : \mathcal{S} \to \mathbb{R}$	Función de valor de la política π	3
$V^*(s)$	Función de valor óptima	3
π^*	Política óptima	3
$Q^\pi : \mathcal{S} \times \mathcal{A} \to \mathbb{R}$	Función acción-valor	3
$Q^*(s,a)$	Función acción-valor óptima	3
$\mathcal{T}$	Operador de Bellman	3
$\mathcal{T}^\pi$	Operador de Bellman de la política π	3
$\mathcal{T}^*$	Operador de Bellman óptimo	3
$\tau = (s_0, a_0, r_0, s_1, a_1, r_1, \ldots)$	Trayectoria	3
$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k}$	Retorno descontado desde el tiempo t	3
H	Horizonte (número de pasos)	3

Tabla B.3: Notación de MDPs y programación dinámica

Evaluación Off-Policy e Inferencia (Parte III)

Símbolo	Descripción	Consulta
π_b	Política de comportamiento (behavior policy)	7
π_e	Política objetivo (evaluation policy)	7
V^{π_e}	Valor de la política objetivo	7
$\hat{V}^{\pi_e}$	Estimador del valor	7
$\rho_t = \frac{\pi_e(a_t\|s_t)}{\pi_b(a_t\|s_t)}$	Ratio de importancia en el paso t	7
$\rho_{0:t} = \prod_{k=0}^{t} \rho_k$	Ratio de importancia acumulado	7
$\hat{V}^{\mathrm{IS}}$	Estimador de importancia de muestreo	7
$\hat{V}^{\mathrm{DR}}$	Estimador doblemente robusto	7

Dr. Rafael Ignacio Cabrera Quirvi

Símbolo	Descripción	Consulta
$\hat{V}^{\mathrm{DM}}$	Estimador directo (model-based)	7
$Q(s,a)$	Modelo de recompensa (función acción-valor)	7
$\hat{Q}$	Estimador del modelo de recompensa	7
ψ	Parámetro de interés (finito-dimensional)	4
λ	Parámetro nuisance (infinito-dimensional)	4
$\varphi(P)$	Funcional sobre distribuciones	4
$\phi(x;P)$	Función de influencia eficiente	4
$\sigma^2(P)$	Varianza asintótica	4
α-mixing	Coeficiente de mezcla fuerte	4
β-mixing	Coeficiente de mezcla absoluta	4
ϕ-mixing	Coeficiente de mezcla uniforme	4

Tabla B.4: Notación de evaluación off-policy e inferencia

Representación Wald → MDP

Concepto	Wald	MDP
Parámetro del modelo	Θ	Índice θ de la familia de MDP
Acciones	$\mathcal{A}$	$\mathcal{A}$
Observaciones	$\mathcal{X}$	Estado inicial observado X
Pérdida/Recompensa	$L(\theta,a)$	$-r_{\theta(x,a)}$
Regla de decisión	$\delta:\mathcal{X}\to\mathcal{A}$	$\pi_{\delta(x)}=\delta(x)$
Riesgo/Retorno	$R(\theta,\delta)$	$-J_{\theta(\pi_\delta)}$
Comparación	Misma clase de reglas	Misma clase de políticas representadas
Bayes	$\min_\delta \rho_{\nu(\delta)}$	$\max_\pi J_{\nu(\pi)}$
Minimax	$\inf_\delta \sup_\theta R$	$\sup_\pi \inf_\theta J_{\theta(\pi)}$

Tabla B.5: Correspondencias de la incrustación fiel

Sistema de Soporte Clínico para Hipertensión (SSCH)

Dr. Jaime Lincovil Cavieres

Símbolo	Descripción	Consulta
$\mathcal{S} = \{s_1, s_2, s_3, s_4, s_5\}$	Estados de salud	4
s_1	Normotensión (PA $<$ 120/80 mmHg)	4
s_2	Presión arterial elevada (120–129/$<$80)	4
s_3	Hipertensión grado 1 (130–139/80–89)	4
s_4	Hipertensión grado 2 ($\geq$140/90)	4
s_5	Crisis hipertensiva ($\geq$180/120)	4
$\mathcal{A} = \{a_1, a_2, a_3, a_4\}$	Intervenciones mensuales	4
a_1	Vigilancia activa	4
a_2	Cambios de estilo de vida	4
a_3	Medicación de primera línea (IECA)	4
a_4	Terapia combinada intensiva	4
$\theta_{s,a,s'}$	Probabilidad de transición	4
$N(s, a, s')$	Conteo de transiciones observadas	4
$r(s, a)$	Beneficio clínico neto	4

Tabla B.6: Notación específica del ejemplo SSCH

Abreviaciones y Acrónimos

Abreviatura	Descripción
MDP	Proceso de Decisión de Markov (Markov Decision Process)
POMDP	Proceso de Decisión de Markov Parcialmente Observable
OPE	Evaluación Off-Policy (Off-Policy Evaluation)
IS	Importancia de Muestreo (Importance Sampling)
DR	Doblemente Robusto (Doubly Robust)
DM	Método Directo (Direct Method)
PDIS	Importancia de Muestreo Per-Decisión
UMVUE	Estimador Uniformemente de Varianza Mínima No Sesgado
CLT	Teorema Central del Límite
SAVE	Estimación de Valor Semiparamétrica Promediada
SSCH	Sistema de Soporte Clínico para Hipertensión
LLM	Modelo de Lenguaje Grande (Large Language Model)
RL	Aprendizaje por Refuerzo (Reinforcement Learning)

Documento Confidencial

Abreviatura	Descripción
HAC	Estimador de Covarianza Heterocedástica y Autocorrelacionada
ACC/AHA	Colegio Americano de Cardiología/Asociación Americana del Corazón
IECA	Inhibidor de la Enzima Convertidora de Angiotensina

Tabla B.7: Abreviaciones y acrónimos

Convenciones Tipográficas

- **Negrita ($\boldsymbol{X}$):** Vectores y matrices cuando el contexto no es ambiguo
- **Caligráfica ($\mathcal{P}$, $\mathcal{F}$):** Familias de conjuntos, σ-álgebras, espacios
- **Script ($\mathcal{L}$):** Operadores lineales (ocasional)
- **Blackboard bold ($\mathbb{R}$, $\mathbb{N}$):** Conjuntos numéricos estándar
- **Itálica (θ, η):** Parámetros, variables escalares
- **Sans serif (T):** Estadísticos cuando se enfatiza su naturaleza aleatoria
- **Tipo escritor (`State`):** Código, nombres de variables en implementaciones
- **Subíndices (X_n, θ_0):** Índices de secuencias, valores específicos
- **Superscripts (V^{π}, $\hat{\theta}^{(k)}$):** Políticas, iteraciones de algoritmos

B.8.1 Convenciones de Notación

Esta monografía adopta un sistema de notación unificado diseñado para hacer explícitas las correspondencias de la incrustación fiel. Cada símbolo tiene una interpretación en el marco estadístico y, cuando aplica, una interpretación en el marco de agentes.

Conjuntos y espacios

Símbolo	Interpretación estadística	Interpretación en agentes
Θ (Θ)	Espacio de parámetros	Estado oculto del entorno / índice de modelo P_θ (¡ no confundir con el estado observado $\mathcal{S}$; ver §0.16)
$\mathcal{X}$ ($\mathcal{X}$)	Espacio muestral	Espacio de observaciones
$\mathcal{A}$ ($\mathcal{A}$)	Espacio de acciones	Espacio de acciones
$\mathcal{S}$ ($\mathcal{S}$)	—	Espacio de estados **observados** del MDP
$\mathcal{D}$ ($\mathcal{D}$)	Clase de reglas de decisión	Clase de políticas
$\mathbb{R}$	Recta real	Recta real
$\mathbb{N}, \mathbb{Z}$	Naturales, enteros	Naturales, enteros

Funciones y operadores

Símbolo	Definición	Contexto
$L(\theta, a)$	Función de pérdida	Decisión estadística
$R(\theta, \delta)$	Función de riesgo $\mathbb{E}_\theta[L(\theta, \delta(X))]$	Decisión de Wald
$V^{\pi}(s)$	Función de valor de política π	MDP
$Q^{\pi}(s, a)$	Función Q de política π	MDP

Símbolo	Definición	Contexto
$\mathcal{T}$	Operador de Bellman	MDP
$\varphi^*(\cdot)$	Función de influencia eficiente	Semiparamétrica
$\mathbb{E}[\cdot]$, $\mathbb{P}[\cdot]$	Esperanza y probabilidad	General
$\mathrm{Var}[\cdot]$, $\mathrm{Cov}[\cdot,\cdot]$	Varianza y covarianza	General
arg max, arg min	Maximizador / minimizador	Optimización

Notación probabilística

Escribimos $X \sim P_\theta$ para indicar que la variable aleatoria X sigue la distribución P_θ indexada por el parámetro θ. La notación $\mathbb{E}_\theta[\cdot]$ y $\mathbb{P}_\theta[\cdot]$ especifica que la expectativa o probabilidad se calcula bajo P_θ. Cuando el parámetro es claro por contexto, omitimos el subíndice.

Para familias exponenciales, usamos la forma canónica $p(x;\eta) = h(x)\exp\{\eta^\top T(x) - A(\eta)\}$, donde η es el parámetro natural, $T(x)$ el estadístico suficiente natural y $A(\eta)$ la función generadora de cumulantes.

Notación de la incrustación fiel

El símbolo $\leftrightarrow$ orienta la lectura de una correspondencia. La igualdad precisa entre riesgo y retorno se formula en el Capítulo 5, con el promedio sobre la distribución inicial y el índice desconocido del modelo. Al utilizar una tabla conviene volver a esa formulación para identificar qué objeto se compara.

Referencias cruzadas

Las referencias a resultados de otros capítulos usan la forma Teorema X.Y, Definición X.Y o Proposición X.Y, donde X es el número de capítulo. Los apéndices contienen las demostraciones de los resultados más técnicos; cada enunciado indica explícitamente cuándo la demostración completa se encuentra en el Apéndice A.

Ref. Universidad Curivil

Apéndice C

LangGraph: organización de los cálculos de un agente

Los capítulos anteriores distinguen observación, estimación y decisión. Este apéndice muestra cómo pueden organizarse esas tareas mediante un grafo de estado en LangGraph. Los nombres de los nodos describen responsabilidades del programa; su relación con un MDP debe justificarse mediante el modelo y la información que conserva el estado, como se discutió en el Capítulo 9.

Ontología de Componentes

LangGraph modela agentes como grafos de estado dirigidos. Los componentes fundamentales son:

Nota C.1 (Nota de alcance: grafo de control vs. dinámica del ambiente). El `StateGraph` (Definición C.2) y sus `Nodes` (Definición C.3) modelan el **flujo de control interno del agente**, que es determinista por construcción: dado un estado s y un nodo v, el siguiente estado interno $s' = v(s)$ está unívocamente determinado.

Esto es **independiente** de si la **dinámica del ambiente** $P(s' \mid s, a)$ (Definición 8.1, Capítulo 3) con la que el agente interactúa es o no estocástica: un `Node` determinista puede perfectamente invocar una acción cuyo efecto en el ambiente sea aleatorio. **No debe confundirse** la determinicidad del grafo de ejecución con una restricción sobre el MDP que el agente resuelve. Esta distinción es relevante para entender por qué la prueba del Teorema 5.3 (Cap. 9) se restringe al caso determinista sin que ello limite la aplicabilidad de LangGraph a ambientes estocásticos.

Definición C.2 (StateGraph). Un `StateGraph` es una tupla $\mathcal{G} = (V, E, \mathcal{S}, s_0, F)$ donde:
- V es el conjunto finito de nodos (funciones de procesamiento)
- $E \subseteq V \times V$ es el conjunto de aristas dirigidas
- $\mathcal{S}$ es el espacio de estados definido por `StateSchema`
- $s_0 \in \mathcal{S}$ es el estado inicial
- $F \subseteq V$ es el conjunto de nodos finales

Definición C.3 (Node). Un `Node` $v \in V$ es una función $v : \mathcal{S} \to \mathcal{S}$ que transforma el estado del agente. En el contexto MDP:

$$v(s) = s' \quad \Leftrightarrow \quad P(s' \mid s, a_v) = 1$$

donde a_v es la acción determinista asociada al nodo.

Definición C.4 (StateSchema). El `StateSchema` $\mathcal{S}$ es un diccionario tipado que define la estructura del estado:

$$\mathcal{S} = \{(k_1, \tau_1), (k_2, \tau_2), ..., (k_m, \tau_m)\}$$

donde k_i son claves (nombres de campo) y τ_i son tipos (incluyendo `Annotated` con operadores de reducción).

Definición C.5 (ConditionalEdge). Una `ConditionalEdge` $e_c : \mathcal{S} \to V$ es una función que determina el siguiente nodo basándose en el estado actual:

$$e_c(s) = v \quad \Leftrightarrow \quad \pi(s) = a_v$$

Representa la política π del agente.

Definición C.6 (Checkpointer). Un `Checkpointer` $\chi : \mathcal{S} \times \mathbb{N} \to \mathcal{M}$ es un mecanismo de persistencia que almacena estados en memoria $\mathcal{M}$, habilitando:
- Continuación de ejecución
- Human-in-the-loop (pausar/reanudar)
- Rollback a estados anteriores
- Branching de trayectorias

Correspondencia LangGraph ↔ MDP

La siguiente tabla establece la correspondencia formal entre componentes de LangGraph y elementos del MDP causal (Capítulo 3).

LangGraph	MDP	Interpretación
`StateSchema`	$\mathcal{S}$	Espacio de estados
`state` (instancia)	$s \in \mathcal{S}$	Estado actual
`Node`	$a \in \mathcal{A}$	Acción (procesamiento)
`ConditionalEdge`	$\pi : \mathcal{S} \to \mathcal{A}$	Política
`add_edge`	$P(s' \mid s, a)$ (det.)	Transición determinista
`add_conditional_edges`	$P(s' \mid s, \pi(s))$	Transición bajo política
`Checkpointer`	Historia h_t	Trayectoria almacenada
`START`	s_0	Estado inicial
`END`	s_T (terminal)	Estado terminal
Función de nodo	$r(s, a, s')$	Recompensa (implícita)
`compile()`	Cierre de π	Política ejecutable
`stream()`	Simulación	Generación de trayectoria

Tabla C.1: Correspondencia LangGraph ↔ MDP

Diagrama de Arquitectura Genérica

El siguiente diagrama ilustra la arquitectura genérica de un agente LangGraph con ciclo de decisión:

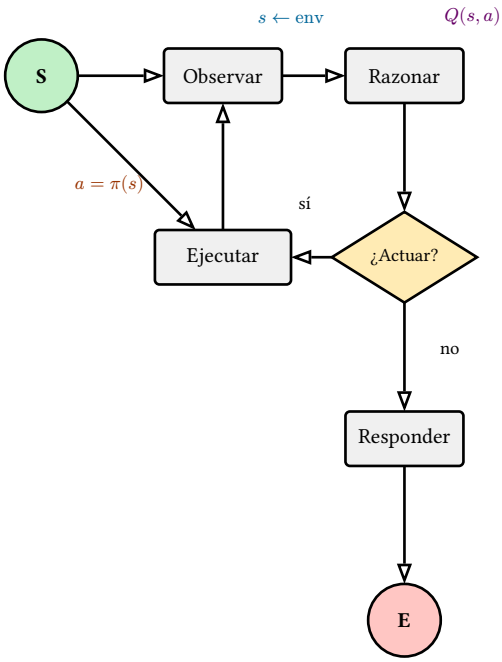


Figura C.1: Arquitectura genérica de agente LangGraph con ciclo ReAct. Las anotaciones en colores indican la correspondencia MDP.

Value Iteration como StateGraph

Ilustramos la implementación de Value Iteration (Algoritmo de Value Iteration del Capítulo 3) como un `StateGraph`.

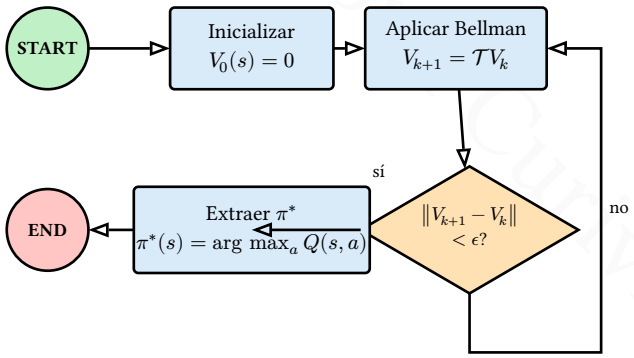


Figura C.2: Value Iteration implementado como `StateGraph`. El nodo *Aplicar Bellman* corresponde al operador de Bellman $\mathcal{T}$ del Teorema de contracción del Capítulo 3.

C.4.1 Descripción del StateSchema

El `StateSchema` para Value Iteration contiene:

- `V`: diccionario $\{s \mapsto V(s)\}$, función de valor actual
- `V_prev`: función de valor de la iteración anterior
- `iteration`: contador de iteraciones k
- `delta`: $\|V_{k+1} - V_k\|_\infty$, criterio de convergencia
- `policy`: diccionario $\{s \mapsto a\}$, política extraída
- `converged`: booleano indicando terminación

Dr. Jaime Hernández Cuevas

C.4.2 Descripción de Nodos

- **Inicializar:** Establece $V_0(s) = 0$ para todo $s \in \mathcal{S}$, $k = 0$, `converged = False`.
- **Aplicar Bellman:** Computa

$$V_{k+1}(s) = \max_{a \in \mathcal{A}} \left[r(s,a) + \gamma \sum_{s'} P(s' \mid s,a) V_k(s') \right]$$

  Actualiza `delta` y `iteration`.
- **Extraer π^*:** Para cada s, computa

$$\pi^*(s) = \arg\max_{a \in \mathcal{A}} Q^*(s,a)$$

  donde $Q^*(s,a) = r(s,a) + \gamma \sum_{s'} P(s' \mid s,a) V^*(s')$.

C.4.3 Arista Condicional

La `ConditionalEdge` después del nodo Bellman implementa:

```
def should_continue(state: VIState) -> str:
    if state["delta"] < epsilon:
        return "extract_policy"
    else:
        return "apply_bellman"
```

Patrones de Diseño para Agentes con Garantías

C.5.1 Patrón: Estimador DR como Nodo

Para integrar el estimador Doubly Robust (Capítulo 7) en un agente evaluador:

1. El `StateSchema` incluye campos para datos logged $\mathcal{D}$, modelo de propensity $\hat{\mu}$, modelo de outcome $\hat{Q}$.
2. Un nodo `fit_nuisance` ajusta $\hat{\mu}$ y $\hat{Q}$ con cross-fitting (ver Apéndice A.6.1).
3. Un nodo `compute_dr` calcula

$$\hat{V}^{\pi}_{\mathrm{DR}} = \frac{1}{n} \sum_{i=1}^{n} \hat{\varphi}_{\mathrm{DR}}(O_i)$$

4. Un nodo `compute_ci` construye el IC de nivel $(1-\alpha)$ usando la varianza estimada de la IF.

C.5.2 Patrón: A/B Testing con Control de FDR

Para evaluar múltiples políticas candidatas controlando FDR:

1. Nodo `generate_hypotheses`: Define $H_{0,j} : V^{\pi_j} \leq V^{\pi_0}$
2. Nodo `compute_pvalues`: Calcula p_j para cada $j = 1, \ldots, m$
3. Nodo `apply_bh`: Aplica Benjamini-Hochberg al nivel α
4. `ConditionalEdge`: Selecciona políticas con $p_j \leq \hat{t}_{\mathrm{BH}}$

C.5.3 Patrón: Human-in-the-Loop con Checkpointer

El `Checkpointer` habilita intervención humana:

1. Nodo `propose_action` genera acción candidata
2. `interrupt_before=["execute"]` pausa antes de ejecutar

Versione Incontrollata

3. Humano revisa y aprueba/modifica en interfaz
4. Nodo `execute` procede con acción (modificada o no)
5. El estado h_t incluye flag `human_approved`

Una organización posible del código

Los laboratorios del Capítulo 10 permiten seguir los cálculos estadísticos en programas reproducibles. Para una implementación por grafos, conviene mantener separados los estados, las funciones de nodo y los procedimientos de estimación. La estructura siguiente ilustra esa separación como una propuesta de organización:

```
statistical-agents-langgraph/
|-- chapter01_exponential_families/
|-- chapter02_sufficiency/
|-- chapter03_estimation/
|-- ...
|-- chapter12_synthesis/
|-- common/
|   |-- state_schemas.py
|   |-- influence_functions.py
|   `-- dr_estimators.py
`-- notebooks/
    `-- interactive_examples.ipynb
```

En esa organización, cada directorio puede reunir:
- `agent.py`: Implementación del `StateGraph`
- `nodes.py`: Funciones de nodo
- `tests.py`: Tests unitarios
- `README.md`: Documentación y correspondencias teóricas

Notas sobre Versiones y Compatibilidad

Los ejemplos de esta monografía fueron desarrollados con:
- `langgraph` $\geq$ 0.2.0
- `langchain-core` $\geq$ 0.3.0
- Python $\geq$ 3.10

Al reproducir los fragmentos conviene registrar las versiones efectivamente utilizadas y comprobar su compatibilidad. Esa información acompaña al código y a sus resultados, como se describe en la Sección C.6.

Uso Educativo Curivil

Apéndice D

Fundamentos Medido-Teóricos

La formulación de un estimador o una política presupone que las funciones utilizadas sean medibles y que sus esperanzas estén definidas. Este apéndice reúne las nociones de medida, integración y proyección que permiten hacer explícitos esos requisitos. Puede consultarse al estudiar las condiciones de un resultado, sin apartar del argumento principal todo su desarrollo técnico.

σ-Álgebras y Espacios Medibles

Definición D.1 (σ-Álgebra). Sea Ω un conjunto no vacío. Una colección $\mathcal{F}$ de subconjuntos de Ω es una *σ-álgebra* si:

1. $\Omega \in \mathcal{F}$
2. Si $A \in \mathcal{F}$, entonces $A^c \in \mathcal{F}$ (cerrado bajo complementos)
3. Si $\{A_n\}_{n=1}^{\infty}$ es una sucesión en $\mathcal{F}$, entonces $\bigcup_{n=1}^{\infty} A_n \in \mathcal{F}$ (cerrado bajo uniones numerables)

Definición D.2 (Espacio Medible). Un *espacio medible* es un par $(\Omega, \mathcal{F})$ donde Ω es un conjunto y $\mathcal{F}$ es una σ-álgebra sobre Ω.

Ejemplo D.3 (σ-Álgebra de Borel). Sea $\Omega = \mathbb{R}$. La *σ-álgebra de Borel* $\mathcal{B}(\mathbb{R})$ es la σ-álgebra más pequeña que contiene todos los intervalos abiertos $(a, b) \subset \mathbb{R}$. Esta σ-álgebra contiene todos los conjuntos de interés práctico en análisis real.

Medibilidad de Funciones

Definición D.4 (Función Medible). Sean $(\Omega, \mathcal{F})$ y $(\Omega', \mathcal{F}')$ espacios medibles. Una función $f : \Omega \to \Omega'$ es *medible* si:

$$f^{-1}(A') \in \mathcal{F} \quad \forall A' \in \mathcal{F}'$$

Proposición D.5 (Composición de Funciones Medibles). *Si $f : \Omega \to \Omega'$ es medible y $g : \Omega' \to \Omega''$ es medible, entonces $g \circ f : \Omega \to \Omega''$ es medible.*

Ejemplo D.6 (Medibilidad de Estadísticos). Sea $X : \Omega \to \mathbb{R}^n$ un vector aleatorio. Si $T : \mathbb{R}^n \to \mathbb{R}^k$ es Borel-medible, entonces $T \circ X$ es medible. El recíproco para un único X no vale: un X constante puede ocultar la falta de medibilidad de T. Toda función continua entre estos espacios es Borel-medible.

Medidas de Probabilidad y Dominación

Definición D.7 (Medida de Probabilidad). Una *medida de probabilidad* sobre $(\Omega, \mathcal{F})$ es una función $P : \mathcal{F} \to [0, 1]$ tal que:

1. $P(\Omega) = 1$
2. Si $\{A_n\}_{n=1}^{\infty}$ son conjuntos disjuntos en $\mathcal{F}$, entonces:

D. Ignacio Novil Cuervil

$$P\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} P(A_n)$$

Definición D.8 (Espacio de Probabilidad). Un *espacio de probabilidad* es una terna $(\Omega, \mathcal{F}, P)$ donde $(\Omega, \mathcal{F})$ es un espacio medible y P es una medida de probabilidad.

Definición D.9 (Dominación). Sea $\mathcal{P} = \{P_\theta : \theta \in \Theta\}$ una familia de medidas de probabilidad sobre $(\Omega, \mathcal{F})$. Decimos que $\mathcal{P}$ está *dominada* por una medida μ si:

$$P_\theta \ll \mu \quad \forall \theta \in \Theta$$

donde $P_\theta \ll \mu$ significa que $P_\theta(A) = 0$ para todo $A \in \mathcal{F}$ con $\mu(A) = 0$.

Teorema D.10 (Teorema de Radon-Nikodym). *Sea μ una medida σ-finita y P una probabilidad con $P \ll \mu$. Existe una función medible no negativa f, finita μ-casi en todas partes y única salvo conjuntos μ-nulos, tal que*

$$P(A) = \int_A f \, \mathrm{d}\mu$$

para todo conjunto medible A. Se escribe $f = \mathrm{d}\frac{P}{\mathrm{d}}\mu$. La hipótesis sobre la medida dominante es parte del resultado; la continuidad absoluta sola no basta para una medida arbitraria.

σ-Álgebras para Espacios de Trayectorias del MDP

Definición D.11 (Espacio de Trayectorias). Sea un MDP con horizonte T. El espacio de trayectorias es:

$$\mathcal{T} = (\mathcal{S} \times \mathcal{A} \times \mathbb{R})^{T+1}$$

Una trayectoria típica es $\tau = (s_0, a_0, r_0, s_1, a_1, r_1, ..., s_T, a_T, r_T)$.

Definición D.12 (σ-Álgebra de Trayectorias). La σ-álgebra de trayectorias $\mathcal{F}_\tau$ se construye como el producto de σ-álgebras:

$$\mathcal{F}_\tau = \prod_{t=0}^{T} (\mathcal{B}(\mathcal{S}) \otimes \mathcal{B}(\mathcal{A}) \otimes \mathcal{B}(\mathbb{R}))$$

donde $\mathcal{B}(\cdot)$ denota la σ-álgebra de Borel.

Definición D.13 (Filtración de Historias). La *filtración de historias* $\{\mathcal{F}_t\}_{t=0}^{T}$ es una familia creciente de σ-álgebras donde $\mathcal{F}_t$ representa la información disponible hasta el tiempo t:

$$\mathcal{F}_t = \sigma(S_0, A_0, R_0, ..., S_t, A_t, R_t)$$

Proposición D.14 (Propiedad de Markov y Filtraciones). *Defina la información antes de observar la recompensa actual como*

$$\mathcal{G}_t = \sigma(S_0, A_0, R_0, ..., S_t, A_t).$$

El modelo Markov controlado exige un núcleo K_t tal que

$$P((R_t, S_{t+1}) \in B | \mathcal{G}_t) = K_{t(B|S_t, A_t)}.$$

La filtración $\mathcal{F}_t$ definida arriba ya contiene R_t; condicionar en ella no puede usarse en esta identidad de la ley conjunta antes de observar R_t. La homogeneidad añade que K_t no depende de t.

Diplomatura en Ciencia de Datos

Condiciones de Medibilidad para Estimadores y Políticas

Definición D.15 (Estimador Medible). Un *estimador* $\hat{\theta}_n : \mathcal{X}^n \to \Theta$ es una función medible que mapea n observaciones a una estimación del parámetro.

Proposición D.16 (Medibilidad de Estimadores Comunes). *La media muestral es continua y, con las sigma-álgebras de Borel, medible. La composición $g(T(X))$ es medible si T y g lo son. Un argmax requiere existencia y selección medible: por ejemplo, en un espacio paramétrico métrico compacto, con criterio medible en los datos y continuo en el parámetro, se puede elegir un maximizador medible bajo las hipótesis estándar de selección. Continuidad de la verosimilitud sola no garantiza que el máximo exista ni que una elección arbitraria entre empates sea medible.*

Definición D.17 (Política Medible). Una *política* $\pi : \mathcal{S} \to \mathcal{A}$ es medible si para todo conjunto medible $A \subseteq \mathcal{A}$:

$$\{s \in \mathcal{S} : \pi(s) \in A\} \in \mathcal{B}(\mathcal{S})$$

Noción de Dominación en Modelos con Estados Continuos

Definición D.18 (Modelo con Estados Continuos). Un modelo estadístico con estados continuos es una familia $\mathcal{P} = \{P_\theta : \theta \in \Theta\}$ donde:

- $\mathcal{X} = \mathbb{R}^d$ (o un espacio de Borel general)
- Cada P_θ tiene densidad $p_\theta(x)$ respecto a la medida de Lebesgue

Proposición D.19 (Dominación en Modelos Continuos). *En modelos con estados continuos, la medida de Lebesgue λ domina a toda la familia $\mathcal{P}$ si:*

1. *Las densidades $p_\theta(x)$ existen para todo θ*
2. *Las densidades son continuas en x (o al menos medibles)*

Ejemplo D.20 (Modelo Gaussiano). Sea $X \sim N(\mu, \sigma^2)$ con $\theta = (\mu, \sigma^2)$ y $\sigma^2 > 0$. La densidad es:

$$p_\theta(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

Esta familia está dominada por la medida de Lebesgue en $\mathbb{R}$.

Teorema de la Función Implícita y medibilidad local

Teorema D.21 (Teorema de la Función Implícita). *Sean $x \in \mathbb{R}^m$, $y \in \mathbb{R}^n$ y $F : U_0 \subset \mathbb{R}^{m+n} \to \mathbb{R}^n$ continuamente diferenciable en un abierto U_0. Supongamos que existe un punto $(x_0, y_0) \in \mathbb{R}^{n+m}$ tal que:*

1. *$F(x_0, y_0) = 0$*
2. *La matriz jacobiana $\frac{\partial F}{\partial y}(x_0, y_0)$ es invertible*

Entonces existen vecindades U de x_0 y V de y_0, y una única función $g : U \to V$ tal que:

1. *$F(x, g(x)) = 0$ para todo $x \in U$*
2. *g es continuamente diferenciable*
3. *$g(x_0) = y_0$*

Proposición D.22 (Condiciones de Regularidad para el Teorema de la Función Implícita). *Para una ecuación de estimación $F(x, \theta) = 0$, el teorema exige F continuamente diferenciable cerca de la solución y Jacobiano $\partial_\theta F$ invertible en ella. La información de Fisher es una esperanza y no coincide necesariamente con el Jacobiano de una ecuación muestral. Su invertibilidad no prueba por sí sola la*

invertibilidad de ese Jacobiano ni la existencia de una solución. Identificación global y no singularidad local son requisitos distintos.

Integrabilidad y Convergencia Dominada

Definición D.23 (Integrabilidad). Una función medible $f : \Omega \to \mathbb{R}$ es *integrable* respecto a una medida μ si:

$$\int_\Omega |f| \, \mathrm{d}\mu < \infty$$

Teorema D.24 (Teorema de Convergencia Dominada de Lebesgue). *Sea $\{f_n\}$ una sucesión de funciones medibles tal que $f_n \to f$ casi seguramente. Si existe una función integrable g tal que $|f_n| \leq g$ para todo n, entonces:*

1. *f es integrable*
2. *$\int f_n \, \mathrm{d}\mu \to \int f \, \mathrm{d}\mu$*

Espacios de Hilbert y Proyecciones Ortogonales

Definición D.25 (Espacio de Hilbert). Un *espacio de Hilbert* es un espacio vectorial completo $\mathcal{H}$ equipado con un producto interno $\langle \cdot, \cdot \rangle$ que induce una norma $\|f\| = \sqrt{\langle f, f \rangle}$.

Ejemplo D.26 (Espacio $L^2(P)$). El espacio $L^2(P)$ de funciones de cuadrado integrable es un espacio de Hilbert con:

- Producto interno: $\langle f, g \rangle = \mathbb{E}_P[fg]$
- Norma: $\|f\|_2 = \sqrt{\mathbb{E}_P[f^2]}$

Teorema D.27 (Teorema de Proyección). *Sea $\mathcal{H}$ un espacio de Hilbert y $\mathcal{M} \subset \mathcal{H}$ un subespacio cerrado. Para todo $f \in \mathcal{H}$, existe un único elemento $P_\mathcal{M} f \in \mathcal{M}$ tal que:*

$$\|f - P_\mathcal{M} f\| = \min_{g \in \mathcal{M}} \|f - g\|$$

Además, $f - P_\mathcal{M} f$ es ortogonal a $\mathcal{M}$.

Resumen de Condiciones Técnicas

Capítulo	Resultado	Condiciones Medido-Teóricas
Capítulo 4	Modelos paramétricos	Medida dominante común, densidades medibles
Capítulo 4	Estadísticos suficientes	Medibilidad de $T(X)$, σ-álgebra generada por T
Capítulo 4	UMVUE	Suficiencia, completitud, insesgadez y segundo momento
Capítulo 4	Convergencia asintótica	$L^2(P)$ completo, convergencia dominada
Capítulo 4	Eficiencia semiparamétrica	Espacio de Hilbert $L^2(P)$, proyección ortogonal
Capítulo 3	MDPs	σ-álgebra de trayectorias, filtración de historias

Original Uncontrolled Curiv

Capítulo	Resultado	Condiciones Medido-Teóricas
Capítulo 5	Incrustación fiel (un paso, determinista)	Espacios numerables, acciones finitas, pérdida acotada y medibilidad
Capítulo 5	Extensión estocástica general (**problema abierto**, Nota 5.4)	Requiere especificar el modelo, los núcleos y el alcance de la representación
Capítulo 7	OPE	Medibilidad de políticas, dominación de medidas

Tabla D.1: Condiciones Técnicas por Capítulo

La tabla ofrece puntos de consulta sobre las herramientas utilizadas. Las condiciones completas se leen en el enunciado del resultado y en el modelo al que se aplica.

Dr. Jaime Lincovil Curivil

Apéndice E

Tablas de Correspondencia

Las tablas permiten volver de un componente del agente al concepto estadístico que interviene en él. Se utilizan como material de consulta junto con el Capítulo 5 y el Capítulo 9: una correspondencia orienta la lectura, y su conclusión precisa se determina en el resultado citado.

Correspondencias entre la decisión y su representación

La primera tabla recorre los objetos que relacionan la decisión de Wald y su representación. Para la identidad exacta entre riesgo y retorno se consulta el Teorema 5.3; los límites de la extensión se precisan en la Nota 5.4.

Wald	MDP	Interpretación	Consulta
Espacios fundamentales			
Espacio paramétrico Θ	Estado oculto del entorno (POMDP) / índice del núcleo P_θ (MDP robusto/bayesiano-adaptativo)	Verdad subyacente a inferir; nunca el estado observado $\mathcal{S}$	4
Espacio muestral $\mathcal{X}$	Espacio de observaciones	Datos/percepciones	4
Espacio de acciones $\mathcal{A}$	Espacio de acciones $\mathcal{A}$	Decisiones disponibles	2
Modelo P_θ	Ley inicial de la representación	Familia de MDP de una decisión	3
Funciones de evaluación			
Pérdida $L(\theta, a)$	Recompensa negativa $-r(s, a)$	Costo de decisión	2
Riesgo $R(\theta, \delta)$	Costo esperado	$\mathbb{E}[L]$ vs $-\mathbb{E}[r]$	2
Riesgo de Bayes $r(\delta, \pi)$	Valor bajo prior	Evaluación global	2
Riesgo minimax	Valor adversarial	Peor caso garantizado	2
Estrategias			

Universidad Privada Ciriví

Wald	MDP	Interpretación	Consulta
Regla de decisión δ	Política π	Mapeo observación $\rightarrow$ acción	5
Estimador $\hat{\theta}$	Actor (determinista)	Aproximación puntual	4
Regla aleatorizada	Política estocástica	$\pi(a \mid s)$	5
Regla de Bayes δ^*	Política óptima π^*	Minimiza riesgo esperado	5
Principios de optimalidad			
Admisibilidad	Pareto-optimalidad	No dominancia estricta	2
Clase completa	Políticas no dominadas	Conjunto reducido	2
Teorema de clase completa	Sin equivalencia general con Bellman	Comparación global de riesgos	5
Reducción de información			
Estadístico suficiente $T(X)$	Resumen para un parámetro	La propiedad predictiva se verifica aparte	4
Suficiencia minimal	Reducción estadística minimal	No caracteriza un estado de control	4
Completitud	Unicidad de funciones insesgadas de T	No equivale a identificabilidad	4
Eficiencia y cotas			
Cota de Cramér-Rao	Cota de varianza	Límite inferior	4
UMVUE	Estimador insesgado de mínima varianza	Dentro de la clase insesgada	4
IF eficiente φ^*	Gradiente canónico del funcional	Determina la cota de varianza	4
Eficiencia semiparamétrica	Eficiencia relativa	$\mathrm{Var}/\mathrm{Var}^*$	4
Inferencia y evaluación			
Test de hipótesis	Clasificación de políticas	$H_0 : V^\pi \leq V^{\pi_0}$	4
Intervalo de confianza	IC para V^π	Cuantificación de incertidumbre	8
Off-Policy Evaluation	Evaluación contrafactual	V^π desde datos de μ	7
Estimador DR	AIPW para MDPs	Robustez doble	7

Tabla E.1: Incrustación fiel Wald $\leftrightarrow$ MDP: correspondencias y su estatus

Propiedad Intelectual UCentral

Correspondencia de Estimadores

La siguiente tabla detalla los estimadores principales y sus análogos en el contexto de evaluación de políticas.

Estadística Clásica	OPE/RL	Expresión	Consulta
Media muestral $\bar{X}$	Monte Carlo	$\frac{1}{n}\sum_i G_i$	4
MLE $\hat{\theta}_{\text{ML}}$	MLE de P, r	$\arg\max \ell(\theta)$	4
Horvitz-Thompson	IPW	$\frac{1}{n}\sum_i \frac{\pi(a_i\|s_i)}{\mu(a_i\|s_i)} r_i$	7
Regresión ajustada	DM (Direct Method)	$\frac{1}{n}\sum_i \hat{Q}^\pi(s_i)$	7
AIPW	DR para V^π	$\hat{V}_{\text{DM}} + \hat{V}_{\text{IPW}} - \hat{V}_{\text{DM,IPW}}$	7
Rao-Blackwellizado	DR con $\hat{Q}$	Varianza reducida	4
Bootstrap percentil	Bootstrap para IC	$\left[\hat{V}^*_{\alpha/2}, \hat{V}^*_{1-\alpha/2}\right]$	4

Tabla E.2: Correspondencia de Estimadores

Correspondencia de Condiciones de Regularidad

La inferencia válida requiere condiciones de regularidad. La siguiente tabla las unifica entre los marcos.

Condición Clásica	Análogo OPE	Implicación
Soporte común	Overlap: $\pi \ll \mu$	$\mu(a\|s) > 0 \Rightarrow \pi(a\|s) > 0$
Identificabilidad	Positivity	Estimación factible
Regularidad de Fisher	Suavidad de Q, μ	CLT aplicable
Momentos finitos	$\mathbb{E}[\rho^2 r^2] < \infty$	Varianza finita de IPW
iid	Trayectorias independientes	Agregación válida
Estacionariedad	MDP estacionario	P, r constantes
Ergodicidad	Mixing del MDP	Convergencia de promedios

Tabla E.3: Condiciones de Regularidad

Nota E.1 (Catálogo A1–A5 para SZLS). La tabla anterior resume condiciones *genéricas*. Para el resultado ancla de la Parte III (Teorema 1 de SZLS, Capítulo 8), las condiciones precisas son **MA** (Markov), **CMIA** (independencia condicional en media), **A1** (suavidad Hölder), **A2** (distribución invariante), **A3** (invertibilidad de Σ_π; ergodicidad geométrica *solo si* $T \to \infty$), **A4** (tasa de estima-

Dr. Jaime Ernesto Luna Lozoya

ción de política) y **A5** (margen). La ergodicidad es **prescindible** cuando T es acotado — el TLC de martingala de SZLS no la requiere en ese régimen. Ver Capítulo 8, §11.2 para el enunciado formal.

Correspondencia de Cotas y Tasas

Cota/Tasa	Expresión	Contexto OPE	Consulta
Cramér-Rao	$\mathrm{Var}\left(\hat{\theta}\right) \geq I(\theta)^{-1}$	Cota para $\mathrm{Var}\left(\hat{V}^{\pi}\right)$	4
Eficiencia semiparam.	$\mathrm{Var}^{*} = \mathbb{E}[\varphi^{*2}]$	Varianza mínima DR	4
Tasa paramétrica	$O\left(n^{-1/2}\right)$	Consistencia $\sqrt{n}$	4
Tasa no paramétrica	Depende de norma, suavidad y modelo	No hay una tasa universal	4
Tasa DML	Producto de errores $o_{P\left(n^{-\frac{1}{2}}\right)}$	Más consistencia, momentos y partición válida	8

Tabla E.4: Cotas de Eficiencia y Tasas de Convergencia

Glosario de Términos

Admisibilidad Una regla de decisión δ es admisible si no existe otra regla δ' que la domine uniformemente en riesgo.

AIPW *Augmented Inverse Probability Weighting*. Estimador que combina IPW con un modelo de regresión, logrando robustez doble.

«Bellman, Operador de» Operador $\mathcal{T}$ definido por $(\mathcal{T}V)(s) = \max_a \left[r(s,a) + \gamma \sum_{s'} P(s'|s,a)V(s')\right]$. Su punto fijo es V^{*}.

«Clase Completa» Conjunto de reglas de decisión tal que para cualquier regla fuera del conjunto existe una dentro que la domina.

Completitud Un estadístico T es completo si $\mathbb{E}_{\theta}[g(T)] = 0$ para todo θ implica $g(T) = 0$ c.s.

«Cramér-Rao, Cota de» Cota inferior para la varianza de estimadores insesgados: $\mathrm{Var}\left(\hat{\theta}\right) \geq I(\theta)^{-1}$.

Cross-fitting Técnica de partición de datos para estimar funciones auxiliares fuera del fold evaluado. Facilita el control empírico, pero no elimina todo sobreajuste ni sustituye hipótesis de tasas e independencia.

DML *Double/Debiased Machine Learning*. Marco para inferencia válida usando estimadores de ML para funciones nuisance.

DR *Doubly Robust*. Propiedad de consistencia bajo especificación correcta de al menos uno de dos modelos.

«Eficiencia Semiparamétrica» Lograr la cota de varianza mínima dentro de la clase de estimadores regulares asintóticamente lineales.

«Función de Influencia» Derivada funcional del funcional estadístico, caracteriza el comportamiento asintótico del estimador.

IPW *Inverse Probability Weighting*. Reponderar observaciones por el inverso de la probabilidad de tratamiento/acción.

«Isomorfismo (en este libro)» Incrustación fiel que preserva operaciones entre dos sistemas matemáticos; en el caso Wald–MDP, demostrada para el subcaso de un paso y determinista (Teorema 5.3), con la generalización estocástica como problema abierto (Nota Nota 5.4).

MDP *Markov Decision Process*. Modelo de decisión secuencial con estados, acciones, transiciones y recompensas.

«Neyman-Pearson, Lema de» El test de razón de verosimilitudes es más potente al contrastar una hipótesis simple contra otra simple, al nivel fijado.

OPE *Off-Policy Evaluation*. Estimar el valor de una política usando datos generados por otra política.

«Ortogonalidad de Neyman» Anulación de la derivada poblacional del momento respecto de los auxiliares en la verdad. Transferirla al estimador requiere una expansión y control del resto.

Overlap Condición de que el soporte de la política objetivo esté contenido en el de la política de comportamiento.

«Rao-Blackwell, Teorema de» Condicionar un estimador insesgado a un estadístico suficiente reduce (o mantiene) la varianza.

Suficiencia Un estadístico $T(X)$ es suficiente para θ si la distribución condicional de $X \mid T$ no depende de θ.

UMVUE *Uniformly Minimum Variance Unbiased Estimator*. Estimador insesgado con mínima varianza para todo θ.

«Valor, Función de» $V^\pi(s) = \mathbb{E}^\pi\left[\sum_{t=0}^{\infty} \gamma^t r_t \;\middle|\; s_0 = s\right]$. Retorno esperado descontado bajo política π.

«Wald, Teoría de Decisión de» Marco formal que unifica inferencia estadística como problema de decisión con pérdidas, riesgos y reglas de decisión.

Índice de Notación por Capítulo

La Tabla E.5 indica dónde se introduce cada símbolo principal.

Símbolo	Significado	Consulta	Sección
Θ	Espacio paramétrico	4	4.1.1
$\mathcal{X}$	Espacio muestral	4	4.1.1
$T(X)$	Estadístico suficiente	4	4.1.8
$\hat{\theta}$	Estimador puntual	4	4.2.1

Símbolo	Significado	Consulta	Sección
$I(\theta)$	Información de Fisher	4	4.2.4
φ_α	Función de test	4	4.3.1
φ^*	IF eficiente	4	4.5.4
$L(\theta, a)$	Función de pérdida	2	2.1.1
$R(\theta, \delta)$	Función de riesgo	2	2.1.2
$\mathcal{S}$	Espacio de estados MDP	3	3.1.1
V^π	Función de valor	3	3.1.2
$\mathcal{T}$	Operador de Bellman	3	3.1.4
Ψ : Wald $\to$ MDP	Incrustación fiel	5	5.1.2
ρ	Importance ratio	7	7.1.4
$\hat{V}_{\mathrm{DR}}$	Estimador DR	7	7.1.7

Tabla E.5: Primera Aparición de Símbolos

Catálogo de Datasets Utilizados

Esta sección centraliza los conjuntos de datos reales empleados en los ejemplos del texto, con información sobre su procedencia, tamaño y forma de acceso reproducible. Todos los datasets son de uso público; ninguno contiene información de identificación personal en la forma en que se utiliza aquí.

Dataset	Consulta	Ejemplo	n	Fuente / Acceso
NASA CMAPSS Turbofan (FD001)	4	4.71	20,631	`kaggle.com/datasets/behrad3d/nasa-cmaps`
UCI Heart Disease (Cleveland)	4, 4	4.13, 4.84	303	`archive.ics.uci.edu/dataset/45`
California Housing	4	4.84	20,640	`sklearn.datasets.fetch_california_housing()`
UCI Auto MPG	4	4.108	398	`archive.ics.uci.edu/dataset/9`
NHANES 2017–2018	4	4.113	5,769	`wwwn.cdc.gov/nchs/nhanes/continuousnhanes/`
NHEFS (Hernán & Robins)	4	4.127	1,566	`hsph.harvard.edu/miguel-hernan/causal-inference-book/`
Haberman's Survival	4	4.126	306	`archive.ics.uci.edu/dataset/43`

Dataset	Consulta	Ejemplo	n	Fuente / Acceso
FrozenLake-v1 (Gymnasium)	3	3.32	—	`gymnasium.farama.org/environments/toy_text/frozen_lake/`
S&P 500 (FRED: SP500)	8	8.1	5,781	`fred.stlouisfed.org/series/SP500`

Tabla E.6: Catálogo de datasets utilizados en la monografía.

Fragmentos de carga en Python

Los siguientes fragmentos reproducen la carga de cada dataset de forma exacta. Se asume `pandas`, `numpy` y, donde se indica, `sklearn` o `gymnasium` ≥ 0.26.

```
import pandas as pd
cols = ['unit','cycle','os1','os2','os3'] + \
      [f's{i}' for i in range(1,22)]
df = pd.read_csv('train_FD001.txt', sep=r'\s+',
                 header=None, names=cols)
# RUL = ciclo maximo - ciclo actual por unidad
df['RUL'] = df.groupby('unit')['cycle'] \
              .transform('max') - df['cycle']
```

Listado 16: NASA CMAPSS Turbofan FD001.

```
import pandas as pd
url = ('https://archive.ics.uci.edu/ml/machine-learning-databases'
       '/heart-disease/processed.cleveland.data')
cols = ['age','sex','cp','trestbps','chol','fbs','restecg',
        'thalach','exang','oldpeak','slope','ca','thal','target']
df = pd.read_csv(url, header=None, names=cols, na_values='?')
df['target'] = (df['target'] > 0).astype(int)
```

Listado 17: UCI Heart Disease (Cleveland).

```
import pandas as pd
url = ('https://archive.ics.uci.edu/ml/machine-learning-databases'
       '/auto-mpg/auto-mpg.data')
df = pd.read_csv(url, sep=r'\s+', header=None, na_values='?',
    names=['mpg','cylinders','displacement','horsepower',
           'weight','acceleration','model_year','origin','name'])
df.dropna(inplace=True)  # elimina 6 filas con HP faltante
```

Listado 18: UCI Auto MPG.

```
import pandas as pd
url_demo = ('https://wwwn.cdc.gov/Nchs/Nhanes/2017-2018'
            '/DEMO_J.XPT')
url_bpx  = ('https://wwwn.cdc.gov/Nchs/Nhanes/2017-2018'
            '/BPX_J.XPT')
demo = pd.read_sas(url_demo, format='xport', encoding='utf-8')
bpx  = pd.read_sas(url_bpx,  format='xport', encoding='utf-8')
df = demo[['SEQN','RIAGENDR']].merge(
        bpx[['SEQN','BPXSY1']], on='SEQN').dropna()
```

Listado 19: NHANES 2017–2018 (presion sistolica).

```
import pandas_datareader.data as web
import datetime
sp500 = web.DataReader('SP500', 'fred',
                       datetime.date(2000,1,3),
                       datetime.date(2023,12,29))
ret = sp500['SP500'].pct_change().dropna()  # n = 5781
```

Listado 20: S&P 500 via FRED.

```
import gymnasium as gym
import numpy as np

env = gym.make('FrozenLake-v1', is_slippery=True,
               render_mode=None)
nS, nA = env.observation_space.n, env.action_space.n

def value_iteration(env, gamma=0.99, tol=1e-8):
    V = np.zeros(nS)
    for _ in range(10_000):
        V_new = np.array([
            max(sum(p*(r + gamma*V[s_])
                    for p,s_,r,_ in env.P[s][a])
                for a in range(nA))
            for s in range(nS)])
        if np.max(np.abs(V_new - V)) < tol:
            break
        V = V_new
    return V

np.random.seed(42)
V_star = value_iteration(env)
```

Listado 21: FrozenLake-v1 (Gymnasium).

Notas éticas y advertencias

- **NHANES:** Los microdatos públicos de NHANES no contienen identificadores directos; el acceso a datos enlazados con mortalidad requiere un *research data center* (RDC) de los CDC.
- **NHEFS:** El dataset de Hernán & Robins es de libre descarga con fines educativos; citar Hernán & Robins (2020) al reutilizarlo.
- **Boston Housing:** Este dataset *no* se utiliza en la monografía dado que contiene una variable proxy de raza (`B`) cuya inclusión es éticamente problemática. Se usó California Housing como alternativa limpia.
- **NASA CMAPSS:** Datos sintéticos de simulación; no representan fallos reales de motores individuales ni información propietaria.

Licencia Lincovil Cerrada

Apéndice F

Condiciones de Regularidad y Mixing

La dependencia temporal cambia la forma de acumular información y de estimar la varianza. Las condiciones de este apéndice permiten seguir ese cambio cuando se trabaja con una trayectoria, en relación con el Capítulo 6 y el Capítulo 8. Sus definiciones y resultados se consultan junto con el proceso y el estimador para los que se formula cada conclusión.

Definiciones de Mixing

Definición F.1 (α-Mixing (Strong Mixing)). Sea $\{X_t\}_{t\in\mathbb{Z}}$ un proceso estocástico. Para $k \geq 1$, definimos:

$$\alpha(k) = \sup_{t\in\mathbb{Z}} \sup_{\substack{A\in\mathcal{F}_{-\infty}^{t} \\ B\in\mathcal{F}_{t+k}^{\infty}}} |P(A\cap B) - P(A)P(B)|$$

donde $\mathcal{F}_a^b = \sigma(X_a, X_{a+1}, ..., X_b)$.

El proceso es α-*mixing* si $\alpha(k) \to 0$ cuando $k \to \infty$.

Definición F.2 (β-Mixing (Absolute Regularity)).

$$\beta(k) = \sup_{t\in\mathbb{Z}} \mathbb{E}\left[\sup_{B\in\mathcal{F}_{t+k}^{\infty}} |P(B \mid \mathcal{F}_{-\infty}^{t}) - P(B)|\right]$$

El proceso es β-*mixing* si $\beta(k) \to 0$.

Definición F.3 (ϕ-Mixing (Uniform Mixing)).

$$\phi(k) = \sup_{t\in\mathbb{Z}} \sup_{\substack{A\in\mathcal{F}_{-\infty}^{t}, P(A)>0 \\ B\in\mathcal{F}_{t+k}^{\infty}}} |P(B|A) - P(B)|$$

Proposición F.4 (Relaciones entre Coeficientes). *Para todo proceso estocástico:*

$$2\alpha(k) \leq \beta(k) \leq \phi(k)$$

Por tanto: ϕ-mixing $\Rightarrow$ β-mixing $\Rightarrow$ α-mixing.

Tasas de Decaimiento

Definición F.5 (Mixing Geométrico). Un proceso tiene *mixing geométrico* si existen $C > 0$ y $\rho \in (0, 1)$ tales que:

$$\alpha(k) \leq C \cdot \rho^k \quad \forall k \geq 1$$

Equivalentemente: $\alpha(k) = O\left(e^{-\lambda k}\right)$ para algún $\lambda > 0$.

Dr. Laurel Linkovich Curiel

Definición F.6 (Mixing Polinomial). Un proceso tiene *mixing polinomial de orden ν* si:

$$\alpha(k) = O(k^{-\nu}) \quad \text{para algún} \quad \nu > 0$$

Tipo de Mixing	Tasa	CLT Válido?	IC Válidos?
Geométrico	$\alpha(k) \leq C\rho^k$	Con momento $2+\delta$	Más varianza positiva y consistente
Polinomial	$\nu \frac{\delta}{2+\delta} > 1$	Con momento $2+\delta$	Más studentización válida
Condición no satisfecha	Sin sumabilidad suficiente	Este teorema no decide	Requiere otra justificación
Sin mixing	$\alpha(k) \nrightarrow 0$	Puede existir otro CLT	Requiere otra justificación

Tabla F.1: Tasas de Mixing y sus Implicaciones para Inferencia

Condiciones para MDPs Ergódicos

Teorema F.7 (Ergodicidad Geométrica de Cadenas de Markov). *Sea $\{S_t\}$ una cadena de Markov con espacio de estados finito $\mathcal{S}$, matriz de transición P, y distribución estacionaria μ. Si la cadena es* irreducible *y* aperiódica*, entonces:*

1. *La cadena es geométricamente ergódica:*

$$\left\|P^k(s,\cdot) - \mu(\cdot)\right\|_{\text{TV}} \leq C(s) \cdot \rho^k$$

   para algún $\rho \in (0,1)$ y constante $C(s)$ dependiente del estado inicial.
2. *En régimen estacionario, el proceso es geométricamente β-mixing (y por tanto α-mixing).*

Corolario F.8 (MDPs con Estados Finitos). *Para un MDP $(\mathcal{S}, \mathcal{A}, P, r, \gamma)$ con $|\mathcal{S}| < \infty$ y $|\mathcal{A}| < \infty$, bajo cualquier política estacionaria π que induzca una cadena irreducible y aperiódica, con inicio estacionario, asignación de acciones mediante aleatorización fresca y recompensas generadas por el kernel Markov del modelo, el proceso (S_t, A_t, R_t) es geométricamente α-mixing. Ruido persistente no incluido en el estado requiere otro análisis.*

Proposición F.9 (Verificación de Irreducibilidad). *Una cadena inducida por política π en MDP es irreducible si:*

1. *$\forall s, s' \in \mathcal{S}$, existe secuencia de acciones con probabilidad positiva bajo π que conecta s con s'.*
2. *Equivalentemente: el grafo dirigido con aristas (s, s') donde $\sum_a \pi(a|s)P(s'|s,a) > 0$ es fuertemente conexo.*

Proposición F.10 (Verificación de Aperiodicidad). *Para una cadena irreducible, el período es común a todos los estados. Un estado con $P(s,s) > 0$ implica período uno para toda la cadena. En general el período de s es $\gcd\{k \geq 1 : P^k(s,s) > 0\}$. Sin irreducibilidad, una clase con auto-bucle no elimina el período de otras clases; hay que examinar las clases pertinentes.*

CLT bajo Dependencia Temporal

Teorema F.11 (CLT de Ibragimov para Procesos α-Mixing). *Sea $\{X_t\}$ un proceso estacionario α-mixing con $\mathbb{E}[X_t] = 0$. Supongamos que:*

1. $\mathbb{E}\big[|X_t|^{2+\delta}\big] < \infty$ *para algún* $\delta > 0$
2. $\sum_{k=1}^{\infty} \alpha(k)^{\delta/(2+\delta)} < \infty$

Entonces:

$$\frac{1}{\sqrt{n}} \sum_{t=1}^{n} X_t \xrightarrow{d} N(0, \sigma_{\mathrm{LR}}^2)$$

donde la varianza de largo plazo *es:*

$$\sigma_{\mathrm{LR}}^2 = \mathrm{Var}(X_0) + 2 \sum_{k=1}^{\infty} \mathrm{Cov}(X_0, X_k)$$

Corolario F.12 (Condición Suficiente para MDPs). *Para MDPs con estados finitos y mixing geométrico ($\alpha(k) \le C\rho^k$), la condición (2) del Teorema F.11 se satisface automáticamente para cualquier $\delta > 0$:*

$$\sum_{k=1}^{\infty} \big(C\rho^k\big)^{\delta/(2+\delta)} = C^{\delta/(2+\delta)} \sum_{k=1}^{\infty} \rho^{k\delta/(2+\delta)} < \infty$$

Teorema F.13 (CLT funcional para una cadena finita). *Sea S_t una cadena finita irreducible y aperiódica, iniciada en su ley estacionaria μ, y f una función real con $\mathbb{E}_{\mu[f]} = 0$. Entonces, en $D[0,1]$ con la topología de Skorokhod,*

$$n^{-\frac{1}{2}} \sum_{t=1}^{\lfloor nu \rfloor} f(S_t) \xrightarrow{d} \sigma W(u),$$

con $\sigma^2 = \sum_{k\in\mathbb{Z}} \mathrm{Cov}(f(S_0), f(S_k))$. Un argumento suficiente usa la ecuación de Poisson $h - Ph = f$, cuya solución centrada existe en esta cadena finita. Se escribe

$$\sum_{t=1}^{n} f(S_t) = \sum_{t=1}^{n} (h(S_t) - Ph(S_{t-1})) + Ph(S_0) - Ph(S_n).$$

Los sumandos son diferencias de martingala acotadas. Ergodicidad hace converger la variación cuadrática condicional normalizada; el CLT funcional de martingalas da el límite y el término de borde es uniformemente despreciable. Es un caso concreto de aproximación de martingalas. Un CLT escalar, por sí solo, no prueba un límite funcional: también se necesita tightness.

Estimación de la Varianza de Largo Plazo

Definición F.14 (Estimador HAC de Newey-West). El estimador HAC (Heteroskedasticity and Autocorrelation Consistent) es:

$$\hat{\sigma}_{\mathrm{HAC}}^2 = \hat{\gamma}_0 + 2 \sum_{k=1}^{K_n} w(k/K_n) \hat{\gamma}_k$$

donde:
- $\hat{\gamma}_k = \frac{1}{n} \sum_{t=k+1}^{n} (X_t - \bar{X})(X_{t-k} - \bar{X})$
- $w(\cdot)$ es un kernel (Bartlett: $w(x) = 1 - x$ para $x \in [0,1]$)
- K_n es el bandwidth (ancho de banda)

Teorema F.15 (Consistencia del Estimador HAC). *Para el kernel de Bartlett, suponga una serie estrictamente estacionaria con segundo momento finito, autocovarianzas absolutamente sumables, $K_n \to \infty$, $\frac{K_n}{n} \to 0$ y*

$$\sum_{k=0}^{K_n} |\hat{\gamma}_k - \gamma_k| \xrightarrow{P} 0.$$

Entonces $\hat{\sigma}^2_{\mathrm{HAC}} \xrightarrow{P} \sigma^2_{\mathrm{LR}}$. *La prueba separa el error de estimación, la cola omitida y el sesgo de ponderación, como en Proposición 8.12. La condición agregada de covarianzas debe demostrarse para el proceso. Mixing geométrico y una cota superior* $K_n = O\left(n^{\frac{1}{3}}\right)$ *no bastan: esa cota permite incluso un ancho fijo y no especifica momentos ni control empírico.*

Nota F.16 (Selección de Bandwidth). El ancho se elige dentro de las condiciones del resultado usado. $K_n = \left\lfloor n^{\frac{1}{3}} \right\rfloor$ es una secuencia candidata, no una garantía universal de consistencia. Las reglas plug-in de Andrews dependen del kernel y de una estimación de cantidades espectrales; no se reducen a elevar la autocorrelación de primer orden a un tercio. Debe justificarse también una selección aleatoria realizada con los datos.

Tabla de Referencia: Ambiente → Condiciones → Garantías

Tipo de MDP	Condiciones	Mixing	Garantías
Tabular, finito	Inicio estacionario; irreducible y aperiódico	Geométrico	CLT con momentos; IC con varianza válida
Con absorción	Diseño episódico o transitorio explícito	No se deduce	Analizar unidades y horizonte
Lineal (LQR)	Estabilidad más condiciones del ruido	Requiere prueba	Momentos y estimador específicos
Con aprox. funciones	Contracción en espacio de funciones	Depende	Condicional
POMDP	Filtro estable	Puede fallar	Verificar
No estacionario	—	No aplica	No transferir

Tabla F.2: Condiciones Requeridas por Tipo de Ambiente

Los coeficientes de dependencia describen propiedades de la ley del proceso. Los diagnósticos de una muestra aportan evidencia parcial sobre ella. Esa diferencia debe conservarse al interpretar la tabla y al elegir el procedimiento de incertidumbre.

Propiedad Intelectual

Apéndice G

Reproducibilidad del estudio de simulación de Shi et al.

Los laboratorios del Capítulo 10 comprueban cálculos en escenarios definidos para la exposición. Este apéndice plantea una tarea diferente: reproducir el estudio de simulación de Shi et al. (2022) mediante la implementación pública de `SAVE`. El diseño y los requisitos de ejecución se registran a continuación; las definiciones por completar y los resultados todavía no obtenidos se señalan junto a sus tablas.

El experimento que se propone reproducir

El estudio original ilustra su método sobre datos reales de monitoreo continuo de glucosa: el conjunto OhioT1DM, con seis pacientes, ocho semanas de registro, intervalos de tres horas, estado tridimensional, acción binaria según las unidades de insulina administradas, recompensa definida por el **Index of Glycemic Control** Rodbard (2009) y factor de descuento $\gamma = 0.5$.

Ese conjunto de datos no es de acceso libre: su uso exige un acuerdo con la institución que lo mantiene. Por eso este libro no lo reanaliza, y la reproducción propuesta se concentra en el estudio de simulación de los mismos autores. Sus resultados deberán obtenerse con el proceso generador de datos y el entorno de ejecución documentados.

Diseño del experimento

Definición G.1 (Grilla experimental de la replicación). Sea n el número de trayectorias por réplica y T el horizonte de cada trayectoria. La replicación recorre la grilla

$$n \in \{25, 50, 100\} \times T \in \{30, 50, 70\},$$

con factor de descuento $\gamma = 0.5$ y, para cada configuración (n, T), ancho de banda

$$L = \lfloor (nT)^{3/7} \rfloor.$$

Para cada celda de la grilla se reportan las métricas de la Sección G.4 sobre las réplicas de Monte Carlo de cada escenario.

$$L = \lfloor (nT)^{3/7} \rfloor$$

es la tasa de la ventana que el artículo usa para los estimadores basados en funciones de influencia truncadas: crece con el tamaño de la muestra pero más despacio que nT, que es lo que permite el intercambio entre sesgo y varianza que el Capítulo 8 analiza.

Escenarios

El artículo evalúa su procedimiento en tres escenarios de simulación —A, B y C— que difieren en la forma del núcleo de transición y en el grado de dependencia temporal.

PENDIENTE — Las definiciones de los escenarios A, B y C de la fuente primaria no se transcriben aquí porque no han sido verificadas línea por línea. Deben copiarse de la fuente antes de reportar cifras: sin la definición exacta del proceso generador de datos, una tabla de resultados no es replicable.

Métricas

Tres métricas, evaluadas sobre el número de réplicas de Monte Carlo de cada celda:

- **ECP** (**empirical coverage probability**): proporción de réplicas en que el intervalo de confianza nominal cubre el valor verdadero de la función de valor. Es la métrica de validez: debe acercarse al nivel nominal.
- **AL** (**average length**): longitud media del intervalo de confianza. Es la métrica de precisión: sin ella, una cobertura alta puede lograrse trivialmente ensanchando el intervalo.
- **log(MSE)**: logaritmo del error cuadrático medio del estimador puntual, promediado sobre réplicas. Es la métrica de eficiencia.

PENDIENTE — Verificar contra la fuente primaria la definición exacta de las tres métricas y el número de réplicas de Monte Carlo por celda (el rango de la grilla (n, T) está fijado arriba; el número de réplicas no). Falta implementar y ejecutar el cálculo con esas definiciones fijadas.

Resultados

PENDIENTE — Las tres tablas siguientes registran la grilla prevista. Sus celdas se completarán con resultados de una ejecución reproducible, una vez fijadas las definiciones y la implementación del experimento.

n	T	ECP	AL	log(MSE)
25	30	–	–	–
25	50	–	–	–
25	70	–	–	–
50	30	–	–	–
50	50	–	–	–
50	70	–	–	–
100	30	–	–	–
100	50	–	–	–

n	T	ECP	AL	log(MSE)
100	70	–	–	–

Tabla G.1: Escenario A: ECP, AL y log(MSE) por configuración (n, T). Celdas «–»: resultados aún no obtenidos.

n	T	ECP	AL	log(MSE)
25	30	–	–	–
25	50	–	–	–
25	70	–	–	–
50	30	–	–	–
50	50	–	–	–
50	70	–	–	–
100	30	–	–	–
100	50	–	–	–
100	70	–	–	–

Tabla G.2: Escenario B: ECP, AL y log(MSE) por configuración (n, T). Celdas «–»: resultados aún no obtenidos.

n	T	ECP	AL	log(MSE)
25	30	–	–	–
25	50	–	–	–
25	70	–	–	–
50	30	–	–	–
50	50	–	–	–
50	70	–	–	–
100	30	–	–	–
100	50	–	–	–
100	70	–	–	–

Tabla G.3: Escenario C: ECP, AL y log(MSE) por configuración (n, T). Celdas «–»: resultados aún no obtenidos.

Lectura de las tablas. Un procedimiento correcto muestra ECP cercano al nivel nominal con AL que decrece en nT y log(MSE) decreciente en nT. Las tres columnas se leen juntas: la validez (ECP) es condición necesaria, la precisión (AL) distingue entre procedimientos válidos y la eficiencia (log(MSE)) decide entre ellos. El Capítulo 8 da las garantías asintóticas que estas tablas deben exhibir en muestras finitas.

Esqueleto de código

Dr. Jaime Rivoli Curivil

Esqueleto del script de la replicación (`apendices/codigo_replicacion/replicacion_save.py`). Las funciones marcadas `NotImplementedError` dependen de los marcadores pendientes de este apéndice.

```
"""Esqueleto de la replicación del estudio de simulación de Shi et al. (Ap. G).

ESTADO: esqueleto (2026-10-13). No contiene definiciones de escenarios ni
resultados: los generadores A/B/C se copian de la fuente primaria antes de
la primera corrida (ver #pendiente de §Escenarios).
Implementación de referencia: SAVE (licencia MIT), commit fijado en
FUENTES.md / REGISTRO_DIARIO.md (2026-10-13).
"""
import math
import numpy as np

N_GRID = (25, 50, 100)        # trayectorias por réplica (def:appG-grid)
T_GRID = (30, 50, 70)         # horizonte (def:appG-grid)
GAMMA = 0.5                   # factor de descuento (def:appG-grid)
N_REPLICAS = None             # por verificar en la fuente primaria
ESCENARIOS = ("A", "B", "C")


def ancho_banda(n: int, T: int) -> int:
    """L = floor((nT)^(3/7)) (def:appG-grid)."""
    return math.floor((n * T) ** (3 / 7))


def generar_datos(escenario: str, n: int, T: int, rng: np.random.Generator):
    """Proceso generador del escenario. Por copiar de la fuente."""
    raise NotImplementedError("Escenarios A/B/C no transcritos (Ap. G
§Escenarios)")


def valor_verdadero(escenario: str, gamma: float = GAMMA) -> float:
    """Valor verdadero de la política objetivo (Monte Carlo largo)."""
    raise NotImplementedError


def estimar_ic_save(datos, L: int, gamma: float = GAMMA, alpha: float = 0.05):
    """Llamada a la implementación pública de SAVE (src/AGENT.py)."""
    raise NotImplementedError


def metricas(ics, estimaciones, v_true):
    """ECP, AL y log(MSE) (§Métricas). Definición exacta: por verificar en la
fuente."""
    raise NotImplementedError


def correr_celda(escenario: str, n: int, T: int, semilla: int):
    rng = np.random.default_rng(semilla)
    L = ancho_banda(n, T)
    ...  # bucle de réplicas: generar_datos -> estimar_ic_save -> metricas


if __name__ == "__main__":
```

```
    for esc in ESCENARIOS:
        for n in N_GRID:
            for T in T_GRID:
                print(esc, n, T, "L =", ancho_banda(n, T))
```

Requisitos de reproducibilidad

Para que la replicación sea verificable debe publicarse, junto con las tablas:

1. la implementación pública del método `SAVE` y su versión exacta;
2. las semillas de los generadores aleatorios de cada celda;
3. el tiempo de cómputo por celda;
4. el entorno de ejecución (versiones de lenguaje y de bibliotecas).

PENDIENTE — Falta fijar la **versión exacta** de la implementación pública del método `SAVE`. El repositorio ya está verificado —el resumen del artículo remite a https://github.com/shengzhang37/SAVE—; lo que no puede fijarse sin ejecutar el experimento es el identificador de la versión con la que se corrieron los resultados. Debe registrarse antes de la primera ejecución.

Esp. Jaime Lincovil Curivil

Bibliografía

Auer, P., Cesa-Bianchi, N., & Fischer, P. (2002). Finite-time analysis of the multiarmed bandit problem. *Machine Learning*, *47*(2–3), 235-256. https://doi.org/10.1023/A:1013689704352

Bellman, R. (1957). *Dynamic Programming*. Princeton University Press.

Benjamini, Y., & Yekutieli, D. (2001). The Control of the False Discovery Rate in Multiple Testing under Dependency. *The Annals of Statistics*, *29*(4), 1165-1188. https://doi.org/10.1214/aos/1013699998

Bennett, A., Kallus, N., Oprescu, M., Sun, W., & Wang, K. (2024). Efficient and Sharp Off-Policy Evaluation in Robust Markov Decision Processes. *Advances in Neural Information Processing Systems (NeurIPS)*, *37*.

Berger, J. O. (1985). *Statistical Decision Theory and Bayesian Analysis* (2nd ed.). Springer. https://doi.org/10.1007/978-1-4757-4286-2

Bickel, P. J., Klaassen, C. A. J., Ritov, Y., & Wellner, J. A. (1993). *Efficient and Adaptive Estimation for Semiparametric Models*. Johns Hopkins University Press. https://doi.org/10.1007/978-1-4612--0899-7

Bradley, R. C. (2005). Basic Properties of Strong Mixing Conditions. A Survey and Some Open Questions. *Probability Surveys*, *2*. https://doi.org/10.1214/154957805100000104

Casella, G., & Berger, R. L. (2002). *Statistical Inference* (2nd ed.). Duxbury Press. https://doi.org/10.1201/9781420057669

Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/Debiased Machine Learning for Treatment and Structural Parameters. *The Econometrics Journal*, *21*(1), C1-C68. https://doi.org/10.1111/ectj.12097

Duchi, J. C., & Namkoong, H. (2021). Learning models with uniform performance via distributionally robust optimization. *The Annals of Statistics*, *49*(3), 1378-1406. https://doi.org/10.1214/20-AOS2004

Dudík, M., Langford, J., & Li, L. (2011). Doubly Robust Policy Evaluation and Learning. *Proceedings of the 28th International Conference on Machine Learning (ICML)*, 1097-1104. https://doi.org/10.1145/3106426.3106468

Efron, B., & Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall. https://doi.org/10.1007/978-1-4899-4541-9

Ferguson, T. S. (1967). *Mathematical Statistics: A Decision Theoretic Approach*. Academic Press. https://doi.org/10.1016/B978-0-12-257650-3.50001-3

Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A., & Rubin, D. B. (2013). *Bayesian Data Analysis* (3.ª ed.). CRC Press.

Gretton, A., Borgwardt, K. M., Rasch, M. J., Schölkopf, B., & Smola, A. (2012). A Kernel Two-Sample Test. *Journal of Machine Learning Research*, *13*, 723-773.

Hall, P. (1992). *The Bootstrap and Edgeworth Expansion*. Springer. https://doi.org/10.1007/978-1--4612-4384-7

Hernán, M. A., & Robins, J. M. (2020). *Causal Inference: What If*. Chapman & Hall/CRC. https://doi.org/10.1201/9781420057669

Jiang, N., & Li, L. (2016). Doubly Robust Off-policy Value Evaluation for Reinforcement Learning. *Proceedings of the 33rd International Conference on Machine Learning (ICML)*, 652-661.

Kallus, N., & Uehara, M. (2020). Double Reinforcement Learning for Efficient Off-Policy Evaluation in Markov Decision Processes. *Journal of Machine Learning Research*, *21*(167), 1-63. http://jmlr.org/papers/v21/19-827.html

Kallus, N., & Uehara, M. (2022). Efficiently Breaking the Curse of Horizon in Off-Policy Evaluation with Double Reinforcement Learning. *Operations Research*, *70*(6), 3282-3302. https://doi.org/10.1287/opre.2021.2249

Kennedy, E. H. (2017,). *Semiparametric Theory*. https://arxiv.org/abs/1709.06418

Kennedy, E. H. (2022). Semiparametric Doubly Robust Targeted Double Machine Learning: A Review. *arXiv preprint arXiv:2203.06469*.

Künsch, H. R. (1989). The jackknife and the bootstrap for general stationary observations. *Annals of Statistics*, *17*(3), 1217-1241. https://doi.org/10.1214/aos/1176347265

Lai, T. L., & Robbins, H. (1985). Asymptotically efficient adaptive allocation rules. *Advances in Applied Mathematics*, *6*(1), 4-22. https://doi.org/10.1016/0196-8858(85)90002-8

Lattimore, T., & Szepesvári, C. (2020). *Bandit Algorithms*. Cambridge University Press. https://doi.org/10.1017/9781108571401

Lehmann, E. L., & Casella, G. (1998). *Theory of Point Estimation* (2nd ed.). Springer. https://doi.org/10.1007/b98854

Lehmann, E. L., & Romano, J. P. (2005). *Testing Statistical Hypotheses* (3rd ed.). Springer. https://doi.org/10.1007/0-387-27605-X

Liu, Q., Li, L., Tang, Z., & Zhou, D. (2018). Breaking the Curse of Horizon: Infinite-Horizon Off-Policy Estimation. *Advances in Neural Information Processing Systems (NeurIPS)*, *31*, 5356-5366. https://doi.org/10.48550/arXiv.1810.12429

Mehrabi, M., & Wager, S. (2024). Off-Policy Evaluation in Markov Decision Processes under Weak Distributional Overlap. *arXiv preprint arXiv:2402.08201*. https://doi.org/10.48550/arXiv.2402.08201

Miao, R., Qi, Z., & Zhang, X. (2022). Off-Policy Evaluation for Episodic Partially Observable Markov Decision Processes under Non-Parametric Models. *Advances in Neural Information Processing Systems (NeurIPS)*, *35*.

Newey, W. K., & West, K. D. (1987). A Simple, Positive Semi-Definite, Heteroskedasticity and Autocorrelation Consistent Covariance Matrix. *Econometrica*, *55*(3), 703. https://doi.org/10.2307/1913610

Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2nd ed.). Cambridge University Press. https://doi.org/10.1017/CBO9780511803161

Precup, D., Sutton, R. S., & Singh, S. P. (2000). Eligibility Traces for Off-Policy Policy Evaluation. *Proceedings of the 17th International Conference on Machine Learning (ICML)*, 759-766.

Puterman, M. L. (2005). *Markov Decision Processes: Discrete Stochastic Dynamic Programming* (2nd ed.). John Wiley & Sons. https://doi.org/10.1002/9780470316887

Quiñonero-Candela, J., Sugiyama, M., Schwaighofer, A., & Lawrence, N. D. (eds.). (2009). *Dataset Shift in Machine Learning*. MIT Press.

Rodbard, D. (2009). Interpretation of Continuous Glucose Monitoring Data: Glycemic Variability and Quality of Glycemic Control. *Diabetes Technology & Therapeutics*, *11*, S55.

Shi, C., Zhang, S., Lu, W., & Song, R. (2022). Statistical Inference of the Value Function for Reinforcement Learning in Infinite Horizon Settings. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, *84*(3), 765-793. https://doi.org/10.1111/rssb.12465

Shi, C., Zhu, J., Shen, Y., Luo, S., Zhu, H., & Song, R. (2024). Off-Policy Confidence Interval Estimation with Confounded Markov Decision Process. *Journal of the American Statistical Association*, *119*(545), 273-284. https://doi.org/10.1080/01621459.2022.2110878

Sugiyama, M., & Kawanabe, M. (2012). *Machine Learning in Non-Stationary Environments: Introduction to Covariate Shift Adaptation*. MIT Press.

Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2nd ed.). MIT Press. https://doi.org/10.5555/3312046

Thomas, P. S., Theocharous, G., & Ghavamzadeh, M. (2015). High Confidence Off-Policy Evaluation. *Proceedings of the 29th AAAI Conference on Artificial Intelligence*, 3000-3006.

Tsiatis, A. A. (2006). *Semiparametric Theory and Missing Data*. Springer. https://doi.org/10.1007/0--387-37345-4

van der Vaart, A. W. (1998). *Asymptotic Statistics*. Cambridge University Press. https://doi.org/10.1017/CBO9780511802256

Wald, A. (1950). *Statistical Decision Functions*. John Wiley & Sons. https://doi.org/10.1007/978-1--4612-0919-5

Universidad Curivil