APERTURA

Dos preguntas sobre una decisión

Tras observar una medición, una regla elige una acción.

Pregunta Wald: ¿qué pérdida produce la regla bajo cada modelo posible?

Pregunta Bellman: ¿cómo cambia la acción las consecuencias futuras?

Notas docentes · Pedir dos ejemplos: una decisión terminal y otra que altera visitas futuras. Mantener fija la información observada en ambas. 5 min.

OBJETIVOS

Resultados de aprendizaje

1. Calcular el vector de riesgo de una regla.
2. Construir su MDP terminal y demostrar $J_\theta = -R_\theta$.
3. Resolver un paso de observación y parada mediante posterior.
4. Delimitar qué inferencia estadística requiere datos y supuestos adicionales.

Notas docentes · Estos objetivos se comprobarán con un caso finito y un taller. 5 min.

RUTA

Secuencia de 180 minutos

Motivación y marcos	60 min
Caso Wald → MDP	30 min
Descanso	15 min
Observación/parada y taller	45 min
Discusión y cierre	30 min

Notas docentes · Apertura 15, desarrollo conceptual 45, caso 30, descanso 15, taller 45, discusión 20 y cierre 10. 5 min.

Wald: comparar procedimientos

Una estimación, un contraste y una recomendación pueden tratarse como reglas que transforman datos en acciones.

La distribución de X bajo θ determina con qué frecuencia incurre cada regla en pérdidas.

El resultado es una **función** de riesgo, no un único número sin criterio adicional.

Notas docentes · Introducir Wald 1950 a través de su problema, sin atribuir citas textuales no verificadas. 5 min.

Cinco objetos antes de comparar

Θ	modelos posibles
$\mathcal{X}$	observaciones
P_θ	ley de X bajo θ
$\mathcal{A}$	acciones
$L(\theta, a)$	pérdida

Notas docentes · Pedir que identifiquen cuál de los cinco objetos define la información disponible y cuál define preferencias. 5 min.

La regla y su riesgo

Una regla determinista $\delta : \mathcal{X} \to \mathcal{A}$ no puede usar el θ desconocido.

$$R(\theta, \delta) = \sum_x P_\theta(x) L(\theta, \delta(x)).$$

El riesgo promedia **antes** de conocer qué x se observará.

Notas docentes · Distinguir el valor de L en un caso observado del riesgo de la regla completa. 6 min.

Tres criterios, tres preguntas

Admisibilidad	¿Otra regla mejora el riesgo en todos los modelos?
Bayes	¿Qué regla minimiza el riesgo promediado por un prior?
Minimax	¿Qué regla minimiza el peor riesgo?

Ningún criterio se elige automáticamente por la forma de R.

Notas docentes · Pedir un caso donde Bayes y minimax prefieran reglas distintas; se verá con vectores de riesgo en clase 3. 5 min.

Bellman: la acción cambia el futuro

La programación dinámica separa el resultado presente del problema que queda después.

estado actual → acción → recompensa + estado siguiente

La decisión local depende del valor de continuación.

Notas docentes · Presentar Bellman 1957 como marco de planificación; no equiparar recompensa inmediata con retorno total. 5 min.

Objetos de un MDP

Un MDP especifica estados $\mathcal{S}$, acciones $\mathcal{A}$, transición $P(s'|s,a)$, recompensa $r(s,a)$ y horizonte o descuento.

Una política $\pi(a|s)$ puede depender del estado; $V^{\pi}(s)$ condiciona en el estado inicial.

Notas docentes · Preguntar qué pieza falta si solo se conoce una tabla de recompensas. 5 min.

Valor y continuación

Para una política fija y un modelo conocido:

$$V^{\pi}(s) = \sum_{a} \pi(a|s) \Big[r(s,a) + \gamma \sum_{s'} P(s'|s,a) V^{\pi}(s') \Big].$$

El segundo término incorpora lo que una decisión hace posible después.

Notas docentes · Leer la ecuación de izquierda a derecha. Aclarar que la fórmula por sí sola no estima P ni r desde datos. 6 min.

COMPARACIÓN

Dos marcos sobre la misma pregunta

Objeto	Wald	MDP
Información	X antes de actuar	S_t en cada decisión
Criterio	$R(\theta, \delta)$	$V^{\pi}(s)$ o $J(\pi)$
Dinámica	una acción terminal	transiciones y futuro

Notas docentes · La fila de Wald se refiere al problema terminal enseñado aquí; Wald admite problemas secuenciales, pero no son la construcción de un paso. 5 min.

VOCABULARIO

Dos usos de «inferencia»

Inferencia estadística: aprender un objetivo desconocido con datos y cuantificar incertidumbre.

Ejecución de un modelo entrenado: producir una salida, con costo, memoria y latencia.

Una ejecución exacta no demuestra que la conclusión estadística sea válida.

Notas docentes · Pedir un ejemplo de mejora de latencia que cambie la política ejecutada. 5 min.

CASO FINITO

Datos y verdad de referencia

$\Theta = \{\frac{1}{5}, \frac{4}{5}\}$, $X \sim \text{Bernoulli}(\theta)$ y acciones $a \in \{0, 1\}$.

La clase verdadera es $g(\theta) = 0$ para $\theta = \frac{1}{5}$ y $g(\theta) = 1$ para $\theta = \frac{4}{5}$.

Pérdida de clasificación: $L(\theta, a) = 1$ si $a \neq g(\theta)$; cero en otro caso.

Notas docentes · Ejemplo didáctico de clasificación terminal, separado del SSCH. Solicitar que escriban Pθ(X=0) y Pθ(X=1). 4 min.

La regla utiliza solo X

Definimos $\delta(x) = x$ para $x \in \{0, 1\}$.

Si $X = 0$, elegimos $a = 0$; si $X = 1$, elegimos $a = 1$.

La misma regla se usa bajo ambos modelos $\theta = \frac{1}{5}$ y $\theta = \frac{4}{5}$.

Notas docentes · Insistir: no cambiar la regla según θ. Eso sería observar el parámetro y alteraría el problema. 3 min.

Riesgo bajo θ=1/5

La acción correcta es 0; la regla se equivoca si $X = 1$.

$$R\left(\tfrac{1}{5}, \delta\right) = P_{\frac{1}{5}}(X = 1) = \tfrac{1}{5}.$$

No se promedia sobre el modelo alternativo: el riesgo se evalúa en un θ fijo.

Notas docentes · Pedir calcular desde la suma de la diapositiva 6. Dos términos, solo uno no nulo. 4 min.

Riesgo bajo θ=4/5

La acción correcta es 1; la regla se equivoca si $X = 0$.

$$R\left(\tfrac{4}{5}, \delta\right) = P_{\frac{4}{5}}(X = 0) = 1 - \tfrac{4}{5} = \tfrac{1}{5}.$$

El vector de riesgo de δ es $\left(\tfrac{1}{5}, \tfrac{1}{5}\right)$.

Notas docentes · Comparar con la regla constante cero: riesgos (0,1). El vector constante no domina a δ. 4 min.

Construir el MDP terminal

Para cada θ: $S_0 = X$ con ley P_θ; la política elige $a = \pi_\delta(X) = \delta(X)$.

Se recibe $r_\theta(x, a) = -L(\theta, a)$ y después se llega a un estado terminal de recompensa cero.

El estado inicial puede ser aleatorio aunque la transición posterior sea determinista.

Notas docentes · Dibujar en la pizarra X→acción→terminal. θ indexa la familia, no forma parte de la observación. 4 min.

Retorno en cada modelo

La política copiada obtiene recompensa -1 cuando clasifica mal y 0 cuando acierta.

$$J_{\frac{1}{5}}(\pi_\delta) = -\frac{1}{5}, \quad J_{\frac{4}{5}}(\pi_\delta) = -\frac{1}{5}.$$

Se promedia sobre $S_0 = X$ bajo el modelo correspondiente.

Notas docentes · Calcular los dos retornos antes de revelar. Distinguir J promediado de V condicionado en x. 4 min.

DEMOSTRACIÓN

Por qué Jθ=−Rθ

$$J_\theta(\pi_\delta) = \sum_x P_\theta(x) r_\theta(x, \delta(x))$$

$$= -\sum_x P_\theta(x) L(\theta, \delta(x)) = -R(\theta, \delta).$$

La igualdad vale para **cada** θ y **cada** regla de la clase construida.

Notas docentes · Marcar los pasos: misma ley inicial; copia de regla; signo de recompensa; horizonte de un paso. La prueba completa se retoma en clase 6. 5 min.

LÍMITE

Qué no demuestra esta igualdad

La correspondencia preserva el criterio de comparación de reglas en el modelo de una decisión.

No identifica el valor desde datos de otra política ni proporciona un intervalo.

Tampoco significa que la recompensa evaluativa sea observada después de actuar.

Notas docentes · Preguntar qué datos se necesitarían para estimar J de una política no ejecutada. No inferir transferencia de garantías de IC. 5 min.

PAUSA

Descanso de 15 minutos

Al volver: ¿por qué $J_\theta = -R(\theta, \delta)$ no demuestra que podamos estimar J_θ desde cualquier registro?

Notas docentes · Pausar quince minutos. Reanudar pidiendo una respuesta con las palabras «datos» e «identificación».

EXTENSIÓN

Ahora sí hay una decisión de observar

Modelo nuevo: $\theta \in \{0, 1\}$ con prior $P(\theta = 1) = \frac{1}{2}$.

Podemos decidir ahora con pérdida 0–1 o pagar c para recibir una señal Y y decidir después.

Solo se permite **una** observación adicional.

Notas docentes · Separar físicamente este ejemplo del MDP terminal anterior; ahora hay prior, mecanismo de observación y una decisión de parada. 4 min.

EXTENSIÓN

La señal tiene precisión 4/5

$$P(Y = \theta|\theta) = \tfrac{4}{5}, \quad P(Y \neq \theta|\theta) = \tfrac{1}{5}.$$

El mismo mecanismo se aplica bajo $\theta = 0$ y $\theta = 1$.

Antes de observar, $P(Y = 1) = P(Y = 0) = \tfrac{1}{2}$.

Notas docentes · Calcular la probabilidad predictiva por mezcla de los dos modelos. 4 min.

EXTENSIÓN

Si paramos ahora

Con prior simétrico y pérdida 0–1, cualquiera de las dos acciones terminales tiene riesgo Bayes:

$$W_0(b) = \min\{P(\theta = 0), P(\theta = 1)\} = \tfrac{1}{2}.$$

El empate se resuelve con una regla declarada.

Notas docentes · Escribir el posterior antes de observar: b=(1/2,1/2). No llamar a esto riesgo frecuentista uniforme. 4 min.

EXTENSIÓN

Posterior después de Y

Si $Y = 1$:

$$P(\theta = 1 | Y = 1) = \frac{\left(\frac{1}{2}\right)\left(\frac{4}{5}\right)}{\frac{1}{2}} = \frac{4}{5}.$$

Si $Y = 0$, por simetría $P(\theta = 1 | Y = 0) = \frac{1}{5}$.

La acción terminal sigue el valor más probable de θ.

Notas docentes · Mostrar numerador y denominador; pedir reconstruir Y=0 antes de exponer la simetría. 5 min.

EXTENSIÓN

Riesgo posterior tras observar

En ambos valores posibles de Y, la menor probabilidad posterior de error es $\frac{1}{5}$.

Como $P(Y=0)=P(Y=1)=\frac{1}{2}$:

$$E_{Y[W_0(B(b,Y))]}=\left(\tfrac{1}{2}\right)\left(\tfrac{1}{5}\right)+\left(\tfrac{1}{2}\right)\left(\tfrac{1}{5}\right)=\tfrac{1}{5}.$$

Notas docentes · La esperanza es sobre la señal predictiva, no sobre un θ conocido. 4 min.

EXTENSIÓN

Costo bajo: conviene observar

Si $c = \frac{1}{10}$, el riesgo Bayes de observar y decidir es:

$$c + E_{Y[W_0(B(b,Y))]} = \frac{1}{10} + \frac{1}{5} = \frac{3}{10}.$$

Como $\frac{3}{10} < \frac{1}{2}$, la estrategia óptima observa.

Notas docentes · Pedir comparar la cifra con parar ahora. La conclusión es bayesiana para este prior, pérdida y horizonte. 4 min.

EXTENSIÓN

Costo alto: conviene parar

Si $c = \frac{2}{5}$, observar costaría:

$$\frac{2}{5} + \frac{1}{5} = \frac{3}{5} > \frac{1}{2}.$$

La mejor acción es detenerse y decidir con el prior.

La política de observación cambia aunque la precisión de Y permanezca fija.

Notas docentes · El costo se paga solo si se observa. Preguntar el valor crítico c*=3/10, porque 1/2−1/5=3/10. 4 min.

Recursión del riesgo restante

Para k observaciones posibles:

$$W_0(b) = \min_a \ell(b, a)$$

$$W_k(b) = \min\Big\{\min_a \ell(b, a), c + \sum_y m_b(y) W_{k-1}(B(b, y))\Big\}.$$

La decisión compara **parar** con **observar y continuar**.

Notas docentes · Derivar el caso k=1 con los números anteriores. El posterior b y k forman el estado; la prueba formal es por inducción. 6 min.

TALLER

Tarea: cambiar la precisión

Mantenga prior $\frac{1}{2}$ y pérdida 0–1, pero use señal correcta con probabilidad $\frac{7}{10}$.

1. Calcule el riesgo posterior esperado tras una observación.
2. Compare observar con parar para $c = \frac{1}{10}$ y $c = \frac{1}{4}$.
3. Escriba el umbral de costo para que observar mejore el riesgo.

Notas docentes · 45 minutos en equipos para diapositivas 30–31: 5 consigna, 25 cálculo, 15 cotejo y discusión. No usar resultados de la señal 4/5 sin recalcular. Fuente: misma recursión, parámetro cambiado.

SOLUCIÓN

Resultado del taller

Con precisión $\frac{7}{10}$, el error posterior mínimo es $\frac{3}{10}$.

Para $c = \frac{1}{10}$: $\frac{1}{10} + \frac{3}{10} = \frac{2}{5} < \frac{1}{2} \rightarrow$ observar.

Para $c = \frac{1}{4}$: $\frac{1}{4} + \frac{3}{10} = \frac{11}{20} > \frac{1}{2} \rightarrow$ parar.

Observar mejora si $c < \frac{1}{5}$; en el umbral hay empate.

Notas docentes · Solicitar que justifiquen la probabilidad predictiva 1/2 y el posterior 7/10 o 3/10. El riesgo posterior esperado es 3/10. Cerrar taller con comparación de dos costos.

DISCUSIÓN

Dos construcciones, dos alcances

Una decisión terminal: copia una regla dada y conserva $J_\theta = -R(\theta, \delta)$ para cada modelo.

Observación y parada: optimiza sobre si comprar información; necesita prior, q_θ, costo y horizonte.

La segunda no se obtiene gratis de la primera.

Notas docentes · 20 minutos de discusión: pedir que cada equipo enumere la información adicional exigida para observación/parada.

DISCUSIÓN

¿Qué no se transfirió?

El cálculo de $J = -R$ no aportó:

1. un mecanismo para registrar recompensas observables;
2. soporte para evaluar acciones no elegidas;
3. una distribución muestral para construir un IC.

Cada resultado inferencial exige su propio diseño y sus hipótesis.

Notas docentes · Pedir una condición para OPE y otra para un IC. Respuestas esperadas: overlap y control de varianza/unidad muestral, respectivamente.

DISCUSIÓN

Ejecutar un modelo no es estimar un valor

Un sistema puede producir una acción en milisegundos y ejecutar correctamente su código.

Eso no demuestra que V^{π} esté identificado, estimado sin sesgo o cubierto por un intervalo.

Una mejora de latencia puede cambiar la política; habría que comprobarlo.

Notas docentes · Utilizar los dos sentidos de inferencia del capítulo 1. Pedir un ejemplo de cambio de implementación que altere probabilidades de acción.

COMPROBACIÓN

Clasifique estas tres afirmaciones

A. «En el MDP terminal, $J_\theta(\pi_\delta) = -R(\theta, \delta)$».

B. «Con $c = \frac{1}{10}$ y señal $\frac{4}{5}$, conviene observar bajo el prior fijado».

C. «Un IC para J tendrá cobertura 95 % en un registro real».

¿Qué hipótesis y evidencia sostienen cada una?

Notas docentes · A: teorema con condiciones de construcción; B: cálculo Bayes específico; C: no se deduce, requiere diseño, estimador y condiciones de inferencia. 5 min.

CIERRE

Tres ideas para la clase siguiente

1. El **riesgo** evalúa reglas bajo modelos posibles.
2. Bellman añade transiciones y consecuencias futuras.
3. La identidad de un paso conserva una comparación, no toda garantía.

Siguiente clase: riesgo, Bayes, minimax y admisibilidad de Wald.

Notas docentes · 10 minutos con la comprobación anterior. Lectura previa: cap. 2, secciones de riesgo y Bayes.

RESPALDO

La posterior en dos líneas

Con prior $\frac{1}{2}$ y señal correcta q:

$$P(Y=1) = \left(\tfrac{1}{2}\right)q + \left(\tfrac{1}{2}\right)(1-q) = \tfrac{1}{2}.$$

$$P(\theta = 1 | Y = 1) = \frac{\left(\frac{1}{2}\right)q}{\frac{1}{2}} = q.$$

Para $Y = 0$, la posterior de $\theta = 1$ es $1 - q$.

Notas docentes · Respaldar la solución del taller sin usar fórmulas memorizadas. Fuente: Bayes y modelo del ejemplo.

RESPALDO

Prueba por inducción del paso Bellman

Base: con $k = 0$, solo queda elegir a y pagar $\ell(b, a)$.

Paso: con $k > 0$, o se decide ya o se paga c, se observa y con probabilidad $m_b(y)$ y queda el problema óptimo de $k - 1$.

El mínimo de las dos alternativas da $W_k(b)$.

Notas docentes · Prueba esquemática para el modelo finito; la fuente completa está en el apéndice de demostraciones.

RESPALDO

Tres reglas en el caso finito

Regla	$R\left(\frac{1}{5}, \delta\right)$	$R\left(\frac{4}{5}, \delta\right)$
$\delta(x) = x$	$\frac{1}{5}$	$\frac{1}{5}$
$\delta(x) = 0$	0	1
$\delta(x) = 1$	1	0

Ninguna de las constantes domina a $\delta(x) = x$.

Notas docentes · El propósito es visualizar que el riesgo es un vector sobre Θ. La clase 3 definirá dominancia formal.

RESPALDO

Falta de soporte: un contraejemplo

Si la política de registro nunca elige $a = 1$, los datos no contienen recompensas de esa acción.

Dos entornos pueden producir el mismo registro bajo $a = 0$ y asignar valores distintos a $a = 1$.

Por ello el valor de una política que elige $a = 1$ no queda identificado solo por ese registro.

Notas docentes · No confundir este problema con la identidad J=−R, que es una igualdad dentro de modelos dados.

RESPALDO

Fuentes para continuar

Wald (1950): Statistical Decision Functions.

Bellman (1957): Dynamic Programming.

Libro local: capítulos 1, 2, 3 y 5; prueba detallada en apéndice A.

Cada cita concreta debe cotejarse con su entrada en `referencias.bib`.

Notas docentes · Diapositiva de consulta. Las referencias se toman de las claves bibliográficas del manuscrito, sin citas textuales directas.