APERTURA

Procesos de decisión de Markov

Clase de tres horas · libro de inferencia estadística y agentes.

Objetivo: distinguir resultado, hipótesis y alcance de cada aplicación.

Resultados de aprendizaje

Escribir Bellman; resolver un MDP pequeño; acotar error por residuo.

Tres resultados observables para esta clase.

RUTA

Plan de la sesión

15 min motivación · 45 min conceptos · 30 min ejemplo · 15 min descanso.

45 min taller · 20 min discusión · 10 min síntesis = 180 min.

CONCEPTO 1

MDP

Un MDP fija estados, acciones, transición y recompensa.

Condición o contexto: Declarar horizonte o descuento γ.

EJEMPLO 1

Ejemplo: un estado

Una sola acción, recompensa 1 por paso y descuento $\gamma = 0{,}9$.

Bellman: $V = 1 + 0{,}9V$.

EJERCICIO 1

MDP · comprobar

¿Qué falta si solo conocemos recompensas?

Trabajar en parejas; justificar cada paso.

SOLUCIÓN 1

MDP · respuesta

La dinámica de transición y el criterio temporal.

Límite: Un MDP mal especificado cambia la política.

CONCEPTO 2

Política

$\pi(a|s)$ da la acción condicional al estado.

Condición o contexto: Distinguir política determinista y estocástica.

EJEMPLO 2

Resolver Bellman

$V = 1/(1-0{,}9) = 10$.

Desde $V_0 = 0$: $V_1 = 1$; $V_2 = 1{,}9$; $V_3 = 2{,}71$.

EJERCICIO 2

Política · comprobar

¿Una tabla de acciones por estado define π?

Trabajar en parejas; justificar cada paso.

SOLUCIÓN 2

Política · respuesta

Sí, si cubre todos los estados relevantes.

Límite: Estados no observados requieren una regla definida.

CONCEPTO 3

Valor

$V\pi(s)=E\pi[\Sigma\ y\hat{}t\ r_t \mid S_0=s]$.

Condición o contexto: El valor depende de estado inicial y política.

EJEMPLO 3

Error de iteración

Si el residuo es $\varepsilon = \|TV - V\|_\infty$, entonces $\|V - V^*\|_\infty \leq \varepsilon/(1-\gamma)$.

Con $\varepsilon = 0{,}01$ y $\gamma = 0{,}9$, cota de error 0,1.

EJERCICIO 3

Valor · comprobar

¿Por qué no promediar estados sin pesos?

Trabajar en parejas; justificar cada paso.

SOLUCIÓN 3

Valor · respuesta

Hay que usar la distribución inicial relevante.

Límite: El descuento altera prioridades temporales.

CONCEPTO 4

Bellman

$$V\pi(s)=\Sigma a\ \pi(a|s)[r(s,a)+\gamma\Sigma s' P(s'|s,a)V\pi(s')].$$

Condición o contexto: Modelo conocido y recompensa integrable.

ALCANCE 4

Bellman · condición crítica

Modelo conocido y recompensa integrable.

Si falla: Si $\gamma=1$ se necesitan condiciones adicionales.

EJERCICIO 4

Bellman · comprobar

¿Qué representa el segundo término?

Trabajar en parejas; justificar cada paso.

SOLUCIÓN 4

Bellman · respuesta

Valor esperado de la continuación descontada.

Límite: Si $\gamma=1$ se necesitan condiciones adicionales.

PAUSA

Descanso

Quince minutos antes de pasar a aplicaciones y límites.

Reanudar con una pregunta de recuperación sobre las primeras cuatro ideas.

CONCEPTO 5

Contracción

Con $\gamma<1$, el operador de Bellman descontado contrae en supremo.

Condición o contexto: Usar espacio acotado y transiciones válidas.

ALCANCE 5

Contracción · condición crítica

Usar espacio acotado y transiciones válidas.

Si falla: No trasladarla sin verificar y y operador.

EJERCICIO 5

Contracción · comprobar

¿Qué garantiza la contracción?

Trabajar en parejas; justificar cada paso.

SOLUCIÓN 5

Contracción · respuesta

Un punto fijo único y convergencia iterativa.

Límite: No trasladarla sin verificar γ y operador.

CONCEPTO 6

Value iteration

Repetir V_{k+1}=TV_k aproxima V*.

Condición o contexto: Guardar tolerancia y residuo de Bellman.

ALCANCE 6

Value iteration · condición crítica

Guardar tolerancia y residuo de Bellman.

Si falla: La cota depende de y.

EJERCICIO 6

Value iteration · comprobar

¿Por qué no parar solo por 100 iteraciones?

Trabajar en parejas; justificar cada paso.

SOLUCIÓN 6

Value iteration · respuesta

El número no certifica error; medir residuo.

Límite: La cota depende de γ.

CONCEPTO 7

Policy iteration

Alterna evaluación y mejora de política.

Condición o contexto: En MDP finito, comparar acciones por Q.

ALCANCE 7

Policy iteration · condición crítica

En MDP finito, comparar acciones por Q.

Si falla: La evaluación aproximada introduce error.

EJERCICIO 7

Policy iteration · comprobar

¿Qué se evalúa antes de mejorar?

Trabajar en parejas; justificar cada paso.

SOLUCIÓN 7

Policy iteration · respuesta

El valor de la política actual.

Límite: La evaluación aproximada introduce error.

CONCEPTO 8

Exploración

Los datos dependen de la política que actúa.

Condición o contexto: Separar planificar con modelo y aprender del entorno.

ALCANCE 8

Exploración · condición crítica

Separar planificar con modelo y aprender del entorno.

Si falla: Explorar tiene costo y restricciones.

EJERCICIO 8

Exploración · comprobar

¿Por qué explorar acciones poco elegidas?

Trabajar en parejas; justificar cada paso.

SOLUCIÓN 8

Exploración · respuesta

Para obtener información sobre sus resultados.

Límite: Explorar tiene costo y restricciones.

TALLER

Aplicación integrada

MDP: s_0 y terminal; $\gamma=0{,}9$. En s_0, a da $r=1$ y termina; b da $r=0$ y vuelve a s_0.

Desde $V_0=0$, calcular tres iteraciones y política codiciosa.

DISCUSIÓN

Auditoría entre pares

¿Qué parte falla si y=1 sin horizonte finito?

Defender la respuesta con hipótesis y evidencia.

SÍNTESIS

Tres preguntas de salida

El valor incluye futuro; Bellman necesita modelo; la cota de error requiere contracción.

Escribir una conclusión y un límite de aplicación.

PUENTE

Preparación de la clase siguiente

Revisar la fuente del capítulo y seleccionar un resultado que requiera otra herramienta.

Anotar el primer supuesto que habría que comprobar.

Trazabilidad

Fuente principal: libro local, capitulos/cap03_mdp.typ.

Material del curso; cifras empíricas solo si se reproduce el laboratorio.